FIQ

UNL . FACULTAD DE
INGENIERÍA QUÍMICA

APUNTES DE CLASE

Análisis Matricial

Licenciatura en Ciencia de Datos
Licenciatura en Matemática Aplicada

Liliana Forzani
Emilia Joerin
Pedro Morin
Pablo Quijano

Facultad de Ingeniería Química – UNL
Santa Fe, 25 de octubre de 2026

Índice general

1 Nociones de álgebra lineal **7**

1.1 Espacios vectoriales y subespacios . . . 7
1.1.1 Subespacios . . . 7
1.1.2 Combinaciones lineales, independencia y bases . . . 8
1.2 Transformaciones lineales y matrices . . . 8
1.2.1 De la transformación a la matriz . . . 9
1.3 Matrices: operaciones y vocabulario . . . 9
1.3.1 El espacio vectorial $\mathbb{R}^{m\times n}$ . . . 9
1.3.2 Traspuesta . . . 10
1.3.3 Matrices con nombre propio . . . 10
1.3.4 Traza . . . 10
1.3.5 El producto escalar y la norma euclídea . . . 11
1.3.6 El producto interno y la norma de Frobenius . . . 11
1.3.7 Lo que vamos a usar del determinante . . . 11
1.3.8 Matrices por bloques . . . 12
1.4 El producto de matrices: cuatro miradas . . . 12
1.4.1 Matriz por vector: combinación lineal de columnas . . . 12
1.4.2 Matriz por matriz: por columnas y por filas . . . 13
1.4.3 Matriz por matriz: suma de matrices de rango 1 . . . 13
1.5 Los cuatro subespacios fundamentales . . . 14
1.6 Rango y la factorización $A = CR$ . . . 15
1.6.1 El rango . . . 16
1.6.2 Los espacios nulos y el teorema de la dimensión . . . 16
1.7 La factorización $A = CMR$ . . . 18
1.8 Actualizaciones de rango uno . . . 19
1.9 Resumen de notación . . . 20

2 Eliminación gaussiana y la factorización LU **24**

2.1 El conjunto solución de $A\boldsymbol{x} = \boldsymbol{b}$ . . . 24
2.2 Interpretación por filas vs. Interpretación por columnas . . . 25
2.3 Eliminación gaussiana . . . 26
2.4 La factorización LU . . . 29
2.4.1 ¿Cuándo existe la factorización? ¿Es única? . . . 33
2.4.2 Las variantes LDU y LDL^T . . . 34
2.5 Conteo de operaciones . . . 35
2.5.1 Moraleja: nunca se calcula la inversa . . . 37
2.6 Factorización LU con pivoteo . . . 38
2.6.1 Por qué conviene el pivote más grande . . . 44

2.7 Eliminación por bloques y el complemento de Schur . . . 46
2.8 El caso general: forma escalonada reducida y la factorización CR . . . 47
2.8.1 La factorización LU en el caso singular . . . 48
2.9 Ejercicios . . . 49

3 Ortogonalidad 52
3.1 Vectores ortogonales . . . 53
3.2 Bases ortogonales y ortonormales . . . 55
3.3 Subespacios ortogonales en $\mathbb{R}^n$ con el producto interno usual . . . 56
3.4 Proyecciones ortogonales en $\mathbb{R}^n$ con el producto interno usual . . . 59
3.5 Ortogonalización de Gram-Schmidt con el producto interno usual en $\mathbb{R}^n$ . . . 64
3.6 Matrices reales ortogonales . . . 65
3.7 La factorización $A = QR$ . . . 71

4 Autovalores y autovectores 82
4.1 Definición y ejemplos . . . 82
4.2 Cálculo de autovalores y autovectores . . . 85
4.3 Propiedades de los autovalores y autovectores . . . 89
4.3.1 Traza y determinante de una matriz . . . 89
4.3.2 La traspuesta: A y A^T . . . 90
4.3.3 AB y BA . . . 90
4.3.4 Potencias y traslaciones de una matriz. . . . 91
4.3.5 Autovalores y autovectores de matrices simétricas y matrices ortogonales . . . 93
4.4 Matrices semejantes y diagonalización . . . 95
4.5 Autovalores de las matrices que ya conocemos . . . 101
4.6 Potencias y sistemas dinámicos . . . 102
4.7 El método de la potencia . . . 105
4.8 Ejercicios . . . 106

5 Schur y bases ortonormales de autovectores 110
5.1 El caso complejo: notación y matrices unitarias . . . 111
5.2 El teorema de Schur . . . 112
5.3 Matrices normales . . . 115
5.4 Los casos particulares importantes . . . 118
5.5 Una consecuencia cuantitativa: cuánto se “ve” en los autovalores . . . 121
5.6 Normal, diagonalizable, defectiva . . . 123
5.7 Ejercicios . . . 123

6 Matrices simétricas y definidas positivas 127
6.1 Matrices simétricas y definidas positivas (sdp) . . . 127
6.1.1 Tres ejemplos para tener a mano . . . 129
6.1.2 El complemento de Schur de una matriz sdp . . . 130
6.1.3 Las cinco caracterizaciones . . . 131

6.2 El cociente de Rayleigh 134
6.3 La raíz cuadrada de una matriz sdp 139
6.4 Factorización de Cholesky 140
6.5 La geometría: elipses y elipsoides 142
6.6 Formas cuadráticas, mínimos y el Hessiano 144

7 Distancias, normas y productos internos 150
7.1 Distancias 150
7.2 Normas 151
7.2.1 Las bolas unitarias 152
7.2.2 Normas equivalentes 153
7.2.3 Normas de matrices 154
7.2.4 ¿Toda distancia viene de una norma? 155
7.3 Productos internos 155
7.3.1 Todo el Capítulo 3, otra vez 156
7.3.2 ¿Toda norma viene de un producto interno? 157
7.4 Los productos internos de $\mathbb{R}^n$ son las matrices sdp 158
7.5 S-ortogonalidad 159
7.5.1 Cómo se ve la S-ortogonalidad 159
7.5.2 Ángulos, Gram-Schmidt y proyecciones 161
7.5.3 Resumen: el mismo capítulo dos veces 164

8 Descomposición en valores singulares (SVD) 167
8.1 Valores singulares y la norma espectral 167
8.2 La descomposición en valores singulares 170
8.2.1 La forma reducida 171
8.2.2 Un ejemplo completo 173
8.2.3 Algunos casos particulares 173
8.3 Demostración de la SVD 174
8.4 Lo que se lee en la SVD 175
8.4.1 Los cuatro subespacios fundamentales 175
8.4.2 Los vectores singulares de A^T 176
8.4.3 Una matriz simétrica que también da la SVD 176
8.4.4 A^TA y AA^T: los mismos valores singulares 176
8.5 La geometría: de la esfera al elipsoide 177
8.6 La descomposición polar 178
8.7 Las tres normas de la SVD 179
8.8 Lo que viene 180

9 Análisis de Componentes Principales (PCA) 185
9.1 Introducción 185
9.2 Lo que vamos a usar de las normas 186
9.3 La SVD truncada 187
9.4 El teorema de Eckart–Young 187
9.5 Un ejemplo: la foto del tigre 190
9.6 PCA: la mejor proyección de los datos 194

9.7 PCA como maximización de la varianza 196
9.7.1 Centrado 196
9.7.2 Covarianza muestral 197
9.7.3 Error de reconstrucción y varianza explicada 198
9.7.4 Máxima varianza y componentes no correlacionadas 198
9.7.5 Proporción de varianza explicada y elección de d 200
9.7.6 Geometría en el plano 200
9.7.7 La elipse de la nube 201
9.8 PCA en la práctica 202
9.8.1 PCA a mano 202
9.8.2 PCA en la computadora 203
9.8.3 Un ejemplo con muchas variables: las *eigenfaces* 203
Ejercicios 204
Trabajo práctico: SVD, imágenes y eigenfaces 209

10 PCA y clasificación 213
10.1 Introducción 213
10.2 La media de cada clase 214
10.3 La regla de la media más cercana 215
10.4 Entrenar y probar 216
10.5 Las unidades importan 217
10.6 PCA antes de clasificar 218
10.7 Lo que PCA no ve 219
Ejercicios 221
Práctica: clasificar con PCA 223

11 Análisis discriminante lineal (LDA) 225
11.1 Introducción 225
11.2 Dos clases: el cociente de Fisher 225
11.3 El cociente de Rayleigh generalizado 227
11.4 La dirección de Fisher, un caso particular 229
11.5 Clasificar con LDA 230
11.6 Más de dos clases 232
11.7 Otra aplicación: la diagonalización simultánea 234
Ejercicios 237
Práctica: LDA versus PCA 239

12 Normas de matrices 242
12.1 Normas matriciales 242
12.2 Normas inducidas 244
12.3 Espectro y radio espectral. 246
12.4 Número de condición y error relativo 250

13 Mínimos cuadrados y pseudoinversa 256
13.1 Cuándo tiene solución un sistema 256
13.1.1 La misma pregunta, leída con la SVD 256

13.2 El problema de mínimos cuadrados . . . 258
13.2.1 De dónde viene . . . 258
13.2.2 Existencia, y todas las soluciones . . . 258
13.2.3 La lectura geométrica . . . 259
13.3 Las ecuaciones normales . . . 259
13.4 Mínimos cuadrados con QR . . . 261
13.5 Por qué no se usan las ecuaciones normales . . . 261
13.6 La pseudoinversa . . . 262
13.7 Regresión lineal . . . 264
Ejercicios . . . 265

1 CAPÍTULO

Nociones de álgebra lineal

Muchos de los conceptos que utilizaremos en esta materia provienen del álgebra lineal básica. Este capítulo tiene tres objetivos. El primero es repasar, sin detenernos demasiado, las nociones que vamos a necesitar; el segundo es fijar la notación y el vocabulario que usaremos en todo el apunte; y el tercero, que es el más importante, es cambiar la forma de mirar una matriz. Al final del capítulo una matriz habrá dejado de ser una tabla de números para pasar a ser un objeto con *cuatro subespacios* asociados y una primera factorización, $A = CR$, que ya contiene casi toda la información que nos interesa.

Convenio. Salvo aviso explícito, todos los escalares son reales. El caso complejo aparecerá cuando lo necesitemos (Capítulos 3 y siguientes) y avisaremos en cada caso.

Sobre los ejercicios de desarrollo. A lo largo del apunte aparecen, dentro del texto, algunos recuadros titulados *Ejercicio de desarrollo*. No son ejercicios de práctica: son partes de la teoría cuya demostración queda a cargo del lector y que después usaremos con toda naturalidad. Se entregan por escrito.

1.1 Espacios vectoriales y subespacios

Un **espacio vectorial** sobre un cuerpo $\mathbb{F}$ (para nosotros, $\mathbb{R}$ o $\mathbb{C}$) es un conjunto V cuyos elementos llamamos **vectores**, en el que están definidas una suma y un producto por escalares que se comportan como uno espera: la suma es asociativa y conmutativa, tiene un neutro $\mathbf{0}$ y cada vector tiene su opuesto; el producto por escalares es asociativo, tiene al 1 como neutro y se distribuye respecto de ambas sumas. No vamos a usar estos axiomas directamente casi nunca: los necesitamos sólo para saber que tiene sentido hablar de combinaciones lineales.

Los espacios que efectivamente aparecerán en este curso son cuatro:

- $\mathbb{R}^n$ y $\mathbb{C}^n$, los vectores columna de n componentes;
- $\mathbb{R}^{m\times n}$, las matrices de m filas y n columnas;
- $\mathcal{P}_n$, los polinomios de grado menor o igual que n;
- los subespacios de los anteriores, que son el objeto central del capítulo.

1.1.1 Subespacios

Un subconjunto $S \subseteq V$ es un **subespacio** de V si

(i) $\mathbf{0} \in S$;

(ii) $\boldsymbol{x}, \boldsymbol{y} \in S \implies \boldsymbol{x} + \boldsymbol{y} \in S$;

(iii) $\boldsymbol{x} \in S,\ \alpha \in \mathbb{F} \implies \alpha\boldsymbol{x} \in S.$

Las condiciones (ii) y (iii) dicen que S es *cerrado* por las dos operaciones; junto con (i) garantizan que S, con las operaciones heredadas, es él mismo un espacio vectorial. Los ejemplos triviales son $\{\mathbf{0}\}$ y el propio V.

Sean U y W subespacios de V. La **suma**

$$U + W = \{\boldsymbol{u} + \boldsymbol{w} : \boldsymbol{u} \in U,\ \boldsymbol{w} \in W\}$$

y la **intersección** $U \cap W$ son también subespacios de V: la primera es el subespacio más chico que contiene a U y a W, y la segunda el más grande contenido en ambos. Si además $U \cap W = \{\mathbf{0}\}$, la suma se llama **suma directa** y se escribe $U \oplus W$; en ese caso cada vector de $U + W$ se escribe de manera **única** como $\boldsymbol{u} + \boldsymbol{w}$ con $\boldsymbol{u} \in U$ y $\boldsymbol{w} \in W$.

1.1.2 Combinaciones lineales, independencia y bases

Dados $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k \in V$ y escalares $\alpha_1, \dots, \alpha_k$, la expresión $\alpha_1\boldsymbol{v}_1 + \cdots + \alpha_k\boldsymbol{v}_k$ es una **combinación lineal** de los $\boldsymbol{v}_i$.

El conjunto $\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_k\}$ es **linealmente independiente** si la única combinación lineal que da el vector nulo es la trivial:

$$\sum_{i=1}^{k} \alpha_i \boldsymbol{v}_i = \mathbf{0} \quad \Longrightarrow \quad \alpha_i = 0 \ \text{ para todo } i.$$

Si no, los vectores son **linealmente dependientes**, y entonces al menos uno de ellos es combinación lineal de los demás.

El conjunto de *todas* las combinaciones lineales de $S = \{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$ es un subespacio de V, el **subespacio generado** por S:

$$\operatorname{span}(S) = \left\{ \sum_{i=1}^{k} \alpha_i \boldsymbol{u}_i \ :\ \alpha_i \in \mathbb{F} \right\}.$$

Una **base** de V es un conjunto linealmente independiente que genera V. Si $B = \{\boldsymbol{v}_1, \dots, \boldsymbol{v}_n\}$ es una base, todo $\boldsymbol{v} \in V$ se escribe de manera **única** como $\boldsymbol{v} = \alpha_1\boldsymbol{v}_1 + \cdots + \alpha_n\boldsymbol{v}_n$, y los escalares α_i se llaman **coordenadas** de $\boldsymbol{v}$ en la base B. Todas las bases de V tienen la misma cantidad de elementos; ese número es la **dimensión** $\dim(V)$. Por ejemplo $\dim \mathbb{R}^n = n$, con la base canónica

$$\boldsymbol{e}_1 = (1, 0, \dots, 0)^T, \quad \boldsymbol{e}_2 = (0, 1, \dots, 0)^T, \quad \dots, \quad \boldsymbol{e}_n = (0, 0, \dots, 1)^T.$$

1.2 Transformaciones lineales y matrices

Sean V y W espacios vectoriales sobre el mismo cuerpo. Una función $T : V \to W$ es una **transformación lineal** si respeta las dos operaciones:

$$T(\boldsymbol{u} + \boldsymbol{v}) = T(\boldsymbol{u}) + T(\boldsymbol{v}), \qquad T(\alpha\boldsymbol{v}) = \alpha\, T(\boldsymbol{v}),$$

o, equivalentemente, si "entra" por las combinaciones lineales: $T\big(\sum_i \alpha_i \boldsymbol{v}_i\big) = \sum_i \alpha_i T(\boldsymbol{v}_i)$.

En $\mathbb{R}^2$ son lineales la homotecia $T(x, y) = (2x, 2y)$ y la reflexión $T(x, y) = (x, -y)$; en $\mathcal{P}_n(\mathbb{R})$ lo es la derivación $D(p) = p'$. No es lineal $T(x, y) = (x + 1, y)$, porque $T(\mathbf{0}) = (1, 0) \neq \mathbf{0}$: toda transformación lineal manda el cero al cero.

Dos subespacios acompañan a cada transformación lineal: el **núcleo**

$$\ker(T) = \{\boldsymbol{v} \in V : T(\boldsymbol{v}) = \mathbf{0}_W\} \subseteq V$$

y la **imagen**

$$\mathrm{Im}(T) = \{T(\boldsymbol{v}) : \boldsymbol{v} \in V\} \subseteq W.$$

Por ejemplo, para $T : \mathbb{R}^3 \to \mathbb{R}^2$ con $T(x, y, z) = (x, y)$, el núcleo es el eje z y la imagen es todo $\mathbb{R}^2$.

1.2.1 De la transformación a la matriz

Como T es lineal, queda completamente determinada por lo que les hace a los vectores de una base: si sabemos calcular $T(\boldsymbol{v}_1), \ldots, T(\boldsymbol{v}_n)$, sabemos calcular T en cualquier vector. Esto es lo que permite reemplazar a T por una tabla de números.

Concretamente, tomemos $T : \mathbb{R}^n \to \mathbb{R}^m$ y las bases canónicas. La **matriz de** T es la matriz $A \in \mathbb{R}^{m\times n}$ cuya columna j es el vector $T(\boldsymbol{e}_j)$:

$$A = \begin{bmatrix} T(\boldsymbol{e}_1) & T(\boldsymbol{e}_2) & \cdots & T(\boldsymbol{e}_n) \end{bmatrix}, \qquad \text{y entonces} \qquad T(\boldsymbol{x}) = A\boldsymbol{x} \ \text{ para todo } \boldsymbol{x} \in \mathbb{R}^n.$$

Ejemplo 1.1. Sea $T(x_1, x_2) = (x_1 + x_2,\ 2x_1,\ x_1 - x_2)$. Como $T(1, 0) = (1, 2, 1)$ y $T(0, 1) = (1, 0, -1)$,

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 1 & -1 \end{bmatrix} \qquad \text{y en efecto} \qquad A \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} a + b \\ 2a \\ a - b \end{bmatrix} = T(a, b).$$

Observación 1.2 (Otras bases)**.** Nada obliga a usar las bases canónicas. Si B_V y B_W son bases cualesquiera de V y W, la columna j de la matriz de T es el vector de coordenadas de $T(\boldsymbol{v}_j)$ en la base B_W, y el producto matriz por vector sigue calculando las coordenadas de la imagen. Cambiar de base cambia la matriz pero no la transformación: dos matrices que representan la misma transformación en bases distintas se llaman *semejantes*, y las estudiaremos en el Capítulo 4. Hasta entonces trabajaremos siempre con las bases canónicas de $\mathbb{R}^n$ y $\mathbb{R}^m$, de modo que *transformación lineal* y *matriz* serán sinónimos.

Por último, la composición de transformaciones lineales corresponde al **producto** de matrices: si T tiene matriz A y S tiene matriz B (con las dimensiones compatibles), entonces $S \circ T$ tiene matriz BA. Esta es la verdadera razón de ser de la regla de multiplicación de matrices, que revisaremos en detalle en la Sección 1.4.

1.3 Matrices: operaciones y vocabulario

1.3.1 El espacio vectorial $\mathbb{R}^{m\times n}$

Una **matriz** es un arreglo rectangular de m filas y n columnas,

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m\times n},$$

y escribimos $(A)_{ij} = a_{ij}$. Notaremos

$$\text{fila}_i(A) = \begin{bmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \end{bmatrix} \in \mathbb{R}^{1\times n}, \qquad \text{col}_j(A) = \begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{bmatrix} \in \mathbb{R}^m.$$

Con la suma y el producto por escalares definidos entrada a entrada, $(A+B)_{ij} = a_{ij} + b_{ij}$ y $(\alpha A)_{ij} = \alpha a_{ij}$, el conjunto $\mathbb{R}^{m\times n}$ es un espacio vectorial de dimensión mn.

1.3.2 Traspuesta

La **traspuesta** de $A \in \mathbb{R}^{m\times n}$ es la matriz $A^T \in \mathbb{R}^{n\times m}$ dada por $(A^T)_{ij} = a_{ji}$: las filas de A son las columnas de A^T. Valen

$$(A^T)^T = A, \qquad (A+B)^T = A^T + B^T, \qquad \boxed{(AB)^T = B^T A^T},$$

y la última, que invierte el orden, se usará constantemente. Una matriz cuadrada es **simétrica** si $A^T = A$. Para cualquier $A \in \mathbb{R}^{m\times n}$, las matrices $A^T A \in \mathbb{R}^{n\times n}$ y $AA^T \in \mathbb{R}^{m\times m}$ son simétricas; volverán a aparecer en proyecciones, en cuadrados mínimos y en la SVD.

1.3.3 Matrices con nombre propio

- La **identidad** $I_n \in \mathbb{R}^{n\times n}$ tiene unos en la diagonal y ceros fuera; sus columnas son $\boldsymbol{e}_1, \ldots, \boldsymbol{e}_n$ y cumple $AI = A$, $IA = A$.
- A cuadrada es **invertible** (o no singular) si existe A^{-1} con $AA^{-1} = A^{-1}A = I$. La inversa, cuando existe, es única, y $(AB)^{-1} = B^{-1}A^{-1}$, $(A^{-1})^T = (A^T)^{-1}$.
- $D = \text{diag}(d_1, \ldots, d_n)$ es **diagonal** si $d_{ij} = 0$ para $i \neq j$. Multiplicar DA escala las *filas* de A y AD escala las *columnas*.
- A es **triangular superior** si $a_{ij} = 0$ para $i > j$, e **inferior** si $a_{ij} = 0$ para $i < j$. Son las protagonistas del Capítulo 2.
- Una matriz de **permutación** P tiene exactamente un 1 en cada fila y en cada columna y ceros en el resto; PA permuta las filas de A y $P^{-1} = P^T$.

1.3.4 Traza

La **traza** de una matriz cuadrada es la suma de su diagonal,

$$\text{tr}(A) = \sum_{i=1}^{n} a_{ii}.$$

Es lineal, $\text{tr}(A^T) = \text{tr}(A)$, y cumple la identidad $\text{tr}(AB) = \text{tr}(BA)$ cada vez que ambos productos tienen sentido (Ejercicio **1.9**), aunque $AB \neq BA$. La traza reaparecerá como suma de autovalores, como rango de una proyección y dentro de la norma de Frobenius.

1.3.5 El producto escalar y la norma euclídea

Antes de seguir conviene fijar las dos operaciones con las que se mide en $\mathbb{R}^n$, que usaremos desde acá en adelante. Dados $\boldsymbol{x} = (x_1, \dots, x_n)^T$ e $\boldsymbol{y} = (y_1, \dots, y_n)^T$, el **producto escalar** (o producto interno usual) y la **norma euclídea** son

$$\boldsymbol{x}^T\boldsymbol{y} \;=\; \sum_{i=1}^{n} x_i y_i, \qquad \|\boldsymbol{x}\| \;=\; \sqrt{\boldsymbol{x}^T\boldsymbol{x}} \;=\; \sqrt{x_1^2 + \cdots + x_n^2},$$

de modo que $\|\boldsymbol{x}\|$ es la longitud de $\boldsymbol{x}$ y $\|\boldsymbol{x} - \boldsymbol{y}\|$ la distancia entre los dos puntos. Diremos que $\boldsymbol{x}$ e $\boldsymbol{y}$ son **ortogonales** si $\boldsymbol{x}^T\boldsymbol{y} = 0$.

Por ahora no necesitamos más que eso. Las propiedades — la desigualdad de Cauchy-Schwarz, la desigualdad triangular, el ángulo entre dos vectores — se prueban en el Capítulo 3, y la noción general de norma y de producto interno, en el Capítulo 7.

1.3.6 El producto interno y la norma de Frobenius

Dijimos que $\mathbb{R}^{m\times n}$ es un espacio vectorial de dimensión mn. Nada impide entonces leer una matriz como un vector largo, apilando sus mn entradas, y copiar sobre las matrices el producto escalar y la norma que acabamos de definir en $\mathbb{R}^{mn}$. Eso da el **producto interno de Frobenius**

$$\langle A, B\rangle_F = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}b_{ij} = \operatorname{tr}(A^T B),$$

donde la segunda igualdad se comprueba observando que la entrada (j,j) de A^TB es $\sum_i a_{ij}b_{ij}$, y sumando en j. La **norma de Frobenius** es la longitud asociada,

$$\|A\|_F = \sqrt{\langle A, A\rangle_F} = \sqrt{\textstyle\sum_{i,j} a_{ij}^2} = \sqrt{\operatorname{tr}(A^T A)}$$

Ejemplo 1.3. Para $A = \left[\begin{smallmatrix} 1 & 2 \\ 0 & -2 \end{smallmatrix}\right]$ es $\|A\|_F = \sqrt{1+4+0+4} = 3$. Y en efecto $A^TA = \left[\begin{smallmatrix} 1 & 2 \\ 2 & 8 \end{smallmatrix}\right]$ tiene traza 9.

No hay nada profundo en esta definición — es la norma euclídea de siempre, con las entradas ordenadas de otra manera — pero la vamos a necesitar mucho antes de estudiar las normas en serio: aparece al medir cuánto se parecen dos matrices, que es la pregunta central de la aproximación de rango bajo. Las normas de vectores y de matrices en general se estudian en el Capítulo 7 y en el capítulo de normas de matrices.

1.3.7 Lo que vamos a usar del determinante

No repasaremos la construcción del determinante. Nos alcanzará con tres hechos, que suponemos conocidos: para $A, B \in \mathbb{R}^{n\times n}$,

$$\det(AB) = \det(A)\det(B), \qquad \det(A^T) = \det(A), \qquad \det(A) \neq 0 \iff A \text{ es invertible},$$

y la fórmula de la inversa de 2×2,

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad - bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

1.3.8 Matrices por bloques

A menudo conviene mirar una matriz partida en submatrices o **bloques**. Si las particiones son compatibles, el producto se calcula "como si los bloques fueran números", respetando el orden:

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}.$$

Los dos casos particulares que más usaremos son escribir una matriz por sus columnas o por sus filas,

$$A = \begin{bmatrix} \boldsymbol{a}_1 & \boldsymbol{a}_2 & \cdots & \boldsymbol{a}_n \end{bmatrix}, \qquad A = \begin{bmatrix} \text{fila}_1(A) \\ \vdots \\ \text{fila}_m(A) \end{bmatrix},$$

que es exactamente lo que hace posible la sección siguiente.

1.4 El producto de matrices: cuatro miradas

El producto AB está definido cuando el número de columnas de A coincide con el de filas de B: si $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$, entonces $AB \in \mathbb{R}^{m\times p}$ y

$$(AB)_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}.$$

Esta es la primera mirada, entrada a entrada. Es la que sirve para calcular a mano y la que menos dice. En lo que sigue veremos otras tres, que son las que usaremos para *pensar*.

Recordemos antes que el **producto escalar** (o producto punto) de $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^m$ es

$$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \sum_{j=1}^{m} x_j\, y_j = \boldsymbol{x}^T \boldsymbol{y} = \boldsymbol{y}^T \boldsymbol{x},$$

de modo que la entrada (i, j) de AB es el producto escalar de la fila i de A con la columna j de B:

$$(AB)_{ij} = \text{fila}_i(A)\ \text{col}_j(B).$$

1.4.1 Matriz por vector: combinación lineal de columnas

Sean $A \in \mathbb{R}^{m\times n}$ y $\boldsymbol{x} \in \mathbb{R}^n$. La regla usual dice

$$A\boldsymbol{x} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \end{bmatrix}. \tag{1.1}$$

Pero si en lugar de mirar entrada por entrada agrupamos por columnas, (1.1) se reescribe como

$$A\boldsymbol{x} = x_1 \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \end{bmatrix} + \cdots + x_n \begin{bmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{mn} \end{bmatrix},$$

es decir,

$$A\boldsymbol{x} \;=\; \sum_{j=1}^{n} x_j \;\mathrm{col}_j(A) \tag{1.2}$$

En palabras: *$A\boldsymbol{x}$ es una combinación lineal de las columnas de A*, con las entradas de $\boldsymbol{x}$ como coeficientes. Esta frase, que parece inocente, es la que hace aparecer al espacio columna en la Sección 1.5.

Simétricamente, si $\boldsymbol{x} \in \mathbb{R}^m$, el producto $\boldsymbol{x}^T A$ es un vector fila que combina las *filas* de A:

$$\boldsymbol{x}^T A \;=\; \sum_{i=1}^{m} x_i \;\mathrm{fila}_i(A) \tag{1.3}$$

1.4.2 Matriz por matriz: por columnas y por filas

Consideremos dos matrices de 2×2,

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \qquad B = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}, \qquad AB = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} \end{bmatrix}.$$

Mirando el resultado por columnas se ve que la primera columna de AB es A por la primera columna de B, y lo mismo con la segunda.

Esto vale en general, y no sólo para matrices de 2×2. Sean $A \in \mathbb{R}^{m\times k}$ y $B \in \mathbb{R}^{k\times n}$. La entrada (i, j) de AB es $\sum_p a_{ip}b_{pj}$, que es también la componente i del vector $A\;\mathrm{col}_j(B)$; recorriendo i se obtiene la columna j entera. Es decir, para todo $j = 1, \ldots, n$,

$$\mathrm{col}_j(AB) \;=\; A\;\mathrm{col}_j(B) \tag{1.4}$$

o sea, *cada columna de AB es una combinación lineal de las columnas de A*, con coeficientes dados por la columna correspondiente de B. De manera completamente simétrica, mirando por filas, para todo $i = 1, \ldots, m$,

$$\mathrm{fila}_i(AB) \;=\; \mathrm{fila}_i(A)\,B \tag{1.5}$$

y *cada fila de AB es una combinación lineal de las filas de B*.

1.4.3 Matriz por matriz: suma de matrices de rango 1

Hay una tercera manera de agrupar los mismos términos, esta vez separando los sumandos:

$$AB = \begin{bmatrix} a_{11}b_{11} & a_{11}b_{12} \\ a_{21}b_{11} & a_{21}b_{12} \end{bmatrix} + \begin{bmatrix} a_{12}b_{21} & a_{12}b_{22} \\ a_{22}b_{21} & a_{22}b_{22} \end{bmatrix},$$

y cada bloque es el producto de una columna de A (2×1) por una fila de B (1×2):

$$AB = \begin{bmatrix} a_{11} \\ a_{21} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} \end{bmatrix} + \begin{bmatrix} a_{12} \\ a_{22} \end{bmatrix} \begin{bmatrix} b_{21} & b_{22} \end{bmatrix}. \tag{1.6}$$

Un producto de un vector columna por un vector fila se llama **producto externo** y se denota $\boldsymbol{x} \otimes \boldsymbol{y} = \boldsymbol{x}\boldsymbol{y}^T$:

$$\boldsymbol{x} \otimes \boldsymbol{y} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \begin{bmatrix} y_1 & y_2 & \cdots & y_m \end{bmatrix} = \begin{bmatrix} x_1y_1 & x_1y_2 & \cdots & x_1y_m \\ x_2y_1 & x_2y_2 & \cdots & x_2y_m \\ \vdots & \vdots & \ddots & \vdots \\ x_ny_1 & x_ny_2 & \cdots & x_ny_m \end{bmatrix}, \qquad (\boldsymbol{x} \otimes \boldsymbol{y})_{ij} = x_i y_j. \tag{1.7}$$

Todas sus columnas son múltiplos de $\boldsymbol{x}$, así que su espacio columna es la recta generada por $\boldsymbol{x}$: el producto externo tiene rango 1 si $\boldsymbol{x}$ e $\boldsymbol{y}$ son no nulos, y rango 0 si alguno es nulo. Cada sumando de (1.6) es entonces una matriz de rango 1.

Esto vale en general. Sean $A \in \mathbb{R}^{m\times k}$ y $B \in \mathbb{R}^{k\times n}$. Por la definición,

$$(AB)_{ij} = \sum_{p=1}^{k} a_{ip}b_{pj} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{ik}b_{kj},$$

y el término $a_{ip}b_{pj}$ es el producto de la componente i de la columna p de A por la componente j de la fila p de B; es decir, es la entrada (i, j) del producto externo $\mathrm{col}_p(A) \otimes \mathrm{fila}_p(B)^T$. Sumando en p:

$$AB \;=\; \sum_{p=1}^{k} \mathrm{col}_p(A)\ \mathrm{fila}_p(B) \tag{1.8}$$

El producto de matrices es una suma de k matrices de rango 1. Esta mirada es la que vuelve natural la pregunta central de la ciencia de datos con matrices: si AB es una suma de matrices de rango 1, ¿cuáles de esos sumandos concentran la información? Esa pregunta recorre el apunte y encuentra su respuesta definitiva en la SVD (Capítulo 8).

1.5 Los cuatro subespacios fundamentales

Ya sabemos que $A\boldsymbol{x}$ es una combinación lineal de las columnas de A. Al hacer variar $\boldsymbol{x}$ en todo $\mathbb{R}^n$ obtenemos *todas* las combinaciones lineales posibles, es decir, un subespacio de $\mathbb{R}^m$: el **espacio columna**

$$C(A) = \mathrm{Im}(A) = \{A\boldsymbol{x} : \boldsymbol{x} \in \mathbb{R}^n\} \subseteq \mathbb{R}^m.$$

En el otro extremo está lo que A destruye, el **espacio nulo** o núcleo,

$$N(A) = \ker(A) = \{\boldsymbol{x} \in \mathbb{R}^n : A\boldsymbol{x} = \boldsymbol{0}\} \subseteq \mathbb{R}^n.$$

Aplicando las mismas dos definiciones a A^T aparecen los otros dos: el **espacio fila** $C(A^T) \subseteq \mathbb{R}^n$, generado por las filas de A (que son las columnas de A^T), y el **espacio nulo izquierdo** $N(A^T) \subseteq \mathbb{R}^m$, formado por los $\boldsymbol{y}$ con $A^T\boldsymbol{y} = \boldsymbol{0}$, o equivalentemente $\boldsymbol{y}^T A = \boldsymbol{0}^T$ — de ahí el nombre.

Estos cuatro subespacios son el esqueleto de la matriz: dos viven en el espacio de partida $\mathbb{R}^n$ y dos en el de llegada $\mathbb{R}^m$, y entre los cuatro describen completamente qué hace A.

Observación 1.4 (Lo que falta de esta figura). Los cuatro subespacios no son cuatro objetos sueltos. Dentro de $\mathbb{R}^n$, el espacio fila y el espacio nulo son *perpendiculares* entre sí, y de

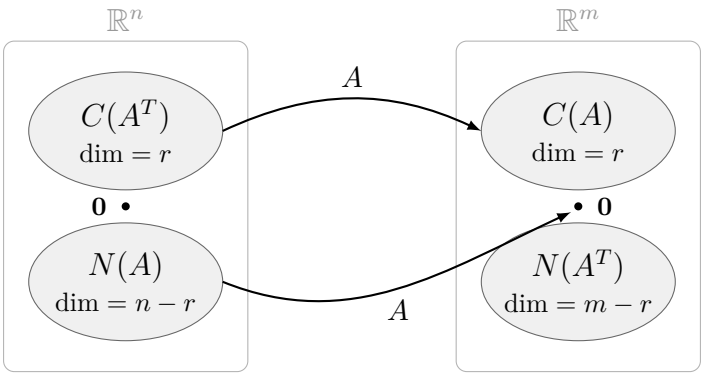


Figura 1.1. Los cuatro subespacios fundamentales de una matriz A de $m \times n$ y rango r. El espacio fila se transforma sobre el espacio columna; el espacio nulo se aplasta en el origen.

hecho cada uno es todo lo que le falta al otro para completar $\mathbb{R}^n$; lo mismo ocurre en $\mathbb{R}^m$ con el espacio columna y el nulo izquierdo. Para enunciarlo y demostrarlo con precisión necesitamos el producto interno y la noción de complemento ortogonal, así que lo dejamos para el Capítulo 3, donde probaremos que

$$N(A) = C(A^T)^\perp \qquad \text{y} \qquad N(A^T) = C(A)^\perp.$$

Por ahora nos concentramos en la otra mitad de la figura: las dimensiones.

1.6 Rango y la factorización $A = CR$

La pregunta natural es cuál es la dimensión de cada uno de los cuatro subespacios. Empecemos por el espacio columna: para conocer su dimensión hay que construir una base, y para eso alcanza con recorrer las columnas de A quedándonos sólo con las que aportan información nueva.

1. Si la primera columna de A no es nula, la ponemos como primera columna de una nueva matriz C (si es nula, la descartamos y seguimos).
2. Si la segunda columna de A no es múltiplo de la primera retenida, la agregamos a C.
3. Si la tercera no es combinación lineal de las ya retenidas, la agregamos a C.
4. Seguimos así hasta recorrer todas las columnas de A.

Al terminar, las r columnas de $C \in \mathbb{R}^{m \times r}$ son linealmente independientes por construcción y generan $C(A)$, porque las columnas descartadas eran combinación lineal de las retenidas. Es decir, las columnas de C son una base de $C(A)$ y

$$\dim C(A) = r.$$

¿Cómo se relacionan A y C? Cada columna $\boldsymbol{a}_j$ de A es combinación lineal de las columnas de C: existen coeficientes $r_{1j}, \dots, r_{rj}$ con

$$\boldsymbol{a}_j = r_{1j}\boldsymbol{c}_1 + \cdots + r_{rj}\boldsymbol{c}_r = C\boldsymbol{r}_j, \qquad \boldsymbol{r}_j = \begin{bmatrix} r_{1j} & \cdots & r_{rj} \end{bmatrix}^T \in \mathbb{R}^r.$$

Poniendo estos vectores uno al lado del otro y usando (1.4) para armar $R = \begin{bmatrix} \boldsymbol{r}_1 & \cdots & \boldsymbol{r}_n \end{bmatrix} \in \mathbb{R}^{r \times n}$, obtenemos la **descomposición** CR:

$$\boxed{A = CR}, \qquad C \in \mathbb{R}^{m \times r}, \quad R \in \mathbb{R}^{r \times n}.$$

Ejemplo 1.5. Para $A \in \mathbb{R}^{3\times 4}$,

$$A = \begin{bmatrix} 1 & 2 & 5 & 2 \\ 0 & 1 & 2 & 1 \\ 0 & 3 & 6 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 1 \end{bmatrix} = CR.$$

Las columnas retenidas son la 1 y la 2; la tercera es $\boldsymbol{a}_3 = \boldsymbol{a}_1 + 2\boldsymbol{a}_2$ y la cuarta es $\boldsymbol{a}_4 = \boldsymbol{a}_2$, y eso es exactamente lo que dicen las columnas 3 y 4 de R.

Observemos una consecuencia del procedimiento: como las columnas de C son columnas de A, cada una de ellas se expresa a sí misma en la base C mediante un vector canónico. Por lo tanto, *en las posiciones de R correspondientes a las columnas elegidas aparece la matriz identidad I_r* (en el Ejemplo 1.5, en las columnas 1 y 2). En particular las r filas de R son linealmente independientes.

Observación 1.6 (C y R no son únicas). El procedimiento elige las columnas independientes de izquierda a derecha, pero cualquier otra elección de r columnas independientes de A sirve igual y da otra factorización $A = CR$. En el Ejemplo 1.5 podríamos haber tomado las columnas 1 y 4. Esta libertad, lejos de ser un defecto, es lo que se explota en la Sección 1.7.

Observación 1.7 (Cómo se calcula en la práctica). El procedimiento de arriba es heurístico: dice qué hay que hacer, no cómo hacerlo de manera sistemática. La eliminación gaussiana del Capítulo 2 responde esa pregunta: las columnas retenidas son las columnas *pivote* de A, y R resulta ser la forma escalonada reducida por filas de A sin sus filas nulas.

1.6.1 El rango

La factorización $A = CR$ nos regala la dimensión del espacio fila. Trasponiendo,

$$A^T = R^T C^T. \tag{1.9}$$

Como R tiene r filas independientes, $R^T \in \mathbb{R}^{n\times r}$ tiene r columnas independientes, y (1.9) dice que las columnas de A^T — o sea las filas de A — son combinación lineal de ellas. Luego las filas de R son una base del espacio fila y

$$\dim C(A^T) = r.$$

Este número r, que cuenta simultáneamente las columnas independientes y las filas independientes de A, es el **rango** de A:

$$\boxed{\dim C(A) = \dim C(A^T) = \operatorname{rg}(A) = r}$$

Vale la pena detenerse en lo que acaba de pasar: aunque $C(A) \subseteq \mathbb{R}^m$ y $C(A^T) \subseteq \mathbb{R}^n$ viven en espacios ambientes de dimensiones distintas, tienen exactamente la misma dimensión interna. No hay ninguna razón evidente para que la cantidad de columnas independientes coincida con la de filas independientes, y sin embargo así es.

1.6.2 Los espacios nulos y el teorema de la dimensión

Con $A = CR$ también se obtienen las dimensiones de los espacios nulos, sin invocar ningún resultado externo.

Proposición 1.8. Si $A = CR$ con $C \in \mathbb{R}^{m\times r}$ de columnas linealmente independientes, entonces $N(A) = N(R)$.

Demostración. Si $R\boldsymbol{x} = \mathbf{0}$ entonces $A\boldsymbol{x} = C(R\boldsymbol{x}) = \mathbf{0}$, así que $N(R) \subseteq N(A)$. Recíprocamente, si $A\boldsymbol{x} = \mathbf{0}$, llamando $\boldsymbol{y} = R\boldsymbol{x} \in \mathbb{R}^r$ tenemos $C\boldsymbol{y} = \mathbf{0}$; pero $C\boldsymbol{y}$ es la combinación lineal de las columnas de C con coeficientes $\boldsymbol{y}$, y esas columnas son independientes, de modo que $\boldsymbol{y} = \mathbf{0}$, es decir $R\boldsymbol{x} = \mathbf{0}$. ∎

Teorema 1.9 (Teorema de la dimensión)**.** Para toda $A \in \mathbb{R}^{m\times n}$ de rango r,

$$\operatorname{rg}(A) + \dim N(A) = n, \qquad \text{esto es} \qquad \dim N(A) = n - r.$$

Demostración. Por la Proposición 1.8 alcanza con calcular $\dim N(R)$. Reordenando las columnas de A (lo que sólo reordena las de R y no cambia dimensiones) podemos suponer que las columnas elegidas para C son las primeras r, de modo que $R = \begin{bmatrix} I_r & R_2 \end{bmatrix}$ con $R_2 \in \mathbb{R}^{r\times(n-r)}$. Partiendo $\boldsymbol{x} = \left[\begin{smallmatrix} \boldsymbol{x}_1 \\ \boldsymbol{x}_2 \end{smallmatrix}\right]$ con $\boldsymbol{x}_1 \in \mathbb{R}^r$ y $\boldsymbol{x}_2 \in \mathbb{R}^{n-r}$,

$$R\boldsymbol{x} = \boldsymbol{x}_1 + R_2\boldsymbol{x}_2 = \mathbf{0} \iff \boldsymbol{x}_1 = -R_2\boldsymbol{x}_2.$$

Es decir, $\boldsymbol{x}_2$ es libre y $\boldsymbol{x}_1$ queda determinado: la aplicación $\boldsymbol{x}_2 \mapsto \left[\begin{smallmatrix} -R_2\boldsymbol{x}_2 \\ \boldsymbol{x}_2 \end{smallmatrix}\right]$ es un isomorfismo de $\mathbb{R}^{n-r}$ sobre $N(R)$. Luego $\dim N(A) = \dim N(R) = n - r$. ∎

Aplicando el mismo teorema a $A^T \in \mathbb{R}^{n\times m}$, cuyo espacio de partida es $\mathbb{R}^m$ y cuyo rango también es r, obtenemos $\dim N(A^T) = m - r$. Las cuatro dimensiones quedan entonces determinadas por tres números, m, n y r:

Subespacio	vive en	dimensión
Espacio columna $C(A)$	$\mathbb{R}^m$	r
Espacio fila $C(A^T)$	$\mathbb{R}^n$	r
Espacio nulo $N(A)$	$\mathbb{R}^n$	$n - r$
Espacio nulo izquierdo $N(A^T)$	$\mathbb{R}^m$	$m - r$

Ejercicio de desarrollo 1.1 | El rango de un producto y de una suma

Las desigualdades que siguen se usan en todo el apunte, casi siempre sin mencionarlas. Todas salen de mirar espacios columna; ninguna necesita coordenadas. En todos los ítems A y B tienen los tamaños que hacen falta para que las operaciones tengan sentido.

(a) Probar que $C(AB) \subseteq C(A)$ y que $C\big((AB)^T\big) \subseteq C(B^T)$. Deducir que

$$\operatorname{rg}(AB) \le \min\{\operatorname{rg}(A), \operatorname{rg}(B)\}.$$

Dar un ejemplo de matrices no nulas A, B con $AB = 0$.

(b) Probar que si B es invertible entonces $\operatorname{rg}(AB) = \operatorname{rg}(A)$, y que si A es invertible entonces $\operatorname{rg}(AB) = \operatorname{rg}(B)$. *Multiplicar por matrices invertibles no cambia el rango*: esto es lo que hace que la eliminación gaussiana, la semejanza y la SVD conserven el rango.

(c) Probar que $C(A+B) \subseteq C(A) + C(B)$ y deducir que

$$\operatorname{rg}(A+B) \leq \operatorname{rg}(A) + \operatorname{rg}(B).$$

Dar un ejemplo donde valga la igualdad y otro donde la desigualdad sea estricta.

(d) Probar que $N(A^TA) = N(A)$ y concluir que $\operatorname{rg}(A^TA) = \operatorname{rg}(A)$. *Sugerencia:* si $A^TA\boldsymbol{x} = \mathbf{0}$, multiplicar por $\boldsymbol{x}^T$ y reconocer $\|A\boldsymbol{x}\|^2$.

(e) Probar que $\operatorname{rg}(A) = r$ si y sólo si A se puede escribir como suma de r matrices de rango 1, y no de menos. *Sugerencia:* para una implicación usar (1.8) aplicada a $A = CR$; para la otra, el ítem (c).

(f) *(Desigualdad de Sylvester — opcional.)* Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$. Probar que

$$\dim N(AB) \;=\; \dim N(B) \;+\; \dim\Big(C(B) \cap N(A)\Big)$$

y deducir, usando el Teorema 1.9, que

$$\operatorname{rg}(AB) \;\geq\; \operatorname{rg}(A) + \operatorname{rg}(B) - n.$$

Verificar la fórmula en un ejemplo de 2×2 en el que la cota se alcance.

Se entrega por escrito. Los ítems (b), (d) y (e) se usan en los capítulos de ortogonalidad, de matrices simétricas y de la SVD respectivamente. El ítem (f) es opcional.

1.7 Columnas y filas de verdad: $A = CMR$

La descomposición $A = CR$ tiene una asimetría que conviene mirar de cerca. Las columnas de C son columnas *de* A: son datos originales. Las filas de R, en cambio, no son filas de A; son los coeficientes que reconstruyen A a partir de C. En el Ejemplo 1.5 las filas de R son $(1,0,1,0)$ y $(0,1,2,1)$, que no aparecen en ningún lado de A.

Cuando la matriz viene de datos, esa asimetría importa. Si las columnas de A son pacientes y las filas son genes, uno quisiera que *ambos* factores estén hechos de pacientes y de genes reales, no de combinaciones lineales abstractas de ellos. Esa es la idea de la factorización

$$A = C\,M\,\boldsymbol{R},$$

donde C contiene r columnas de A, $\boldsymbol{R}$ contiene r filas de A, y la matriz invertible $M \in \mathbb{R}^{r\times r}$, llamada **matriz de mezcla**, es la que hace que la igualdad sea cierta. Las factorizaciones QR y la SVD, que veremos más adelante, son numéricamente mucho mejores pero pagan un precio: sus factores están formados por vectores ortogonalizados, que ya no son datos.

Ejercicio de desarrollo 1.2 | La factorización $A = CMR$

Sea $A \in \mathbb{R}^{m\times n}$ de rango r. Sea $C \in \mathbb{R}^{m\times r}$ una matriz formada por r columnas linealmente independientes de A y sea $\boldsymbol{R} \in \mathbb{R}^{r\times n}$ una matriz formada por r filas linealmente independientes de A.

(a) Probar que C^TC y $\boldsymbol{R}\boldsymbol{R}^T$ son invertibles. *Sugerencia:* son de $r\times r$ y se puede

usar el ítem (d) de la entrega anterior.

(b) *(Existencia.)* Sea $A = CR$ la factorización de la Sección 1.6. Justificar que las filas de R pertenecen al espacio fila de A y que las filas de $\boldsymbol{R}$ son una base de ese espacio. Deducir que existe $M \in \mathbb{R}^{r\times r}$ con $R = M\boldsymbol{R}$, y por lo tanto

$$A = C\,M\,\boldsymbol{R}.$$

Probar además que M es invertible.

(c) *(Fórmula.)* Partiendo de $A = CM\boldsymbol{R}$, multiplicar por C^T a izquierda y por $\boldsymbol{R}^T$ a derecha y despejar

$$M = (C^TC)^{-1}\left(C^TA\,\boldsymbol{R}^T\right)(\boldsymbol{R}\,\boldsymbol{R}^T)^{-1}. \qquad (*)$$

Concluir que M es única.

(d) *(Rango 1.)* Verificar con $(*)$ que para $A = \left[\begin{smallmatrix}2 & 4\\ 3 & 6\end{smallmatrix}\right]$, tomando la primera columna y la primera fila, se obtiene $M = \left[\frac{1}{2}\right]$. Probar en general que si $A = \boldsymbol{u}\boldsymbol{v}^T$ es de rango 1 y se eligen la columna j y la fila i con $a_{ij} \neq 0$, entonces $M = \left[1/a_{ij}\right]$.

(e) *(Un caso de rango 2.)* Para

$$A = \begin{bmatrix}1 & 3 & 8\\ 1 & 2 & 6\\ 0 & 1 & 2\end{bmatrix},$$

tomar C con las columnas 1 y 2 y $\boldsymbol{R}$ con las filas 1 y 2. Calcular M con la fórmula $(*)$ y verificar que $A = CM\boldsymbol{R}$.

(f) *(Lo que la fórmula esconde.)* Sean $I = \{i_1, \ldots, i_r\}$ las filas de A elegidas para $\boldsymbol{R}$ y $J = \{j_1, \ldots, j_r\}$ las columnas elegidas para C, y sea $W \in \mathbb{R}^{r\times r}$ la submatriz de A que queda en el cruce de esas filas y columnas. Probar que

$$M = W^{-1}.$$

Sugerencia: quedarse con las filas I de los dos miembros de $A = CM\boldsymbol{R}$ y observar qué matriz es la formada por las filas I de $\boldsymbol{R}$. Verificarlo en el ítem (e). Discutir, a partir de esto, por qué al elegir las filas y columnas conviene que W esté lo más lejos posible de ser singular.

Se entrega por escrito. El ítem (f) explica por qué esta factorización, bajo el nombre de descomposición CUR*, se usa hoy para matrices grandes.*

1.8 Actualizaciones de rango uno

Cerramos el capítulo con una última aparición del producto externo, esta vez en un papel distinto. En muchas aplicaciones no se resuelve un problema una sola vez: se resuelve, llega un dato nuevo, y hay que volver a resolverlo con una matriz que difiere de la anterior en muy poco. Si ese "muy poco" es una matriz de rango 1 — agregar una observación,

corregir una entrada, quitar un dato del conjunto —, entonces no hace falta empezar de cero: la inversa se puede *actualizar*. La fórmula que hace eso se conoce como fórmula de Sherman–Morrison, y es sorprendentemente simple.

Ejercicio de desarrollo 1.3 | Actualizaciones de rango uno: Sherman–Morrison

Sea $A \in \mathbb{R}^{n\times n}$ invertible y sean $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$.

(a) Supongamos $1 + \boldsymbol{v}^T A^{-1}\boldsymbol{u} \neq 0$. Verificar, multiplicando directamente, que

$$\left(A + \boldsymbol{u}\boldsymbol{v}^T\right)^{-1} = A^{-1} - \frac{A^{-1}\boldsymbol{u}\,\boldsymbol{v}^T A^{-1}}{1 + \boldsymbol{v}^T A^{-1}\boldsymbol{u}}.$$

Sugerencia: el único truco es notar que $\boldsymbol{v}^T A^{-1}\boldsymbol{u}$ es un *número*, y que por lo tanto se puede mover libremente dentro del producto.

(b) Probar el recíproco: si $1 + \boldsymbol{v}^T A^{-1}\boldsymbol{u} = 0$, entonces $A + \boldsymbol{u}\boldsymbol{v}^T$ es singular. *Sugerencia:* exhibir un vector no nulo del espacio nulo usando $A^{-1}\boldsymbol{u}$.

(c) Contar operaciones: suponiendo que ya se conoce A^{-1}, ¿cuántas operaciones cuesta aplicar la fórmula del ítem (a)? Invertir $A + \boldsymbol{u}\boldsymbol{v}^T$ desde cero cuesta del orden de n^3 operaciones.

(d) Probar que $\operatorname{rg}(A + \boldsymbol{u}\boldsymbol{v}^T)$ y $\operatorname{rg}(A)$ difieren en a lo sumo 1 (usar el ítem (c) del Ejercicio de desarrollo 1.1). Dar ejemplos de los tres casos posibles: que el rango suba, que baje, y que no cambie.

(e) *(Para pensar, sin cuentas.)* En un modelo lineal se trabaja con la matriz $A = X^T X$, donde cada fila de X es una observación. Si se quita una observación $\boldsymbol{x}_i$, la nueva matriz es $A - \boldsymbol{x}_i\boldsymbol{x}_i^T$. Explicar por qué los ítems anteriores permiten recalcular el modelo sin la observación i para cada i, a un costo mucho menor que rehacer todo n veces.

Se entrega por escrito. El ítem (e) es la base de la validación cruzada leave-one-out*; la fórmula del ítem (a) reaparece cada vez que hay que actualizar un modelo con datos nuevos.*

1.9 Resumen de notación

A lo largo del apunte usaremos sistemáticamente lo siguiente.

$\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{v}$	vectores columna; $\boldsymbol{x}^T$ es un vector fila
$\boldsymbol{e}_i$	i-ésimo vector de la base canónica
$\mathbf{0}$	vector nulo (o matriz nula, según el contexto)
A, B, C	matrices; $a_{ij} = (A)_{ij}$
$\text{fila}_i(A),\ \text{col}_j(A)$	fila i y columna j de A
A^T	traspuesta; A^{-1}, inversa
I, I_n	matriz identidad
$\text{diag}(d_1, \ldots, d_n)$	matriz diagonal
$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^T \boldsymbol{y}$	producto escalar usual en $\mathbb{R}^n$
$\boldsymbol{x} \otimes \boldsymbol{y} = \boldsymbol{x}\boldsymbol{y}^T$	producto externo (matriz de rango ≤ 1)
$\text{span}(S)$	subespacio generado por S
$C(A) = \text{Im}(A)$	espacio columna
$N(A) = \ker(A)$	espacio nulo
$C(A^T)$, $N(A^T)$	espacio fila y espacio nulo izquierdo
$\text{rg}(A)$	rango
$\text{tr}(A)$	traza
$\langle A, B \rangle_F = \text{tr}(A^T B)$, $\|A\|_F$	producto interno y norma de Frobenius
$\dim V$	dimensión
$U \oplus W$, $V^\perp$	suma directa, complemento ortogonal (Cap. 3)

Ejercicios

1.1 Sean $\boldsymbol{u} \in \mathbb{R}^m$ y $\boldsymbol{v} \in \mathbb{R}^n$ dos vectores columna no nulos. Definimos la matriz $M = \boldsymbol{u}\boldsymbol{v}^T \in \mathbb{R}^{m \times n}$.

a) ¿Qué dirección tiene siempre el vector resultante $M\boldsymbol{x}$ para cualquier $\boldsymbol{x} \in \mathbb{R}^n$?

b) Deduzca a partir de lo anterior cuál es el espacio columna $C(M)$ y cuál es el espacio nulo $N(M)$.

1.2 Considere la matriz

$$M = \begin{bmatrix} 2 & -4 & 6 \\ 1 & -2 & 3 \\ -3 & 6 & -9 \end{bmatrix}.$$

a) Encuentre dos vectores $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^3$ tales que $M = \boldsymbol{x} \otimes \boldsymbol{y} = \boldsymbol{x}\boldsymbol{y}^T$.

b) Sin calcular $N(M)$ mediante eliminación gaussiana, argumente geométricamente por qué la imagen de esta matriz es una recta y halle la ecuación del plano que define a su espacio nulo $N(M)$.

1.3 Sean $\boldsymbol{c}_1, \boldsymbol{c}_2, \boldsymbol{c}_3 \in \mathbb{R}^m$ las tres columnas de una matriz $A \in \mathbb{R}^{m \times 3}$. Suponga que no conoce los elementos individuales de A, pero sabe que sus columnas son vectores no nulos.

a) Exprese mediante un producto matriz-vector de la forma $A\boldsymbol{x}$ el vector de salida $\boldsymbol{y} \in \mathbb{R}^m$ que resulta de realizar las siguientes operaciones:

i) Restar la segunda columna de la primera.

ii) Calcular el promedio de las tres columnas.

iii) Duplicar la primera columna y anular la tercera.

b) Si se sabe que las columnas de A satisfacen la relación lineal $\boldsymbol{c}_3 = 2\boldsymbol{c}_1 - \boldsymbol{c}_2$, encuentre un vector no nulo $\boldsymbol{x} \in \mathbb{R}^3$ tal que $A\boldsymbol{x} = \boldsymbol{0}$, sin calcular componentes individuales.

1.4 Dada una matriz arbitraria $X \in \mathbb{R}^{4\times n}$, cuyas filas denotamos por $\boldsymbol{f}_1, \boldsymbol{f}_2, \boldsymbol{f}_3, \boldsymbol{f}_4 \in \mathbb{R}^{1\times n}$, y sin realizar multiplicaciones componente a componente, construya la matriz $E \in \mathbb{R}^{4\times 4}$ tal que el producto EX produzca una nueva matriz cuyas filas sean:

a) la primera fila multiplicada por 2;

b) la segunda y la tercera fila intercambiadas entre sí;

c) la cuarta fila reemplazada por la diferencia $\boldsymbol{f}_4 - \boldsymbol{f}_1$.

1.5 Considere las matrices $A \in \mathbb{R}^{3\times 2}$ y $B \in \mathbb{R}^{2\times n}$, expresadas en función de sus columnas y filas respectivamente:

$$A = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 0 & -1 \end{bmatrix}, \quad B = \begin{bmatrix} \boldsymbol{b}_1 \\ \boldsymbol{b}_2 \end{bmatrix},$$

donde $\boldsymbol{b}_1, \boldsymbol{b}_2 \in \mathbb{R}^{1\times n}$ son los dos renglones de B.

a) Escriba el producto $AB \in \mathbb{R}^{3\times n}$ como la suma de dos matrices de rango 1 utilizando el producto externo.

b) Si la segunda fila de B es nula, determine el rango de AB (asumiendo $\boldsymbol{b}_1 \neq \boldsymbol{0}$).

1.6 Sea $A \in \mathbb{R}^{m\times n}$ de rango r, cuya descomposición CR adopta la forma

$$A = C \begin{bmatrix} I_r & R_2 \end{bmatrix},$$

con $C \in \mathbb{R}^{m\times r}$ y $R_2 \in \mathbb{R}^{r\times(n-r)}$.

a) Particionando $A = \begin{bmatrix} A_1 & A_2 \end{bmatrix}$, con $A_1 \in \mathbb{R}^{m\times r}$ y $A_2 \in \mathbb{R}^{m\times(n-r)}$, efectúe la multiplicación por bloques.

b) Deduzca la relación exacta entre A_1 y C.

c) Exprese A_2 en términos de C y R_2.

1.7 Considere la matriz

$$A = \begin{bmatrix} 1 & 3 & 2 & 0 \\ 2 & 6 & 4 & 1 \\ 0 & 0 & 0 & 2 \end{bmatrix} \in \mathbb{R}^{3\times 4}.$$

a) Aplique el procedimiento de la Sección 1.6 para obtener la matriz C.

b) Deduzca R resolviendo $A = CR$ columna por columna, interpretando cada columna de R como las coordenadas de la columna correspondiente de A en la base C.

c) Verifique que I_r aparece incrustada en las columnas correspondientes de R.

1.8 Sea $A \in \mathbb{R}^{m\times n}$ de rango r.

a) Considere $B = \begin{bmatrix} A & A \end{bmatrix} \in \mathbb{R}^{m\times 2n}$. Exprese $B\boldsymbol{x}$ por bloques para $\boldsymbol{x} = \left[\begin{smallmatrix} \boldsymbol{x}_1 \\ \boldsymbol{x}_2 \end{smallmatrix}\right]$ y determine $\operatorname{rg}(B)$, $C(B)$ y $\dim N(B)$.

b) Considere ahora $D = \left[\begin{smallmatrix} A \\ A \end{smallmatrix}\right] \in \mathbb{R}^{2m\times n}$ y determine $\operatorname{rg}(D)$, $C(D)$ y $\dim N(D)$.

1.9 Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times m}$.

a) Probar que $\operatorname{tr}(AB) = \operatorname{tr}(BA)$, escribiendo ambos miembros como una doble suma.

b) Dar un ejemplo con $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ pero $AB \neq BA$.

c) Probar que $\operatorname{tr}(\boldsymbol{x}\boldsymbol{y}^T) = \boldsymbol{y}^T\boldsymbol{x}$ para $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$.

1.10 Dada una matriz cuadrada $P \in \mathbb{R}^{n\times n}$ que cumple $P^2 = P$ (se dice que P es *idempotente*):

a) Muestre que si $\boldsymbol{y} \in C(P)$, entonces $P\boldsymbol{y} = \boldsymbol{y}$.

b) Demuestre que cualquier $\boldsymbol{x} \in \mathbb{R}^n$ se descompone de forma única como

$$\boldsymbol{x} = P\boldsymbol{x} + (I - P)\boldsymbol{x},$$

donde $P\boldsymbol{x} \in C(P)$ y $(I - P)\boldsymbol{x} \in N(P)$. Es decir, $\mathbb{R}^n = C(P) \oplus N(P)$.

c) Usando el Ejercicio **1.9**, ¿qué relación sospecha entre $\operatorname{tr}(P)$ y $\operatorname{rg}(P)$? (La probaremos en el Capítulo 4.)

2 CAPÍTULO

Eliminación gaussiana y la factorización LU

Uno de los grandes problemas del álgebra lineal es resolver un sistema lineal $A\boldsymbol{x} = \boldsymbol{b}$. En este capítulo veremos que el método que todos conocemos — la eliminación gaussiana — no es sólo un algoritmo para despejar incógnitas: es, en realidad, una *factorización* de A. Esa es la idea que va a organizar el resto del apunte, porque todas las descomposiciones que veremos (LU, QR, $Q\Lambda Q^T$, $U\Sigma V^T$) responden al mismo esquema: escribir A como producto de matrices más simples y leer en esos factores la información que buscamos.

2.1 El conjunto solución de $Ax = b$

Antes de calcular conviene saber qué estamos buscando. Los cuatro subespacios del Capítulo 1 responden por completo las dos preguntas básicas sobre un sistema lineal: *¿tiene solución?* y *¿es única?*

La primera es inmediata si recordamos que $A\boldsymbol{x}$ recorre exactamente el espacio columna:

$$A\boldsymbol{x} = \boldsymbol{b} \text{ tiene solución } \iff \boldsymbol{b} \in C(A) \iff \operatorname{rg}\left(\begin{bmatrix} A & \boldsymbol{b} \end{bmatrix}\right) = \operatorname{rg}(A),$$

donde la última equivalencia dice que agregar $\boldsymbol{b}$ como columna no agranda el espacio columna. La segunda pregunta la responde el espacio nulo.

Teorema 2.1 (Estructura del conjunto solución)**.** Sea $A \in \mathbb{R}^{m\times n}$ y $\boldsymbol{b} \in \mathbb{R}^m$. Si $\boldsymbol{x}_p$ es una solución particular de $A\boldsymbol{x} = \boldsymbol{b}$, entonces el conjunto de todas las soluciones es

$$\{\boldsymbol{x}_p + \boldsymbol{z} \ : \ \boldsymbol{z} \in N(A)\},$$

un trasladado del espacio nulo. En particular la solución, cuando existe, es única si y sólo si $N(A) = \{\boldsymbol{0}\}$.

Demostración. Si $\boldsymbol{z} \in N(A)$ entonces $A(\boldsymbol{x}_p + \boldsymbol{z}) = A\boldsymbol{x}_p + A\boldsymbol{z} = \boldsymbol{b}$. Recíprocamente, si $A\boldsymbol{x} = \boldsymbol{b}$, entonces $A(\boldsymbol{x} - \boldsymbol{x}_p) = \boldsymbol{b} - \boldsymbol{b} = \boldsymbol{0}$, o sea $\boldsymbol{z} = \boldsymbol{x} - \boldsymbol{x}_p \in N(A)$ y $\boldsymbol{x} = \boldsymbol{x}_p + \boldsymbol{z}$. ∎

Un sistema lineal no tiene entonces "una" solución: tiene un conjunto solución que es vacío, un punto, o un trasladado de un subespacio de dimensión $n - r$. Las dos preguntas se contestan con dos números, $\operatorname{rg}(A)$ y $\dim N(A)$, y no hace falta resolver nada para saber la respuesta.

En este capítulo nos concentraremos en el caso más frecuente, el de una matriz A cuadrada *no singular*, donde el conjunto solución es siempre un único punto. Vale la

pena recordar las caracterizaciones equivalentes de esa situación: para $A \in \mathbb{R}^{n\times n}$ son equivalentes

1. Para todo $\boldsymbol{b} \in \mathbb{R}^n$ existe $\boldsymbol{x} \in \mathbb{R}^n$ tal que $A\boldsymbol{x} = \boldsymbol{b}$.
2. Si $A\boldsymbol{x} = \boldsymbol{b}$ tiene solución, esa solución es única.
3. Si $A\boldsymbol{x} = \boldsymbol{0}$, entonces $\boldsymbol{x} = \boldsymbol{0}$, es decir $N(A) = \{\boldsymbol{0}\}$.
4. Las columnas de A son linealmente independientes.
5. Las filas de A son linealmente independientes.
6. $\operatorname{rg}(A) = n$.
7. Existe $A^{-1} \in \mathbb{R}^{n\times n}$ tal que $AA^{-1} = A^{-1}A = I$.
8. $\det(A) \neq 0$.

(La equivalencia entre (4), (5) y (6) es el teorema del rango del capítulo anterior; las demás son el Teorema 2.1 leído en el caso $m = n$.) Al final del capítulo, en la Sección 2.8, volveremos al caso rectangular o singular, donde la eliminación produce la factorización CR que ya conocemos.

2.2 Interpretación por filas vs. Interpretación por columnas

Antes de pasar al problema de resolver un sistema de ecuaciones lineales, veamos cómo la reinterpretación del producto de matrices del capítulo anterior permite ver un mismo sistema $A\boldsymbol{x} = \boldsymbol{b}$ de dos maneras distintas. Las dos valen para cualquier tamaño: con $A \in \mathbb{R}^{m\times n}$, $\boldsymbol{x} \in \mathbb{R}^n$ y $\boldsymbol{b} \in \mathbb{R}^m$, cada una corresponde a una de las dos fórmulas (1.5) y (1.2) del Capítulo 1. Lo que haremos con 2×2 es sólo dibujarlas, porque en el plano se ven; el enunciado general va después de cada dibujo.

Por filas

Leer $A\boldsymbol{x}$ fila por fila, como en (1.5), convierte el sistema en m ecuaciones escalares, una por fila:

$$\operatorname{fila}_i(A)\,\boldsymbol{x} = b_i, \qquad i = 1, \ldots, m.$$

Cada una de esas ecuaciones es una condición sobre el punto $\boldsymbol{x} \in \mathbb{R}^n$, y el conjunto de puntos que la cumplen es un **hiperplano** de $\mathbb{R}^n$: una recta si $n = 2$, un plano si $n = 3$, y en general un objeto de dimensión $n - 1$. Resolver el sistema es entonces *intersecar los m hiperplanos*.

Con $m = n = 2$ esto se dibuja: el sistema es

$$\begin{cases} a_{11}x_1 + a_{12}x_2 = b_1, \\ a_{21}x_1 + a_{22}x_2 = b_2. \end{cases}$$

y cada ecuación es una recta del plano; la solución es el punto donde se cortan.

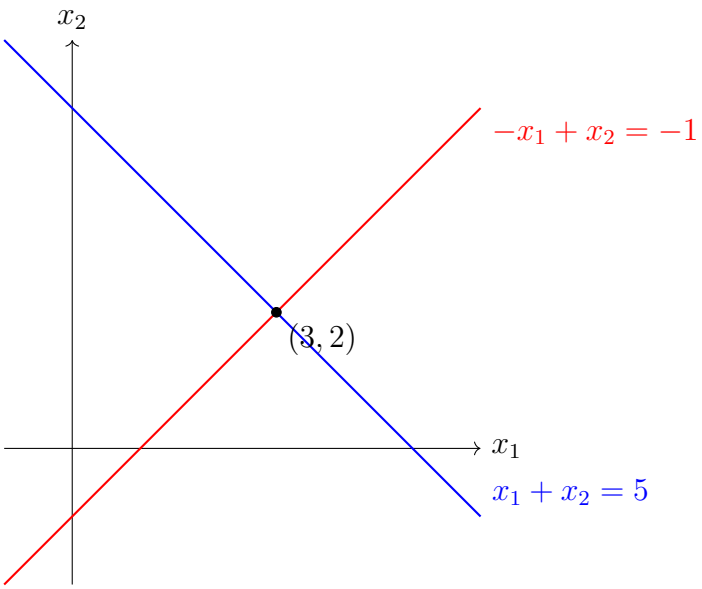


Figura 2.1. Intersección de las rectas $x_1 + x_2 = 5$ y $-x_1 + x_2 = -1$.

Por columnas

Leer $A\boldsymbol{x}$ por columnas, como en (1.2), da una pregunta de otra naturaleza. Allí vimos que $A\boldsymbol{x} = \sum_{j=1}^{n} x_j \operatorname{col}_j(A)$, de modo que el sistema $A\boldsymbol{x} = \boldsymbol{b}$ pide

$$x_1 \operatorname{col}_1(A) + x_2 \operatorname{col}_2(A) + \cdots + x_n \operatorname{col}_n(A) = \boldsymbol{b}\,:$$

¿se puede escribir $\boldsymbol{b}$ *como combinación lineal de las* n *columnas de* A*, y con qué coeficientes?* No hay nada que intersecar: hay que ver si $\boldsymbol{b}$ está al alcance de las columnas. Dicho de otra manera, el sistema tiene solución si y sólo si $\boldsymbol{b} \in C(A)$, y las soluciones son los vectores de coeficientes que lo logran.

De nuevo con $m = n = 2$, buscamos los escalares x_1, x_2 tales que

$$x_1 \begin{bmatrix} a_{11} \\ a_{21} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ a_{22} \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}.$$

es decir, estiramos cada columna por un escalar y pedimos que la suma de los dos vectores resultantes dé $\boldsymbol{b}$.

Las dos miradas describen el mismo conjunto solución, pero no sirven para lo mismo. La de filas es la que guía el *cálculo*: la eliminación gaussiana de la sección siguiente opera sobre las filas. La de columnas es la que guía la *teoría*: "$A\boldsymbol{x} = \boldsymbol{b}$ tiene solución si y sólo si $\boldsymbol{b} \in C(A)$" es un enunciado sobre subespacios, no sobre cuentas, y es el que seguiremos usando en todo el apunte. Conviene además notar que el dibujo de filas se vuelve inmanejable apenas n crece — nadie interseca cuatro hiperplanos de $\mathbb{R}^4$ mentalmente — mientras que el enunciado por columnas no cambia en nada al crecer el tamaño.

2.3 Eliminación gaussiana

Esta sección no desarrolla la teoría de la eliminación gaussiana: suponemos que el método ya se conoce del curso de álgebra lineal. Lo que hacemos es *un solo ejemplo, con todo el detalle*, por dos motivos.

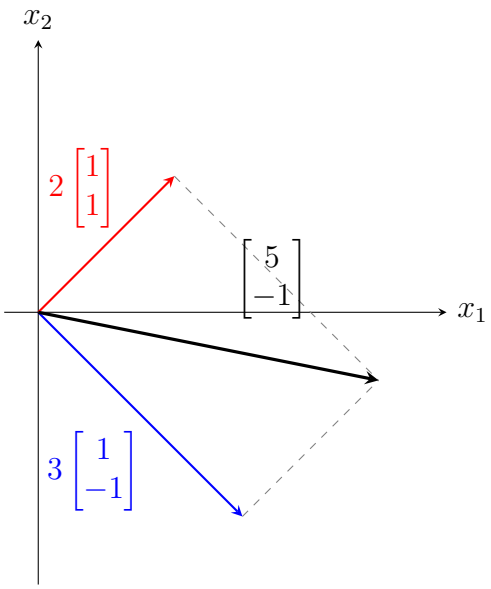


Figura 2.2. Suma de vectores: $3\begin{bmatrix}1\\-1\end{bmatrix}+2\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}5\\-1\end{bmatrix}$.

El primero es repasar el procedimiento y fijar el vocabulario — pivote, multiplicador, sustitución hacia atrás — que vamos a usar durante todo el capítulo.

El segundo es más importante, y conviene anunciarlo antes de empezar. En la sección siguiente vamos a construir la factorización LU de la *misma* matriz, y lo que se va a ver es que no hay ningún método nuevo: la factorización LU **es** esta eliminación, ejecutada paso por paso igual que acá, con una única diferencia. Al eliminar, cada multiplicador se usa una vez y se tira; para factorizar, cada multiplicador se *guarda* en el lugar de la matriz que acaba de anular. Esos números guardados son exactamente las entradas de L, y la matriz triangular con la que uno termina es U. Nada más. Conviene entonces leer el ejemplo que sigue prestando atención a los multiplicadores 2, 3, 5, 4, 6 y 7 que van apareciendo, porque son los que vamos a reencontrar, uno por uno, en la Sección 2.4.

Empecemos considerando el siguiente sistema de 4 incógnitas con 4 ecuaciones:

$$\begin{cases} 4x_1 - 5x_2 + 6x_3 - 2x_4 = 11 \\ 8x_1 - 8x_2 + 15x_3 - 8x_4 = 30 \\ 12x_1 - 7x_2 + 40x_3 - 31x_4 = 76 \\ 20x_1 - 13x_2 + 118x_3 - 93x_4 = 184 \end{cases}$$

Este sistema puede escribirse de forma matricial como $A\boldsymbol{x} = \boldsymbol{b}$, donde A es la matriz de coeficientes, $\boldsymbol{x}$ el vector de incógnitas y $\boldsymbol{b}$ el vector de términos independientes. Para aplicar la eliminación gaussiana resulta conveniente trabajar con la **matriz aumentada** $[A|\boldsymbol{b}]$, que agrupa la información de manera compacta:

$$\left[\begin{array}{cccc|c} 4 & -5 & 6 & -2 & 11 \\ 8 & -8 & 15 & -8 & 30 \\ 12 & -7 & 40 & -31 & 76 \\ 20 & -13 & 118 & -93 & 184 \end{array}\right]$$

Ahora vamos a tomar la primera fila y considerar el 4 de la posición $(1,1)$ como

elemento pivote. Elegimos un multiplicador adecuado para cada fila (de la segunda en adelante) de modo que, al sumarle ese múltiplo de la primera fila, se anule el elemento de la primera columna correspondiente.

Para la fila 2: el multiplicador es $\frac{8}{4} = 2$.
Para la fila 3: el multiplicador es $\frac{12}{4} = 3$.
Para la fila 4: el multiplicador es $\frac{20}{4} = 5$.

Hacemos entonces:

$$F_2 \leftarrow F_2 - 2F_1, \qquad F_3 \leftarrow F_3 - 3F_1, \qquad F_4 \leftarrow F_4 - 5F_1$$

y la matriz aumentada queda:

$$\left[\begin{array}{cccc|c} 4 & -5 & 6 & -2 & 11 \\ 0 & 2 & 3 & -4 & 8 \\ 0 & 8 & 22 & -25 & 43 \\ 0 & 12 & 88 & -83 & 129 \end{array}\right]$$

Ahora tomamos como pivote el elemento 2 de la posición $(2, 2)$. Los multiplicadores para anular los elementos debajo de él en la segunda columna son:

$$\text{Para } F_3 : \frac{8}{2} = 4, \qquad \text{Para } F_4 : \frac{12}{2} = 6$$

Realizamos:

$$F_3 \leftarrow F_3 - 4F_2, \qquad F_4 \leftarrow F_4 - 6F_2$$

y obtenemos:

$$\left[\begin{array}{cccc|c} 4 & -5 & 6 & -2 & 11 \\ 0 & 2 & 3 & -4 & 8 \\ 0 & 0 & 10 & -9 & 11 \\ 0 & 0 & 70 & -59 & 81 \end{array}\right]$$

El siguiente pivote es el 10 en la posición $(3, 3)$. El multiplicador para la cuarta fila es:

$$\text{Para } F_4 : \frac{70}{10} = 7$$

Efectuamos:

$$F_4 \leftarrow F_4 - 7F_3$$

y llegamos a la matriz triangular superior:

$$\left[\begin{array}{cccc|c} 4 & -5 & 6 & -2 & 11 \\ 0 & 2 & 3 & -4 & 8 \\ 0 & 0 & 10 & -9 & 11 \\ 0 & 0 & 0 & 4 & 4 \end{array}\right]$$

La matriz triangular superior que obtuvimos corresponde al sistema equivalente:

$$\begin{cases} 4x_1 - 5x_2 + 6x_3 - 2x_4 = 11 \\ 2x_2 + 3x_3 - 4x_4 = 8 \\ 10x_3 - 9x_4 = 11 \\ 4x_4 = 4 \end{cases}$$

Ahora resolvemos de abajo hacia arriba mediante **sustitución hacia atrás**. Comenzamos por la última ecuación, que ya tiene una sola incógnita, y vamos reemplazando los valores obtenidos en las ecuaciones anteriores.

- De la cuarta ecuación: $4x_4 = 4 \implies x_4 = 1$.
- Sustituimos $x_4 = 1$ en la tercera ecuación: $10x_3 - 9(1) = 11 \implies 10x_3 = 20 \implies x_3 = 2$.
- Sustituimos $x_3 = 2$ y $x_4 = 1$ en la segunda ecuación: $2x_2 + 3(2) - 4(1) = 8 \implies 2x_2 + 6 - 4 = 8 \implies 2x_2 = 6 \implies x_2 = 3$.
- Finalmente, sustituimos $x_2 = 3$, $x_3 = 2$ y $x_4 = 1$ en la primera ecuación: $4x_1 - 5(3) + 6(2) - 2(1) = 11 \implies 4x_1 - 15 + 12 - 2 = 11 \implies 4x_1 = 16 \implies x_1 = 4$.

Por lo tanto, la solución del sistema es:

$$\boxed{x_1 = 4, \quad x_2 = 3, \quad x_3 = 2, \quad x_4 = 1}$$

Antes de seguir, vale la pena mirar para atrás y hacer un inventario de lo que produjo esta cuenta. Por un lado quedó la matriz triangular superior del último paso, con los pivotes 4, 2, 10 y 4 en la diagonal. Por otro lado quedaron, desparramados en el camino y ya usados, los seis multiplicadores

$$\ell_{21} = 2, \quad \ell_{31} = 3, \quad \ell_{41} = 5, \qquad \ell_{32} = 4, \quad \ell_{42} = 6, \qquad \ell_{43} = 7,$$

donde ℓ_{ik} es el multiplicador que usamos para anular la entrada (i, k). Si tuviéramos que resolver otro sistema con la misma matriz A y otro término independiente, habría que volver a calcularlos todos. La sección que sigue muestra que no hace falta: guardándolos se obtiene $A = LU$, y con eso cada nuevo sistema sale con dos sustituciones y sin volver a eliminar.

2.4 La factorización LU

Ahora vamos a estudiar la factorización LU. La idea es expresar una matriz A como el producto LU, donde L es una matriz triangular inferior (del inglés *lower triangular*) y U es una matriz triangular superior (*upper triangular*). Veremos primero cómo la eliminación gaussiana nos proporciona un camino natural para construir esta factorización para luego ver las ventajas de conseguir estas matrices triangulares a la hora de resolver sistemas de ecuaciones.

Retomemos la matriz de coeficientes del ejemplo anterior:

$$A = \begin{bmatrix} 4 & -5 & 6 & -2 \\ 8 & -8 & 15 & -8 \\ 12 & -7 & 40 & -31 \\ 20 & -13 & 118 & -93 \end{bmatrix}$$

A partir de A construimos una nueva matriz formada de la siguiente manera: cada fila de esta nueva matriz es igual a la primera fila de A multiplicada por el multiplicador que usamos en el primer paso de la eliminación para anular la primera columna de esa fila. Es decir, la primera fila queda multiplicada por 1, la segunda por 2, la tercera por 3 y la cuarta por 5. Así obtenemos la matriz:

$$M_1 = \begin{bmatrix} 1\cdot(4) & 1\cdot(-5) & 1\cdot(6) & 1\cdot(-2) \\ 2\cdot(4) & 2\cdot(-5) & 2\cdot(6) & 2\cdot(-2) \\ 3\cdot(4) & 3\cdot(-5) & 3\cdot(6) & 3\cdot(-2) \\ 5\cdot(4) & 5\cdot(-5) & 5\cdot(6) & 5\cdot(-2) \end{bmatrix} = \begin{bmatrix} 4 & -5 & 6 & -2 \\ 8 & -10 & 12 & -4 \\ 12 & -15 & 18 & -6 \\ 20 & -25 & 30 & -10 \end{bmatrix}$$

Ahora restamos esta matriz de A:

$$A - M_1 = \begin{bmatrix} 4 & -5 & 6 & -2 \\ 8 & -8 & 15 & -8 \\ 12 & -7 & 40 & -31 \\ 20 & -13 & 118 & -93 \end{bmatrix} - \begin{bmatrix} 4 & -5 & 6 & -2 \\ 8 & -10 & 12 & -4 \\ 12 & -15 & 18 & -6 \\ 20 & -25 & 30 & -10 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 2 & 3 & -4 \\ 0 & 8 & 22 & -25 \\ 0 & 12 & 88 & -83 \end{bmatrix}$$

Observamos que el resultado es justamente la matriz que apareció debajo del primer renglón después de la primera etapa de eliminación, pero ahora con la primera fila completa de ceros. Más aún, si observamos la matriz M_1 vemos que es una matriz de rango uno que puede construirse multiplicando el vector columna de los multiplicadores (que llamaremos ℓ_1) por la primera fila de la matriz A (que llamaremos $u_1^\star$, esto es

$$M_1 = \ell_1 u_1^\star = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 5 \end{bmatrix} \begin{bmatrix} 4 & -5 & 6 & -2 \end{bmatrix},$$

por lo que

$$A = \ell_1 u_1^\star + A_2 = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 5 \end{bmatrix} \begin{bmatrix} 4 & -5 & 6 & -2 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 2 & 3 & -4 \\ 0 & 8 & 22 & -25 \\ 0 & 12 & 88 & -83 \end{bmatrix}.$$

Ahora repetimos la misma idea sobre la parte activa de la matriz A_2. Observemos que en A_2 la primera fila ya es nula y el trabajo de eliminación continuó a partir de la segunda fila. Los multiplicadores de la segunda etapa fueron 4 para la tercera fila y 6 para la cuarta (recordemos que los obtuvimos al dividir los elementos de la segunda columna por el pivote 2). Formamos entonces el vector columna ℓ_2, que tendrá un 1 en la posición del pivote y los multiplicadores debajo, y la fila pivote $u_2^\star$, que es justamente la segunda fila de A_2:

$$\ell_2 = \begin{bmatrix} 0 \\ 1 \\ 4 \\ 6 \end{bmatrix}, \qquad u_2^\star = \begin{bmatrix} 0 & 2 & 3 & -4 \end{bmatrix}.$$

Con estos construimos la matriz de rango 1 correspondiente al segundo paso de eliminación:

$$M_2 = \ell_2\, u_2^\star = \begin{bmatrix} 0 \\ 1 \\ 4 \\ 6 \end{bmatrix} \begin{bmatrix} 0 & 2 & 3 & -4 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 2 & 3 & -4 \\ 0 & 8 & 12 & -16 \\ 0 & 12 & 18 & -24 \end{bmatrix}.$$

Restamos M_2 de A_2:

$$A_2 - M_2 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 2 & 3 & -4 \\ 0 & 8 & 22 & -25 \\ 0 & 12 & 88 & -83 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 2 & 3 & -4 \\ 0 & 8 & 12 & -16 \\ 0 & 12 & 18 & -24 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 70 & -59 \end{bmatrix} \equiv A_3.$$

Así, A_2 se descompone como $A_2 = \ell_2 u_2^\star + A_3$, y por lo tanto

$$A = \ell_1 u_1^\star + \ell_2 u_2^\star + A_3.$$

Damos el último paso con la submatriz activa de A_3, que involucra las filas 3 y 4 a partir de la tercera columna. El multiplicador de la tercera etapa fue 7 para la cuarta fila (pivote 10). Definimos

$$\ell_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 7 \end{bmatrix}, \qquad u_3^\star = \begin{bmatrix} 0 & 0 & 10 & -9 \end{bmatrix},$$

y la matriz correspondiente es

$$M_3 = \ell_3\, u_3^\star = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 7 \end{bmatrix} \begin{bmatrix} 0 & 0 & 10 & -9 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 70 & -63 \end{bmatrix}.$$

Restamos M_3 de A_3:

$$A_3 - M_3 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 70 & -59 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 70 & -63 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \end{bmatrix} \equiv A_4,$$

donde A_4 ya tiene solo la última fila no nula, correspondiente al cuarto pivote.

Así, $A_3 = \ell_3 u_3^\star + A_4$, y juntando todo obtenemos

$$A = \ell_1 u_1^\star + \ell_2 u_2^\star + \ell_3 u_3^\star + A_4.$$

Observemos que A_4 puede escribirse como $\ell_4 u_4^\star$ con

$$\ell_4 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}, \qquad u_4^\star = \begin{bmatrix} 0 & 0 & 0 & 4 \end{bmatrix},$$

aunque en este caso no hay eliminación, simplemente es la última fila pivote y obtenemos:

$$A = \ell_1 u_1^\star + \ell_2 u_2^\star + \ell_3 u_3^\star + \ell_4 u_4^\star.$$

Ahora, las filas $u_1^\star, u_2^\star, u_3^\star, u_4^\star$ son exactamente las filas de la matriz triangular superior que obtuvimos al final de la eliminación. Si las apilamos formamos la matriz U:

$$U = \begin{bmatrix} u_1^\star \\ u_2^\star \\ u_3^\star \\ u_4^\star \end{bmatrix} = \begin{bmatrix} 4 & -5 & 6 & -2 \\ 0 & 2 & 3 & -4 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 0 & 4 \end{bmatrix}.$$

Por otro lado, si colocamos los vectores columna $\ell_1, \ell_2, \ell_3, \ell_4$ como columnas de una matriz, obtenemos una matriz triangular inferior con unos en la diagonal:

$$L = \begin{bmatrix} \ell_1 & \ell_2 & \ell_3 & \ell_4 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 4 & 1 & 0 \\ 5 & 6 & 7 & 1 \end{bmatrix}.$$

Finalmente, de la descomposición en suma de matrices de rango 1 se sigue la factorización

$$A = L\,U.$$

En efecto, puede verificarse que

$$LU = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 4 & 1 & 0 \\ 5 & 6 & 7 & 1 \end{bmatrix} \begin{bmatrix} 4 & -5 & 6 & -2 \\ 0 & 2 & 3 & -4 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 0 & 4 \end{bmatrix} = \begin{bmatrix} 4 & -5 & 6 & -2 \\ 8 & -8 & 15 & -8 \\ 12 & -7 & 40 & -31 \\ 20 & -13 & 118 & -93 \end{bmatrix} = A.$$

Este proceso permite, en ciertos casos, construir la factorización LU de una matriz cuadrada A siempre que en cada paso el pivote correspondiente sea no nulo (esto implica en particular que A es una matriz no singular). Obteniendo entonces

$$A = LU = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \ell_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{bmatrix},$$

Una vez obtenida la factorización $A = LU$, resolver el sistema $A\boldsymbol{x} = \boldsymbol{b}$ se vuelve muy eficiente. Reescribimos el sistema como

$$LU\boldsymbol{x} = \boldsymbol{b}.$$

Si definimos un nuevo vector $\boldsymbol{c} = U\boldsymbol{x}$, el problema se descompone en dos sistemas triangulares consecutivos:

$$\begin{aligned} L\boldsymbol{c} &= \boldsymbol{b} \quad \text{(sustitución hacia adelante)}, \\ U\boldsymbol{x} &= \boldsymbol{c} \quad \text{(sustitución hacia atrás)}. \end{aligned}$$

La ventaja es que, al ser L triangular inferior con unos en la diagonal y U triangular superior, cada uno de estos sistemas se resuelve de forma directa sin necesidad de aplicar nuevamente la eliminación gaussiana.

Volvamos al ejemplo que venimos trabajando. Teníamos

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 4 & 1 & 0 \\ 5 & 6 & 7 & 1 \end{bmatrix}, \qquad U = \begin{bmatrix} 4 & -5 & 6 & -2 \\ 0 & 2 & 3 & -4 \\ 0 & 0 & 10 & -9 \\ 0 & 0 & 0 & 4 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 11 \\ 30 \\ 76 \\ 184 \end{bmatrix}.$$

Paso 1: Resolvemos $L\boldsymbol{c} = \boldsymbol{b}$ por sustitución hacia adelante.

$$\begin{cases} c_1 = 11 \\ 2c_1 + c_2 = 30 \\ 3c_1 + 4c_2 + c_3 = 76 \\ 5c_1 + 6c_2 + 7c_3 + c_4 = 184 \end{cases}$$

De la primera ecuación obtenemos $c_1 = 11$. Sustituyendo en la segunda:

$$2(11) + c_2 = 30 \implies c_2 = 30 - 22 = 8.$$

Llevamos c_1, c_2 a la tercera:

$$3(11) + 4(8) + c_3 = 76 \implies 33 + 32 + c_3 = 76 \implies c_3 = 11.$$

Finalmente, reemplazamos en la cuarta:

$$5(11) + 6(8) + 7(11) + c_4 = 184 \implies 55 + 48 + 77 + c_4 = 184 \implies c_4 = 4.$$

Así resulta

$$\boldsymbol{c} = \begin{bmatrix} 11 \\ 8 \\ 11 \\ 4 \end{bmatrix}.$$

Paso 2: Resolvemos $U\boldsymbol{x} = \boldsymbol{c}$ por sustitución hacia atrás. Pero este es exactamente el sistema triangular que ya resolvimos al final de la Sección 2.3, porque $\boldsymbol{c}$ es el lado derecho que allí quedó después de la eliminación. La solución es, naturalmente, la misma:

$$\boxed{x_1 = 4,\ x_2 = 3,\ x_3 = 2,\ x_4 = 1}.$$

De esta manera, la factorización LU nos permite resolver el sistema con dos sustituciones sencillas. Además, si luego necesitáramos resolver $A\boldsymbol{x} = \boldsymbol{b}'$ para un nuevo término independiente $\boldsymbol{b}'$, bastaría con repetir los dos procesos de sustitución usando las mismas matrices L y U, lo que representa un ahorro considerable de operaciones.

2.4.1 ¿Cuándo existe la factorización? ¿Es única?

El procedimiento anterior se traba en cuanto un pivote es cero, y no siempre podemos anticiparlo mirando A. La condición exacta se enuncia en términos de las **submatrices principales**

$$A_k = \begin{bmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{bmatrix}, \qquad k = 1, \ldots, n,$$

es decir, los bloques cuadrados de arriba a la izquierda de A (en particular $A_n = A$).

Teorema 2.2 (Existencia y unicidad de LU)**.** Sea $A \in \mathbb{R}^{n\times n}$. Entonces A admite una factorización $A = LU$ con L triangular inferior de unos en la diagonal y U triangular superior con todos sus pivotes no nulos si y sólo si todas las submatrices principales $A_1, \ldots, A_n$ son invertibles. En ese caso L y U son únicas, los pivotes valen

$$u_{kk} = \frac{\det A_k}{\det A_{k-1}} \qquad (\det A_0 := 1),$$

y en consecuencia

$$\det A = u_{11}u_{22}\cdots u_{nn}.$$

La demostración es el Ejercicio de desarrollo que sigue: toda la información está en la multiplicación por bloques de la Sección 1.3.8.

Ejercicio de desarrollo 2.1 | Existencia y unicidad de la factorización LU

Sea $A \in \mathbb{R}^{n\times n}$ y supongamos primero que $A = LU$ con L triangular inferior de unos en la diagonal y U triangular superior.

(a) Escribiendo L y U por bloques,

$$L = \begin{bmatrix} L_k & 0 \\ * & * \end{bmatrix}, \qquad U = \begin{bmatrix} U_k & * \\ 0 & * \end{bmatrix},$$

con L_k, U_k de $k \times k$, probar que $A_k = L_k U_k$ para todo k.

(b) Deducir que $\det A_k = u_{11}u_{22}\cdots u_{kk}$ y, por lo tanto, que $u_{kk} = \det A_k / \det A_{k-1}$. Concluir que si todos los pivotes son no nulos, entonces todas las submatrices principales son invertibles.

(c) *(Recíproco.)* Supongamos ahora que $A_1, \dots, A_n$ son invertibles. Probar, por inducción sobre k, que el procedimiento de la Sección 2.4 no se traba: en el paso k el pivote es no nulo. *Sugerencia:* el pivote del paso k es $\det A_k / \det A_{k-1}$ por el ítem (b), y el primer paso no cambia las submatrices principales.

(d) *(Unicidad.)* Supongamos $L_1U_1 = L_2U_2$ con L_i triangulares inferiores de diagonal unitaria y U_i triangulares superiores invertibles. Probar que $L_2^{-1}L_1 = U_2U_1^{-1}$, observar que el miembro izquierdo es triangular inferior con unos en la diagonal y el derecho es triangular superior, y concluir que ambos valen I. *Sugerencia:* la inversa de una triangular inferior de diagonal unitaria es triangular inferior de diagonal unitaria, y el producto de dos triangulares superiores es triangular superior; conviene probar antes esas dos afirmaciones.

(e) Deducir que $\det A$ es el producto de los pivotes y verificarlo en el ejemplo de la Sección 2.4, donde los pivotes son $4, 2, 10, 4$.

(f) Exhibir una matriz invertible que *no* admita factorización LU e indicar cuál de sus submatrices principales es singular. ¿Contradice esto el teorema?

Se entrega por escrito. El ítem (b) — los pivotes como cocientes de menores — reaparece en el Capítulo 6 como criterio de positividad, y el ítem (d) es el modelo de casi todas las pruebas de unicidad de factorizaciones del apunte.

2.4.2 Las variantes LDU y LDL^T

En la factorización $A = LU$ la matriz L tiene unos en la diagonal pero U no: sus elementos diagonales son los pivotes. Esa asimetría es fácil de corregir. Llamemos

$$D = \operatorname{diag}(u_{11}, u_{22}, \dots, u_{nn})$$

a la matriz diagonal de los pivotes. Como los pivotes son no nulos, D es invertible y podemos escribir $U = D\,U'$, donde $U' = D^{-1}U$ es triangular superior *con unos en la diagonal* (dividir la fila k de U por su pivote). Obtenemos así

$$\boxed{A = L\,D\,U'}$$

con L y U' triangulares de diagonal unitaria y D diagonal. Esta factorización también es única (mismo argumento que el ítem (d) de la entrega anterior).

El caso simétrico es el interesante. Si $A = A^T$, trasponiendo $A = LDU'$ se obtiene $A = A^T = (U')^T D L^T$, que es otra factorización LDU de A: el primer factor es triangular inferior de diagonal unitaria, el segundo es diagonal y el tercero es triangular superior de diagonal unitaria. Por unicidad, $U' = L^T$ y entonces

$$\boxed{A = L\,D\,L^T} \qquad \text{para } A \text{ simétrica.}$$

La consecuencia práctica es inmediata: para una matriz simétrica basta calcular y guardar L y D, con lo que la eliminación cuesta la mitad. Cuando además todos los pivotes son *positivos*, $D^{1/2}$ tiene sentido y $A = (LD^{1/2})(LD^{1/2})^T$; esa es la factorización de Cholesky, que veremos en el Capítulo 6 junto con las matrices definidas positivas.

2.5 Conteo de operaciones

En la sección anterior aprendimos a factorizar (cuando esto es posible) una matriz cuadrada no singular $A \in \mathbb{R}^{n\times n}$ en la forma $A = LU$ donde L es una matriz triangular inferior de la forma

$$L = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \ell_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \cdots & 1 \end{bmatrix}$$

y U es una matriz triangular superior de la forma

$$U = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{bmatrix}.$$

Contemos, en primer lugar, cuántas operaciones debemos realizar para resolver $A\boldsymbol{x} = \boldsymbol{b}$ si ya tenemos A factorizada. En primer lugar debemos resolver el sistema triangular inferior

$$L\boldsymbol{c} = \boldsymbol{b}.$$

Como L es triangular inferior con unos en la diagonal, este sistema no requiere divisiones. La primera incógnita se obtiene directamente:

$$c_1 = b_1.$$

Para cada fila $i = 2, \ldots, n$, una vez conocidas $c_1, \ldots, c_{i-1}$, calculamos

$$c_i = b_i - \sum_{j=1}^{i-1} \ell_{ij} c_j.$$

En la fila i-ésima hay $i-1$ multiplicaciones y $i-1$ restas. Por lo tanto, la sustitución hacia adelante requiere

$$\sum_{i=2}^{n} (i-1) = \frac{n(n-1)}{2}$$

multiplicaciones y

$$\sum_{i=2}^{n}(i-1) = \frac{n(n-1)}{2}$$

sumas/restas. No se necesita ninguna división porque la diagonal de L está formada por unos. Tenemos entonces $n^2 - n$ operaciones para resolver $L\boldsymbol{c} = \boldsymbol{b}$.

A continuación resolvemos el sistema triangular superior

$$U\boldsymbol{x} = \boldsymbol{c}.$$

Aquí sí aparecen divisiones, una por cada fila, al despejar cada incógnita. Comenzando por la última fila:

$$x_n = \frac{c_n}{u_{nn}}.$$

Para una fila general $i = 1, \ldots, n-1$, una vez conocidas $x_{i+1}, \ldots, x_n$, calculamos

$$x_i = \frac{c_i - \sum_{j=i+1}^{n} u_{ij}x_j}{u_{ii}}.$$

En la fila i-ésima se realizan $n - i$ multiplicaciones, $n - i$ restas y una división. Sumando sobre todas las filas, la sustitución hacia atrás requiere

$$\sum_{i=1}^{n}(n-i) = \frac{n(n-1)}{2}$$

multiplicaciones y

$$\sum_{i=1}^{n}(n-i) = \frac{n(n-1)}{2}$$

sumas/restas, además de

$$n$$

divisiones. Lo que da un total de n^2 operaciones para resolver $U\boldsymbol{x} = \boldsymbol{c}$

En total, para resolver $A\boldsymbol{x} = \boldsymbol{b}$ una vez que se dispone de L y U, se realizan $2n^2 - n$ operaciones, es decir, el orden es de n^2.

Vamos a contar ahora cuántas operaciones necesitamos para construir la factorización LU de una matriz $A \in \mathbb{R}^{n\times n}$,

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}.$$

En el primer paso consideramos el pivote de la posición $(1,1)$ y construimos la matriz de multiplicadores M_1. Para construir esta matriz necesitamos $n-1$ divisiones (una por cada fila excepto la primera) para calcular los multiplicadores

$$\ell_{21} = \frac{a_{21}}{a_{11}}, \quad \ell_{31} = \frac{a_{31}}{a_{11}}, \quad \ldots, \quad \ell_{n1} = \frac{a_{n1}}{a_{11}}.$$

Luego $(n-1)(n-1)$ multiplicaciones (una por cada entrada que no esté en la primera fila ni en la primera columna). Posteriormente hacemos $(n-1)(n-1)$ sumas para calcular la

matriz A_2 como $A - M_1$. Notar que en este conteo no estamos operando sobre las entradas que ya sabemos que son ceros.

En general, en el k-ésimo paso de eliminación, con $k = 1, \ldots, n-1$, trabajamos con la submatriz activa de tamaño $(n-k+1) \times (n-k+1)$. Para anular las entradas debajo del pivote a_{kk} se necesitan

$$n - k$$

divisiones, con las cuales se calculan los multiplicadores. Luego, para calcular M_k de tamaño efectivo $(n-k) \times (n-k)$, se realizan

$$(n-k)^2$$

multiplicaciones y para calcular A_k se realizan

$$(n-k)^2$$

Sumando sobre todos los pasos, el número total de divisiones es

$$\sum_{k=1}^{n-1} (n-k) = \frac{n(n-1)}{2}.$$

El número total de multiplicaciones es

$$\sum_{k=1}^{n-1} (n-k)^2 = \sum_{m=1}^{n-1} m^2 = \frac{(n-1)n(2n-1)}{6},$$

y el de sumas/restas es exactamente el mismo. Para valores grandes de n, las multiplicaciones y las sumas dominan, y se comportan como

$$\frac{(n-1)n(2n-1)}{6} = \frac{n^3}{3} - \frac{n^2}{2} + \frac{n}{6} \approx \frac{n^3}{3}$$

cada una. Sumando multiplicaciones y sumas, el total es del orden de

$$\frac{2n^3}{3}.$$

Así, la construcción de la factorización LU requiere en el orden de n^3 operaciones.

En resumen, si bien el costo de resolver un sistema una vez que se dispone de la matriz factorizada $A = LU$ es bajo, del orden de $O(n^2)$ operaciones, hay que tener en cuenta que el costo de construir dicha factorización es del mismo orden que resolver el sistema mediante eliminación gaussiana, es decir, $O(n^3)$. Sin embargo, si vamos a resolver el mismo sistema con la misma matriz A para varios lados derechos $\boldsymbol{b}$, entonces se justifica realizar una única vez la eliminación y guardar en memoria la factorización LU, de modo que cada nuevo término independiente solo requiera resolver dos sistemas triangulares de bajo costo.

2.5.1 Moraleja: nunca se calcula la inversa

El conteo anterior tiene una consecuencia práctica que conviene subrayar, porque va a contramano de lo que sugiere la notación $\boldsymbol{x} = A^{-1}\boldsymbol{b}$. Calcular A^{-1} es resolver los n sistemas $A\boldsymbol{x} = \boldsymbol{e}_j$, $j = 1, \ldots, n$: cuesta la factorización ($\approx 2n^3/3$) más n pares de sustituciones ($n \cdot 2n^2 = 2n^3$), en total unas $8n^3/3$ operaciones, cuatro veces más que factorizar. Y una vez que se tiene A^{-1}, calcular el producto $A^{-1}\boldsymbol{b}$ cuesta $2n^2$ operaciones: exactamente lo mismo que las dos sustituciones con L y U. Es decir, se paga cuatro veces más para no ganar nada — y el resultado, además, es numéricamente peor. *La inversa se usa para pensar y para escribir fórmulas; para calcular se factoriza.*

Observación 2.3. Por la misma razón, el determinante tampoco sirve para medir cuán cerca está una matriz de ser singular. Si $A \in \mathbb{R}^{30\times 30}$ tiene $\det(A) = 1$, entonces

$$\det(0.1\,A) = (0.1)^{30}\det(A) = 10^{-30},$$

y sin embargo $0.1\,A$ es tan invertible como A: resolver un sistema con una u otra es igual de fácil. Un determinante chico no indica que la matriz sea *casi singular*. La medida correcta es el *número de condición*, que veremos en el capítulo de normas de matrices.

2.6 Factorización LU con pivoteo

En secciones anteriores explicamos cómo encontrar la factorización LU de matrices A no singulares. Sin embargo, hay casos en los que el algoritmo que desarrollamos falla. Siempre supusimos que el pivote en cada paso es un número no nulo, pero ¿qué sucede si el pivote es cero? Hagamos primero un ejemplo de cómo resolver un sistema con una matriz de estas características mediante eliminación gaussiana.

Consideremos

$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 3 & 7 \\ 2 & 1 & 8 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}.$$

Si tuviéramos que aplicar el método de eliminación, lo que hacemos usualmente es intercambiar filas. Un buen criterio es usar siempre como pivote el elemento de mayor valor absoluto de la columna correspondiente. En este caso, la primera columna tiene entradas 0, 1 y 2; la de mayor valor absoluto es 2, que está en la fila 3. Entonces intercambiamos la fila 1 con la fila 3, y nos queda

$$\left[\begin{array}{ccc|c} 2 & 1 & 8 & b_3 \\ 1 & 3 & 7 & b_2 \\ 0 & 1 & 1 & b_1 \end{array}\right].$$

Notemos que hemos cambiado también el lado derecho para no cambiar el sistema de ecuaciones que queremos resolver.

Ahora continuamos con eliminación gaussiana. El pivote es 2 y el multiplicador para la segunda fila es

$$\frac{1}{2}.$$

Aplicamos

$$F_2 \leftarrow F_2 - \frac{1}{2}F_1$$

y obtenemos

$$\left[\begin{array}{ccc|c} 2 & 1 & 8 & b_3 \\ 0 & \frac{5}{2} & 3 & b_2 - \frac{1}{2}b_3 \\ 0 & 1 & 1 & b_1 \end{array}\right].$$

El siguiente pivote es $\frac{5}{2}$. Para eliminar el elemento de la tercera fila, el multiplicador es

$$\frac{1}{\frac{5}{2}} = \frac{2}{5}.$$

Hacemos

$$F_3 \leftarrow F_3 - \frac{2}{5}F_2$$

y llegamos a la matriz triangular superior

$$\left[\begin{array}{ccc|c} 2 & 1 & 8 & b_3 \\ 0 & \frac{5}{2} & 3 & b_2 - \frac{1}{2}b_3 \\ 0 & 0 & -\frac{1}{5} & b_1 - \frac{2}{5}b_2 + \frac{1}{5}b_3 \end{array}\right].$$

Resolvemos ahora por sustitución hacia atrás. De la tercera ecuación:

$$-\frac{1}{5}x_3 = b_1 - \frac{2}{5}b_2 + \frac{1}{5}b_3,$$

de donde

$$x_3 = -5b_1 + 2b_2 - b_3.$$

De la segunda ecuación:

$$\frac{5}{2}x_2 + 3x_3 = b_2 - \frac{1}{2}b_3,$$

reemplazando x_3 y despejando se obtiene

$$x_2 = 6b_1 - 2b_2 + b_3.$$

Finalmente, de la primera ecuación:

$$2x_1 + x_2 + 8x_3 = b_3,$$

y reemplazando x_2 y x_3 resulta

$$x_1 = 17b_1 - 7b_2 + 4b_3.$$

Ahora bien, ¿cómo reflejamos ese cambio de filas a la hora de hacer la factorización? Vamos a hacer uso de las matrices de permutación. Tomemos por ejemplo

$$P = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}.$$

Para entender qué hace P no hace falta ninguna cuenta nueva: alcanza con las dos fórmulas (1.4) y (1.5) de la Sección 1.4.2 del Capítulo 1,

$$\text{fila}_i(PA) = \text{fila}_i(P)\, A \qquad \text{y} \qquad \text{col}_j(AP) = A\ \text{col}_j(P).$$

Esto significa que, si multiplicamos por P a la izquierda, estamos combinando filas de A de acuerdo con las filas de P. Como cada fila de P tiene un único 1, al calcular PA se permutan las filas de A.

En efecto, para nuestro ejemplo,

$$PA = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 1 \\ 1 & 3 & 7 \\ 2 & 1 & 8 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 8 \\ 0 & 1 & 1 \\ 1 & 3 & 7 \end{bmatrix}.$$

Observamos que la primera fila de PA es la tercera fila de A, la segunda fila de PA es la primera fila de A, y la tercera fila de PA es la segunda fila de A. Es decir, P permuta filas.

De manera análoga, si multiplicamos por P a la derecha, se permutan las columnas de A. Usando la propiedad de columnas,

$$AP = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 3 & 7 \\ 2 & 1 & 8 \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 3 & 7 & 1 \\ 1 & 8 & 2 \end{bmatrix}.$$

Aquí la primera columna de AP es la segunda columna de A, la segunda columna de AP es la tercera columna de A, y la tercera columna de AP es la primera columna de A. Por lo tanto, multiplicar por la derecha por P permuta columnas.

La matriz P es un ejemplo de una matriz de permutación. Una **matriz de permutación** es una matriz binaria cuadrada que tiene exactamente un 1 en cada fila y en cada columna, y 0 en todas las demás entradas. Una matriz de permutación de $n \times n$ puede representar una permutación de n elementos. Premultiplicar una matriz M de n filas por una matriz de permutación P, formando PM, permuta las filas de M; análogamente, postmultiplicar una matriz M de n columnas, formando MP, permuta las columnas de M.

Toda matriz de permutación P satisface

$$P^{-1} = P^T$$

es decir, para deshacer una permutación de filas alcanza con trasponer. Esto se verifica directamente: la entrada (i, j) de $P^T P$ es el producto escalar de las columnas i y j de P, y como cada columna tiene un único 1 y están en posiciones distintas, ese producto vale 1 si $i = j$ y 0 si $i \neq j$; o sea $P^T P = I$. En el Capítulo 3 veremos que las matrices que cumplen esta propiedad se llaman *ortogonales*, y que las de permutación son un caso particular.

Ahora veamos cómo incorporar las matrices de permutación en la factorización LU. Volvamos al ejemplo de hoy. Vamos a aplicar la técnica llamada **pivoteo parcial**, que consiste en realizar intercambios de filas de manera que, en cada paso, el pivote sea el elemento de mayor valor absoluto de la columna correspondiente.

Para la matriz

$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 3 & 7 \\ 2 & 1 & 8 \end{bmatrix},$$

el primer pivote sería $a_{11} = 0$, que no es admisible. En la primera columna, el mayor valor absoluto es 2, ubicado en la fila 3. Por lo tanto, intercambiamos la fila 1 con la fila 3. Esta operación se representa con la matriz de permutación

$$P = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}.$$

Trabajamos entonces con la matriz permutada

$$\tilde{A} = PA = \begin{bmatrix} 2 & 1 & 8 \\ 1 & 3 & 7 \\ 0 & 1 & 1 \end{bmatrix}.$$

Ahora aplicamos a $\tilde{A}$ la misma construcción con matrices de multiplicadores que usamos antes.

En el primer paso, el pivote es 2. Los multiplicadores son

$$\ell_{21} = \frac{1}{2}, \qquad \ell_{31} = \frac{0}{2} = 0.$$

Definimos

$$\ell_1 = \begin{bmatrix} 1 \\ 1/2 \\ 0 \end{bmatrix}, \qquad u_1^\star = \begin{bmatrix} 2 & 1 & 8 \end{bmatrix},$$

y construimos

$$M_1 = \ell_1 u_1^\star = \begin{bmatrix} 1 \\ 1/2 \\ 0 \end{bmatrix} \begin{bmatrix} 2 & 1 & 8 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 8 \\ 1 & 1/2 & 4 \\ 0 & 0 & 0 \end{bmatrix}.$$

Restamos esta matriz de $\widetilde{A}$:

$$\widetilde{A} - M_1 = \begin{bmatrix} 2 & 1 & 8 \\ 1 & 3 & 7 \\ 0 & 1 & 1 \end{bmatrix} - \begin{bmatrix} 2 & 1 & 8 \\ 1 & 1/2 & 4 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 5/2 & 3 \\ 0 & 1 & 1 \end{bmatrix} \equiv A_2.$$

En el segundo paso, el pivote es $5/2$ y el multiplicador para la tercera fila es

$$\ell_{32} = \frac{1}{5/2} = \frac{2}{5}.$$

Definimos

$$\ell_2 = \begin{bmatrix} 0 \\ 1 \\ 2/5 \end{bmatrix}, \qquad u_2^\star = \begin{bmatrix} 0 & 5/2 & 3 \end{bmatrix},$$

y

$$M_2 = \ell_2 u_2^\star = \begin{bmatrix} 0 \\ 1 \\ 2/5 \end{bmatrix} \begin{bmatrix} 0 & 5/2 & 3 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 5/2 & 3 \\ 0 & 1 & 6/5 \end{bmatrix}.$$

Restamos M_2 de A_2:

$$A_2 - M_2 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 5/2 & 3 \\ 0 & 1 & 1 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 \\ 0 & 5/2 & 3 \\ 0 & 1 & 6/5 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1/5 \end{bmatrix} \equiv A_3.$$

Observemos que A_3 puede escribirse como

$$A_3 = \ell_3 u_3^\star,$$

con

$$\ell_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \qquad u_3^\star = \begin{bmatrix} 0 & 0 & -1/5 \end{bmatrix}.$$

Así,

$$\widetilde{A} = \ell_1 u_1^\star + \ell_2 u_2^\star + \ell_3 u_3^\star.$$

Apilando las filas $u_1^\star, u_2^\star, u_3^\star$ obtenemos

$$U = \begin{bmatrix} u_1^\star \\ u_2^\star \\ u_3^\star \end{bmatrix} = \begin{bmatrix} 2 & 1 & 8 \\ 0 & 5/2 & 3 \\ 0 & 0 & -1/5 \end{bmatrix},$$

y colocando las columnas ℓ_1, ℓ_2, ℓ_3 obtenemos

$$L = \begin{bmatrix} \ell_1 & \ell_2 & \ell_3 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1/2 & 1 & 0 \\ 0 & 2/5 & 1 \end{bmatrix}.$$

Por lo tanto,

$$PA = LU,$$

es decir,

$$\begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 1 \\ 1 & 3 & 7 \\ 2 & 1 & 8 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1/2 & 1 & 0 \\ 0 & 2/5 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 8 \\ 0 & 5/2 & 3 \\ 0 & 0 & -1/5 \end{bmatrix}.$$

Terminemos esta sección con un ejemplo donde se necesita más de una permutación. Consideremos

$$A = \begin{bmatrix} 0 & 2 & 1 \\ 1 & 1 & 1 \\ 2 & 5 & 1 \end{bmatrix}.$$

Paso 1. En la primera columna, el pivote $a_{11} = 0$ no es admisible. El mayor valor absoluto de la primera columna es 2, que está en la fila 3. Por lo tanto, intercambiamos la fila 1 con la fila 3 mediante la matriz de permutación

$$P_1 = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}.$$

Trabajamos entonces con

$$P_1 A = \begin{bmatrix} 2 & 5 & 1 \\ 1 & 1 & 1 \\ 0 & 2 & 1 \end{bmatrix}.$$

Ahora aplicamos la misma construcción con matrices de multiplicadores que usamos antes. El pivote es 2. Los multiplicadores son

$$\ell_{21} = \frac{1}{2}, \qquad \ell_{31} = \frac{0}{2} = 0.$$

Definimos

$$\ell_1 = \begin{bmatrix} 1 \\ 1/2 \\ 0 \end{bmatrix}, \qquad u_1^\star = \begin{bmatrix} 2 & 5 & 1 \end{bmatrix},$$

y construimos

$$M_1 = \ell_1 u_1^\star = \begin{bmatrix} 1 \\ 1/2 \\ 0 \end{bmatrix} \begin{bmatrix} 2 & 5 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 5 & 1 \\ 1 & 5/2 & 1/2 \\ 0 & 0 & 0 \end{bmatrix}.$$

Restamos M_1 de P_1A:

$$P_1A - M_1 = \begin{bmatrix} 2 & 5 & 1 \\ 1 & 1 & 1 \\ 0 & 2 & 1 \end{bmatrix} - \begin{bmatrix} 2 & 5 & 1 \\ 1 & 5/2 & 1/2 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & -3/2 & 1/2 \\ 0 & 2 & 1 \end{bmatrix} \equiv A_2.$$

Paso 2. Antes de continuar, examinamos la submatriz activa de A_2, es decir, las filas 2 y 3 a partir de la segunda columna. El elemento en la posición $(2,2)$ es $-\frac{3}{2}$, pero el mayor valor absoluto en esa columna es 2, que está en la fila 3. Por lo tanto, intercambiamos la fila 2 con la fila 3 de A_2. La matriz de permutación correspondiente es

$$P_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}.$$

Al aplicar P_2 a A_2 obtenemos

$$P_2A_2 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 1 \\ 0 & -3/2 & 1/2 \end{bmatrix}.$$

Definimos

$$\ell_2 = \begin{bmatrix} 0 \\ 1 \\ -3/4 \end{bmatrix}, \qquad u_2^\star = \begin{bmatrix} 0 & 2 & 1 \end{bmatrix},$$

y construimos

$$M_2 = \ell_2 u_2^\star = \begin{bmatrix} 0 \\ 1 \\ -3/4 \end{bmatrix} \begin{bmatrix} 0 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 1 \\ 0 & -3/2 & -3/4 \end{bmatrix}.$$

Restamos M_2 de P_2A_2:

$$P_2A_2 - M_2 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 1 \\ 0 & -3/2 & 1/2 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 1 \\ 0 & -3/2 & -3/4 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 5/4 \end{bmatrix} = A_3.$$

Como

$$A_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & 5/4 \end{bmatrix},$$

si definimos

$$\ell_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \qquad u_3^\star = \begin{bmatrix} 0 & 0 & 5/4 \end{bmatrix},$$

tenemos que

$$P_2A_2 = \ell_2 u_2^\star + \ell_3 u_3^\star.$$

Volviendo a la matriz original, teniamos que

$$P_1A = \ell_1 u_1^\star + A_2,$$

entonces

$$P_2P_1A = P_2\ell_1u_1^\star + P_2A_2 = (P_2\ell_1)u_1^\star + \ell_2u_2^\star + \ell_3u_3^\star.$$

Es importante notar aquí que, al permutar las filas 2 y 3, también debemos permutar las componentes correspondientes de los multiplicadores ya calculados. El vector ℓ_1 que teníamos era

$$\ell_1 = \begin{bmatrix} 1 \\ 1/2 \\ 0 \end{bmatrix}.$$

Al aplicar P_2 a sus filas, obtenemos

$$\ell_1' = P_2\ell_1 = \begin{bmatrix} 1 \\ 0 \\ 1/2 \end{bmatrix}.$$

Obtenemos entonces que

$$\begin{aligned} P_2P_1A &= \ell_1'u_1^\star + \ell_2u_2^\star + \ell_3u_3^\star \\ &= \begin{bmatrix} 1 \\ 0 \\ 1/2 \end{bmatrix}\begin{bmatrix} 2 & 5 & 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ -3/4 \end{bmatrix}\begin{bmatrix} 0 & 2 & 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}\begin{bmatrix} 0 & 0 & 5/4 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1/2 & -3/4 & 1 \end{bmatrix}\begin{bmatrix} 2 & 5 & 1 \\ 0 & 2 & 1 \\ 0 & 0 & 5/4 \end{bmatrix} \\ &= LU \end{aligned}$$

La matriz de permutación total es el producto de las permutaciones aplicadas:

$$P = P_2P_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}\begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}.$$

Finalmente, la factorización con pivoteo parcial es

$$PA = LU,$$

es decir,

$$\begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}\begin{bmatrix} 0 & 2 & 1 \\ 1 & 1 & 1 \\ 2 & 5 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1/2 & -3/4 & 1 \end{bmatrix}\begin{bmatrix} 2 & 5 & 1 \\ 0 & 2 & 1 \\ 0 & 0 & 5/4 \end{bmatrix}.$$

2.6.1 Por qué conviene el pivote más grande

Dijimos al empezar que "un buen criterio es usar siempre como pivote el elemento de mayor valor absoluto de la columna". Si sólo quisiéramos evitar la división por cero bastaría con elegir *cualquier* pivote no nulo; la razón para elegir el más grande es otra, y es puramente numérica.

Observemos que los multiplicadores son cocientes $\ell_{ik} = a_{ik}/a_{kk}$. Si el pivote a_{kk} es chico comparado con las entradas que están debajo, los multiplicadores son enormes, y al restar $\ell_k u_k^\star$ las entradas originales de la submatriz activa quedan sepultadas bajo números

mucho más grandes. En aritmética exacta no pasa nada; en aritmética de punto flotante, esa información se pierde por redondeo y no se recupera nunca más. El pivoteo parcial ataca exactamente eso: al elegir como pivote el elemento de mayor módulo de la columna, se garantiza que

$$|\ell_{ik}| \le 1 \qquad \text{para todos los multiplicadores,}$$

de modo que el paso de eliminación no puede amplificar lo que ya estaba calculado. El Ejercicio de desarrollo que sigue muestra el fenómeno en la matriz más chica posible.

Observación 2.4 (Pivoteo completo). El pivoteo parcial busca el pivote recorriendo sólo la columna activa. Se puede ser más ambicioso y buscar el elemento de mayor módulo en *toda* la submatriz activa, intercambiando entonces filas *y* columnas; eso se llama **pivoteo completo** y produce una factorización

$$PAQ = LU,$$

con P y Q matrices de permutación. El intercambio de columnas reordena las incógnitas, así que al final hay que deshacer ese reordenamiento en el vector solución: si $PAQ = LU$ y llamamos $\boldsymbol{y}$ a la solución del sistema triangular, la solución del sistema original es $\boldsymbol{x} = Q\boldsymbol{y}$.

El pivoteo completo controla el crecimiento de las entradas mucho mejor que el parcial, y hay matrices (poco frecuentes, pero construibles) para las cuales el pivoteo parcial efectivamente falla. Aun así, en la práctica casi nadie lo usa: buscar el máximo en toda la submatriz activa cuesta del orden de n^3 comparaciones en total — comparable al costo de la eliminación misma, que es $\sim n^3/3$ operaciones aritméticas — mientras que el pivoteo parcial cuesta $\sim n^2/2$. Para las matrices que aparecen en problemas reales el pivoteo parcial anda bien, y ése es el que implementan MATLAB, PYTHON y las bibliotecas numéricas estándar.

Ejercicio de desarrollo 2.2 | Por qué se pivotea: un experimento numérico

Consideremos, para $\varepsilon \neq 0$,

$$A = \begin{bmatrix} \varepsilon & 1 \\ 1 & 1 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

(a) Calcular L y U sin pivotear y resolver $A\boldsymbol{x} = \boldsymbol{b}$ en aritmética exacta. Verificar que la solución es $\boldsymbol{x} = \left(\frac{1}{1-\varepsilon}, \frac{1-2\varepsilon}{1-\varepsilon}\right)^T$, que para ε chico está cerca de $(1,1)^T$. Observar que A no tiene nada de particular: sus dos columnas están lejos de ser dependientes.

(b) Rehacer la cuenta del ítem (a) con $\varepsilon = 10^{-4}$ *redondeando a tres cifras significativas después de cada operación*, como haría una computadora con precisión limitada. Comparar con la solución exacta. ¿Cuántas cifras correctas quedan en x_1? ¿Y en x_2?

(c) Repetir el ítem (b) intercambiando primero las dos filas (es decir, factorizando PA con $P = \left[\begin{smallmatrix} 0 & 1 \\ 1 & 0 \end{smallmatrix}\right]$) y con el mismo redondeo a tres cifras. Comparar.

(d) Explicar qué salió mal en (b). *No* es que el problema esté mal planteado: la solución exacta depende suavemente de los datos. Identificar en qué operación concreta se perdió la información y relacionarlo con el tamaño del multiplicador $1/\varepsilon$.

(e) Probar que con pivoteo parcial todos los multiplicadores cumplen $|\ell_{ik}| \le 1$, y dar un ejemplo de 3×3 donde sin pivotear algún multiplicador sea mayor que 100.

(f) *(Opcional.)* Calcular $\max_{ij} |u_{ij}| / \max_{ij} |a_{ij}|$ en los casos (b) y (c). Ese cociente se llama *factor de crecimiento* y es la cantidad que el pivoteo parcial mantiene bajo control.

Se entrega por escrito. Conviene hacer las cuentas a mano, redondeando explícitamente; el punto del ejercicio se pierde si se delega en una calculadora que trabaja con más cifras.

2.7 Eliminación por bloques y el complemento de Schur

Todo lo que hicimos con números se puede hacer con bloques, y el resultado es una de las identidades más útiles del álgebra matricial. Partamos una matriz cuadrada en cuatro bloques,

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix}, \qquad A \in \mathbb{R}^{k \times k} \text{ invertible},$$

y hagamos *un* paso de eliminación, pero tratando al bloque A como si fuera el pivote: a la segunda fila de bloques le restamos CA^{-1} veces la primera. El multiplicador es ahora la matriz CA^{-1}, y lo que queda en el lugar de D es

$$S = D - CA^{-1}B,$$

llamado el **complemento de Schur** de A en M. En términos de factorizaciones, lo que acabamos de hacer es

$$M = \begin{bmatrix} I & 0 \\ CA^{-1} & I \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & S \end{bmatrix} \begin{bmatrix} I & A^{-1}B \\ 0 & I \end{bmatrix}, \tag{2.1}$$

como se comprueba multiplicando los tres factores. Es exactamente una factorización LDU por bloques.

Observación 2.5 (Es la eliminación de siempre). Si tomamos $k = 1$, entonces $A = a_{11}$ es el primer pivote, B es el resto de la primera fila, C el resto de la primera columna, y

$$S = D - \frac{1}{a_{11}} C\,B$$

es precisamente la submatriz activa A_2 que obtuvimos al restar $\ell_1 u_1^\star$ en la Sección 2.4. La eliminación gaussiana es la iteración del complemento de Schur con bloques de tamaño 1.

De (2.1) se leen de inmediato tres consecuencias, porque los factores triangulares por bloques tienen determinante 1 y son invertibles:

$$\det M = \det(A)\,\det(S), \qquad \operatorname{rg}(M) = k + \operatorname{rg}(S), \qquad M \text{ es invertible} \iff S \text{ es invertible}.$$

La primera generaliza la fórmula del determinante de una matriz triangular por bloques; la segunda dice que el rango de M se reparte entre el bloque pivote y lo que queda después de eliminar. El complemento de Schur volverá a aparecer en el Capítulo 6, donde da el criterio para decidir si una matriz simétrica por bloques es definida positiva.

2.8 El caso general: forma escalonada reducida y la factorización CR

Hasta acá supusimos A cuadrada y no singular. Si A es rectangular, o es cuadrada pero singular, el algoritmo no se rompe: simplemente algunas columnas no aportan pivote y hay que saltearlas. Esto cierra una deuda del Capítulo 1, donde construimos la factorización $A = CR$ mediante un procedimiento que llamamos *heurístico* porque no decía cómo encontrar sistemáticamente las columnas independientes. La eliminación lo dice.

El procedimiento es el de siempre, con una regla extra: en el paso k se busca un pivote no nulo en la columna actual; si toda la columna activa es nula, esa columna *no es columna pivote* y se pasa a la siguiente sin eliminar nada. Al terminar se obtiene una matriz **escalonada**: cada fila no nula empieza más a la derecha que la anterior. Si además dividimos cada fila por su pivote y eliminamos también *hacia arriba*, obtenemos la **forma escalonada reducida por filas** de A, que anotaremos $\operatorname{rref}(A)$: los pivotes valen 1 y son los únicos elementos no nulos de sus columnas.

Ejemplo 2.6. Tomemos la matriz del Ejemplo 1.5 del capítulo anterior:

$$A = \begin{bmatrix} 1 & 2 & 5 & 2 \\ 0 & 1 & 2 & 1 \\ 0 & 3 & 6 & 3 \end{bmatrix}.$$

La primera columna ya tiene ceros debajo del pivote 1. El segundo pivote es el 1 de la posición $(2,2)$ y la operación $F_3 \leftarrow F_3 - 3F_2$ da

$$\begin{bmatrix} 1 & 2 & 5 & 2 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

La tercera columna no tiene pivote (su parte activa es nula), y la cuarta tampoco: la eliminación terminó con $r = 2$ pivotes, en las columnas 1 y 2. Eliminando ahora hacia arriba, $F_1 \leftarrow F_1 - 2F_2$, llegamos a

$$\operatorname{rref}(A) = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

Comparemos con el capítulo anterior: las columnas pivote 1 y 2 de A son exactamente las columnas de C, y las dos filas no nulas de $\operatorname{rref}(A)$ son exactamente las filas de R.

Esto no es una casualidad del ejemplo.

Proposición 2.7. Sea $A \in \mathbb{R}^{m \times n}$ de rango r. Entonces:

(i) $\operatorname{rref}(A)$ tiene exactamente r filas no nulas;

(ii) las r columnas pivote de A forman una matriz C cuyas columnas son una base de $C(A)$;

(iii) si R es la matriz formada por las r filas no nulas de $\operatorname{rref}(A)$, entonces $A = CR$;

(iv) las columnas pivote de $\operatorname{rref}(A)$ son los vectores canónicos $\boldsymbol{e}_1, \ldots, \boldsymbol{e}_r$, de modo que R contiene a I_r incrustada.

La razón de fondo es que cada paso de eliminación es una multiplicación a izquierda por una matriz invertible, y multiplicar a izquierda por una matriz invertible no cambia ni el espacio nulo ni las relaciones de dependencia entre las columnas (ítem (b) del Ejercicio de desarrollo 1.1 del capítulo anterior). Las columnas de $\operatorname{rref}(A)$ heredan entonces las mismas dependencias que las de A, y en $\operatorname{rref}(A)$ esas dependencias se leen a simple vista.

Esto da además la forma práctica de describir el espacio nulo. Las variables asociadas a columnas *sin* pivote se llaman **variables libres**; hay $n - r$ de ellas. Fijando una en 1 y las demás en 0, y despejando las variables pivote, se obtiene una base de $N(A)$ con $n - r$ vectores — que es la demostración constructiva del teorema de la dimensión.

Ejemplo 2.8. Para la matriz del Ejemplo 2.6, las variables libres son x_3 y x_4. De $\operatorname{rref}(A)\boldsymbol{x} = \mathbf{0}$ se obtiene $x_1 = -x_3$ y $x_2 = -2x_3 - x_4$, de donde

$$N(A) = \operatorname{span}\left\{\begin{bmatrix}-1\\-2\\1\\0\end{bmatrix}, \begin{bmatrix}0\\-1\\0\\1\end{bmatrix}\right\}, \qquad \dim N(A) = 4 - 2 = 2 = n - r.$$

2.8.1 La factorización LU en el caso singular

En el ejemplo anterior nos detuvimos en $\operatorname{rref}(A)$, pero vale la pena no soltar la otra mitad: la eliminación que hicimos también produce una factorización LU, y mirarla deja en claro qué se conserva y qué se pierde cuando A no es cuadrada no singular.

Volvamos al Ejemplo 2.6. Para llegar a la forma escalonada hicimos una única operación, $F_3 \leftarrow F_3 - 3F_2$, con multiplicador $\ell_{32} = 3$; el primer paso no requirió ninguna, porque la primera columna ya tenía ceros debajo del pivote. Guardando los multiplicadores como siempre:

$$A = \begin{bmatrix}1&2&5&2\\0&1&2&1\\0&3&6&3\end{bmatrix} = \underbrace{\begin{bmatrix}1&0&0\\0&1&0\\0&3&1\end{bmatrix}}_{L}\underbrace{\begin{bmatrix}1&2&5&2\\0&1&2&1\\0&0&0&0\end{bmatrix}}_{U}.$$

Vale la pena observar tres cosas. Primero, que L sigue siendo cuadrada ($m \times m$) y triangular inferior con unos en la diagonal, igual que antes. Segundo, que U ya no es triangular superior sino **escalonada**: tiene el tamaño de A y sus filas no nulas son exactamente $r = 2$, una por pivote. Y tercero, que U *no* es $\operatorname{rref}(A)$: para llegar a la forma reducida faltaba todavía eliminar hacia arriba y normalizar los pivotes, y esos pasos ya no son parte de la factorización LU.

¿Es única?

Para A cuadrada con todas sus submatrices principales invertibles, el Teorema 2.2 garantizaba que L y U son únicas. Acá esa hipótesis no se cumple —A no es ni siquiera cuadrada— y, en general, **la unicidad se pierde**. Conviene ver exactamente por qué.

Supongamos $A = LU$ con U escalonada, y supongamos que la fila k de U es nula. Al multiplicar, la columna k de L aparece siempre multiplicando a esa fila nula: la contribución de ℓ_{ik} al producto es $\ell_{ik}\ \operatorname{fila}_k(U) = \mathbf{0}$ para todo $i > k$. Es decir, *las entradas de L que están debajo de la diagonal en una columna correspondiente a una fila nula de U no intervienen en el producto y se pueden elegir a gusto.* Ésa es toda la no-unicidad que hay.

El ejemplo más chico posible:

$$A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \ell & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 0 & -\ell \end{bmatrix} \qquad \text{para cualquier } \ell \in \mathbb{R},$$

donde la segunda fila de U es nula sólo cuando $\ell = 0$, pero el producto da A igual: hay infinitas factorizaciones.

En cambio, en nuestro Ejemplo 2.6 la factorización *sí* es única, y el criterio anterior explica por qué: la única fila nula de U es la *última*, y debajo de la diagonal de la tercera columna de L no hay ninguna entrada. No queda ningún parámetro libre. (El Ejercicio 1 pide verificarlo despejando L y U entrada por entrada.)

Observación 2.9 (También puede fallar la existencia)**.** La no-unicidad no es el único síntoma. Para $A = \left[\begin{smallmatrix} 1 & 2 \\ 2 & 4 \\ 0 & 1 \end{smallmatrix}\right]$ directamente *no existe* ninguna factorización $A = LU$ con L triangular inferior de diagonal unitaria y U escalonada: después del primer paso de eliminación la segunda fila se anula, y el pivote de la segunda columna aparece recién en la tercera fila, de modo que hay que permutar. Igual que en el caso no singular, la permutación arregla todo: lo que siempre existe es $PA = LU$.

2.9 Ejercicios

1. *(Unicidad de LU en el caso singular.)* Sea

$$A = \begin{bmatrix} 1 & 2 & 5 & 2 \\ 0 & 1 & 2 & 1 \\ 0 & 3 & 6 & 3 \end{bmatrix}$$

la matriz de la Sección 2.8.1. Planteando $A = LU$ con $L \in \mathbb{R}^{3\times 3}$ triangular inferior de diagonal unitaria y $U \in \mathbb{R}^{3\times 4}$ escalonada, y comparando fila por fila, despejar sucesivamente $\text{fila}_1(U)$, luego ℓ_{21} y $\text{fila}_2(U)$, y finalmente ℓ_{31}, ℓ_{32} y $\text{fila}_3(U)$. Concluir que la factorización es única y que coincide con la que da la eliminación.

   (a) Repetir el planteo para $B = \left[\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right]$ y describir *todas* las factorizaciones $B = LU$.

   (b) ¿Para qué matrices A de 3×4 y rango 2 es única la factorización? *Sugerencia:* mirar en qué fila de U quedan los ceros.

2. Halle la factorización $A = LU$ de las siguientes matrices:

$$A = \begin{bmatrix} 2 & 1 \\ 6 & 7 \end{bmatrix} \qquad A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \qquad A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

3. Si $a_{11}, \ldots, a_{1n}$ es la primera fila de una matriz A de rango 1 y $a_{11}, \ldots, a_{m1}$ es la primera columna, *encuentre una fórmula para a_{ij}*. Verifique la fórmula en el caso $a_{11} = 2, a_{12} = 3, a_{21} = 4$. ¿Cuándo no funcionará la fórmula?

4. ¿Qué matriz triangular inferior E transforma A en una triangular superior $EA = U$?

$$A = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 4 & 2 \\ 6 & 3 & 5 \end{bmatrix}$$

5. **Este problema muestra cómo se multiplican las inversas de cada paso para obtener $\boldsymbol{L}$.** Esto es claro cuando $A = L$ ya es una matriz triangular inferior con unos en la diagonal. En este caso, $\boldsymbol{U = I}$:

$$\text{Premultiplique } A = \begin{bmatrix} 1 & 0 & 0 \\ a & 1 & 0 \\ b & c & 1 \end{bmatrix} \text{ por } E_1 = \begin{bmatrix} 1 & 0 & 0 \\ -a & 1 & 0 \\ -b & 0 & 1 \end{bmatrix}$$

$$\text{Luego, premultiplique ese resultado por } E_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -c & 1 \end{bmatrix}.$$

Observar que el resultado es una matriz triagular superior.

(a) Multiplique E_2E_1 para encontrar la matriz E que produce $EA = I$.

(b) Calcule $(E_2E_1)^{-1}$ para encontrar la matriz $A = L$.

Los multiplicadores $\boldsymbol{a, b, c}$ están mezclados en $\boldsymbol{E = L^{-1}}$ pero están perfectos en $\boldsymbol{L}$.

6. *La factorización $A = LU$ no es posible cuando aparece cero en una posición pivote* (es necesario que los pivotes sean distintos de cero en U). Demuestre por qué en estos ejemplos las descomposiciones LU son imposibles:

$$\begin{bmatrix} 0 & 1 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \ell & 1 \end{bmatrix} \begin{bmatrix} d & e \\ 0 & f \end{bmatrix} \qquad \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 2 \\ 1 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 & & \\ \ell & 1 & \\ m & n & 1 \end{bmatrix} \begin{bmatrix} d & e & g \\ & f & h \\ & & i \end{bmatrix}.$$

Estas matrices necesitan un intercambio de filas utilizando una *matriz de permutación* P.

7. Considere la siguiente matriz:

$$A = \begin{bmatrix} 1 & c & 0 \\ 2 & 4 & 1 \\ 3 & 5 & 1 \end{bmatrix}.$$

(a) ¿Qué número c hace que sea cero la segunda posición pivote? En este caso, se necesitaría un intercambio de filas ya que no sería posible realizar $A = LU$.

(b) ¿Qué c produce un cero en la tercera posición pivote? En este caso, un intercambio de filas no sirviría y la eliminación fallaría:

8. (*Recomendado*) Calcule L y U para la matriz simétrica A:

$$A = \begin{bmatrix} a & a & a & a \\ a & b & b & b \\ a & b & c & c \\ a & b & c & d \end{bmatrix}.$$

Encuentre condiciones sobre a, b, c, d para obtener $A = LU$ con cuatro pivotes no nulos.

9. Las *matrices tridiagonales* tienen ceros en todas las posiciones excepto en la diagonal principal y las dos diagonales adyacentes. Factorice las siguientes matrices como $A = LU$. Luego, corrobore que se satisface que $A = LDL^T$, para alguna matriz diagonal D:

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \quad \text{y} \quad A = \begin{bmatrix} a & a & 0 \\ a & a+b & b \\ 0 & b & b+c \end{bmatrix}.$$

10. *Fácil pero importante.* Si A tiene pivotes $5, 9, 3$ sin hacer intercambio de filas, ¿Cuales son los pivotes para la submatriz superior izquierda de 2 por 2 A_2 (es decir, la matriz que resulta de quitarle a A la fila 3 y la columna 3)?

11. Este ejercicio propone estudiar qué matrices invertibles permiten la descomposición $A = LU$ (eliminación sin intercambio de filas) ¡Es una buena pregunta! Observe cada una de las submatrices cuadradas superiores izquierdas $A_1, A_2, \ldots, A_n$.

Todas las submatrices superiores izquierdas A_k deben ser invertibles: la de tamaño 1×1, la de 2×2, ..., la de $n \times n$.

Explique la respuesta: A_k se factoriza como _____ ya que $LU = \begin{bmatrix} L_k & 0 \\ * & * \end{bmatrix} \begin{bmatrix} U_k & * \\ 0 & * \end{bmatrix}$.

12. En algunas aplicaciones de ciencia de los datos, el primer pivote es el *mayor número* $|a_{ij}|$ *de* A. La fila i se convierte en la primera fila pivote $\boldsymbol{u}_1^*$. La columna j es la primera columna pivote. Se divide esta columna por a_{ij} de manera que $\boldsymbol{\ell}_1$ tiene un 1 en la fila i. Luego se resta $\boldsymbol{\ell_1 u_1^*}$ de A.

En este ejemplo $a_{22} = 4$ es el primer pivote ($i = j = 2$). Dividiendo por 4 se obtiene $\boldsymbol{\ell}_1$:

$$\begin{bmatrix} 1 & 2 \\ 3 & \mathbf{4} \end{bmatrix} = \begin{bmatrix} 1/2 \\ 1 \end{bmatrix} \begin{bmatrix} 3 & \mathbf{4} \end{bmatrix} + \begin{bmatrix} -1/2 & 0 \\ 0 & 0 \end{bmatrix} = \boldsymbol{\ell_1 u_1^*} + \boldsymbol{\ell_2 u_2^*} = \begin{bmatrix} 1/2 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 3 & 4 \\ -1/2 & 0 \end{bmatrix}$$

Observar que las matrices A, L y U contienen permutaciones. P_1 intercambia las filas para obtener L. P_2 intercambia las columnas para obtener la matriz triangular superior U. Entonces $\boldsymbol{P_1 A P_2 = LU}$.

Permutadas de antemano $\quad \boldsymbol{P_1 A P_2} = \begin{bmatrix} 1 & 0 \\ 1/2 & 1 \end{bmatrix} \begin{bmatrix} 4 & 3 \\ 0 & -1/2 \end{bmatrix} = \begin{bmatrix} \mathbf{4} & \mathbf{3} \\ \mathbf{2} & \mathbf{1} \end{bmatrix}$

Sea $A = \begin{bmatrix} \mathbf{1} & \mathbf{3} \\ \mathbf{2} & \mathbf{4} \end{bmatrix}$. Aplique pivoteo completo para producir $P_1 A P_2 = LU$.

13. Decimos que una matriz A de $m \times n$ es baja y ancha cuando $m < n$, ¿Cómo se ve a partir del proceso de eliminación que hay soluciones no nulas de $A\boldsymbol{x} = \mathbf{0}$? ¿Qué sabe acerca de la dimensión del espacio nulo de A? La dimensión del espacio nulo es al menos _____.

Sugerencia: Primero construya una matriz A de 2×3 y hágase esas preguntas sobre A.

3 CAPÍTULO

Ortogonalidad

La palabra **ortogonal** significa *perpendicular*, pero en álgebra lineal su alcance es mucho mayor que el ángulo entre dos flechas. Lo que hace este capítulo es seguir esa idea mientras crece, desde el caso más simple hasta la factorización que la resume.

Se empieza por los **vectores**: dos vectores de $\mathbb{R}^n$ son ortogonales cuando su producto escalar $\boldsymbol{x}^T\boldsymbol{y}$ es cero, y ese único test da, casi gratis, la desigualdad de Cauchy-Schwarz, la definición de ángulo y el teorema de Pitágoras. De ahí se pasa a las **bases**: una base en la que todos los vectores son perpendiculares entre sí y de longitud uno — una base *ortonormal* — vuelve triviales cuentas que en general son un sistema de ecuaciones, porque cada coeficiente se obtiene con un producto escalar y sin mirar a los demás.

El salto siguiente es de los vectores a los **subespacios**: dos subespacios son ortogonales cuando cada vector de uno es perpendicular a cada vector del otro. El ejemplo central ya lo teníamos sin saberlo, y es el que completa el cuadro de los cuatro subespacios fundamentales del Capítulo 1: el espacio fila de A es ortogonal a su espacio nulo, y el espacio columna lo es al espacio nulo de A^T.

Con subespacios ortogonales aparece la operación que domina el resto del apunte: **proyectar**. Dado un subespacio y un vector de afuera, la proyección es el punto del subespacio más cercano al vector, y resulta ser el único para el cual el error es perpendicular al subespacio. Esa operación se escribe como una matriz, y cuando el subespacio viene dado por una base ortonormal escrita en las columnas de Q esa matriz es simplemente $P = QQ^T$.

Las matrices Q con columnas ortonormales, que cumplen $Q^TQ = I$, son las protagonistas de la segunda mitad. Cuando además son cuadradas se llaman **ortogonales** y satisfacen $Q^{-1} = Q^T$: multiplicar por ellas no cambia longitudes ni ángulos, que es la razón por la que el cálculo numérico las prefiere a cualquier otra. Veremos una colección de ejemplos — rotaciones, reflexiones, permutaciones, reflexiones de Householder, rotaciones de Givens, matrices de Hadamard — que reaparecen constantemente.

Todo esto se junta al final en la **factorización** $A = QR$, que escribe cualquier matriz de columnas independientes como una matriz de columnas ortonormales por una triangular superior. La construiremos de dos maneras: con el proceso de Gram-Schmidt, que es el camino conceptual, y con reflexiones de Householder, que es el que se usa en la práctica. Los mínimos cuadrados, que son la gran aplicación de las proyecciones y de QR, tienen capítulo propio más adelante.

3.1 Vectores ortogonales

Las dos operaciones con las que vamos a trabajar ya están definidas: el **producto escalar** y la **norma euclídea** de la Sección 1.3.5 del Capítulo 1,

$$\boldsymbol{x}^T\boldsymbol{y} = x_1y_1 + x_2y_2 + \cdots + x_ny_n, \qquad \|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^T\boldsymbol{x}} = \sqrt{x_1^2 + \cdots + x_n^2},$$

junto con la noción de vectores **ortogonales**, que son los que cumplen $\boldsymbol{x}^T\boldsymbol{y} = 0$ y que anotamos $\boldsymbol{x} \perp \boldsymbol{y}$. Un vector es **unitario** si $\|\boldsymbol{x}\| = 1$, y el vector nulo es ortogonal a todos.

Allá dijimos que las propiedades quedaban para este capítulo, y de eso se trata esta sección: no de definir nada nuevo, sino de probar lo que esas dos operaciones cumplen. Dos propiedades son inmediatas desde la definición y conviene tenerlas a mano. Del producto escalar:

(1) $\boldsymbol{x}^T\boldsymbol{x} \geq 0$, y $\boldsymbol{x}^T\boldsymbol{x} = 0$ si y sólo si $\boldsymbol{x} = \boldsymbol{0}$;

(2) $\boldsymbol{x}^T\boldsymbol{y} = \boldsymbol{y}^T\boldsymbol{x}$ (es un número, luego igual a su traspuesta);

(3) $(a\boldsymbol{x} + \boldsymbol{y})^T\boldsymbol{u} = a\,\boldsymbol{x}^T\boldsymbol{u} + \boldsymbol{y}^T\boldsymbol{u}$ para todo $a \in \mathbb{R}$: el producto escalar es lineal en cada variable.

Y de la norma, las dos primeras propiedades de las tres que la definen: $\|\boldsymbol{x}\| \geq 0$ con igualdad sólo en $\boldsymbol{x} = \boldsymbol{0}$, y $\|a\boldsymbol{x}\| = |a|\,\|\boldsymbol{x}\|$.

La tercera, la **desigualdad triangular** $\|\boldsymbol{x}+\boldsymbol{y}\| \leq \|\boldsymbol{x}\|+\|\boldsymbol{y}\|$, no es inmediata: necesita la desigualdad de Cauchy-Schwarz, que probamos a continuación y que es además la que permite definir el *ángulo* entre dos vectores. Después de eso viene el teorema de Pitágoras, y con esas tres herramientas queda armado todo lo que el resto del capítulo necesita.

Teorema 3.1 (Desigualdad de Cauchy-Schwarz). Para todos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$,

$$|\boldsymbol{x}^T\boldsymbol{y}| \leq \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|,$$

con igualdad si y solo si $\boldsymbol{x}$ e $\boldsymbol{y}$ son linealmente dependientes.

Demostración. Si $\boldsymbol{x} = \boldsymbol{0}$ no hay nada que probar. Si no, miramos la función cuadrática en t

$$p(t) = \|t\boldsymbol{x} + \boldsymbol{y}\|^2 = (t\boldsymbol{x} + \boldsymbol{y})^T(t\boldsymbol{x} + \boldsymbol{y}) = t^2\,\|\boldsymbol{x}\|^2 + 2t\,\boldsymbol{x}^T\boldsymbol{y} + \|\boldsymbol{y}\|^2.$$

Como $p(t) \geq 0$ para todo t (¡es una norma al cuadrado!), la parábola no puede tener dos raíces reales distintas, así que su discriminante es ≤ 0:

$$4(\boldsymbol{x}^T\boldsymbol{y})^2 - 4\,\|\boldsymbol{x}\|^2\|\boldsymbol{y}\|^2 \leq 0.$$

Hay igualdad exactamente cuando p tiene una raíz doble t_0, es decir cuando $\|t_0\boldsymbol{x}+\boldsymbol{y}\| = 0$: cuando $\boldsymbol{y} = -t_0\boldsymbol{x}$ es múltiplo de $\boldsymbol{x}$. ∎

Proposición 3.2 (Desigualdad triangular). $\|\boldsymbol{x}+\boldsymbol{y}\| \leq \|\boldsymbol{x}\|+\|\boldsymbol{y}\|$ para todos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$.

Demostración. $\|\boldsymbol{x}+\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2+2\,\boldsymbol{x}^T\boldsymbol{y}+\|\boldsymbol{y}\|^2 \leq \|\boldsymbol{x}\|^2+2\|\boldsymbol{x}\|\|\boldsymbol{y}\|+\|\boldsymbol{y}\|^2 = (\|\boldsymbol{x}\|+\|\boldsymbol{y}\|)^2$, usando Cauchy-Schwarz en el término del medio. ∎

Cauchy-Schwarz dice que el cociente $\boldsymbol{x}^T\boldsymbol{y}/(\|\boldsymbol{x}\|\|\boldsymbol{y}\|)$ siempre cae en $[-1,1]$ (para vectores no nulos): por lo tanto es el coseno de un ángulo. *Definimos* el ángulo θ entre $\boldsymbol{x}$ e $\boldsymbol{y}$ por

$$\cos\theta = \frac{\boldsymbol{x}^T\boldsymbol{y}}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|},$$

que coincide con el ángulo geométrico en el plano que generan. Ser ortogonales es exactamente tener $\cos\theta = 0$, es decir $\theta = 90°$.

Observación 3.3 (Similitud coseno). En ciencia de datos, ese coseno se usa constantemente como medida de *similitud* entre dos vectores (documentos representados por conteos de palabras, *embeddings*, perfiles de usuarios): la **similitud coseno** compara direcciones ignorando las magnitudes. Dos vectores con las mismas proporciones tienen similitud 1 aunque uno sea "el doble de largo" que el otro (ese es justo el caso de igualdad de Cauchy-Schwarz). Los ortogonales tienen similitud 0: no comparten información direccional.

Teorema 3.4 (Pitágoras). Si $\boldsymbol{x} \perp \boldsymbol{y}$ entonces

$$\|\boldsymbol{x}-\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2 \qquad \text{y también} \qquad \|\boldsymbol{x}+\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2.$$

Demostración. Desarrollamos el cuadrado usando que el producto interno es lineal:

$$\|\boldsymbol{x}-\boldsymbol{y}\|^2 = (\boldsymbol{x}-\boldsymbol{y})^T(\boldsymbol{x}-\boldsymbol{y}) = \boldsymbol{x}^T\boldsymbol{x} - \boldsymbol{x}^T\boldsymbol{y} - \boldsymbol{y}^T\boldsymbol{x} + \boldsymbol{y}^T\boldsymbol{y} = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2 - 2\,\boldsymbol{x}^T\boldsymbol{y}.$$

Si $\boldsymbol{x}^T\boldsymbol{y} = 0$, los dos términos cruzados desaparecen y queda Pitágoras. El mismo cálculo con $\boldsymbol{x}+\boldsymbol{y}$ da el otro enunciado. ∎

Ejemplo 3.5. $\boldsymbol{x} = (1,2,2)^T$ y $\boldsymbol{y} = (2,1,-2)^T$ cumplen $\boldsymbol{x}^T\boldsymbol{y} = 2+2-4 = 0$. La hipotenusa es $\boldsymbol{x}-\boldsymbol{y} = (-1,1,4)^T$ y Pitágoras dice $18 = 9+9$. □

Observación 3.6 (Ley de cosenos). Sin suponer ortogonalidad, el cálculo de la demostración anterior da

$$\|\boldsymbol{x}-\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2 - 2\,\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|\cos\theta,$$

la ley de cosenos $c^2 = a^2 + b^2 - 2ab\cos\theta$. Los vectores ortogonales tienen $\cos\theta = 0$ y ese último término desaparece.

El caso complejo

Para vectores complejos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{C}^n$ el test cambia: hay que conjugar. El producto interno usual se define como

$$\overline{\boldsymbol{x}}^T\boldsymbol{y} = \overline{x}_1 y_1 + \cdots + \overline{x}_n y_n, \qquad \|\boldsymbol{x}\|^2 = \overline{\boldsymbol{x}}^T\boldsymbol{x} = |x_1|^2 + \cdots + |x_n|^2,$$

y $\boldsymbol{x} \perp \boldsymbol{y}$ significa $\overline{\boldsymbol{x}}^T\boldsymbol{y} = 0$.

¿Por qué conjugar? Porque sin conjugar la norma deja de servir. Lo único que le pedimos a $\|\boldsymbol{x}\|^2$ es que sea un número *real y no negativo*, que valga cero sólo en el vector nulo; eso es lo que permite hablar de longitudes y de distancias. Si copiáramos la fórmula real sin cambios, tendríamos $\boldsymbol{x}^T\boldsymbol{x} = \sum_k x_k^2$, y los cuadrados de números complejos no tienen por qué ser positivos ni siquiera reales. El ejemplo más chico lo muestra: para $\boldsymbol{x} = (1,i)^T$ es

$$\boldsymbol{x}^T\boldsymbol{x} = 1^2 + i^2 = 1 - 1 = 0,$$

o sea un vector no nulo tendría longitud cero. En cambio, conjugando el primer factor cada término se vuelve $\overline{x}_k x_k = |x_k|^2 \geq 0$, y entonces

$$\overline{\boldsymbol{x}}^T \boldsymbol{x} = |x_1|^2 + \cdots + |x_n|^2 \ \geq 0,$$

que se anula sólo si todas las coordenadas son nulas. Para el mismo ejemplo, $\overline{\boldsymbol{x}}^T \boldsymbol{x} = |1|^2 + |i|^2 = 2$ y $\|\boldsymbol{x}\| = \sqrt{2}$, que es lo razonable.

El precio es que el producto deja de ser simétrico: ahora $\overline{\boldsymbol{y}}^T \boldsymbol{x} = \overline{\overline{\boldsymbol{x}}^T \boldsymbol{y}}$, es decir, intercambiar los argumentos conjuga el resultado. Y la linealidad vale en la segunda variable pero en la primera aparece un conjugado: $\overline{(c\boldsymbol{x})}^T \boldsymbol{y} = \overline{c}\, \overline{\boldsymbol{x}}^T \boldsymbol{y}$. Todo lo demás — Cauchy-Schwarz, Pitágoras, la desigualdad triangular, las proyecciones — sigue valiendo palabra por palabra, cambiando $\boldsymbol{x}^T$ por $\overline{\boldsymbol{x}}^T$. La matriz de Fourier de los ejercicios es el ejemplo estrella de ortogonalidad compleja.

3.2 Bases ortogonales y ortonormales

Definición 3.7. Una base $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r$ de un subespacio **de** $\mathbb{R}^n$ es una **base ortogonal** si $\boldsymbol{v}_i^T \boldsymbol{v}_j = 0$ para todo $i \neq j$. Si además todos los vectores son unitarios ($\boldsymbol{v}_i^T \boldsymbol{v}_i = 1$), es una **base ortonormal**. En ese caso escribimos $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_r$:

$$\boldsymbol{q}_i^T \boldsymbol{q}_j = \begin{cases} 0 & i \neq j \\ 1 & i = j. \end{cases}$$

De ortogonal a ortonormal se pasa dividiendo cada vector por su norma: $\boldsymbol{q}_i = \boldsymbol{v}_i / \|\boldsymbol{v}_i\|$. El ejemplo más simple es la **base canónica** $\boldsymbol{e}_1, \ldots, \boldsymbol{e}_n$ de $\mathbb{R}^n$, que es ortonormal: en $\mathbb{R}^3$,

$$\boldsymbol{i} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \boldsymbol{j} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad \boldsymbol{k} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Proposición 3.8. Vectores ortogonales no nulos son linealmente independientes.

Demostración. Supongamos $c_1 \boldsymbol{v}_1 + \cdots + c_r \boldsymbol{v}_r = \boldsymbol{0}$ con los $\boldsymbol{v}_i$ ortogonales no nulos. Multiplicando por $\boldsymbol{v}_k^T$ a la izquierda, todos los productos $\boldsymbol{v}_k^T \boldsymbol{v}_i$ con $i \neq k$ se anulan y queda $c_k\, \boldsymbol{v}_k^T \boldsymbol{v}_k = 0$. Como $\boldsymbol{v}_k \neq \boldsymbol{0}$, es $\|\boldsymbol{v}_k\|^2 > 0$ y por lo tanto $c_k = 0$, para cada k. ∎

¿ Cuál es el análogo en $\mathbb{C}^n$?

Coeficientes en una base ortonormal

Aquí está la gran ventaja práctica de la ortonormalidad. Si $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_n$ es una base ortonormal de $\mathbb{R}^n$, todo vector se escribe

$$\boldsymbol{v} = c_1 \boldsymbol{q}_1 + c_2 \boldsymbol{q}_2 + \cdots + c_n \boldsymbol{q}_n. \tag{3.1}$$

En una base cualquiera, encontrar los c_i exige resolver un sistema lineal. En una base ortonormal, *cada coeficiente se obtiene por separado con un producto interno*:

Teorema 3.9 (Coeficientes en una base ortonormal)**.**

$$c_1 = \boldsymbol{q}_1^T \boldsymbol{v}, \qquad c_2 = \boldsymbol{q}_2^T \boldsymbol{v}, \qquad \dots \qquad c_n = \boldsymbol{q}_n^T \boldsymbol{v}.$$

Demostración. *Demostración vectorial.* Multiplicamos (3.1) por $\boldsymbol{q}_1^T$:

$$\boldsymbol{q}_1^T \boldsymbol{v} = c_1\, \boldsymbol{q}_1^T \boldsymbol{q}_1 + c_2\, \boldsymbol{q}_1^T \boldsymbol{q}_2 + \cdots + c_n\, \boldsymbol{q}_1^T \boldsymbol{q}_n = c_1,$$

porque todos los términos se anulan salvo $c_1 \boldsymbol{q}_1^T \boldsymbol{q}_1 = c_1$. Lo mismo con cada $\boldsymbol{q}_k$.

Demostración matricial. La ecuación (3.1) es $\boldsymbol{v} = Q\boldsymbol{c}$ con $Q = [\boldsymbol{q}_1 \ \cdots \ \boldsymbol{q}_n]$. Multiplicando por Q^T:

$$Q^T \boldsymbol{v} = Q^T Q\, \boldsymbol{c} = \boldsymbol{c},$$

que da todos los coeficientes $c_k = \boldsymbol{q}_k^T \boldsymbol{v}$ de una sola vez. ∎

Observación 3.10. Esta es la aplicación clave de las bases ortonormales (por ejemplo, la base de las series de Fourier): cada coeficiente se calcula de manera independiente de los demás. Los términos $c_k \boldsymbol{q}_k$ son las componentes de $\boldsymbol{v}$ a lo largo de los ejes ortogonales definidos por la base: son las proyecciones de $\boldsymbol{v}$ sobre esos ejes.

¿ Cuál es el análogo en $\mathbb{C}^n$?

Matrices de Hadamard

¿Existen bases ortogonales de $\mathbb{R}^n$ formadas solo por 1 y -1? Para $n = 2, 4, 8$ sí, y son las columnas de las **matrices de Hadamard**:

$$H_2 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \qquad H_4 = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix} \qquad H_8 = \begin{bmatrix} H_4 & H_4 \\ H_4 & -H_4 \end{bmatrix}.$$

¿Son matrices ortogonales? *No todavía*: sus columnas tienen normas $\sqrt{2}, \sqrt{4}, \sqrt{8}$. Dividiendo por esas normas obtenemos bases ortonormales de $\mathbb{R}^2, \mathbb{R}^4, \mathbb{R}^8$, y la construcción por bloques $H_{2n} = \left[\begin{smallmatrix} H_n & H_n \\ H_n & -H_n \end{smallmatrix}\right]$ continúa la lista para $n = 16, 32, \dots$

Observación 3.11 (Conjetura de Hadamard)**.** Si H_n existe (con $n > 2$), entonces n debe ser múltiplo de 4 (ver ejercicios). La **conjetura de Hadamard** propone la recíproca: que hay una matriz de ± 1 con columnas ortogonales siempre que 4 divide a n. Sigue abierta; el tamaño más chico sin matriz de Hadamard conocida es $n = 668$.

3.3 Subespacios ortogonales en $\mathbb{R}^n$ con el producto interno usual

Definición 3.12. Dos subespacios $\mathbf{V}$ y $\mathbf{W}$ de $\mathbb{R}^n$ son **ortogonales** si todo vector de $\mathbf{V}$ es ortogonal a todo vector de $\mathbf{W}$: $\boldsymbol{v}^T \boldsymbol{w} = 0$ para todo $\boldsymbol{v} \in \mathbf{V}$, $\boldsymbol{w} \in \mathbf{W}$. El **complemento ortogonal** de $\mathbf{V}$ es

$$\mathbf{V}^\perp = \{\boldsymbol{w} \in \mathbb{R}^n : \ \boldsymbol{w}^T \boldsymbol{v} = 0 \text{ para todo } \boldsymbol{v} \in \mathbf{V}\}.$$

En $\mathbb{R}^3$, dos paredes perpendiculares *no* son subespacios ortogonales: comparten la recta de intersección, y un vector no nulo nunca es ortogonal a sí mismo. Dos subespacios ortogonales solo se cortan en $\{\mathbf{0}\}$ (por Pitágoras, o por la Proposición 3.8).

Observación 3.13 (Ortogonales no es lo mismo que complementos)**.** Dos subespacios ortogonales no son necesariamente complementos ortogonales uno del otro. En $\mathbb{R}^3$, $\mathbf{U} = \operatorname{span}\{(1,0,0)\}$ y $\mathbf{W} = \operatorname{span}\{(0,1,0)\}$ son ortogonales, pero el complemento ortogonal de $\mathbf{U}$ es $\mathbf{U}^\perp = \operatorname{span}\{(0,1,0),(0,0,1)\}$, que contiene *estrictamente* a $\mathbf{W}$: falta una dimensión. Ser complementos exige más que ser ortogonales: las dimensiones tienen que sumar n.

Proposición 3.14 (Descomposición ortogonal)**.** Sea $\mathbf{W}$ un subespacio de $\mathbb{R}^n$. Entonces:

(i) $\mathbf{W} \cap \mathbf{W}^\perp = \{\mathbf{0}\}$;

(ii) todo $\boldsymbol{v} \in \mathbb{R}^n$ se escribe de manera *única* como $\boldsymbol{v} = \boldsymbol{w} + \boldsymbol{z}$ con $\boldsymbol{w} \in \mathbf{W}$ y $\boldsymbol{z} \in \mathbf{W}^\perp$ (escribimos $\mathbb{R}^n = \mathbf{W} \oplus \mathbf{W}^\perp$);

(iii) $\dim \mathbf{W}^\perp = n - \dim \mathbf{W}$;

(iv) $(\mathbf{W}^\perp)^\perp = \mathbf{W}$.

Demostración. (i) Si $\boldsymbol{w}$ está en ambos, es ortogonal a sí mismo: $\boldsymbol{w}^T\boldsymbol{w} = 0$ y $\boldsymbol{w} = \mathbf{0}$.

(ii) *Existencia:* tomemos una base ortonormal $\boldsymbol{q}_1, \dots, \boldsymbol{q}_r$ de $\mathbf{W}$ (existe por Gram-Schmidt, Sección 3.5, que no usa nada de esta proposición). Sea $\boldsymbol{w} = \boldsymbol{q}_1(\boldsymbol{q}_1^T\boldsymbol{v}) + \cdots + \boldsymbol{q}_r(\boldsymbol{q}_r^T\boldsymbol{v}) \in \mathbf{W}$ y $\boldsymbol{z} = \boldsymbol{v} - \boldsymbol{w}$. Para cada k, $\boldsymbol{q}_k^T\boldsymbol{z} = \boldsymbol{q}_k^T\boldsymbol{v} - \boldsymbol{q}_k^T\boldsymbol{v} = 0$, y como todo elemento de $\mathbf{W}$ es combinación de los $\boldsymbol{q}_k$, resulta $\boldsymbol{z} \perp \mathbf{W}$. *Unicidad:* si $\boldsymbol{w}_1 + \boldsymbol{z}_1 = \boldsymbol{w}_2 + \boldsymbol{z}_2$, entonces $\boldsymbol{w}_1 - \boldsymbol{w}_2 = \boldsymbol{z}_2 - \boldsymbol{z}_1 \in \mathbf{W} \cap \mathbf{W}^\perp = \{\mathbf{0}\}$.

(iii) Juntando una base de $\mathbf{W}$ con una de $\mathbf{W}^\perp$ se obtiene, por (ii), un conjunto generador de $\mathbb{R}^n$ que es independiente (Proposición 3.8 aplicada por bloques, o directamente por (i)): una base. Las dimensiones suman n.

(iv) $\mathbf{W} \subseteq (\mathbf{W}^\perp)^\perp$ es inmediato de la definición. Recíprocamente, si $\boldsymbol{v} \in (\mathbf{W}^\perp)^\perp$, escribimos $\boldsymbol{v} = \boldsymbol{w} + \boldsymbol{z}$ como en (ii); entonces $\boldsymbol{z}^T\boldsymbol{z} = \boldsymbol{z}^T(\boldsymbol{v} - \boldsymbol{w}) = \boldsymbol{z}^T\boldsymbol{v} - \boldsymbol{z}^T\boldsymbol{w} = 0 - 0 = 0$ (el primer término se anula porque $\boldsymbol{z} \in \mathbf{W}^\perp$ y $\boldsymbol{v}$ es ortogonal a todo $\mathbf{W}^\perp$). Luego $\boldsymbol{z} = \mathbf{0}$ y $\boldsymbol{v} = \boldsymbol{w} \in \mathbf{W}$. ∎

El ejemplo que organiza todo el curso viene de $A\boldsymbol{x} = \mathbf{0}$:

Teorema 3.15 (Espacio fila ⊥ espacio nulo)**.** Para toda matriz A de $m \times n$:

$$C(A^T) \perp N(A) \qquad \text{y} \qquad C(A) \perp N(A^T).$$

Más aún, $N(A) = C(A^T)^\perp$ y $N(A^T) = C(A)^\perp$.

Demostración. La definición del espacio nulo ya contiene la ortogonalidad. Que $A\boldsymbol{x} = \mathbf{0}$ significa que *cada fila* de A multiplica a $\boldsymbol{x}$ y da cero:

$$A\boldsymbol{x} = \begin{bmatrix} \text{fila 1 de } A \\ \vdots \\ \text{fila } m \text{ de } A \end{bmatrix} \begin{bmatrix} \\ \boldsymbol{x} \\ \\ \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Entonces $\boldsymbol{x}$ es ortogonal a cada fila, y por linealidad a cada combinación de filas: a todo el espacio fila $C(A^T)$. Recíprocamente, si $\boldsymbol{x}$ es ortogonal a todas las filas, entonces $A\boldsymbol{x} = \mathbf{0}$; por eso $N(A)$ es *exactamente* el complemento ortogonal del espacio fila.

Aplicando lo mismo a $A^T\boldsymbol{y} = \mathbf{0}$: las columnas de A (filas de A^T) son todas ortogonales a $\boldsymbol{y}$, y también sus combinaciones. El espacio columna de A es ortogonal al espacio nulo de A^T. ∎

Observación 3.16 (Las dimensiones encajan). Las dimensiones r y $n-r$ suman n: una base del espacio fila (r vectores) junto con una base del espacio nulo ($n-r$ vectores) forma una base de todo $\mathbb{R}^n$. En consecuencia, **todo vector $\boldsymbol{v} \in \mathbb{R}^n$ se descompone de manera única** como

$$\boldsymbol{v} = \boldsymbol{v}_{\text{fila}} + \boldsymbol{v}_{\text{nulo}}, \qquad \boldsymbol{v}_{\text{fila}} \in C(A^T), \quad \boldsymbol{v}_{\text{nulo}} \in N(A),$$

y las dos componentes son ortogonales entre sí. Lo mismo pasa en $\mathbb{R}^m$ con $C(A)$ y $N(A^T)$, de dimensiones r y $m-r$.

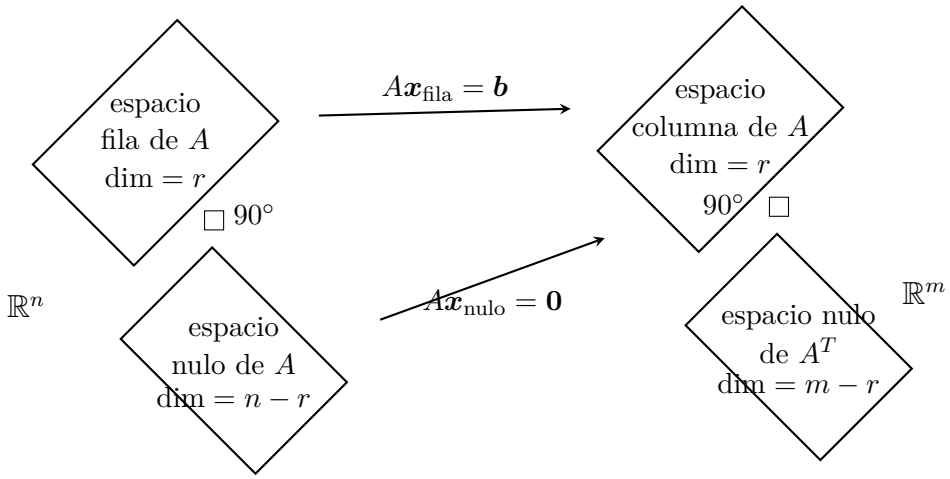


Figura 3.1. Dos pares de subespacios ortogonales. Las dimensiones suman n y suman m. Esta es la *gran figura* del álgebra lineal: dos subespacios en $\mathbb{R}^n$ y dos en $\mathbb{R}^m$.

Corolario 3.17 (Los cuatro subespacios, completo). Sea $A \in \mathbb{R}^{m\times n}$ de rango r. Entonces

$$\mathbb{R}^n = C(A^T) \oplus N(A), \qquad \mathbb{R}^m = C(A) \oplus N(A^T),$$

y ambas descomposiciones son ortogonales. En particular

$$\dim C(A^T) = r, \quad \dim N(A) = n-r, \qquad \dim C(A) = r, \quad \dim N(A^T) = m-r,$$

y $\big(C(A^T)\big)^{\perp\perp} = C(A^T)$, $\big(N(A)\big)^{\perp} = C(A^T)$.

Demostración. Por el Teorema 3.15, $N(A) = C(A^T)^{\perp}$; la Proposición 3.14 aplicada a $\mathbf{W} = C(A^T)$ da la suma directa ortogonal y $\dim N(A) = n - \dim C(A^T) = n-r$. Lo mismo con A^T en lugar de A. ∎

Observación 3.18 (Dónde se calcula esta descomposición). El Corolario 3.17 dice que todo $\boldsymbol{x} \in \mathbb{R}^n$ se parte de manera única en $\boldsymbol{x} = \boldsymbol{x}_{\text{fila}} + \boldsymbol{x}_{\text{nulo}}$, pero no dice cómo calcular

las dos piezas. La respuesta está en la sección siguiente: si P es la proyección ortogonal sobre el espacio fila, entonces $\boldsymbol{x}_{\text{fila}} = P\boldsymbol{x}$ y $\boldsymbol{x}_{\text{nulo}} = (I - P)\boldsymbol{x}$. Las proyecciones son la herramienta *computacional* que corresponde a esta figura.

Observación 3.19 (Dos consecuencias que usaremos todo el tiempo). De $N(A) = C(A^T)^\perp$ se deduce en dos líneas que

$$N(A^TA) = N(A) \qquad \text{y} \qquad C(A^TA) = C(A^T),$$

donde la primera igualdad ya apareció en el Ejercicio de desarrollo 1.1 del Capítulo 1 y dice, en particular, que *A^TA es invertible si y sólo si las columnas de A son independientes*. Esa es la hipótesis que hará falta para proyectar sobre $C(A)$ cuando la base no sea ortonormal.

Observación 3.20 (Anticipo: las bases especiales de la SVD). Gram-Schmidt (Sección 3.5) produce bases ortonormales $\boldsymbol{v}_1, \dots, \boldsymbol{v}_r$ del espacio fila y $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ del espacio columna. La descomposición en valores singulares (SVD), el teorema más importante de la ciencia de datos, encuentra bases con una propiedad extra: cada par queda conectado por A,

$$A\boldsymbol{v}_1 = \sigma_1\boldsymbol{u}_1, \quad A\boldsymbol{v}_2 = \sigma_2\boldsymbol{u}_2, \quad \dots \quad A\boldsymbol{v}_r = \sigma_r\boldsymbol{u}_r.$$

En la Figura 3.1: multiplicar por A lleva una base ortogonal de $\boldsymbol{v}$'s (a la izquierda) a una base ortogonal de $\boldsymbol{u}$'s (a la derecha). Volveremos sobre esto.

3.4 Proyecciones ortogonales en $\mathbb{R}^n$ con el producto interno usual

Proyección sobre una recta

Sea $\boldsymbol{a} \neq \boldsymbol{0}$ y sea la recta $\text{span}\{\boldsymbol{a}\}$. La **proyección ortogonal** de $\boldsymbol{b}$ sobre esa recta es el punto de la recta más cercano a $\boldsymbol{b}$. Todo punto de la recta es un múltiplo $\alpha\,\boldsymbol{a}$ con $\alpha \in \mathbb{R}$, así que buscamos el *escalar* α para el cual el *error* $\boldsymbol{e} = \boldsymbol{b} - \alpha\,\boldsymbol{a}$ resulta ortogonal a $\boldsymbol{a}$:

$$\boldsymbol{a}^T(\boldsymbol{b} - \alpha\,\boldsymbol{a}) = 0 \qquad \Longrightarrow \qquad \alpha = \frac{\boldsymbol{a}^T\boldsymbol{b}}{\boldsymbol{a}^T\boldsymbol{a}} \qquad \Longrightarrow \qquad \boxed{\boldsymbol{p} = \frac{\boldsymbol{a}^T\boldsymbol{b}}{\boldsymbol{a}^T\boldsymbol{a}}\,\boldsymbol{a}}$$

En forma matricial, $\boldsymbol{p} = P\boldsymbol{b}$ con $P = \dfrac{\boldsymbol{a}\,\boldsymbol{a}^T}{\boldsymbol{a}^T\boldsymbol{a}}$, una matriz de rango uno. Si el vector es unitario, $\boldsymbol{q} = \boldsymbol{a}/\|\boldsymbol{a}\|$, la fórmula es simplemente $P = \boldsymbol{q}\boldsymbol{q}^T$ y $\boldsymbol{p} = \boldsymbol{q}(\boldsymbol{q}^T\boldsymbol{b})$: el coeficiente $\boldsymbol{q}^T\boldsymbol{b}$ del Teorema 3.9 multiplicado por $\boldsymbol{q}$.

Proyección sobre un subespacio: $P = QQ^T$

Sea $\mathbf{V}$ un subespacio de $\mathbb{R}^m$ con base ortonormal $\boldsymbol{q}_1, \dots, \boldsymbol{q}_r$, y sea $Q = [\boldsymbol{q}_1 \ \cdots \ \boldsymbol{q}_r]$ de $m \times r$, de modo que $Q^TQ = I_r$. Con una base ortonormal, proyectar sobre $\mathbf{V}$ es proyectar sobre cada eje y sumar:

$$\boldsymbol{p} = \boldsymbol{q}_1(\boldsymbol{q}_1^T\boldsymbol{b}) + \cdots + \boldsymbol{q}_r(\boldsymbol{q}_r^T\boldsymbol{b}) = QQ^T\boldsymbol{b}.$$

Teorema 3.21. La matriz $P = QQ^T$ satisface

$$P = P^T = P^2,$$

y $P\boldsymbol{b}$ es la proyección ortogonal de $\boldsymbol{b}$ sobre $C(Q)$: el error $\boldsymbol{e} = \boldsymbol{b} - P\boldsymbol{b}$ es ortogonal a $C(Q)$, y $P\boldsymbol{b}$ es el punto de $C(Q)$ más cercano a $\boldsymbol{b}$. Recíprocamente, toda matriz con $P^2 = P = P^T$ es la proyección ortogonal sobre su espacio columna.

Demostración. Simetría: $(QQ^T)^T = QQ^T$. Idempotencia: en el medio eliminamos $Q^TQ = I$,

$$P^2 = (QQ^T)(QQ^T) = Q\,(Q^TQ)\,Q^T = QQ^T = P.$$

El error es ortogonal al subespacio: para cada columna $\boldsymbol{q}_k$,

$$Q^T(\boldsymbol{b} - QQ^T\boldsymbol{b}) = Q^T\boldsymbol{b} - (Q^TQ)Q^T\boldsymbol{b} = Q^T\boldsymbol{b} - Q^T\boldsymbol{b} = \boldsymbol{0}.$$

Y estar más cerca es Pitágoras: si $\boldsymbol{v} \in C(Q)$ es cualquier otro punto, $\boldsymbol{b} - \boldsymbol{v} = (\boldsymbol{b} - P\boldsymbol{b}) + (P\boldsymbol{b} - \boldsymbol{v})$ con los dos sumandos ortogonales (el primero es el error, el segundo vive en $C(Q)$), así que $\|\boldsymbol{b} - \boldsymbol{v}\|^2 = \|\boldsymbol{b} - P\boldsymbol{b}\|^2 + \|P\boldsymbol{b} - \boldsymbol{v}\|^2 \geq \|\boldsymbol{b} - P\boldsymbol{b}\|^2$.

Recíproca. Sea ahora P cualquier matriz con $P^2 = P = P^T$ y sea $\mathbf{W} = C(P)$. Para todo $\boldsymbol{b}$: primero, $P\boldsymbol{b} \in \mathbf{W}$. Segundo, el "error" $\boldsymbol{b} - P\boldsymbol{b}$ está en el espacio nulo de P, porque $P(\boldsymbol{b} - P\boldsymbol{b}) = P\boldsymbol{b} - P^2\boldsymbol{b} = \boldsymbol{0}$; y por simetría $N(P) = N(P^T) = C(P)^\perp$ (Teorema 3.15). Es decir, $P\boldsymbol{b} \in \mathbf{W}$ y $\boldsymbol{b} - P\boldsymbol{b} \perp \mathbf{W}$: por la unicidad de la descomposición ortogonal (Proposición 3.14), $P\boldsymbol{b}$ es *la* proyección ortogonal de $\boldsymbol{b}$ sobre $\mathbf{W}$. Las dos condiciones $P^2 = P$ y $P = P^T$ caracterizan completamente a las proyecciones ortogonales. ■

Ejercicio de desarrollo 3.1 | Proyecciones oblicuas: por qué se pide $P = P^T$

El Teorema 3.21 caracteriza las proyecciones ortogonales con *dos* condiciones, $P^2 = P$ y $P = P^T$. Este ejercicio explora qué queda si se conserva sólo la primera.

(a) Sea $P \in \mathbb{R}^{n\times n}$ con $P^2 = P$ (*idempotente*), sin suponer simetría. Probar que $\mathbb{R}^n = C(P) \oplus N(P)$ y que, en esa descomposición, $P\boldsymbol{x}$ es la componente de $\boldsymbol{x}$ en $C(P)$ *a lo largo de* $N(P)$. Probar también que $I - P$ es idempotente, con $C(I - P) = N(P)$ y $N(I - P) = C(P)$. La suma es directa, pero en general *no* es ortogonal.

(b) Verificarlo en $P = \left[\begin{smallmatrix} 1 & 1 \\ 0 & 0 \end{smallmatrix}\right]$: comprobar $P^2 = P$, identificar $C(P)$ y $N(P)$, dibujarlos, y marcar en el dibujo cómo se proyecta un vector cualquiera.

(c) Para $P_t = \left[\begin{smallmatrix} 1 & t \\ 0 & 0 \end{smallmatrix}\right]$ con $t \in \mathbb{R}$, calcular $\|P_t\boldsymbol{x}\|$ para $\boldsymbol{x} = (0, 1)^T$ y mostrar que el cociente $\|P_t\boldsymbol{x}\|/\|\boldsymbol{x}\|$ se puede hacer tan grande como se quiera. Comparar con el caso ortogonal, donde siempre $\|P\boldsymbol{x}\| \leq \|\boldsymbol{x}\|$ (¿por qué?). *Esta es la razón de fondo para exigir $P = P^T$: las proyecciones oblicuas amplifican, y todo lo que amplifica amplifica también los errores.*

(d) Probar que, para P idempotente, $P = P^T$ si y sólo si $N(P) = C(P)^\perp$.

(e) Construir una matriz idempotente de 2×2 cuyo espacio columna y espacio nulo formen un ángulo de $30°$, y calcular para ella el máximo de $\|P\boldsymbol{x}\|/\|\boldsymbol{x}\|$. ¿Qué pasa con ese máximo cuando el ángulo tiende a cero?

Se entrega por escrito. El ítem (c) explica por qué en todo el curso "proyección" significa "proyección ortogonal" salvo aviso en contrario.

Observación 3.22 (La proyección complementaria). Toda proyección parte a $\boldsymbol{b}$ en dos piezas perpendiculares:

$$\boldsymbol{b} = \underbrace{P\boldsymbol{b}}_{\text{en } C(Q)} + \underbrace{(I-P)\boldsymbol{b}}_{\text{ortogonal a } C(Q)}.$$

La matriz $I-P$ *también* es una proyección ortogonal, y proyecta sobre el complemento ortogonal $C(Q)^\perp$. En efecto, cumple las dos condiciones del Teorema 3.21:

$$(I-P)^T = I - P^T = I - P, \qquad (I-P)^2 = I - 2P + P^2 = I - 2P + P = I - P,$$

usando $P^T = P$ y $P^2 = P$. Y su espacio columna es $C(Q)^\perp$, porque $(I-P)\boldsymbol{b}$ es el error, que ya vimos que es ortogonal a $C(Q)$; recíprocamente, si $\boldsymbol{w} \perp C(Q)$ entonces $P\boldsymbol{w} = \boldsymbol{0}$ y por lo tanto $\boldsymbol{w} = (I-P)\boldsymbol{w} \in C(I-P)$.

Las dos proyecciones son, entonces, las dos mitades de la identidad: $P + (I-P) = I$. Esto ya había aparecido en la Sección 3.3 al descomponer un vector en su parte del espacio fila y su parte del espacio nulo.

Ejemplo 3.23. Tres matrices con columnas ortonormales, creciendo de 3×1 a 3×2 y a 3×3:

$$Q_1 = \frac{1}{3}\begin{bmatrix} 2 \\ 2 \\ -1 \end{bmatrix} \qquad Q_2 = \frac{1}{3}\begin{bmatrix} 2 & 2 \\ 2 & -1 \\ -1 & 2 \end{bmatrix} \qquad Q_3 = \frac{1}{3}\begin{bmatrix} 2 & 2 & -1 \\ 2 & -1 & 2 \\ -1 & 2 & 2 \end{bmatrix}.$$

Proyectemos el mismo $\boldsymbol{b} = (3,3,3)^T$ sobre los tres espacios columna.

Sobre la recta $C(Q_1)$:

$$P_1\boldsymbol{b} = Q_1(Q_1^T\boldsymbol{b}) = \frac{1}{3}\begin{bmatrix} 2 \\ 2 \\ -1 \end{bmatrix} \cdot \frac{2\cdot 3 + 2\cdot 3 - 1\cdot 3}{3} = \begin{bmatrix} 2 \\ 2 \\ -1 \end{bmatrix}, \qquad \boldsymbol{e} = \begin{bmatrix} 1 \\ 1 \\ 4 \end{bmatrix}, \quad \|\boldsymbol{e}\| = \sqrt{18}.$$

Sobre el plano $C(Q_2)$ (que contiene a la recta anterior):

$$P_2\boldsymbol{b} = Q_2(Q_2^T\boldsymbol{b}) = \begin{bmatrix} 4 \\ 1 \\ 1 \end{bmatrix}, \qquad \boldsymbol{e} = \begin{bmatrix} -1 \\ 2 \\ 2 \end{bmatrix}, \quad \|\boldsymbol{e}\| = \sqrt{9} = 3.$$

El error se achicó ($3 < \sqrt{18}$): el plano contiene a la recta, así que su punto más cercano a $\boldsymbol{b}$ está más cerca.

Sobre todo el espacio $C(Q_3) = \mathbb{R}^3$: ahora Q_3 es cuadrada, $P_3 = Q_3Q_3^T = I$, y $P_3\boldsymbol{b} = \boldsymbol{b}$. **El error es cero.** Proyectar sobre el espacio total no cambia nada. □

¿Y si la base no es ortonormal?

Todo lo anterior supone que tenemos a mano una base *ortonormal* del subespacio. En la práctica lo habitual es que el subespacio venga dado como $C(A)$, con las columnas de A independientes pero no ortonormales. La fórmula de la proyección sigue existiendo y es

$$P = A(A^TA)^{-1}A^T \tag{3.2}$$

que tiene sentido gracias a la Observación 3.19 (A^TA es invertible exactamente cuando las columnas de A son independientes) y que se reduce a QQ^T cuando $A = Q$ ya tiene columnas ortonormales, porque entonces $Q^TQ = I$. Demostrarla, y entender por qué es la proyección correcta, es el siguiente ejercicio de desarrollo.

Ejercicio de desarrollo 3.2 | La proyección sobre $C(A)$ con una base cualquiera

Sea $A \in \mathbb{R}^{m\times n}$ con columnas linealmente independientes y sea $P = A(A^TA)^{-1}A^T$.

(a) Probar que A^TA es invertible, de modo que P está bien definida. *Sugerencia:* es de $n \times n$; alcanza con ver que $N(A^TA) = N(A)$.

(b) Probar que $P^2 = P$ y $P^T = P$.

(c) Probar que $C(P) = C(A)$ y que $N(P) = C(A)^\perp$. Deducir que $\operatorname{rg}(P) = n$.

(d) Probar que, para todo $\boldsymbol{b} \in \mathbb{R}^m$, el error $\boldsymbol{b} - P\boldsymbol{b}$ es ortogonal a $C(A)$, y que $P\boldsymbol{b}$ es el punto de $C(A)$ más cercano a $\boldsymbol{b}$:

$$\|\boldsymbol{b} - P\boldsymbol{b}\| \le \|\boldsymbol{b} - \boldsymbol{v}\| \qquad \text{para todo } \boldsymbol{v} \in C(A),$$

con igualdad sólo si $\boldsymbol{v} = P\boldsymbol{b}$. *Sugerencia:* Pitágoras, como en el Teorema 3.21.

(e) *(No depende de la base.)* Sea $M \in \mathbb{R}^{n\times n}$ invertible y $B = AM$ (las columnas de B son otra base del mismo subespacio). Probar que $B(B^TB)^{-1}B^T = A(A^TA)^{-1}A^T$. Es decir: la proyección depende del *subespacio*, no de la base elegida para describirlo.

(f) Verificar que si las columnas de A son ortonormales, entonces (3.2) se reduce a $P = AA^T$.

(g) Probar que $\operatorname{tr}(P) = n$. *Sugerencia:* usar $\operatorname{tr}(XY) = \operatorname{tr}(YX)$ del Capítulo 1. (Es un caso particular del Corolario 5.11: para cualquier proyección, la traza es el rango.)

(h) Calcular P para

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

y verificar sobre esa matriz concreta los ítems (b), (c) y (g).

Se entrega por escrito. La fórmula (3.2) es la que resuelve el problema de mínimos cuadrados, que veremos en su propio capítulo; el ítem (e) explica por qué tiene sentido hablar de "la" proyección sobre un subespacio.

Volver a $A\boldsymbol{x} = \boldsymbol{b}$

Con las proyecciones en la mano podemos cerrar la discusión que quedó abierta en el Capítulo 2: allí vimos que el conjunto solución de $A\boldsymbol{x} = \boldsymbol{b}$, cuando no es vacío, es $\boldsymbol{x}_p + N(A)$, un trasladado del espacio nulo. La ortogonalidad permite decir dos cosas más: cómo reconocer sin resolver si el sistema es compatible, y cuál es, entre todas las soluciones, la

mejor.

Ejercicio de desarrollo 3.3 | Compatibilidad y la solución de norma mínima

Sea $A \in \mathbb{R}^{m\times n}$ y $\boldsymbol{b} \in \mathbb{R}^m$.

(a) *(Alternativa de Fredholm.)* Probar que

$$A\boldsymbol{x} = \boldsymbol{b} \text{ tiene solución} \iff \boldsymbol{y}^T\boldsymbol{b} = 0 \text{ para todo } \boldsymbol{y} \text{ con } A^T\boldsymbol{y} = \boldsymbol{0}.$$

Sugerencia: $C(A) = N(A^T)^\perp$, por el Teorema 3.15 y la Proposición 3.14(iv).

(b) Interpretarlo en términos de ecuaciones: cada $\boldsymbol{y} \in N(A^T)$ da una combinación lineal de las filas de A cuyo resultado es la ecuación $0 = \boldsymbol{y}^T\boldsymbol{b}$; el sistema es compatible exactamente cuando todas esas "ecuaciones vacías" son ciertas. Encontrar todas las condiciones de compatibilidad del sistema

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 1 & 3 \end{bmatrix} \boldsymbol{x} = \boldsymbol{b},$$

calculando primero $N(A^T)$.

(c) Supongamos ahora el sistema compatible. Probar que todas sus soluciones tienen la *misma* componente en el espacio fila: si $\boldsymbol{x}$ y $\boldsymbol{x}'$ son soluciones y las escribimos como $\boldsymbol{x} = \boldsymbol{x}_{\text{fila}} + \boldsymbol{x}_{\text{nulo}}$ según el Corolario 3.17, entonces $\boldsymbol{x}_{\text{fila}} = \boldsymbol{x}'_{\text{fila}}$.

(d) Deducir que hay exactamente *una* solución que pertenece a $C(A^T)$, y que es la de **norma mínima**: para toda solución $\boldsymbol{x}$,

$$\|\boldsymbol{x}\|^2 = \|\boldsymbol{x}_{\text{fila}}\|^2 + \|\boldsymbol{x}_{\text{nulo}}\|^2 \;\geq\; \|\boldsymbol{x}_{\text{fila}}\|^2,$$

con igualdad si y sólo si $\boldsymbol{x} = \boldsymbol{x}_{\text{fila}}$.

(e) Probar que la restricción de A al espacio fila,

$$A\big|_{C(A^T)} : C(A^T) \longrightarrow C(A),$$

es una biyección. *(Esta es la semilla de la inversa generalizada y de las bases especiales $A\boldsymbol{v}_k = \sigma_k\boldsymbol{u}_k$ de la SVD.)*

(f) Para

$$A = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 3 \end{bmatrix},$$

describir todas las soluciones y hallar la de norma mínima de dos maneras: proyectando una solución cualquiera sobre $C(A^T)$, y buscándola directamente de la forma $\boldsymbol{x} = A^T\boldsymbol{z}$. Comprobar que dan lo mismo y explicar por qué toda solución de la forma $A^T\boldsymbol{z}$ está en el espacio fila.

Se entrega por escrito. El ítem (a) convierte la condición $\boldsymbol{b} \in C(A)$, que es difícil de verificar, en una ortogonalidad que se chequea; los ítems (d) y (e) son el punto de partida de la inversa generalizada.

3.5 Ortogonalización de Gram-Schmidt con el producto interno usual en $\mathbb{R}^n$

Aquí hay un hecho clave: **todo subespacio de $\mathbb{R}^n$ tiene una base ortogonal** (y, normalizando, una ortonormal). Pensemos en un plano de $\mathbb{R}^3$ generado por dos vectores independientes $\boldsymbol{a}$ y $\boldsymbol{b}$. Para conseguir una base ortogonal del mismo plano, a $\boldsymbol{b}$ le restamos su componente en la dirección de $\boldsymbol{a}$ (¡una proyección!):

$$\text{Base ortogonal:} \quad \boldsymbol{a} \qquad \text{y} \qquad \boldsymbol{c} = \boldsymbol{b} - \frac{\boldsymbol{a}^T\boldsymbol{b}}{\boldsymbol{a}^T\boldsymbol{a}}\,\boldsymbol{a}. \tag{3.3}$$

La cuenta lo confirma: $\boldsymbol{a}^T\boldsymbol{c} = \boldsymbol{a}^T\boldsymbol{b} - \dfrac{\boldsymbol{a}^T\boldsymbol{b}}{\boldsymbol{a}^T\boldsymbol{a}}\,\boldsymbol{a}^T\boldsymbol{a} = 0$. Y $\boldsymbol{c} \neq \boldsymbol{0}$ porque $\boldsymbol{b}$ no era múltiplo de $\boldsymbol{a}$. El plano generado no cambió: solo cambiamos la base.

Esta idea de "ortogonalizar" se aplica a cualquier cantidad de vectores, restando en cada paso las proyecciones sobre los vectores ya construidos. Ese es el **proceso de Gram-Schmidt**.

Teorema 3.24 (Gram-Schmidt). Sean $\boldsymbol{a}_1, \ldots, \boldsymbol{a}_r$ linealmente independientes. Definimos

$$\boldsymbol{v}_1 = \boldsymbol{a}_1, \qquad \boldsymbol{v}_k = \boldsymbol{a}_k - \sum_{j=1}^{k-1} \frac{\boldsymbol{v}_j^T\boldsymbol{a}_k}{\boldsymbol{v}_j^T\boldsymbol{v}_j}\,\boldsymbol{v}_j \qquad (k = 2, \ldots, r).$$

Entonces $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r$ son ortogonales, no nulos, y

$$\operatorname{span}\{\boldsymbol{v}_1, \ldots, \boldsymbol{v}_k\} = \operatorname{span}\{\boldsymbol{a}_1, \ldots, \boldsymbol{a}_k\} \qquad \text{para cada } k.$$

Normalizando, $\boldsymbol{q}_k = \boldsymbol{v}_k/\|\boldsymbol{v}_k\|$ es una base ortonormal del subespacio generado. En particular, *todo subespacio tiene una base ortonormal.*

Demostración. Por inducción en k. Para $k = 1$ no hay nada que probar. Supongamos que $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_{k-1}$ ya son ortogonales, no nulos, y generan lo mismo que $\boldsymbol{a}_1, \ldots, \boldsymbol{a}_{k-1}$. El vector $\boldsymbol{v}_k$ es $\boldsymbol{a}_k$ menos su proyección sobre el subespacio generado por $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_{k-1}$ (proyectar sobre cada eje ortogonal y sumar, como en la Sección 3.4). Para cada $i < k$:

$$\boldsymbol{v}_i^T\boldsymbol{v}_k = \boldsymbol{v}_i^T\boldsymbol{a}_k - \sum_{j=1}^{k-1} \frac{\boldsymbol{v}_j^T\boldsymbol{a}_k}{\boldsymbol{v}_j^T\boldsymbol{v}_j}\,\boldsymbol{v}_i^T\boldsymbol{v}_j = \boldsymbol{v}_i^T\boldsymbol{a}_k - \frac{\boldsymbol{v}_i^T\boldsymbol{a}_k}{\boldsymbol{v}_i^T\boldsymbol{v}_i}\,\boldsymbol{v}_i^T\boldsymbol{v}_i = 0,$$

porque en la suma solo sobrevive el término $j = i$. Además $\boldsymbol{v}_k \neq \boldsymbol{0}$: si fuera cero, $\boldsymbol{a}_k$ sería combinación de $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_{k-1}$, es decir de $\boldsymbol{a}_1, \ldots, \boldsymbol{a}_{k-1}$, contradiciendo la independencia. Los generados coinciden porque $\boldsymbol{v}_k$ difiere de $\boldsymbol{a}_k$ en una combinación de los anteriores. ∎

En la práctica conviene normalizar a medida que se avanza: así cada paso es "restar proyecciones sobre los $\boldsymbol{q}$ ya construidos y normalizar".

Algoritmo de Gram-Schmidt (entrada: $\boldsymbol{a}_1, \ldots, \boldsymbol{a}_r$ independientes; salida: $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_r$ ortonormales).

1. Inicializar: $\boldsymbol{q}_1 = \boldsymbol{a}_1/\|\boldsymbol{a}_1\|$.

2. Para $k = 2, \dots, r$: restar de $\boldsymbol{a}_k$ su proyección sobre lo ya construido,

$$\boldsymbol{v}_k = \boldsymbol{a}_k - \boldsymbol{q}_1(\boldsymbol{q}_1^T \boldsymbol{a}_k) - \cdots - \boldsymbol{q}_{k-1}(\boldsymbol{q}_{k-1}^T \boldsymbol{a}_k),$$

y normalizar: $\boldsymbol{q}_k = \boldsymbol{v}_k / \|\boldsymbol{v}_k\|$.

En cada paso, $\operatorname{span}\{\boldsymbol{q}_1, \dots, \boldsymbol{q}_k\} = \operatorname{span}\{\boldsymbol{a}_1, \dots, \boldsymbol{a}_k\}$: el subespacio construido crece de a una dimensión por vez.

Ejemplo 3.25 (Gram-Schmidt en acción). Ortogonalicemos

$$\boldsymbol{a}_1 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \qquad \boldsymbol{a}_2 = \begin{bmatrix} 2 \\ 0 \\ -2 \end{bmatrix}, \qquad \boldsymbol{a}_3 = \begin{bmatrix} 3 \\ -3 \\ 3 \end{bmatrix}.$$

Paso 1. $\boldsymbol{v}_1 = \boldsymbol{a}_1 = (1, -1, 0)^T$.

Paso 2. $\boldsymbol{v}_1^T \boldsymbol{a}_2 = 2$ y $\boldsymbol{v}_1^T \boldsymbol{v}_1 = 2$:

$$\boldsymbol{v}_2 = \boldsymbol{a}_2 - \frac{2}{2}\boldsymbol{v}_1 = \begin{bmatrix} 2 \\ 0 \\ -2 \end{bmatrix} - \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}.$$

Paso 3. $\boldsymbol{v}_1^T \boldsymbol{a}_3 = 6$, $\boldsymbol{v}_2^T \boldsymbol{a}_3 = -6$, $\boldsymbol{v}_2^T \boldsymbol{v}_2 = 6$:

$$\boldsymbol{v}_3 = \boldsymbol{a}_3 - \frac{6}{2}\boldsymbol{v}_1 - \frac{-6}{6}\boldsymbol{v}_2 = \begin{bmatrix} 3 \\ -3 \\ 3 \end{bmatrix} - \begin{bmatrix} 3 \\ -3 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Verificación: $\boldsymbol{v}_1^T \boldsymbol{v}_2 = 1 - 1 + 0 = 0$, $\boldsymbol{v}_1^T \boldsymbol{v}_3 = 0$, $\boldsymbol{v}_2^T \boldsymbol{v}_3 = 0$. Normalizando,

$$\boldsymbol{q}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \qquad \boldsymbol{q}_2 = \frac{1}{\sqrt{6}}\begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}, \qquad \boldsymbol{q}_3 = \frac{1}{\sqrt{3}}\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

es una base ortonormal de $\mathbb{R}^3$. □

Observación 3.26. En la Sección 3.7 veremos que este proceso, escrito en forma matricial, *es* una factorización: si las columnas de A son $\boldsymbol{a}_1, \dots, \boldsymbol{a}_r$ y las de Q son $\boldsymbol{q}_1, \dots, \boldsymbol{q}_r$, entonces $A = QR$ con R triangular superior.

3.6 Matrices reales ortogonales

Altas y delgadas primero: $Q^TQ = I$

Sea Q de $m \times r$ con columnas ortonormales $\boldsymbol{q}_1, \dots, \boldsymbol{q}_r$, es decir,

$$\boldsymbol{q}_i^T \boldsymbol{q}_j = \delta_{ij} = \begin{cases} 1 & \text{si } i = j, \\ 0 & \text{si } i \neq j. \end{cases}$$

Esas r^2 condiciones se resumen en una sola igualdad matricial. En efecto, las filas de Q^T son las columnas de Q traspuestas, de modo que al multiplicar Q^T por Q la entrada (i, j) del producto es

$$(Q^TQ)_{ij} = \text{fila}_i(Q^T)\ \text{col}_j(Q) = \boldsymbol{q}_i^T \boldsymbol{q}_j = \delta_{ij},$$

es decir, Q^TQ *es la tabla de todos los productos escalares entre columnas de* Q. Pedir que las columnas sean ortonormales es pedir que esa tabla sea la identidad:

$$Q^TQ = \begin{bmatrix} — & \boldsymbol{q}_1^T & — \\ & \vdots & \\ — & \boldsymbol{q}_r^T & — \end{bmatrix} \begin{bmatrix} | & & | \\ \boldsymbol{q}_1 & \cdots & \boldsymbol{q}_r \\ | & & | \end{bmatrix} = \begin{bmatrix} \boldsymbol{q}_1^T\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_1^T\boldsymbol{q}_r \\ \vdots & \ddots & \vdots \\ \boldsymbol{q}_r^T\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_r^T\boldsymbol{q}_r \end{bmatrix} = \begin{bmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{bmatrix} = I_r.$$

Conviene leer las dos lecturas por separado: los *unos* de la diagonal dicen que cada columna es unitaria, y los *ceros* de afuera dicen que cada par de columnas distintas es ortogonal. En resumen,

$$\text{las columnas de } Q \text{ son ortonormales} \iff Q^TQ = I_r$$

Vale la pena insistir en que esto *no* dice que Q sea invertible. La igualdad $Q^TQ = I_r$ dice que Q^T es inversa *a izquierda* de Q, y nada más; cuando $m > r$ la matriz Q ni siquiera es cuadrada. En ese caso se la llama **semiortogonal**, y el producto en el otro orden *no* da la identidad: $QQ^T \neq I_m$. De hecho ya sabemos qué es, porque es la proyección P del Teorema 3.21, una matriz de rango r; si fuera $QQ^T = I_m$ tendría rango $m > r$, imposible. Dicho de otro modo: las m filas de Q son m vectores de $\mathbb{R}^r$ y no pueden ser ortonormales si $m > r$, porque en $\mathbb{R}^r$ no entran más de r vectores ortonormales.

Proposición 3.27 (*Q* preserva normas y ángulos). Si $Q^TQ = I$ entonces, para todos $\boldsymbol{x}, \boldsymbol{y}$,

$$\|Q\boldsymbol{x}\| = \|\boldsymbol{x}\| \qquad \text{y} \qquad (Q\boldsymbol{x})^T(Q\boldsymbol{y}) = \boldsymbol{x}^T\boldsymbol{y}.$$

Demostración. $(Q\boldsymbol{x})^T(Q\boldsymbol{y}) = \boldsymbol{x}^TQ^TQ\,\boldsymbol{y} = \boldsymbol{x}^T\boldsymbol{y}$; con $\boldsymbol{y} = \boldsymbol{x}$ queda $\|Q\boldsymbol{x}\|^2 = \|\boldsymbol{x}\|^2$. ∎

Multiplicar por Q no cambia magnitudes ni ángulos. Esta es la razón por la que las matrices ortogonales son las favoritas del cálculo numérico: **los cálculos con Q nunca se desbordan**. Multiplicar muchas veces por matrices ortogonales no agranda ni achica los errores de redondeo.

Matrices ortogonales: cuadradas

Definición 3.28. Una **matriz ortogonal** es una matriz *cuadrada* con columnas ortonormales.

Teorema 3.29. Si Q es cuadrada, son equivalentes:

(i) las columnas de Q son ortonormales, es decir $Q^TQ = I$;

(ii) Q es invertible y $Q^{-1} = Q^T$;

(iii) $QQ^T = I$, es decir las filas de Q son ortonormales;

(iv) $\|Q\boldsymbol{x}\| = \|\boldsymbol{x}\|$ para todo $\boldsymbol{x}$.

Demostración. (i)⇒(ii): Q cuadrada con columnas ortonormales tiene columnas independientes (Proposición 3.8), luego es invertible; de $Q^TQ = I$, la inversa a izquierda Q^T es

la inversa. (ii)⇒(iii): $QQ^T = QQ^{-1} = I$, y ese producto calcula los productos internos entre filas: las filas son ortonormales (¡probablemente una base ortonormal distinta de la de las columnas!). (iii)⇒(i): aplicando (i)⇒(iii) a Q^T. (i)⇒(iv) es la Proposición 3.27. Para (iv)⇒(i): de $\|Q\boldsymbol{x}\|^2 = \|\boldsymbol{x}\|^2$ para todo $\boldsymbol{x}$ se recuperan los productos internos por polarización, $\boldsymbol{x}^T\boldsymbol{y} = \frac{1}{2}(\|\boldsymbol{x}+\boldsymbol{y}\|^2 - \|\boldsymbol{x}\|^2 - \|\boldsymbol{y}\|^2)$, aplicada a $Q\boldsymbol{x}$ y $Q\boldsymbol{y}$; en particular $\boldsymbol{q}_i^T\boldsymbol{q}_j = \boldsymbol{e}_i^T\boldsymbol{e}_j$. ∎

Observación 3.30. El nombre honesto sería "matriz ortonormal", pero la tradición manda: cuando Q es cuadrada y $Q^T = Q^{-1}$, se dice matriz ortogonal.

Observación 3.31 (La identidad como suma de matrices de rango uno). Escribamos $QQ^T = I$ con la multiplicación *columnas por filas* del Capítulo 1:

$$I = \boldsymbol{q}_1\boldsymbol{q}_1^T + \boldsymbol{q}_2\boldsymbol{q}_2^T + \cdots + \boldsymbol{q}_n\boldsymbol{q}_n^T.$$

¡La identidad descompuesta en n matrices de rango uno, una por cada eje de la base ortonormal! El caso trivial es $I = \sum_k \boldsymbol{e}_k\boldsymbol{e}_k^T$ con la base canónica. Aplicada a un vector, esta identidad es otra vez el Teorema 3.9:

$$\boldsymbol{v} = I\boldsymbol{v} = \boldsymbol{q}_1(\boldsymbol{q}_1^T\boldsymbol{v}) + \cdots + \boldsymbol{q}_n(\boldsymbol{q}_n^T\boldsymbol{v}) = c_1\boldsymbol{q}_1 + \cdots + c_n\boldsymbol{q}_n.$$

Y si en lugar de sumar los n términos sumamos solo r, obtenemos $\boldsymbol{q}_1\boldsymbol{q}_1^T + \cdots + \boldsymbol{q}_r\boldsymbol{q}_r^T = QQ^T$ con Q de $n \times r$: la proyección de la Sección 3.4. *Proyectar es truncar la identidad.*

Proposición 3.32 (Productos e inversas). Si Q_1 y Q_2 son ortogonales del mismo tamaño, entonces Q_1Q_2 es ortogonal, y $Q^{-1} = Q^T$ es ortogonal.

Demostración. $(Q_1Q_2)^T(Q_1Q_2) = Q_2^TQ_1^TQ_1Q_2 = Q_2^TQ_2 = I$. Y $(Q^T)^TQ^T = QQ^T = I$ por el Teorema 3.29. ∎

Matrices ortogonales famosas

1. Rotaciones. Cuando todo el plano gira un ángulo θ alrededor de $(0,0)$, las magnitudes no cambian y los ángulos entre vectores tampoco. Las columnas son las imágenes de $\boldsymbol{e}_1$ y $\boldsymbol{e}_2$: vectores unitarios ortogonales, con $\cos^2\theta + \sin^2\theta = 1$:

$$Q_{\text{rota}} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} = \textbf{rotación de ángulo } \theta, \qquad \det Q_{\text{rota}} = +1. \tag{3.4}$$

2. Reflexiones. Si multiplicamos la segunda columna por -1, las dos columnas siguen siendo ortogonales y unitarias:

$$Q_{\text{refleja}} = \begin{bmatrix} \cos\theta & \sin\theta \\ \sin\theta & -\cos\theta \end{bmatrix} = \textbf{reflexión en la recta a ángulo } \tfrac{\theta}{2}, \qquad \det Q_{\text{refleja}} = -1. \tag{3.5}$$

Esta Q refleja cada vector como en un espejo: la recta espejo forma ángulo $\theta/2$ con el eje x. La rotación tiene determinante $+1$ (el plano gira); la reflexión tiene determinante -1 (el plano se da vuelta).

Componer transformaciones es multiplicar matrices, y la Proposición 3.32 dice que el producto sigue siendo ortogonal: rotación por rotación = rotación; reflexión por

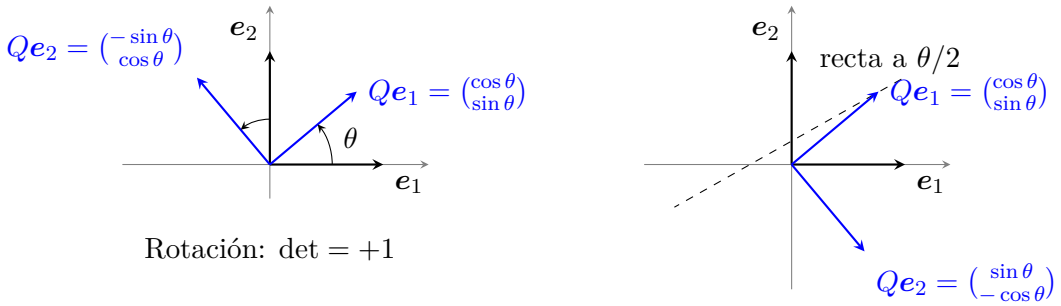


Figura 3.2. Girar todo el plano un ángulo θ; reflejar cada vector respecto de la recta a ángulo $\theta/2$ (con $\theta = 40°$). Las columnas de Q son $Q\boldsymbol{e}_1$ y $Q\boldsymbol{e}_2$.

reflexión = rotación; rotación por reflexión = reflexión (los determinantes se multiplican: $(+1)(+1) = +1$, $(-1)(-1) = +1$, $(+1)(-1) = -1$). Todo esto sigue valiendo en $\mathbb{R}^n$.

3. Reflexiones de Householder. Ejemplos hermosos de reflexiones en $\mathbb{R}^n$. Se elige un vector unitario $\boldsymbol{u}$ y se define

$$H = I - 2\,\boldsymbol{u}\boldsymbol{u}^T. \tag{3.6}$$

H es simétrica (es la identidad menos dos veces la matriz simétrica de rango uno $\boldsymbol{u}\boldsymbol{u}^T$) y es ortogonal: usando $\boldsymbol{u}^T\boldsymbol{u} = 1$,

$$H^TH = H^2 = (I - 2\boldsymbol{u}\boldsymbol{u}^T)(I - 2\boldsymbol{u}\boldsymbol{u}^T) = I - 4\boldsymbol{u}\boldsymbol{u}^T + 4\boldsymbol{u}\,(\boldsymbol{u}^T\boldsymbol{u})\,\boldsymbol{u}^T = I.$$

Dos reflexiones seguidas devuelven cada vector a su lugar. Geométricamente, H refleja respecto del hiperplano perpendicular a $\boldsymbol{u}$:

$$H\boldsymbol{u} = \boldsymbol{u} - 2\boldsymbol{u}(\boldsymbol{u}^T\boldsymbol{u}) = -\boldsymbol{u}, \qquad H\boldsymbol{w} = \boldsymbol{w} \quad \text{si } \boldsymbol{w} \perp \boldsymbol{u}.$$

Los "autovalores" de H son -1 (una vez, en la dirección $\boldsymbol{u}$) y $+1$ ($n-1$ veces, en el espejo): como toda reflexión.

Observación 3.33 (Reflexiones ↔ proyecciones). La construcción de Householder es un caso particular de una correspondencia general. Si P es *cualquier* proyección ortogonal ($P^2 = P = P^T$), la matriz

$$H = I - 2P$$

es simétrica y ortogonal: $H^2 = (I - 2P)^2 = I - 4P + 4P^2 = I$. Y refleja: para $\boldsymbol{w} \in C(P)$ es $H\boldsymbol{w} = \boldsymbol{w} - 2\boldsymbol{w} = -\boldsymbol{w}$, mientras que para $\boldsymbol{z} \perp C(P)$ es $H\boldsymbol{z} = \boldsymbol{z}$. Es la reflexión que invierte $C(P)$ y deja fijo su complemento ortogonal. Householder es el caso $P = \boldsymbol{u}\boldsymbol{u}^T$ (proyección sobre la recta de $\boldsymbol{u}$). Recíprocamente, si H es simétrica con $H^2 = I$, entonces

$$P = \tfrac{1}{2}(I - H)$$

cumple $P^T = P$ y $P^2 = \frac{1}{4}(I - 2H + H^2) = \frac{1}{4}(2I - 2H) = P$: es una proyección ortogonal. **Reflexiones y proyecciones son dos caras de la misma moneda**: $H = I - 2P$, $P = \frac{1}{2}(I - H)$.

Con $\boldsymbol{u} = (1, 1, \ldots, 1)^T/\sqrt{n}$, la fórmula $H_n = I - \frac{2}{n}\,\mathbf{unos}(n, n)$ da ejemplos fáciles de recordar:

$$H_3 = \frac{1}{3}\begin{bmatrix} 1 & -2 & -2 \\ -2 & 1 & -2 \\ -2 & -2 & 1 \end{bmatrix} \qquad H_4 = \frac{1}{2}\begin{bmatrix} 1 & -1 & -1 & -1 \\ -1 & 1 & -1 & -1 \\ -1 & -1 & 1 & -1 \\ -1 & -1 & -1 & 1 \end{bmatrix},$$

y H_4 se parece a una matriz de Hadamard.

Ejercicio de desarrollo 3.4 | Reflexiones de Householder

Sea $\boldsymbol{u} \in \mathbb{R}^n$ con $\|\boldsymbol{u}\| = 1$ y sea $H = I - 2\,\boldsymbol{u}\boldsymbol{u}^T$.

(a) Probar que $H^T = H$, que $H^2 = I$ y que H es ortogonal, y concluir que $H^{-1} = H$: *reflejar dos veces es no hacer nada.*

(b) Probar que $H\boldsymbol{u} = -\boldsymbol{u}$ y que $H\boldsymbol{w} = \boldsymbol{w}$ para todo $\boldsymbol{w} \perp \boldsymbol{u}$. Describir en palabras qué le hace H a un vector cualquiera, descomponiéndolo según $\mathbb{R}^n = \operatorname{span}\{\boldsymbol{u}\} \oplus \boldsymbol{u}^{\perp}$.

(c) *(El lema que hace funcionar todo.)* Sean $\boldsymbol{x} \neq \boldsymbol{y}$ con $\|\boldsymbol{x}\| = \|\boldsymbol{y}\|$. Probar que, tomando

$$\boldsymbol{u} = \frac{\boldsymbol{x} - \boldsymbol{y}}{\|\boldsymbol{x} - \boldsymbol{y}\|},$$

resulta $H\boldsymbol{x} = \boldsymbol{y}$. *Sugerencia:* calcular $\|\boldsymbol{x} - \boldsymbol{y}\|^2$ usando $\|\boldsymbol{x}\| = \|\boldsymbol{y}\|$ y ver que $\boldsymbol{u}^T\boldsymbol{x} = \frac{1}{2}\|\boldsymbol{x} - \boldsymbol{y}\|$.

(d) Aplicar el ítem anterior al caso que nos interesa: dado $\boldsymbol{x} \neq \boldsymbol{0}$, los únicos $\boldsymbol{y}$ múltiplos de $\boldsymbol{e}_1$ con $\|\boldsymbol{y}\| = \|\boldsymbol{x}\|$ son $\boldsymbol{y} = \pm\|\boldsymbol{x}\|\,\boldsymbol{e}_1$. Escribir $\boldsymbol{u}$ explícitamente en cada caso.

(e) Hacer las cuentas con $\boldsymbol{x} = (1, 2, 2)^T$ para las dos elecciones de signo y verificar que

$$H = \frac{1}{3}\begin{bmatrix} 1 & 2 & 2 \\ 2 & 1 & -2 \\ 2 & -2 & 1 \end{bmatrix} \qquad \text{da} \qquad H\boldsymbol{x} = 3\,\boldsymbol{e}_1,$$

$$H' = \frac{1}{3}\begin{bmatrix} -1 & -2 & -2 \\ -2 & 2 & -1 \\ -2 & -1 & 2 \end{bmatrix} \qquad \text{da} \qquad H'\boldsymbol{x} = -3\,\boldsymbol{e}_1.$$

(f) *(Estabilidad — opcional.)* En el ítem (c) hay que dividir por $\|\boldsymbol{x} - \boldsymbol{y}\|$. Mostrar que, con $\boldsymbol{y} = \pm\|\boldsymbol{x}\|\boldsymbol{e}_1$,

$$\|\boldsymbol{x} - \boldsymbol{y}\|^2 = 2\|\boldsymbol{x}\|\big(\|\boldsymbol{x}\| \mp x_1\big),$$

y explicar por qué conviene elegir el signo $\boldsymbol{y} = -\operatorname{sgn}(x_1)\,\|\boldsymbol{x}\|\,\boldsymbol{e}_1$. ¿Qué pasa si se elige el otro y $\boldsymbol{x}$ ya está casi alineado con $\boldsymbol{e}_1$?

(g) *(Costo — opcional.)* Para $X \in \mathbb{R}^{n\times k}$, comparar el costo de calcular HX ensamblando primero la matriz H con el de calcular $X - \boldsymbol{u}\,(2\boldsymbol{u}^T X)$ sin ensamblarla nunca. *Las reflexiones de Householder no se guardan como matrices: se guarda el vector* $\boldsymbol{u}$.

Se entrega por escrito. Los ítems (c), (d) y (e) son exactamente lo que necesita la construcción de la factorización QR de la Sección 3.7: allí los usaremos sin volver a demostrarlos. Los ítems (f) y (g) son opcionales: explican, respectivamente, cómo se elige el signo y por qué estas reflexiones nunca se guardan como matrices.

4. Permutaciones. Ya las usamos: son las matrices que aparecieron en la Sección 2.6 del Capítulo 2 para intercambiar filas durante el pivoteo, y las que hacen que la factorización $PA = LU$ exista siempre. Una **matriz de permutación** P tiene las mismas columnas que la identidad, en algún orden; sus columnas son vectores canónicos distintos y por lo tanto ortonormales. Allá probamos $P^{-1} = P^T$ a mano, y dijimos que las matrices con esa propiedad se llamarían ortogonales: acá se cierra esa promesa, porque es exactamente la definición de arriba. La inversa es también una permutación: la que deshace el reordenamiento. Por ejemplo,

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix} \qquad \text{tiene columnas ortonormales, } P^T P = I.$$

5. Rotaciones de Givens. Son rotaciones que actúan sobre un solo par de coordenadas y dejan todas las demás quietas. Dados $i < j$ y un ángulo θ, la matriz $G(i, j, \theta) \in \mathbb{R}^{n \times n}$ es la identidad salvo las cuatro entradas

$$g_{ii} = g_{jj} = c = \cos\theta, \qquad g_{ij} = -s = -\sin\theta, \qquad g_{ji} = s = \sin\theta,$$

es decir, es la rotación (3.4) embebida en las filas y columnas i, j:

$$G(2, 4, \theta) = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & c & 0 & -s \\ 0 & 0 & 1 & 0 \\ 0 & s & 0 & c \end{bmatrix}.$$

Multiplicar $G\boldsymbol{x}$ sólo cambia las coordenadas i y j de $\boldsymbol{x}$, rotándolas en su plano. Eligiendo bien el ángulo se puede *anular* una de las dos: mientras Householder pone en cero toda una columna de un solo golpe, Givens lo hace entrada por entrada. Eso lo vuelve la herramienta adecuada cuando la matriz ya tiene muchos ceros y no queremos destruirlos.

Ejercicio de desarrollo 3.5 | Rotaciones de Givens

(a) Probar que $G(i, j, \theta)$ es ortogonal y que $\det G = +1$. Describir G^T en términos de G.

(b) Dado $\boldsymbol{x} \in \mathbb{R}^n$ con $(x_i, x_j) \neq (0, 0)$, hallar c y s con $c^2 + s^2 = 1$ tales que $G(i, j, \theta)\boldsymbol{x}$ tenga un cero en la coordenada j, y comprobar que en la coordenada i queda $\sqrt{x_i^2 + x_j^2}$. Escribir c y s sin usar funciones trigonométricas, y explicar cómo calcular $\sqrt{x_i^2 + x_j^2}$ sin que se desborde cuando x_i o x_j son muy grandes. *Sugerencia:* sacar factor común el mayor de los dos en valor absoluto.

(c) Verificar que las demás coordenadas de $\boldsymbol{x}$ no cambian, y que $\|G\boldsymbol{x}\| = \|\boldsymbol{x}\|$ (dos veces: por la Proposición 3.27 y haciendo la cuenta).

(d) *(Factorización QR por Givens.)* Describir cómo anular, una por una, todas las entradas debajo de la diagonal de una matriz $A \in \mathbb{R}^{m \times n}$ usando rotaciones de Givens, y verificar que se obtiene $G_N \cdots G_1 A = \widetilde{R}$ y por lo tanto $A = \widetilde{Q}\widetilde{R}$ con $\widetilde{Q} = G_1^T \cdots G_N^T$. ¿Cuántas rotaciones hacen falta si A es llena? Hacerlo

explícitamente con

$$A = \begin{bmatrix} 3 & 1 \\ 4 & 1 \\ 0 & 2 \end{bmatrix}.$$

(e) *(Cuándo conviene.)* Estimar el costo de QR por Givens para una matriz llena y compararlo con Householder. Después, contar cuántas rotaciones hacen falta si A es *tridiagonal* de $n \times n$, o si es de Hessenberg superior (ceros debajo de la primera subdiagonal). Explicar por qué en esos casos Givens gana por lejos.

(f) *(Actualizar una factorización.)* Supongamos conocida $A = \widetilde{Q}\widetilde{R}$ y que se agrega una fila nueva $\boldsymbol{a}^T$ al final de A. Mostrar cómo recuperar la factorización de la matriz ampliada con n rotaciones de Givens, en lugar de refactorizar desde cero. *Este es el procedimiento que se usa cuando los datos llegan de a una observación por vez.*

Se entrega por escrito. Las rotaciones de Givens vuelven a aparecer en el algoritmo QR para calcular autovalores, donde las matrices que hay que factorizar son justamente de Hessenberg.

Observación 3.34 (De dónde salen los vectores ortogonales). Cuando una matriz es simétrica u ortogonal, **tiene autovectores ortogonales**. Esta es la fuente más importante de vectores ortogonales de la matemática aplicada, y es el corazón de los Capítulos 5 a 8: teorema espectral $S = Q\Lambda Q^T$ y SVD $A = U\Sigma V^T$. Los ejercicios sobre la matriz de Fourier (autovectores de una permutación) son el primer ejemplo de este fenómeno.

3.7 La factorización $A = QR$

Cerramos el capítulo juntando las dos ideas centrales: ortonormalizar (Gram-Schmidt) y reflejar (Householder). Las dos producen la misma factorización.

Gram-Schmidt en forma matricial

Sea $A \in \mathbb{R}^{m\times n}$ con columnas $\boldsymbol{a}_1, \dots, \boldsymbol{a}_n$ linealmente independientes, y apliquémosles Gram-Schmidt para obtener $\boldsymbol{q}_1, \dots, \boldsymbol{q}_n$. La clave es leer al revés el algoritmo: en el paso k escribimos

$$\boldsymbol{a}_k = (\boldsymbol{q}_1^T \boldsymbol{a}_k)\, \boldsymbol{q}_1 + \cdots + (\boldsymbol{q}_{k-1}^T \boldsymbol{a}_k)\, \boldsymbol{q}_{k-1} + \|\boldsymbol{v}_k\|\, \boldsymbol{q}_k,$$

porque $\boldsymbol{v}_k = \boldsymbol{a}_k - \sum_{j<k} (\boldsymbol{q}_j^T \boldsymbol{a}_k)\boldsymbol{q}_j$ y $\boldsymbol{q}_k = \boldsymbol{v}_k/\|\boldsymbol{v}_k\|$. Es decir: *cada $\boldsymbol{a}_k$ es combinación lineal de los primeros k vectores $\boldsymbol{q}$*, y los coeficientes son productos internos.

Acá es donde conviene recordar la fórmula (1.4) del Capítulo 1, que decía

$$\mathrm{col}_k(QR) = Q\ \mathrm{col}_k(R).$$

Leída de derecha a izquierda, dice exactamente lo que necesitamos: *una combinación lineal de las columnas de Q es una columna de un producto QR, y los coeficientes de esa combinación son la columna correspondiente de R.* Nuestra relación de arriba es precisamente una combinación lineal de $\boldsymbol{q}_1, \dots, \boldsymbol{q}_k$ que da $\boldsymbol{a}_k$, de modo que si llamamos $\boldsymbol{r}_k$ al vector de coeficientes,

$$\boldsymbol{r}_k = \big(\boldsymbol{q}_1^T \boldsymbol{a}_k,\ \dots,\ \boldsymbol{q}_{k-1}^T \boldsymbol{a}_k,\ \|\boldsymbol{v}_k\|,\ 0, \dots, 0\big)^T \in \mathbb{R}^n,$$

entonces $\boldsymbol{a}_k = Q\,\boldsymbol{r}_k$ para cada k. Poniendo esas n igualdades una al lado de la otra, es decir armando la matriz cuya columna k es $\boldsymbol{r}_k$, obtenemos de un saque

$$\underbrace{\begin{bmatrix}\boldsymbol{a}_1 & \cdots & \boldsymbol{a}_n\end{bmatrix}}_{A} = Q\,\underbrace{\begin{bmatrix}\boldsymbol{r}_1 & \cdots & \boldsymbol{r}_n\end{bmatrix}}_{R}, \qquad \text{o sea} \qquad A = QR,$$

donde los ceros al final de cada $\boldsymbol{r}_k$ son los que vuelven triangular superior a R. Explícitamente:

$$Q = \begin{bmatrix}\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_n\end{bmatrix} \in \mathbb{R}^{m\times n}, \qquad R = \begin{bmatrix} \|\boldsymbol{v}_1\| & \boldsymbol{q}_1^T\boldsymbol{a}_2 & \boldsymbol{q}_1^T\boldsymbol{a}_3 & \cdots & \boldsymbol{q}_1^T\boldsymbol{a}_n \\ 0 & \|\boldsymbol{v}_2\| & \boldsymbol{q}_2^T\boldsymbol{a}_3 & \cdots & \boldsymbol{q}_2^T\boldsymbol{a}_n \\ 0 & 0 & \|\boldsymbol{v}_3\| & \cdots & \boldsymbol{q}_3^T\boldsymbol{a}_n \\ \vdots & & & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \|\boldsymbol{v}_n\| \end{bmatrix} \in \mathbb{R}^{n\times n}.$$

La matriz R es triangular superior *porque* $\boldsymbol{a}_k$ no usa $\boldsymbol{q}_{k+1}, \ldots, \boldsymbol{q}_n$: el subespacio generado crece de a una dimensión por vez. Y su diagonal es positiva porque $\|\boldsymbol{v}_k\| > 0$.

Teorema 3.35 (Factorización QR reducida). Sea $A \in \mathbb{R}^{m\times n}$ con columnas linealmente independientes (en particular $m \geq n$). Entonces existen $Q \in \mathbb{R}^{m\times n}$ con columnas ortonormales y $R \in \mathbb{R}^{n\times n}$ triangular superior con diagonal positiva tales que

$$A = QR.$$

Además Q y R son *únicas* con esas condiciones.

Demostración. La existencia es la construcción de arriba. Para la unicidad, supongamos $Q_1R_1 = Q_2R_2$ con las dos R_i triangulares superiores de diagonal positiva (y por lo tanto invertibles). Entonces $Q_2^TQ_1 = R_2R_1^{-1}$. El miembro izquierdo es ortogonal: en efecto, $Q_1 = Q_2(R_2R_1^{-1})$ y multiplicando por su traspuesta, $I = Q_1^TQ_1 = (R_2R_1^{-1})^T(R_2R_1^{-1})$. Llamemos $T = R_2R_1^{-1}$: es triangular superior con diagonal positiva (producto e inversa de triangulares superiores de diagonal positiva) y cumple $T^TT = I$. Pero entonces $T^{-1} = T^T$ es a la vez triangular superior y triangular inferior, o sea diagonal; y una matriz diagonal con $T^TT = I$ y diagonal positiva es $T = I$. Luego $R_2 = R_1$ y $Q_2 = Q_1$. ∎

Ejemplo 3.36 (QR del Ejemplo 3.25). Con $\boldsymbol{a}_1 = (1,-1,0)^T$, $\boldsymbol{a}_2 = (2,0,-2)^T$, $\boldsymbol{a}_3 = (3,-3,3)^T$ habíamos obtenido $\boldsymbol{v}_1 = (1,-1,0)^T$, $\boldsymbol{v}_2 = (1,1,-2)^T$, $\boldsymbol{v}_3 = (1,1,1)^T$, de normas $\sqrt{2}, \sqrt{6}, \sqrt{3}$. Los coeficientes de R son $\boldsymbol{q}_1^T\boldsymbol{a}_2 = \sqrt{2}$, $\boldsymbol{q}_1^T\boldsymbol{a}_3 = 3\sqrt{2}$ y $\boldsymbol{q}_2^T\boldsymbol{a}_3 = -\sqrt{6}$, así que

$$\underbrace{\begin{bmatrix}1 & 2 & 3\\ -1 & 0 & -3\\ 0 & -2 & 3\end{bmatrix}}_{A} = \underbrace{\begin{bmatrix}\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}}\\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}}\\ 0 & -\frac{2}{\sqrt{6}} & \frac{1}{\sqrt{3}}\end{bmatrix}}_{Q} \underbrace{\begin{bmatrix}\sqrt{2} & \sqrt{2} & 3\sqrt{2}\\ 0 & \sqrt{6} & -\sqrt{6}\\ 0 & 0 & \sqrt{3}\end{bmatrix}}_{R}.$$

Conviene verificar columna por columna: la primera dice $\boldsymbol{a}_1 = \sqrt{2}\,\boldsymbol{q}_1$; la segunda, $\boldsymbol{a}_2 = \sqrt{2}\,\boldsymbol{q}_1 + \sqrt{6}\,\boldsymbol{q}_2$. □

Observación 3.37 (QR completa). La Q del Teorema 3.35 es *alta y delgada*: tiene columnas ortonormales pero no es una matriz ortogonal si $m > n$. Completando $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_n$ hasta

una base ortonormal de $\mathbb{R}^m$ se obtiene la **factorización QR completa**

$$A = \widetilde{Q}\,\widetilde{R}, \qquad \widetilde{Q} \in \mathbb{R}^{m\times m} \text{ ortogonal}, \qquad \widetilde{R} = \begin{bmatrix} R \\ 0 \end{bmatrix} \in \mathbb{R}^{m\times n},$$

donde las $m - n$ columnas nuevas de $\widetilde{Q}$ son una base ortonormal de $C(A)^\perp = N(A^T)$. Las dos versiones son útiles: la reducida es la que se guarda, la completa es la que se usa en las demostraciones.

QR por reflexiones de Householder

Gram-Schmidt construye Q ortonormalizando las columnas de A. La construcción de Householder hace exactamente lo contrario: deja A quieta y la va *triangulando* a fuerza de reflexiones, igual que la eliminación gaussiana la triangula a fuerza de restas de filas — con la diferencia capital de que ahora las operaciones son ortogonales y por lo tanto no amplifican los errores.

La herramienta son los ítems (c) y (d) del Ejercicio de desarrollo 3.4: dado $\boldsymbol{x}$, existe una reflexión H con

$$H\boldsymbol{x} = -\operatorname{sgn}(x_1)\,\|\boldsymbol{x}\|\,\boldsymbol{e}_1,$$

es decir, una reflexión que concentra todo $\boldsymbol{x}$ en su primera coordenada y anula las demás. Apliquémosla a la primera columna de A:

$$H_1 A = \begin{bmatrix} \rho_1 & \boldsymbol{r}_1^T \\ \mathbf{0} & A_1 \end{bmatrix}, \qquad \rho_1 = -\operatorname{sgn}(a_{11})\|\operatorname{col}_1(A)\|,$$

con $A_1 \in \mathbb{R}^{(m-1)\times(n-1)}$. Ahora repetimos sobre A_1: tomamos $H_2' \in \mathbb{R}^{(m-1)\times(m-1)}$ que anula todo debajo del primer elemento de $\operatorname{col}_1(A_1)$ y la embebemos sin tocar la primera fila ni la primera columna,

$$H_2 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H_2' \end{bmatrix},$$

que sigue siendo ortogonal y simétrica. Después de n pasos,

$$H_n \cdots H_2 H_1\, A = \begin{bmatrix} R \\ 0 \end{bmatrix}, \qquad \text{y por lo tanto} \qquad A = \underbrace{H_1 H_2 \cdots H_n}_{\widetilde{Q}} \begin{bmatrix} R \\ 0 \end{bmatrix},$$

usando que cada H_k es su propia inversa. El producto de matrices ortogonales es ortogonal (Proposición 3.32), así que $\widetilde{Q}$ lo es.

Teorema 3.38 (QR por Householder). Toda matriz $A \in \mathbb{R}^{m\times n}$ con $m \geq n$ admite una factorización $A = \widetilde{Q}\widetilde{R}$ con $\widetilde{Q} \in \mathbb{R}^{m\times m}$ ortogonal y $\widetilde{R} = \left[\begin{smallmatrix} R \\ 0 \end{smallmatrix}\right]$ con R triangular superior de $n \times n$. Si las columnas de A son independientes, R es invertible.

Observación 3.39 (Cuál conviene). Las dos construcciones dan la misma factorización cuando las columnas son independientes (por la unicidad del Teorema 3.35, salvo signos de las columnas de Q), pero no son equivalentes en la práctica.

- Gram-Schmidt es más transparente y da directamente la versión reducida, pero es *numéricamente frágil*: los $\boldsymbol{q}_k$ calculados pierden ortogonalidad a medida que k crece, y el efecto empeora cuanto más parecidas entre sí son las columnas de A. (La variante llamada *Gram-Schmidt modificado*, que resta las proyecciones de a una en lugar de todas juntas, es matemáticamente idéntica y numéricamente mucho mejor.)

- Householder trabaja siempre con matrices ortogonales, que por la Proposición 3.27 no agrandan nada, y produce una $\widetilde{Q}$ ortogonal hasta la precisión de la máquina. Además no hay que ensamblar ninguna H_k: alcanza con guardar los vectores $\boldsymbol{u}_k$.
- No hace falta que las columnas de A sean independientes: Householder funciona igual y los ceros aparecen solos en la diagonal de R.

Por eso todas las bibliotecas numéricas calculan QR con reflexiones de Householder.

Observación 3.40 (Para qué sirve). La factorización QR es la herramienta estándar para resolver el problema de **mínimos cuadrados**: minimizar $\|A\boldsymbol{x} - \boldsymbol{b}\|$. Como multiplicar por $\widetilde{Q}^T$ no cambia las normas,

$$\|A\boldsymbol{x} - \boldsymbol{b}\|^2 = \|\widetilde{Q}^T(A\boldsymbol{x} - \boldsymbol{b})\|^2 = \left\| \begin{bmatrix} R \\ 0 \end{bmatrix} \boldsymbol{x} - \begin{bmatrix} \boldsymbol{c}_1 \\ \boldsymbol{c}_2 \end{bmatrix} \right\|^2 = \|R\boldsymbol{x} - \boldsymbol{c}_1\|^2 + \|\boldsymbol{c}_2\|^2,$$

con $\boldsymbol{c} = \widetilde{Q}^T\boldsymbol{b}$. El primer término se puede hacer cero resolviendo el sistema triangular $R\boldsymbol{x} = \boldsymbol{c}_1$, y el segundo es el error mínimo, que no depende de $\boldsymbol{x}$. Desarrollamos esto en el capítulo dedicado a mínimos cuadrados, donde lo compararemos con las ecuaciones normales $A^TA\boldsymbol{x} = A^T\boldsymbol{b}$ que salen de la proyección (3.2). Allí se verá también por qué esta vía es preferible: formar A^TA eleva al cuadrado el número de condición del problema.

Ideas clave en $\mathbb{R}^n$

- **Ortogonalidad**: $\boldsymbol{x} \perp \boldsymbol{y} \iff \boldsymbol{x}^T\boldsymbol{y} = 0$ (caso complejo: $\overline{\boldsymbol{x}}^T\boldsymbol{y} = 0$). Pitágoras: $\|\boldsymbol{x} \pm \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2$. Cauchy-Schwarz: $|\boldsymbol{x}^T\boldsymbol{y}| \le \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$, que define el ángulo (similitud coseno) $\cos\theta = \boldsymbol{x}^T\boldsymbol{y}/(\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|)$.
- **Base ortonormal** $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_n$: los coeficientes de $\boldsymbol{v} = \sum c_k\boldsymbol{q}_k$ se obtienen por separado, $c_k = \boldsymbol{q}_k^T\boldsymbol{v}$ (matricialmente, $\boldsymbol{v} = Q\boldsymbol{c} \Rightarrow \boldsymbol{c} = Q^T\boldsymbol{v}$).
- **Subespacios ortogonales**: $C(A^T) \perp N(A)$ y $C(A) \perp N(A^T)$; las dimensiones suman n y m. Todo $\boldsymbol{v} = \boldsymbol{v}_{\text{fila}} + \boldsymbol{v}_{\text{nulo}}$, con componentes ortogonales; en general $\mathbb{R}^n = \mathbf{W} \oplus \mathbf{W}^\perp$ y $(\mathbf{W}^\perp)^\perp = \mathbf{W}$ (ortogonales $\neq$ complementos: las dimensiones deben sumar n).
- **Proyección**: con base ortonormal del subespacio, $P = QQ^T$ cumple $P = P^T = P^2$; el error $(I - P)\boldsymbol{b}$ es ortogonal al subespacio y $P\boldsymbol{b}$ es el punto más cercano. Recíprocamente, $P^2 = P = P^T$ *caracteriza* a las proyecciones ortogonales, y $H = I - 2P$ da la reflexión asociada. La identidad se descompone como $I = \sum_k \boldsymbol{q}_k\boldsymbol{q}_k^T$: proyectar es truncar esa suma.
- **Gram-Schmidt**: restar proyecciones ortogonaliza. Todo subespacio tiene base ortonormal.
- **Matriz ortogonal**: cuadrada con $Q^TQ = I$, o sea $Q^{-1} = Q^T$; preserva normas y ángulos ($\|Q\boldsymbol{x}\| = \|\boldsymbol{x}\|$). Famosas: rotaciones ($\det = +1$), reflexiones y Householder $H = I - 2\boldsymbol{u}\boldsymbol{u}^T$ ($\det = -1$), rotaciones de Givens, permutaciones, Hadamard/$\sqrt{n}$, Fourier (compleja). Productos e inversas de ortogonales son ortogonales.

- **Factorización** $A = QR$: Q con columnas ortonormales, R triangular superior de diagonal positiva; es Gram-Schmidt leído como producto de matrices, y es única. La misma factorización se obtiene triangulando A con reflexiones de Householder, que es la forma numéricamente estable y la que usan las bibliotecas.
- **Anticipo**: simétricas y ortogonales tienen autovectores ortogonales; proyecciones y $QR \to$ mínimos cuadrados.

Ejercicios

Las etiquetas indican el sabor de cada ejercicio: [Cálculo] para fijar la mecánica, [Concepto] para justificar y demostrar, [Datos] para la conexión con ciencia de datos. Las soluciones están al final del capítulo.

3.1 [Cálculo] Si $\boldsymbol{u}$ y $\boldsymbol{v}$ son vectores unitarios ortogonales, demuestre que $\boldsymbol{u} + \boldsymbol{v}$ es ortogonal a $\boldsymbol{u} - \boldsymbol{v}$. ¿Cuáles son las magnitudes de esos vectores?

3.2 [Cálculo] Dibuje dos vectores unitarios $\boldsymbol{u}$ y $\boldsymbol{v}$ que *no sean* ortogonales. Muestre que $\boldsymbol{w} = \boldsymbol{v} - \boldsymbol{u}(\boldsymbol{u}^T\boldsymbol{v})$ es ortogonal a $\boldsymbol{u}$ (y agregue $\boldsymbol{w}$ al gráfico). ¿Qué paso de Gram-Schmidt acaba de hacer?

3.3 [Concepto] Dibuje dos vectores $\boldsymbol{u}$ y $\boldsymbol{v}$ cualesquiera a partir del origen $(0, 0)$. Complete dos lados más para hacer un paralelogramo con diagonales $\boldsymbol{w} = \boldsymbol{u} + \boldsymbol{v}$ y $\boldsymbol{z} = \boldsymbol{u} - \boldsymbol{v}$. Muestre que $\boldsymbol{w}^T\boldsymbol{w} + \boldsymbol{z}^T\boldsymbol{z}$ es igual a $2\boldsymbol{u}^T\boldsymbol{u} + 2\boldsymbol{v}^T\boldsymbol{v}$ (*ley del paralelogramo*: la suma de los cuadrados de las diagonales es la suma de los cuadrados de los cuatro lados).

3.4 [Cálculo] Sean $\boldsymbol{x} = (1, i)^T$ y $\boldsymbol{y} = (i, 1)^T$ en $\mathbb{C}^2$.

(a) Calcule $\boldsymbol{x}^T\boldsymbol{y}$ y $\overline{\boldsymbol{x}}^T\boldsymbol{y}$. ¿Son $\boldsymbol{x}$ y $\boldsymbol{y}$ ortogonales?

(b) Calcule $\|\boldsymbol{x}\|$ y $\|\boldsymbol{y}\|$ con la norma correcta $\|\boldsymbol{x}\|^2 = \overline{\boldsymbol{x}}^T\boldsymbol{x}$. ¿Qué daría la fórmula real $\boldsymbol{x}^T\boldsymbol{x}$, y por qué es inaceptable?

3.5 [Concepto] Suponga que H_n es una matriz de Hadamard: entradas ± 1 y columnas ortogonales, con $n \geq 2$.

(a) Mirando dos columnas, muestre que n debe ser par.

(b) Mirando tres columnas, muestre que n debe ser múltiplo de 4. *Ayuda:* puede suponer que la primera columna es toda de unos (¿por qué?); cuente con $a =$ cantidad de filas donde la segunda y la tercera columna tienen ambas un $+1$, etc.

3.6 [Cálculo] Sea $\boldsymbol{q} = \frac{1}{3}(2, 2, -1)^T$ (unitario) y $P = \boldsymbol{q}\boldsymbol{q}^T$.

(a) Escriba la matriz P y verifique $P = P^T = P^2$. ¿Cuál es su rango?

(b) Proyecte $\boldsymbol{b} = (0, 3, 3)^T$ sobre la recta generada por $\boldsymbol{q}$ y verifique que el error $\boldsymbol{e} = \boldsymbol{b} - P\boldsymbol{b}$ es ortogonal a $\boldsymbol{q}$.

(c) ¿Sobre qué subespacio proyecta $I - P$? Verifique $\|P\boldsymbol{b}\|^2 + \|\boldsymbol{e}\|^2 = \|\boldsymbol{b}\|^2$.

3.7 [Cálculo] Aplique Gram-Schmidt a

$$\boldsymbol{a}_1 = \begin{bmatrix}1\\0\\1\end{bmatrix}, \qquad \boldsymbol{a}_2 = \begin{bmatrix}1\\1\\0\end{bmatrix}, \qquad \boldsymbol{a}_3 = \begin{bmatrix}0\\1\\1\end{bmatrix},$$

y escriba la base ortonormal resultante $\boldsymbol{q}_1, \boldsymbol{q}_2, \boldsymbol{q}_3$.

3.8 [Concepto] Propiedad clave de toda matriz ortogonal: $\|Q\boldsymbol{x}\|^2 = \|\boldsymbol{x}\|^2$ para todo vector $\boldsymbol{x}$. Más aún, muestre que $(Q\boldsymbol{x})^T(Q\boldsymbol{y}) = \boldsymbol{x}^T\boldsymbol{y}$ para todo par $\boldsymbol{x}, \boldsymbol{y}$. Entonces Q no modifica las magnitudes ni los ángulos. ¡Los cálculos con Q nunca se desbordan! Explique por qué esto también garantiza que las columnas de Q (las imágenes $Q\boldsymbol{e}_k$) son ortonormales.

3.9 [Cálculo] Con las matrices de (3.4) y (3.5):

(a) Multiplique dos rotaciones de ángulos θ_1 y θ_2 y muestre que el producto es la rotación de ángulo $\theta_1 + \theta_2$ (recupere las fórmulas de suma de senos y cosenos).

(b) Sin multiplicar matrices, use determinantes para decidir: ¿reflexión por reflexión es rotación o reflexión? ¿Y rotación por reflexión?

3.10 [Concepto] En $\mathbb{R}^2$, tome el vector unitario $\boldsymbol{u} = (-\sin\varphi, \cos\varphi)^T$, normal a la recta que forma ángulo φ con el eje x. Calcule $H = I - 2\boldsymbol{u}\boldsymbol{u}^T$ y muestre que coincide con la reflexión (3.5) con $\theta = 2\varphi$: las reflexiones de Householder en $\mathbb{R}^2$ son exactamente las matrices Q_{refleja}.

3.11 [Cálculo] Una **matriz de permutación** tiene las mismas columnas que la matriz identidad (en algún orden). *Explique por qué esta y todas las matrices de permutación son ortogonales*:

$$P = \begin{bmatrix}0&1&0&0\\0&0&1&0\\0&0&0&1\\1&0&0&0\end{bmatrix} \quad \text{tiene columnas ortonormales, entonces } P^TP = I \text{ y } P^{-1} = P^T.$$

¿Qué permutación es P^{-1}, en términos de la que hace P?

3.12 [Cálculo] Cuatro autovectores de esa matriz P son $\boldsymbol{x}_1 = (1,1,1,1)$, $\boldsymbol{x}_2 = (1, i, i^2, i^3)$, $\boldsymbol{x}_3 = (1, i^2, i^4, i^6)$ y $\boldsymbol{x}_4 = (1, i^3, i^6, i^9)$. Multiplique P por cada uno de esos vectores para encontrar $\lambda_1, \lambda_2, \lambda_3, \lambda_4$. Los autovectores son las columnas de la **matriz de Fourier** $\boldsymbol{F}$ de 4×4.

$$\text{Muestre que } Q = \frac{F}{2} = \frac{1}{2}\begin{bmatrix}1&1&1&1\\1&i&-1&i^3\\1&i^2&1&i^6\\1&i^3&-1&i^9\end{bmatrix} \text{ tiene columnas ortonormales : } \overline{Q}^TQ = I.$$

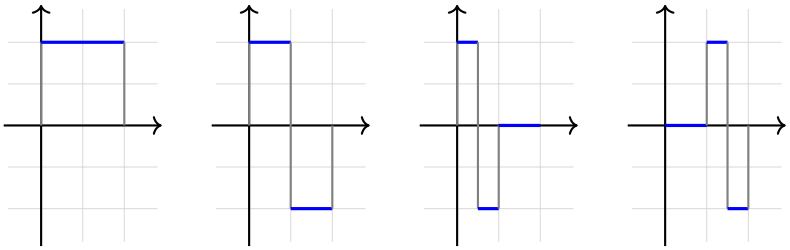
(La matriz de Fourier es la matriz ortogonal compleja más importante de la matemática aplicada. Como es compleja, el test correcto es $\overline{\boldsymbol{x}}_j^T\boldsymbol{x}_k = 0$.)

3.13 [Cálculo] **Las wavelets de Haar son vectores ortogonales (columnas de W) que usan solo $1, -1, 0$:**

$$n = 4 \qquad W = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & -1 & 0 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & 0 & -1 \end{bmatrix}$$

Encuentre $W^T W$, W^{-1} y las ocho wavelets de Haar para $n = 8$.

Las wavelets de Haar pueden pensarse como funciones con soporte en el intervalo $[0, 1]$. Son estudiadas en diferentes campos de la matemática y resultan una herramienta útil en informática e ingeniería, por ejemplo para la codificación de señales.



3.14 [Datos] (Compresión con la base de Haar.) Normalice las columnas de la matriz W del ejercicio anterior para obtener una base ortonormal $\boldsymbol{w}_1, \boldsymbol{w}_2, \boldsymbol{w}_3, \boldsymbol{w}_4$ de $\mathbb{R}^4$, y tome la "señal" $\boldsymbol{v} = (5, 3, -1, 1)^T$.

(a) Calcule los cuatro coeficientes $c_k = \boldsymbol{w}_k^T \boldsymbol{v}$ (¡cada uno por separado!) y verifique la reconstrucción $\boldsymbol{v} = \sum c_k \boldsymbol{w}_k$.

(b) Verifique la identidad de Parseval $\|\boldsymbol{v}\|^2 = c_1^2 + c_2^2 + c_3^2 + c_4^2$ y explique por qué vale en cualquier base ortonormal.

(c) *Comprima*: conserve solo los dos coeficientes más grandes y reconstruya $\widetilde{\boldsymbol{v}}$. ¿Qué forma tiene $\widetilde{\boldsymbol{v}}$ y cuánto vale el error $\|\boldsymbol{v} - \widetilde{\boldsymbol{v}}\|$? (Esta es la idea de la codificación de señales e imágenes: guardar pocos coeficientes en una base ortonormal bien elegida.)

3.15 [Datos] Sea Q ortogonal de $n \times n$ y sean $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N \in \mathbb{R}^n$ los puntos de un conjunto de datos.

(a) Muestre que $\|Q\boldsymbol{x}_i - Q\boldsymbol{x}_j\| = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|$ para todo par i, j: rotar (o reflejar) la nube de datos no cambia ninguna distancia.

(b) Concluya que cualquier método basado en distancias (por ejemplo, buscar el vecino más cercano de un punto) da exactamente el mismo resultado con los datos $\boldsymbol{x}_i$ que con los datos rotados $Q\boldsymbol{x}_i$.

(c) Si en cambio multiplicamos por una matriz invertible *no* ortogonal, dé un ejemplo de 2×2 donde el vecino más cercano de un punto cambie.

3.16 [Datos] (Similitud coseno.) Tres "documentos" se representan por sus conteos de tres palabras clave: $\boldsymbol{x} = (3, 1, 0)^T$, $\boldsymbol{y} = (6, 2, 0)^T$, $\boldsymbol{z} = (0, 2, 3)^T$.

(a) Calcule las tres similitudes coseno entre pares.

(b) ¿Por qué $\boldsymbol{x}$ e $\boldsymbol{y}$ tienen similitud exactamente 1? Relacione con el caso de igualdad de Cauchy-Schwarz.

(c) Explique por qué la similitud coseno es la medida natural cuando un documento puede ser "el doble de largo" que otro con el mismo tema.

3.17 [Concepto] (Reflexiones $\leftrightarrow$ proyecciones.) Sea P una proyección ortogonal ($P^2 = P = P^T$) y $H = I - 2P$.

(a) Muestre que H es simétrica y ortogonal, que $H\boldsymbol{w} = -\boldsymbol{w}$ para $\boldsymbol{w} \in C(P)$ y que $H\boldsymbol{z} = \boldsymbol{z}$ para $\boldsymbol{z} \perp C(P)$.

(b) Recíprocamente, si H es simétrica con $H^2 = I$, muestre que $P = \frac{1}{2}(I - H)$ es una proyección ortogonal.

(c) Tome $P = \boldsymbol{q}\boldsymbol{q}^T$ con $\boldsymbol{q} = \frac{1}{3}(2, 2, -1)^T$ (ejercicio **5.6**) y escriba la matriz $H = I - 2P$. ¿Qué hace H geométricamente?

Soluciones

3.1 $(\boldsymbol{u} + \boldsymbol{v})^T(\boldsymbol{u} - \boldsymbol{v}) = \boldsymbol{u}^T\boldsymbol{u} - \boldsymbol{u}^T\boldsymbol{v} + \boldsymbol{v}^T\boldsymbol{u} - \boldsymbol{v}^T\boldsymbol{v} = \|\boldsymbol{u}\|^2 - \|\boldsymbol{v}\|^2 = 1 - 1 = 0$. Las magnitudes: $\|\boldsymbol{u} \pm \boldsymbol{v}\|^2 = \|\boldsymbol{u}\|^2 + \|\boldsymbol{v}\|^2 = 2$ (Pitágoras), así que ambas diagonales miden $\sqrt{2}$.

3.2 $\boldsymbol{u}^T\boldsymbol{w} = \boldsymbol{u}^T\boldsymbol{v} - (\boldsymbol{u}^T\boldsymbol{u})(\boldsymbol{u}^T\boldsymbol{v}) = \boldsymbol{u}^T\boldsymbol{v} - \boldsymbol{u}^T\boldsymbol{v} = 0$, usando $\boldsymbol{u}^T\boldsymbol{u} = 1$. En el dibujo, $\boldsymbol{w}$ es $\boldsymbol{v}$ menos su "sombra" sobre $\boldsymbol{u}$. Es exactamente el paso 2 de Gram-Schmidt (3.3): restar a $\boldsymbol{v}$ su proyección sobre $\boldsymbol{u}$.

3.3 $\boldsymbol{w}^T\boldsymbol{w} + \boldsymbol{z}^T\boldsymbol{z} = (\|\boldsymbol{u}\|^2 + 2\boldsymbol{u}^T\boldsymbol{v} + \|\boldsymbol{v}\|^2) + (\|\boldsymbol{u}\|^2 - 2\boldsymbol{u}^T\boldsymbol{v} + \|\boldsymbol{v}\|^2) = 2\boldsymbol{u}^T\boldsymbol{u} + 2\boldsymbol{v}^T\boldsymbol{v}$. Los términos cruzados se cancelan entre las dos diagonales, sean o no ortogonales $\boldsymbol{u}$ y $\boldsymbol{v}$.

3.4 (a) $\boldsymbol{x}^T\boldsymbol{y} = 1 \cdot i + i \cdot 1 = 2i \neq 0$, pero el test correcto da $\overline{\boldsymbol{x}}^T\boldsymbol{y} = 1 \cdot i + \bar{i} \cdot 1 = i - i = 0$: sí son ortogonales. (b) $\|\boldsymbol{x}\|^2 = |1|^2 + |i|^2 = 2$, luego $\|\boldsymbol{x}\| = \|\boldsymbol{y}\| = \sqrt{2}$. La fórmula real daría $\boldsymbol{x}^T\boldsymbol{x} = 1 + i^2 = 0$: un vector no nulo con "norma" cero, inaceptable; por eso la norma compleja conjuga.

3.5 (a) Sean $\boldsymbol{h}_j, \boldsymbol{h}_k$ dos columnas. Cada producto $h_{ij}h_{ik}$ vale ± 1, y la suma de los n productos es 0: la mitad son $+1$ y la mitad -1, así que n es par. (b) Cambiar de signo una fila completa no altera ni las entradas ± 1 ni la ortogonalidad de las columnas; haciéndolo fila por fila podemos suponer que la columna 1 es toda de unos. Entonces, por (a) aplicado contra la columna 1, las columnas 2 y 3 tienen exactamente $n/2$ unos. Sean a, b, c, d las cantidades de filas donde (columna 2, columna 3) valen $(+,+), (+,-), (-,+), (-,-)$. Ortogonalidad con la columna 1: $a + b = c + d = n/2$ y $a + c = b + d = n/2$, de donde $b = c$ y $a = d$. Ortogonalidad entre las columnas 2 y 3: $a - b - c + d = 0$, o sea $2a = 2b$. Entonces $a = b = c = d$ y $n = 4a$: múltiplo de 4.

3.6 (a)

$$P = \boldsymbol{q}\boldsymbol{q}^T = \frac{1}{9}\begin{bmatrix} 4 & 4 & -2 \\ 4 & 4 & -2 \\ -2 & -2 & 1 \end{bmatrix},$$

claramente simétrica, y $P^2 = \boldsymbol{q}(\boldsymbol{q}^T\boldsymbol{q})\boldsymbol{q}^T = \boldsymbol{q}\boldsymbol{q}^T = P$ porque $\boldsymbol{q}^T\boldsymbol{q} = 1$. Es de rango 1 (todas las columnas son múltiplos de $\boldsymbol{q}$). (b) $\boldsymbol{q}^T\boldsymbol{b} = \frac{0+6-3}{3} = 1$, así que $P\boldsymbol{b} = \boldsymbol{q} =$

$(2/3, 2/3, -1/3)^T$ y $\boldsymbol{e} = \boldsymbol{b} - P\boldsymbol{b} = (-2/3, 7/3, 10/3)^T$; $\boldsymbol{q}^T\boldsymbol{e} = \frac{-4/3+14/3-10/3}{3} = 0$. (c) $I - P$ proyecta sobre el plano $\boldsymbol{q}^\perp$, el complemento ortogonal de la recta. Pitágoras: $\|P\boldsymbol{b}\|^2 + \|\boldsymbol{e}\|^2 = 1 + 17 = 18 = \|\boldsymbol{b}\|^2$.

3.7 $\boldsymbol{v}_1 = (1, 0, 1)^T$. Después $\boldsymbol{v}_2 = \boldsymbol{a}_2 - \frac{1}{2}\boldsymbol{v}_1 = (\frac{1}{2}, 1, -\frac{1}{2})^T$ (o, reescalado, $(1, 2, -1)^T$). Después, con $\boldsymbol{v}_1^T\boldsymbol{a}_3 = 1$ y $\boldsymbol{v}_2^T\boldsymbol{a}_3 = \frac{1}{2}$, $\boldsymbol{v}_2^T\boldsymbol{v}_2 = \frac{3}{2}$:

$$\boldsymbol{v}_3 = \boldsymbol{a}_3 - \frac{1}{2}\,\boldsymbol{v}_1 - \frac{1/2}{3/2}\,\boldsymbol{v}_2 = \left(-\tfrac{2}{3}, \tfrac{2}{3}, \tfrac{2}{3}\right)^T \quad \text{(o, reescalado, } (-1, 1, 1)^T\text{)}.$$

Normalizando:

$$\boldsymbol{q}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\0\\1\end{bmatrix}, \qquad \boldsymbol{q}_2 = \frac{1}{\sqrt{6}}\begin{bmatrix}1\\2\\-1\end{bmatrix}, \qquad \boldsymbol{q}_3 = \frac{1}{\sqrt{3}}\begin{bmatrix}-1\\1\\1\end{bmatrix}.$$

3.8 $(Q\boldsymbol{x})^T(Q\boldsymbol{y}) = \boldsymbol{x}^TQ^TQ\boldsymbol{y} = \boldsymbol{x}^T\boldsymbol{y}$; tomando $\boldsymbol{y} = \boldsymbol{x}$, $\|Q\boldsymbol{x}\|^2 = \|\boldsymbol{x}\|^2$. Como las normas y los productos internos no cambian, tampoco cambian los ángulos ($\cos\theta = \boldsymbol{x}^T\boldsymbol{y}/\|\boldsymbol{x}\|\|\boldsymbol{y}\|$), y los números nunca crecen al multiplicar por Q. Las columnas de Q son $Q\boldsymbol{e}_1, \ldots, Q\boldsymbol{e}_n$; el producto interno de dos de ellas es $(Q\boldsymbol{e}_i)^T(Q\boldsymbol{e}_j) = \boldsymbol{e}_i^T\boldsymbol{e}_j$, que vale 1 si $i = j$ y 0 si no: ortonormales.

3.9 (a) Escribiendo $c_k = \cos\theta_k$ y $s_k = \sin\theta_k$:

$$\begin{bmatrix}c_1 & -s_1\\ s_1 & c_1\end{bmatrix}\begin{bmatrix}c_2 & -s_2\\ s_2 & c_2\end{bmatrix} = \begin{bmatrix}c_1c_2 - s_1s_2 & -(c_1s_2 + s_1c_2)\\ s_1c_2 + c_1s_2 & c_1c_2 - s_1s_2\end{bmatrix},$$

que es la rotación de ángulo $\theta_1 + \theta_2$; comparando entradas se leen las fórmulas de suma $\cos(\theta_1 + \theta_2) = \cos\theta_1\cos\theta_2 - \sin\theta_1\sin\theta_2$ y $\sin(\theta_1 + \theta_2) = \sin\theta_1\cos\theta_2 + \cos\theta_1\sin\theta_2$. (b) El producto de dos ortogonales es ortogonal, y su determinante es el producto de los determinantes: reflexión por reflexión tiene $\det = (-1)(-1) = +1$, es una rotación; rotación por reflexión tiene $\det = -1$, es una reflexión.

3.10 Con $\boldsymbol{u} = (-\sin\varphi, \cos\varphi)^T$:

$$\boldsymbol{u}\boldsymbol{u}^T = \begin{bmatrix}\sin^2\varphi & -\sin\varphi\cos\varphi\\ -\sin\varphi\cos\varphi & \cos^2\varphi\end{bmatrix},$$

$$H = I - 2\boldsymbol{u}\boldsymbol{u}^T = \begin{bmatrix}1 - 2\sin^2\varphi & 2\sin\varphi\cos\varphi\\ 2\sin\varphi\cos\varphi & 1 - 2\cos^2\varphi\end{bmatrix} = \begin{bmatrix}\cos 2\varphi & \sin 2\varphi\\ \sin 2\varphi & -\cos 2\varphi\end{bmatrix},$$

usando las fórmulas del ángulo doble. Es (3.5) con $\theta = 2\varphi$: refleja respecto de la recta a ángulo $\theta/2 = \varphi$, que es justo la recta perpendicular a $\boldsymbol{u}$. Las Householder de 2×2 son todas las reflexiones.

3.11 Las columnas de P son los vectores canónicos $\boldsymbol{e}_4, \boldsymbol{e}_1, \boldsymbol{e}_2, \boldsymbol{e}_3$: distintos vectores de la base canónica, que es ortonormal. Entonces $P^TP = I$ y $P^{-1} = P^T$, que vuelve a ser una matriz de permutación: la que *deshace* el reordenamiento (si P corre cíclicamente las coordenadas hacia arriba, P^T las corre hacia abajo).

3.12 Multiplicar por P corre las coordenadas: $P(x_1,x_2,x_3,x_4)^T=(x_2,x_3,x_4,x_1)^T$. Entonces

$$P\boldsymbol{x}_1=\boldsymbol{x}_1\ (\lambda_1=1),\qquad P\boldsymbol{x}_2=(i,i^2,i^3,1)^T=i\,\boldsymbol{x}_2\ (\lambda_2=i),$$
$$P\boldsymbol{x}_3=(i^2,i^4,i^6,1)^T=i^2\boldsymbol{x}_3\ (\lambda_3=i^2=-1),\qquad P\boldsymbol{x}_4=i^3\boldsymbol{x}_4\ (\lambda_4=i^3=-i).$$

Los autovalores son las cuatro raíces cuartas de 1. Para la ortonormalidad, con $\omega=i$: la entrada (j,k) de $\overline{F}^TF$ es

$$\overline{\boldsymbol{x}}_j^T\boldsymbol{x}_k=\sum_{m=0}^{3}\overline{\omega^{jm}}\,\omega^{km}=\sum_{m=0}^{3}\omega^{(k-j)m}=\begin{cases}4 & j=k\\ \dfrac{\omega^{4(k-j)}-1}{\omega^{k-j}-1}=0 & j\neq k,\end{cases}$$

(suma geométrica de raíces de la unidad). Entonces $\overline{F}^TF=4I$ y $Q=F/2$ cumple $\overline{Q}^TQ=I$. Por ejemplo, $\overline{\boldsymbol{x}}_1^T\boldsymbol{x}_2=1+i+i^2+i^3=(1-1)+(i-i)=0$ y $\overline{\boldsymbol{x}}_2^T\boldsymbol{x}_3=(1,-i,-1,i)\,(1,i^2,i^4,i^6)^T=1+i-1-i=0$: al conjugar el primer vector, i se cambia por $-i$.

3.13 Las columnas de W son ortogonales (verificarlo par a par), con normas al cuadrado $4,4,2,2$:

$$W^TW=\begin{bmatrix}4&0&0&0\\0&4&0&0\\0&0&2&0\\0&0&0&2\end{bmatrix},\qquad W^{-1}=(W^TW)^{-1}W^T=\begin{bmatrix}1/4&1/4&1/4&1/4\\1/4&1/4&-1/4&-1/4\\1/2&-1/2&0&0\\0&0&1/2&-1/2\end{bmatrix}.$$

(Como las columnas son ortogonales pero no unitarias, la inversa es $D^{-1}W^T$ con $D=W^TW$ diagonal.) Para $n=8$, cada wavelet se "parte" en dos mitades de soporte:

$$W_8=\begin{bmatrix}1&1&1&0&1&0&0&0\\1&1&1&0&-1&0&0&0\\1&1&-1&0&0&1&0&0\\1&1&-1&0&0&-1&0&0\\1&-1&0&1&0&0&1&0\\1&-1&0&1&0&0&-1&0\\1&-1&0&-1&0&0&0&1\\1&-1&0&-1&0&0&0&-1\end{bmatrix}:$$

la constante; la que separa mitades; dos a escala $1/2$; y cuatro "finas" del tipo $(1,-1)$ en posiciones consecutivas.

3.14 Las columnas normalizadas son $\boldsymbol{w}_1=\frac12(1,1,1,1)^T$, $\boldsymbol{w}_2=\frac12(1,1,-1,-1)^T$, $\boldsymbol{w}_3=\frac{1}{\sqrt2}(1,-1,0,0)^T$, $\boldsymbol{w}_4=\frac{1}{\sqrt2}(0,0,1,-1)^T$. (a) $c_1=\frac{5+3-1+1}{2}=4$, $c_2=\frac{5+3+1-1}{2}=4$, $c_3=\frac{5-3}{\sqrt2}=\sqrt2$, $c_4=\frac{-1-1}{\sqrt2}=-\sqrt2$. Reconstrucción: $4\boldsymbol{w}_1+4\boldsymbol{w}_2=(4,4,0,0)^T$, $\sqrt2\,\boldsymbol{w}_3=(1,-1,0,0)^T$, $-\sqrt2\,\boldsymbol{w}_4=(0,0,-1,1)^T$; la suma es $(5,3,-1,1)^T=\boldsymbol{v}$. (b) $\|\boldsymbol{v}\|^2=25+9+1+1=36$ y $c_1^2+c_2^2+c_3^2+c_4^2=16+16+2+2=36$. En general $\boldsymbol{v}=Q\boldsymbol{c}$ con Q ortogonal, y entonces $\|\boldsymbol{v}\|=\|Q\boldsymbol{c}\|=\|\boldsymbol{c}\|$: las matrices ortogonales preservan normas. (c) Conservando $c_1=c_2=4$: $\widetilde{\boldsymbol{v}}=(4,4,0,0)^T$, que promedia la señal por bloques ($4=\frac{5+3}{2}$, $0=\frac{-1+1}{2}$). El error es $\boldsymbol{v}-\widetilde{\boldsymbol{v}}=(1,-1,-1,1)^T$ con $\|\boldsymbol{v}-\widetilde{\boldsymbol{v}}\|=2=\sqrt{c_3^2+c_4^2}$: por Parseval, el error de comprimir es exactamente la energía de los coeficientes descartados.

3.15 (a) $\|Q\boldsymbol{x}_i - Q\boldsymbol{x}_j\| = \|Q(\boldsymbol{x}_i - \boldsymbol{x}_j)\| = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|$ por la Proposición 3.27. (b) Todas las distancias entre pares son las mismas antes y después, así que cualquier comparación de distancias (en particular "¿cuál es el punto más cercano a $\boldsymbol{x}_i$?") da la misma respuesta. (c) Con $A = \begin{bmatrix} 1 & 0 \\ 0 & 1/10 \end{bmatrix}$ y los puntos $\boldsymbol{x}_1 = (0,0)$, $\boldsymbol{x}_2 = (1,0)$, $\boldsymbol{x}_3 = (0,2)$: antes, el más cercano a $\boldsymbol{x}_1$ es $\boldsymbol{x}_2$ ($1 < 2$); después, $A\boldsymbol{x}_2 = (1,0)$ queda a distancia 1 pero $A\boldsymbol{x}_3 = (0, 0.2)$ queda a distancia 0.2: el vecino más cercano cambió. Las matrices invertibles cualesquiera deforman; las ortogonales solo mueven rígidamente.

3.16 (a) $\|\boldsymbol{x}\| = \sqrt{10}$, $\|\boldsymbol{y}\| = \sqrt{40} = 2\sqrt{10}$, $\|\boldsymbol{z}\| = \sqrt{13}$. Entonces

$$\cos(\boldsymbol{x},\boldsymbol{y}) = \frac{18+2}{\sqrt{10}\cdot 2\sqrt{10}} = \frac{20}{20} = 1, \qquad \cos(\boldsymbol{x},\boldsymbol{z}) = \frac{2}{\sqrt{10}\sqrt{13}} = \frac{2}{\sqrt{130}} \approx 0{,}18,$$

y $\cos(\boldsymbol{y},\boldsymbol{z}) = \frac{4}{2\sqrt{10}\sqrt{13}} = \frac{2}{\sqrt{130}}$, igual que el anterior. (b) $\boldsymbol{y} = 2\boldsymbol{x}$: son linealmente dependientes con constante positiva, que es exactamente el caso de igualdad de Cauchy-Schwarz (Teorema 3.1); mismas proporciones de palabras $\Rightarrow$ misma dirección $\Rightarrow$ similitud 1. (c) Duplicar el largo de un documento duplica su vector de conteos pero no cambia su dirección: la similitud coseno ignora la magnitud y compara solo las proporciones (el "tema"). Por eso $\boldsymbol{y}$ tiene la misma similitud con $\boldsymbol{z}$ que $\boldsymbol{x}$.

3.17 (a) $H^T = (I-2P)^T = I - 2P = H$ y $H^2 = I - 4P + 4P^2 = I - 4P + 4P = I$, así que $H^TH = H^2 = I$: ortogonal. Si $\boldsymbol{w} \in C(P)$ entonces $P\boldsymbol{w} = \boldsymbol{w}$ (la proyección deja fijo al subespacio) y $H\boldsymbol{w} = \boldsymbol{w} - 2\boldsymbol{w} = -\boldsymbol{w}$; si $\boldsymbol{z} \perp C(P)$ entonces $P\boldsymbol{z} = \boldsymbol{0}$ y $H\boldsymbol{z} = \boldsymbol{z}$. (b) $P^T = \frac{1}{2}(I-H)^T = P$ y

$$P^2 = \tfrac{1}{4}(I - 2H + H^2) = \tfrac{1}{4}(2I - 2H) = \tfrac{1}{2}(I - H) = P :$$

proyección ortogonal (por la recíproca del Teorema 3.21). (c) Con P del Ejercicio **3.6**,

$$H = I - 2P = \frac{1}{9}\begin{bmatrix} 1 & -8 & 4 \\ -8 & 1 & 4 \\ 4 & 4 & 7 \end{bmatrix},$$

que es la reflexión de Householder $I - 2\boldsymbol{q}\boldsymbol{q}^T$: invierte la dirección de $\boldsymbol{q}$ y deja fijo el plano espejo $\boldsymbol{q}^{\perp}$.

4 CAPÍTULO

Autovalores y autovectores

4.1 Definición y ejemplos

Convenio. A diferencia de los capítulos anteriores, acá no podemos quedarnos en $\mathbb{R}$. El ejemplo de la rotación que veremos en un momento muestra que una matriz *real* puede no tener ningún autovalor real, y el teorema fundamental del álgebra garantiza que sobre $\mathbb{C}$ siempre hay exactamente n autovalores contados con multiplicidad. Por eso, salvo aviso explícito, en este capítulo las matrices son reales pero los autovalores se buscan en $\mathbb{C}$ y los autovectores en $\mathbb{C}^n$. Cuando un resultado valga sólo para autovalores reales, lo diremos.

Definición 4.1 (Autovalor y autovector). Sea $A \in \mathbb{C}^{n\times n}$. Un vector *no nulo* $\boldsymbol{v} \in \mathbb{C}^n$ es un **autovector** (o vector propio) de A si existe un escalar $\lambda \in \mathbb{C}$ tal que

$$A\boldsymbol{v} = \lambda \boldsymbol{v}$$

En ese caso λ se llama **autovalor** (o valor propio) de A asociado a $\boldsymbol{v}$.

Hay una asimetría en la definición que conviene subrayar desde el principio: *el vector tiene que ser no nulo, pero el escalar puede ser cero.* La exclusión de $\boldsymbol{v} = \mathbf{0}$ no es un capricho: la igualdad $A\mathbf{0} = \lambda\mathbf{0}$ se cumple para cualquier λ, así que admitirlo haría que todo número fuera autovalor de toda matriz y la definición no diría nada. En cambio $\lambda = 0$ es perfectamente admisible, y lejos de ser un caso degenerado resultará ser el más informativo: lo veremos en el Corolario 4.3.

Geométricamente, la ecuación $A\boldsymbol{v} = \lambda\boldsymbol{v}$ admite una lectura muy intuitiva: cuando la transformación lineal representada por A actúa sobre el vector $\boldsymbol{v}$, el resultado es un nuevo vector que permanece en la misma recta que $\boldsymbol{v}$. Es decir, la transformación no desvía a $\boldsymbol{v}$ de su dirección original, sino que simplemente lo alarga o acorta (y eventualmente invierte su sentido) según el factor λ. Los autovectores son, por tanto, las direcciones privilegiadas de la transformación, aquellas que la matriz deja invariantes, y el autovalor mide cuánto se estira o encoge el vector en esa dirección.

Por ejemplo, para

$$D = \begin{pmatrix} 4 & 0 \\ 0 & -2 \end{pmatrix},$$

tomemos $\boldsymbol{v}_1 = (1, 0)^T$. Entonces

$$D\boldsymbol{v}_1 = \begin{pmatrix} 4 & 0 \\ 0 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 4 \\ 0 \end{pmatrix} = 4 \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

luego $\boldsymbol{v}_1$ es autovector con autovalor $\lambda_1 = 4$. De igual forma, para $\boldsymbol{v}_2 = (0,1)^T$ se tiene

$$D\boldsymbol{v}_2 = \begin{pmatrix} 0 \\ -2 \end{pmatrix} = -2 \begin{pmatrix} 0 \\ 1 \end{pmatrix},$$

así que $\boldsymbol{v}_2$ es autovector con autovalor $\lambda_2 = -2$.

Obsérvese que, en realidad, cualquier múltiplo escalar no nulo de los autovectores encontrados también es un autovector con el mismo autovalor. En efecto, si $c \neq 0$, entonces

$$D(c\boldsymbol{v}_1) = cD\boldsymbol{v}_1 = c(4\boldsymbol{v}_1) = 4(c\boldsymbol{v}_1),$$

luego $c\boldsymbol{v}_1$ es también autovector con autovalor 4. Análogamente, $c\boldsymbol{v}_2$ es autovector con autovalor -2. Este hecho es general: los autovectores asociados a un mismo autovalor forman un espacio vectorial (el espacio propio), y cualquier vector no nulo de ese espacio es también un autovector.

Consideremos ahora la matriz

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

El escalar $\lambda = 2$ es un autovalor, pues para $\boldsymbol{v}_1 = (1,0,0)^T$ se tiene

$$A\boldsymbol{v}_1 = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix},$$

y también para $\boldsymbol{v}_2 = (0,0,1)^T$,

$$A\boldsymbol{v}_2 = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix} = 2 \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}.$$

De hecho, cualquier combinación lineal no nula de $\boldsymbol{v}_1$ y $\boldsymbol{v}_2$, digamos $\boldsymbol{w} = \alpha\boldsymbol{v}_1 + \beta\boldsymbol{v}_2 = (\alpha, 0, \beta)^T$, también es un autovector con el mismo autovalor, puesto que

$$A\boldsymbol{w} = A(\alpha\boldsymbol{v}_1 + \beta\boldsymbol{v}_2) = \alpha A\boldsymbol{v}_1 + \beta A\boldsymbol{v}_2 = 2\alpha\boldsymbol{v}_1 + 2\beta\boldsymbol{v}_2 = 2(\alpha\boldsymbol{v}_1 + \beta\boldsymbol{v}_2) = 2\boldsymbol{w}.$$

Hasta aquí solo hemos comprobado que ciertos pares vector-escalar cumplen la definición, lo cual no es más que efectuar la multiplicación matricial. Antes de abordar el problema inverso (cómo encontrar todos los autovalores y autovectores de una matriz dada) conviene destacar una propiedad estructural que ya se insinúa en los ejemplos.

Teorema 4.2. Sea A una matriz $n \times n$ y sea λ un autovalor de A. El conjunto

$$E_\lambda = \{\boldsymbol{v} \in \mathbb{C}^n : A\boldsymbol{v} = \lambda\boldsymbol{v}\}$$

es un subespacio vectorial de $\mathbb{C}^n$.

Demostración. En primer lugar, el vector nulo pertenece a E_λ, pues $A\mathbf{0} = \mathbf{0} = \lambda\mathbf{0}$. Si $\boldsymbol{v}, \boldsymbol{w} \in E_\lambda$, entonces

$$A(\boldsymbol{v} + \boldsymbol{w}) = A\boldsymbol{v} + A\boldsymbol{w} = \lambda\boldsymbol{v} + \lambda\boldsymbol{w} = \lambda(\boldsymbol{v} + \boldsymbol{w}),$$

luego $\boldsymbol{v} + \boldsymbol{w} \in E_\lambda$. Finalmente, si $\boldsymbol{v} \in E_\lambda$ y $c \in \mathbb{C}$, se tiene

$$A(c\boldsymbol{v}) = cA\boldsymbol{v} = c(\lambda\boldsymbol{v}) = \lambda(c\boldsymbol{v}),$$

así que $c\boldsymbol{v} \in E_\lambda$. Por tanto, E_λ es cerrado para la suma y el producto por escalares, y contiene al cero; luego es un subespacio vectorial. ∎

A este subespacio E_λ se le denomina **espacio propio** (o autoespacio) asociado al autovalor λ. Su dimensión, que será clave más adelante, recibe el nombre de **multiplicidad geométrica** de λ.

Conviene observar desde ya que E_λ no es un objeto nuevo: reescribiendo $A\boldsymbol{v} = \lambda\boldsymbol{v}$ como $(A - \lambda I)\boldsymbol{v} = \mathbf{0}$ se ve que

$$\boxed{E_\lambda = N(A - \lambda I)} \tag{4.1}$$

es el *espacio nulo* de otra matriz. Todo lo que sabemos del Capítulo 1 se aplica entonces sin cambios: en particular, por el teorema de la dimensión (Teorema 1.9),

$$\text{multiplicidad geométrica de } \lambda \;=\; \dim N(A - \lambda I) \;=\; n - \operatorname{rg}(A - \lambda I),$$

y calcular una base de E_λ es exactamente el cálculo del Capítulo 2: llevar $A - \lambda I$ a su forma escalonada reducida y leer las variables libres.

El caso $\lambda = 0$ merece destacarse aparte, porque conecta toda la teoría espectral con lo que venimos haciendo desde el Capítulo 1.

Corolario 4.3. Sea $A \in \mathbb{C}^{n\times n}$. Tomando $\lambda = 0$ en (4.1),

$$\boxed{E_0 = N(A)}$$

es decir, *los autovectores de autovalor* 0 *son exactamente los vectores no nulos del espacio nulo de* A. En consecuencia,

$$\boxed{A \text{ es singular} \iff 0 \text{ es autovalor de } A}$$

y, cuando eso ocurre, la multiplicidad geométrica de $\lambda = 0$ es $\dim N(A) = n - \operatorname{rg}(A)$.

Demostración. La primera igualdad es (4.1) con $\lambda = 0$, ya que $A - 0 \cdot I = A$. Para la segunda: 0 es autovalor si y sólo si existe $\boldsymbol{v} \neq \mathbf{0}$ con $A\boldsymbol{v} = \mathbf{0}$, o sea si y sólo si $N(A) \neq \{\mathbf{0}\}$, que es precisamente la condición de que A no sea invertible (ítem 3 de la lista de equivalencias de la Sección 2.1). La multiplicidad geométrica es $\dim E_0 = \dim N(A)$, y el teorema de la dimensión da $n - \operatorname{rg}(A)$. ∎

Vale la pena detenerse en lo que dice este corolario, porque es el puente entre los dos primeros capítulos y éste. Hasta ahora teníamos una lista de ocho condiciones equivalentes a que A sea invertible — espacio nulo trivial, columnas independientes, rango

n, determinante no nulo, y las demás —; el corolario agrega una novena, de naturaleza distinta: *que* 0 *no esté en el espectro*. Y al revés, cada vez que una matriz resulte singular ya sabemos, sin calcular nada, que 0 es uno de sus autovalores y que su espacio propio es el espacio nulo que aprendimos a describir con la eliminación. El espacio nulo, que apareció como el conjunto de soluciones de $A\boldsymbol{x} = \mathbf{0}$, es entonces un espacio propio: el del autovalor 0.

Terminamos esta sección con una observación que demuestra la utilidad de los autovalores y autovectores. Si $\boldsymbol{x}$ es un autovector de A con autovalor λ, entonces $A\boldsymbol{x} = \lambda\boldsymbol{x}$; por lo tanto, calcular la potencia n-ésima de A aplicada a $\boldsymbol{x}$ resulta inmediato:

$$A^n\boldsymbol{x} = \lambda^n\boldsymbol{x}.$$

Este procedimiento no se limita a autovectores aislados, sino que puede extenderse a cualquier vector de $\mathbb{R}^n$ en ciertos casos de especial importancia. Supongamos que $A \in \mathbb{R}^{n\times n}$ admite n autovectores linealmente independientes, digamos $\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n\}$, con sus correspondientes autovalores $\lambda_1, \ldots, \lambda_n$ (no necesariamente distintos). Entonces estos autovectores forman una base de $\mathbb{R}^n$. Dado cualquier vector $\boldsymbol{v} \in \mathbb{R}^n$, existen escalares únicos $c_1, \ldots, c_n$ tales que

$$\boldsymbol{v} = c_1\boldsymbol{x}_1 + \cdots + c_n\boldsymbol{x}_n.$$

Aplicando A y usando la linealidad,

$$A\boldsymbol{v} = A(c_1\boldsymbol{x}_1 + \cdots + c_n\boldsymbol{x}_n) = c_1A\boldsymbol{x}_1 + \cdots + c_nA\boldsymbol{x}_n = c_1\lambda_1\boldsymbol{x}_1 + \cdots + c_n\lambda_n\boldsymbol{x}_n.$$

Iterando el proceso, para cualquier entero positivo k se obtiene la fórmula general

$$A^k\boldsymbol{v} = c_1\lambda_1^k\boldsymbol{x}_1 + \cdots + c_n\lambda_n^k\boldsymbol{x}_n.$$

Visto en términos matriciales, si definimos la matriz $P = [\boldsymbol{x}_1 \cdots \boldsymbol{x}_n]$ (cuya inversa existe pues sus columnas son independientes) y $D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$, entonces la relación $A\boldsymbol{x}_i = \lambda_i\boldsymbol{x}_i$ para cada i se condensa en la igualdad $AP = PD$, o equivalentemente

$$A = PDP^{-1}.$$

De aquí se deduce que

$$A^k = PD^kP^{-1}$$

para todo $k \in \mathbb{N}$, lo que reduce el cálculo de potencias de matrices al simple cálculo de potencias de una matriz diagonal. Esta factorización es una de las aplicaciones más poderosas de la teoría espectral, y volveremos a ella en detalle en la sección dedicada a la diagonalización.

4.2 Cálculo de autovalores y autovectores

La definición $A\boldsymbol{v} = \lambda\boldsymbol{v}$ puede reescribirse como

$$(A - \lambda I)\boldsymbol{v} = \mathbf{0}.$$

Para que exista un vector $\boldsymbol{v} \neq \mathbf{0}$ que satisfaga esta ecuación, la matriz $A - \lambda I$ debe ser singular, es decir, su determinante debe anularse. Obtenemos así la ecuación fundamental

$$\det(A - \lambda I) = 0,$$

conocida como **ecuación característica** de A. El polinomio $p(\lambda) = \det(A - \lambda I)$ se denomina **polinomio característico** de A, y sus raíces son precisamente los autovalores de la matriz.

Una vez hallados los autovalores, para cada uno de ellos λ_i se resuelve el sistema lineal homogéneo

$$(A - \lambda_i I)\boldsymbol{v} = \mathbf{0},$$

cuyas soluciones no triviales constituyen el espacio propio E_{λ_i}. El procedimiento se resume en los siguientes pasos:

1. Calcular el polinomio característico $p(\lambda) = \det(A - \lambda I)$.
2. Hallar las raíces de $p(\lambda)$; cada raíz es un autovalor.
3. Para cada autovalor λ, resolver el sistema $(A - \lambda I)\boldsymbol{v} = \mathbf{0}$ para obtener una base del espacio propio asociado.

Ilustremos este algoritmo con los ejemplos de la sección anterior y dos nuevos casos.

Ejemplo 1. Para la matriz diagonal

$$D = \begin{pmatrix} 4 & 0 \\ 0 & -2 \end{pmatrix},$$

el polinomio característico es

$$\det(D - \lambda I) = \det \begin{pmatrix} 4-\lambda & 0 \\ 0 & -2-\lambda \end{pmatrix} = (4-\lambda)(-2-\lambda).$$

Las raíces son $\lambda_1 = 4$ y $\lambda_2 = -2$, que ya habíamos verificado.

Para $\lambda_1 = 4$, resolvemos $(D - 4I)\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} 0 & 0 \\ 0 & -6 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies -6v_2 = 0 \implies v_2 = 0,$$

luego $\boldsymbol{v} = (v_1, 0)^T = v_1(1, 0)^T$, y el espacio propio es $E_4 = \operatorname{span}\{(1, 0)^T\}$.

Para $\lambda_2 = -2$, resolvemos $(D + 2I)\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} 6 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies 6v_1 = 0 \implies v_1 = 0,$$

así que $\boldsymbol{v} = (0, v_2)^T = v_2(0, 1)^T$, y $E_{-2} = \operatorname{span}\{(0, 1)^T\}$.

Ejemplo 2. Para la matriz simétrica

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix},$$

el polinomio característico es

$$\det(A - \lambda I) = \det \begin{pmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{pmatrix} = (2-\lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 1)(\lambda - 3).$$

Por tanto, los autovalores son $\lambda_1 = 1$ y $\lambda_2 = 3$.

Para $\lambda_1 = 1$, resolvemos $(A - I)\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies v_1 + v_2 = 0 \implies v_1 = -v_2,$$

luego $\boldsymbol{v} = (-v_2, v_2)^T = v_2(-1, 1)^T$, y $E_1 = \text{span}\{(-1, 1)^T\}$.

Para $\lambda_2 = 3$, resolvemos $(A - 3I)\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies -v_1 + v_2 = 0 \implies v_1 = v_2,$$

así que $\boldsymbol{v} = (v_1, v_1)^T = v_1(1, 1)^T$, y $E_3 = \text{span}\{(1, 1)^T\}$.

Ejemplo 3. Para la matriz singular

$$B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix},$$

el polinomio característico es

$$\det(B - \lambda I) = \det \begin{pmatrix} 1 - \lambda & 1 \\ 1 & 1 - \lambda \end{pmatrix} = (1 - \lambda)^2 - 1 = \lambda^2 - 2\lambda = \lambda(\lambda - 2).$$

Los autovalores son $\lambda_1 = 0$ y $\lambda_2 = 2$.

Para $\lambda_1 = 0$, resolvemos $B\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies v_1 + v_2 = 0 \implies v_1 = -v_2,$$

luego $\boldsymbol{v} = (-v_2, v_2)^T = v_2(-1, 1)^T$, y $E_0 = \text{span}\{(-1, 1)^T\}$.

Para $\lambda_2 = 2$, resolvemos $(B - 2I)\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies -v_1 + v_2 = 0 \implies v_1 = v_2,$$

así que $\boldsymbol{v} = (v_1, v_1)^T = v_1(1, 1)^T$, y $E_2 = \text{span}\{(1, 1)^T\}$.

Obsérvese que la presencia del autovalor $\lambda = 0$ confirma que la matriz es singular.

Ejemplo 4 (autovalores complejos). Consideremos la matriz de rotación de 45° en el plano:

$$R = \begin{pmatrix} \cos 45^\circ & -\sin 45^\circ \\ \sin 45^\circ & \cos 45^\circ \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}.$$

Su polinomio característico es

$$\det(R - \lambda I) = \det \begin{pmatrix} \frac{\sqrt{2}}{2} - \lambda & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} - \lambda \end{pmatrix} = \left(\frac{\sqrt{2}}{2} - \lambda\right)^2 + \left(\frac{\sqrt{2}}{2}\right)^2 = \lambda^2 - \sqrt{2}\lambda + 1.$$

Resolviendo la ecuación cuadrática,

$$\lambda = \frac{\sqrt{2} \pm \sqrt{2 - 4}}{2} = \frac{\sqrt{2} \pm i\sqrt{2}}{2} = \frac{\sqrt{2}}{2} \pm i\frac{\sqrt{2}}{2}.$$

Por tanto, los autovalores son $\lambda_1 = \frac{\sqrt{2}}{2} + i\frac{\sqrt{2}}{2}$ y $\lambda_2 = \frac{\sqrt{2}}{2} - i\frac{\sqrt{2}}{2}$, que son complejos conjugados. Este ejemplo pone de manifiesto que, incluso para matrices reales, los autovalores pueden ser complejos si el cuerpo base es $\mathbb{R}$. En tal caso, no existen autovectores reales (la rotación no deja invariante ninguna dirección real), pero sí existen autovectores en $\mathbb{C}^2$. Para trabajar con total generalidad, conviene considerar el polinomio característico sobre los complejos, donde el teorema fundamental del álgebra garantiza que siempre tiene n raíces contando multiplicidades.

Ejemplo 5 (multiplicidades distintas). Consideremos ahora la matriz

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

Al ser triangular superior, su polinomio característico es el producto de los elementos de la diagonal:

$$\det(A - \lambda I) = \det \begin{pmatrix} 2-\lambda & 1 & 0 \\ 0 & 2-\lambda & 0 \\ 0 & 0 & 2-\lambda \end{pmatrix} = (2-\lambda)^3.$$

La única raíz es $\lambda = 2$, con multiplicidad 3 como raíz del polinomio.

Para hallar el espacio propio, resolvemos $(A - 2I)\boldsymbol{v} = \mathbf{0}$:

$$\begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \implies v_2 = 0.$$

Por tanto, $\boldsymbol{v} = (v_1, 0, v_3)^T = v_1(1,0,0)^T + v_3(0,0,1)^T$, y el espacio propio es

$$E_2 = \operatorname{span}\{(1,0,0)^T, (0,0,1)^T\},$$

cuya dimensión es 2.

Multiplicidades algebraica y geométrica. Los ejemplos anteriores motivan dos definiciones fundamentales. Dado un autovalor λ_i de una matriz A de tamaño $n \times n$:

- Su **multiplicidad algebraica** es la multiplicidad de λ_i como raíz del polinomio característico $p(\lambda)$. Es decir, el exponente del factor $(\lambda - \lambda_i)$ en la factorización de $p(\lambda)$.
- Su **multiplicidad geométrica** es la dimensión del espacio propio asociado, $\dim E_{\lambda_i}$.

El teorema fundamental del álgebra asegura que, trabajando sobre $\mathbb{C}$, el polinomio característico de grado n se factoriza completamente en n factores lineales. Por tanto, si contamos cada autovalor tantas veces como indique su multiplicidad algebraica, la suma de todas las multiplicidades algebraicas es exactamente n. En el ejemplo 5, el autovalor $\lambda = 2$ tiene multiplicidad algebraica 3.

Sin embargo, como también hemos visto, la multiplicidad geométrica puede ser estrictamente menor que la algebraica. En el ejemplo 5, la multiplicidad geométrica de $\lambda = 2$ es 2, que es menor que 3. En general, siempre se cumple la desigualdad

$$1 \leq \text{multiplicidad geométrica de } \lambda_i \leq \text{multiplicidad algebraica de } \lambda_i.$$

La primera desigualdad refleja que todo autovalor posee al menos un autovector asociado (por definición). La segunda es una propiedad fundamental que demostraremos más adelante. Lo relevante es que la igualdad no está garantizada: la suma de las multiplicidades geométricas de todos los autovalores puede ser estrictamente menor que n, como ocurre en el ejemplo 5 ($2 < 3$). Cuando esto sucede, la matriz no posee suficientes autovectores linealmente independientes como para formar una base del espacio total, y por tanto no es diagonalizable. La condición necesaria y suficiente para que una matriz sea diagonalizable es precisamente que, para cada autovalor, su multiplicidad geométrica coincida con su multiplicidad algebraica. Volveremos a esto en siguientes secciones.

El procedimiento que hemos descrito (calcular el polinomio característico, hallar sus raíces y resolver los sistemas lineales asociados) es conceptualmente sencillo y funciona perfectamente para matrices de tamaño pequeño, como las de los ejemplos que hemos visto. Sin embargo, su utilidad práctica se desvanece rápidamente cuando las dimensiones crecen. En primer lugar, el polinomio característico de una matriz $n \times n$ tiene grado n, y obtener sus coeficientes requiere un número de operaciones que crece como $O(n^3)$, pero lo más gravoso es que, para $n \geq 5$, el teorema de Abel-Ruffini establece que no existen fórmulas algebraicas generales que expresen las raíces del polinomio en términos de radicales. Esto hace que el método sea impracticable, tanto por el costo computacional como por la inestabilidad numérica que sufren los algoritmos basados en el polinomio característico. En la práctica, los autovalores y autovectores de matrices grandes se calculan mediante métodos iterativos como el método de la potencia, el método de iteración de subespacios o el algoritmo QR, que evitan por completo el polinomio característico y se basan en aproximaciones sucesivas que convergen a los valores deseados. El estudio de estos algoritmos constituye una parte fundamental del análisis numérico matricial, que probablemente se aborde en cursos más avanzados.

4.3 Propiedades de los autovalores y autovectores

4.3.1 Traza y determinante de una matriz

Los autovalores de una matriz no solo determinan su comportamiento espectral, sino que también se relacionan directamente con dos de los invariantes más importantes del álgebra lineal: la traza y el determinante. Estas relaciones, que enunciamos a continuación, ofrecen una herramienta poderosa para verificar cálculos y extraer información estructural de una matriz sin necesidad de diagonalizarla explícitamente. La demostración es mucho más limpia con la factorización de Schur, así que la dejamos para el Capítulo 5 (Corolario 5.10), donde sale en tres renglones.

Teorema 4.4. Sea A una matriz $n \times n$ con autovalores $\lambda_1, \ldots, \lambda_n$ (contados con su multiplicidad algebraica). Entonces:

1. $\operatorname{tr}(A) = \lambda_1 + \lambda_2 + \cdots + \lambda_n$.
2. $\det(A) = \lambda_1 \lambda_2 \cdots \lambda_n$.

Estas propiedades pueden verificarse directamente en los ejemplos de la sección anterior: para $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ se tiene $\operatorname{tr}(A) = 4$ y $\det(A) = 3$, y los autovalores 1 y 3 suman 4 y

multiplican 3; para la rotación R, $\operatorname{tr}(R) = \sqrt{2}$ y $\det(R) = 1$, y los autovalores complejos $\frac{\sqrt{2}}{2} \pm i\frac{\sqrt{2}}{2}$ suman $\sqrt{2}$ y multiplican 1 (obsérvese que la fórmula necesita los autovalores complejos: con los reales no cerraría). Los demás ejemplos del capítulo quedan como verificación para el lector.

Estas dos propiedades son especialmente útiles en la práctica: la traza y el determinante de una matriz pueden calcularse directamente a partir de sus entradas, y proporcionan una comprobación inmediata de que los autovalores hallados son correctos. Además, la relación con el determinante vuelve a dar, por otro camino, el Corolario 4.3: el producto de los autovalores es $\det(A)$, que se anula si y sólo si alguno de los factores es cero.

4.3.2 La traspuesta: A y A^T

Antes de seguir conviene aislar un hecho que usaremos varias veces y que es inmediato a partir del polinomio característico.

Proposición 4.5. Sea $A \in \mathbb{C}^{n\times n}$. Entonces A y A^T tienen *el mismo polinomio característico* y, por lo tanto, *los mismos autovalores con las mismas multiplicidades algebraicas*.

Demostración. Una matriz y su traspuesta tienen el mismo determinante (Sección 1.3.7 del Capítulo 1). Aplicándolo a $A - \lambda I$ y usando que $(A - \lambda I)^T = A^T - \lambda I$, porque I es simétrica,

$$\det(A - \lambda I) = \det\left((A - \lambda I)^T\right) = \det(A^T - \lambda I) \qquad \text{para todo } \lambda.$$

Los dos polinomios característicos coinciden, y con ellos sus raíces y las multiplicidades de cada raíz. ∎

Observación 4.6 (Los autovalores sí, los autovectores no). La proposición habla de *autovalores* y nada dice de los autovectores: en general A y A^T tienen autovectores completamente distintos. Por ejemplo,

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix} \qquad \text{y} \qquad A^T = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}$$

tienen ambas autovalores 1 y 2, pero el autovector de A para $\lambda = 1$ es $(1, 0)^T$ mientras que el de A^T es $(1, -1)^T$. Los autovectores de A^T se llaman *autovectores a izquierda* de A, porque $A^T\boldsymbol{y} = \lambda\boldsymbol{y}$ equivale a $\boldsymbol{y}^T A = \lambda\boldsymbol{y}^T$: son los vectores fila que A deja invariantes al multiplicar por la izquierda. Coinciden con los de A exactamente cuando A es simétrica, y volverán a aparecer con las matrices de Markov y en el Capítulo 8.

4.3.3 AB y BA

Otro hecho que no depende de ninguna factorización y que conviene tener aislado: dos matrices rectangulares multiplicadas en los dos órdenes dan matrices de tamaños distintos, pero casi los mismos autovalores.

Proposición 4.7. Si $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times m}$, entonces AB (de $m \times m$) y BA (de $n \times n$) tienen los mismos autovalores no nulos.

Demostración. Sea $AB\boldsymbol{x} = \lambda\boldsymbol{x}$ con $\boldsymbol{x} \neq \mathbf{0}$ y $\lambda \neq 0$. Multiplicando por B a izquierda,

$$BA(B\boldsymbol{x}) = B(AB\boldsymbol{x}) = B(\lambda\boldsymbol{x}) = \lambda(B\boldsymbol{x}),$$

así que $B\boldsymbol{x}$ sería un autovector de BA con autovalor λ, siempre que no sea nulo. Y no lo es: si fuera $B\boldsymbol{x} = \mathbf{0}$, entonces $\lambda\boldsymbol{x} = AB\boldsymbol{x} = \mathbf{0}$ y, como $\lambda \neq 0$, sería $\boldsymbol{x} = \mathbf{0}$, contra lo supuesto. Luego todo autovalor no nulo de AB lo es de BA. El argumento simétrico —intercambiando los papeles de A y B— da la otra inclusión. ∎

Observación 4.8. Cuando B es cuadrada e invertible el resultado sale solo: de $B^{-1}(BA)B = AB$ se ve que AB y BA son *semejantes* (Sección 4.4) y las matrices semejantes tienen los mismos autovalores. La gracia de la demostración de arriba es que no pide nada: vale para matrices rectangulares, donde ni siquiera tiene sentido hablar de semejanza porque AB y BA son de tamaños distintos.

La palabra importante del enunciado es *no nulos*. Los autovalores cero sí pueden diferir, y de hecho tienen que hacerlo cuando $m \neq n$, porque una matriz de $m \times m$ tiene m autovalores contados con multiplicidad y una de $n \times n$ tiene n. El caso extremo es $A = \boldsymbol{u}$ y $B = \boldsymbol{v}^T$ con $\boldsymbol{u}, \boldsymbol{v} \in \mathbb{R}^n$: entonces $BA = \boldsymbol{v}^T\boldsymbol{u}$ es un número —un único autovalor— mientras que $AB = \boldsymbol{u}\boldsymbol{v}^T$ es una matriz de $n \times n$ de rango uno, cuyos autovalores son $\boldsymbol{v}^T\boldsymbol{u}$ y 0 repetido $n - 1$ veces.

Lo vamos a usar con $B = A^T$ en el Capítulo 8: dirá que A^TA y AA^T tienen los mismos autovalores no nulos, que es lo que hace que los valores singulares de una matriz no dependan de por cuál de las dos se empiece.

4.3.4 Potencias y traslaciones de una matriz.

Una de las grandes ventajas de trabajar con autovalores es que las operaciones algebraicas básicas sobre la matriz se traducen en operaciones elementales sobre sus autovalores, manteniendo los mismos autovectores.

Proposición 4.9. Sea A una matriz $n \times n$, sea λ un autovalor de A y sea $\boldsymbol{v}$ un autovector asociado. Entonces, *con el mismo autovector*:

1. $A^k\boldsymbol{v} = \lambda^k\boldsymbol{v}$ para todo entero positivo k;
2. $(A + \alpha I)\boldsymbol{v} = (\lambda + \alpha)\boldsymbol{v}$ para todo escalar α;
3. $p(A)\boldsymbol{v} = p(\lambda)\boldsymbol{v}$ para todo polinomio p;
4. si A es invertible, $A^{-1}\boldsymbol{v} = \lambda^{-1}\boldsymbol{v}$.

Observación 4.10. La proposición dice que λ^k *es* un autovalor de A^k, pero no que esos sean *todos* los autovalores de A^k ni con qué multiplicidad aparecen. Eso también es cierto, y lo probaremos en el Capítulo 5 (Corolario 5.10), donde triangularizar de una sola vez resuelve las dos cuestiones.

Demostración. Todas las afirmaciones se siguen directamente de la definición, aplicada al mismo autovector.

Para la potencia, procedemos por inducción. El caso $k = 1$ es trivial. Supongamos que $A^{k-1}\boldsymbol{v} = \lambda^{k-1}\boldsymbol{v}$; entonces

$$A^k\boldsymbol{v} = A(A^{k-1}\boldsymbol{v}) = A(\lambda^{k-1}\boldsymbol{v}) = \lambda^{k-1}(A\boldsymbol{v}) = \lambda^{k-1}(\lambda\boldsymbol{v}) = \lambda^k\boldsymbol{v}.$$

Para la traslación, calculamos directamente:

$$(A + \alpha I)\boldsymbol{v} = A\boldsymbol{v} + \alpha I\boldsymbol{v} = \lambda\boldsymbol{v} + \alpha\boldsymbol{v} = (\lambda + \alpha)\boldsymbol{v}.$$

Para un polinomio $p(x) = c_0 + c_1x + \cdots + c_dx^d$ basta combinar los dos puntos anteriores. Y si A es invertible, de $A\boldsymbol{v} = \lambda\boldsymbol{v}$ se sigue $\lambda \neq 0$ (si no, $\boldsymbol{v} \in N(A) = \{\mathbf{0}\}$), y multiplicando por A^{-1} queda $\boldsymbol{v} = \lambda A^{-1}\boldsymbol{v}$, o sea $A^{-1}\boldsymbol{v} = \lambda^{-1}\boldsymbol{v}$. ∎

Observación 4.11. Estas propiedades son particularmente útiles para el cálculo rápido de autovalores de matrices que provienen de polinomios en A. Por ejemplo, si $p(x)$ es cualquier polinomio, entonces los autovalores de $p(A)$ son exactamente $p(\lambda_1), \ldots, p(\lambda_n)$. La demostración es idéntica: basta aplicar el polinomio al autovector.

Retomando los ejemplos anteriores:

- Para la matriz $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, cuyos autovalores son 1 y 3, se tiene que A^2 tiene autovalores $1^2 = 1$ y $3^2 = 9$. El lector puede verificar que $\det(A^2 - \mu I) = (\mu - 1)(\mu - 9)$.
- Para la matriz diagonal $D = \operatorname{diag}(4, -2)$, la matriz $D + 3I = \operatorname{diag}(7, 1)$ tiene autovalores $4 + 3 = 7$ y $-2 + 3 = 1$, como era de esperar.
- En el caso de la rotación R de 45°, con autovalores $\lambda = \frac{\sqrt{2}}{2} \pm i\frac{\sqrt{2}}{2}$, la matriz R^2 corresponde a una rotación de 90° y debe tener autovalores λ^2. Efectivamente, $\lambda^2 = (\frac{\sqrt{2}}{2} \pm i\frac{\sqrt{2}}{2})^2 = \pm i$, que son los autovalores de la matriz de rotación de 90° (sin autovalores reales).
- Para la matriz singular $B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ con autovalores 0 y 2, la matriz $B - I = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ debe tener autovalores $0 - 1 = -1$ y $2 - 1 = 1$. Esto es correcto, pues la matriz $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ tiene autovalores ± 1.

Estas sencillas reglas nos permiten extender el conocimiento espectral de una matriz a toda una familia de matrices relacionadas con ella, sin necesidad de recalcular el polinomio característico. Volveremos sobre ellas en la Sección 4.6, donde veremos que si todos los autovalores tienen módulo menor que 1 entonces $A^k \to 0$.

Dado que los autovalores se comportan bien con potencias, polinomios y traslaciones de una misma matriz, es natural preguntarse si existe una regla análoga para la suma o el producto de dos matrices distintas. La respuesta es negativa: en general, no hay ninguna relación simple entre los autovalores de $A + B$ y los de A y B, ni entre los de AB y los de A y B. La razón profunda es que los autovalores de una matriz dependen de la transformación lineal completa, no solo de los autovalores de sus sumandos, y la interacción entre las direcciones propias de cada matriz destruye cualquier posible correspondencia.

Para convencerse de ello, basta con considerar dos ejemplos sencillos en dimensión 2. Tomemos

$$A = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}, \qquad B = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Ambas tienen autovalores $\{1, -1\}$. Sin embargo, su suma es

$$A + B = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix},$$

cuyos autovalores son $\pm\sqrt{2}$, que no son ni la suma ni la resta de los autovalores originales. De igual modo, el producto

$$AB = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}$$

tiene autovalores $\pm i$, mientras que el producto de los autovalores de A y B sería $1 \cdot 1 = 1$, $1 \cdot (-1) = -1$, etc., pero nunca i. Estos contraejemplos muestran que no existe una fórmula general que exprese los autovalores de $A + B$ o AB en términos de los autovalores de A y B por separado.

4.3.5 Autovalores y autovectores de matrices simétricas y matrices ortogonales

Las matrices simétricas reales ocupan un lugar privilegiado en el álgebra lineal por sus extraordinarias propiedades espectrales. A continuación demostramos las dos propiedades fundamentales que las caracterizan.

Teorema 4.12. Sea $S \in \mathbb{R}^{n\times n}$ una matriz simétrica ($S^T = S$). Entonces:

1. Todos los autovalores de S son números reales.
2. Los autovectores correspondientes a autovalores distintos son ortogonales (con el producto escalar usual de $\mathbb{R}^n$).

Demostración. **Autovalores reales.** Sea $\lambda \in \mathbb{C}$ un autovalor de S y sea $\boldsymbol{v} \in \mathbb{C}^n$ un autovector asociado, $\boldsymbol{v} \neq \mathbf{0}$. Por definición,

$$S\boldsymbol{v} = \lambda \boldsymbol{v}.$$

Tomando conjugado traspuesto (operación denotada por *) y usando que S es real y simétrica ($S^* = S^T = S$), obtenemos

$$\boldsymbol{v}^* S = \overline{\lambda}\boldsymbol{v}^*.$$

Multiplicando la primera ecuación a la izquierda por $\boldsymbol{v}^*$ y la segunda a la derecha por $\boldsymbol{v}$, se tiene

$$\boldsymbol{v}^* S\boldsymbol{v} = \lambda \boldsymbol{v}^*\boldsymbol{v}, \qquad \boldsymbol{v}^* S\boldsymbol{v} = \overline{\lambda}\boldsymbol{v}^*\boldsymbol{v}.$$

Igualando ambas expresiones y como $\boldsymbol{v}^*\boldsymbol{v} = \sum |v_i|^2 > 0$, concluimos que $\lambda = \overline{\lambda}$, luego $\lambda \in \mathbb{R}$.

Ortogonalidad de autovectores. Sean $\lambda \neq \mu$ dos autovalores reales de S, con autovectores $\boldsymbol{u}$ y $\boldsymbol{v}$ respectivamente, ambos en $\mathbb{R}^n$. Entonces

$$S\boldsymbol{u} = \lambda \boldsymbol{u}, \qquad S\boldsymbol{v} = \mu \boldsymbol{v}.$$

Calculemos el producto escalar $\boldsymbol{u}^T S\boldsymbol{v}$ de dos maneras. Por un lado,

$$\boldsymbol{u}^T S\boldsymbol{v} = \boldsymbol{u}^T(\mu \boldsymbol{v}) = \mu(\boldsymbol{u}^T\boldsymbol{v}).$$

Por otro lado, usando la simetría de S,

$$\boldsymbol{u}^T S\boldsymbol{v} = (S\boldsymbol{u})^T\boldsymbol{v} = (\lambda\boldsymbol{u})^T\boldsymbol{v} = \lambda(\boldsymbol{u}^T\boldsymbol{v}).$$

Igualando obtenemos

$$\mu(\boldsymbol{u}^T\boldsymbol{v}) = \lambda(\boldsymbol{u}^T\boldsymbol{v}) \quad \Longrightarrow \quad (\lambda-\mu)(\boldsymbol{u}^T\boldsymbol{v}) = 0.$$

Como $\lambda \neq \mu$, se sigue que $\boldsymbol{u}^T\boldsymbol{v} = 0$, es decir, $\boldsymbol{u}$ y $\boldsymbol{v}$ son ortogonales. ■

La primera propiedad garantiza que el polinomio característico de una matriz simétrica tiene todas sus raíces reales, por lo que se factoriza completamente sobre $\mathbb{R}$. La segunda propiedad asegura que los espacios propios correspondientes a distintos autovalores son mutuamente ortogonales. Además, dentro de cada espacio propio E_λ (que ya sabemos que es un subespacio de $\mathbb{R}^n$), siempre es posible elegir una base ortonormal mediante el proceso de Gram-Schmidt. Por tanto, se puede construir una base ortonormal de $\mathbb{R}^n$ formada íntegramente por autovectores de S.

Verifiquemos estas propiedades en los ejemplos que hemos manejado. Para la matriz $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, los autovalores 1 y 3 son reales y los autovectores $(-1,1)^T$ y $(1,1)^T$ son ortogonales: $(-1)\cdot 1 + 1\cdot 1 = 0$. Para la matriz diagonal $D = \operatorname{diag}(4,-2)$, los autovalores son reales y los autovectores $(1,0)^T$ y $(0,1)^T$ son ortogonales. En cambio, para la rotación R, que no es simétrica, sus autovalores no son reales (son complejos) y no existen autovectores reales, lo que confirma la necesidad de la hipótesis de simetría.

Las matrices ortogonales son aquellas que preservan el producto escalar y, por tanto, las longitudes y ángulos. Su estructura espectral tiene una característica muy particular: todos sus autovalores se encuentran sobre la circunferencia unidad en el plano complejo. Recordemos que una matriz $Q \in \mathbb{R}^{n\times n}$ se dice **ortogonal** si satisface $Q^TQ = I$, o equivalentemente $Q^{-1} = Q^T$.

Teorema 4.13. Sea Q una matriz ortogonal. Entonces todos sus autovalores tienen módulo 1, es decir, si λ es un autovalor de Q, entonces $|\lambda| = 1$.

Demostración. Sea $\lambda \in \mathbb{C}$ un autovalor de Q y sea $\boldsymbol{v} \in \mathbb{C}^n$ un autovector asociado, $\boldsymbol{v} \neq \boldsymbol{0}$. Por definición,

$$Q\boldsymbol{v} = \lambda\boldsymbol{v}.$$

Tomando conjugado traspuesto en ambos lados y usando que Q es real ($\overline{Q} = Q$) y ortogonal ($Q^TQ = I$), se tiene

$$(Q\boldsymbol{v})^* = (\lambda\boldsymbol{v})^*.$$

Por lo que

$$\boldsymbol{v}^*Q^T = \overline{\lambda}\boldsymbol{v}^*.$$

Multipliquemos ahora a la derecha por $Q\boldsymbol{v}$ en ambos lados de esta última ecuación:

$$\boldsymbol{v}^*Q^TQ\boldsymbol{v} = \overline{\lambda}\boldsymbol{v}^*\boldsymbol{v}.$$

Como $Q^TQ = I$ y $Q\boldsymbol{v} = \lambda\boldsymbol{v}$, obtenemos

$$\boldsymbol{v}^*\boldsymbol{v} = \overline{\lambda}\boldsymbol{v}^*Q\boldsymbol{v} = \overline{\lambda}\boldsymbol{v}^*(\lambda\boldsymbol{v}) = |\lambda|^2\boldsymbol{v}^*\boldsymbol{v}.$$

Dado que $\boldsymbol{v} \neq \mathbf{0}$, se tiene $\boldsymbol{v}^*\boldsymbol{v} = \sum |v_i|^2 > 0$, por lo que podemos cancelar y concluir que

$$|\lambda|^2 = 1 \quad \text{y} \quad |\lambda| = 1.$$

■

Puesto que el polinomio característico de una matriz ortogonal real tiene coeficientes reales, si λ es un autovalor complejo, su conjugado $\overline{\lambda}$ también lo es, y ambos tienen módulo 1. Además, si λ es real, entonces $\lambda = \pm 1$. Por tanto, los autovalores de una matriz ortogonal real solo pueden ser 1, -1, o pares de números complejos conjugados de la forma $e^{\pm i\theta}$, con $\theta \in \mathbb{R}$.

Verifiquemos esta propiedad en los ejemplos que hemos visto. Para la matriz de rotación R de 45°,

$$R = \begin{pmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix},$$

se tiene $R^T R = I$, luego es ortogonal. Sus autovalores son $\lambda = \frac{\sqrt{2}}{2} \pm i\frac{\sqrt{2}}{2}$, cuyo módulo es

$$\left| \frac{\sqrt{2}}{2} \pm i\frac{\sqrt{2}}{2} \right| = \sqrt{\frac{1}{2} + \frac{1}{2}} = 1.$$

Esta es la expresión general: una rotación en el plano tiene autovalores $e^{\pm i\theta}$, donde θ es el ángulo de rotación.

En el otro extremo, la matriz

$$Q = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

es ortogonal (reflexión respecto al eje x) y tiene autovalores 1 y -1, ambos de módulo 1. En general, las matrices de reflexión tienen autovalores ± 1.

Observamos así una diferencia fundamental con las matrices simétricas: mientras que estas últimas tienen autovalores reales, las matrices ortogonales, que representan isometrías, tienen autovalores sobre la circunferencia unidad, reflejando que estas transformaciones no alteran las normas de los vectores.

4.4 Matrices semejantes y diagonalización

En esta sección introducimos un concepto fundamental que nos permitirá comprender cuándo dos matrices representan la misma transformación lineal en distintas bases, y que está íntimamente relacionado con la diagonalización.

Dos matrices $A, C \in \mathbb{R}^{n\times n}$ se dicen **semejantes** si existe una matriz invertible $P \in \mathbb{R}^{n\times n}$ tal que

$$C = P^{-1}AP.$$

Equivalentemente, A y C son semejantes si $A = PCP^{-1}$. La semejanza expresa que A y C son representaciones de una misma transformación lineal en diferentes bases: si A representa la transformación en la base canónica, entonces $C = P^{-1}AP$ es la representación en la base cuyas columnas son los vectores de P.

Proposición 4.14. La relación de semejanza es una relación de equivalencia en el conjunto de matrices cuadradas.

Demostración. Reflexiva: $A = I^{-1}AI$. Simétrica: si $C = P^{-1}AP$, entonces $A = (P^{-1})^{-1}C(P^{-1})$. Transitiva: si $C = P^{-1}AP$ y $D = Q^{-1}CQ$, entonces $D = (PQ)^{-1}A(PQ)$. ∎

El siguiente resultado es el que justifica la importancia de la semejanza en el estudio de los autovalores.

Teorema 4.15. Si A y C son matrices semejantes, entonces tienen el mismo polinomio característico y, en consecuencia, los mismos autovalores (con las mismas multiplicidades algebraicas).

Demostración. Sea $C = P^{-1}AP$. Sacando factor común P^{-1} y P,

$$C - \lambda I = P^{-1}AP - \lambda P^{-1}P = P^{-1}(A - \lambda I)P,$$

y tomando determinantes, que son multiplicativos,

$$\det(C - \lambda I) = \det(P^{-1})\det(A - \lambda I)\det(P) = \det(A - \lambda I),$$

porque $\det(P^{-1})\det(P) = 1$. Los dos polinomios característicos coinciden, y por lo tanto también sus raíces y las multiplicidades de esas raíces. ∎

Observación 4.16. El cálculo anterior dice más: si $A\boldsymbol{x} = \lambda\boldsymbol{x}$ entonces $C(P^{-1}\boldsymbol{x}) = P^{-1}APP^{-1}\boldsymbol{x} = P^{-1}A\boldsymbol{x} = \lambda\,(P^{-1}\boldsymbol{x})$, de modo que $\boldsymbol{x} \mapsto P^{-1}\boldsymbol{x}$ es una biyección entre $E_\lambda(A)$ y $E_\lambda(C)$. Los espacios propios tienen la misma dimensión: *la semejanza también conserva las multiplicidades geométricas.*

Antes de adentrarnos en la noción de diagonalización, observemos un hecho sencillo pero fundamental sobre las matrices triangulares. Si T es una matriz triangular superior (o inferior), entonces su polinomio característico es

$$p_T(\lambda) = \det(T - \lambda I) = \prod_{i=1}^{n}(t_{ii} - \lambda),$$

pues el determinante de una matriz triangular es el producto de los elementos de su diagonal. Por tanto, las raíces de $p_T(\lambda)$ son precisamente los elementos de la diagonal de T. En particular, si D es una matriz diagonal, sus autovalores son exactamente las entradas $d_{11}, d_{22}, \ldots, d_{nn}$ que aparecen en su diagonal. Este hecho ya lo habíamos verificado en los ejemplos de la sección anterior.

La pregunta natural que surge es: ¿qué matrices pueden transformarse, mediante un cambio de base, en una matriz diagonal? Es decir, ¿cuándo una matriz es semejante a una matriz diagonal? Esta cuestión es central en el álgebra lineal y da origen a la siguiente definición.

Una matriz $A \in \mathbb{R}^{n\times n}$ se dice **diagonalizable** si es semejante a una matriz diagonal. Es decir, si existe una matriz invertible P y una matriz diagonal D tales que $A = PDP^{-1}$, o equivalentemente $D = P^{-1}AP$. En tal caso, la matriz P se llama la matriz de paso y la diagonal de D contiene los autovalores de A (con sus multiplicidades algebraicas correspondientes).

La cuestión que nos ocupa ahora es determinar cuándo una matriz admite tal representación diagonal. El siguiente resultado proporciona una condición suficiente y, como veremos más adelante, también necesaria.

Si una matriz $A \in \mathbb{R}^{n\times n}$ posee n autovectores linealmente independientes, entonces A es diagonalizable. En efecto, supongamos que $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$ son autovectores de A linealmente independientes, con autovalores asociados $\lambda_1, \ldots, \lambda_n$ (no necesariamente distintos). Definamos la matriz $X \in \mathbb{R}^{n\times n}$ cuyas columnas son esos autovectores:

$$X = [\boldsymbol{x}_1 \ \boldsymbol{x}_2 \ \cdots \ \boldsymbol{x}_n].$$

Puesto que las columnas de X son linealmente independientes, X es invertible. Sea Λ la matriz diagonal con los autovalores en la diagonal:

$$\Lambda = \operatorname{diag}(\lambda_1, \lambda_2, \ldots, \lambda_n).$$

Ahora calculemos el producto AX. Por definición de producto matricial, la columna j-ésima de AX es $A\boldsymbol{x}_j$, que por hipótesis es $\lambda_j \boldsymbol{x}_j$. Por otro lado, la columna j-ésima de $X\Lambda$ es $\lambda_j \boldsymbol{x}_j$ (pues Λ es diagonal y multiplica a la derecha a X escalando cada columna por el correspondiente λ_j). Por lo tanto, las columnas de AX y de $X\Lambda$ coinciden, luego

$$AX = X\Lambda.$$

Multiplicando a la derecha por X^{-1} (que existe porque X es invertible), obtenemos

$$A = X\Lambda X^{-1}.$$

Esto expresa que A es semejante a la matriz diagonal Λ, con matriz de paso X. Por tanto, A es diagonalizable. Hemos probado así que la existencia de n autovectores linealmente independientes es suficiente para garantizar la diagonalización de la matriz.

Ilustremos el proceso de diagonalización con un ejemplo concreto. Consideremos la matriz

$$A = \begin{pmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{pmatrix}.$$

Se trata de una matriz estocástica (sus columnas suman 1) y, como veremos, es diagonalizable.

Comenzamos calculando su polinomio característico:

$$\det(A - \lambda I) = \det \begin{pmatrix} 0.8 - \lambda & 0.3 \\ 0.2 & 0.7 - \lambda \end{pmatrix} = (0.8 - \lambda)(0.7 - \lambda) - 0.06.$$

Desarrollando, $(0.8 - \lambda)(0.7 - \lambda) = 0.56 - 1.5\lambda + \lambda^2$, restando 0.06 queda $\lambda^2 - 1.5\lambda + 0.5$. Factorizando, $(\lambda - 1)(\lambda - 0.5) = 0$. Por tanto, los autovalores son $\lambda_1 = 1$ y $\lambda_2 = 0.5$.

Ahora hallamos los autovectores. Para $\lambda_1 = 1$, resolvemos $(A - I)\boldsymbol{x} = \boldsymbol{0}$:

$$\begin{pmatrix} -0.2 & 0.3 \\ 0.2 & -0.3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

que da la ecuación $-0.2x_1 + 0.3x_2 = 0$, es decir, $x_1 = 1.5x_2$. Elegimos, por simplicidad, $\boldsymbol{x}_1 = (3, 2)^T$. Verifiquemos:

$$A\boldsymbol{x}_1 = \begin{pmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 2.4 + 0.6 \\ 0.6 + 1.4 \end{pmatrix} = \begin{pmatrix} 3 \\ 2 \end{pmatrix} = 1 \cdot \boldsymbol{x}_1.$$

Efectivamente, $\boldsymbol{x}_1$ es autovector con autovalor 1.

Para $\lambda_2 = 0.5$, resolvemos $(A - 0.5I)\boldsymbol{x} = \mathbf{0}$:

$$\begin{pmatrix} 0.3 & 0.3 \\ 0.2 & 0.2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

de donde $0.3x_1 + 0.3x_2 = 0$, o $x_1 = -x_2$. Tomamos $\boldsymbol{x}_2 = (1, -1)^T$. Comprobamos:

$$A\boldsymbol{x}_2 = \begin{pmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0.8 - 0.3 \\ 0.2 - 0.7 \end{pmatrix} = \begin{pmatrix} 0.5 \\ -0.5 \end{pmatrix} = 0.5 \cdot \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

Así, $\boldsymbol{x}_2$ es autovector con autovalor 0.5.

Los dos autovectores $\boldsymbol{x}_1 = (3, 2)^T$ y $\boldsymbol{x}_2 = (1, -1)^T$ son linealmente independientes (su determinante es $3 \cdot (-1) - 2 \cdot 1 = -5 \neq 0$), por lo que forman una base de $\mathbb{R}^2$. Por el teorema anterior, la matriz A es diagonalizable. Construimos la matriz de paso

$$X = [\boldsymbol{x}_1 \ \boldsymbol{x}_2] = \begin{pmatrix} 3 & 1 \\ 2 & -1 \end{pmatrix},$$

y la matriz diagonal de autovalores

$$\Lambda = \begin{pmatrix} 1 & 0 \\ 0 & 0.5 \end{pmatrix}.$$

Entonces se cumple $AX = X\Lambda$, y por tanto $A = X\Lambda X^{-1}$. La inversa de X es

$$X^{-1} = \frac{1}{-5} \begin{pmatrix} -1 & -1 \\ -2 & 3 \end{pmatrix} = \begin{pmatrix} 0.2 & 0.2 \\ 0.4 & -0.6 \end{pmatrix},$$

como puede comprobarse multiplicando.

La utilidad de esta descomposición se aprecia al calcular potencias de A aplicadas a un vector. Supongamos que queremos estudiar el comportamiento de $A^n\boldsymbol{v}$ para un vector inicial $\boldsymbol{v} \in \mathbb{R}^2$. Como $\{\boldsymbol{x}_1, \boldsymbol{x}_2\}$ es una base, existen escalares únicos c_1, c_2 tales que

$$\boldsymbol{v} = c_1\boldsymbol{x}_1 + c_2\boldsymbol{x}_2.$$

Entonces, aplicando A y usando la linealidad,

$$A\boldsymbol{v} = c_1A\boldsymbol{x}_1 + c_2A\boldsymbol{x}_2 = c_1\lambda_1\boldsymbol{x}_1 + c_2\lambda_2\boldsymbol{x}_2.$$

Iterando, para todo $n \in \mathbb{N}$,

$$A^n\boldsymbol{v} = c_1\lambda_1^n\boldsymbol{x}_1 + c_2\lambda_2^n\boldsymbol{x}_2 = c_1 \cdot 1^n \cdot (3, 2)^T + c_2 \cdot (0.5)^n \cdot (1, -1)^T.$$

Esta expresión revela el comportamiento asintótico: como $0.5^n \to 0$ cuando $n \to \infty$, el término correspondiente al autovalor 0.5 se desvanece, y $A^n\boldsymbol{v} \to c_1(3, 2)^T$. Es decir, la iteración de A converge a un múltiplo del autovector de autovalor 1, lo que refleja la propiedad de estas matrices estocásticas de converger a un estado estacionario.

Para concretar con un ejemplo, tomemos $\boldsymbol{v} = (1, 0)^T$. Resolvemos $c_1\boldsymbol{x}_1 + c_2\boldsymbol{x}_2 = (1, 0)^T$:

$$\begin{pmatrix} 3 & 1 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

La solución es $c_1 = 0.2$, $c_2 = 0.4$ (usando X^{-1} obtenemos $c = X^{-1}\boldsymbol{v}$). Por tanto,

$$A^n \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 0.2 \cdot 1^n \begin{pmatrix} 3 \\ 2 \end{pmatrix} + 0.4 \cdot (0.5)^n \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

Por ejemplo, para $n = 1$, esto da $0.2(3,2)^T + 0.4 \cdot 0.5(1,-1)^T = (0.6, 0.4)^T + (0.2, -0.2)^T = (0.8, 0.2)^T$, que es exactamente la primera columna de A, como cabía esperar. Para n grande, el segundo término tiende a cero y $A^n(1,0)^T \to 0.2(3,2)^T = (0.6, 0.4)^T$, que es el vector estacionario (las columnas de A convergen a $(0.6, 0.4)^T$).

En forma matricial, la potencia n-ésima de A se calcula como

$$A^n = X\Lambda^n X^{-1} = \begin{pmatrix} 3 & 1 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & (0.5)^n \end{pmatrix} X^{-1},$$

lo que evita tener que multiplicar la matriz A repetidamente. Este procedimiento es el núcleo de la utilidad práctica de la diagonalización: reduce el cálculo de potencias de matrices al simple cálculo de potencias de números escalares.

Retomemos ahora las nociones de multiplicidades que introdujimos en la sección de cálculo de autovalores y conectémoslas con la diagonalización.

Recordemos que para cada autovalor λ_i de una matriz A definimos dos números: su **multiplicidad algebraica**, que es la potencia del factor $(\lambda - \lambda_i)$ en el polinomio característico, y su **multiplicidad geométrica**, que es la dimensión del espacio propio E_{λ_i}, es decir, el número máximo de autovectores linealmente independientes asociados a λ_i. Siempre se cumple que

$$1 \leq \text{mult. geométrica de } \lambda_i \leq \text{mult. algebraica de } \lambda_i.$$

La primera desigualdad es cierta porque todo autovalor tiene al menos un autovector; la segunda es una propiedad general que no demostraremos aquí, pero que es fundamental.

El ejemplo que vimos en la sección anterior, con la matriz

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix},$$

es particularmente ilustrativo. Su polinomio característico es $(2-\lambda)^3$, luego el único autovalor es $\lambda = 2$ con multiplicidad algebraica 3. Sin embargo, al resolver el sistema $(A - 2I)\boldsymbol{v} = 0$, obtuvimos que el espacio propio E_2 tiene dimensión 2, pues los autovectores son de la forma $(v_1, 0, v_3)^T$. Por tanto, la multiplicidad geométrica de $\lambda = 2$ es 2, estrictamente menor que la algebraica.

¿Qué consecuencias tiene esta deficiencia? Si una matriz es diagonalizable, debe existir una base de $\mathbb{R}^n$ formada por autovectores. Pero en el ejemplo anterior, el espacio propio E_2 solo aporta dos direcciones independientes, y no hay otros autovalores que contribuyan con más direcciones, ya que $\lambda = 2$ es el único. En total, solo podemos reunir dos autovectores linealmente independientes, no tres. Por tanto, no existe una base de autovectores de $\mathbb{R}^3$, y la matriz no puede ser semejante a una diagonal. En general, si para algún autovalor la multiplicidad geométrica es menor que la algebraica, la matriz carece de suficientes autovectores para completar una base del espacio total. En consecuencia, la matriz no es diagonalizable.

Podemos enunciar entonces el siguiente criterio: una matriz $A \in \mathbb{R}^{n\times n}$ es diagonalizable si y solo si para cada uno de sus autovalores, la multiplicidad geométrica coincide con la multiplicidad algebraica. Cuando esta condición se cumple, podemos escoger, para cada autovalor, una base de su espacio propio; la unión de todas esas bases proporciona exactamente n vectores linealmente independientes, que forman la base de autovectores que necesitamos. Si falla para al menos un autovalor, la matriz es no diagonalizable, y decimos que es defectuosa (o que tiene un defecto espectral). Este es el caso del ejemplo anterior: el defecto es la diferencia $3 - 2 = 1$.

En la práctica, cuando una matriz no es diagonalizable, no podemos simplificar su potencia mediante una matriz diagonal. No obstante, existe una forma canónica más general, llamada forma de Jordan, que permite un tratamiento sistemático de estos casos, aunque su estudio queda fuera del alcance de este capítulo.

Nos queda entonces enunciar con precisión lo que venimos usando. La pieza que falta es el siguiente lema, que explica por qué autovalores distintos aportan direcciones *genuinamente* nuevas.

Teorema 4.17 (Independencia y criterio de diagonalización). Sea $A \in \mathbb{C}^{n\times n}$.

1. Autovectores correspondientes a autovalores *distintos* son linealmente independientes.
2. Si A tiene n autovalores distintos, entonces A es diagonalizable.
3. Para todo autovalor λ vale $1 \le \dim E_\lambda \le$ mult. algebraica de λ.
4. A es diagonalizable si y sólo si, para *cada* autovalor, la multiplicidad geométrica coincide con la algebraica.

La demostración es el ejercicio de desarrollo que sigue. Vale la pena subrayar que el recíproco de (2) es falso: la identidad tiene un solo autovalor y es diagonalizable. Tener autovalores distintos es cómodo, pero no necesario.

Ejercicio de desarrollo 4.1 | Multiplicidades y el criterio de diagonalización

Este ejercicio demuestra el Teorema 4.17. Sea $A \in \mathbb{C}^{n\times n}$.

(a) Sean $\lambda_1, \dots, \lambda_k$ autovalores distintos de A con autovectores $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k$. Probar que son linealmente independientes. *Sugerencia:* por inducción en k; si $c_1\boldsymbol{v}_1 + \cdots + c_k\boldsymbol{v}_k = \mathbf{0}$, aplicar $A - \lambda_k I$ a los dos miembros y ver qué término desaparece.

(b) Deducir que si A tiene n autovalores distintos entonces es diagonalizable, y dar un ejemplo de matriz diagonalizable con autovalores repetidos (para ver que la implicación no se invierte).

(c) Probar que $\dim E_\lambda \ge 1$ para todo autovalor, y que la desigualdad puede ser estricta en el otro extremo: exhibir una matriz de 3×3 con un autovalor de multiplicidad algebraica 3 y multiplicidad geométrica 1.

(d) *(La desigualdad de las multiplicidades.)* Sea λ un autovalor con $\dim E_\lambda = g$. Tomar una base $\boldsymbol{v}_1, \dots, \boldsymbol{v}_g$ de E_λ, extenderla a una base de $\mathbb{C}^n$ y llamar P a la

matriz que tiene esos n vectores como columnas. Probar que

$$P^{-1}AP = \begin{bmatrix} \lambda I_g & B \\ 0 & C \end{bmatrix}$$

y deducir, usando el determinante de una matriz triangular por bloques (Sección 2.7) y que la semejanza conserva el polinomio característico, que $(\lambda - t)^g$ divide a $\det(A - tI)$. Concluir que

$$\text{multiplicidad geométrica de } \lambda \;\leq\; \text{multiplicidad algebraica de } \lambda.$$

(e) Probar que la suma de los espacios propios de autovalores distintos es directa: si $\boldsymbol{w}_1 + \cdots + \boldsymbol{w}_k = \boldsymbol{0}$ con $\boldsymbol{w}_i \in E_{\lambda_i}$ y los λ_i distintos, entonces todos los $\boldsymbol{w}_i$ son nulos. *Sugerencia:* es el ítem (a) aplicado a los $\boldsymbol{w}_i$ no nulos.

(f) Concluir el criterio: A es diagonalizable si y sólo si $\sum_\lambda \dim E_\lambda = n$, y esto ocurre si y sólo si para cada autovalor las dos multiplicidades coinciden.

(g) Aplicar el criterio a

$$A_1 = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}, \qquad A_2 = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 5 \end{bmatrix}, \qquad A_3 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix},$$

decidiendo en cada caso si es diagonalizable sobre $\mathbb{R}$ y sobre $\mathbb{C}$.

Se entrega por escrito. El ítem (d) usa el cálculo de determinantes por bloques del Capítulo 2; el ítem (a) es el argumento que reaparece cada vez que hay que probar que una familia de autovectores es una base.

4.5 Autovalores de las matrices que ya conocemos

Antes de seguir conviene detenerse a mirar el espectro de las matrices que venimos usando desde el primer capítulo. En casi todos los casos los autovalores se leen sin calcular ningún polinomio característico: alcanza con reconocer qué hace la matriz.

El caso más simple es el de las **matrices triangulares**: como el determinante de una triangular es el producto de su diagonal, los autovalores son los elementos diagonales, y esto incluye a las diagonales y a la identidad.

Otro caso que ya sabemos leer es el de las **matrices de rango uno**. Si $A = \boldsymbol{u}\boldsymbol{v}^T$ con $\boldsymbol{u}, \boldsymbol{v} \neq \boldsymbol{0}$, entonces para todo $\boldsymbol{x}$

$$A\boldsymbol{x} = \boldsymbol{u}(\boldsymbol{v}^T\boldsymbol{x}),$$

de modo que la imagen de A es la recta generada por $\boldsymbol{u}$. Tomando $\boldsymbol{x} = \boldsymbol{u}$ queda $A\boldsymbol{u} = (\boldsymbol{v}^T\boldsymbol{u})\,\boldsymbol{u}$: el propio $\boldsymbol{u}$ es autovector, con autovalor $\boldsymbol{v}^T\boldsymbol{u}$. Y todo $\boldsymbol{x}$ ortogonal a $\boldsymbol{v}$ cumple $A\boldsymbol{x} = \boldsymbol{0}$, de modo que $E_0 = N(A) = \{\boldsymbol{v}\}^\perp$ tiene dimensión $n - 1$. En total: los autovalores de $\boldsymbol{u}\boldsymbol{v}^T$ son $\boldsymbol{v}^T\boldsymbol{u}$ y 0 con multiplicidad $n - 1$, y la traza $\operatorname{tr}(\boldsymbol{u}\boldsymbol{v}^T) = \boldsymbol{v}^T\boldsymbol{u}$ confirma la cuenta.

El resto del catálogo queda como ejercicio de desarrollo.

Ejercicio de desarrollo 4.2 | El espectro de las matrices conocidas

En todos los ítems, identificar los autovalores *con su multiplicidad* y los espacios propios, y decidir si la matriz es diagonalizable.

(a) *(Rango uno.)* Completar el razonamiento del texto: probar que $\boldsymbol{u}\boldsymbol{v}^T$ es diagonalizable si y sólo si $\boldsymbol{v}^T\boldsymbol{u} \neq 0$, y describir qué pasa geométricamente en el caso $\boldsymbol{v}^T\boldsymbol{u} = 0$ (mirar $\left[\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right]$).

(b) *(Proyecciones ortogonales.)* Sea P con $P^2 = P = P^T$. Probar que sus únicos autovalores posibles son 0 y 1, que $E_1 = C(P)$ y $E_0 = N(P)$, que P es siempre diagonalizable, y deducir

$$\operatorname{tr}(P) = \operatorname{rg}(P).$$

(Esta es la relación que quedó anunciada en el Ejercicio 1.10 del Capítulo 1.)

(c) *(Proyecciones oblicuas.)* Si sólo se pide $P^2 = P$, ¿siguen valiendo las conclusiones del ítem anterior? Decidir cuáles sí y cuáles no, usando $P = \left[\begin{smallmatrix} 1 & 1 \\ 0 & 0 \end{smallmatrix}\right]$ del Ejercicio de desarrollo 3.1.

(d) *(Householder.)* Sea $H = I - 2\boldsymbol{u}\boldsymbol{u}^T$ con $\|\boldsymbol{u}\| = 1$. Probar directamente, sin calcular ningún determinante, que -1 es autovalor simple (con $E_{-1} = \operatorname{span}\{\boldsymbol{u}\}$) y que 1 tiene multiplicidad $n-1$ (con $E_1 = \{\boldsymbol{u}\}^\perp$). Deducir $\det H = -1$ y $\operatorname{tr} H = n-2$, que en el Capítulo 3 habíamos obtenido por otro camino.

(e) *(Permutación cíclica.)* Sea P la matriz de $n \times n$ que manda $(x_1, x_2, \ldots, x_n)$ en $(x_2, \ldots, x_n, x_1)$. Probar que $P^n = I$ y deducir que sus autovalores están entre las raíces n-ésimas de la unidad. Verificar que, en efecto, son todas: para $\omega = e^{2\pi i/n}$, el vector $(1, \omega^k, \omega^{2k}, \ldots, \omega^{(n-1)k})^T$ es autovector. Las columnas que resultan forman la **matriz de Fourier** del Ejercicio 3.12.

(f) *(Rotaciones de Givens.)* Calcular los autovalores de $G(i, j, \theta)$ del Capítulo 3. ¿Para qué valores de θ es diagonalizable sobre $\mathbb{R}$?

(g) *(Triangular por bloques.)* Probar que los autovalores de $\left[\begin{smallmatrix} A & B \\ 0 & C \end{smallmatrix}\right]$ son los de A junto con los de C. Dar un ejemplo donde la matriz completa no sea diagonalizable aunque A y C sí lo sean.

Se entrega por escrito. El ítem (b) cierra una promesa del Capítulo 1 y el (d) una del Capítulo 3.

4.6 Potencias y sistemas dinámicos

El ejemplo de la matriz de Markov de la sección anterior no era un ejemplo suelto: es el prototipo de una situación que aparece por todas partes. Un **sistema dinámico lineal discreto** es una sucesión de vectores definida por

$$\boldsymbol{x}_{k+1} = A\boldsymbol{x}_k, \qquad \boldsymbol{x}_0 \text{ dado},$$

de modo que $\boldsymbol{x}_k = A^k\boldsymbol{x}_0$. La pregunta es siempre la misma: ¿qué le pasa a $\boldsymbol{x}_k$ cuando k crece?

Si A es diagonalizable, la respuesta es completa. Sea $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n$ una base de autovectores con autovalores $\lambda_1, \ldots, \lambda_n$, y escribamos el dato inicial en esa base, $\boldsymbol{x}_0 = c_1\boldsymbol{v}_1 + \cdots + c_n\boldsymbol{v}_n$.

Entonces

$$\boxed{\boldsymbol{x}_k = A^k \boldsymbol{x}_0 = c_1 \lambda_1^k \boldsymbol{v}_1 + \cdots + c_n \lambda_n^k \boldsymbol{v}_n} \tag{4.2}$$

Toda la dinámica está en los n números λ_i^k: cada dirección propia evoluciona por su cuenta, multiplicándose por su autovalor en cada paso. Esa es la razón profunda por la que los autovalores importan.

De (4.2) se leen de inmediato los tres comportamientos posibles. Llamemos

$$\rho(A) = \max_i |\lambda_i|$$

al **radio espectral** de A. Si $\rho(A) < 1$, todos los términos tienden a cero y $\boldsymbol{x}_k \to \mathbf{0}$ para todo dato inicial. Si $\rho(A) > 1$, el término de mayor módulo domina y $\|\boldsymbol{x}_k\| \to \infty$ salvo que el dato inicial no tenga componente en esas direcciones. Y si $\rho(A) = 1$ el sistema se mantiene acotado, con un caso especialmente importante: cuando $\lambda = 1$ es autovalor y todos los demás tienen módulo menor que 1, la sucesión converge a $c_1 \boldsymbol{v}_1$, la componente del dato inicial en la dirección de $\lambda = 1$. Eso es exactamente lo que pasaba con la matriz de Markov, y explica por qué convergía a un estado estacionario independiente de casi todo.

Observación 4.18. El radio espectral vuelve a aparecer, ahora medido con normas de matrices, en el capítulo de normas de matrices. Allí veremos que $A^k \to 0$ si y sólo si $\rho(A) < 1$, *sin* suponer que A sea diagonalizable.

El caso continuo: sistemas de ecuaciones diferenciales

Todo lo anterior tiene un gemelo continuo, y la analogía es tan exacta que conviene verla en paralelo. El punto de partida es la ecuación escalar más simple que existe:

$$u'(t) = a\,u(t), \qquad u(0) = v \qquad \Longrightarrow \qquad u(t) = v\,e^{at}.$$

La derivada es proporcional a la función, y la solución es una exponencial. Pasemos ahora a n funciones acopladas:

$$\boldsymbol{u}'(t) = A\,\boldsymbol{u}(t), \qquad \boldsymbol{u}(0) = \boldsymbol{v},$$

donde $\boldsymbol{u}(t) = (u_1(t), \ldots, u_n(t))^T$ y la derivada se toma coordenada a coordenada. Las ecuaciones están mezcladas entre sí — cada u_i' depende de todas las u_j — y esa es justamente la dificultad.

Los autovectores la deshacen. Si $A\boldsymbol{x} = \lambda \boldsymbol{x}$, la función $\boldsymbol{u}(t) = e^{\lambda t}\boldsymbol{x}$ cumple

$$\boldsymbol{u}'(t) = \lambda e^{\lambda t}\boldsymbol{x} = e^{\lambda t}(A\boldsymbol{x}) = A\,\boldsymbol{u}(t)\,:$$

en la dirección de un autovector, el sistema se comporta como la ecuación escalar. Si A es diagonalizable, con base de autovectores $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$, escribimos el dato inicial en esa base, $\boldsymbol{v} = c_1\boldsymbol{x}_1 + \cdots + c_n\boldsymbol{x}_n$, y sumamos:

$$\boxed{\boldsymbol{u}(t) = c_1 e^{\lambda_1 t}\boldsymbol{x}_1 + c_2 e^{\lambda_2 t}\boldsymbol{x}_2 + \cdots + c_n e^{\lambda_n t}\boldsymbol{x}_n} \tag{4.3}$$

Comparada con (4.2), la única diferencia es que λ_i^k se reemplazó por $e^{\lambda_i t}$. En forma matricial esto se escribe $\boldsymbol{u}(t) = e^{At}\boldsymbol{v}$, donde la **exponencial de una matriz** se define por la misma serie que la exponencial de un número,

$$e^{At} = \sum_{k=0}^{\infty} \frac{(At)^k}{k!}, \qquad \text{y para } A = X\Lambda X^{-1} \text{ resulta} \qquad e^{At} = X\,e^{\Lambda t}\,X^{-1}$$

con $e^{\Lambda t} = \operatorname{diag}(e^{\lambda_1 t}, \dots, e^{\lambda_n t})$: otra vez, diagonalizar convierte un problema matricial en n problemas escalares.

Observación 4.19 (El diccionario entre los dos casos). La correspondencia se resume así:

	discreto $\boldsymbol{x}_{k+1} = A\boldsymbol{x}_k$	**continuo** $\boldsymbol{u}' = A\boldsymbol{u}$
solución	$\boldsymbol{x}_k = A^k\boldsymbol{x}_0 = \sum c_i \lambda_i^k \boldsymbol{v}_i$	$\boldsymbol{u}(t) = e^{At}\boldsymbol{u}_0 = \sum c_i e^{\lambda_i t}\boldsymbol{x}_i$
tiende a $\mathbf{0}$	$\lvert\lambda_i\rvert < 1$ para todo i	$\operatorname{Re}\lambda_i < 0$ para todo i
región estable	interior del círculo unitario	semiplano izquierdo
queda acotado	$\lvert\lambda_i\rvert \le 1$	$\operatorname{Re}\lambda_i \le 0$

Las dos columnas no son independientes: evaluar la solución continua en tiempos $t = 0, 1, 2, \dots$ da un sistema discreto con matriz e^A, cuyos autovalores son e^{λ_i}. Y en efecto $|e^{\lambda}| = e^{\operatorname{Re}\lambda} < 1$ si y sólo si $\operatorname{Re}\lambda < 0$: las dos condiciones de estabilidad son la misma.

Observación 4.20 (Para qué sirven los autovalores complejos). Acá se ve por fin qué significan los autovalores complejos que aparecieron con la rotación. Si $\lambda = \alpha + i\beta$, entonces

$$e^{\lambda t} = e^{\alpha t}\big(\cos\beta t + i\,\operatorname{sen}\beta t\big)\,:$$

la parte real de λ controla el crecimiento o el amortiguamiento, y la parte imaginaria controla la *oscilación*, con frecuencia β. Un par de autovalores complejos conjugados con parte real negativa describe exactamente una oscilación que se apaga. Sin números complejos no hay manera de escribir eso.

Ejercicio de desarrollo 4.3 | Fibonacci y sistemas dinámicos

La sucesión de Fibonacci se define por $F_0 = 0$, $F_1 = 1$ y $F_{k+1} = F_k + F_{k-1}$.

(a) Verificar que, tomando $\boldsymbol{x}_k = (F_{k+1}, F_k)^T$, la recursión se escribe $\boldsymbol{x}_{k+1} = A\boldsymbol{x}_k$ con

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}, \qquad \boldsymbol{x}_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

(b) Calcular los autovalores de A y comprobar que son $\varphi = \frac{1+\sqrt{5}}{2}$ y $\psi = \frac{1-\sqrt{5}}{2}$, con $\varphi + \psi = 1$ y $\varphi\psi = -1$. Hallar autovectores y verificar que A es diagonalizable (¿qué ítem del Teorema 4.17 lo garantiza sin hacer cuentas?).

(c) Usar (4.2) para deducir la **fórmula de Binet**

$$F_k = \frac{\varphi^k - \psi^k}{\sqrt{5}},$$

y verificarla para $k = 1, \dots, 6$.

(d) Como $|\psi| < 1$, probar que F_k es el entero más cercano a $\varphi^k/\sqrt{5}$ y que $F_{k+1}/F_k \to \varphi$. Explicar, en términos de (4.2), por qué el cociente converge al autovalor dominante *cualquiera sea* el dato inicial (con tal de que $c_1 \neq 0$).

(e) *(El caso general.)* Sea A diagonalizable con $|\lambda_1| > |\lambda_2| \ge \cdots \ge |\lambda_n|$ y sea $\boldsymbol{x}_0$ con $c_1 \neq 0$. Probar que $\boldsymbol{x}_k/\lambda_1^k \to c_1\boldsymbol{v}_1$, y caracterizar en términos de $\rho(A)$ cuándo $\boldsymbol{x}_k \to \mathbf{0}$, cuándo queda acotada y cuándo explota.

(f) *(Markov.)* Sea A con entradas no negativas y columnas que suman 1. Probar que $\lambda = 1$ siempre es autovalor. *Sugerencia:* mirar A^T y el vector de unos, y usar la Proposición 4.5. Probar además que todo autovalor cumple $|\lambda| \leq 1$. *Sugerencia:* si $A^T\boldsymbol{y} = \lambda\boldsymbol{y}$, tomar la coordenada i de mayor módulo de $\boldsymbol{y}$ y acotar.

(g) Aplicar lo anterior a $A = \left[\begin{smallmatrix} 0{,}6 & 0{,}2 \\ 0{,}4 & 0{,}8 \end{smallmatrix}\right]$: hallar el estado estacionario y estimar cuántos pasos hacen falta para que el término transitorio sea menor que 10^{-3}.

(h) *(El caso continuo.)* Resolver $\boldsymbol{u}' = A\boldsymbol{u}$ con $A = \left[\begin{smallmatrix} 0 & 1 \\ 1 & 0 \end{smallmatrix}\right]$ y $\boldsymbol{u}(0) = (1, 0)^T$ usando (4.3), y verificar que la solución obtenida satisface efectivamente el sistema. Identificar las funciones que aparecen.

(i) *(Estabilidad.)* Probar que, si A es diagonalizable, entonces $\boldsymbol{u}(t) \to \mathbf{0}$ para *todo* dato inicial si y sólo si $\operatorname{Re}\lambda_i < 0$ para todos los autovalores. Comparar con la condición $\rho(A) < 1$ del caso discreto y explicar, usando el diccionario, por qué las dos condiciones dicen lo mismo.

(j) *(Un oscilador.)* La ecuación $y''(t) + y(t) = 0$ se convierte en un sistema de primer orden tomando $\boldsymbol{u} = (y, y')^T$. Escribir la matriz A correspondiente, calcular sus autovalores y deducir, vía (4.3), la solución general $y(t) = c\cos t + d\,\operatorname{sen} t$. ¿Qué pasa con $y'' + 2\mu y' + y = 0$ cuando $\mu > 0$? Relacionar el signo de $\operatorname{Re}\lambda$ con el amortiguamiento.

Se entrega por escrito. El ítem (e) es el fundamento del método de la potencia de la sección siguiente.

4.7 El método de la potencia

Dijimos al final de la Sección 4.2 que en la práctica los autovalores no se calculan con el polinomio característico. Ahora estamos en condiciones de entender el más simple de los métodos que sí se usan, y que además es la contracara constructiva de todo lo que acabamos de ver: la fórmula (4.2) dice que iterar A *amplifica automáticamente* la dirección del autovalor de mayor módulo. Si en lugar de pelear contra ese efecto lo aprovechamos, tenemos un algoritmo.

La idea es iterar $\boldsymbol{x}_{k+1} = A\boldsymbol{x}_k$ normalizando en cada paso para que el vector no se desborde ni se desvanezca:

$$\boldsymbol{y}_{k+1} = A\boldsymbol{x}_k, \qquad \boldsymbol{x}_{k+1} = \frac{\boldsymbol{y}_{k+1}}{\|\boldsymbol{y}_{k+1}\|}.$$

Si hay un autovalor dominante, $\boldsymbol{x}_k$ se alinea con su autovector y la constante de proporcionalidad entre $A\boldsymbol{x}_k$ y $\boldsymbol{x}_k$ se acerca al autovalor. El método es barato — cada paso es un producto matriz-vector — y no necesita conocer la matriz completa: alcanza con saber multiplicar por ella, que es la situación típica cuando A es enorme y rala.

Ejercicio de desarrollo 4.4 | El método de la potencia

Sea $A \in \mathbb{R}^{n\times n}$ diagonalizable con autovalores $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ y autovectores $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n$, y sea $\boldsymbol{x}_0$ un vector con componente no nula en la dirección de $\boldsymbol{v}_1$.

(a) Probar que, si $\boldsymbol{x}_k$ se define normalizando como arriba, entonces $\boldsymbol{x}_k$ converge a $\pm \boldsymbol{v}_1/\|\boldsymbol{v}_1\|$ (el signo puede alternar: explicar cuándo). *Sugerencia:* escribir $A^k \boldsymbol{x}_0$ con (4.2) y sacar factor común λ_1^k.

(b) Probar que el error se comporta como $\left|\lambda_2/\lambda_1\right|^k$: el método converge *linealmente* y tanto más rápido cuanto más separado esté el autovalor dominante del siguiente.

(c) Dar dos maneras de estimar λ_1 a partir de $\boldsymbol{x}_k$: el cociente entre una coordenada de $A\boldsymbol{x}_k$ y la misma coordenada de $\boldsymbol{x}_k$, y el cociente de normas $\|A\boldsymbol{x}_k\|/\|\boldsymbol{x}_k\|$. Discutir qué pasa con el segundo si $\lambda_1 < 0$. *(Más adelante en el curso veremos una tercera estimación, mejor que estas dos.)*

(d) Probar el método sobre $A = \left[\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right]$ con $\boldsymbol{x}_0 = (1,0)^T$: hacer cuatro iteraciones a mano y comparar con los valores exactos $\lambda_1 = 3$, $\boldsymbol{v}_1 = (1,1)^T$. Verificar que el error se divide aproximadamente por 3 en cada paso y explicar por qué.

(e) *(Cuándo falla.)* Analizar qué ocurre si $|\lambda_1| = |\lambda_2|$ en los tres casos siguientes: $\lambda_2 = \lambda_1$ (autovalor repetido), $\lambda_2 = -\lambda_1$ y $\lambda_{1,2}$ complejos conjugados. Ilustrar el segundo caso con $\left[\begin{smallmatrix} 1 & 0 \\ 0 & -1 \end{smallmatrix}\right]$ y el tercero con una rotación.

(f) *(Desplazamiento.)* Sea σ un escalar que no es autovalor de A. Usando la Proposición 4.9, probar que los autovalores de $(A-\sigma I)^{-1}$ son $1/(\lambda_i - \sigma)$ con los *mismos* autovectores. Deducir que aplicar el método de la potencia a $(A-\sigma I)^{-1}$ encuentra el autovalor de A *más cercano a* σ, y no el de mayor módulo. ¿Cómo se implementa eso sin invertir la matriz? *(Sugerencia: la factorización LU del Capítulo 2.)*

Se entrega por escrito. El ítem (f) es la base de los algoritmos que efectivamente se usan; el ítem (b) explica por qué el método puede ser desesperadamente lento cuando los dos autovalores dominantes están cerca.

4.8 Ejercicios

1. La rotación $Q = \begin{bmatrix} \cos\theta & -\operatorname{sen}\theta \\ \operatorname{sen}\theta & \cos\theta \end{bmatrix}$ tiene autovalores complejos $\lambda = \cos\theta \pm i \operatorname{sen}\theta$:

$$Q\begin{bmatrix} 1 \\ -i \end{bmatrix} = (\cos\theta + i\operatorname{sen}\theta)\begin{bmatrix} 1 \\ -i \end{bmatrix} \quad \text{y} \quad Q\begin{bmatrix} 1 \\ i \end{bmatrix} = (\cos\theta - i\operatorname{sen}\theta)\begin{bmatrix} 1 \\ i \end{bmatrix}.$$

   Verifique que $\lambda_1 + \lambda_2$ es igual la traza de Q. Verifique que $(\lambda_1)(\lambda_2)$ es igual al determinante. Verifique que esos autovectores complejos son ortogonales, usando el producto punto complejo $\overline{\boldsymbol{x}}_1 \cdot \boldsymbol{x}_2$ (¡no solo $\boldsymbol{x}_1 \cdot \boldsymbol{x}_2$!).

   ¿Qué es Q^{-1} y cuáles son sus autovalores?

2. Calcule los autovalores y autovectores de A y A^{-1}. ¡Verifique la traza!

$$A = \begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix} \qquad A^{-1} = \begin{bmatrix} -1/2 & 1 \\ 1/2 & 0 \end{bmatrix}.$$

3. Encuentre los autovalores de A y B (fácil en matrices triangulares) y $A+B$:

$$A = \begin{bmatrix} 3 & 0 \\ 1 & 1 \end{bmatrix} \qquad B = \begin{bmatrix} 1 & 1 \\ 0 & 3 \end{bmatrix} \qquad A+B = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix}.$$

¿ Los autovalores de $A+B$ coinciden con los autovalores de A mas los autovalores de B?

4. Encuentre los autovalores de A, B, AB y BA:

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \qquad B = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} \qquad AB = \begin{bmatrix} 1 & 2 \\ 1 & 3 \end{bmatrix} \qquad BA = \begin{bmatrix} 3 & 2 \\ 1 & 1 \end{bmatrix}.$$

   (a) ¿Son los autovalores de AB iguales a los autovalores de A por los autovalores de B?

   (b) ¿Son los autovalores de AB iguales a los autovalores de BA?

5. (a) Si sabe que x es un autovector, la manera de encontrar λ es:.

   (b) Si sabe que λ es un autovalor, la manera de encontrar x es:

6. Encuentre los autovalores y autovectores para las dos matrices de Markov A y A^∞. Explique a partir de las respuestas por qué A^{100} es cercana a A^∞:

$$A = \begin{bmatrix} 0.6 & 0.2 \\ 0.4 & 0.8 \end{bmatrix} \quad \text{y} \quad A^\infty = \begin{bmatrix} 1/3 & 1/3 \\ 2/3 & 2/3 \end{bmatrix}.$$

7. **El determinante de A es igual al producto $\lambda_1\lambda_2\cdots\lambda_n$.** Comience escribiendo el polinomio $\det(A-\lambda I)$ separado en sus n factores (siempre posible). Luego tome $\lambda = 0$:

$$\det(A-\lambda I) = (\lambda_1-\lambda)(\lambda_2-\lambda)\cdots(\lambda_n-\lambda) \quad \text{entonces} \quad \det A = .$$

   Verifique esta regla en la matriz de Markov de la Sección 4.4, que tiene $\lambda_1 = 1$ y $\lambda_2 = 1/2$.

8. La suma de los elementos de la diagonal (la *traza*) es igual a la suma de sus autovalores:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad \text{tiene} \quad \det(A-\lambda I) = \lambda^2 - (a+d)\lambda + ad - bc = 0.$$

   La fórmula cuadrática da los autovalores $\lambda = (a+d+\sqrt{\quad})/2$ y $\lambda =$. Su suma es:. Si A tiene $\lambda_1 = 3$ y $\lambda_2 = 4$ entonces $\det(A-\lambda I) =$:.

9. Sea A con $\lambda_1 = 4$ y $\lambda_2 = 5$, luego $\det(A-\lambda I) = (\lambda-4)(\lambda-5) = \lambda^2 - 9\lambda + 20 = 0$. Encuentre tres matrices diferentes de 2×2 que tengan autovalores $\lambda = 4, 5$. Notar que debe cumplirse que la traza es 9 y su determinante 20.

10. Elija las últimas filas de A y C para que tengan autovalores $4, 7$ y $1, 2, 3$ respectivamente:

Matrices compañeras $\qquad A = \begin{bmatrix} 0 & 1 \\ * & * \end{bmatrix} \quad C = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ * & * & * \end{bmatrix}.$

11. La Proposición 4.5 dice que A y A^T tienen los mismos autovalores. Muestre con un ejemplo de 2×2, distinto del de la Observación 4.6, que los *autovectores* de A y de A^T no son los mismos. ¿Para qué matrices sí coinciden?

12. La siguiente matriz es singular de rango uno. Encuentre tres λ y tres autovectores:

$$A = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \begin{bmatrix} 2 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 2 \\ 4 & 2 & 4 \\ 2 & 1 & 2 \end{bmatrix}.$$

13. Sabemos que si A y B tienen los mismos autovalores $\lambda_1, \ldots, \lambda_n$ con los mismos autovectores independientes $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$, entonces $A = B$. Cualquier vector $\boldsymbol{x}$ se puede escribir como una combinación $c_1\boldsymbol{x}_1 + \cdots + c_n\boldsymbol{x}_n$. ¿ Cómo se relacionan los coeficientes c_i con el producto $A\boldsymbol{x}$? ¿ Y con $B\boldsymbol{x}$?

14. Suponga que A tiene autovalores $0, 3, 5$ con autovectores independientes $\boldsymbol{u}, \boldsymbol{v}, \boldsymbol{w}$.

    (a) Dé una base para el espacio nulo y una base para el espacio columna.

    (b) Encuentre una solución particular para $A\boldsymbol{x} = \boldsymbol{v} + \boldsymbol{w}$. Encuentre todas las soluciones.

    (c) $Ax = u$ no tiene solución. Si la tuviera entonces ____ estaría en el espacio columna.

15. (a) Factorice estas dos matrices en $A = X\Lambda X^{-1}$:

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} \qquad A = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix}.$$

    (b) Si $A = X\Lambda X^{-1}$ entonces $A^3 = (\quad)(\quad)(\quad)$ y $A^{-1} = (\quad)(\quad)(\quad)$.

16. Suponga que $A = X\Lambda X^{-1}$. ¿ Cuál es la matriz de autovalores para $A + 2I$? ¿ Cuál es la matriz de autovectores ? Verifique que $A + 2I = (\quad)(\quad)(\quad)^{-1}$.

17. Escriba la matriz más general que tiene autovectores $\begin{bmatrix} \mathbf{1} \\ \mathbf{1} \end{bmatrix}$ y $\begin{bmatrix} \mathbf{1} \\ \mathbf{-1} \end{bmatrix}$.

18. Verdadero o falso: Si los autovalores de A son $2, 2, 5$ entonces la matriz es sin dudas

    (a) invertible,

    (b) diagonalizable,

    (c) no diagonalizable.

19. Verdadero o falso: Si los únicos autovectores de A son múltiplos de $(1, 4)$ entonces A:

(a) no tiene inversa, (b) tiene un autovalor repetido, (c) no tiene diagonalización $X\Lambda X^{-1}$.

20. $A^k = X\Lambda^k X^{-1}$ se acerca a la matriz cero cuando $k \to \infty$ si y solo si todo λ tiene valor absoluto menor a ____. ¿ Cuál de estas matrices cumple $A^k \to 0$?

$$A_1 = \begin{bmatrix} .6 & .9 \\ .4 & .1 \end{bmatrix} \qquad A_2 = \begin{bmatrix} .6 & .9 \\ .1 & .6 \end{bmatrix}.$$

21. Diagonalice A y calcule $X\Lambda^k X^{-1}$ y demuestre la fórmula presentada para A^k:

$$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \qquad \text{tiene} \qquad A^k = \frac{1}{2}\begin{bmatrix} 1+3^k & 1-3^k \\ 1-3^k & 1+3^k \end{bmatrix}.$$

22. Los autovalores de A son 1 y 9, y los autovalores de B son -1 y 9:

$$A = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix} \qquad B = \begin{bmatrix} 4 & 5 \\ 5 & 4 \end{bmatrix}.$$

Encuentre una matriz raíz cuadrada de A a partir de $R = X\sqrt{\Lambda}\,X^{-1}$. ¿Por qué no hay una matriz real que sea raíz cuadrada de B?

23. Suponga que la misma X diagonaliza a ambas matrices A y B. Tienen *los mismos autovectores* en $A = X\Lambda_1 X^{-1}$ y $B = X\Lambda_2 X^{-1}$. Demuestre que $AB = BA$.

24. La traspuesta de $A = X\Lambda X^{-1}$ es $A^{\mathsf{T}} = (X^{-1})^{\mathsf{T}}\Lambda X^{\mathsf{T}}$. Los autovectores en $A^{\mathsf{T}}\boldsymbol{y} = \lambda\boldsymbol{y}$ son las columnas de la matriz $(X^{-1})^{\mathsf{T}}$. Se los conoce como ***autovectores a izquierda de A***, porque $\boldsymbol{y}^{\mathsf{T}}A = \lambda\boldsymbol{y}^{\mathsf{T}}$. ¿Cómo multiplicaría matrices para encontrar esta fórmula para A?

Suma de matrices de rango 1 $\quad A = X\Lambda X^{-1} = \lambda_1\boldsymbol{x}_1\boldsymbol{y}_1^{\mathsf{T}} + \cdots + \lambda_n\boldsymbol{x}_n\boldsymbol{y}_n^{\mathsf{T}}.$

25. **¿Cuándo es una matriz A semejante a su matriz de autovalores Λ?**

A y Λ siempre tienen los mismos autovalores. Pero para que sean semejantes se requiere de una matriz B con $A = B\Lambda B^{-1}$. Entonces B es la matriz ____ y A debe tener n ____ independientes.

5 CAPÍTULO

Schur y bases ortonormales de autovectores

El Capítulo 4 terminó con una respuesta y una frustración. La respuesta: una matriz es diagonalizable exactamente cuando tiene una base de autovectores independientes, y entonces $A = X\Lambda X^{-1}$ convierte potencias, polinomios y sistemas dinámicos en cuentas con números. La frustración: hay matrices que no la tienen, y no parece haber nada que hacer con ellas.

Este capítulo muestra que sí lo hay, y que el remedio pasa por bajar una pretensión y subir otra. Bajamos la pretensión de llegar hasta una matriz *diagonal* y nos conformamos con una *triangular*; a cambio, subimos la exigencia sobre la base y la pedimos **ortonormal**. El resultado es el teorema de Schur, y lo notable es que vale *siempre*, sin ninguna hipótesis: toda matriz cuadrada, diagonalizable o no, real o compleja, se escribe como

$$A = UTU^*, \qquad U \text{ unitaria}, \quad T \text{ triangular superior}.$$

Cambiar X^{-1} por U^* no es un detalle: las matrices unitarias son las que conservan normas y ángulos — lo probamos en la Sección 5.1 —, así que una factorización con U es estable y una con X cualquiera puede no serlo. Por eso esta es la factorización que usan de verdad los algoritmos numéricos.

Con Schur en la mano, dos preguntas se vuelven fáciles. La primera es qué información se lee en la diagonal de T: allí están los autovalores con sus multiplicidades, y de ahí salen en tres renglones las fórmulas de la traza y el determinante que el Capítulo 4 había dejado anunciadas. La segunda es cuándo se puede llegar hasta una matriz diagonal manteniendo la base ortonormal, es decir, cuándo *sí* hay una base ortonormal de autovectores. La respuesta es sorprendentemente limpia:

$$A \text{ tiene una base ortonormal de autovectores} \iff AA^* = A^*A,$$

una condición que se verifica multiplicando dos matrices. Las matrices que la cumplen se llaman **normales**, e incluyen a las simétricas, las hermíticas, las ortogonales, las unitarias y las de permutación: casi todas las matrices con nombre propio que fuimos encontrando. El caso real y simétrico de este resultado es el *teorema espectral*, $A = Q\Lambda Q^T$, que es la herramienta con la que se construyen las matrices definidas positivas del Capítulo 6 y la SVD del Capítulo 8.

Cerramos con una consecuencia cuantitativa: para una matriz normal, el tamaño de la matriz — medido con la norma de Frobenius de la Sección 1.3.6 — está íntegramente repartido entre sus autovalores. Eso es lo que permite decir cuánto se pierde al quedarse sólo con los más grandes, que es la idea que sostiene la aproximación de rango bajo y el análisis de componentes principales.

5.1 El caso complejo: notación y matrices unitarias

Como en el Capítulo 4, acá no alcanza con $\mathbb{R}$: los autovalores viven en $\mathbb{C}$ y los autovectores en $\mathbb{C}^n$. Antes de empezar fijamos la notación y probamos las pocas propiedades que vamos a usar todo el tiempo. Nada de esto es difícil; lo único que hay que hacer es acordarse de conjugar.

La adjunta A^*

En la Sección 3.1 vimos que el producto interno de $\mathbb{C}^n$ es $\overline{\boldsymbol{x}}^T\boldsymbol{y}$, con el primer factor conjugado. La operación "conjugar y trasponer" aparece tantas veces que conviene darle nombre y símbolo.

Definición 5.1 (Adjunta). Sea $A \in \mathbb{C}^{m\times n}$. La **adjunta** (o traspuesta conjugada) de A es la matriz $A^* \in \mathbb{C}^{n\times m}$ dada por

$$A^* = \overline{A}^T, \qquad (A^*)_{ij} = \overline{a_{ji}}$$

Con esta notación el producto interno de $\mathbb{C}^n$ se escribe simplemente $\boldsymbol{x}^*\boldsymbol{y}$: un vector columna es una matriz de $n \times 1$, y su adjunta es el vector fila conjugado. Las reglas son las de la traspuesta, con un conjugado encima:

$$(A^*)^* = A, \qquad (A+B)^* = A^* + B^*, \qquad (cA)^* = \overline{c}\,A^*, \qquad (AB)^* = B^*A^*$$

La última, que vuelve a invertir el orden, se verifica igual que para la traspuesta: $\overline{(AB)}^T = (\overline{A}\,\overline{B})^T = \overline{B}^T\overline{A}^T = B^*A^*$.

El nombre *adjunta* viene de la propiedad siguiente, que es la razón de ser de toda esta notación: A^* es la matriz que permite pasar A de un lado al otro del producto interno.

Proposición 5.2. Para todos $\boldsymbol{x} \in \mathbb{C}^n$, $\boldsymbol{y} \in \mathbb{C}^m$ y $A \in \mathbb{C}^{m\times n}$,

$$(A\boldsymbol{x})^*\boldsymbol{y} = \boldsymbol{x}^*(A^*\boldsymbol{y}).$$

Demostración. $(A\boldsymbol{x})^*\boldsymbol{y} = (\boldsymbol{x}^*A^*)\boldsymbol{y} = \boldsymbol{x}^*(A^*\boldsymbol{y})$, usando $(AB)^* = B^*A^*$ y la asociatividad del producto. ∎

Hermíticas y unitarias

Dos familias de matrices complejas llevan nombre propio, y son las versiones complejas de dos que ya conocemos.

Definición 5.3 (Hermítica y unitaria). Sea $A \in \mathbb{C}^{n\times n}$. Decimos que

- A es **hermítica** si $A^* = A$, es decir, si $a_{ij} = \overline{a_{ji}}$;
- A es **unitaria** si $A^*A = I$, es decir, si sus columnas forman una base ortonormal de $\mathbb{C}^n$ con el producto interno complejo.

El diccionario con el caso real es inmediato: si A tiene todas sus entradas reales entonces $\overline{A} = A$ y por lo tanto $A^* = A^T$, de modo que

$$\text{hermítica} \longleftrightarrow \text{simétrica}, \qquad \text{unitaria} \longleftrightarrow \text{ortogonal}.$$

Todo lo que digamos de hermíticas y unitarias contiene, como caso particular, lo que ya sabemos de simétricas y ortogonales. Observemos de paso que una matriz hermítica tiene la diagonal real, porque $a_{ii} = \overline{a_{ii}}$.

Observación 5.4 (Cuidado con la palabra). En el Capítulo 2 hablamos de matrices triangulares "de diagonal unitaria", queriendo decir que los elementos de la diagonal valen 1. Es un uso distinto y desafortunado de la misma palabra: una matriz *unitaria* en el sentido de la definición anterior no tiene por qué tener unos en la diagonal, ni al revés. El contexto siempre deja claro cuál de los dos sentidos está en juego.

Lo único que necesitamos de las unitarias es que no deforman: ésta es la propiedad que hace que la factorización de Schur sea numéricamente estable, y es la versión compleja de la Proposición 3.27 del Capítulo 3, que allí probamos para matrices reales.

Proposición 5.5 (Las unitarias preservan normas y ángulos). Sea $U \in \mathbb{C}^{n\times n}$ unitaria. Entonces, para todos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{C}^n$,

$$(U\boldsymbol{x})^*(U\boldsymbol{y}) = \boldsymbol{x}^*\boldsymbol{y} \qquad \text{y} \qquad \|U\boldsymbol{x}\| = \|\boldsymbol{x}\|.$$

Además U es invertible con $U^{-1} = U^*$, y U^* es también unitaria.

Demostración. La primera igualdad es una cuenta:

$$(U\boldsymbol{x})^*(U\boldsymbol{y}) = \boldsymbol{x}^*U^*U\boldsymbol{y} = \boldsymbol{x}^*I\boldsymbol{y} = \boldsymbol{x}^*\boldsymbol{y}.$$

Tomando $\boldsymbol{y} = \boldsymbol{x}$ queda $\|U\boldsymbol{x}\|^2 = \|\boldsymbol{x}\|^2$, y como las normas son no negativas, $\|U\boldsymbol{x}\| = \|\boldsymbol{x}\|$. Para la invertibilidad: U es cuadrada y $U^*U = I$ dice que U^* es inversa a izquierda; para una matriz cuadrada eso basta para que sea la inversa, de modo que $U^{-1} = U^*$ y también $UU^* = I$. Esta última igualdad, leída como $(U^*)^*U^* = I$, dice que U^* es unitaria. ∎

Conservar el producto interno es conservar normas *y* ángulos: si dos vectores eran ortogonales, sus imágenes lo siguen siendo. Por eso multiplicar por una matriz unitaria no agranda errores de redondeo, y por eso todas las factorizaciones que usan los algoritmos numéricos — QR, Schur, SVD — están hechas con matrices de esta clase.

5.2 El teorema de Schur

Teorema 5.6 (Schur). Para toda $A \in \mathbb{C}^{n\times n}$ existe una matriz unitaria U tal que

$$T := U^*AU \quad \text{es triangular superior}, \qquad \text{equivalentemente} \qquad A = UTU^*.$$

Además, la diagonal de T está formada por los autovalores de A (contados con multiplicidad). La factorización $A = UTU^*$ se llama *descomposición de Schur* de A.

Demostración por inducción en n. Caso base $n = 1$. Trivial.

Paso inductivo. Supongamos el enunciado cierto para tamaño $n-1$ y sea $A \in \mathbb{C}^{n\times n}$. Por el teorema fundamental del álgebra, el polinomio característico de A tiene una raíz $\lambda \in \mathbb{C}$; sea $v \neq 0$ un autovector asociado. Normalizamos $\|v\| = 1$ y extendemos $\{v\}$ a una base ortonormal de $\mathbb{C}^n$, $\{v, v_2, \dots, v_n\}$ (por ejemplo con Gram–Schmidt), y sea

$$U_1 = [\, v \;\; v_2 \;\; \cdots \;\; v_n \,].$$

Entonces U_1 es unitaria y, escribiendo $B := U_1^* A U_1$, se tiene

$$Be_1 \;=\; U_1^* A\, U_1 e_1 \;=\; U_1^* A v \;=\; U_1^*(\lambda v) \;=\; \lambda\, U_1^* v \;=\; \lambda e_1,$$

con $e_1 = (1, 0, \dots, 0)^T$. Por lo tanto la primera columna de B es $(\lambda, 0, \dots, 0)^T$ y B adopta la forma por bloques

$$B = \begin{bmatrix} \lambda & * \\ 0 & A_1 \end{bmatrix}, \qquad A_1 \in \mathbb{C}^{(n-1)\times(n-1)}.$$

Por hipótesis inductiva existe una unitaria $U_2 \in \mathbb{C}^{(n-1)\times(n-1)}$ tal que $U_2^* A_1 U_2 = T_1$ es triangular superior. Definimos

$$U \;=\; U_1 \begin{bmatrix} 1 & 0 \\ 0 & U_2 \end{bmatrix},$$

que es unitaria por ser producto de unitarias, y calculamos

$$U^* A U = \begin{bmatrix} 1 & 0 \\ 0 & U_2^* \end{bmatrix} \begin{bmatrix} \lambda & * \\ 0 & A_1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & U_2 \end{bmatrix} = \begin{bmatrix} \lambda & * \\ 0 & T_1 \end{bmatrix},$$

que es triangular superior. La diagonal está formada por λ seguido de la diagonal de T_1, que por inducción son los autovalores de A_1 y, por ende, de A (pues A y B son semejantes y $\det(B - zI) = (\lambda - z)\det(A_1 - zI)$). Esto cierra la inducción. ∎

Corolario 5.7 (Las multiplicidades se leen en la diagonal). Con las notaciones del Teorema 5.6, el polinomio característico de A es

$$\det(A - zI) = \det(T - zI) = \prod_{k=1}^{n} (t_{kk} - z),$$

de modo que cada autovalor aparece en la diagonal de T tantas veces como indica su *multiplicidad algebraica*. En consecuencia, si λ tiene multiplicidad algebraica m, entonces $T - \lambda I$ tiene exactamente m ceros en la diagonal, $\operatorname{rg}(T - \lambda I) \geq n - m$ y por lo tanto

$$\dim E_\lambda = \dim N(A - \lambda I) \leq m :$$

la multiplicidad geométrica nunca supera a la algebraica.

Demostración. $A - zI = U(T - zI)U^*$ es semejante a $T - zI$, y el determinante de una triangular es el producto de su diagonal. Para la segunda parte, $A - \lambda I$ y $T - \lambda I$ son semejantes, así que tienen el mismo rango y espacios nulos de la misma dimensión; y una matriz triangular con $n - m$ elementos diagonales no nulos tiene al menos $n - m$ columnas independientes. ∎

Observación 5.8. La desigualdad entre multiplicidades ya la habíamos demostrado, por otro camino, en el Ejercicio de desarrollo 4.1 del Capítulo 4. Vale la pena comparar las dos pruebas: allá se extendía una base del autoespacio y se miraba un bloque; acá se triangula de una vez y la desigualdad se lee en la diagonal.

Observación 5.9 (El orden de la diagonal se puede elegir). En el paso inductivo, λ es *cualquier* autovalor de A. Repitiendo el argumento se ve que, dado un orden prefijado $\lambda_1, \dots, \lambda_n$ de los autovalores de A (con multiplicidad), existe una unitaria U tal que U^*AU es triangular superior con esa diagonal en ese orden. Esto se usa, por ejemplo, para poner primero el autovalor de mayor módulo.

Corolario 5.10 (Traza, determinante, potencias y polinomios). Sea $A \in \mathbb{C}^{n\times n}$ con autovalores $\lambda_1, \dots, \lambda_n$ contados con multiplicidad algebraica. Entonces

$$\operatorname{tr}(A) = \lambda_1 + \cdots + \lambda_n, \qquad \det(A) = \lambda_1 \lambda_2 \cdots \lambda_n.$$

Más aún, para todo $m \in \mathbb{N}$ los autovalores de A^m son $\lambda_1^m, \dots, \lambda_n^m$, y para todo polinomio p los autovalores de $p(A)$ son $p(\lambda_1), \dots, p(\lambda_n)$, en todos los casos contados con multiplicidad. Si A es invertible, los autovalores de A^{-1} son $\lambda_1^{-1}, \dots, \lambda_n^{-1}$.

Demostración. Escribamos $A = UTU^*$ con U unitaria y T triangular superior cuya diagonal es $\lambda_1, \dots, \lambda_n$ (Teorema 5.6). Como $\operatorname{tr}(XY) = \operatorname{tr}(YX)$,

$$\operatorname{tr}(A) = \operatorname{tr}(UTU^*) = \operatorname{tr}(TU^*U) = \operatorname{tr}(T) = \lambda_1 + \cdots + \lambda_n,$$

y como el determinante es multiplicativo y $\det(U^*) = \det(U)^{-1}$,

$$\det(A) = \det(U)\det(T)\det(U^*) = \det(T) = \lambda_1 \cdots \lambda_n,$$

porque el determinante de una matriz triangular es el producto de su diagonal.

Para las potencias, $A^m = UT^mU^*$, y el producto de matrices triangulares superiores es triangular superior con la diagonal multiplicada entrada a entrada: la diagonal de T^m es $\lambda_1^m, \dots, \lambda_n^m$. Como A^m es semejante a T^m, esos son sus autovalores. El mismo argumento, aplicado a $p(T)$, da el caso de un polinomio; y si A es invertible, ningún λ_i es cero, T es invertible y la diagonal de T^{-1} es λ_i^{-1}. ∎

Una consecuencia pequeña pero que vamos a usar varias veces cierra una deuda del Capítulo 3.

Corolario 5.11 (La traza de una proyección es su rango). Sea $P \in \mathbb{R}^{n\times n}$ con $P^2 = P$ (una proyección, ortogonal o no). Entonces los autovalores de P son 0 y 1, y

$$\operatorname{rg}(P) = \operatorname{tr}(P)$$

Demostración. Si $Px = \lambda x$ con $x \neq 0$, entonces $\lambda x = Px = P^2x = \lambda Px = \lambda^2 x$, de donde $\lambda^2 = \lambda$ y $\lambda \in \{0, 1\}$. El espacio propio de $\lambda = 1$ es $C(P)$: si $Px = x$ entonces $x \in C(P)$, y recíprocamente si $x = Py$ entonces $Px = P^2y = Py = x$. El de $\lambda = 0$ es $N(P)$. Como $\mathbb{R}^n = C(P) \oplus N(P)$ —todo x se escribe $x = Px + (x - Px)$ y la intersección es nula—, la suma de las dimensiones de los dos espacios propios es n: P es diagonalizable y sus autovalores son 1 repetido $\operatorname{rg}(P)$ veces y 0 repetido $n - \operatorname{rg}(P)$ veces. Por el Corolario 5.10, $\operatorname{tr}(P)$ es la suma de esos autovalores, es decir $\operatorname{rg}(P)$. ∎

Observación 5.12. Estas fórmulas se anunciaron en el Capítulo 4 sin demostración. Vale la pena notar lo que aportó Schur: allí sabíamos que *cada* λ_i^m era un autovalor de A^m, pero no que fueran *todos* ni con qué multiplicidad. Triangular de una sola vez resuelve las dos cosas.

Observación 5.13 (Qué dice y qué no dice Schur)**.** Schur vale para *toda* matriz compleja, sin ninguna hipótesis: siempre hay una base ortonormal en la que A es triangular. Lo que *no* dice es que esa base sea de autovectores: solo la primera columna de U lo es. La pregunta natural es entonces *cuándo* se puede llegar hasta una matriz diagonal. La respuesta es el Teorema 5.17.

Ejemplo 5.14 (Una descomposición de Schur a mano)**.** Sea

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}.$$

Sus autovalores son 1 y 2 (es triangular). Tomemos el autovalor 2 para que la primera columna de U sea un autovector suyo: de $(A - 2I)\boldsymbol{v} = \mathbf{0}$ sale $\boldsymbol{v} = (1, 1)^T$, que normalizado es $\boldsymbol{q}_1 = \frac{1}{\sqrt{2}}(1, 1)^T$. Completamos con $\boldsymbol{q}_2 = \frac{1}{\sqrt{2}}(1, -1)^T$, ortogonal al anterior, y formamos

$$U = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \qquad \Longrightarrow \qquad T = U^* A U = \begin{bmatrix} 2 & -1 \\ 0 & 1 \end{bmatrix}.$$

Se ve lo que anuncia la observación anterior: la diagonal de T tiene los autovalores en el orden elegido, la primera columna de U es un autovector, y la segunda *no* lo es — si lo fuera, T sería diagonal. Y no puede serlo: A no es normal ($AA^T \neq A^T A$), aunque sí es diagonalizable, con autovectores $(1, 0)^T$ y $(1, 1)^T$ que son independientes pero no ortogonales. □

5.3 Matrices normales

Definición (matriz normal). Una matriz $A \in \mathbb{C}^{n \times n}$ es *normal* si

$$AA^* = A^* A,$$

donde $A^* = \overline{A}^T$ denota la adjunta (conjugada traspuesta) de A.

> **Lema 5.15** (Triangular normal ⇒ diagonal)**.** Si $T \in \mathbb{C}^{n \times n}$ es triangular superior y normal, entonces T es diagonal.

Demostración por inducción en n. Caso base $n = 1$. Trivial.

Paso inductivo. Supongamos el enunciado cierto para matrices $(n-1) \times (n-1)$. Sea $T \in \mathbb{C}^{n \times n}$ triangular superior y normal. Escribimos T en bloques

$$T = \begin{bmatrix} \lambda & w^* \\ 0 & S \end{bmatrix}, \qquad T^* = \begin{bmatrix} \overline{\lambda} & 0 \\ w & S^* \end{bmatrix},$$

donde $\lambda \in \mathbb{C}$, $w \in \mathbb{C}^{n-1}$ y $S \in \mathbb{C}^{(n-1)\times(n-1)}$ es triangular superior. Calculamos

$$T^* T = \begin{bmatrix} |\lambda|^2 & \overline{\lambda}\, w^* \\ \lambda\, w & w w^* + S^* S \end{bmatrix}, \qquad T T^* = \begin{bmatrix} |\lambda|^2 + \|w\|_2^2 & w^* S^* \\ S w & S S^* \end{bmatrix}.$$

Como T es normal, $T^*T = TT^*$. Comparando el bloque $(1,1)$ se obtiene $|\lambda|^2 = |\lambda|^2 + \|w\|_2^2$, luego $\|w\|_2^2 = 0$ y por tanto $w = 0$. Con $w = 0$, la igualdad de los bloques $(2,2)$ da $S^*S = SS^*$, o sea, S es normal. Como además S es triangular superior, por hipótesis inductiva S es diagonal. De $w = 0$ se sigue que

$$T = \begin{bmatrix} \lambda & 0 \\ 0 & S \end{bmatrix}$$

es diagonal. Esto completa la inducción. ∎

Lema 5.16 (Propiedades básicas de una normal). Sea $A \in \mathbb{C}^{n\times n}$ normal. Entonces:

(i) $\|Av\| = \|A^*v\|$ para todo $v \in \mathbb{C}^n$.

(ii) $Av = \lambda v \iff A^*v = \overline{\lambda}\, v$. Es decir, A y A^* tienen los mismos autovectores, con autovalores conjugados.

(iii) Autovectores asociados a autovalores *distintos* son ortogonales.

Demostración. (i) $\|Av\|^2 = v^*A^*Av = v^*AA^*v = \|A^*v\|^2$.

(ii) Si A es normal, también lo es $A - \lambda I$, porque $(A-\lambda I)(A-\lambda I)^* = AA^* - \lambda A^* - \overline{\lambda}A + |\lambda|^2 I$ coincide con $(A-\lambda I)^*(A-\lambda I)$ usando $AA^* = A^*A$. Aplicando (i) a $A - \lambda I$:

$$\|(A-\lambda I)v\| = \|(A-\lambda I)^*v\| = \|(A^* - \overline{\lambda} I)v\|,$$

y un lado se anula si y solo si se anula el otro.

(iii) Sean $Av = \lambda v$ y $Aw = \mu w$ con $\lambda \neq \mu$. Por (ii), $A^*w = \overline{\mu}\, w$. Entonces

$$\lambda\,(w^*v) = w^*(Av) = (A^*w)^*v = (\overline{\mu}\, w)^*v = \mu\,(w^*v),$$

luego $(\lambda - \mu)\, w^*v = 0$ y, como $\lambda \neq \mu$, resulta $w^*v = 0$. ∎

Teorema 5.17 (Caracterización vía Schur). Sea $A \in \mathbb{C}^{n\times n}$. Son equivalentes:

1. A es normal, es decir, $AA^* = A^*A$.
2. A admite una base *ortonormal* de autovectores; equivalentemente, existen U unitaria y D diagonal tales que $A = UDU^*$ (A *es unitariamente diagonalizable*).

Demostración. (2) $\Rightarrow$ (1): Si $A = UDU^*$ con U unitaria y D diagonal, entonces $A^* = (UDU^*)^* = UD^*U^*$, y como D es diagonal $D^* = \overline{D}$ (la diagonal conjugada). Por lo tanto

$$AA^* = UDU^*\,U\overline{D}U^* = U(D\overline{D})U^* = U(\overline{D}D)U^* = U\overline{D}U^*\,UDU^* = A^*A,$$

porque dos matrices diagonales siempre conmutan.

(1) $\Rightarrow$ (2): Tomamos la descomposición de Schur $A = UTU^*$ con T triangular superior (Teorema 5.6). Entonces

$$AA^* = UTU^*\,UT^*U^* = U(TT^*)U^*, \qquad A^*A = U(T^*T)U^*.$$

Como U es invertible, la igualdad $AA^* = A^*A$ equivale a $TT^* = T^*T$, o sea, T es normal. Por el Lema 5.15, T es diagonal. Luego $A = UDU^*$ con $D = T$ diagonal, y las columnas de U forman una base ortonormal de autovectores de A. ∎

Corolario 5.18 (Descomposición espectral)**.** Si A es normal, con $U = [q_1 \ \cdots \ q_n]$ y $D = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ como arriba, entonces

$$A = \sum_{k=1}^{n} \lambda_k \, q_k q_k^*, \qquad \text{y además} \qquad I = \sum_{k=1}^{n} q_k q_k^*.$$

Cada $q_k q_k^*$ es el proyector ortogonal sobre la recta generada por q_k: la matriz A queda descompuesta como una suma de proyecciones ortogonales *pesadas por los autovalores*. En consecuencia, para todo $m \in \mathbb{N}$,

$$A^m = \sum_{k=1}^{n} \lambda_k^m \, q_k q_k^*,$$

y más generalmente $p(A) = \sum_k p(\lambda_k)\, q_k q_k^*$ para cualquier polinomio p.

Demostración. $A = UDU^*$ y el producto UDU^*, escrito por columnas, es $\sum_k \lambda_k q_k q_k^*$; con $D = I$ se obtiene la segunda identidad. Para las potencias, $A^m = UD^mU^*$ pues $U^*U = I$. ∎

Observación 5.19 (Lectura para datos)**.** El Corolario 5.18 es el motivo por el cual los autovalores "mandan" en las aplicaciones: aplicar A repetidas veces amplifica las direcciones q_k con $|\lambda_k|$ grande y aplasta las de $|\lambda_k|$ chico. De ahí salen el método de la potencia, la convergencia de cadenas de Markov, los filtros de señales y la aproximación de rango bajo.

Ejercicio de desarrollo 5.1 | Matrices que conmutan y diagonalización simultánea

El teorema espectral diagonaliza una matriz normal. Este ejercicio responde una pregunta natural: ¿cuándo se pueden diagonalizar *dos* matrices con la *misma* base?

(a) Sean $A, B \in \mathbb{C}^{n\times n}$ con $AB = BA$. Probar que cada autoespacio de A es invariante por B: si $Av = \lambda v$, entonces $A(Bv) = \lambda(Bv)$.

(b) Supongamos ahora que A y B son *normales* y conmutan. Usando (a) y el Teorema 5.17 aplicado a la restricción de B a cada autoespacio de A, construir una base ortonormal de $\mathbb{C}^n$ formada por autovectores *de las dos matrices a la vez*. Concluir que existe una única unitaria U con

$$U^*AU = D_1 \quad \text{y} \quad U^*BU = D_2$$

ambas diagonales. *Sugerencia:* hay que verificar que la restricción de B a un autoespacio de A sigue siendo normal.

(c) Probar el recíproco: si existe una unitaria que diagonaliza a las dos, entonces conmutan. *(Es la parte fácil: las diagonales conmutan.)*

(d) Verificar que dos matrices circulantes cualesquiera conmutan (Ejercicio 5 de este capítulo) y explicar, a la luz de (b) y (c), por qué *todas* las circulantes de tamaño n se diagonalizan con la misma matriz de Fourier F.

(e) Dar dos matrices normales que no conmuten y comprobar que no tienen ninguna base ortonormal de autovectores en común.

(f) *(Una consecuencia.)* Probar que si A es normal y p es un polinomio, entonces A y $p(A)$ conmutan, y deducir que se diagonalizan simultáneamente con los mismos autovectores y autovalores λ_k y $p(\lambda_k)$.

Se entrega por escrito. El ítem (b) es la razón profunda por la que en procesamiento de señales una sola transformada, la de Fourier, sirve para todos los filtros a la vez.

5.4 Los casos particulares importantes

Corolario 5.20 (Caso hermítico)**.** Si A es hermítica ($A^* = A$), entonces A es normal y, por el Teorema 5.17, existen U unitaria y Λ diagonal *real* tales que $A = U\Lambda U^*$. En particular, los autovalores de una matriz hermítica son *reales*.

Demostración. Si $A^* = A$, entonces $AA^* = A^2 = A^*A$: A es normal. La diagonalización unitaria sigue del Teorema 5.17. Que Λ sea real se deduce de $Av = \lambda v$ con $\|v\| = 1$:

$$\lambda = \lambda\|v\|^2 = v^*Av = v^*A^*v = \overline{v^*Av} = \overline{\lambda} \implies \lambda \in \mathbb{R}.$$

■

Corolario 5.21 (Antihermíticas y unitarias)**.** (i) Si $A^* = -A$ (antihermítica), sus autovalores son *imaginarios puros*.

(ii) Si $A^*A = I$ (unitaria), sus autovalores tienen *módulo* 1.

En ambos casos A es normal, luego unitariamente diagonalizable.

Demostración. (i) A es normal ($AA^* = -A^2 = A^*A$) y, si $Av = \lambda v$ con $\|v\| = 1$, $\lambda = v^*Av = -v^*A^*v = -\overline{\lambda}$, o sea $\operatorname{Re}\lambda = 0$.

(ii) A es normal pues $A^* = A^{-1}$ conmuta con A. Si $Av = \lambda v$ con $\|v\| = 1$, entonces $1 = \|v\|^2 = \|Av\|^2 = |\lambda|^2$. ■

Particularización al caso real. Si $A \in \mathbb{R}^{n\times n}$, la adjunta es la traspuesta y "normal" significa $AA^T = A^TA$. Hay que tener cuidado: *una matriz real normal puede no tener autovalores reales*, y en ese caso no hay diagonalización real (ver Ejemplo 5.23). El caso perfecto es el simétrico:

Teorema 5.22 (Teorema espectral real)**.** Si $A \in \mathbb{R}^{n\times n}$ es simétrica ($A^T = A$), existen Q *ortogonal* real ($Q^TQ = I$) y Λ diagonal real tales que

$$A = Q\Lambda Q^T = \sum_{k=1}^{n} \lambda_k\, q_k q_k^T.$$

Demostración. Vista como matriz compleja, A es hermítica, así que por el Corolario 5.20 todos sus autovalores λ son reales. Para cada uno, el sistema $(A - \lambda I)x = 0$ tiene coeficientes reales, luego admite una base de soluciones *reales*; aplicando Gram–Schmidt dentro de cada autoespacio obtenemos bases ortonormales reales. Por el Lema 5.16(iii),

autoespacios de autovalores distintos son ortogonales entre sí, y por el Teorema 5.17 la suma de sus dimensiones es n. Juntando todas esas bases se obtiene una base ortonormal real de autovectores, que forma las columnas de Q. ∎

Ejemplo 5.23 (Una rotación: normal real sin autovectores reales). Sea

$$R_\theta = \begin{bmatrix} \cos\theta & -\operatorname{sen}\theta \\ \operatorname{sen}\theta & \cos\theta \end{bmatrix}, \qquad 0 < \theta < \pi.$$

Es ortogonal, luego normal. Su polinomio característico es $z^2 - 2\cos\theta\, z + 1$, con raíces $e^{\pm i\theta}$: son de módulo 1 (como debe ser) pero *no reales*. Geométricamente es evidente: una rotación no deja ninguna recta de $\mathbb{R}^2$ fija. Sobre $\mathbb{C}^2$, en cambio, R_θ es unitariamente diagonalizable con autovectores $\frac{1}{\sqrt{2}}(1, \mp i)^T$.

Teorema 5.24 (Forma de Schur real). Si $A \in \mathbb{R}^{n\times n}$, existe Q ortogonal *real* tal que $Q^T A Q$ es triangular superior *por bloques*, con bloques diagonales de tamaño 1×1 (los autovalores reales) y 2×2 (uno por cada par de autovalores complejos conjugados, como en el Ejemplo 5.23). Es la forma que efectivamente calculan los algoritmos numéricos, porque se obtiene sin salir de la aritmética real.

La demostración es el ejercicio de desarrollo que sigue: es la misma inducción del Teorema 5.6, con el cuidado de no abandonar $\mathbb{R}$.

Ejercicio de desarrollo 5.2 | La forma de Schur real

Sea $A \in \mathbb{R}^{n\times n}$.

(a) Supongamos que A tiene un autovalor *real* λ. Probar que existe un autovector real asociado. *Sugerencia:* el sistema $(A - \lambda I)x = 0$ tiene coeficientes reales.

(b) Supongamos ahora $Av = \lambda v$ con $\lambda = \alpha + i\beta$, $\beta \neq 0$, y escribamos $v = p + iq$ con $p, q \in \mathbb{R}^n$. Separando parte real e imaginaria, probar que

$$Ap = \alpha p - \beta q, \qquad Aq = \beta p + \alpha q.$$

Deducir que $W = \operatorname{span}\{p, q\}$ es un subespacio *real* invariante por A.

(c) Probar que p y q son linealmente independientes, de modo que $\dim W = 2$. *Sugerencia:* si $q = cp$ entonces $v = (1 + ic)p$ sería un múltiplo complejo de un vector real, y entonces $Av = \lambda v$ obligaría a λ a ser real.

(d) Ortonormalizar $\{p, q\}$ con Gram–Schmidt para obtener q_1, q_2, verificar que la matriz de A restringida a W en esa base es de 2×2 y comprobar que sus autovalores son λ y $\overline{\lambda}$.

(e) Armar la inducción: completar q_1, q_2 a una base ortonormal de $\mathbb{R}^n$, escribir $Q_1^T A Q_1$ por bloques y aplicar la hipótesis inductiva al bloque de abajo a la derecha. Tratar por separado el caso de autovalor real, donde el bloque es 1×1.

(f) Hacer las cuentas explícitamente con

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & 1 & 0 \end{bmatrix},$$

identificando el bloque 1×1 y el bloque 2×2.

(g) Explicar por qué un algoritmo que trabaja en aritmética real no puede producir la forma triangular compleja del Teorema 5.6, y qué se gana a cambio con esta versión.

Se entrega por escrito. El ítem (b) es el mecanismo por el cual un par de autovalores complejos conjugados de una matriz real se manifiesta como una rotación *en un plano, que es lo que vimos en el Capítulo 4 al resolver* $\boldsymbol{u}' = A\boldsymbol{u}$.

Ejercicio de desarrollo 5.3 | Caracterizaciones de las matrices normales

Sea $A \in \mathbb{C}^{n\times n}$.

(a) Probar que A es normal si y sólo si $\|A\boldsymbol{x}\| = \|A^*\boldsymbol{x}\|$ para todo $\boldsymbol{x}$. *Sugerencia:* una implicación es el Lema 5.16(i); para la otra, desarrollar $\boldsymbol{x}^*(A^*A - AA^*)\boldsymbol{x} = 0$ y usar que una matriz hermítica con esa propiedad es nula (polarización).

(b) Deducir que si A es normal entonces $N(A) = N(A^*)$ y, tomando complementos ortogonales, $C(A) = C(A^*)$. Concluir que

$$\mathbb{C}^n = C(A) \oplus N(A)$$

es una descomposición *ortogonal*: para una matriz normal, los cuatro subespacios fundamentales del Capítulo 3 colapsan a dos.

(c) Dar una matriz con $N(A) = N(A^*)$ que no sea normal, para ver que (b) no se invierte.

(d) Probar que A es normal si y sólo si los autovalores de A^*A son exactamente $|\lambda_1|^2, \dots, |\lambda_n|^2$, donde los λ_i son los autovalores de A. *Sugerencia:* comparar trazas usando la desigualdad de Schur 5.25.

(e) *(Una caracterización sorprendente.)* Probar que si A es normal entonces existe un polinomio p con $A^* = p(A)$. *Sugerencia:* diagonalizar y buscar un polinomio que interpole $p(\lambda_k) = \overline{\lambda_k}$ en los autovalores distintos. Probar también el recíproco.

(f) Verificar (e) explícitamente para una matriz de permutación de 3×3 y para una simétrica real (¿cuál es p en ese caso?).

Se entrega por escrito. El ítem (b) es la razón por la que para matrices normales — y en particular simétricas — no hace falta distinguir entre el espacio fila y el espacio columna.

5.5 Una consecuencia cuantitativa: cuánto se “ve” en los autovalores

Teorema 5.25 (Desigualdad de Schur). Sea $A \in \mathbb{C}^{n\times n}$ con autovalores $\lambda_1, \dots, \lambda_n$ (con multiplicidad). Entonces

$$\sum_{k=1}^{n} |\lambda_k|^2 \;\le\; \|A\|_F^2 := \sum_{i,j} |a_{ij}|^2,$$

con igualdad *si y solo si* A es normal.

Demostración. La norma de Frobenius, definida en la Sección 1.3.6, satisface $\|A\|_F^2 = \operatorname{tr}(A^*A)$ y es invariante por multiplicación por unitarias: si $U^*U = I$,

$$\|UA\|_F^2 = \operatorname{tr}\left((UA)^*UA\right) = \operatorname{tr}(A^*U^*UA) = \operatorname{tr}(A^*A) = \|A\|_F^2,$$

y análogamente por la derecha usando $\operatorname{tr}(XY) = \operatorname{tr}(YX)$; en particular $\|UAV\|_F = \|A\|_F$. Si $A = UTU^*$ es la descomposición de Schur, entonces

$$\|A\|_F^2 = \|T\|_F^2 = \sum_k |\lambda_k|^2 + \sum_{i<j} |t_{ij}|^2 \;\ge\; \sum_k |\lambda_k|^2,$$

con igualdad si y solo si todos los t_{ij} con $i < j$ son nulos, es decir, si y solo si T es diagonal, lo que por el Teorema 5.17 equivale a que A sea normal. ∎

Observación 5.26. Para una matriz normal, entonces, “toda la energía” de A está en sus autovalores: $\|A\|_F^2 = \sum_k |\lambda_k|^2$. Esto es lo que permite medir el error de aproximar A quedándose solo con los autovalores más grandes, que es el contenido del Ejercicio de desarrollo 5.4. La diferencia $\|A\|_F^2 - \sum_k |\lambda_k|^2$ mide, en cambio, cuán lejos de normal está A.

Más ejemplos de matrices normales.

- **Unitarias:** $U^*U = I \Rightarrow UU^* = I$, luego $UU^* = U^*U$.
- **Ortogonales** (caso real de las unitarias); en particular, las **matrices de permutación**.
- **Hermíticas y simétricas reales.**
- **Skew-hermíticas (antihermíticas):** $A^* = -A \Rightarrow AA^* = -A^2 = A^*A$.
- **Diagonales** (y, por semejanza unitaria, todas las unitariamente diagonalizables): conmutan con su adjunta.
- **Bloque-diagonales:** $\operatorname{diag}(N_1, \dots, N_k)$ es normal si y solo si cada N_i es normal.
- **Polinomios de una normal:** si A es normal y p es un polinomio, entonces $p(A)$ es normal (de $A = UDU^*$ sale $p(A) = Up(D)U^*$).

Ejercicio de desarrollo 5.4 | Aproximación de rango bajo de una matriz simétrica

Sea $S \in \mathbb{R}^{n\times n}$ simétrica, con autovalores ordenados por módulo $|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n|$ y base ortonormal de autovectores $q_1, \ldots, q_n$, de modo que $S = \sum_k \lambda_k q_k q_k^T$ (Teorema 5.22). Para $1 \leq r < n$ definimos el *truncamiento*

$$S_r = \sum_{k=1}^{r} \lambda_k \, q_k q_k^T.$$

(a) Probar que S_r es simétrica, que $\operatorname{rg}(S_r) \leq r$, y que

$$\|S - S_r\|_F^2 = \lambda_{r+1}^2 + \cdots + \lambda_n^2.$$

(b) Probar que $\|S\|_F^2 = \sum_k \lambda_k^2$ (es la igualdad del Teorema 5.25 para matrices normales) y deducir que el error relativo de la aproximación es $\|S - S_r\|_F^2 / \|S\|_F^2 = \sum_{k>r} \lambda_k^2 \big/ \sum_k \lambda_k^2$.

(c) *(Optimalidad.)* Probar que S_r es la *mejor* aproximación: para toda matriz simétrica B con $\operatorname{rg}(B) \leq r$,

$$\|S - B\|_F \;\geq\; \|S - S_r\|_F.$$

Sugerencia: escribir todo en la base $q_1, \ldots, q_n$, es decir, reemplazar S y B por $Q^T S Q = \Lambda$ y $Q^T B Q$, lo cual no cambia ninguna de las dos normas de Frobenius ni el rango; después mirar la diagonal.

(d) Aplicarlo a la matriz de similitudes del Ejercicio 4 de este capítulo y comparar con el cálculo directo que se pide allí.

(e) ¿Qué pasa si se ordenan los autovalores por valor y no por módulo? Dar un ejemplo de 2×2 donde eso produzca una aproximación peor.

Se entrega por escrito. El ítem (c) es la primera versión que vemos de un teorema de optimalidad: truncar no sólo da una *aproximación de rango bajo, da la mejor que existe.*

Observación 5.27 (Hacia dónde va esto). El ejercicio anterior es un anticipo de dos resultados que se tratan más adelante y que conviene no mezclar con lo de acá.

El primero es la **versión general**. Lo que probamos vale para matrices simétricas, que son las que tienen base ortonormal de autovectores. Para una matriz cualquiera — incluso rectangular — el enunciado análogo es el *teorema de Eckart-Young*, donde los autovalores se reemplazan por los valores singulares y el truncamiento S_r por el de la descomposición en valores singulares. La demostración sigue las mismas líneas. Los valores singulares aparecen en el Capítulo 8.

El segundo es la **lectura estadística**. Si las filas de una matriz X son observaciones de varias variables y uno le resta a cada columna su media, la matriz $X^T X$ es simétrica y semidefinida positiva, y sus autovectores resultan ser las direcciones en las que los datos más se dispersan. Truncar como en este ejercicio es entonces quedarse con esas pocas direcciones y describir la nube de puntos con menos coordenadas de las que tenía. Esa técnica se llama *análisis de componentes principales*, y tiene capítulo propio después de la

SVD; recién ahí estaremos en condiciones de decir en qué sentido preciso esas direcciones son las mejores.

5.6 Normal, diagonalizable, defectiva

Conviene ordenar las tres nociones que estuvimos manejando, porque es fácil confundirlas. Para $A \in \mathbb{C}^{n\times n}$:

	qué existe	**caracterización**
siempre	base ortonormal con A *triangular*	Teorema 5.6
diagonalizable	base de autovectores *independientes*	mult. geom. = mult. alg.
normal	base *ortonormal* de autovectores	$AA^* = A^*A$ (Teorema 5.17)

Las tres filas son cada vez más exigentes, y ninguna de las dos implicaciones se invierte. Que ser diagonalizable no alcance para ser normal se ve en el Ejemplo 5.14: la matriz $\left[\begin{smallmatrix} 1 & 1 \\ 0 & 2 \end{smallmatrix}\right]$ tiene autovalores distintos, luego es diagonalizable por el criterio del Capítulo 4, pero no es normal y sus autovectores $(1,0)^T$ y $(1,1)^T$ son independientes pero no ortogonales. Y que Schur no alcance para ser diagonalizable se ve en el bloque de Jordan $\left[\begin{smallmatrix} \lambda & 1 \\ 0 & \lambda \end{smallmatrix}\right]$, que es *defectiva*: tiene un solo autovector independiente. Schur, en cambio, no falla nunca; en ese caso lo mejor que se puede conseguir es, justamente, triangular.

Observación 5.28 (Lo que viene). El Corolario 5.18 escribe una matriz normal como $A = \sum_k \lambda_k\, q_k q_k^*$: una suma de proyecciones ortogonales pesadas por los autovalores, con los q_k ortonormales. En el Capítulo 8 veremos que *toda* matriz, incluso rectangular, admite una descomposición del mismo aspecto,

$$A = \sum_{k=1}^{r} \sigma_k\, u_k v_k^T,$$

con dos familias ortonormales en lugar de una y con los $\sigma_k > 0$. El precio de renunciar a la normalidad — y hasta a que la matriz sea cuadrada — es tener que usar dos bases distintas en lugar de una. La herramienta para construirla es el Teorema 5.22 aplicado a la matriz simétrica A^TA.

5.7 Ejercicios

1. **Matrices de covarianza, traza y ortogonalidad**
   En Ciencia de Datos es común trabajar con la matriz de covarianza (sin normalizar) $S = X^TX$, donde $X \in \mathbb{R}^{n\times p}$ es una matriz de datos.

   a) Demostrá que S es simétrica y, en consecuencia, normal.

   b) Usando el Teorema 5.22, justificá por qué S admite una matriz de autovectores Q con $Q^{-1} = Q^T$ (matriz ortogonal), y por qué sus autovalores son reales.

   c) Sabiendo que la traza de una matriz es igual a la suma de sus autovalores, demostrá que la suma de los autovalores de S es igual a la suma de las normas al cuadrado de las columnas de X.

d) Probá que $\lambda_k = \|Xq_k\|^2 \geq 0$ para todo k, donde q_k es el k-ésimo autovector unitario de S. Interpretá: ¿qué mide λ_k sobre los datos proyectados en la dirección q_k?

2. **Proyecciones ortogonales y normalidad**
Sea $Q \in \mathbb{R}^{n\times k}$ una matriz alta y delgada con columnas ortonormales, es decir, $Q^TQ = I_k$. Definimos $P = QQ^T$.

a) Demostrá que P es normal.

b) Verificá analíticamente que $P^2 = P$.

c) Usando la definición de autovalor ($Pv = \lambda v$, $v \neq 0$) y la propiedad anterior, demostrá que los únicos autovalores posibles de P son $\lambda = 0$ y $\lambda = 1$.

d) ¿Es P diagonalizable ortogonalmente? Justificá con el Teorema 5.17.

e) Deducí, usando la traza, que la multiplicidad del autovalor 1 es exactamente k. ¿Cuál es el autoespacio asociado a $\lambda = 1$? ¿Y a $\lambda = 0$?

3. **Matrices de adyacencia y análisis de redes**
Un grafo no dirigido se representa por su matriz de adyacencia $W \in \mathbb{R}^{n\times n}$, con $W_{ij} = W_{ji} \geq 0$ el peso de la conexión entre los nodos i y j.

a) Justificá que W es simétrica real, luego normal, y que por lo tanto sus autovalores son reales.

b) Sea D diagonal con $D_{ii} = \sum_{j=1}^{n} W_{ij}$ (el grado del nodo i). Definimos la *matriz Laplaciana* $L = D - W$. Demostrá que L es normal.

c) Demostrá que el vector de unos $\mathbf{1} = (1, \ldots, 1)^T$ es siempre autovector de L. ¿Cuál es el autovalor asociado?

d) Probá la *identidad de Dirichlet*: para todo $x \in \mathbb{R}^n$,

$$x^TLx = \tfrac{1}{2}\sum_{i,j=1}^{n} W_{ij}\,(x_i - x_j)^2 \;\geq\; 0.$$

Deducí que todos los autovalores de L son ≥ 0.

e) Supongamos que el grafo tiene dos componentes conexas C_1 y C_2. Exhibí dos autovectores linealmente independientes de L con autovalor 0 (sugerencia: vectores indicadores de C_1 y C_2, y usá (d) para ver que $Lx = 0 \iff x$ es constante en cada componente). ¿Qué sugiere esto como algoritmo para *detectar* comunidades en una red?

4. **Descomposición espectral y aproximación de rango bajo**
Sea

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix},$$

la matriz de similitudes entre tres documentos.

a) Escribí $A = I + \mathbf{1}\mathbf{1}^T$ y hallá, sin calcular el polinomio característico, todos los autovalores de A y una base ortonormal de autovectores. (Sugerencia: ¿qué le hace $\mathbf{1}\mathbf{1}^T$ a $\mathbf{1}$? ¿y a un vector ortogonal a $\mathbf{1}$?)

b) Escribí explícitamente la descomposición espectral $A = \sum_{k=1}^{3} \lambda_k q_k q_k^T$ del Corolario 5.18.

c) Sea $A_1 = \lambda_1 q_1 q_1^T$ con λ_1 el autovalor de mayor módulo. Calculá la matriz $A - A_1$ y verificá que $\|A - A_1\|_F = \sqrt{\lambda_2^2 + \lambda_3^2}$, como predice el Teorema 5.25.

d) Interpretá q_1: ¿qué característica de los tres documentos captura esa dirección? ¿Y qué información se pierde al quedarse solo con A_1?

e) Calculá A^m para todo m usando el Corolario 5.18, y mostrá que $\dfrac{A^m}{\lambda_1^m} \longrightarrow q_1 q_1^T$ cuando $m \to \infty$. (Esta es la idea del *método de la potencia*.)

5. **Filtros, matrices circulantes y Fourier**
Sea $P \in \mathbb{R}^{n\times n}$ la permutación cíclica definida por $Pe_j = e_{j+1}$ para $j = 1, \dots, n$ (con $e_{n+1} := e_1$); en coordenadas, $(Px)_i = x_{i-1}$ (con $x_0 := x_n$). Una *matriz circulante* es

$$C = c_0 I + c_1 P + c_2 P^2 + \cdots + c_{n-1} P^{n-1}, \qquad c_j \in \mathbb{R}.$$

a) Probá que P es ortogonal ($P^T P = I$) y deducí que es normal. ¿Es simétrica? ¿Cuánto vale P^n?

b) Deducí que C es normal para cualquier elección de los c_j.

c) Sea $\omega = e^{2\pi i/n}$ y $f_k = \frac{1}{\sqrt{n}}\left(1, \omega^k, \omega^{2k}, \dots, \omega^{(n-1)k}\right)^T$, $k = 0, \dots, n-1$. Verificá que $P f_k = \omega^{-k} f_k$ y que $\{f_0, \dots, f_{n-1}\}$ es una base ortonormal de $\mathbb{C}^n$ (la matriz $F = [f_0 \ \cdots \ f_{n-1}]$ es la *matriz de Fourier*, unitaria).

d) Concluí que *todas* las circulantes de tamaño n se diagonalizan con la *misma* unitaria F, con autovalores

$$\lambda_k = \sum_{j=0}^{n-1} c_j \, \omega^{-jk},$$

es decir, la transformada discreta de Fourier del vector de coeficientes c.

e) Deducí que dos matrices circulantes cualesquiera *conmutan*, y que el producto de circulantes es circulante. (En el lenguaje de señales: convolucionar es multiplicar coordenada a coordenada en el dominio de Fourier.)

f) **Suavizado.** Considerá el filtro de *media móvil* de tres términos: $c_0 = c_1 = c_{n-1} = \frac{1}{3}$ y el resto nulo, de modo que $(Cx)_i = \frac{1}{3}(x_{i-1} + x_i + x_{i+1})$. Mostrá que

$$\lambda_k = \tfrac{1}{3}\left(1 + 2\cos\tfrac{2\pi k}{n}\right).$$

Interpretá: ¿qué le pasa a la componente de frecuencia baja ($k = 0$)? ¿Y a la de frecuencia alta ($k \approx n/2$)?

g) Usando el Corolario 5.18, describí qué le pasa a una señal x al aplicarle el filtro m veces, es decir, calculá $C^m x$ en términos de los coeficientes de Fourier de x. ¿Hacia qué señal converge $C^m x$ cuando $m \to \infty$?

6. **Falso o verdadero** (justificar o dar contraejemplo)

a) Si A es normal y λ es autovalor de A, entonces $\overline{\lambda}$ es autovalor de A.

b) Si A y B son normales, $A + B$ es normal.

c) Si A es normal e invertible, A^{-1} es normal.

d) Si A es real y normal, entonces A es simétrica.

e) Si A es triangular superior y todos sus autovalores son reales, entonces A es diagonalizable.

f) Si $\|A\|_F^2 = \sum_k |\lambda_k|^2$, entonces A admite una base ortonormal de autovectores.

6 CAPÍTULO

Matrices simétricas y definidas positivas

Este capítulo agrega una única condición a las matrices simétricas y recoge una cantidad sorprendente de consecuencias. La condición es

$$x^T S x > 0 \qquad \text{para todo } x \neq 0,$$

y las matrices que la cumplen se llaman *definidas positivas*. Es la versión matricial de "$s > 0$" para un número: así como un número positivo tiene raíz cuadrada real, así como sx^2 es una parábola con un mínimo estricto en el origen y así como dividir por s nunca se traba, veremos que una matriz sdp tiene raíz cuadrada, que $x^T S x$ tiene un mínimo estricto en el origen y que la eliminación gaussiana nunca necesita permutar filas.

El capítulo es, en buena medida, una cosecha de lo que ya construimos. Del Capítulo 2 usaremos los pivotes, la factorización LDL^T y los pivotes como cocientes de menores; del Capítulo 5, el teorema espectral $S = Q\Lambda Q^T$. El resultado central del capítulo dice que cinco condiciones que provienen de esos lugares distintos — una sobre la forma cuadrática, una sobre los autovalores, una sobre la forma $A^T A$, una sobre los determinantes y una sobre los pivotes — son todas la misma condición. Tener cinco caras de un mismo objeto es lo que vuelve a estas matrices tan cómodas: uno elige la cara que más convenga según lo que tenga a mano.

No es un capítulo sólo teórico. Las matrices de covarianza son sdp (o al menos semidefinidas) porque la varianza de cualquier combinación lineal de variables no puede ser negativa; las matrices de Gram y las matrices *kernel* lo son por construcción; y en optimización las matrices sdp son exactamente las que separan los problemas convexos, con mínimo global único, de los que tienen mínimos locales y puntos de ensilladura. Volveremos a encontrarlas en los capítulos de normas, de SVD y en el de mínimos cuadrados.

6.1 Matrices simétricas y definidas positivas (sdp)

En los capítulos anteriores hemos trabajado extensamente con matrices simétricas y ya establecimos para ellas varias propiedades fundamentales. Recordemos, en primer lugar, que toda matriz simétrica tiene todos sus autovalores reales y que sus autovectores correspondientes a autovalores distintos son ortogonales entre sí. Más aún, el teorema espectral (Teorema 5.22) nos permite afirmar que cualquier matriz simétrica S admite una descomposición $S = Q\Lambda Q^T$, donde Q es ortogonal — sus columnas son una base ortonormal de autovectores — y Λ es diagonal con los autovalores reales en la diagonal.

En el presente capítulo añadiremos una condición extra sobre estas matrices simétricas. Esta condición resultará ser equivalente a que los autovalores en la matriz diagonal Λ sean todos positivos, y nos permitirá probar otras caracterizaciones equivalentes de gran utilidad.

Definición 6.1. Se dice que una matriz $A \in \mathbb{R}^{n\times n}$ es simétrica y definida positiva, o brevemente **sdp**, si

$$A^T = A \qquad \text{y} \qquad x^T Ax > 0, \quad \forall x \in \mathbb{R}^n \setminus \{0\}.$$

Se dice *semidefinida positiva* si $A^T = A$ y $x^T Ax \geq 0$ para todo $x \in \mathbb{R}^n$.

La cantidad $x^T Ax$ se llama a veces la **energía** de x. Conviene tenerla escrita como suma: si $A = (a_{ij})$,

$$x^T Ax = \sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}x_i x_j,$$

un polinomio homogéneo de grado 2 en las variables $x_1, \ldots, x_n$, que se llama la **forma cuadrática** asociada a A. Por ejemplo, para $A = \left[\begin{smallmatrix} 2 & 1 \\ 1 & 3 \end{smallmatrix}\right]$ resulta $x^T Ax = 2x_1^2 + 2x_1x_2 + 3x_2^2$.

Observación 6.2. Vale la pena observar lo siguiente:

(1) $x^T Ax = (Ax)\cdot x$. Luego, si A es sdp el coseno del ángulo entre Ax y x es > 0, por lo que el ángulo entre x y Ax es agudo. Si pensamos en la transformación $x \mapsto Ax$, vemos que transforma x en otro vector Ax que apunta en una dirección *parecida* a x: ninguna matriz sdp da vuelta un vector.

(2) Si A es sdp, entonces A es invertible. En efecto, $Ax = 0$ implica $x^T Ax = 0$, lo que implica $x = 0$; la única solución del problema homogéneo $Ax = 0$ es la trivial.

(3) Si A es sdp, $a_{ii} = e_i^T Ae_i > 0$ para $i = 1, \ldots, n$: todos los elementos de la diagonal son positivos. (El recíproco es falso: en $\left[\begin{smallmatrix} 1 & 10 \\ 10 & 1 \end{smallmatrix}\right]$ la diagonal es positiva y $x = (1, -1)^T$ da energía -18.)

(4) Si $R \in \mathbb{R}^{m\times n}$, entonces $R^T R$ es simétrica y semidefinida positiva, pues $x^T R^T Rx = (Rx)^T(Rx) = \|Rx\|^2 \geq 0$ para todo $x \in \mathbb{R}^n$. Si además las n columnas de R son linealmente independientes, entonces $R^T R$ es sdp (será necesario que $n \leq m$).

(5) Si A y B son sdp y $t > 0$, entonces $A + B$ y tA son sdp: el conjunto de las matrices sdp es un *cono convexo*. En cambio no es un subespacio, porque $-A$ nunca es sdp.

(6) Sabemos que toda matriz se puede escribir como suma de una simétrica más una antisimétrica:

$$A = \underbrace{\frac{A + A^T}{2}}_{\text{parte simétrica de } A} + \underbrace{\frac{A - A^T}{2}}_{\text{parte antisimétrica de } A}.$$

Como $x^T Ax \in \mathbb{R}$, resulta $x^T Ax = (x^T Ax)^T = x^T A^T x$, y por lo tanto,

$$x^T\left(\frac{A - A^T}{2}\right)x = -x^T\left(\frac{A - A^T}{2}\right)x \quad \Longrightarrow \quad x^T\left(\frac{A - A^T}{2}\right)x = 0.$$

En consecuencia

$$x^T Ax = x^T\left(\frac{A + A^T}{2}\right)x + x^T\left(\frac{A - A^T}{2}\right)x = x^T\left(\frac{A + A^T}{2}\right)x.$$

Por lo tanto, si una matriz A cumple $x^T Ax > 0$ para todo $x \in \mathbb{R}^n \setminus \{0\}$, luego su *parte simétrica* $\frac{A+A^T}{2}$ es sdp. Pedir simetría en la definición no es una restricción: la parte antisimétrica no se ve en la energía.

6.1.1 Tres ejemplos para tener a mano

Antes de probar nada conviene tener delante unas pocas matrices concretas. Las tres que siguen van a reaparecer en todo el capítulo, y entre las tres cubren los tres casos posibles: definida positiva, semidefinida, y simétrica pero ninguna de las dos cosas.

Ejemplo 6.3 (La matriz de las diferencias segundas). Sea

$$K = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}.$$

Es la matriz que aparece al discretizar una derivada segunda, y es probablemente la matriz sdp más frecuente de toda la matemática aplicada. Que es sdp se ve *sin usar ningún teorema*, agrupando la energía en cuadrados:

$$x^T K x = 2x_1^2 + 2x_2^2 + 2x_3^2 - 2x_1x_2 - 2x_2x_3 = x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2.$$

Es una suma de cuadrados, así que $x^T K x \geq 0$ siempre; y si vale 0, los cuatro cuadrados son nulos, lo que fuerza $x_1 = 0$, $x_1 = x_2$, $x_2 = x_3$, es decir $x = 0$. Luego K es sdp.

Los cuatro cuadrados no aparecieron por casualidad. Son las cuatro coordenadas de Ax, con

$$A = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & -1 \end{bmatrix} \in \mathbb{R}^{4\times 3}, \qquad \text{y en efecto} \qquad A^T A = K.$$

O sea que $x^T K x = \|Ax\|^2$: la matriz K *viene* escrita como $A^T A$, que es el ítem **(c)** del teorema que vamos a probar. La matriz A toma diferencias de coordenadas consecutivas, y por eso a K se la llama matriz de diferencias segundas.

Ejemplo 6.4 (La versión periódica: semidefinida). Cambiemos las diferencias "con bordes" por diferencias *cíclicas*: en lugar de comparar x_1 con 0 y x_3 con 0, comparemos x_3 con x_1. La matriz es

$$C = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}, \qquad x^T C x = (x_1 - x_2)^2 + (x_2 - x_3)^2 + (x_3 - x_1)^2.$$

Otra vez una suma de cuadrados, así que $x^T C x \geq 0$: C es semidefinida positiva. Pero ahora la energía *sí* se anula sin que x sea cero: si $x_1 = x_2 = x_3$ los tres cuadrados son nulos. Es decir, $x^T C x = 0$ para todo x múltiplo de $(1,1,1)^T$, de modo que C no es definida positiva. De hecho $C(1,1,1)^T = 0$: la matriz es singular, y sus autovalores son 0, 3 y 3.

La diferencia entre K y C es exactamente la diferencia entre "definida" y "semidefinida", y está en una sola cosa: si la suma de cuadrados puede anularse sin que se anule x. Vale la pena quedarse con el ejemplo, porque es el que explica de dónde salen las matrices semidefinidas: aparecen cuando el problema tiene una *simetría* —acá, sumarle una constante a todas las coordenadas no cambia nada— y esa simetría se ve como un vector en el núcleo.

Ejemplo 6.5 (Ser sdp no tiene nada que ver con tener entradas positivas)**.** Es el error más común. Comparemos

$$P = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \qquad \text{y} \qquad K_2 = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

Todas las entradas de P son positivas, y sin embargo P *no* es sdp: con $x = (1,-1)^T$ queda $x^T P x = 1 - 4 + 1 = -2 < 0$. En cambio K_2 tiene entradas negativas y sí es sdp: $x^T K_2 x = x_1^2 + (x_1 - x_2)^2 + x_2^2 > 0$ salvo en el origen.

No hay ninguna contradicción: la energía $x^T S x$ mezcla las entradas con los signos de las coordenadas de x, y por eso lo que importa no es el signo de cada a_{ij} sino el *balance* entre la diagonal y lo que está fuera de ella. Lo único cierto en esa dirección es lo que ya vimos en la Observación 6.2(3): si S es sdp, su diagonal es positiva. El recíproco es falso, y P es el contraejemplo.

Observación 6.6 (Dónde aparecen de verdad)**.** Las tres de arriba son de juguete en el tamaño pero no en la forma. La que aparece en los datos es la **matriz de covarianza**: si X es una tabla de datos con las columnas centradas, $S = \frac{1}{n-1} X^T X$ es semidefinida positiva por la Observación 6.2(4), y es definida positiva en cuanto las columnas de X sean linealmente independientes. Es el objeto central del Capítulo 9, y toda la geometría de este capítulo —la raíz cuadrada, las elipses, la distancia asociada a S— se va a aplicar ahí sin cambiar una coma.

6.1.2 El complemento de Schur de una matriz sdp

Antes del teorema principal probamos un lema que usaremos dos veces: una para los pivotes y otra para Cholesky. Recordemos de la Sección 2.7 que si escribimos A por bloques

$$A = \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix}, \qquad \alpha \in \mathbb{R}, \quad a \in \mathbb{R}^{n-1}, \quad A_* \in \mathbb{R}^{(n-1)\times(n-1)}, \tag{6.1}$$

y $\alpha \neq 0$, entonces un paso de eliminación gaussiana deja

$$\begin{bmatrix} \alpha & a^T \\ 0 & A_* - \frac{1}{\alpha} a a^T \end{bmatrix},$$

y la matriz $A_* - \frac{1}{\alpha} a a^T$ es el **complemento de Schur** de α en A. El lema dice que la condición sdp se hereda al complemento de Schur; es decir, *la eliminación gaussiana preserva la positividad*.

Lema 6.7. Sea $A \in \mathbb{R}^{n\times n}$ sdp, escrita por bloques como en (6.1). Entonces

(a) $\alpha > 0$ y A_* es sdp;

(b) el complemento de Schur $A_* - \frac{1}{\alpha} a a^T$ es sdp.

Demostración. (a) Ya vimos que $\alpha = a_{11} = e_1^T A e_1 > 0$. Y si $y \in \mathbb{R}^{n-1}$ es no nulo, tomando $x = \begin{pmatrix} 0 \\ y \end{pmatrix} \neq 0$ resulta $y^T A_* y = x^T A x > 0$; además A_* es simétrica por serlo A.

(b) Sea $y \in \mathbb{R}^{n-1}$, $y \neq 0$. La idea es elegir $\eta \in \mathbb{R}$ de modo que el vector $x = \begin{pmatrix} \eta \\ y \end{pmatrix}$ tenga por energía exactamente $y^T(A_* - \frac{1}{\alpha} aa^T)y$. Calculemos primero la energía de ese x:

$$\begin{aligned} x^T A x &= \begin{pmatrix} \eta & y^T \end{pmatrix} \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix} \begin{pmatrix} \eta \\ y \end{pmatrix} = \begin{pmatrix} \eta & y^T \end{pmatrix} \begin{pmatrix} \alpha\eta + a^T y \\ a\eta + A_* y \end{pmatrix} \\ &= \alpha\eta^2 + \eta a^T y + \eta y^T a + y^T A_* y = \alpha\eta^2 + 2\eta\, a^T y + y^T A_* y. \end{aligned}$$

Por otro lado,

$$y^T \Big(A_* - \tfrac{1}{\alpha} aa^T \Big) y = y^T A_* y - \tfrac{1}{\alpha} (a^T y)^2.$$

Igualando las dos expresiones queda la ecuación

$$\alpha\eta^2 + 2\eta\, a^T y = -\tfrac{1}{\alpha}(a^T y)^2, \qquad \text{es decir} \qquad \tfrac{1}{\alpha}\big(\alpha\eta + a^T y\big)^2 = 0,$$

que se cumple tomando $\eta = -\,a^T y/\alpha$. Con esa elección, $x \neq 0$ (su cola es $y \neq 0$) y por lo tanto

$$y^T \Big(A_* - \tfrac{1}{\alpha} aa^T \Big) y = x^T A x > 0.$$

La simetría de $A_* - \frac{1}{\alpha} aa^T$ es inmediata. ∎

Corolario 6.8. Si A es sdp, la eliminación gaussiana sobre A se puede llevar a cabo *sin intercambios de filas* y todos los pivotes resultan positivos.

Demostración. El primer pivote es $\alpha = a_{11} > 0$, así que el primer paso no se traba. Lo que queda por eliminar después de ese paso es el complemento de Schur, que por el Lema 6.7 vuelve a ser sdp y es de tamaño $n-1$. Por inducción, su primer elemento diagonal — que es el segundo pivote de A — es positivo, y así sucesivamente. ∎

6.1.3 Las cinco caracterizaciones

Teorema 6.9. Sea $S \in \mathbb{R}^{n\times n}$ una matriz simétrica. Las siguientes condiciones son equivalentes.

- **(a)** $x^T S x > 0$ para todo $x \in \mathbb{R}^n$ *no nulo*.
- **(b)** Todos los autovalores de S son positivos.
- **(c)** $S = A^T A$ para alguna matriz A con columnas linealmente independientes.
- **(d)** Todos los determinantes principales $D_k = \det S_k$, $k = 1, \ldots, n$, son positivos.
- **(e)** Todos los pivotes de S son positivos en la eliminación.

(Aquí S_k denota, como en el Capítulo 2, la submatriz principal formada por las primeras k filas y columnas de S.)

Demostración. Probaremos el circuito

$$\textbf{(a)} \Rightarrow \textbf{(b)} \Rightarrow \textbf{(a)}, \qquad \textbf{(a)} \Rightarrow \textbf{(e)} \Leftrightarrow \textbf{(d)}, \qquad \textbf{(e)} \Rightarrow \textbf{(c)} \Rightarrow \textbf{(a)}.$$

(a)⇒(b). Sea λ un autovalor de S y $x \neq 0$ un autovector correspondiente. De $Sx = \lambda x$ sale $x^T S x = \lambda\, x^T x$, o sea

$$\lambda = \frac{x^T S x}{x^T x}.$$

El numerador es positivo por **(a)** y el denominador es $\|x\|^2 > 0$. Luego $\lambda > 0$.

(b)⇒(a). Por el teorema espectral (Teorema 5.22), $S = Q\Lambda Q^T$ con Q ortogonal y $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$, donde $\lambda_i > 0$ para todo i por **(b)**. Dado $x \neq 0$, llamemos $y = Q^T x$. Entonces

$$x^T S x = x^T Q \Lambda Q^T x = (Q^T x)^T \Lambda (Q^T x) = y^T \Lambda y = \sum_{i=1}^{n} \lambda_i y_i^2.$$

Como Q es invertible y $x \neq 0$, es $y \neq 0$, y entonces la suma es estrictamente positiva.

(a)⇒(e). Es el Corolario 6.8.

(e)⇔(d). Los dos sentidos salen de la fórmula de los pivotes como cocientes de menores del Teorema 2.2:

$$u_{kk} = \frac{\det S_k}{\det S_{k-1}} = \frac{D_k}{D_{k-1}}, \qquad D_0 := 1.$$

Si todos los pivotes son positivos, entonces $D_k = u_{11} u_{22} \cdots u_{kk} > 0$ para todo k. Recíprocamente, si todos los D_k son positivos, cada $u_{kk} = D_k / D_{k-1}$ es cociente de dos números positivos. (En ambos sentidos la hipótesis garantiza que los D_k son no nulos, así que las submatrices principales son invertibles y el Teorema 2.2 se aplica: la eliminación no se traba.)

(e)⇒(c). Si los pivotes son no nulos, S admite factorización LU y, por ser simétrica, la forma $S = LDL^T$ de la Sección 2.4.2 con $D = \operatorname{diag}(u_{11}, \ldots, u_{nn})$. Como todos los pivotes son positivos, tiene sentido $D^{1/2} = \operatorname{diag}(\sqrt{u_{11}}, \ldots, \sqrt{u_{nn}})$ y podemos escribir

$$S = LDL^T = \left(LD^{1/2}\right)\left(D^{1/2} L^T\right) = A^T A, \qquad \text{con } A := D^{1/2} L^T.$$

La matriz A es triangular superior con diagonal $\sqrt{u_{kk}} \neq 0$, luego es invertible y sus columnas son linealmente independientes.

(c)⇒(a). Si $S = A^T A$ con $A \in \mathbb{R}^{m \times n}$ de columnas independientes, entonces para $x \neq 0$

$$x^T S x = x^T (A^T A) x = (Ax)^T (Ax) = \|Ax\|^2,$$

y $Ax \neq 0$ porque $N(A) = \{0\}$. Luego $x^T S x > 0$. ∎

Observación 6.10 (Cuál usar). Las cinco condiciones no cuestan lo mismo. Para decidir si una matriz concreta es sdp, la condición **(e)** (los pivotes) es la más barata: es una eliminación gaussiana, $\sim n^3/3$ operaciones, y de paso uno se queda con la factorización. La **(d)** (los determinantes) es cómoda a mano para $n = 2$ o 3 y desastrosa para n grande. La **(b)** (los autovalores) es la más cara de calcular pero la más informativa. La **(a)** es la definición, y la **(c)** es la que aparece sola en las aplicaciones: las matrices de covarianza y las matrices de Gram *vienen* en la forma $A^T A$.

Ejemplo 6.11. Para $n = 2$ el criterio **(d)** es un renglón: $S = \left[\begin{smallmatrix} a & b \\ b & c \end{smallmatrix}\right]$ es sdp si y sólo si $a > 0$ y $ac - b^2 > 0$. Así, $\left[\begin{smallmatrix} 1 & 10 \\ 10 & 100 \end{smallmatrix}\right]$ no es sdp ($D_2 = 0$: es semidefinida), mientras que $\left[\begin{smallmatrix} 1 & 10 \\ 10 & 101 \end{smallmatrix}\right]$ sí lo es ($D_1 = 1 > 0$, $D_2 = 1 > 0$). Los pivotes de esta última son 1 y $101 - 100 = 1$, de acuerdo con $u_{22} = D_2 / D_1$.

Ejemplo 6.12 (Los cinco criterios, en una familia de matrices). El teorema se aprecia mejor cuando hay un parámetro y la pregunta es "¿para qué valores?". Tomemos

$$S_b = \begin{bmatrix} 1 & b & b \\ b & 1 & b \\ b & b & 1 \end{bmatrix}, \qquad b \in \mathbb{R},$$

que no es una matriz inventada: es la matriz de correlación de tres variables que están correlacionadas todas con todas por igual. La pregunta es para qué b es sdp, y vale la pena contestarla con tres criterios distintos para ver que dan lo mismo y cuánto cuesta cada uno.

Con los autovalores (b). Escribamos $S_b = (1-b)I + b\,\mathbf{1}\mathbf{1}^T$, con $\mathbf{1} = (1,1,1)^T$. Como $\mathbf{1}\mathbf{1}^T$ tiene autovalor 3 en la dirección $\mathbf{1}$ y autovalor 0 en el plano $\mathbf{1}^\perp$, los autovalores de S_b son

$$\lambda = 1 + 2b \ \text{ (en la dirección } \mathbf{1}), \qquad \lambda = 1 - b \ \text{ (doble, en } \mathbf{1}^\perp).$$

Los dos son positivos exactamente cuando

$$\boxed{-\tfrac{1}{2} < b < 1}$$

Con los determinantes (d). Es una cuenta directa:

$$D_1 = 1, \qquad D_2 = 1 - b^2, \qquad D_3 = \det S_b = (1-b)^2(1+2b).$$

Pedir los tres positivos da $-1 < b < 1$ de D_2, y $b > -\frac{1}{2}$ con $b \neq 1$ de D_3; juntando todo, $-\frac{1}{2} < b < 1$. El mismo intervalo.

Con los pivotes (e). Usando $u_{kk} = D_k / D_{k-1}$,

$$u_{11} = 1, \qquad u_{22} = 1 - b^2, \qquad u_{33} = \frac{(1-b)(1+2b)}{1+b},$$

y de nuevo los tres son positivos exactamente en $-\frac{1}{2} < b < 1$.

Tres observaciones que valen más que la cuenta.

- *El intervalo no es simétrico.* Una correlación común puede ser tan grande como se quiera (cerca de 1) pero no puede ser muy negativa: con $b < -\frac{1}{2}$ la matriz deja de ser sdp. Tiene sentido: tres variables no pueden estar todas muy anticorrelacionadas entre sí al mismo tiempo. Para n variables en lugar de tres, el mismo argumento da $-\frac{1}{n-1} < b < 1$: el margen negativo se achica a medida que hay más variables.
- *Los bordes son los casos semidefinidos.* En $b = 1$ todas las filas son iguales y $S_1 = \mathbf{1}\mathbf{1}^T$ tiene rango uno; en $b = -\frac{1}{2}$ el autovalor $1 + 2b$ se anula y el núcleo es la dirección $\mathbf{1}$ —es, salvo un factor, la matriz C del Ejemplo 6.4—. Las matrices semidefinidas son siempre el *borde* del conjunto de las sdp.
- *Para qué sirvió cada criterio.* Acá los autovalores se pudieron calcular porque la matriz tiene mucha simetría; es lo excepcional. En una matriz cualquiera de 3×3 los autovalores son las raíces de una cúbica y no hay fórmula cómoda, mientras que los determinantes y los pivotes siguen siendo dos renglones. Esa es, en concreto, la asimetría de la Observación 6.10.

Ejercicio de desarrollo 6.1 | Matrices semidefinidas positivas

El Teorema 6.9 tiene una versión "con $\geq$" que se usa tanto como la original — las matrices de covarianza son, en general, sólo semidefinidas — pero que no se obtiene cambiando mecánicamente $>$ por $\geq$ en las cinco condiciones. El objetivo es entender exactamente dónde falla.
Sea $S \in \mathbb{R}^{n\times n}$ simétrica.

(a) Probar que son equivalentes: (i) $x^T S x \geq 0$ para todo $x \in \mathbb{R}^n$; (ii) todos los autovalores de S son ≥ 0; (iii) $S = A^T A$ para alguna matriz A (ahora sin pedir columnas independientes). *Sugerencia:* imitar el circuito **(a)**⇒**(b)**⇒**(a)** del teorema y, para (iii), usar $A = \Lambda^{1/2} Q^T$.

(b) Probar que S es semidefinida positiva si y sólo si $S + \varepsilon I$ es sdp para todo $\varepsilon > 0$. Es decir: una matriz semidefinida se vuelve definida apenas se le suma cualquier cosa positiva en la diagonal, por chica que sea.

(c) Mostrar con un ejemplo de 2×2 que la condición "$D_k = \det S_k \geq 0$ para todo k" *no* implica que S sea semidefinida positiva.

(d) El criterio correcto necesita *todos* los menores principales y no sólo los de arriba a la izquierda. Llamemos $S_{[I]}$ a la submatriz obtenida quedándose con las filas y columnas de índices en $I \subseteq \{1, \ldots, n\}$. Probar que si S es semidefinida positiva entonces $\det S_{[I]} \geq 0$ para todo I. *Sugerencia:* probar primero que $S_{[I]}$ es semidefinida positiva, usando vectores x con ceros fuera de I.

(e) Explicar por qué el argumento del ítem (d) aplicado a las sdp da, gratis, que $\det S_{[I]} > 0$ para todo I, y en particular que en una matriz sdp vale $a_{ij}^2 < a_{ii} a_{jj}$ para $i \neq j$. ¿Qué dice esto sobre dónde está el elemento más grande en valor absoluto de una matriz sdp?

(f) ¿Qué pasa con los pivotes de una matriz semidefinida positiva? Dar un ejemplo en el que la eliminación se trabe y explicar qué se puede afirmar.

Se entrega por escrito. El ítem (c) es el error más frecuente con estas matrices; el (e) es la razón por la que en una matriz de covarianza las varianzas "dominan" a las covarianzas. Dicho sea de paso, el ítem (b) admite una lectura más corta para quien tenga a mano algo de topología: dice que las matrices semidefinidas positivas son exactamente la clausura del conjunto de las sdp.

6.2 El cociente de Rayleigh

Las cinco caracterizaciones contestan la pregunta "¿cuándo es la energía $x^T S x$ positiva para todo x?". La pregunta que sigue es la natural: *¿cuán grande puede ser esa energía?* Para que tenga sentido hay que fijar el tamaño de x —si no, $x^T S x$ crece sin cota multiplicando x por un número grande—, y entonces la respuesta es exactamente el mayor autovalor. Es el resultado más usado de todo el capítulo: con él se definen los valores singulares en el Capítulo 8, se construyen las componentes principales en el Capítulo 9 y se separan clases en el Capítulo 11.

Esta sección no usa nada más que el teorema espectral.

Teorema 6.13 (El máximo de la energía sobre la esfera). Sea $S \in \mathbb{R}^{n\times n}$ simétrica, con autovalores $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ y una base ortonormal de autovectores $q_1, \ldots, q_n$ (teorema espectral). Entonces, para todo x con $\|x\| = 1$,

$$\lambda_n \;\leq\; x^T S x \;\leq\; \lambda_1$$

El máximo se alcanza en $x = q_1$ y el mínimo en $x = q_n$. Más precisamente, vale $x^T S x = \lambda_1$ si y sólo si x es un autovector unitario asociado a λ_1.

Demostración. **Paso 1: cambiar a la base de autovectores.** Sea $Q = [\, q_1 \;\cdots\; q_n \,]$, que es ortogonal, y $S = Q\Lambda Q^T$. Dado x, llamemos $y = Q^T x$, es decir, el vector de las coordenadas de x en la base $q_1, \ldots, q_n$. Dos cuentas:

$$x^T S x = x^T Q \Lambda Q^T x = (Q^T x)^T \Lambda (Q^T x) = y^T \Lambda y = \sum_{i=1}^{n} \lambda_i \, y_i^2,$$

y, como Q^T es ortogonal y por lo tanto no cambia las longitudes,

$$\|y\| = \|Q^T x\| = \|x\| = 1, \qquad \text{o sea} \qquad \sum_{i=1}^{n} y_i^2 = 1.$$

El problema quedó así: hay que acotar $\sum_i \lambda_i y_i^2$ sabiendo que $\sum_i y_i^2 = 1$. Ya no hay matrices, sólo números.

Paso 2: la cota, restando. En lugar de razonar sobre la suma, miremos cuánto le falta para llegar a λ_1. Usando $\sum_i y_i^2 = 1$ para escribir $\lambda_1 = \lambda_1 \sum_i y_i^2$,

$$\lambda_1 - x^T S x = \lambda_1 \sum_{i=1}^{n} y_i^2 - \sum_{i=1}^{n} \lambda_i y_i^2 = \sum_{i=1}^{n} (\lambda_1 - \lambda_i)\, y_i^2.$$

Miremos un sumando cualquiera, $(\lambda_1 - \lambda_i)\, y_i^2$. Es un producto de dos números que *no pueden ser negativos*: el primero porque λ_1 es el mayor de todos los autovalores, y el segundo porque es un cuadrado. Luego cada sumando es ≥ 0, y una suma de números ≥ 0 es ≥ 0. Es decir, $\lambda_1 - x^T S x \geq 0$, que es la cota de arriba.

La de abajo es la misma cuenta del otro lado:

$$x^T S x - \lambda_n = \sum_{i=1}^{n} (\lambda_i - \lambda_n)\, y_i^2 \;\geq\; 0,$$

porque ahora $\lambda_i - \lambda_n \geq 0$ para todo i.

Paso 3: cuándo hay igualdad. La cuenta del paso 2 da más que la desigualdad: dice exactamente cuánto falta. Una suma de números ≥ 0 vale cero si y sólo si *todos* los sumandos son cero, así que

$$x^T S x = \lambda_1 \iff (\lambda_1 - \lambda_i)\, y_i^2 = 0 \;\text{ para todo } i \iff y_i = 0 \;\text{ para todo } i \text{ con } \lambda_i < \lambda_1.$$

Es decir, $x = Qy$ no tiene componente fuera del espacio propio de λ_1: x es un autovector unitario asociado a λ_1. En particular $x = q_1$ sirve, y da $q_1^T S q_1 = \lambda_1$. Lo mismo para el mínimo con λ_n. ∎

Observación 6.14 (Dónde está la gracia de la demostración)**.** Conviene subrayar los dos movimientos, porque son los que hacen que el argumento no requiera creer nada.

El primero es *normalizar antes de empezar*: pedir $\|x\| = 1$ convierte una pregunta sobre un cociente en una pregunta sobre una suma con una restricción, y las sumas con restricciones se manipulan sin esfuerzo.

El segundo es *restar en lugar de comparar*. La tentación es decir que $\sum_i \lambda_i y_i^2$ es un promedio ponderado de los λ_i —con pesos y_i^2 que suman 1— y que un promedio nunca se sale del rango de los números promediados. Es cierto, pero es una interpretación: para convencerse hay que volver a hacer una cuenta. Restando, en cambio, la desigualdad se vuelve una *identidad*:

$$\lambda_1 - x^T S x = \sum_{i=1}^{n} (\lambda_1 - \lambda_i)\, y_i^2,$$

y del lado derecho no hay nada que discutir: es una suma de productos de números no negativos. De paso, la identidad entrega gratis el caso de igualdad, que con el argumento del promedio hay que probar aparte.

Observación 6.15 (La lectura "promedio ponderado")**.** Dicho lo anterior, la lectura del promedio es la que deja la imagen correcta y vale la pena tenerla, ahora que la cuenta ya está hecha. Los números $w_i = y_i^2$ son no negativos y suman 1, así que

$$x^T S x = \sum_{i=1}^{n} \lambda_i w_i$$

es una *mezcla* de los autovalores. Por ejemplo, con $\Lambda = \operatorname{diag}(5, 2, 1)$ y $x = \frac{1}{\sqrt{3}}(q_1 + q_2 + q_3)$ los pesos son $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ y la energía vale $\frac{5+2+1}{3} = \frac{8}{3}$, que está entre 1 y 5 como tiene que estar.

Otra manera de verlo, útil para recordar *dónde* se alcanza el máximo: la condición $\sum_i y_i^2 = 1$ es un presupuesto de una unidad para repartir entre las n direcciones propias, y la dirección i-ésima paga λ_i por cada unidad que se le asigne. Para cobrar lo máximo hay que poner todo el presupuesto en la dirección que mejor paga, que es q_1; repartirlo entre varias sólo puede empeorar el resultado. Eso explica por qué el máximo se alcanza en un autovector y no en alguna dirección intermedia.

El cociente que le da el nombre al resultado es sólo la manera de escribirlo sin la restricción $\|x\| = 1$.

Definición 6.16 (Cociente de Rayleigh)**.** Sea $S \in \mathbb{R}^{n\times n}$ simétrica. El **cociente de Rayleigh** de un vector $x \neq 0$ es

$$R(x) = \frac{x^T S x}{x^T x}.$$

Corolario 6.17 (Versión con cociente)**.** Con la notación del Teorema 6.13, para todo $x \neq 0$ vale

$$\lambda_n \;\leq\; \frac{x^T S x}{x^T x} \;\leq\; \lambda_1, \qquad \text{es decir} \qquad \max_{x\neq 0} \frac{x^T S x}{x^T x} = \lambda_1, \quad \min_{x\neq 0} \frac{x^T S x}{x^T x} = \lambda_n.$$

Demostración. Dado $x \neq 0$, el vector $u = x/\|x\|$ tiene norma 1, y

$$R(x) = \frac{x^T S x}{\|x\|^2} = \left(\frac{x}{\|x\|}\right)^T S \left(\frac{x}{\|x\|}\right) = u^T S u,$$

así que el cociente de un x cualquiera es la energía del vector unitario que apunta en la misma dirección. Aplicando el teorema a u se obtienen las dos cotas, y los valores extremos se alcanzan en q_1 y q_n como antes. ∎

Observación 6.18 (Cuál de las dos formas usar)**.** Las dos dicen lo mismo y conviene tener las dos a mano, pero sirven para cosas distintas. La forma con cociente es la cómoda para *enunciar*, porque no arrastra la condición $\|x\| = 1$ y porque deja ver de un golpe que R sólo depende de la dirección de x: $R(cx) = R(x)$ para todo $c \neq 0$. La forma con la esfera, en cambio, es la cómoda para *demostrar* y para *calcular*, porque convierte el problema en maximizar una suma con una restricción. Cuando haya que hacer una cuenta —y en los capítulos que vienen las hay— conviene normalizar primero y olvidarse del cociente.

La versión restringida se demuestra sin cambiar nada: lo único que hace la hipótesis extra es poner en cero algunas coordenadas y_i.

Corolario 6.19 (Los autovalores siguientes)**.** Con la notación del Teorema 6.13, para cada $k = 1, \dots, n$,

$$\max\Big\{\, x^T S x \;:\; \|x\| = 1,\ x \perp q_1, \dots, q_{k-1} \Big\} = \lambda_k, \qquad \text{alcanzado en } x = q_k.$$

Demostración. Con $y = Q^T x$ como antes, la condición $x \perp q_i$ dice $y_i = q_i^T x = 0$. Si eso vale para $i = 1, \dots, k-1$, entonces

$$x^T S x = \sum_{i \geq k} \lambda_i y_i^2, \qquad \sum_{i \geq k} y_i^2 = 1,$$

y repitiendo el Paso 2 con λ_k en lugar de λ_1,

$$\lambda_k - x^T S x = \sum_{i \geq k} (\lambda_k - \lambda_i)\, y_i^2 \;\geq\; 0,$$

porque $\lambda_i \leq \lambda_k$ para $i \geq k$. La igualdad se alcanza en $x = q_k$. ∎

Observación 6.20 (Para qué lo vamos a usar)**.** El teorema convierte un problema de autovalores en uno de *optimización*: λ_1 es el máximo de una función sobre la esfera, y q_1 el vector donde se alcanza. De ahí salen las tres aplicaciones del resto del apunte.

La norma espectral. Dada $A \in \mathbb{R}^{m \times n}$ cualquiera —ni simétrica ni cuadrada—, ¿cuánto puede estirar a un vector? Con $\|x\| = 1$,

$$\|Ax\|^2 = (Ax)^T (Ax) = x^T (A^T A) x,$$

y $A^T A$ es simétrica y semidefinida positiva (Observación 6.2(4)). Por el teorema, ese máximo es $\lambda_1(A^T A)$ y se alcanza en el autovector correspondiente. La raíz cuadrada de ese número es el primer *valor singular* de A y también su *norma espectral*: es el punto de partida del Capítulo 8, y notemos que para llegar ahí no hizo falta ninguna factorización nueva.

De a una dirección por vez. El Corolario 6.19 dice que q_1 maximiza, q_2 maximiza entre los perpendiculares a q_1, y así siguiendo. Esa construcción secuencial es, literalmente, la definición de las componentes principales del Capítulo 9.

Con dos matrices. En el Capítulo 11 aparece el cociente x^TAx/x^TBx con B sdp en el denominador. Se resuelve reduciéndolo a éste, y la herramienta para hacerlo es la raíz cuadrada de B, que es el tema de la sección que sigue.

Ejemplo 6.21. Para $S = \left[\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right]$ los autovalores son $\lambda_1 = 3$, con $q_1 = \frac{1}{\sqrt{2}}(1,1)^T$, y $\lambda_2 = 1$, con $q_2 = \frac{1}{\sqrt{2}}(1,-1)^T$. Evaluemos la energía en tres vectores unitarios:

$$\begin{array}{llll} x = q_1 = \frac{1}{\sqrt{2}}(1,1)^T: & x^TSx = 3 = \lambda_1 & \text{(el máximo)} & y = (1,0)^T, \\ x = q_2 = \frac{1}{\sqrt{2}}(1,-1)^T: & x^TSx = 1 = \lambda_2 & \text{(el mínimo)} & y = (0,1)^T, \\ x = (1,0)^T: & x^TSx = 2 & \text{(en el medio)} & y = \frac{1}{\sqrt{2}}(1,-1)^T. \end{array}$$

La tercera fila es la que ilustra la demostración: las coordenadas de $(1,0)^T$ en la base de autovectores son $y = \frac{1}{\sqrt{2}}(1,-1)^T$, con pesos $w = (\frac{1}{2}, \frac{1}{2})$, y en efecto $3 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = 2$. La cuenta del Paso 2 da $\lambda_1 - x^TSx = (3-3) \cdot \frac{1}{2} + (3-1) \cdot \frac{1}{2} = 1$, que es exactamente lo que le falta a 2 para llegar a 3.

Ejercicio de desarrollo 6.2 | El cociente de Rayleigh

Sea $S \in \mathbb{R}^{n \times n}$ simétrica, con $\lambda_1 \geq \cdots \geq \lambda_n$ y base ortonormal de autovectores $q_1, \ldots, q_n$.

(a) *(Otra demostración, sin coordenadas.)* Probar el Teorema 6.13 por un camino completamente distinto: mostrar que los autovalores de $\lambda_1 I - S$ son los $\lambda_1 - \lambda_i$ y que por lo tanto $\lambda_1 I - S$ es semidefinida positiva; deducir de la condición de la energía que $x^T(\lambda_1 I - S)x \geq 0$, es decir $\lambda_1 \, x^Tx \geq x^TSx$, para *todo* x. Hacer lo mismo con $S - \lambda_n I$ para la cota de abajo. ¿Cómo se identifican, en esta versión, los vectores donde hay igualdad?

(b) *(Una familia, a mano.)* Sea $S_c = \left[\begin{smallmatrix} 2 & c \\ c & 2 \end{smallmatrix}\right]$ con $c \in \mathbb{R}$. Calcular $\lambda_1(S_c)$ y $\lambda_2(S_c)$ y sus autovectores. Verificar el teorema evaluando la energía en los vectores unitarios en las direcciones $(1,0)$, $(1,1)$ y $(1,-1)$, y en cada caso escribir explícitamente los pesos $w_i = y_i^2$ y la identidad del Paso 2. ¿Para qué valores de c la dirección de máxima energía deja de ser $(1,1)$?

(c) *(La traza, otra vez.)* Probar que

$$\frac{1}{n}\sum_{i=1}^{n} q_i^T S q_i = \frac{\operatorname{tr}(S)}{n},$$

y deducir que $\lambda_n \leq \operatorname{tr}(S)/n \leq \lambda_1$. Interpretar: el promedio de la diagonal de S siempre cae entre el menor y el mayor autovalor. Verificarlo en las matrices K y C de los Ejemplos 6.3 y 6.4.

(d) *(Hacia la norma espectral.)* Sea $A \in \mathbb{R}^{m \times n}$. Probar que

$$\max_{\|x\|=1} \|Ax\|^2 = \lambda_1(A^TA),$$

y que el máximo se alcanza en un autovector unitario de A^TA asociado a λ_1. Calcularlo explícitamente para $A = \left[\begin{smallmatrix} 3 & 0 \\ 4 & 5 \end{smallmatrix}\right]$: hallar A^TA, sus autovalores y el vector que más se estira, y comprobar el resultado calculando $\|Ax\|$ en unos cuantos vectores unitarios.

(e) *(Monotonía.)* Probar que si S y T son simétricas y $T - S$ es semidefinida positiva, entonces $\lambda_1(S) \le \lambda_1(T)$ y $\lambda_n(S) \le \lambda_n(T)$. *Sugerencia:* es inmediato con el Teorema 6.13; ¿se le ocurre alguna demostración que no lo use?

(f) *(Opcional.)* Probar que el conjunto de valores que toma el cociente de Rayleigh es exactamente el intervalo $[\lambda_n, \lambda_1]$: todos los valores intermedios se alcanzan. *Sugerencia:* mirar $x(t) = (1-t)q_n + tq_1$ normalizado, con $t \in [0,1]$.

Se entrega por escrito. El ítem (d) es, tal cual, la definición del primer valor singular del Capítulo 8: conviene hacerlo con cuidado porque se usa enseguida. El Corolario 6.19 es el primer caso de una familia de resultados —los teoremas de Courant-Fischer— que describen todos *los autovalores de una matriz simétrica como máximos y mínimos de la energía sobre subespacios.*

6.3 La raíz cuadrada de una matriz sdp

La analogía con los números positivos se puede llevar bastante lejos. Si $s > 0$, existe un único $r > 0$ con $r^2 = s$. Lo mismo pasa con las matrices sdp, y la construcción es inmediata a partir del teorema espectral: si $S = Q\Lambda Q^T$ con $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ y todos los $\lambda_i > 0$, definimos

$$S^{1/2} := Q\,\Lambda^{1/2}\,Q^T, \qquad \Lambda^{1/2} = \operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}).$$

Entonces $S^{1/2}$ es simétrica, sus autovalores $\sqrt{\lambda_i}$ son positivos — luego es sdp — y

$$\left(S^{1/2}\right)^2 = Q\Lambda^{1/2}Q^TQ\Lambda^{1/2}Q^T = Q\Lambda^{1/2}\Lambda^{1/2}Q^T = Q\Lambda Q^T = S.$$

Observación 6.22 (Dos factorizaciones $S = A^TA$ distintas). El Teorema 6.9 nos dio una matriz A con $S = A^TA$ y la construcción anterior nos da otra: $S = S^{1/2}S^{1/2} = (S^{1/2})^TS^{1/2}$. Son distintas — una es triangular y la otra simétrica — y ninguna de las dos es la única: si Q_0 es cualquier matriz ortogonal, $A' = Q_0A$ cumple $(A')^TA' = A^TQ_0^TQ_0A = A^TA = S$. Es decir, *la factorización $S = A^TA$ nunca es única*: la matriz A está determinada a menos de una ortogonal por izquierda. Lo que sí es único es el factor triangular con diagonal positiva (Cholesky, próxima sección) y lo que sí es única es la raíz *sdp* (ítem (b) de la entrega que sigue).

Ejercicio de desarrollo 6.3 | La raíz cuadrada

Sea $S \in \mathbb{R}^{n\times n}$ sdp y sea $S^{1/2} = Q\Lambda^{1/2}Q^T$ la matriz construida más arriba.

(a) Verificar que $S^{1/2}$ es sdp, que conmuta con S y que $S^{1/2}$ y S tienen los mismos autovectores.

(b) *(Unicidad.)* Probar que $S^{1/2}$ es la *única* matriz sdp R con $R^2 = S$. *Sugerencia:*

si R es sdp y $R^2 = S$, y v es un autovector de R con autovalor $\mu > 0$, entonces v es autovector de S con autovalor μ^2; usar que la base de autovectores de R diagonaliza también a S y que μ queda determinado por μ^2 al ser $\mu > 0$.

(c) Mostrar que $\det(S^{1/2}) = \sqrt{\det S}$ y que $\operatorname{tr}(S^{1/2}) = \sum_i \sqrt{\lambda_i}$. ¿Es cierto que $\operatorname{tr}(S^{1/2}) = \sqrt{\operatorname{tr} S}$? Dar un contraejemplo.

(d) Exhibir una matriz simétrica S y dos matrices *simétricas* distintas $R_1 \neq R_2$ con $R_1^2 = R_2^2 = S$. ¿Se contradice el ítem (b)?

(e) Calcular $S^{1/2}$ para $S = \left[\begin{smallmatrix} 5 & 4 \\ 4 & 5 \end{smallmatrix}\right]$ y para $S = \left[\begin{smallmatrix} 10 & 6 \\ 6 & 10 \end{smallmatrix}\right]$, y verificar en cada caso que $(S^{1/2})^T S^{1/2} = S$.

(f) Usando la raíz cuadrada, probar que si S es sdp y M es simétrica, entonces SM es diagonalizable y sus autovalores son reales, aunque SM *no* sea simétrica. *Sugerencia:* SM es semejante a $S^{-1/2}(SM)S^{1/2} = S^{1/2}MS^{1/2}$, que sí es simétrica.

Se entrega por escrito. El ítem (f) es la razón por la que los problemas de autovalores generalizados $Ax = \lambda Bx$ con B sdp se comportan como los simétricos; volveremos sobre eso más adelante.

6.4 Factorización de Cholesky

Entre todas las factorizaciones $S = A^T A$, hay una en la que A es triangular superior. Es la que efectivamente se calcula, porque cuesta la mitad que una eliminación gaussiana común y porque resolver con factores triangulares es inmediato.

Teorema 6.23. Si $A \in \mathbb{R}^{n\times n}$ es sdp, entonces existe R triangular superior (de $n \times n$) tal que $A = R^T R$.

Demostración. La demostración es constructiva. Observemos que si existiera tal matriz R debería cumplir que

$$A = \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix} = \begin{bmatrix} \rho & 0^T \\ r & R_*^T \end{bmatrix} \begin{bmatrix} \rho & r^T \\ 0 & R_* \end{bmatrix} = \begin{bmatrix} \rho^2 & \rho r^T \\ \rho r & R_*^T R_* + r r^T \end{bmatrix},$$

con $\alpha = a_{11}$, $\rho \in \mathbb{R}$, $r \in \mathbb{R}^{n-1}$ y $A_*, R_* \in \mathbb{R}^{(n-1)\times(n-1)}$, con R_* triangular superior. Para que valga la igualdad se debería cumplir:

1. $\rho^2 = \alpha$;
2. $\rho r = a$;
3. $R_*^T R_* + r r^T = A_*$.

Para que se cumplan las dos primeras, basta con elegir $\rho = \sqrt{\alpha} > 0$ (recordemos que $\alpha = a_{11} > 0$) y $r = \frac{1}{\rho} a$. Para que se cumpla la tercera, observemos que debemos hallar $R_* \in \mathbb{R}^{(n-1)\times(n-1)}$, triangular superior, tal que

$$R_*^T R_* = A_* - r r^T.$$

Ahora bien, con la elección $r = a/\rho$ y $\rho^2 = \alpha$ resulta

$$A_* - rr^T = A_* - \tfrac{1}{\alpha}\, aa^T,$$

que es exactamente el complemento de Schur de α en A y que, por el Lema 6.7, es sdp. El argumento se sigue entonces por inducción sobre n (el caso $n = 1$ es $\rho = \sqrt{a_{11}}$). ∎

Observación 6.24. Vale la pena observar lo siguiente:

- La matriz R se llama **factor de Cholesky** de A.
- La factorización de Cholesky es una factorización LU con $L = R^T$ y $U = R$ (aquí L no tiene unos en la diagonal).
- Por el ítem **(c)** del Teorema 6.9, el recíproco también vale, de modo que podríamos haber enunciado el teorema de la siguiente manera:

  > Sea $A \in \mathbb{R}^{n\times n}$ simétrica. Entonces A es sdp si y sólo si existe R triangular superior no singular tal que $A = R^T R$.

- La demostración es un algoritmo: en cada paso se toma la raíz del primer elemento diagonal, se divide la primera fila por ella y se actualiza el bloque restante restándole rr^T.

Cuánto cuesta

Contemos las operaciones como en la Sección 2.5, siguiendo los pasos de la demostración. En el paso k-ésimo ($k = 1, \dots, n$) el bloque activo es de tamaño $(n-k+1) \times (n-k+1)$ y hay que hacer tres cosas:

(1) calcular $\rho = \sqrt{\alpha}$: **una raíz cuadrada**;

(2) calcular $r = a/\rho$, donde a tiene $n-k$ componentes: $n-k$ **divisiones**;

(3) actualizar el bloque restante, $A_* - rr^T$, que es de tamaño $(n-k) \times (n-k)$.

El paso (3) es el único que pesa, y es también donde aparece la ventaja de Cholesky. La matriz $A_* - rr^T$ es simétrica, así que *no hace falta calcularla entera*: alcanza con su triángulo superior, que tiene

$$\frac{(n-k)(n-k+1)}{2}$$

entradas. Cada una de ellas cuesta una multiplicación (el producto $r_i r_j$) y una resta. Ésa es exactamente la mitad del trabajo que hace la eliminación gaussiana en el mismo paso, que actualiza las $(n-k)^2$ entradas del bloque sin aprovechar la simetría.

Sumando sobre los n pasos, el número total de multiplicaciones es

$$\sum_{k=1}^{n} \frac{(n-k)(n-k+1)}{2} = \sum_{m=0}^{n-1} \frac{m(m+1)}{2} = \frac{(n-1)n(n+1)}{6} \approx \frac{n^3}{6},$$

y el de restas es exactamente el mismo. Las n raíces cuadradas y las $\sum_k (n-k) = n(n-1)/2$ divisiones son de orden n y n^2: no cuentan para n grande. En total,

$$\frac{n^3}{6} + \frac{n^3}{6} = \frac{n^3}{3} \quad \text{operaciones},$$

contra las $2n^3/3$ de la factorización LU general que contamos en la Sección 2.5: **Cholesky cuesta exactamente la mitad**.

El ahorro viene de dos lugares, y conviene separarlos. Primero, la simetría: se guarda y se opera sobre medio arreglo. Segundo, y menos visible, el hecho de que *no hace falta buscar pivote*: por el Teorema 6.9(e) todos los pivotes de una matriz sdp son positivos, así que la eliminación nunca se traba y nunca hay que permutar filas. Eso no cambia el conteo de operaciones aritméticas, pero sí evita las comparaciones y, sobre todo, los movimientos de datos, que en una computadora real suelen costar más que las cuentas. Por las dos razones, Cholesky es el algoritmo estándar para sistemas sdp, y de hecho la manera práctica de *verificar* que una matriz es sdp es intentar calcular su factorización de Cholesky y ver si se traba al pedir una raíz cuadrada.

Observación 6.25 (Unicidad)**.** Dada A sdp, existe una *única* matriz R triangular superior *con elementos de la diagonal positivos* tal que $A = R^T R$: en la construcción anterior, la elección $\rho = +\sqrt{\alpha}$ es forzada en cada paso, y $r = a/\rho$ queda entonces determinado. Sin la condición sobre el signo hay 2^n factores, uno por cada elección de signos en la diagonal.

Observación 6.26 (Cholesky y LDL^T)**.** Las dos factorizaciones son la misma cuenta escrita de dos maneras. Si $A = LDL^T$ es la factorización de la Sección 2.4.2, con L de diagonal unitaria y D la matriz de los pivotes (positivos por el Teorema 6.9), entonces

$$A = LDL^T = \left(LD^{1/2}\right)\left(D^{1/2}L^T\right) = R^T R, \qquad R = D^{1/2}L^T,$$

y recíprocamente, si $A = R^T R$ y D_R es la diagonal de R, entonces

$$A = R^T R = \underbrace{R^T D_R^{-1}}_{L}\,\underbrace{D_R^2}_{D}\,\underbrace{D_R^{-1} R}_{L^T}.$$

En particular, *los elementos de la diagonal del factor de Cholesky son las raíces cuadradas de los pivotes*. Cholesky evita las raíces cuadradas sólo si uno se queda con LDL^T; ésa es la variante que se usa cuando A es sólo semidefinida.

6.5 La geometría: elipses y elipsoides

Hasta acá todo fue algebraico. La lectura geométrica es la que explica por qué estas matrices aparecen en estadística y en optimización. Fijemos S sdp y miremos el conjunto de nivel

$$E = \{x \in \mathbb{R}^n : x^T S x = 1\}.$$

Empecemos por el caso diagonal. Si $S = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$ con $\lambda_i > 0$, la ecuación es

$$\lambda_1 x_1^2 + \lambda_2 x_2^2 + \cdots + \lambda_n x_n^2 = 1,$$

es decir, una elipse (en $\mathbb{R}^2$), un elipsoide (en $\mathbb{R}^3$) o un elipsoide n-dimensional, con **semiejes** sobre los ejes coordenados y de longitudes $1/\sqrt{\lambda_1}, \ldots, 1/\sqrt{\lambda_n}$: cuanto más grande el autovalor, más corto el semieje.

El caso general se reduce a ése con el teorema espectral. Escribiendo $S = Q\Lambda Q^T$ y llamando $y = Q^T x$ — que son las coordenadas de x en la base ortonormal de autovectores $q_1, \ldots, q_n$ — resulta

$$x^T S x = y^T \Lambda y = \sum_{i=1}^{n} \lambda_i y_i^2.$$

Es la misma elipse de antes, vista en otra base ortonormal. Por lo tanto:

El conjunto $x^T S x = 1$ es un elipsoide cuyos ejes principales apuntan en las direcciones de los autovectores q_i de S y cuyos semiejes miden $1/\sqrt{\lambda_i}$.

Los autovectores dicen *hacia dónde* está inclinada la elipse y los autovalores dicen *cuánto* mide en cada dirección. Que S sea sdp es justamente lo que garantiza que el conjunto de nivel sea acotado: si algún λ_i fuera negativo aparecería una hipérbola en vez de una elipse, y si fuera cero, un cilindro.

Ejemplo 6.27. Para $S = \left[\begin{smallmatrix} 3 & 1 \\ 1 & 3 \end{smallmatrix}\right]$ los autovalores son $\lambda_1 = 4$ y $\lambda_2 = 2$, con autovectores $q_1 = (1,1)^T/\sqrt{2}$ y $q_2 = (1,-1)^T/\sqrt{2}$. La curva $3x_1^2 + 2x_1x_2 + 3x_2^2 = 1$ es entonces una elipse inclinada 45°, con semieje corto $1/2$ en la dirección de $(1,1)$ y semieje largo $1/\sqrt{2}$ en la dirección de $(1,-1)$ (Figura 6.1).

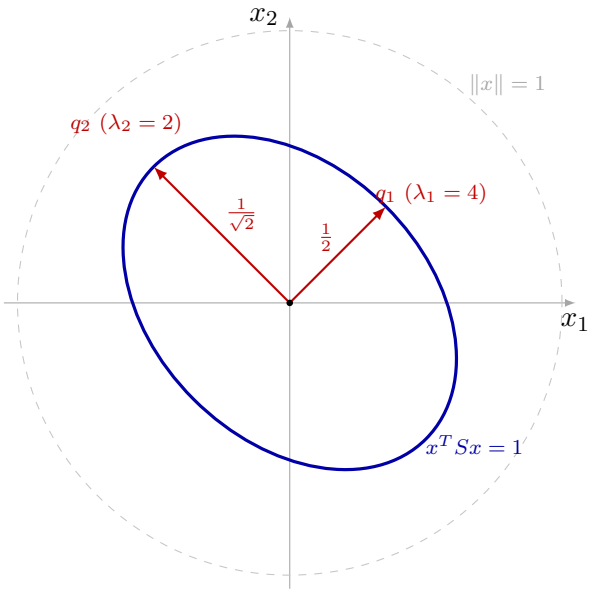


Figura 6.1. La elipse $x^T S x = 1$ para $S = \left[\begin{smallmatrix} 3 & 1 \\ 1 & 3 \end{smallmatrix}\right]$. Los ejes principales apuntan en las direcciones de los autovectores y los semiejes miden $1/\sqrt{\lambda_i}$: el autovalor grande da el semieje corto. En punteado, la circunferencia unitaria euclídea ($S = I$).

Esta imagen es la que hay que tener en la cabeza en tres lugares distintos:

- en estadística, E es una *elipse de confianza*: si Σ es la matriz de covarianza de un vector aleatorio, $x^T \Sigma^{-1} x = c$ describe las regiones de igual densidad de una gaussiana, y los autovectores de Σ son las direcciones de máxima y mínima varianza (esto es, esencialmente, PCA);
- en optimización, E es un conjunto de nivel de la función que se minimiza, y el cociente $\lambda_{\max}/\lambda_{\min}$ — el *número de condición*, que veremos en el capítulo de normas de matrices — mide cuán alargada es la elipse y, con eso, cuán lento es el descenso por gradiente;
- en el Capítulo 8 veremos que *toda* matriz A manda la esfera unitaria a un elipsoide, y los semiejes de ese elipsoide serán los valores singulares, que son las raíces de los autovalores de $A^T A$.

Ejercicio de desarrollo 6.4 | Elipses, elipsoides y la distancia asociada a S

Sea $S \in \mathbb{R}^{n\times n}$ sdp, con autovalores $\lambda_1 \geq \cdots \geq \lambda_n > 0$ y base ortonormal de autovectores $q_1, \ldots, q_n$. Para $x \in \mathbb{R}^n$ definimos

$$\|x\|_S := \sqrt{x^T S x}.$$

(a) Probar que $\|x\|_S = \|S^{1/2}x\|$, donde $\|\cdot\|$ es la norma euclídea usual y $S^{1/2}$ es la raíz cuadrada de la Sección 6.3. Deducir que $\|x\|_S = 0$ si y sólo si $x = 0$, y que $\|tx\|_S = |t|\,\|x\|_S$.

(b) Probar las desigualdades

$$\sqrt{\lambda_n}\,\|x\| \;\leq\; \|x\|_S \;\leq\; \sqrt{\lambda_1}\,\|x\|,$$

y mostrar que ambas se alcanzan (decir en qué vectores). *Sugerencia:* es el Teorema 6.13 y nada más: $\|x\|_S^2 = x^T S x$, así que para $\|x\| = 1$ las cotas son λ_n y λ_1; el caso general sale multiplicando por $\|x\|$. Interpretar: la "regla" $\|\cdot\|_S$ mide a lo sumo $\sqrt{\lambda_1/\lambda_n}$ veces distinto que la euclídea.

(c) Dibujar, para $S = \left[\begin{smallmatrix} 4 & 0 \\ 0 & 1 \end{smallmatrix}\right]$ y para $S = \left[\begin{smallmatrix} 5 & 4 \\ 4 & 5 \end{smallmatrix}\right]$, el conjunto $\{x : \|x\|_S = 1\}$, indicando las direcciones y las longitudes de los semiejes. Dibujar en el mismo gráfico la circunferencia unitaria euclídea.

(d) Probar que $\langle x, y\rangle_S := x^T S y$ cumple las propiedades del producto escalar que usamos en el Capítulo 3: es bilineal, simétrico y $\langle x, x\rangle_S > 0$ para $x \neq 0$. Probar además que $\|x\|_S^2 = \langle x, x\rangle_S$ y que vale la desigualdad de Cauchy-Schwarz $|\langle x, y\rangle_S| \leq \|x\|_S \|y\|_S$. *Sugerencia:* $\langle x, y\rangle_S = (S^{1/2}x)^T(S^{1/2}y)$ reduce todo al caso euclídeo.

(e) Dibujar la elipse $x^2 + xy + y^2 = 1$ y calcular las longitudes de sus ejes a partir de los autovalores de la matriz S correspondiente. ¿Cuál es el área encerrada? *Sugerencia:* el área de una elipse de semiejes a y b es πab; expresarla en términos de $\det S$.

(f) Sea $A \in \mathbb{R}^{m\times n}$ con columnas independientes y $S = A^T A$. Probar que $\|x\|_S = \|Ax\|$. Interpretar geométricamente: la elipse $\{x : \|x\|_S = 1\}$ es la preimagen por A de la esfera unitaria de $\mathbb{R}^m$.

Se entrega por escrito. En el Capítulo 7 veremos que $\|\cdot\|_S$ es un caso particular de una noción general de norma, y que el producto $\langle\cdot,\cdot\rangle_S$ del ítem (d) es el ejemplo estándar de producto interno no euclídeo.

6.6 Formas cuadráticas, mínimos y el Hessiano

Observación 6.28 (Sobre esta sección)**.** Es la única del capítulo que usa cálculo en varias variables —gradientes, matrices Hessianas, desarrollo de Taylor de segundo orden—. Nada de lo que viene después del capítulo depende de ella, así que puede leerse en diagonal, o dejarse para el final, sin que eso afecte a la SVD, a las componentes principales ni a nada de lo que sigue. Dicho esto, es la sección que explica de dónde viene el nombre "definida

positiva" y por qué estas matrices son las que separan los problemas de optimización fáciles de los difíciles. Quien no haya visto el Hessiano puede quedarse sólo con el Teorema 6.29, cuya demostración es algebraica y no usa derivadas en ningún lado.

La otra lectura de las matrices sdp es la de la optimización, y es la que justifica el nombre "energía" para $x^T S x$.

Empecemos por el caso más simple. Dada $S \in \mathbb{R}^{n\times n}$ simétrica y $b \in \mathbb{R}^n$, consideremos

$$J(x) = \tfrac{1}{2}\, x^T S x - b^T x,$$

que es la versión n-dimensional de $\frac{1}{2}sx^2 - bx$. Si S es sdp, esta función tiene un mínimo global, es único y se calcula resolviendo un sistema lineal.

Teorema 6.29. Sea $S \in \mathbb{R}^{n\times n}$ sdp y $b \in \mathbb{R}^n$. Entonces $J(x) = \frac{1}{2}x^T S x - b^T x$ tiene un único mínimo global, alcanzado en la solución x^* de

$$S x^* = b,$$

y el valor mínimo es $J(x^*) = -\frac{1}{2}\,(x^*)^T S x^* = -\frac{1}{2}\, b^T S^{-1} b$.

Demostración. Como S es invertible, $x^* = S^{-1}b$ está bien definido. Para cualquier $x \in \mathbb{R}^n$ escribamos $x = x^* + h$. Usando $Sx^* = b$ y la simetría de S,

$$\begin{aligned} J(x^*+h) &= \tfrac{1}{2}(x^*+h)^T S(x^*+h) - b^T(x^*+h) \\ &= \tfrac{1}{2}(x^*)^T S x^* + h^T S x^* + \tfrac{1}{2}h^T S h - b^T x^* - b^T h \\ &= \underbrace{\tfrac{1}{2}(x^*)^T S x^* - b^T x^*}_{J(x^*)} + \underbrace{h^T b - b^T h}_{=0} + \tfrac{1}{2}h^T S h = J(x^*) + \tfrac{1}{2}\, h^T S h. \end{aligned}$$

Como S es sdp, $h^T S h > 0$ para todo $h \neq 0$: el mínimo es estricto y único. Finalmente, $J(x^*) = \frac{1}{2}(x^*)^T b - b^T x^* = -\frac{1}{2}(x^*)^T b$. ∎

Observación 6.30 (Resolver un sistema es minimizar)**.** El teorema se lee en los dos sentidos. De izquierda a derecha dice cómo minimizar J: resolver $Sx = b$. De derecha a izquierda dice que resolver un sistema con matriz sdp *es* un problema de minimización, y por eso se le pueden aplicar métodos de optimización. Ésa es la idea del método del *gradiente conjugado*, que es hoy el algoritmo estándar para sistemas sdp grandes y ralos, donde la eliminación gaussiana es impracticable.

Para funciones generales, la conexión pasa por la matriz de derivadas segundas. Si $F : \mathbb{R}^n \to \mathbb{R}$ es dos veces derivable con continuidad, su **matriz Hessiana** en un punto x es

$$H(x) = \begin{bmatrix} \dfrac{\partial^2 F}{\partial x_1^2} & \cdots & \dfrac{\partial^2 F}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial^2 F}{\partial x_n \partial x_1} & \cdots & \dfrac{\partial^2 F}{\partial x_n^2} \end{bmatrix},$$

que es simétrica porque las derivadas cruzadas coinciden. El desarrollo de Taylor de segundo orden alrededor de un punto crítico x_0 (donde $\nabla F(x_0) = 0$) es

$$F(x_0 + h) = F(x_0) + \tfrac{1}{2}\, h^T H(x_0)\, h + o(\|h\|^2),$$

y ahí reaparece exactamente la forma cuadrática del Teorema 6.29. De modo que el criterio de la derivada segunda de una variable, $f''(x_0) > 0$, se generaliza así:

$H(x_0)$ definida positiva	x_0 es un **mínimo** local estricto
$H(x_0)$ definida negativa	x_0 es un **máximo** local estricto
$H(x_0)$ con autovalores de ambos signos	x_0 es un **punto de ensilladura**
$H(x_0)$ singular semidefinida	el criterio no decide

Ejemplo 6.31. Para $F(x,y) = 4x^2 + 12xy + cy^2$ el Hessiano es constante, $H = \left[\begin{smallmatrix} 8 & 12 \\ 12 & 2c \end{smallmatrix}\right]$, y el origen es un punto crítico. Los determinantes principales son $D_1 = 8 > 0$ y $D_2 = 16c - 144$. Entonces $(0,0)$ es un mínimo si $c > 9$, un punto de ensilladura si $c < 9$, y para $c = 9$ la matriz es semidefinida: la función es $(2x+3y)^2$, que vale 0 sobre toda una recta. El gráfico pasa de ser un bol a ser una canaleta y después una montura.

Ejercicio de desarrollo 6.5 | Mínimos y Hessianos

(a) Calcular el gradiente de $J(x) = \frac{1}{2}x^T Sx - b^T x$ con S simétrica y verificar que $\nabla J(x) = Sx - b$ y que el Hessiano de J es S. *Sugerencia:* escribir J en coordenadas y derivar respecto de x_k, prestando atención a que x_k aparece en la fila k y en la columna k.

(b) Probar que si S es simétrica pero *no* definida positiva, entonces J no tiene mínimo: exhibir una dirección h en la que $J(th) \to -\infty$ cuando $t \to \infty$. ¿Qué pasa si S es semidefinida positiva y singular?

(c) Encontrar y clasificar los puntos críticos de $F(x,y) = x^4 + y^4 - 4xy$ usando el Hessiano. ¿En cuáles el criterio decide?

(d) Sea $C \in \mathbb{R}^{m\times m}$ sdp y $A \in \mathbb{R}^{m\times n}$ con columnas independientes. Probar que $S = A^T CA$ es sdp aplicando la condición de la energía a $x^T A^T CAx$. (Esta matriz aparece en casi todos los métodos de elementos finitos y en mínimos cuadrados con pesos.)

Se entrega por escrito. El ítem (d) es la matriz que aparece en casi todos los métodos de elementos finitos y en los problemas de cuadrados mínimos con pesos.

Observación 6.32 (Lo que queda para después). Dos temas centrales quedan pendientes y tienen capítulo propio. El primero es el problema de **mínimos cuadrados**: minimizar $\|Ax - b\|$ cuando el sistema $Ax = b$ no tiene solución. Con lo de este capítulo ya están todas las piezas — la proyección del Capítulo 3, la matriz $A^T A$ que ahora sabemos sdp cuando las columnas de A son independientes, y la factorización QR —, pero conviene tratarlo junto con sus variantes (pesos, regularización, rango deficiente). El segundo es el de las **normas** en general: acá apareció $\|x\|_S = \sqrt{x^T Sx}$ como ejemplo, y en el Capítulo 7 veremos qué tienen en común todas las maneras razonables de medir.

Ejercicios

1. Muestre que si S_1 y S_2 son matrices sdp y $r > 0$ entonces

$$rS_1 + S_2$$

es una matriz sdp.

2. Suponga que $S^T = S$ y $S\boldsymbol{x} = \lambda\boldsymbol{x}$ y $S\boldsymbol{y} = \alpha\boldsymbol{y}$ son reales. Muestre que

$$\boldsymbol{y}^T S\boldsymbol{x} = \lambda \boldsymbol{y}^T\boldsymbol{x} \quad , \quad \boldsymbol{x}^T S\boldsymbol{y} = \alpha \boldsymbol{x}^T\boldsymbol{y} \quad \text{y} \quad \boldsymbol{y}^T S\boldsymbol{x} = \boldsymbol{x}^T S\boldsymbol{y}.$$

Además, muestre que $\boldsymbol{y}^T\boldsymbol{x}$ debe ser cero si $\lambda \neq \alpha$: **autovectores ortogonales.**

3. ¿Cuál o cuáles de S_1, S_2, S_3, S_4 tiene dos autovalores positivos? Use una condición, no calcule los λ. Encuentre también un $\boldsymbol{x}$ para el que $\boldsymbol{x}^T S_1\boldsymbol{x} < 0$ y de este modo probar que S_1 no es definida positiva.

$$S_1 = \begin{bmatrix} 5 & 6 \\ 6 & 7 \end{bmatrix} \quad S_2 = \begin{bmatrix} -1 & -2 \\ -2 & -5 \end{bmatrix} \quad S_3 = \begin{bmatrix} 1 & 10 \\ 10 & 100 \end{bmatrix} \quad S_4 = \begin{bmatrix} 1 & 10 \\ 10 & 101 \end{bmatrix}.$$

4. ¿Para qué números b y c las siguientes matrices son definidas positivas?

$$S = \begin{bmatrix} 1 & b \\ b & 9 \end{bmatrix} \qquad S = \begin{bmatrix} 2 & 4 \\ 4 & c \end{bmatrix} \qquad S = \begin{bmatrix} c & b \\ b & c \end{bmatrix}.$$

Con los pivotes en D y los multiplicadores en L, factorice cada S en LDL^T.

5. He aquí una "prueba" rápida de que los autovalores de toda matriz real A son reales:

$$\textbf{Prueba falsa} \quad A\boldsymbol{x} = \lambda\boldsymbol{x} \quad \text{da} \quad \boldsymbol{x}^T A\boldsymbol{x} = \lambda \boldsymbol{x}^T\boldsymbol{x} \quad \text{así} \quad \lambda = \frac{\boldsymbol{x}^T A\boldsymbol{x}}{\boldsymbol{x}^T\boldsymbol{x}} = \frac{\text{real}}{\text{real}}.$$

Encuentre la falla en este razonamiento, una suposición oculta injustificada. Puede seguir esos pasos con la matriz de rotación de 90° $\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ con $\lambda = i$ y $\boldsymbol{x} = (i, 1)$.

6. Escriba S y B como $\lambda_1\boldsymbol{x}_1\boldsymbol{x}_1^T + \lambda_2\boldsymbol{x}_2\boldsymbol{x}_2^T$ del teorema espectral $Q\Lambda Q^T$:

$$S = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \qquad B = \begin{bmatrix} 9 & 12 \\ 12 & 16 \end{bmatrix} \quad (\text{mantenga } \|\boldsymbol{x}_1\| = \|\boldsymbol{x}_2\| = 1).$$

7. (Recomendado) La siguiente matriz M es antisimétrica y también ortogonal. Luego, todos sus autovalores son imaginarios puros y tienen $|\lambda| = 1$. ($\|M\boldsymbol{x}\| = \|\boldsymbol{x}\|$ para todo $\boldsymbol{x}$ entonces $\|\lambda\boldsymbol{x}\| = \|\boldsymbol{x}\|$ para los autovectores.) Encuentre los cuatro autovalores a partir de la traza de M:

$$M = \frac{1}{\sqrt{3}} \begin{bmatrix} 0 & 1 & 1 & 1 \\ -1 & 0 & -1 & 1 \\ -1 & 1 & 0 & -1 \\ -1 & -1 & 1 & 0 \end{bmatrix} \quad \text{solo puede tener autovalores } i \text{ o } -i.$$

8. Muestre que la siguiente matriz A (**simétrica pero compleja**) tiene solo una recta de autovectores:

$$A = \begin{bmatrix} i & 1 \\ 1 & -i \end{bmatrix} \text{ no es ni siquiera diagonalizable: autovalores } \lambda = 0 \text{ y } 0.$$

$A^T = A$ no es una propiedad especial para las matrices complejas. La buena propiedad es $\overline{A}^T = A$. Entonces todos los autovalores son reales y A tiene n autovectores ortogonales.

9. Esta A es casi simétrica pero sus autovectores están lejos de ser ortogonales:

$$A = \begin{bmatrix} 1 & 10^{-15} \\ 0 & 1 + 10^{-15} \end{bmatrix} \quad \text{tiene autovectores} \quad \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{y} \quad \begin{bmatrix} ? \end{bmatrix}$$

¿Cuál es el ángulo entre los autovectores?

10. *¿Qué matrices simétricas S también son ortogonales?* Las que tienen $S^T = S$ y $S^T = S^{-1}$.

(a) Muestre cómo la simetría y la ortogonalidad llevan a $S^2 = I$.

(b) ¿Cuáles son los autovalores posibles de S? Describa todos los Λ posibles.

Entonces $S = Q\Lambda Q^T$ para una de esas matrices de autovalores Λ y una Q ortogonal.

11. Si S es simétrica, muestre que $A^T S A$ también es simétrica (tome la traspuesta de $A^T S A$). Aquí A es de $m \times n$ y S es de $m \times m$. ¿Es cierto que los autovalores de S coinciden con los de $A^T S A$?

En caso de que A sea cuadrada e invertible, se dice que $A^T S A$ es *congruente* con S.

Tienen la misma cantidad de autovalores positivos, negativos y cero: **Ley de inercia**.

12. He aquí una manera de mostrar que a está *entre* los autovalores λ_1 y λ_2 de S:

$$S = \begin{bmatrix} a & b \\ b & c \end{bmatrix} \qquad \begin{array}{l} \det(S - \lambda I) = \lambda^2 - a\lambda - c\lambda + ac - b^2 \\ \text{es una parábola hacia arriba (debido a } \lambda^2) \end{array}$$

Muestre que $\det(S - \lambda I)$ es negativa en $\lambda = a$. Entonces la parábola cruza el eje a la izquierda y a la derecha de $\lambda = a$. Lo cruza en los dos autovalores de S, que entonces deben encerrar a a.

Los $n - 1$ autovalores de A siempre se encuentran entre los n autovalores de $S = \begin{bmatrix} A & \boldsymbol{b} \\ \boldsymbol{b}^T & c \end{bmatrix}$: es el fenómeno de *entrelazado* de autovalores.

13. La energía $\boldsymbol{x}^T S \boldsymbol{x} = 2x_1x_2$ tiene ciertamente un punto de ensilladura y no un mínimo en $(0, 0)$. ¿Qué matriz simétrica S produce esta energía? ¿Cuáles son sus autovalores?

14. Verifique alguna condición para ver si $A^T A$ es definida positiva en cada caso: A necesita columnas independientes.

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} \quad \text{o} \quad A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 2 & 1 \end{bmatrix} \quad \text{o} \quad A = \begin{bmatrix} 1 & 1 & 2 \\ 1 & 2 & 1 \end{bmatrix}.$$

15. Encuentre la matriz S de 3 por 3 y sus pivotes, rango, autovalores, y determinante que satisface:

$$\begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} \quad \\ \quad S \quad \\ \quad \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 4(x_1 - x_2 + 2x_3)^2.$$

16. Calcule los tres determinantes superiores izquierdos de S para establecer si es definida positiva. Verifique que sus cocientes den el segundo y tercer pivote.

$$\textbf{Pivotes} = \textbf{cocientes de determinantes} \qquad S = \begin{bmatrix} 2 & 2 & 0 \\ 2 & 5 & 3 \\ 0 & 3 & 8 \end{bmatrix}.$$

17. ¿Para qué números c y d son S y T definidas positivas? Verifique sus 3 determinantes:

$$S = \begin{bmatrix} c & 1 & 1 \\ 1 & c & 1 \\ 1 & 1 & c \end{bmatrix} \quad \text{o} \quad T = \begin{bmatrix} 1 & 2 & 3 \\ 2 & d & 4 \\ 3 & 4 & 5 \end{bmatrix}.$$

18. Encuentre una matriz simétrica

$$S = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$$

cuyos elementos cumplan $a > 0$, $c > 0$ y $a + c > 2b$, y que sin embargo tenga un autovalor negativo. (Es decir: esas tres condiciones *no* alcanzan para que S sea definida positiva.)

19. Una matriz definida positiva no puede tener un cero (o peor, un número negativo) en su diagonal principal. Muestre que esta matriz no verifica $\boldsymbol{x}^T S \boldsymbol{x} > 0$:

$$\begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} 4 & 1 & 1 \\ 1 & 0 & 2 \\ 1 & 2 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \text{ no es positiva cuando } (x_1, x_2, x_3) = (\quad , \quad , \quad).$$

20. Justifique el siguiente razonamiento: un elemento s_{jj} de la diagonal de una matriz simétrica S no puede ser menor que *todos* los autovalores de S. En efecto, si lo fuera, $S - s_{jj}I$ tendría todos sus autovalores positivos y sería definida positiva; pero $S - s_{jj}I$ tiene un cero en la diagonal, lo que es imposible por el ejercicio anterior. Concluya que $\lambda_{\min} \le s_{jj} \le \lambda_{\max}$ para todo j.

21. En la factorización de Cholesky $S = A^T A$, con $A = \sqrt{D}L^T$, las raíces cuadradas de los pivotes están en la diagonal de A. Encuentre A (triangular superior) para

$$S = \begin{bmatrix} 9 & 0 & 0 \\ 0 & 1 & 2 \\ 0 & 2 & 8 \end{bmatrix} \quad \text{o} \quad S = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 7 \end{bmatrix}.$$

22. Sin multiplicar $S = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 5 \end{bmatrix} \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix}$, encontrar

(a) el determinante de S (b) los autovalores de S
(c) los autovectores de S (d) una razón por la que S es simétrica y definida positiva.

23. ¿Para cuáles a y c es esta matriz definida positiva? ¿Para cuáles a y c es semidefinida positiva (esto incluye definida)?

$$S = \begin{bmatrix} a & a & a \\ a & a+c & a-c \\ a & a-c & a+c \end{bmatrix}$$

Las 5 condiciones son posibles.
La energía $\boldsymbol{x}^T S \boldsymbol{x}$ es igual a
$a\,(x_1 + x_2 + x_3)^2 + c\,(x_2 - x_3)^2$.

7 CAPÍTULO

Distancias, normas y productos internos

Hasta acá medimos siempre de la misma manera. La longitud de un vector de $\mathbb{R}^n$ fue $\|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^T\boldsymbol{x}}$, el ángulo salió del producto $\boldsymbol{x}^T\boldsymbol{y}$, y ortogonal quiso decir $\boldsymbol{x}^T\boldsymbol{y} = 0$. Con eso alcanzó para construir proyecciones, bases ortonormales, la factorización QR y el teorema espectral.

Este capítulo hace dos cosas. La primera es separar lo esencial del ropaje: ¿qué propiedades de $\boldsymbol{x}^T\boldsymbol{y}$ usamos realmente en el Capítulo 3? Resulta que muy pocas, y que cualquier función que las cumpla — un *producto interno* — da lugar a la misma geometría, con sus ángulos, su Pitágoras y sus proyecciones. Lo mismo pasa un escalón más abajo: hay muchas maneras razonables de medir longitudes (*normas*) y de medir distancias, y conviene saber cuáles vienen de un producto interno y cuáles no.

La segunda es más concreta y es la que da sentido a la primera. En el Capítulo 6 apareció, casi de contrabando, la expresión $\|\boldsymbol{x}\|_S = \sqrt{\boldsymbol{x}^T S\boldsymbol{x}}$ con S sdp, y la elipse $\boldsymbol{x}^T S\boldsymbol{x} = 1$. Veremos que *ésos son todos los productos internos de* $\mathbb{R}^n$: elegir un producto interno en $\mathbb{R}^n$ es exactamente elegir una matriz sdp. Y entonces cada matriz sdp trae su propia noción de perpendicularidad, sus propios ángulos y sus propias proyecciones, distintas de las euclídeas. La elipse de S es el dibujo que hay que mirar para entender esa geometría: es la circunferencia de ese producto interno.

Esto no es una curiosidad. Los cuadrados mínimos con pesos, la distancia de Mahalanobis en estadística, los métodos de elementos finitos y el gradiente conjugado son todos el mismo movimiento: cambiar I por S y rehacer la geometría.

7.1 Distancias

Empezamos con lo mínimo: un conjunto $\mathbb{X} \neq \emptyset$, sin estructura alguna.

Definición 7.1. Una función $d : \mathbb{X} \times \mathbb{X} \to \mathbb{R}$ es una **distancia** (o *métrica*) en $\mathbb{X}$ si para todo $\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{z} \in \mathbb{X}$:

(d1) $d(\boldsymbol{x}, \boldsymbol{y}) = d(\boldsymbol{y}, \boldsymbol{x})$ (simetría)

(d2) $d(\boldsymbol{x}, \boldsymbol{y}) \geq 0$, y $d(\boldsymbol{x}, \boldsymbol{y}) = 0$ si y sólo si $\boldsymbol{x} = \boldsymbol{y}$ (confiabilidad)

(d3) $d(\boldsymbol{x}, \boldsymbol{z}) \leq d(\boldsymbol{x}, \boldsymbol{y}) + d(\boldsymbol{y}, \boldsymbol{z})$ (desigualdad triangular)

El par $(\mathbb{X}, d)$ se llama **espacio métrico**.

El nombre que le ponemos a (d2) merece una palabra, porque no es el habitual. Lo que dice la propiedad es que la distancia *no miente*: nunca devuelve un número negativo, y si devuelve cero es porque los dos puntos son efectivamente el mismo. Sin ella uno

podría tener dos puntos distintos a distancia cero —indistinguibles para la regla con la que estamos midiendo, aunque no sean iguales— y entonces no se podría confiar en lo que la distancia informa. De ahí *confiabilidad*.

Los ejemplos clásicos son $\mathbb{X} = \mathbb{R}$ con $d(x, y) = |x - y|$ y $\mathbb{X} = \mathbb{R}^n$ con la distancia euclídea

$$d_2(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2},$$

pero en $\mathbb{R}^n$ también son distancias

$$d_1(\boldsymbol{x}, \boldsymbol{y}) = \sum_{i=1}^{n} |x_i - y_i| \qquad \text{y} \qquad d_\infty(\boldsymbol{x}, \boldsymbol{y}) = \max_i |x_i - y_i|.$$

La primera se llama a veces *distancia del taxista*: en una ciudad cuadriculada uno no puede ir en diagonal.

Estas tres tienen algo en común que la definición no pide: sólo dependen de la *diferencia* $\boldsymbol{x} - \boldsymbol{y}$. Eso es lo que las hace provenir de una norma, y es el tema de la sección siguiente. Que no toda distancia es así se ve con la **distancia discreta** sobre cualquier conjunto,

$$d(\boldsymbol{x}, \boldsymbol{y}) = \begin{cases} 1, & \boldsymbol{x} \neq \boldsymbol{y} \\ 0, & \boldsymbol{x} = \boldsymbol{y}, \end{cases} \tag{7.1}$$

que ni siquiera necesita que $\mathbb{X}$ sea un espacio vectorial.

7.2 Normas

Definición 7.2. Sea $\mathbb{V}$ un espacio vectorial sobre $\mathbb{R}$. Una función $\|\cdot\| : \mathbb{V} \to \mathbb{R}$ es una **norma** si para todo $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}$ y $c \in \mathbb{R}$:

(n1) $\|c\boldsymbol{x}\| = |c|\,\|\boldsymbol{x}\|$ (homogeneidad)

(n2) $\|\boldsymbol{x}\| \geq 0$, y $\|\boldsymbol{x}\| = 0$ si y sólo si $\boldsymbol{x} = 0$ (confiabilidad)

(n3) $\|\boldsymbol{x} + \boldsymbol{y}\| \leq \|\boldsymbol{x}\| + \|\boldsymbol{y}\|$ (desigualdad triangular)

El par $(\mathbb{V}, \|\cdot\|)$ es un **espacio vectorial normado**.

La propiedad (n2) es la (d2) de recién leída sobre un espacio vectorial, y le damos el mismo nombre por la misma razón: una "norma" que le asignara tamaño cero a un vector no nulo no serviría para medir nada.

Toda norma induce una distancia:

$$d(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\|, \tag{7.2}$$

como se verifica en el Ejercicio 1. Las tres distancias de la sección anterior vienen, respectivamente, de

$$\|\boldsymbol{x}\|_1 = \sum_{i=1}^{n} |x_i|, \qquad \|\boldsymbol{x}\|_2 = \left(\sum_{i=1}^{n} |x_i|^2 \right)^{1/2}, \qquad \|\boldsymbol{x}\|_\infty = \max_{i=1,\ldots,n} |x_i|, \tag{7.3}$$

que son los tres casos destacados de la **familia** ℓ^p

$$\|\boldsymbol{x}\|_p = \left(\sum_{i=1}^{n} |x_i|^p\right)^{1/p}, \qquad 1 \le p < \infty,$$

con $\|\boldsymbol{x}\|_\infty = \lim_{p\to\infty} \|\boldsymbol{x}\|_p$. Que $\|\cdot\|_p$ cumpla la desigualdad triangular no es evidente para $p \neq 1, 2, \infty$: esa es la *desigualdad de Minkowski*, y sale de la desigualdad de Hölder del Ejercicio 15.

7.2.1 Las bolas unitarias

La forma más útil de comparar normas es mirar sus **bolas unitarias**

$$B_{\|\cdot\|} = \{\boldsymbol{x} \in \mathbb{R}^n : \|\boldsymbol{x}\| \le 1\}.$$

En $\mathbb{R}^2$, la de $\|\cdot\|_2$ es el disco de siempre; la de $\|\cdot\|_1$ es el cuadrado de vértices $(\pm 1, 0)$, $(0, \pm 1)$; la de $\|\cdot\|_\infty$ es el cuadrado de vértices $(\pm 1, \pm 1)$ (Figura 7.1).

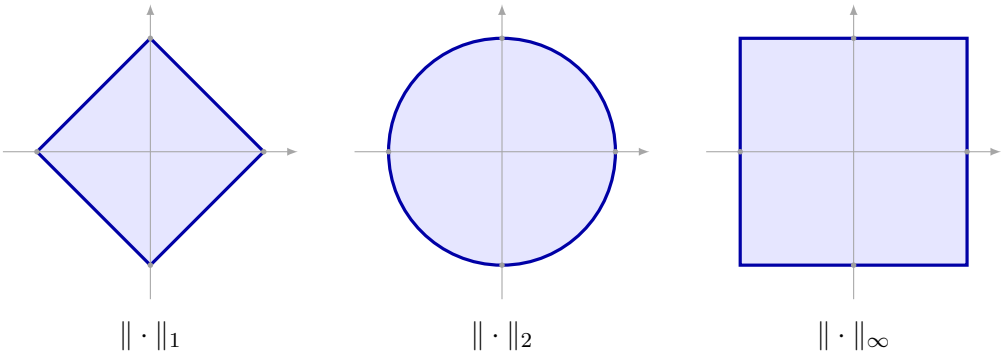


Figura 7.1. Las bolas unitarias de $\|\cdot\|_1$, $\|\cdot\|_2$ y $\|\cdot\|_\infty$ en $\mathbb{R}^2$. Están encajadas, $B_1 \subseteq B_2 \subseteq B_\infty$, y esas inclusiones son exactamente las desigualdades $\|\boldsymbol{x}\|_\infty \le \|\boldsymbol{x}\|_2 \le \|\boldsymbol{x}\|_1$: cuanto más chica la bola, más grande la norma.

Las tres bolas son convexas y simétricas respecto del origen; eso no es casualidad — lo garantizan (n3) y (n1) — y de hecho toda región convexa, simétrica y acotada con el origen en su interior es la bola unitaria de alguna norma. Las diferencias entre ellas están en las esquinas, y son las que importan en la práctica: la bola de ℓ^1 tiene vértices sobre los ejes coordenados, es decir en vectores con coordenadas nulas.

Observación 7.3 (Por qué ℓ^1 produce soluciones ralas)**.** Supongamos que buscamos, entre todos los $\boldsymbol{v}$ de una recta dada del plano, el de norma mínima. Geométricamente: inflamos la bola unitaria hasta que toque la recta. Con $\|\cdot\|_2$ el contacto ocurre en un punto cualquiera, donde el disco es suave. Con $\|\cdot\|_1$ el contacto ocurre casi siempre en un *vértice* del rombo, o sea en un vector con una coordenada igual a cero. Esa observación — que se generaliza a $\mathbb{R}^n$, donde los vértices de B_1 tienen $n-1$ coordenadas nulas — es la razón de fondo por la que penalizar con $\|\cdot\|_1$ en un problema de ajuste (el método conocido como *lasso*) selecciona automáticamente unas pocas variables, mientras que penalizar con $\|\cdot\|_2$ (*ridge*) achica todos los coeficientes sin anular ninguno. Es la Entrega 7.1.

7.2.2 Normas equivalentes

Las desigualdades que se leen en la Figura 7.1 se pueden dar vuelta y acotar en los dos sentidos: en $\mathbb{R}^n$ vale

$$\|\boldsymbol{x}\|_\infty \le \|\boldsymbol{x}\|_2 \le \sqrt{n}\,\|\boldsymbol{x}\|_\infty, \qquad \|\boldsymbol{x}\|_2 \le \|\boldsymbol{x}\|_1 \le \sqrt{n}\,\|\boldsymbol{x}\|_2.$$

Dos normas $\|\cdot\|_a$ y $\|\cdot\|_b$ sobre un mismo espacio se dicen **equivalentes** si existen constantes $0 < c \le C$ con

$$c\,\|\boldsymbol{x}\|_a \le \|\boldsymbol{x}\|_b \le C\,\|\boldsymbol{x}\|_a \qquad \text{para todo } \boldsymbol{x}.$$

Vale el siguiente teorema, que no demostraremos porque requiere argumentos de compacidad que exceden estas notas.

Teorema 7.4. En un espacio vectorial de dimensión finita, todas las normas son equivalentes.

La consecuencia práctica es grande: en $\mathbb{R}^n$, una sucesión converge en una norma si y sólo si converge en cualquier otra, y al mismo límite. Uno puede entonces elegir la norma que le resulte más cómoda para estimar, sin cambiar qué converge y qué no. (En dimensión infinita el teorema es falso, y ahí la elección de la norma sí cambia el problema.)

Ejercicio de desarrollo 7.1 | Bolas unitarias y soluciones ralas

Trabajamos en $\mathbb{R}^2$ salvo aviso.

(a) Dibujar con cuidado B_1, B_2 y B_∞ en un mismo gráfico. Probar las inclusiones $B_1 \subseteq B_2 \subseteq B_\infty$ y escribir las desigualdades entre normas equivalentes a ellas.

(b) Probar que en $\mathbb{R}^n$ valen $\|\boldsymbol{x}\|_\infty \le \|\boldsymbol{x}\|_2 \le \sqrt{n}\,\|\boldsymbol{x}\|_\infty$ y $\|\boldsymbol{x}\|_2 \le \|\boldsymbol{x}\|_1 \le \sqrt{n}\,\|\boldsymbol{x}\|_2$, indicando en cada una para qué vectores hay igualdad. *Sugerencia:* para la última, aplicar Cauchy-Schwarz a $\boldsymbol{x}$ y al vector de signos de sus coordenadas.

(c) Sea $L = \{\boldsymbol{v} \in \mathbb{R}^2 : a_1 v_1 + a_2 v_2 = 1\}$ una recta que no pasa por el origen, con $a_1, a_2 > 0$ distintos. Calcular el mínimo de $\|\boldsymbol{v}\|_2$ sobre L y el punto donde se alcanza. Repetir con $\|\boldsymbol{v}\|_1$ y con $\|\boldsymbol{v}\|_\infty$.

(d) Interpretar el ítem (c) geométricamente: el mínimo se alcanza donde la bola $\{\|\boldsymbol{v}\| \le t\}$, al inflarse, toca L por primera vez. Explicar por qué con $\|\cdot\|_1$ el contacto ocurre en un vértice del rombo — salvo para pendientes excepcionales que hay que identificar — y por qué eso significa que el minimizador tiene una coordenada nula.

(e) Generalizar en palabras a $\mathbb{R}^n$: describir los vértices de B_1 y decir cuántas coordenadas nulas tiene un vector que esté en uno de ellos. Explicar en una o dos frases por qué penalizar con $\|\cdot\|_1$ selecciona variables (*lasso*) y penalizar con $\|\cdot\|_2$ no (*ridge*).

(f) Verificar que $\|\boldsymbol{x}\|_p$ *no* es una norma para $0 < p < 1$, usando $\boldsymbol{x} = (1, 0)$ e $\boldsymbol{y} = (0, 1)$. ¿Qué le pasa a la "bola unitaria" en ese caso?

Se entrega por escrito. Los ítems (d) y (e) son la explicación geométrica estándar de por qué la regularización ℓ^1 produce modelos ralos.

7.2.3 Normas de matrices

Como $\mathbb{R}^{m\times n}$ es un espacio vectorial de dimensión mn, todo lo anterior se aplica a matrices sin cambiar una coma: alcanza con leer una matriz como un vector largo. Así se obtiene la **norma de Frobenius** que ya definimos en la Sección 1.3.6,

$$\|A\|_F = \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}^2} = \sqrt{\operatorname{tr}(A^TA)},$$

que no es otra cosa que la norma $\|\cdot\|_2$ de $\mathbb{R}^{mn}$.

Hay otra manera de medir una matriz, que no viene de olvidarse de que es una matriz sino justamente de usarlo: mirar cuánto estira. Es la **norma espectral**

$$\|A\|_2 = \max_{\|\boldsymbol{x}\|_2=1} \|A\boldsymbol{x}\|_2 = \max_{\boldsymbol{x}\neq 0} \frac{\|A\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2}.$$

Acá hay algo que podría pasar desapercibido: *ese máximo ya sabemos que existe*. No hace falta esperar a ningún capítulo posterior. En efecto, si $\|\boldsymbol{x}\|_2 = 1$,

$$\|A\boldsymbol{x}\|_2^2 = (A\boldsymbol{x})^T(A\boldsymbol{x}) = \boldsymbol{x}^T(A^TA)\boldsymbol{x},$$

y A^TA es simétrica y semidefinida positiva, de modo que el Teorema 6.13 del Capítulo 6 dice que el máximo de esa energía sobre la esfera unitaria es $\lambda_1(A^TA)$, alcanzado en el autovector correspondiente. Es decir,

$$\|A\|_2 = \sqrt{\lambda_1(A^TA)}. \tag{7.4}$$

Lo que falta no es la existencia sino el *nombre* y la factorización que lo acompaña: a ese número se lo llama el mayor *valor singular* de A y se lo escribe σ_1, y de ahí en adelante empieza el Capítulo 8. La familia general de normas definidas por un máximo como éste —una por cada norma vectorial— es el tema del Capítulo 12.

El caso simétrico sale del mismo teorema y conviene hacerlo acá, porque hay una trampa.

Proposición 7.5. Si $S \in \mathbb{R}^{n\times n}$ es simétrica con autovalores $\lambda_1, \ldots, \lambda_n$, entonces

$$\|S\|_2 = \max_i |\lambda_i|.$$

Demostración. Por (7.4) con $A = S$, es $\|S\|_2^2 = \lambda_1(S^TS) = \lambda_1(S^2)$. Ahora bien, si $S = Q\Lambda Q^T$ es el teorema espectral, entonces $S^2 = Q\Lambda^2Q^T$: los autovalores de S^2 son los λ_i^2, con los mismos autovectores. El mayor de ellos es $\max_i \lambda_i^2$, y tomando raíz cuadrada queda $\max_i |\lambda_i|$. ∎

Observación 7.6 (Dos máximos que no son el mismo)**.** Para una matriz simétrica conviven dos cantidades que es fácil confundir:

$$\max_{\|\boldsymbol{x}\|_2=1} \boldsymbol{x}^TS\boldsymbol{x} = \lambda_1 \qquad \text{y} \qquad \max_{\|\boldsymbol{x}\|_2=1} \|S\boldsymbol{x}\|_2 = \max_i |\lambda_i|.$$

La primera es el máximo de la *energía* y lleva el signo; la segunda es el máximo *estiramiento* y mira el módulo. Coinciden si S es semidefinida positiva —ahí todos los autovalores son ≥ 0— y en general no: para $S = \operatorname{diag}(1, -5)$ la energía máxima es 1 y la norma espectral es 5. La primera es el Teorema 6.13 tal cual; la segunda es ese teorema aplicado a S^2, que es donde desaparecen los signos.

7.2.4 ¿Toda distancia viene de una norma?

No. Ya vimos que una distancia puede vivir en un conjunto que ni siquiera es un espacio vectorial, y aun sobre un espacio vectorial la distancia discreta (7.1) no puede provenir de ninguna norma: si viniera de $\|\cdot\|$, tendríamos $d(2\boldsymbol{x}, \mathbf{0}) = 2\, d(\boldsymbol{x}, \mathbf{0})$ para todo $\boldsymbol{x}$, imposible si d sólo toma los valores 0 y 1. Las dos propiedades que delatan a las que sí provienen de una norma son precisamente las que acabamos de usar.

Teorema 7.7. Sea $\mathbb{V}$ un espacio vectorial y d una distancia en $\mathbb{V}$. Entonces d es inducida por alguna norma si y sólo si para todos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}$ satisface

(a) $d(\boldsymbol{x} + \boldsymbol{a}, \boldsymbol{y} + \boldsymbol{a}) = d(\boldsymbol{x}, \boldsymbol{y})$ para todo $\boldsymbol{a} \in \mathbb{V}$ (invarianza traslacional)

(b) $d(\lambda \boldsymbol{x}, \lambda \boldsymbol{y}) = |\lambda|\, d(\boldsymbol{x}, \boldsymbol{y})$ para todo $\lambda \in \mathbb{R}$ (homogeneidad)

En ese caso la norma es $\|\boldsymbol{x}\| = d(\boldsymbol{x}, \mathbf{0})$.

La prueba es el Ejercicio 6.

7.3 Productos internos

Definición 7.8. Sea $\mathbb{V}$ un espacio vectorial sobre $\mathbb{R}$. Una función $\langle \cdot, \cdot \rangle : \mathbb{V} \times \mathbb{V} \to \mathbb{R}$ es un **producto interno** si para todo $\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{z} \in \mathbb{V}$ y $c \in \mathbb{R}$:

(p1) $\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \langle \boldsymbol{y}, \boldsymbol{x} \rangle$

(p2) $\langle c\boldsymbol{x}, \boldsymbol{y} \rangle = c \langle \boldsymbol{x}, \boldsymbol{y} \rangle$

(p3) $\langle \boldsymbol{x} + \boldsymbol{y}, \boldsymbol{z} \rangle = \langle \boldsymbol{x}, \boldsymbol{z} \rangle + \langle \boldsymbol{y}, \boldsymbol{z} \rangle$

(p4) $\langle \boldsymbol{x}, \boldsymbol{x} \rangle \geq 0$, y $\langle \boldsymbol{x}, \boldsymbol{x} \rangle = 0$ si y sólo si $\boldsymbol{x} = 0$

Los ítems (p2) y (p3) dicen que $\langle \cdot, \cdot \rangle$ es lineal en la primera variable; por (p1) también lo es en la segunda. Es decir: una forma bilineal, simétrica y definida positiva.

Ejemplo 7.9. Tres ejemplos que ya conocemos, cada uno en su espacio:

(1) El **producto escalar usual** en $\mathbb{R}^n$, $\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^T \boldsymbol{y} = \sum_i x_i y_i$, que es el del Capítulo 3.

(2) El **producto asociado a una matriz sdp**: si $S \in \mathbb{R}^{n \times n}$ es sdp, $\langle \boldsymbol{x}, \boldsymbol{y} \rangle_S = \boldsymbol{x}^T S \boldsymbol{y}$ es un producto interno en $\mathbb{R}^n$ (Entrega 6.4, ítem (d)). Con $S = I$ se recupera el anterior.

(3) El **producto de Frobenius** en $\mathbb{R}^{m \times n}$, $\langle A, B \rangle_F = \operatorname{tr}(A^T B)$, de la Sección 1.3.6.

Todo producto interno trae consigo una longitud:

$$\|\boldsymbol{x}\| = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x} \rangle}. \tag{7.5}$$

Que esto sea efectivamente una norma lo probaremos enseguida. Lo importante es lo que viene primero.

7.3.1 Todo el Capítulo 3, otra vez

En el Capítulo 3 probamos, para $\mathbb{R}^n$ con el producto usual, la desigualdad de Cauchy-Schwarz (Teorema 3.1), la desigualdad triangular, el teorema de Pitágoras (Teorema 3.4) y la definición del ángulo por $\cos\theta = \boldsymbol{x}^T\boldsymbol{y}/(\|\boldsymbol{x}\|\|\boldsymbol{y}\|)$. Vale la pena releer aquellas demostraciones con esta pregunta en la cabeza: *¿en qué lugar se usó que el espacio era $\mathbb{R}^n$, o que el producto era $\sum_i x_i y_i$?*

La respuesta es: en ninguno. Todas las cuentas fueron desarrollar cuadrados, sacar escalares afuera y usar que $\|\boldsymbol{v}\|^2 \geq 0$ — es decir, exactamente (p1)–(p4). Por lo tanto:

Teorema 7.10 (Cauchy-Schwarz)**.** Sea $\mathbb{V}$ un espacio vectorial con producto interno y $\|\cdot\|$ la norma (7.5). Entonces, para todos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}$,

$$|\langle \boldsymbol{x}, \boldsymbol{y}\rangle| \leq \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|,$$

con igualdad si y sólo si $\boldsymbol{x}$ e $\boldsymbol{y}$ son linealmente dependientes.

Demostración. Es, palabra por palabra, la demostración del Teorema 3.1: si $\boldsymbol{x} = 0$ no hay nada que probar, y si no, el polinomio

$$p(t) = \|t\boldsymbol{x} + \boldsymbol{y}\|^2 = t^2\|\boldsymbol{x}\|^2 + 2t\,\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2$$

es no negativo para todo t, luego su discriminante $4\langle \boldsymbol{x}, \boldsymbol{y}\rangle^2 - 4\|\boldsymbol{x}\|^2\|\boldsymbol{y}\|^2$ es ≤ 0. Hay igualdad exactamente cuando p tiene una raíz doble t_0, es decir cuando $\boldsymbol{y} = -t_0\boldsymbol{x}$. ∎

Teorema 7.11 (Pitágoras)**.** Si $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = 0$, entonces $\|\boldsymbol{x} \pm \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2$.

Demostración. La del Teorema 3.4: desarrollar $\|\boldsymbol{x} \pm \boldsymbol{y}\|^2 = \langle \boldsymbol{x} \pm \boldsymbol{y}, \boldsymbol{x} \pm \boldsymbol{y}\rangle = \|\boldsymbol{x}\|^2 \pm 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2$ y anular el término del medio. ∎

Con Cauchy-Schwarz podemos definir el **ángulo** entre dos vectores no nulos de $\mathbb{V}$ por

$$\cos\theta = \frac{\langle \boldsymbol{x}, \boldsymbol{y}\rangle}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} \in [-1, 1], \tag{7.6}$$

y decimos que $\boldsymbol{x}$ e $\boldsymbol{y}$ son **ortogonales**, $\boldsymbol{x} \perp \boldsymbol{y}$, cuando $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = 0$. Insistimos en el punto, porque es el que usaremos en todo lo que sigue: *cambiar el producto interno cambia qué vectores son ortogonales y cuánto mide el ángulo entre dos vectores dados.*

Recién ahora podemos cerrar la promesa pendiente.

Teorema 7.12. Si $\mathbb{V}$ tiene un producto interno, entonces $\|\boldsymbol{x}\| = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x}\rangle}$ es una norma en $\mathbb{V}$.

Demostración. (n2) es exactamente (p4). Para (n1),

$$\|c\boldsymbol{x}\| = \sqrt{\langle c\boldsymbol{x}, c\boldsymbol{x}\rangle} = \sqrt{c^2\langle \boldsymbol{x}, \boldsymbol{x}\rangle} = |c|\,\|\boldsymbol{x}\|,$$

usando (p2) en las dos variables. Para (n3), desarrollamos el cuadrado y acotamos el término cruzado con Cauchy-Schwarz:

$$\|\boldsymbol{x} + \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2 \leq \|\boldsymbol{x}\|^2 + 2\|\boldsymbol{x}\|\,\|\boldsymbol{y}\| + \|\boldsymbol{y}\|^2 = (\|\boldsymbol{x}\| + \|\boldsymbol{y}\|)^2.$$ ∎

7.3.2 ¿Toda norma viene de un producto interno?

Tampoco. Y el criterio para decidirlo es una identidad puramente métrica.

Proposición 7.13. Sea $\mathbb{V}$ un espacio con producto interno y $\|\cdot\|$ la norma (7.5). Entonces, para $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{V}$,

(a) **Ley del paralelogramo:** $\|\boldsymbol{x}+\boldsymbol{y}\|^2 + \|\boldsymbol{x}-\boldsymbol{y}\|^2 = 2\big(\|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2\big)$.

(b) **Identidad de polarización:** $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \frac{1}{4}\big(\|\boldsymbol{x}+\boldsymbol{y}\|^2 - \|\boldsymbol{x}-\boldsymbol{y}\|^2\big)$.

Demostración. Desarrollando, $\|\boldsymbol{x} \pm \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 \pm 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2$. Sumando las dos igualdades sale (a); restándolas, (b). ∎

Las dos dicen cosas distintas y conviene no confundirlas. La ley del paralelogramo es una *restricción* sobre la norma: relaciona las diagonales de un paralelogramo con sus lados, y no toda norma la cumple. La identidad de polarización es una *fórmula de recuperación*: muestra que el producto interno queda determinado por su norma, de modo que no puede haber dos productos internos distintos con la misma norma.

Ejemplo 7.14. En $\mathbb{R}^2$ con $\|\cdot\|_\infty$, tomemos $\boldsymbol{x} = (1,0)^T$ e $\boldsymbol{y} = (0,1)^T$. Entonces $\boldsymbol{x}+\boldsymbol{y} = (1,1)^T$ y $\boldsymbol{x}-\boldsymbol{y} = (1,-1)^T$, de modo que

$$\|\boldsymbol{x}+\boldsymbol{y}\|_\infty^2 + \|\boldsymbol{x}-\boldsymbol{y}\|_\infty^2 = 1+1 = 2, \qquad 2\big(\|\boldsymbol{x}\|_\infty^2 + \|\boldsymbol{y}\|_\infty^2\big) = 2(1+1) = 4.$$

La ley del paralelogramo falla, y por el teorema que sigue $\|\cdot\|_\infty$ no proviene de ningún producto interno. El mismo par de vectores sirve para $\|\cdot\|_1$.

Teorema 7.15 (Jordan–von Neumann)**.** Sea $\mathbb{V}$ un espacio vectorial y $\|\cdot\|$ una norma sobre $\mathbb{V}$. Existe un producto interno que induce $\|\cdot\|$ si y sólo si $\|\cdot\|$ satisface la ley del paralelogramo.

Demostración. Si $\|\cdot\|$ viene de un producto interno, la ley vale por la Proposición 7.13.

Supongamos ahora que la norma satisface la ley del paralelogramo. Definimos el candidato a producto interno por la identidad de polarización:

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \tfrac{1}{4}\big(\|\boldsymbol{x}+\boldsymbol{y}\|^2 - \|\boldsymbol{x}-\boldsymbol{y}\|^2\big).$$

Simetría (p1). Como $\|\boldsymbol{w}\| = \|-\boldsymbol{w}\|$, es $\|\boldsymbol{x}+\boldsymbol{y}\| = \|\boldsymbol{y}+\boldsymbol{x}\|$ y $\|\boldsymbol{x}-\boldsymbol{y}\| = \|\boldsymbol{y}-\boldsymbol{x}\|$, de donde $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \langle \boldsymbol{y}, \boldsymbol{x}\rangle$.

Aditividad (p3). Por la ley del paralelogramo aplicada a $\boldsymbol{x}+\boldsymbol{z}$ y $\boldsymbol{y}$,

$$\|\boldsymbol{x}+\boldsymbol{y}+\boldsymbol{z}\|^2 = 2\|\boldsymbol{x}+\boldsymbol{z}\|^2 + 2\|\boldsymbol{y}\|^2 - \|\boldsymbol{x}-\boldsymbol{y}+\boldsymbol{z}\|^2,$$

e intercambiando $\boldsymbol{x}$ con $\boldsymbol{y}$,

$$\|\boldsymbol{x}+\boldsymbol{y}+\boldsymbol{z}\|^2 = 2\|\boldsymbol{y}+\boldsymbol{z}\|^2 + 2\|\boldsymbol{x}\|^2 - \|\boldsymbol{y}-\boldsymbol{x}+\boldsymbol{z}\|^2.$$

Promediando ambas,

$$\|\boldsymbol{x}+\boldsymbol{y}+\boldsymbol{z}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2 + \|\boldsymbol{x}+\boldsymbol{z}\|^2 + \|\boldsymbol{y}+\boldsymbol{z}\|^2 - \tfrac{1}{2}\|\boldsymbol{x}-\boldsymbol{y}+\boldsymbol{z}\|^2 - \tfrac{1}{2}\|\boldsymbol{y}-\boldsymbol{x}+\boldsymbol{z}\|^2.$$

Reemplazando $\boldsymbol{z}$ por $-\boldsymbol{z}$ y usando $\|\boldsymbol{w}\| = \|-\boldsymbol{w}\|$ en los dos últimos términos, que quedan iguales,

$$\|\boldsymbol{x}+\boldsymbol{y}-\boldsymbol{z}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2 + \|\boldsymbol{x}-\boldsymbol{z}\|^2 + \|\boldsymbol{y}-\boldsymbol{z}\|^2 - \tfrac{1}{2}\|\boldsymbol{x}-\boldsymbol{y}-\boldsymbol{z}\|^2 - \tfrac{1}{2}\|\boldsymbol{y}-\boldsymbol{x}-\boldsymbol{z}\|^2.$$

Restando las dos últimas igualdades y dividiendo por 4,

$$\langle \boldsymbol{x}+\boldsymbol{y}, \boldsymbol{z}\rangle = \tfrac{1}{4}\Big(\|\boldsymbol{x}+\boldsymbol{z}\|^2 - \|\boldsymbol{x}-\boldsymbol{z}\|^2\Big) + \tfrac{1}{4}\Big(\|\boldsymbol{y}+\boldsymbol{z}\|^2 - \|\boldsymbol{y}-\boldsymbol{z}\|^2\Big) = \langle \boldsymbol{x}, \boldsymbol{z}\rangle + \langle \boldsymbol{y}, \boldsymbol{z}\rangle.$$

Positividad (p4). Directamente,

$$\langle \boldsymbol{x}, \boldsymbol{x}\rangle = \tfrac{1}{4}\Big(\|2\boldsymbol{x}\|^2 - \|\boldsymbol{0}\|^2\Big) = \tfrac{1}{4}\cdot 4\|\boldsymbol{x}\|^2 = \|\boldsymbol{x}\|^2,$$

que es ≥ 0 y se anula sólo si $\boldsymbol{x} = 0$. De paso, esto confirma que el producto interno construido induce la norma de partida.

Homogeneidad (p2). Es la única parte laboriosa. De la aditividad sale $\langle n\boldsymbol{x}, \boldsymbol{y}\rangle = n\langle \boldsymbol{x}, \boldsymbol{y}\rangle$ para $n \in \mathbb{N}$ por inducción, de ahí para $n \in \mathbb{Z}$ (usando $\langle -\boldsymbol{x}, \boldsymbol{y}\rangle = -\langle \boldsymbol{x}, \boldsymbol{y}\rangle$, que se ve directo en la fórmula), y de ahí para todo racional $q = m/n$ escribiendo $n\langle q\boldsymbol{x}, \boldsymbol{y}\rangle = \langle m\boldsymbol{x}, \boldsymbol{y}\rangle$. Para pasar a los reales se usa que $c \mapsto \langle c\boldsymbol{x}, \boldsymbol{y}\rangle$ es continua, por serlo la norma, y que los racionales son densos. Los detalles son el Ejercicio 14. ∎

7.4 Los productos internos de $\mathbb{R}^n$ son las matrices sdp

Volvemos a $\mathbb{R}^n$, que es donde trabajamos. La pregunta natural es cuántos productos internos hay. La respuesta es completa y es la bisagra de todo el capítulo.

Teorema 7.16. Sea $\langle\cdot,\cdot\rangle$ una función de $\mathbb{R}^n \times \mathbb{R}^n$ en $\mathbb{R}$. Entonces $\langle\cdot,\cdot\rangle$ es un producto interno si y sólo si existe una matriz $S \in \mathbb{R}^{n\times n}$ sdp tal que

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{x}^T S\, \boldsymbol{y} \qquad \text{para todos } \boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n.$$

Además S es única, y está dada por $s_{ij} = \langle e_i, e_j\rangle$.

Demostración. ($\Leftarrow$) Si S es sdp, la simetría (p1) vale porque $\boldsymbol{x}^T S\boldsymbol{y}$ es un número, luego igual a su traspuesta $\boldsymbol{y}^T S^T \boldsymbol{x} = \boldsymbol{y}^T S\boldsymbol{x}$; los ítems (p2) y (p3) son la linealidad del producto de matrices; y (p4) es exactamente la definición de definida positiva.

($\Rightarrow$) Sea $\langle\cdot,\cdot\rangle$ un producto interno y definamos $s_{ij} = \langle e_i, e_j\rangle$. La matriz $S = (s_{ij})$ es simétrica por (p1). Escribiendo $\boldsymbol{x} = \sum_i x_i e_i$ e $\boldsymbol{y} = \sum_j y_j e_j$ y usando la bilinealidad,

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \sum_{i=1}^{n}\sum_{j=1}^{n} x_i y_j \langle e_i, e_j\rangle = \sum_{i,j} x_i s_{ij} y_j = \boldsymbol{x}^T S\boldsymbol{y}.$$

Finalmente, $\boldsymbol{x}^T S\boldsymbol{x} = \langle \boldsymbol{x}, \boldsymbol{x}\rangle > 0$ para $\boldsymbol{x} \neq 0$ por (p4), de modo que S es sdp. La unicidad es inmediata: $s_{ij} = e_i^T S e_j$ está forzado. ∎

La matriz S se llama la **matriz de Gram** del producto interno en la base canónica. Escribiremos de ahora en más

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle_S = \boldsymbol{x}^T S\boldsymbol{y}, \qquad \|\boldsymbol{x}\|_S = \sqrt{\boldsymbol{x}^T S\boldsymbol{x}},$$

como en la Sección 6.5. El caso $S = I$ es el producto usual.

Observación 7.17 (Qué dice el teorema)**.** Elegir una geometría en $\mathbb{R}^n$ — una manera de medir longitudes y ángulos que venga de un producto interno — es exactamente elegir una matriz sdp. No hay más opciones y no hay menos. Y como en el Capítulo 6 vimos que la matriz sdp S está retratada por su elipse $\boldsymbol{x}^T S\boldsymbol{x} = 1$, tenemos también el diccionario geométrico: *la elipse de S es la circunferencia unitaria del producto interno $\langle\cdot,\cdot\rangle_S$*. Todo lo que sigue es leer ese diccionario.

Observación 7.18 (La distancia de Mahalanobis)**.** El ejemplo canónico en estadística: si Σ es la matriz de covarianza de un vector aleatorio, entonces Σ^{-1} es sdp y

$$d_\Sigma(\boldsymbol{x},\boldsymbol{y}) = \|\boldsymbol{x}-\boldsymbol{y}\|_{\Sigma^{-1}} = \sqrt{(\boldsymbol{x}-\boldsymbol{y})^T\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{y})}$$

es la *distancia de Mahalanobis*. Mide en unidades de desviación estándar y en las direcciones propias de los datos: dos puntos separados en una dirección de mucha varianza están, para esta distancia, más cerca que dos puntos igualmente separados en una dirección de poca varianza. Es la distancia euclídea aplicada después de blanquear los datos, que es lo mismo que decir $\|\boldsymbol{v}\|_{\Sigma^{-1}} = \|\Sigma^{-1/2}\boldsymbol{v}\|_2$.

7.5 S-ortogonalidad

Fijemos de acá en adelante $S \in \mathbb{R}^{n\times n}$ sdp, con autovalores $\lambda_1 \geq \cdots \geq \lambda_n > 0$ y base ortonormal de autovectores $\boldsymbol{q}_1,\ldots,\boldsymbol{q}_n$, y sea $S^{1/2}$ su raíz cuadrada (Sección 6.3).

Definición 7.19. Dos vectores $\boldsymbol{x},\boldsymbol{y} \in \mathbb{R}^n$ son **S-ortogonales** (o *conjugados respecto de S*) si

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle_S = \boldsymbol{x}^T S\boldsymbol{y} = 0,$$

y lo escribimos $\boldsymbol{x} \perp_S \boldsymbol{y}$. Una base $\boldsymbol{v}_1,\ldots,\boldsymbol{v}_n$ de $\mathbb{R}^n$ es **S-ortonormal** si $\boldsymbol{v}_i^T S\boldsymbol{v}_j = \delta_{ij}$, es decir, si la matriz $V = [\,\boldsymbol{v}_1\ \cdots\ \boldsymbol{v}_n\,]$ cumple $V^T SV = I$.

La herramienta que traduce todo al caso conocido es la raíz cuadrada:

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle_S = (S^{1/2}\boldsymbol{x})^T(S^{1/2}\boldsymbol{y}), \qquad \|\boldsymbol{x}\|_S = \|S^{1/2}\boldsymbol{x}\|_2. \tag{7.7}$$

En palabras: *la geometría de S es la geometría euclídea vista a través de $S^{1/2}$*. Dos vectores son S-ortogonales exactamente cuando sus imágenes por $S^{1/2}$ son ortogonales en el sentido usual, y una base es S-ortonormal exactamente cuando $S^{1/2}V$ es ortogonal, o sea $V = S^{-1/2}Q$ con Q ortogonal.

7.5.1 Cómo se ve la S-ortogonalidad

El dibujo correcto es la elipse. Recordemos de la Sección 6.5 que

$$E_S = \{\boldsymbol{x} : \boldsymbol{x}^T S\boldsymbol{x} = 1\} = \{\boldsymbol{x} : \|\boldsymbol{x}\|_S = 1\}$$

es un elipsoide de ejes $\boldsymbol{q}_i$ y semiejes $1/\sqrt{\lambda_i}$: la circunferencia unitaria de esta geometría.

Ahora bien, ¿cómo se reconoce un par S-ortogonal *mirando la elipse*? La respuesta clásica: son los **diámetros conjugados**. Sea $\boldsymbol{x} \in E_S$ y consideremos la recta tangente a E_S en $\boldsymbol{x}$. Derivando $\boldsymbol{x}^T S\boldsymbol{x} = 1$ se ve que el vector normal (euclídeo) a esa tangente es $S\boldsymbol{x}$; por lo tanto la tangente tiene dirección $\boldsymbol{y}$ si y sólo si $\boldsymbol{y}^T S\boldsymbol{x} = 0$, es decir si y sólo si $\boldsymbol{y} \perp_S \boldsymbol{x}$. En resumen:

$\boldsymbol{y}$ es S-ortogonal a $\boldsymbol{x}$ si y sólo si $\boldsymbol{y}$ es paralelo a la recta tangente a la elipse E_S en el punto $\boldsymbol{x}$.

Para $S = I$ la elipse es una circunferencia, la tangente es perpendicular al radio, y recuperamos la ortogonalidad de siempre. Para $S \neq I$ la tangente ya no es perpendicular al radio y por eso dos vectores S-ortogonales se ven, al ojo euclídeo, oblicuos (Figura 7.2).

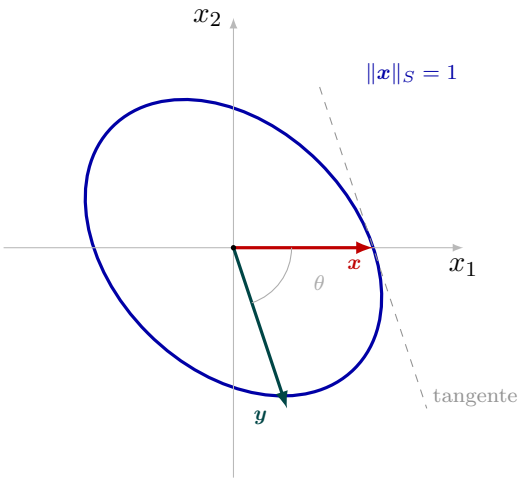


Figura 7.2. S-ortogonalidad para $S = \left[\begin{smallmatrix} 3 & 1 \\ 1 & 3 \end{smallmatrix}\right]$. El vector $\boldsymbol{y}$ es S-ortogonal a $\boldsymbol{x}$: es paralelo a la tangente a la elipse en $\boldsymbol{x}$. Al ojo euclídeo forman un ángulo $\theta \neq 90°$; en la geometría de S son perpendiculares. Si S fuera I la elipse sería una circunferencia y la tangente, perpendicular al radio.

Observación 7.20 (Los autovectores no se enteran). Los autovectores $\boldsymbol{q}_i$ de S son el único par de direcciones que es ortogonal en los dos sentidos a la vez: si $i \neq j$,

$$\boldsymbol{q}_i^T S \boldsymbol{q}_j = \lambda_j \, \boldsymbol{q}_i^T \boldsymbol{q}_j = 0.$$

Son los ejes de la elipse, y una elipse es simétrica respecto de sus ejes. De hecho $\boldsymbol{q}_i/\sqrt{\lambda_i}$ es una base S-ortonormal: ya teníamos la base, sólo hubo que reescalarla.

Ejercicio de desarrollo 7.2 | La geometría de una matriz sdp

Sea $S \in \mathbb{R}^{n\times n}$ sdp con autovalores $\lambda_1 \geq \cdots \geq \lambda_n > 0$ y autovectores ortonormales $\boldsymbol{q}_1, \ldots, \boldsymbol{q}_n$. Trabajamos con $\langle \boldsymbol{x}, \boldsymbol{y} \rangle_S = \boldsymbol{x}^T S \boldsymbol{y}$ y $\|\boldsymbol{x}\|_S = \sqrt{\boldsymbol{x}^T S \boldsymbol{x}}$.

(a) Probar que $\langle \cdot, \cdot \rangle_S$ es un producto interno y que $\|\cdot\|_S$ es una norma. *Sugerencia:* lo segundo sale gratis del Teorema 7.12, o bien de (7.7); hacerlo de las dos maneras.

(b) En la Entrega 6.4 del Capítulo 6 probaron, con el Teorema 6.13, que $\sqrt{\lambda_n}\,\|\boldsymbol{x}\|_2 \leq \|\boldsymbol{x}\|_S \leq \sqrt{\lambda_1}\,\|\boldsymbol{x}\|_2$. Releerlo con el vocabulario de este capítulo: deducir que $\|\cdot\|_S$ y $\|\cdot\|_2$ son *equivalentes* en el sentido de la Sección 7.2.1, que las constantes son óptimas, y que la bola $\{\|\boldsymbol{x}\|_S \leq 1\}$ está encajada entre las bolas euclídeas de radios $1/\sqrt{\lambda_1}$ y $1/\sqrt{\lambda_n}$. ¿Qué norma $\|\cdot\|_S$ da la bola más parecida a la euclídea?

(c) Probar que $\boldsymbol{x} \perp_S \boldsymbol{y}$ si y sólo si $S^{1/2}\boldsymbol{x} \perp S^{1/2}\boldsymbol{y}$ en el sentido euclídeo. Deducir que $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$ es una base S-ortonormal si y sólo si $V = S^{-1/2}Q$ para alguna Q ortogonal, y que por lo tanto hay infinitas.

(d) *(Diámetros conjugados.)* Sea $\boldsymbol{x}$ con $\|\boldsymbol{x}\|_S = 1$. Probar que el vector normal euclídeo a la elipse E_S en el punto $\boldsymbol{x}$ es $S\boldsymbol{x}$, y deducir que $\boldsymbol{y} \perp_S \boldsymbol{x}$ si y sólo si $\boldsymbol{y}$ es paralelo a la tangente a E_S en $\boldsymbol{x}$.

(e) Tomar $S = \left[\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right]$. Dibujar E_S; elegir $\boldsymbol{x} = (1,0)^T/\sqrt{2}$ (verificar que está en E_S); encontrar todos los $\boldsymbol{y}$ con $\boldsymbol{x} \perp_S \boldsymbol{y}$; dibujarlos y comprobar sobre el dibujo que son paralelos a la tangente. Calcular el ángulo euclídeo entre $\boldsymbol{x}$ y esos $\boldsymbol{y}$ y comprobar que no es recto.

(f) Verificar que $\boldsymbol{q}_i \perp_S \boldsymbol{q}_j$ para $i \neq j$ y que $\{\boldsymbol{q}_i/\sqrt{\lambda_i}\}$ es base S-ortonormal. Explicar por qué los autovectores son las únicas direcciones ortogonales en los dos sentidos a la vez, usando el dibujo de la elipse.

Se entrega por escrito. El ítem (c) es la clave de todo: cambiar de producto interno es cambiar de coordenadas por $S^{1/2}$. El (d) explica el dibujo de la Figura 7.2.

7.5.2 Ángulos, Gram-Schmidt y proyecciones

Todo lo que hicimos en el Capítulo 3 se rehace cambiando $\boldsymbol{x}^T\boldsymbol{y}$ por $\boldsymbol{x}^T S\boldsymbol{y}$, porque las demostraciones sólo usaban los axiomas. En particular:

- El **ángulo** S entre $\boldsymbol{x}$ e $\boldsymbol{y}$ no nulos es $\cos\theta_S = \dfrac{\boldsymbol{x}^T S\boldsymbol{y}}{\|\boldsymbol{x}\|_S \|\boldsymbol{y}\|_S}$, y está en $[-1,1]$ por Cauchy-Schwarz para $\langle\cdot,\cdot\rangle_S$.
- **Gram-Schmidt** funciona igual: partiendo de una base cualquiera $\boldsymbol{a}_1, \dots, \boldsymbol{a}_n$ y restando proyecciones S,
$$\boldsymbol{v}_k = \boldsymbol{a}_k - \sum_{j<k} \frac{\langle \boldsymbol{a}_k, \boldsymbol{v}_j\rangle_S}{\langle \boldsymbol{v}_j, \boldsymbol{v}_j\rangle_S}\, \boldsymbol{v}_j,$$
se obtiene una base S-ortogonal, y normalizando con $\|\cdot\|_S$, una S-ortonormal. Todo subespacio tiene base S-ortonormal.
- **Pitágoras** vale con $\perp_S$ y $\|\cdot\|_S$, y es lo que hace que la proyección S sea la mejor aproximación en $\|\cdot\|_S$.

Lo interesante es la proyección, porque ahí la diferencia con el caso euclídeo se vuelve visible en la matriz. Sea $A \in \mathbb{R}^{n\times m}$ con columnas linealmente independientes y sea $W = C(A)$. Queremos, dado $\boldsymbol{x}$, el punto de W más cercano a $\boldsymbol{x}$ *en la métrica de* S; equivalentemente (Pitágoras), el $P_S\boldsymbol{x} \in W$ tal que el error $\boldsymbol{x} - P_S\boldsymbol{x}$ es S-ortogonal a W.

Escribamos $P_S\boldsymbol{x} = A\boldsymbol{c}$ e impongamos la condición. Que el error $\boldsymbol{x} - A\boldsymbol{c}$ sea S-ortogonal a todo $W = C(A)$ equivale a que lo sea a cada elemento de una base de W, es decir, a cada columna $\mathrm{col}_1(A), \dots, \mathrm{col}_m(A)$ de A:

$$\begin{cases} \mathrm{col}_1(A)^T S\,(\boldsymbol{x} - A\boldsymbol{c}) = 0 \\ \qquad\qquad\qquad\qquad\ \vdots \\ \mathrm{col}_m(A)^T S\,(\boldsymbol{x} - A\boldsymbol{c}) = 0 \end{cases}$$

Ahora bien, $\mathrm{col}_j(A)^T$ es la fila j de A^T, de modo que esas m ecuaciones son las m componentes de una sola ecuación matricial:

$$A^T S\,(\boldsymbol{x} - A\boldsymbol{c}) = \mathbf{0}.$$

Distribuyendo llegamos a las **ecuaciones normales pesadas**

$$A^T S A\,\boldsymbol{c} = A^T S \boldsymbol{x}. \tag{7.8}$$

La matriz $A^T S A$ es sdp — es el ítem (f) de la Entrega 6.5 — luego invertible, y despejando:

$$\boxed{P_S = A\,(A^T S A)^{-1} A^T S} \tag{7.9}$$

Con $S = I$ se recupera $P = A(A^T A)^{-1}A^T$ de (3.2). La diferencia de fondo aparece al trasponer:

Proposición 7.21. La matriz P_S de (7.9) cumple $P_S^2 = P_S$ y $C(P_S) = C(A)$, y es autoadjunta para $\langle\cdot,\cdot\rangle_S$, es decir $\langle P_S\boldsymbol{x}, \boldsymbol{y}\rangle_S = \langle \boldsymbol{x}, P_S\boldsymbol{y}\rangle_S$ para todos $\boldsymbol{x}, \boldsymbol{y}$. Esto último equivale a que SP_S sea simétrica. En general $P_S \neq P_S^T$.

Es decir: *P_S es, en general, una proyección oblicua en el sentido euclídeo*, de las que estudiamos en la Entrega 3.1 — $P^2 = P$ pero $P \neq P^T$ —, y sin embargo es una proyección *ortogonal* para la geometría de S. La misma matriz, dos lecturas. El criterio "$P^2 = P$ y $P = P^T$" que caracterizaba a las proyecciones ortogonales se transforma en

$$P^2 = P \quad \text{y} \quad SP = (SP)^T \qquad \Longleftrightarrow \qquad P \text{ es la proyección } S\text{-ortogonal sobre } C(P), \tag{7.10}$$

que con $S = I$ es el criterio de siempre. Todo esto se demuestra en la Entrega 7.3.

Ejemplo 7.22. Proyectemos sobre la recta generada por $\boldsymbol{a} = (1,1)^T$ en $\mathbb{R}^2$, con $S = \mathrm{diag}(1,4)$. La fórmula (7.9) con $A = \boldsymbol{a}$ da $\boldsymbol{a}^T S \boldsymbol{a} = 1 + 4 = 5$, $\boldsymbol{a}^T S = (1,4)$, y

$$P_S = \frac{1}{5}\begin{bmatrix}1\\1\end{bmatrix}\begin{bmatrix}1 & 4\end{bmatrix} = \frac{1}{5}\begin{bmatrix}1 & 4\\ 1 & 4\end{bmatrix}.$$

Se verifica $P_S^2 = P_S$, pero $P_S \neq P_S^T$; en cambio $SP_S = \frac{1}{5}\left[\begin{smallmatrix}1 & 4\\ 4 & 16\end{smallmatrix}\right]$ sí es simétrica. Para $\boldsymbol{x} = (0,1)^T$ resulta $P_S\boldsymbol{x} = \frac{4}{5}(1,1)^T$, mientras que la proyección euclídea sería $\frac{1}{2}(1,1)^T$: el peso 4 en la segunda coordenada hace que el error en esa dirección sea más caro, y la proyección se corre para reducirlo.

Observación 7.23 (Dónde aparece esto)**.** Tres lugares, el mismo cálculo. En **cuadrados mínimos con pesos**, uno minimiza $\sum_i w_i\,(\text{residuo}_i)^2$ en lugar de la suma sin pesos: eso es $\|A\boldsymbol{c} - \boldsymbol{b}\|_S^2$ con $S = \mathrm{diag}(w_1, \ldots, w_n)$, y la solución son las ecuaciones (7.8). Se usa cuando los datos tienen precisiones distintas; el peso óptimo es la inversa de la varianza, y ahí reaparece Mahalanobis. En los **métodos de elementos finitos**, S es la matriz de rigidez y la solución aproximada es la proyección S-ortogonal de la solución exacta sobre el espacio de dimensión finita elegido. Y en el **método del gradiente conjugado** para resolver $S\boldsymbol{x} = \boldsymbol{b}$, las direcciones de búsqueda sucesivas se eligen S-ortogonales entre sí — de ahí el nombre "conjugado" —, y cada paso es exactamente una proyección S-ortogonal.

Ejercicio de desarrollo 7.3 | La proyección S-ortogonal

Sea $S \in \mathbb{R}^{n\times n}$ sdp, $A \in \mathbb{R}^{n\times m}$ con columnas linealmente independientes, y

$$P_S = A(A^TSA)^{-1}A^TS.$$

(a) Probar que A^TSA es sdp, y en particular invertible, de modo que P_S está bien definida. *Sugerencia:* $\boldsymbol{c}^TA^TSA\boldsymbol{c} = \|A\boldsymbol{c}\|_S^2$.

(b) Probar que $P_S^2 = P_S$, que $C(P_S) = C(A)$ y que $P_S\boldsymbol{x} = \boldsymbol{x}$ para todo $\boldsymbol{x} \in C(A)$. Deducir $\operatorname{rg}(P_S) = \operatorname{tr}(P_S) = m$.

(c) Probar que P_S es autoadjunta para $\langle\cdot,\cdot\rangle_S$, es decir $\langle P_S\boldsymbol{x}, \boldsymbol{y}\rangle_S = \langle \boldsymbol{x}, P_S\boldsymbol{y}\rangle_S$ para todos $\boldsymbol{x}, \boldsymbol{y}$, y que esto equivale a que SP_S sea simétrica.

(d) Probar que el error es S-ortogonal al subespacio, en la forma matricial $A^TS\,(\boldsymbol{x} - P_S\boldsymbol{x}) = \boldsymbol{0}$, y explicar por qué esa única igualdad dice exactamente que el error es S-ortogonal a cada columna de A y, por lo tanto, a todo $C(A)$. Deducir la versión S del teorema de la mejor aproximación,

$$\|\boldsymbol{x} - P_S\boldsymbol{x}\|_S \le \|\boldsymbol{x} - \boldsymbol{v}\|_S \qquad \text{para todo } \boldsymbol{v} \in C(A),$$

con igualdad sólo si $\boldsymbol{v} = P_S\boldsymbol{x}$. *Sugerencia:* Pitágoras con $\perp_S$.

(e) Probar que $P_S\boldsymbol{x} = A\hat{\boldsymbol{c}}$ donde $\hat{\boldsymbol{c}}$ resuelve las ecuaciones normales pesadas $A^TSA\,\hat{\boldsymbol{c}} = A^TS\boldsymbol{x}$, y que P_S no depende de la base: si $B = AM$ con M invertible, entonces $B(B^TSB)^{-1}B^TS = P_S$.

(f) *(Recíproco.)* Probar que si $P \in \mathbb{R}^{n\times n}$ cumple $P^2 = P$ y SP simétrica, entonces P es la proyección S-ortogonal sobre $C(P)$.

(g) *(La conexión con las proyecciones oblicuas.)* Probar que $P_S = S^{-1/2}\,\widetilde{P}\,S^{1/2}$, donde $\widetilde{P}$ es la proyección ortogonal euclídea sobre $C(S^{1/2}A)$. Deducir que los autovalores de P_S son 0 y 1, y que $\|P_S\boldsymbol{x}\|_S \le \|\boldsymbol{x}\|_S$ para todo $\boldsymbol{x}$ — aunque, como se vio en la Entrega 3.1, el cociente $\|P_S\boldsymbol{x}\|_2/\|\boldsymbol{x}\|_2$ pueda ser tan grande como se quiera. ¿Contradicción? Explicar.

(h) *(Casos concretos.)*

(i) Con $\boldsymbol{a} = (1,1,1)^T$ (una sola columna) y $S = \operatorname{diag}(1,2,3)$, calcular P_S y describir en palabras qué hace $P_S\boldsymbol{x}$.

(ii) Con $A = \left[\begin{smallmatrix}1&0\\1&1\\0&1\end{smallmatrix}\right]$ y $S = \operatorname{diag}(1,2,1)$, calcular P_S, verificar $P_S^2 = P_S$ y $\operatorname{tr} P_S = 2$, comprobar que $P_S \neq P_S^T$ pero que SP_S sí es simétrica, y comparar con la proyección usual ($S = I$).

(iii) *(Una base S-ortonormal a mano.)* Aplicar Gram-Schmidt con $\langle\cdot,\cdot\rangle_S$ a la base canónica de $\mathbb{R}^2$, con $S = \left[\begin{smallmatrix}2&1\\1&2\end{smallmatrix}\right]$, y verificar que la base obtenida cumple $V^TSV = I$. Dibujarla sobre la elipse E_S y compararla con la base $\{\boldsymbol{q}_i/\sqrt{\lambda_i}\}$ de los autovectores reescalados.

Se entrega por escrito. El ítem (g) es el que explica por qué una misma matriz puede ser "oblicua" y "ortogonal" al mismo tiempo: depende de con qué producto interno se la mire. El (e) es el punto de partida de los cuadrados mínimos con pesos.

7.5.3 Resumen: el mismo capítulo dos veces

	euclídeo $(S = I)$	**geometría de** S
producto	$\boldsymbol{x}^T\boldsymbol{y}$	$\boldsymbol{x}^T S\boldsymbol{y}$
norma	$\|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^T\boldsymbol{x}}$	$\|\boldsymbol{x}\|_S = \sqrt{\boldsymbol{x}^T S\boldsymbol{x}} = \|S^{1/2}\boldsymbol{x}\|$
esfera unitaria	circunferencia	elipse $\boldsymbol{x}^T S\boldsymbol{x} = 1$
ortogonalidad	$\boldsymbol{x}^T\boldsymbol{y} = 0$	$\boldsymbol{x}^T S\boldsymbol{y} = 0$ (diámetros conjugados)
base ortonormal	$Q^TQ = I$	$V^TSV = I$, o sea $V = S^{-1/2}Q$
proyección sobre $C(A)$	$A(A^TA)^{-1}A^T$	$A(A^TSA)^{-1}A^TS$
criterio	$P^2 = P$, $P = P^T$	$P^2 = P$, SP simétrica
ecuaciones normales	$A^TA\boldsymbol{c} = A^T\boldsymbol{b}$	$A^TSA\boldsymbol{c} = A^TS\boldsymbol{b}$

La columna de la derecha no es una generalización gratuita: contiene a la izquierda como el caso $S = I$, y todos sus enunciados se demuestran copiando los de la izquierda, porque las pruebas nunca usaron más que los axiomas del producto interno. Ése es, en definitiva, el argumento a favor de haber definido las cosas abstractamente.

Ejercicios

1. Probar que en un espacio vectorial normado $(\mathbb{V}, \|\cdot\|)$ la función $d(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\|$ es una distancia.

2. Probar que $\|\cdot\|_1$, $\|\cdot\|_2$ y $\|\cdot\|_\infty$ son normas en $\mathbb{R}^n$. ¿Qué distancias inducen?

3. Probar que $\|A\|_F$ es una norma en $\mathbb{R}^{m\times n}$ de dos maneras: directamente, y observando que proviene del producto interno de Frobenius. Probar además que $\|A\|_F = \|A^T\|_F$ y que $\|QA\|_F = \|A\|_F$ si Q es ortogonal. *Sugerencia:* $\|A\|_F^2 = \operatorname{tr}(A^TA)$.

4. Mostrar directamente que para todo $\boldsymbol{v} \in \mathbb{R}^n$ vale $\|\boldsymbol{v}\|_2^2 \le \|\boldsymbol{v}\|_1 \|\boldsymbol{v}\|_\infty$.

5. Mostrar que la distancia discreta es una distancia en cualquier conjunto $\mathbb{X} \neq \emptyset$. Si se la considera sobre un espacio vectorial $\mathbb{V}$, ¿puede existir alguna norma que la induzca?

6. Demostrar el Teorema 7.7.

7. *(Distancia del tren en Francia.)* Considerar en $\mathbb{R}^n$ la función

$$d(\boldsymbol{x}, \boldsymbol{y}) = \begin{cases} d_2(\boldsymbol{x}, \boldsymbol{y}) & \text{si } \boldsymbol{x} = \alpha\boldsymbol{y} \text{ para algún } \alpha \in \mathbb{R}, \\ d_2(\boldsymbol{x}, \boldsymbol{0}) + d_2(\boldsymbol{0}, \boldsymbol{y}) & \text{en otro caso.} \end{cases}$$

   Mostrar que es una distancia. ¿Puede ser inducida por alguna norma en $\mathbb{R}^2$?

8. Demostrar la Proposición 7.13, y verificar la ley del paralelogramo explícitamente sobre $\mathbb{R}^2$ con $\|\cdot\|_2$ y sobre $\mathbb{R}^{2\times 2}$ con $\|\cdot\|_F$.

9. Sean $\mathbb{V}$ un espacio vectorial con producto interno y $\|\cdot\|$ la norma inducida. Probar que
$$\|\boldsymbol{x}\| = \sup_{\|\boldsymbol{y}\|=1} |\langle \boldsymbol{x}, \boldsymbol{y}\rangle|,$$
e indicar dónde se alcanza el supremo.

10. Mostrar que $\|\cdot\|_1$ y $\|\cdot\|_\infty$ no provienen de ningún producto interno en $\mathbb{R}^n$, $n \geq 2$. *Sugerencia:* Ejemplo 7.14.

11. Dar una demostración de la Proposición 7.5 que no pase por S^2: escribir $\boldsymbol{x}$ en la base de autovectores de S, calcular $\|S\boldsymbol{x}\|_2^2$ directamente y acotar como en el Teorema 6.13. Decir en qué vectores se alcanza el máximo cuando hay dos autovalores de módulo máximo y signos opuestos. ¿Qué parte del argumento se rompe si S no es simétrica?

12. Probar que para toda $A \in \mathbb{R}^{m\times n}$ vale $\|A\|_2 \leq \|A\|_F \leq \sqrt{\operatorname{rg}(A)}\,\|A\|_2$. *Sugerencia:* para la primera, $\|A\boldsymbol{x}\|_2 \leq \|A\|_F\|\boldsymbol{x}\|_2$; la segunda es más fácil después del Capítulo 8.

13. Probar que en un espacio con producto interno la convergencia $\boldsymbol{x}_k \to \boldsymbol{x}$ (es decir $\|\boldsymbol{x}_k - \boldsymbol{x}\| \to 0$) implica $\langle \boldsymbol{x}_k, \boldsymbol{y}\rangle \to \langle \boldsymbol{x}, \boldsymbol{y}\rangle$ para todo $\boldsymbol{y}$ fijo. *Sugerencia:* Cauchy-Schwarz.

14. *(Homogeneidad en el Teorema 7.15.)* En las condiciones de ese teorema, con $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \frac{1}{4}(\|\boldsymbol{x}+\boldsymbol{y}\|^2 - \|\boldsymbol{x}-\boldsymbol{y}\|^2)$, probar sucesivamente:
    (a) $\langle k\boldsymbol{x}, \boldsymbol{y}\rangle = k\langle \boldsymbol{x}, \boldsymbol{y}\rangle$ para $k \in \mathbb{N}$;
    (b) lo mismo para $k \in \mathbb{Z}$;
    (c) lo mismo para $k \in \mathbb{Q}$;
    (d) lo mismo para $k \in \mathbb{R}$, usando que $c \mapsto \langle c\boldsymbol{x}, \boldsymbol{y}\rangle$ es continua.

15. Decimos que $p, q > 1$ son *exponentes conjugados* si $\frac{1}{p} + \frac{1}{q} = 1$. Demostraremos paso a paso la **desigualdad de Hölder**: para todos $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$,
$$\sum_{i=1}^n |x_i y_i| \leq \left(\sum_{i=1}^n |x_i|^p\right)^{1/p} \left(\sum_{i=1}^n |y_i|^q\right)^{1/q}.$$
    (a) **Desigualdad de Young.** Demostrar que para $a, b \geq 0$ y $p, q > 1$ conjugados vale $ab \leq \frac{a^p}{p} + \frac{b^q}{q}$. *Sugerencia:* estudiar $\varphi(t) = \frac{t^p}{p} + \frac{1}{q} - t$ para $t \geq 0$.
    (b) **Caso normalizado.** Sean $A = \left(\sum_i |x_i|^p\right)^{1/p}$ y $B = \left(\sum_i |y_i|^q\right)^{1/q}$. Mostrar que si $A = 0$ o $B = 0$ la desigualdad es trivial. En caso contrario, definir $u_i = |x_i|/A$ y $v_i = |y_i|/B$ y verificar que $\sum_i u_i^p = \sum_i v_i^q = 1$.
    (c) **Aplicación de Young.** Aplicar el ítem 1 con $a = u_i$, $b = v_i$, sumar en i y usar las normalizaciones del ítem 2.
    (d) **Conclusión.** Escribir $u_i v_i = |x_i||y_i|/(AB)$ y deducir Hölder. Observar que $p = q = 2$ es Cauchy-Schwarz.
    (e) **Caso extremo.** Demostrar Hölder para $p = 1$, $q = \infty$, donde $\|\boldsymbol{y}\|_\infty = \max_i |y_i|$.
    (f) **Minkowski.** Deducir de Hölder que $\|\boldsymbol{x}+\boldsymbol{y}\|_p \leq \|\boldsymbol{x}\|_p + \|\boldsymbol{y}\|_p$, es decir, que $\|\cdot\|_p$ es una norma. *Sugerencia:* escribir $\sum_i |x_i + y_i|^p \leq \sum_i |x_i|\,|x_i+y_i|^{p-1} + \sum_i |y_i|\,|x_i+y_i|^{p-1}$ y aplicar Hölder a cada sumando.

16. Sea S sdp y $\|\boldsymbol{x}\|_S = \sqrt{\boldsymbol{x}^T S \boldsymbol{x}}$. Probar que $\|\cdot\|_S$ satisface la ley del paralelogramo, como debe ser por el Teorema 7.15, y recuperar $\langle \cdot, \cdot \rangle_S$ a partir de $\| \cdot \|_S$ por polarización.

17. Sea S sdp. Probar que una matriz U cumple $U^T S U = S$ si y sólo si U preserva el producto interno $\langle \cdot, \cdot \rangle_S$. Verificar que estas matrices forman un grupo, y que para $S = I$ son exactamente las ortogonales. ¿Qué transformaciones del plano son, geométricamente, cuando $S = \mathrm{diag}(1, 4)$?

8 CAPÍTULO

Descomposición en valores singulares (SVD)

Las matrices simétricas son cómodas: tienen autovalores reales y una base ortonormal de autovectores, y eso es todo el Capítulo 5. Las matrices cuadradas generales ya no: los autovalores pueden ser complejos y los autovectores pueden no ser ortogonales, o no alcanzar para formar una base. Y si A no es cuadrada, la ecuación $A\boldsymbol{x} = \lambda\boldsymbol{x}$ ni siquiera tiene sentido, porque el miembro izquierdo vive en $\mathbb{R}^m$ y el derecho en $\mathbb{R}^n$.

Hace falta una idea que funcione para *cualquier* matriz, y la descomposición en valores singulares la provee de una manera que resulta perfecta. El precio a pagar es abandonar la idea de una sola base: en lugar de una familia de autovectores necesitaremos **dos** familias ortonormales, una en $\mathbb{R}^n$ y otra en $\mathbb{R}^m$, relacionadas no por $A\boldsymbol{x} = \lambda\boldsymbol{x}$ sino por

$$A\boldsymbol{v}_k = \sigma_k \boldsymbol{u}_k.$$

La matriz manda cada $\boldsymbol{v}_k$ a un múltiplo de $\boldsymbol{u}_k$: no conserva la dirección — no puede, si cambia de espacio — pero manda una base ortonormal a otra base ortonormal, estirando cada eje por su propio factor.

El capítulo se organiza así. En la Sección 8.1 definimos los valores singulares *antes* de tener la SVD, a partir de la matriz simétrica A^TA, y probamos que el primero de ellos es la norma que mide cuánto estira A. Recién después (Secciones 8.2 y 8.3) enunciamos y probamos la descomposición. El resto del capítulo es leer lo que la SVD dice: bases ortonormales de los cuatro subespacios fundamentales, la imagen de la esfera unitaria, y la descomposición polar.

Dos resultados centrales quedan para después. El **teorema de Eckart-Young** — que truncar la SVD da la mejor aproximación de rango bajo — se prueba en el capítulo de PCA, que es donde se usa. Y la **pseudoinversa**, que la SVD permite definir para cualquier matriz, se trata en el capítulo final junto con los cuadrados mínimos.

8.1 Valores singulares y la norma espectral

Sea $A \in \mathbb{R}^{m\times n}$, de rango r. Aunque A no sea cuadrada, la matriz $A^TA \in \mathbb{R}^{n\times n}$ siempre es simétrica y semidefinida positiva:

$$(A^TA)^T = A^TA, \qquad \boldsymbol{x}^T(A^TA)\boldsymbol{x} = \|A\boldsymbol{x}\|^2 \geq 0.$$

Por el teorema espectral (Teorema 5.22) tiene autovalores reales, y por la Entrega 6.1 todos son ≥ 0. Además, por la Observación 3.19 sabemos que $N(A^TA) = N(A)$, de modo que $\operatorname{rg}(A^TA) = \operatorname{rg}(A) = r$: exactamente r de esos autovalores son positivos.

Definición 8.1 (Valores singulares). Sean $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$ los autovalores de A^TA, y sean $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n$ autovectores ortonormales correspondientes. Los **valores singulares** de A son

$$\sigma_k = \sqrt{\lambda_k}, \qquad k = 1, \ldots, n,$$

de modo que $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ y $\sigma_{r+1} = \cdots = \sigma_n = 0$. Los $\boldsymbol{v}_k$ se llaman **vectores singulares a derecha**.

Conviene subrayar que esto es una *definición*, no un teorema: no necesitamos la SVD para hablar de los σ_k. Lo que sigue tampoco.

Teorema 8.2 (El primer valor singular). Sea $A \in \mathbb{R}^{m\times n}$ no nula. Entonces

$$\max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \sigma_1, \qquad \text{equivalentemente} \qquad \max_{\boldsymbol{x}\neq 0} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \sigma_1,$$

y el máximo se alcanza exactamente en los autovectores unitarios de A^TA asociados a λ_1; en particular en $\boldsymbol{x} = \boldsymbol{v}_1$.

Demostración. Conviene normalizar primero y elevar al cuadrado después. Si $\|\boldsymbol{x}\| = 1$,

$$\|A\boldsymbol{x}\|^2 = (A\boldsymbol{x})^T(A\boldsymbol{x}) = \boldsymbol{x}^T(A^TA)\boldsymbol{x},$$

de modo que maximizar $\|A\boldsymbol{x}\|$ sobre los vectores unitarios es maximizar la *energía* de la matriz simétrica $S = A^TA$ sobre la esfera. Por el Teorema 6.13, ese máximo vale λ_1 —el mayor autovalor de A^TA— y se alcanza exactamente en los autovectores unitarios asociados a λ_1. Tomando raíz cuadrada, $\max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \sqrt{\lambda_1} = \sigma_1$.

La versión con cociente es la misma, por el Corolario 6.17: para $\boldsymbol{x} \neq 0$ cualquiera, $\|A\boldsymbol{x}\|/\|\boldsymbol{x}\| = \|A\boldsymbol{u}\|$ con $\boldsymbol{u} = \boldsymbol{x}/\|\boldsymbol{x}\|$ unitario. ∎

El teorema dice que el cociente $\|A\boldsymbol{x}\|/\|\boldsymbol{x}\|$ — cuánto estira A al vector $\boldsymbol{x}$ — está acotado, y que σ_1 es el estiramiento máximo. Eso es exactamente lo que hace falta para medir una matriz.

Definición 8.3 (Norma espectral). La **norma espectral** de $A \in \mathbb{R}^{m\times n}$ es

$$\|A\|_2 = \max_{\boldsymbol{x}\neq 0} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \sigma_1(A)$$

Proposición 8.4. $\|\cdot\|_2$ es una norma en $\mathbb{R}^{m\times n}$, y para todo $\boldsymbol{x} \in \mathbb{R}^n$ vale

$$\|A\boldsymbol{x}\| \leq \|A\|_2 \, \|\boldsymbol{x}\|.$$

Demostración. La desigualdad es la definición del máximo. Para los axiomas de norma (Sección 7.2):

(n2) Claramente $\|A\|_2 \geq 0$. Si $\|A\|_2 = 0$ entonces $A\boldsymbol{x} = 0$ para todo $\boldsymbol{x}$, en particular para los $\boldsymbol{e}_j$, así que todas las columnas de A son nulas y $A = 0$.

(n1) $\|cA\|_2 = \max_{\|\boldsymbol{x}\|=1} \|cA\boldsymbol{x}\| = |c| \max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = |c| \, \|A\|_2$.

(n3) Para $\|\boldsymbol{x}\| = 1$, usando la desigualdad triangular de la norma de vectores,

$$\|(A+B)\boldsymbol{x}\| \le \|A\boldsymbol{x}\| + \|B\boldsymbol{x}\| \le \|A\|_2 + \|B\|_2,$$

y tomando el máximo sobre esos $\boldsymbol{x}$ queda $\|A+B\|_2 \le \|A\|_2 + \|B\|_2$. ∎

Observación 8.5 (Dos normas de matrices, dos ideas distintas). Ya tenemos dos maneras de medir una matriz. La de Frobenius (Sección 1.3.6) se olvida de que A es una matriz y la mide como al vector largo de sus mn entradas; viene de un producto interno. La espectral la mide *como transformación*: cuánto estira en el peor caso. Son distintas y las dos se usan. En el capítulo de PCA se verá cómo se relacionan con los σ_k y entre sí; en el capítulo de normas de matrices estudiaremos la familia general de normas definidas por un máximo como el de arriba, y qué se gana al pedirle a una norma de matrices que se lleve bien con el producto.

Corolario 8.6 (Los autovalores no superan a σ_1). Si $A \in \mathbb{R}^{n\times n}$ y λ es un autovalor real de A, entonces $|\lambda| \le \sigma_1$.

Demostración. Si $A\boldsymbol{x} = \lambda\boldsymbol{x}$ con $\boldsymbol{x} \neq 0$, entonces $|\lambda|\,\|\boldsymbol{x}\| = \|A\boldsymbol{x}\| \le \sigma_1\|\boldsymbol{x}\|$. ∎

Ejemplo 8.7. Para una matriz de rango uno $A = \boldsymbol{x}\boldsymbol{y}^T$ (con $\boldsymbol{x}, \boldsymbol{y}$ no nulos), la desigualdad anterior es Cauchy-Schwarz disfrazada. En efecto, $A^TA = \boldsymbol{y}\boldsymbol{x}^T\boldsymbol{x}\boldsymbol{y}^T = \|\boldsymbol{x}\|^2\,\boldsymbol{y}\boldsymbol{y}^T$ tiene autovalor no nulo $\|\boldsymbol{x}\|^2\|\boldsymbol{y}\|^2$, de modo que

$$\sigma_1 = \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|, \qquad \boldsymbol{v}_1 = \frac{\boldsymbol{y}}{\|\boldsymbol{y}\|}, \qquad \boldsymbol{u}_1 = \frac{\boldsymbol{x}}{\|\boldsymbol{x}\|}.$$

Por otro lado, el único autovalor no nulo de A es $\lambda = \boldsymbol{y}^T\boldsymbol{x}$, con autovector $\boldsymbol{x}$, porque $(\boldsymbol{x}\boldsymbol{y}^T)\boldsymbol{x} = \boldsymbol{x}(\boldsymbol{y}^T\boldsymbol{x})$. El Corolario 8.6 dice entonces $|\boldsymbol{y}^T\boldsymbol{x}| \le \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$.

Necesitaremos también la versión del Teorema 8.2 para los valores singulares siguientes, que se obtiene restringiendo el máximo.

Corolario 8.8 (Los σ_k siguientes). Con las notaciones de la Definición 8.1, para cada $k = 1, \dots, n$,

$$\max\Big\{\|A\boldsymbol{x}\| : \|\boldsymbol{x}\| = 1,\ \boldsymbol{x} \perp \boldsymbol{v}_1, \dots, \boldsymbol{v}_{k-1}\Big\} = \sigma_k,$$

y el máximo se alcanza en $\boldsymbol{x} = \boldsymbol{v}_k$.

Demostración. Escribamos $\boldsymbol{x} = \sum_i c_i\boldsymbol{v}_i$ en la base ortonormal de autovectores. La condición $\boldsymbol{x} \perp \boldsymbol{v}_1, \dots, \boldsymbol{v}_{k-1}$ dice $c_1 = \cdots = c_{k-1} = 0$, y $\|\boldsymbol{x}\| = 1$ dice $\sum_i c_i^2 = 1$. Entonces

$$\|A\boldsymbol{x}\|^2 = \boldsymbol{x}^T(A^TA)\boldsymbol{x} = \sum_{i\ge k} \lambda_i c_i^2 \le \lambda_k \sum_{i\ge k} c_i^2 = \lambda_k,$$

con igualdad cuando $c_k = 1$ y el resto cero, es decir en $\boldsymbol{x} = \boldsymbol{v}_k$. ∎

Este corolario es la manera de entender los vectores singulares **uno por uno** en lugar de todos juntos: $\boldsymbol{v}_1$ es la dirección que más se estira; $\boldsymbol{v}_2$ es la que más se estira entre las perpendiculares a $\boldsymbol{v}_1$; y así sucesivamente. Es también el punto de partida del capítulo de PCA, donde este argumento se generaliza a d direcciones a la vez.

8.2 La descomposición en valores singulares

Ya tenemos la mitad de los ingredientes: los σ_k y los $\boldsymbol{v}_k$. Los vectores singulares a izquierda salen ahora de la relación que queremos que valga.

Definición 8.9 (Vectores singulares a izquierda). Para $k = 1, \dots, r$ definimos

$$\boldsymbol{u}_k = \frac{A\boldsymbol{v}_k}{\sigma_k} \in \mathbb{R}^m.$$

Con esa definición, $A\boldsymbol{v}_k = \sigma_k \boldsymbol{u}_k$ vale por construcción para $k \le r$; y para $k > r$ es $\|A\boldsymbol{v}_k\|^2 = \lambda_k = 0$, o sea $A\boldsymbol{v}_k = \boldsymbol{0}$. Es decir:

$$\boxed{A\boldsymbol{v}_1 = \sigma_1\boldsymbol{u}_1, \quad \dots, \quad A\boldsymbol{v}_r = \sigma_r\boldsymbol{u}_r} \qquad \boxed{A\boldsymbol{v}_{r+1} = \boldsymbol{0}, \quad \dots, \quad A\boldsymbol{v}_n = \boldsymbol{0}} \tag{8.1}$$

Los últimos $n - r$ vectores $\boldsymbol{v}$ están en el espacio nulo de A.

Falta ver que los $\boldsymbol{u}_k$ son ortonormales — lo haremos en la sección siguiente — y completar la lista hasta $\boldsymbol{u}_m$. Aceptándolo por un momento, pasemos (8.1) a forma matricial. Son n ecuaciones, una por cada $\boldsymbol{v}_k$, y lo que queremos es escribirlas como *una sola* igualdad entre matrices. La herramienta es la fórmula de las columnas de un producto del Capítulo 1.

Pongamos los $\boldsymbol{v}$ como columnas de $V \in \mathbb{R}^{n\times n}$ y los $\boldsymbol{u}$ como columnas de $U \in \mathbb{R}^{m\times m}$, ambas ortogonales, y llamemos $\Sigma \in \mathbb{R}^{m\times n}$ a la matriz con $\sigma_1, \dots, \sigma_r$ en las primeras posiciones diagonales y ceros en todo lo demás. Ahora comparemos las columnas de AV con las de $U\Sigma$, una por una.

La columna j de AV. Por (1.4),

$$\operatorname{col}_j(AV) = A \operatorname{col}_j(V) = A\boldsymbol{v}_j.$$

La columna j de $U\Sigma$. Otra vez por (1.4), $\operatorname{col}_j(U\Sigma) = U \operatorname{col}_j(\Sigma)$. Y las columnas de Σ son fáciles: $\operatorname{col}_j(\Sigma) = \sigma_j \boldsymbol{e}_j$ si $j \le r$, y $\operatorname{col}_j(\Sigma) = \boldsymbol{0}$ si $j > r$. Usando ahora la fórmula del producto matriz por vector (1.2), que dice que $U\boldsymbol{x}$ es la combinación de las columnas de U con coeficientes las entradas de $\boldsymbol{x}$,

$$\operatorname{col}_j(U\Sigma) = U(\sigma_j\boldsymbol{e}_j) = \sigma_j \operatorname{col}_j(U) = \sigma_j\boldsymbol{u}_j \quad (j \le r), \qquad \operatorname{col}_j(U\Sigma) = U\boldsymbol{0} = \boldsymbol{0} \quad (j > r).$$

Comparando las dos listas con (8.1): para $j \le r$ las dos columnas valen $\sigma_j\boldsymbol{u}_j$, y para $j > r$ las dos valen $\boldsymbol{0}$. Dos matrices con las mismas columnas son la misma matriz, así que

$$\boxed{AV = U\Sigma} \tag{8.2}$$

Las n ecuaciones de (8.1) quedaron empaquetadas en una. La Figura 8.1 muestra los tamaños y qué hay en cada factor.

Y como V es ortogonal, $V^{-1} = V^T$, y multiplicando (8.2) a derecha por V^T:

Teorema 8.10 (Descomposición en valores singulares). Toda matriz $A \in \mathbb{R}^{m\times n}$ se puede escribir como

$$\boxed{A = U\,\Sigma\,V^T}$$

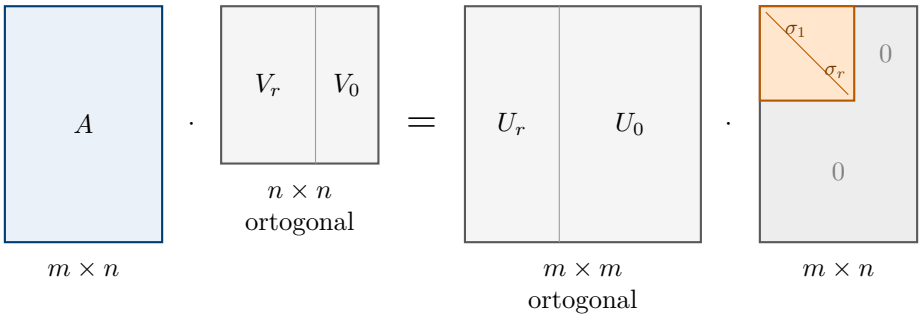


Figura 8.1. La igualdad $AV = U\Sigma$ en tamaños. Las columnas de V y de U vienen partidas en dos grupos: V_r son las primeras r columnas de V —una base ortonormal del espacio fila $C(A^T)$— y V_0 las restantes, que son una base de $N(A)$; U_r es una base de $C(A)$ y U_0 una de $N(A^T)$. La matriz Σ tiene los σ_k en el bloque $r \times r$ de arriba a la izquierda y ceros en todo lo demás: es la que "recorta", y la que explica por qué de U sólo llegan a usarse las primeras r columnas.

con $U \in \mathbb{R}^{m\times m}$ y $V \in \mathbb{R}^{n\times n}$ ortogonales y $\Sigma \in \mathbb{R}^{m\times n}$ "diagonal" con entradas $\sigma_1 \geq \cdots \geq \sigma_r > 0$ y el resto ceros.

Para ver qué hay adentro de ese producto volvemos al Capítulo 1, esta vez a la fórmula (1.8), que escribe un producto de matrices como suma de matrices de rango uno. Agrupemos $A = (U\Sigma)\,V^T$ y apliquémosla al par $U\Sigma$ (de $m \times n$) y V^T (de $n \times n$):

$$A = \sum_{p=1}^{n} \mathrm{col}_p(U\Sigma)\ \ \mathrm{fila}_p(V^T).$$

Los dos factores de cada sumando ya los calculamos: $\mathrm{col}_p(U\Sigma)$ vale $\sigma_p \boldsymbol{u}_p$ si $p \leq r$ y $\mathbf{0}$ si $p > r$, y $\mathrm{fila}_p(V^T) = \boldsymbol{v}_p^T$. Los $n - r$ últimos sumandos son nulos, y queda

$$A = U\Sigma V^T = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T + \sigma_2 \boldsymbol{u}_2 \boldsymbol{v}_2^T + \cdots + \sigma_r \boldsymbol{u}_r \boldsymbol{v}_r^T \tag{8.3}$$

Observación 8.11 (Por qué importa esta forma). Como $A = LU$, como $A = QR$ y como $S = Q\Lambda Q^T$, la SVD separa la matriz en sumandos de rango uno. Lo que la distingue es que *los sumandos vienen ordenados por importancia*: $\sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T$ es la matriz de rango uno más cercana a A, y más en general, la suma de los primeros d sumandos es la mejor aproximación de rango d que existe. Ése es el teorema de Eckart-Young, y es el motivo por el que la SVD es la factorización central en ciencia de datos. Lo enunciaremos con precisión en la Sección 8.8 y se prueba en el capítulo de PCA.

8.2.1 La forma reducida

En (8.3) se ve que los últimos $n - r$ sumandos no aportan nada: el corazón de la SVD está en los primeros r vectores. Eso sugiere quedarse sólo con ellos. Llamemos

$$U_r = [\,\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_r\,] \in \mathbb{R}^{m\times r}, \qquad V_r = [\,\boldsymbol{v}_1\ \cdots\ \boldsymbol{v}_r\,] \in \mathbb{R}^{n\times r}, \qquad \Sigma_r = \mathrm{diag}(\sigma_1, \ldots, \sigma_r).$$

Lo interesante es que para llegar a la forma reducida no hace falta ninguna cuenta nueva: alcanza con leer (1.8) *al revés*. Esa fórmula dice que una suma de productos externos es un producto de matrices, con los vectores de la izquierda como columnas del

primer factor y los de la derecha como filas del segundo. Y en (8.3) tenemos justamente una suma de r productos externos:

$$A = \sum_{p=1}^{r} (\sigma_p \boldsymbol{u}_p)\, \boldsymbol{v}_p^T = \sum_{p=1}^{r} \mathrm{col}_p(U_r \Sigma_r)\ \ \mathrm{fila}_p(V_r^T),$$

donde usamos que $\mathrm{col}_p(U_r\Sigma_r) = \sigma_p \boldsymbol{u}_p$ —la misma cuenta de antes, ahora con Σ_r cuadrada— y que $\mathrm{fila}_p(V_r^T) = \boldsymbol{v}_p^T$. Aplicando (1.8) de derecha a izquierda:

$$\boxed{A = U_r\, \Sigma_r\, V_r^T} \qquad (\textbf{SVD reducida}).$$

La Figura 8.2 la muestra al lado de la completa.

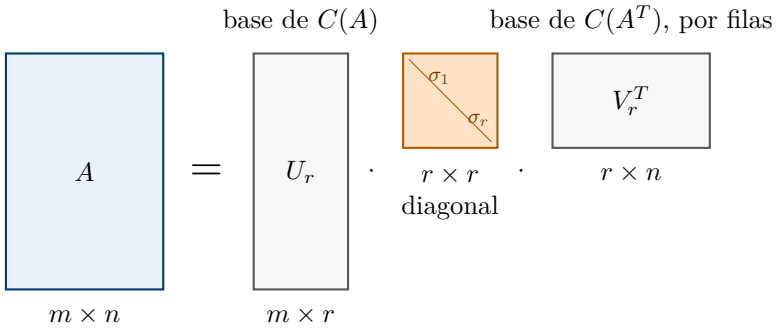


Figura 8.2. La SVD reducida $A = U_r\Sigma_r V_r^T$. Comparada con la Figura 8.1, desaparecieron las columnas de U y de V que Σ multiplicaba por cero, y Σ_r quedó cuadrada e invertible. Guardar A cuesta mn números; guardar los tres factores de la derecha, $r(m+n+1)$. Cuando r es chico frente a m y n, la diferencia es enorme: es la idea que explota el capítulo de PCA.

También se puede llegar por el otro lado, que es el camino del Ejercicio 9: las ecuaciones (8.1) que no son triviales son las r columnas de

$$A \underbrace{\begin{bmatrix} \boldsymbol{v}_1 & \cdots & \boldsymbol{v}_r \end{bmatrix}}_{\text{base del espacio fila}} = \underbrace{\begin{bmatrix} \boldsymbol{u}_1 & \cdots & \boldsymbol{u}_r \end{bmatrix}}_{\text{base del espacio columna}} \Sigma_r, \qquad \text{es decir} \qquad AV_r = U_r\Sigma_r, \tag{8.4}$$

y de ahí se multiplica por V_r^T. Pero atención: acá V_r *no* es cuadrada, así que V_r^T no es su inversa y el paso necesita un argumento —es justamente lo que pide ese ejercicio—, mientras que por el camino de los productos externos la igualdad sale sin invertir nada.

Sigue valiendo $V_r^T V_r = I_r$ y $U_r^T U_r = I_r$, porque las columnas son ortonormales. Pero cuando V_r y U_r no son cuadradas ya no hay inversa de los dos lados: en general $V_r V_r^T \neq I$ y $U_r U_r^T \neq I$.

Ejemplo 8.12. Con $V_r = \begin{bmatrix} 1/3 \\ 2/3 \\ 2/3 \end{bmatrix}$ es $V_r^T V_r = [1]$, pero

$$V_r V_r^T = \frac{1}{9}\begin{bmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{bmatrix}$$

tiene rango 1. (Lo que sí es cierto, y lo veremos en la Sección 8.4, es que $V_r V_r^T$ es la proyección ortogonal sobre el espacio fila de A.)

8.2.2 Un ejemplo completo

Ejemplo 8.13. Calculemos U, Σ y V para $A = \left[\begin{smallmatrix} 3 & 0 \\ 4 & 5 \end{smallmatrix}\right]$.

El rango es 2, así que habrá dos valores singulares positivos. Empezamos por las dos matrices simétricas:

$$A^TA = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}, \qquad AA^T = \begin{bmatrix} 9 & 12 \\ 12 & 41 \end{bmatrix}.$$

Tienen la misma traza (50) y los mismos autovalores, $\lambda_1 = 45$ y $\lambda_2 = 5$; luego $\sigma_1 = \sqrt{45} = 3\sqrt{5}$ y $\sigma_2 = \sqrt{5}$. Observemos de paso que $\sigma_1\sigma_2 = 3\sqrt{5}\cdot\sqrt{5} = 15 = \det A$, y que $\sigma_1 > 5 = \lambda_{\max}(A)$ mientras que $\sigma_2 < 3 = \lambda_{\min}(A)$: los valores singulares *no* son los autovalores.

Los autovectores de A^TA son inmediatos:

$$\begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}\begin{pmatrix} 1 \\ 1 \end{pmatrix} = 45\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}\begin{pmatrix} -1 \\ 1 \end{pmatrix} = 5\begin{pmatrix} -1 \\ 1 \end{pmatrix},$$

y normalizando, $\boldsymbol{v}_1 = \frac{1}{\sqrt{2}}(1,1)^T$, $\boldsymbol{v}_2 = \frac{1}{\sqrt{2}}(-1,1)^T$. Los $\boldsymbol{u}$ salen de la Definición 8.9:

$$A\boldsymbol{v}_1 = \frac{3}{\sqrt{2}}\begin{pmatrix} 1 \\ 3 \end{pmatrix} = \sqrt{45}\cdot\frac{1}{\sqrt{10}}\begin{pmatrix} 1 \\ 3 \end{pmatrix} = \sigma_1\boldsymbol{u}_1, \qquad A\boldsymbol{v}_2 = \frac{1}{\sqrt{2}}\begin{pmatrix} -3 \\ 1 \end{pmatrix} = \sqrt{5}\cdot\frac{1}{\sqrt{10}}\begin{pmatrix} -3 \\ 1 \end{pmatrix} = \sigma_2\boldsymbol{u}_2.$$

La división por $\sqrt{10}$ deja a $\boldsymbol{u}_1$ y $\boldsymbol{u}_2$ ortonormales. En resumen,

$$U = \frac{1}{\sqrt{10}}\begin{bmatrix} 1 & -3 \\ 3 & 1 \end{bmatrix}, \qquad \Sigma = \begin{bmatrix} \sqrt{45} & \\ & \sqrt{5} \end{bmatrix}, \qquad V = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Y la descomposición en sumandos de rango uno, con $\sqrt{2}\sqrt{10} = \sqrt{20}$:

$$\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^T + \sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^T = \frac{\sqrt{45}}{\sqrt{20}}\begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} + \frac{\sqrt{5}}{\sqrt{20}}\begin{bmatrix} 3 & -3 \\ -1 & 1 \end{bmatrix} = \frac{3}{2}\begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} + \frac{1}{2}\begin{bmatrix} 3 & -3 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = A.$$

8.2.3 Algunos casos particulares

Ejemplo 8.14 (Una matriz sdp)**.** Si $S = Q\Lambda Q^T$ es simétrica y definida positiva, su SVD es esa misma descomposición: $U = V = Q$ y $\Sigma = \Lambda$. Para una matriz sdp, valores singulares y autovalores coinciden.

Ejemplo 8.15 (Una simétrica con autovalores negativos)**.** Si $S = Q\Lambda Q^T$ es simétrica y $S\boldsymbol{x} = -\alpha\boldsymbol{x}$ con $\alpha > 0$, el valor singular correspondiente es $\sigma = +\alpha$, y uno de los dos vectores singulares (el $\boldsymbol{u}$ o el $\boldsymbol{v}$) hay que tomarlo con el signo cambiado: con $\boldsymbol{v} = \boldsymbol{x}$ y $\boldsymbol{u} = -\boldsymbol{x}$, la igualdad $S\boldsymbol{x} = -\alpha\boldsymbol{x}$ es exactamente $S\boldsymbol{v} = \sigma\boldsymbol{u}$. En general, para S simétrica, $\sigma_k = |\lambda_k|$ reordenados de mayor a menor.

Ejemplo 8.16 (Una matriz ortogonal)**.** Si $A = Q$ es ortogonal, $A^TA = I$ y todos los valores singulares valen 1, o sea $\Sigma = I$. Los vectores singulares no son únicos: $Q = QII^T$ sirve, pero también $Q = (QQ_1)IQ_1^T$ para cualquier Q_1 ortogonal. Esto es coherente con $\|Q\|_2 = 1$: una matriz ortogonal no estira nada.

8.3 Demostración de la SVD

Queda por verificar lo que dimos por sentado: que los $\boldsymbol{u}_k$ de la Definición 8.9 son ortonormales, y que se los puede completar hasta una base ortonormal de $\mathbb{R}^m$.

Demostración del Teorema 8.10. *Los $\boldsymbol{u}_k$ son ortonormales.* Para $j, k \le r$,

$$\boldsymbol{u}_j^T \boldsymbol{u}_k = \left(\frac{A\boldsymbol{v}_j}{\sigma_j}\right)^T \left(\frac{A\boldsymbol{v}_k}{\sigma_k}\right) = \frac{\boldsymbol{v}_j^T (A^T A\, \boldsymbol{v}_k)}{\sigma_j \sigma_k} = \frac{\lambda_k}{\sigma_j \sigma_k} \boldsymbol{v}_j^T \boldsymbol{v}_k = \frac{\sigma_k}{\sigma_j} \boldsymbol{v}_j^T \boldsymbol{v}_k = \begin{cases} 1 & \text{si } j = k, \\ 0 & \text{si } j \neq k, \end{cases}$$

usando que los $\boldsymbol{v}$ son ortonormales y que $\lambda_k = \sigma_k^2$.

Los $\boldsymbol{u}_k$ son autovectores de AA^T. No hace falta para la prueba, pero lo confirma:

$$AA^T \boldsymbol{u}_k = AA^T \left(\frac{A\boldsymbol{v}_k}{\sigma_k}\right) = A\left(\frac{A^T A\, \boldsymbol{v}_k}{\sigma_k}\right) = A\, \frac{\sigma_k^2 \boldsymbol{v}_k}{\sigma_k} = \sigma_k^2 \boldsymbol{u}_k.$$

El paso decisivo fue $(AA^T)A = A(A^T A)$: mover los paréntesis, que es la ley asociativa y es la clave de una cantidad enorme de pruebas del álgebra lineal.

Completar las bases. Los $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ están en $C(A)$ y son r vectores ortonormales, así que son una base ortonormal de $C(A)$, que tiene dimensión r. Elegimos $\boldsymbol{u}_{r+1}, \dots, \boldsymbol{u}_m$ como cualquier base ortonormal de $N(A^T)$. Por el Corolario 3.17, $C(A) \perp N(A^T)$ y las dimensiones suman m, así que la lista completa es una base ortonormal de $\mathbb{R}^m$ y U es ortogonal. Lo mismo ya estaba hecho del lado de V: los $\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n$ generan $N(A)$, que es ortogonal a $C(A^T) = \operatorname{span}(\boldsymbol{v}_1, \dots, \boldsymbol{v}_r)$.

Con eso, $AV = U\Sigma$ columna por columna es exactamente (8.1), y multiplicando por V^T queda $A = U\Sigma V^T$. ∎

Observación 8.17 (Por qué los $\boldsymbol{u}$ se definen y no se eligen)**.** Podría parecer más simétrico tomar los $\boldsymbol{v}$ como autovectores ortonormales de $A^T A$ y los $\boldsymbol{u}$ como autovectores ortonormales de AA^T, por separado. No funciona, por dos razones. Primero, los signos: si $\boldsymbol{u}$ es autovector, $-\boldsymbol{u}$ también, y la SVD exige el signo que hace $A\boldsymbol{v}_k = \sigma_k \boldsymbol{u}_k$ con $\sigma_k > 0$. Segundo, y más serio: cuando un σ está repetido hay un plano entero (o más) de autovectores donde elegir, y una elección independiente de los dos lados no tiene por qué ser compatible. Definir $\boldsymbol{u}_k = A\boldsymbol{v}_k/\sigma_k$ resuelve las dos cosas de un saque. Es exactamente el punto que hace fallar a la "prueba rápida" del Ejercicio 10.

Ejercicio de desarrollo 8.1 | Una construcción de la SVD

La demostración anterior parte de los autovectores de $A^T A$ y construye los $\boldsymbol{u}$. Esta entrega hace el camino inverso — parte de AA^T y construye los $\boldsymbol{v}$ — y arma la factorización paso a paso.
Sea $A \in \mathbb{R}^{m \times n}$.

(a) Probar que $A^T A$ y AA^T son simétricas, semidefinidas positivas, y que tienen los mismos autovalores no nulos. *Sugerencia:* para lo último, si $A^T A\, \boldsymbol{v} = \lambda \boldsymbol{v}$ con $\lambda \neq 0$, ver que $A\boldsymbol{v}$ es autovector de AA^T con el mismo autovalor, y verificar que $A\boldsymbol{v} \neq \boldsymbol{0}$.

Sean $\sigma_1 \ge \cdots \ge \sigma_r > 0$ tales que $\sigma_1^2, \dots, \sigma_r^2$ son los autovalores no nulos de AA^T, con $r = \operatorname{rg}(A)$. Sea $U = [\, \boldsymbol{u}_1 \ \cdots \ \boldsymbol{u}_m \,]$ ortogonal con columnas autovectores de AA^T,

y $U_r = [\,\boldsymbol{u}_1 \;\cdots\; \boldsymbol{u}_r\,]$. Definimos $\Sigma_r = \operatorname{diag}(\sigma_1, \ldots, \sigma_r)$ y

$$V_r = A^T U_r \Sigma_r^{-1} \in \mathbb{R}^{n \times r}.$$

Elegimos además $V_{-r} = [\,\boldsymbol{v}_{r+1} \;\cdots\; \boldsymbol{v}_n\,]$ una base ortonormal de $N(A)$, y ponemos $V = [\,V_r \;\; V_{-r}\,]$, $U = [\,U_r \;\; U_{-r}\,]$ y

$$\Sigma = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

(b) Probar que $AV_r = U_r \Sigma_r$.

(c) Probar que $AV_{-r} = 0$.

(d) Concluir que $AV = [\,U_r \Sigma_r \;\; 0\,] = U\Sigma$.

(e) Probar que $V^T V = I_n$. *Sugerencia:* verificar por separado $V_r^T V_r = I_r$, $V_r^T V_{-r} = 0$ y $V_{-r}^T V_{-r} = I_{n-r}$.

(f) Deducir, por ser V cuadrada, que $VV^T = I_n$ y $V^T = V^{-1}$.

(g) Concluir que $A = U\Sigma V^T$.

(h) Comparar con la construcción de la Sección 8.3: ¿en qué punto exacto de esta construcción se usa que los $\boldsymbol{u}$ ya estaban elegidos, y por qué eso determina los signos de los $\boldsymbol{v}$?

Se entrega por escrito. El ítem (a) es el que se usa en todo el capítulo; el (h) es la contracara de la observación anterior sobre por qué una de las dos familias se define a partir de la otra.

8.4 Lo que se lee en la SVD

8.4.1 Los cuatro subespacios fundamentales

El Capítulo 1 presentó los cuatro subespacios fundamentales y el Capítulo 3 probó cómo se aparean ortogonalmente. La SVD hace algo más: da bases *ortonormales* de los cuatro al mismo tiempo.

Proposición 8.18. Sea $A = U\Sigma V^T$ con $\operatorname{rg}(A) = r$. Entonces

subespacio	base ortonormal	dimensión
espacio fila $C(A^T)$	$\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r$	r
espacio nulo $N(A)$	$\boldsymbol{v}_{r+1}, \ldots, \boldsymbol{v}_n$	$n - r$
espacio columna $C(A)$	$\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r$	r
espacio nulo a izquierda $N(A^T)$	$\boldsymbol{u}_{r+1}, \ldots, \boldsymbol{u}_m$	$m - r$

Además, las proyecciones ortogonales sobre esos subespacios son

$$P_{C(A)} = U_r U_r^T, \qquad P_{C(A^T)} = V_r V_r^T,$$

y $P_{N(A^T)} = I - U_r U_r^T$, $P_{N(A)} = I - V_r V_r^T$.

Demostración. De (8.1), $A\boldsymbol{v}_k = \mathbf{0}$ para $k > r$, así que $\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n$ son $n-r$ vectores ortonormales de $N(A)$, que tiene dimensión $n-r$: son una base. Los $\boldsymbol{v}_1, \dots, \boldsymbol{v}_r$ son ortonormales y ortogonales a $N(A)$, luego están en $N(A)^\perp = C(A^T)$ (Corolario 3.17), y son r: base. Del lado de U, los $\boldsymbol{u}_k = A\boldsymbol{v}_k/\sigma_k$ con $k \le r$ están en $C(A)$ y son r ortonormales: base de $C(A)$; los restantes completan y están en $C(A)^\perp = N(A^T)$.

Para las proyecciones: U_r tiene columnas ortonormales que generan $C(A)$, y ya vimos en la Sección 3.4 que la proyección ortogonal sobre el espacio generado por columnas ortonormales es QQ^T. ∎

Observación 8.19. Vale la pena leer la tabla junto con (8.1): la SVD dice que A manda una base ortonormal del espacio fila a una base ortogonal del espacio columna, estirando cada dirección por su σ_k, y aplasta el espacio nulo a cero. Ésa es toda la información que hay en una matriz.

8.4.2 Los vectores singulares de A^T

Trasponiendo $A = U\Sigma V^T$ se obtiene $A^T = V\Sigma^T U^T$, que recorre el camino inverso: de los $\boldsymbol{u}$ a los $\boldsymbol{v}$.

Proposición 8.20. $A^T\boldsymbol{u}_k = \sigma_k\boldsymbol{v}_k$ para $k = 1, \dots, r$, y $A^T\boldsymbol{u}_k = \mathbf{0}$ para $k = r+1, \dots, m$. En particular A y A^T tienen los mismos valores singulares no nulos, y $\|A\|_2 = \|A^T\|_2$.

Demostración. Multiplicando $A\boldsymbol{v}_k = \sigma_k\boldsymbol{u}_k$ por A^T y usando $A^TA\boldsymbol{v}_k = \sigma_k^2\boldsymbol{v}_k$ queda $\sigma_k^2\boldsymbol{v}_k = \sigma_k A^T\boldsymbol{u}_k$; dividiendo por $\sigma_k \neq 0$ sale la igualdad. Para $k > r$, $\boldsymbol{u}_k \in N(A^T)$ por la Proposición 8.18. ∎

8.4.3 Una matriz simétrica que también da la SVD

Construimos la SVD a partir de A^TA y AA^T. Hay otra manera, que usa una sola matriz simétrica de tamaño $m+n$ y tiene r pares de autovalores opuestos:

$$S = \begin{bmatrix} 0 & A \\ A^T & 0 \end{bmatrix} \qquad \text{tiene autovectores} \qquad \begin{pmatrix} \boldsymbol{u}_k \\ \boldsymbol{v}_k \end{pmatrix} \quad \text{y} \quad \begin{pmatrix} -\boldsymbol{u}_k \\ \boldsymbol{v}_k \end{pmatrix}.$$

En efecto, usando $A\boldsymbol{v}_k = \sigma_k\boldsymbol{u}_k$ y $A^T\boldsymbol{u}_k = \sigma_k\boldsymbol{v}_k$,

$$\begin{bmatrix} 0 & A \\ A^T & 0 \end{bmatrix} \begin{pmatrix} \pm\boldsymbol{u}_k \\ \boldsymbol{v}_k \end{pmatrix} = \begin{pmatrix} A\boldsymbol{v}_k \\ \pm A^T\boldsymbol{u}_k \end{pmatrix} = \sigma_k \begin{pmatrix} \boldsymbol{u}_k \\ \boldsymbol{v}_k \end{pmatrix} \quad \text{y} \quad -\sigma_k \begin{pmatrix} -\boldsymbol{u}_k \\ \boldsymbol{v}_k \end{pmatrix}. \tag{8.5}$$

Eso da $2r$ autovalores, $\pm\sigma_1, \dots, \pm\sigma_r$. Los autovectores son ortogonales: $(-\boldsymbol{u}_k)^T\boldsymbol{u}_k + \boldsymbol{v}_k^T\boldsymbol{v}_k = -1 + 1 = 0$. Los otros $(m-r)+(n-r)$ autovectores, correspondientes a $\lambda = 0$, se arman con los $\boldsymbol{u}$ y $\boldsymbol{v}$ que quedaron en $N(A^T)$ y $N(A)$ (Ejercicio 8).

8.4.4 A^TA y AA^T: los mismos valores singulares

La construcción partió de A^TA, pero podríamos haber empezado por AA^T y nada habría cambiado. La razón es un hecho general sobre autovalores, que no tiene nada que ver con la SVD y que por eso probamos en su lugar: la Proposición 4.7 del Capítulo 4 dice que AB y BA tienen los mismos autovalores no nulos, aun siendo rectangulares.

Con $B = A^T$ eso dice que A^TA y AA^T tienen los mismos autovalores no nulos, o sea que A tiene *los mismos valores singulares* se los calcule como se los calcule. Lo que cambia es sólo el tamaño: si $m > n$, la matriz AA^T es de $m \times m$ y tiene $m - n$ autovalores *cero* de más respecto de A^TA, que es de $n \times n$. Eso explica la asimetría de la Figura 8.1: sobran columnas en U, no en V. En la práctica conviene diagonalizar la más chica de las dos, y es exactamente lo que hace el truco de la matriz de Gram del capítulo de PCA.

8.5 La geometría: de la esfera al elipsoide

La SVD factoriza A como (ortogonal) $\times$ (diagonal) $\times$ (ortogonal), y esos tres factores tienen una lectura geométrica inmediata: V^T y U rotan (posiblemente con una reflexión) y Σ estira a lo largo de los ejes. En dos dimensiones se puede dibujar todo el proceso (Figura 8.3): un vector $\boldsymbol{x}$ de la circunferencia unitaria se rota a $V^T\boldsymbol{x}$, se estira a $\Sigma V^T\boldsymbol{x}$ y se vuelve a rotar hasta $A\boldsymbol{x} = U\Sigma V^T\boldsymbol{x}$, que recorre una elipse.

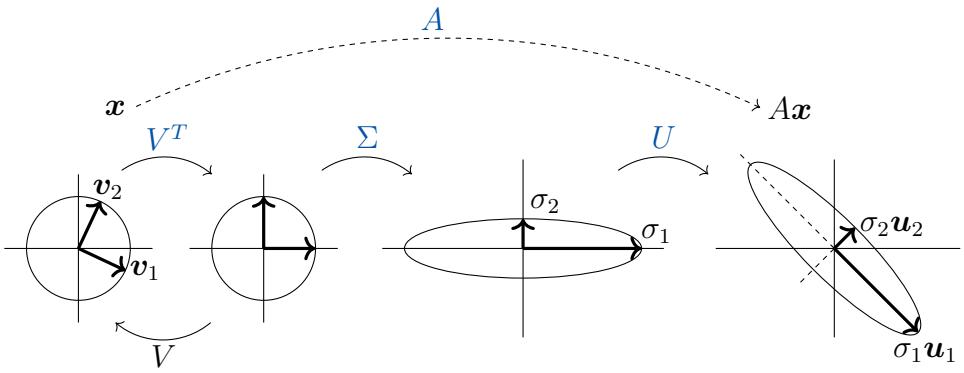


Figura 8.3. Rotación, estiramiento y rotación. V^T y U son rotaciones (posiblemente con reflexión) y Σ estira los ejes por σ_1 y σ_2. La circunferencia unitaria va a parar a una elipse de semiejes σ_1 y σ_2 en las direcciones $\boldsymbol{u}_1$ y $\boldsymbol{u}_2$.

El enunciado preciso es el siguiente, y conecta con la Sección 6.5, donde estudiamos las elipses asociadas a una matriz sdp.

Teorema 8.21 (La imagen de la esfera). Sea $A \in \mathbb{R}^{n\times n}$ invertible, con valores singulares $\sigma_1 \geq \cdots \geq \sigma_n > 0$. Entonces la imagen de la esfera unitaria,

$$\{A\boldsymbol{x} : \|\boldsymbol{x}\| = 1\},$$

es el elipsoide de semiejes $\sigma_1, \ldots, \sigma_n$ en las direcciones $\boldsymbol{u}_1, \ldots, \boldsymbol{u}_n$. En particular, σ_1 y σ_n son el semieje mayor y el semieje menor: A estira a lo sumo σ_1 y a lo menos σ_n.

Demostración. Sea $\boldsymbol{y} = A\boldsymbol{x}$ con $\|\boldsymbol{x}\| = 1$. Escribiendo $\boldsymbol{x} = \sum_k c_k\boldsymbol{v}_k$, es $\boldsymbol{y} = \sum_k c_k\sigma_k\boldsymbol{u}_k$, y las coordenadas de $\boldsymbol{y}$ en la base ortonormal $\{\boldsymbol{u}_k\}$ son $y'_k = \boldsymbol{u}_k^T\boldsymbol{y} = \sigma_k c_k$. La condición $\|\boldsymbol{x}\|^2 = \sum c_k^2 = 1$ se traduce entonces en

$$\sum_{k=1}^{n} \frac{(y'_k)^2}{\sigma_k^2} = 1,$$

que es la ecuación de un elipsoide de semiejes σ_k en las direcciones $\boldsymbol{u}_k$. Recíprocamente, todo punto que cumple esa ecuación es la imagen del $\boldsymbol{x}$ correspondiente. ∎

Observación 8.22 (Es la elipse del Capítulo 6)**.** El elipsoide del teorema es exactamente el conjunto $\{\boldsymbol{y} : \boldsymbol{y}^T(AA^T)^{-1}\boldsymbol{y} = 1\}$, o sea la elipse asociada a la matriz sdp $(AA^T)^{-1}$ en el sentido de la Sección 6.5: sus ejes son los autovectores $\boldsymbol{u}_k$ de AA^T y sus semiejes son $1/\sqrt{\lambda_k((AA^T)^{-1})} = \sqrt{\lambda_k(AA^T)} = \sigma_k$. La SVD es, leída así, el teorema que dice que *toda* matriz manda esferas a elipsoides, y que los ejes de llegada son los $\boldsymbol{u}_k$ y los de partida los $\boldsymbol{v}_k$.

Observación 8.23 (Contar parámetros)**.** La factorización ordena la información de una matriz de 2×2: los cuatro números a, b, c, d se corresponden con dos ángulos θ, ϕ y dos valores singulares,

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} = \begin{bmatrix} \cos\theta & -\operatorname{sen}\theta \\ \operatorname{sen}\theta & \cos\theta \end{bmatrix} \begin{bmatrix} \sigma_1 & \\ & \sigma_2 \end{bmatrix} \begin{bmatrix} \cos\phi & \operatorname{sen}\phi \\ -\operatorname{sen}\phi & \cos\phi \end{bmatrix}.$$

Si la matriz es simétrica hay sólo tres parámetros independientes: ¿cómo se reducen entonces los cuatro? El Ejercicio 11 sigue esta cuenta en dimensiones más altas.

8.6 La descomposición polar

Todo número complejo se escribe en forma polar como $z = re^{i\theta}$, con $r \geq 0$ y $|e^{i\theta}| = 1$. Pensando a los números como matrices de 1×1, el factor $e^{i\theta}$ hace de matriz ortogonal y r de matriz semidefinida positiva. La SVD dice que esa descomposición existe en cualquier dimensión.

Teorema 8.24 (Descomposición polar)**.** Toda $A \in \mathbb{R}^{n\times n}$ se factoriza como

$$A = QS$$

con Q ortogonal y S simétrica semidefinida positiva. Si A es invertible, S es definida positiva y $S = (A^TA)^{1/2}$ es la raíz cuadrada de la Sección 6.3.

Demostración. Sea $A = U\Sigma V^T$. Intercalando $V^TV = I$,

$$A = U\Sigma V^T = (UV^T)(V\Sigma V^T) = QS, \qquad Q := UV^T, \quad S := V\Sigma V^T.$$

Q es ortogonal por ser producto de ortogonales. S es simétrica y sus autovalores son los $\sigma_k \geq 0$, luego es semidefinida positiva, y definida positiva si todos los $\sigma_k > 0$, es decir si A es invertible. Finalmente $S^2 = V\Sigma^2V^T = V\Sigma^TU^TU\Sigma V^T = A^TA$, y como S es sdp, es *la* raíz cuadrada de A^TA por la unicidad probada en la Entrega 6.3. ∎

También vale la versión con los factores al revés, $A = S_1Q$ con $S_1 = U\Sigma U^T = (AA^T)^{1/2}$ y el mismo $Q = UV^T$.

Ejemplo 8.25. Para $A = \left[\begin{smallmatrix} 3 & 0 \\ 4 & 5 \end{smallmatrix}\right]$, con la SVD del Ejemplo 8.13,

$$Q = UV^T = \frac{1}{\sqrt{5}}\begin{bmatrix} 2 & -1 \\ 1 & 2 \end{bmatrix}, \qquad S = V\Sigma V^T = \sqrt{5}\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Observación 8.26 (Rotación y deformación)**.** En mecánica del continuo la descomposición polar separa la *rotación* de un cuerpo (el factor Q) de su *deformación* (el factor S): los autovalores de S son los factores de estiramiento y sus autovectores, las direcciones principales de deformación. Es la misma lectura que la del Teorema 8.21, reagrupada.

8.7 Las tres normas de la SVD

La norma de Frobenius apareció en la Sección 1.3.6 y la espectral en la Sección 8.1. Hasta ahora no tenían nada que ver una con otra: la primera lee la matriz como un vector largo y la segunda mide cuánto estira. La SVD las pone a las dos —y a una tercera— en el mismo idioma: *todas se leen de los valores singulares*. Esta sección es corta y es la que van a citar los dos capítulos siguientes.

El ingrediente es que multiplicar por una matriz de columnas ortonormales no cambia la norma de Frobenius: si $Q^TQ = I$, entonces

$$\|QA\|_F^2 = \operatorname{tr}\big((QA)^T(QA)\big) = \operatorname{tr}(A^TQ^TQA) = \operatorname{tr}(A^TA) = \|A\|_F^2,$$

y lo mismo del otro lado, porque $\|AP\|_F^2 = \operatorname{tr}(APP^TA^T)$ y $\|A\|_F^2 = \operatorname{tr}(AA^T)$ también.

Proposición 8.27 (Frobenius cuenta todos los valores singulares)**.** Sea $A \in \mathbb{R}^{m\times n}$ con valores singulares $\sigma_1 \geq \cdots \geq \sigma_r > 0$. Entonces

$$\|A\|_F^2 = \sigma_1^2 + \sigma_2^2 + \cdots + \sigma_r^2$$

Demostración. Con la SVD reducida $A = U_r\Sigma_rV_r^T$ de (8.4), las columnas de U_r y las de V_r son ortonormales, así que

$$\|A\|_F = \|U_r\Sigma_rV_r^T\|_F = \|\Sigma_rV_r^T\|_F = \|\Sigma_r\|_F,$$

y $\Sigma_r = \operatorname{diag}(\sigma_1, \ldots, \sigma_r)$ tiene norma de Frobenius $\left(\sum_k \sigma_k^2\right)^{1/2}$. ∎

Comparando con $\|A\|_2 = \sigma_1$ (Teorema 8.2) sale de una

$$\|A\|_2 \;\leq\; \|A\|_F \;\leq\; \sqrt{r}\,\|A\|_2,$$

con la primera igualdad exactamente cuando A tiene rango uno y la segunda cuando todos los valores singulares no nulos coinciden.

Hay una tercera manera obvia de resumir los σ_k en un número, y también es una norma.

Definición 8.28 (Norma nuclear)**.** La **norma nuclear** (o *norma de traza*) de A es la suma de sus valores singulares,

$$\|A\|_* = \sigma_1 + \sigma_2 + \cdots + \sigma_r.$$

Que sea una norma no es evidente desde esta definición —la desigualdad triangular dice que los valores singulares de $A + B$ suman menos que los de A más los de B, y eso hay que probarlo— y lo dejamos para el capítulo de normas de matrices. Las tres juntas:

$$\|A\|_2 = \sigma_1, \qquad \|A\|_F = \left(\sigma_1^2 + \cdots + \sigma_r^2\right)^{1/2}, \qquad \|A\|_* = \sigma_1 + \cdots + \sigma_r,$$

y son genuinamente distintas, ya que para la identidad de $n \times n$ dan 1, $\sqrt{n}$ y n.

Lo que tienen en común es más importante que lo que las diferencia.

Definición 8.29 (Norma ortogonalmente invariante). Una norma $\|\cdot\|$ en $\mathbb{R}^{m\times n}$ es **ortogonalmente invariante** si

$$\|QAP\| = \|A\| \qquad \text{para toda } A$$

y todas las matrices ortogonales $Q \in \mathbb{R}^{m\times m}$, $P \in \mathbb{R}^{n\times n}$.

Corolario 8.30. Las normas espectral, de Frobenius y nuclear son ortogonalmente invariantes.

Demostración. Si $A = U\Sigma V^T$, entonces $QAP = (QU)\Sigma(P^TV)^T$ es una SVD de QAP, porque QU y P^TV son ortogonales. Luego QAP tiene *los mismos valores singulares* que A, y las tres normas se calculan con ellos. ∎

Esa es la propiedad que hace que la SVD sea la herramienta correcta para medir distancias entre matrices: si una norma no ve más que los valores singulares, la SVD ya la calculó. El capítulo de PCA se apoya exactamente en esto para probar que la SVD truncada es la mejor aproximación de rango bajo.

Observación 8.31 (Cuál es cuál). Conviene quedarse con una imagen de cada una. La espectral mide el *peor caso*: cuánto puede estirar A a un vector. La de Frobenius mide la *energía total*, repartida entre todas las direcciones. La nuclear es la que mejor detecta el *rango*: es la suma de los σ_k, así que penaliza tener muchos valores singulares chicos y no solo uno grande —por eso aparece cuando se quiere forzar que una matriz tenga rango bajo.

8.8 Lo que viene

Cerramos enunciando, sin demostrar, los dos resultados que esta factorización hace posibles y que se tratan en los capítulos siguientes.

Aproximación de rango bajo. Truncar la suma (8.3) en el término d-ésimo,

$$A_d = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T + \cdots + \sigma_d \boldsymbol{u}_d \boldsymbol{v}_d^T,$$

da una matriz de rango d. El **teorema de Eckart-Young** afirma que es la mejor posible:

$$\text{si } \operatorname{rg}(B) \le d, \text{ entonces } \|A - A_d\| \le \|A - B\|,$$

tanto en la norma de Frobenius como en la espectral. Ésa es la razón por la que la SVD truncada se usa para comprimir imágenes y para reducir la dimensión de un conjunto de datos. El enunciado preciso, la demostración y la lectura estadística son el contenido del capítulo de PCA.

La pseudoinversa. Si A no es invertible — o ni siquiera cuadrada — no hay A^{-1}, pero la SVD permite hacer lo más parecido posible: invertir lo que se puede invertir y dejar en cero el resto. Con $\Sigma^+ \in \mathbb{R}^{n\times m}$ la matriz que tiene $1/\sigma_1, \ldots, 1/\sigma_r$ en la diagonal y ceros en el resto, se define

$$A^+ = V\,\Sigma^+\,U^T.$$

Se verá que AA^+ y A^+A son las proyecciones ortogonales sobre $C(A)$ y $C(A^T)$ — comparar con la Proposición 8.18 —, que $A^+ = (A^TA)^{-1}A^T$ cuando las columnas de A son

independientes, y que $A^+\boldsymbol{b}$ es la solución de cuadrados mínimos de norma mínima. Es el contenido del capítulo final.

Ejercicios de desarrollo

Ejercicio de desarrollo 8.2 | La norma espectral

Todo este ejercicio se apoya en la Definición 8.3 y en el Teorema 8.2; casi nada necesita la SVD.

(a) Verificar directamente sobre la definición que

$$\|A\|_2 = \max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \max_{0<\|\boldsymbol{x}\|\leq 1} \|A\boldsymbol{x}\|,$$

es decir, que las tres expresiones dan el mismo número. (Que el máximo se alcance, y no haya que escribir supremo, ya lo sabemos: el Teorema 8.2 exhibe el vector donde se alcanza.)

(b) Calcular $\|A\|_2$ para $A = \left[\begin{smallmatrix} 1 & 0 \\ 0 & 3 \end{smallmatrix}\right]$, $A = \left[\begin{smallmatrix} 0 & 2 \\ 0 & 0 \end{smallmatrix}\right]$ y $A = \left[\begin{smallmatrix} 1 & 1 \\ 0 & 1 \end{smallmatrix}\right]$. En el último caso, comparar $\|A\|_2$ con $\max_i |\lambda_i(A)|$ y observar que la desigualdad del Corolario 8.6 es estricta.

(c) Probar que $\|A\|_2 = \|A^T\|_2$. *Sugerencia:* A^TA y AA^T tienen los mismos autovalores no nulos (Proposición 4.7). Mostrar en cambio con un ejemplo que *no* es cierto que $\|A\boldsymbol{x}\| = \|A^T\boldsymbol{x}\|$ para todo $\boldsymbol{x}$, y probar que sí lo es cuando A conmuta con su traspuesta.

(d) Probar que $\|QA\|_2 = \|A\|_2 = \|AQ'\|_2$ si Q y Q' son ortogonales de tamaños compatibles. *Sugerencia:* las ortogonales no cambian la norma de los vectores.

(e) *(Una submatriz no puede estirar más que la matriz entera.)* Sea B la submatriz de A formada por algunas de sus filas y algunas de sus columnas. Probar que $\sigma_1(B) \leq \sigma_1(A)$, es decir $\|B\|_2 \leq \|A\|_2$, de las dos maneras siguientes.

(i) *A mano.* Si C se obtiene de A quedándose con algunas columnas y $\boldsymbol{y}$ es un vector del tamaño correspondiente, sea $\boldsymbol{x} \in \mathbb{R}^n$ el vector que resulta de rellenar con ceros las posiciones eliminadas: verificar que $A\boldsymbol{x} = C\boldsymbol{y}$ y $\|\boldsymbol{x}\| = \|\boldsymbol{y}\|$, y concluir $\|C\|_2 \leq \|A\|_2$. Después, si D sale de C quedándose con algunas filas, observar que $D\boldsymbol{y}$ es $C\boldsymbol{y}$ con coordenadas borradas, así que $\|D\boldsymbol{y}\| \leq \|C\boldsymbol{y}\|$. Encadenar las dos operaciones.

(ii) *En forma matricial.* Escribir $B = R\,A\,C^T$ con R y C matrices de ceros y unos que seleccionan filas y columnas, verificar que R y C tienen filas ortonormales y deducir la desigualdad del ítem (d).

(f) Sea A con valores singulares $\sigma_1, \ldots, \sigma_r$. Determinar los valores singulares de A^T, de A^TA, de AA^TA, y de A^{-1} cuando A es cuadrada e invertible. ¿Cuánto vale $\|A^{-1}\|_2$?

(g) *(La norma espectral no viene de un producto interno.)* Tomar $A = \left[\begin{smallmatrix} 1 & 0 \\ 0 & 0 \end{smallmatrix}\right]$ y $B = \left[\begin{smallmatrix} 0 & 0 \\ 0 & 1 \end{smallmatrix}\right]$. Calcular $\|A+B\|_2$, $\|A-B\|_2$, $\|A\|_2$, $\|B\|_2$ y verificar que falla la ley del paralelogramo. Concluir, por el Teorema 7.15, que $\|\cdot\|_2$ no proviene de ningún producto interno. Repetir la cuenta con $\|\cdot\|_F$ y las mismas dos matrices, y explicar por qué esta vez la ley *tiene* que cumplirse.

Se entrega por escrito. El ítem (b) muestra que σ_1 y $|\lambda|_{\max}$ son cosas distintas incluso para matrices cuadradas; el (g) es la diferencia de fondo entre las dos normas de matrices que manejamos.

Ejercicio de desarrollo 8.3 | La SVD y los cuatro subespacios

Sea $A \in \mathbb{R}^{m\times n}$ de rango r, con SVD $A = U\Sigma V^T$.

(a) Calcular la SVD completa de $A = \begin{bmatrix} 0 & 2 & 0 \\ 0 & 0 & 3 \\ 0 & 0 & 0 \end{bmatrix}$ y exhibir las bases ortonormales de los cuatro subespacios que da la Proposición 8.18. (Acá U y V son matrices de permutación.)

(b) Verificar sobre esa matriz que $U_rU_r^T$ y $V_rV_r^T$ son las proyecciones ortogonales sobre $C(A)$ y $C(A^T)$: comprobar $P^2 = P = P^T$ y $\operatorname{tr}(P) = r$.

(c) Probar en general que $U_rU_r^TA = A$ y $AV_rV_r^T = A$, e interpretar las dos igualdades en palabras.

(d) Probar que $\sigma_1(A) \geq \sigma_1(A_d)$ y, más precisamente, que los valores singulares de $A_d = \sum_{k\leq d}\sigma_k\boldsymbol{u}_k\boldsymbol{v}_k^T$ son $\sigma_1,\dots,\sigma_d$, y los de $A - A_d$ son $\sigma_{d+1},\dots,\sigma_r$. Deducir $\|A - A_d\|_2 = \sigma_{d+1}$.

(e) *(La esfera y el elipsoide.)* Para $A = \left[\begin{smallmatrix} 3 & 0 \\ 4 & 5 \end{smallmatrix}\right]$ del Ejemplo 8.13, dibujar la circunferencia unitaria, marcar $\boldsymbol{v}_1$ y $\boldsymbol{v}_2$, y dibujar su imagen $\{A\boldsymbol{x} : \|\boldsymbol{x}\| = 1\}$ marcando $\sigma_1\boldsymbol{u}_1$ y $\sigma_2\boldsymbol{u}_2$. Verificar sobre el dibujo que $\boldsymbol{v}_1 \perp \boldsymbol{v}_2$ y que $\boldsymbol{u}_1 \perp \boldsymbol{u}_2$, y observar que A *no* preserva los ángulos entre otros pares de vectores.

(f) Probar que $\{A\boldsymbol{x} : \|\boldsymbol{x}\| \leq 1\}$ es el elipsoide *lleno*, y que su volumen es $|\det A|$ veces el de la bola unitaria. *Sugerencia:* $|\det A| = \sigma_1\cdots\sigma_n$ (probarlo también).

Se entrega por escrito. El ítem (d) es el que se usa en el capítulo de PCA para medir el error de la SVD truncada; el (f) explica por qué el determinante mide volúmenes.

Ejercicios

1. Una matriz simétrica S tiene autovectores ortonormales $\boldsymbol{v}_1,\dots,\boldsymbol{v}_n$, así que todo $\boldsymbol{x}$ se escribe $\boldsymbol{x} = c_1\boldsymbol{v}_1 + \cdots + c_n\boldsymbol{v}_n$. Explicar estas dos fórmulas:
$$\boldsymbol{x}^T\boldsymbol{x} = c_1^2 + \cdots + c_n^2, \qquad \boldsymbol{x}^TS\boldsymbol{x} = \lambda_1c_1^2 + \cdots + \lambda_nc_n^2.$$

2. El ejercicio anterior da una forma clara del cociente de Rayleigh:
$$R(\boldsymbol{x}) = \frac{\boldsymbol{x}^TS\boldsymbol{x}}{\boldsymbol{x}^T\boldsymbol{x}} = \frac{\lambda_1c_1^2 + \cdots + \lambda_nc_n^2}{c_1^2 + \cdots + c_n^2}.$$

¿Por qué el valor máximo de este cociente es λ_1? ¿Y por qué se alcanza cuando $c_1 = 1$ y $c_2 = \cdots = c_n = 0$? Ésta es la forma más simple de entender el Teorema 8.2.

3. Siguiendo el ejercicio anterior: maximizar $R(\boldsymbol{x})$ con la condición $\boldsymbol{x}^T\boldsymbol{v}_1 = 0$. ¿Qué significa esa condición para c_1? ¿Por qué el máximo es ahora λ_2? ¿Y sujeto a qué dos condiciones sobre $\boldsymbol{x}$ el máximo vale λ_3?

4. Para maximizar $\boldsymbol{x}^T S\boldsymbol{x}$ con la restricción $\boldsymbol{x}^T\boldsymbol{x} = 1$, el método de Lagrange trabaja con $L(\boldsymbol{x}) = \boldsymbol{x}^T S\boldsymbol{x} - \lambda(\boldsymbol{x}^T\boldsymbol{x} - 1)$. Mostrar que $\nabla L = \boldsymbol{0}$ es exactamente $S\boldsymbol{x} = \lambda\boldsymbol{x}$, de modo que otra vez $\max R(\boldsymbol{x}) = \lambda_1$.

5. Encontrar los σ, los $\boldsymbol{v}$ y los $\boldsymbol{u}$ en la SVD de $A = \left[\begin{smallmatrix} 3 & 4 \\ 0 & 5 \end{smallmatrix}\right]$.

6. Encontrar la SVD de la matriz de rango uno $A = \left[\begin{smallmatrix} 2 & 4 \\ 1 & 2 \end{smallmatrix}\right]$, y factorizar A^TA como $Q\Lambda Q^T$.

7. Sea A con valores singulares $\sigma_1 \geq \cdots \geq \sigma_r > 0$ y sea $B = A - \sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^T$ la matriz que queda al quitarle a A su sumando de rango uno más grande. ¿Cuáles son los valores singulares de B? ¿Cuánto vale $\|B\|_2$? ¿Cuál es el rango de B?

8. Verificar que la traza de $S = \left[\begin{smallmatrix} 0 & A \\ A^T & 0 \end{smallmatrix}\right]$, sumando sus elementos diagonales, coincide con la suma de los autovalores de (8.5). Si A es diagonal de $n \times n$ con elementos $1, 2, \ldots, n$, ¿cuáles son los $2n$ autovalores y autovectores de S? Describir además los autovectores correspondientes a $\lambda = 0$ en el caso general.

9. La ecuación (8.4) es $AV_r = U_r\Sigma_r$. Multiplicando por V_r^T se obtiene $A = U_r\Sigma_r V_r^T$. Para ese paso *no* se puede usar $V_rV_r^T = I$ (que es falso cuando $r < n$). Mostrar en cambio que la matriz $U_r\Sigma_r V_r^T$ satisface (8.1), y concluir que es A.

10. He aquí una prueba rápida de la SVD. El paso 2 usa las factorizaciones $A^TA = V\Lambda V^T$ y $AA^T = U\Lambda U^T$ (con los mismos autovalores en Λ):

1	$A(A^TA)$	$= (AA^T)A$
2	$AV\Lambda V^T$	$= U\Lambda U^TA$
3	$(U^TAV)\Lambda$	$= \Lambda(U^TAV)$
4	U^TAV debe ser diagonal	

El paso 3 multiplica el paso 2 por U^T a izquierda y por V a derecha. Entonces U^TAV conmuta con la matriz diagonal Λ.

   (a) Probar, en el caso 3×3, que si $\Sigma\Lambda = \Lambda\Sigma$ con Λ diagonal de elementos *distintos*, entonces Σ es diagonal. Comparar las primeras filas de los dos productos.

   (b) Identificar dónde falla el argumento si Λ tiene autovalores repetidos, y relacionarlo con la observación de la Sección 8.3 sobre por qué los $\boldsymbol{u}$ hay que definirlos como $A\boldsymbol{v}/\sigma$.

   (c) El mismo problema aparece en las pruebas simples del teorema espectral $S = Q\Lambda Q^T$. ¿Dónde?

11. Una matriz de 2×2 tiene cuatro elementos y su SVD, cuatro parámetros: θ, ϕ, σ_1, σ_2. Pasemos a una de 2×3, con seis elementos. ¿Cuántos valores singulares tiene? La matriz U (2×2) necesita un solo ángulo; ¿cuántos ángulos determinan entonces a V (3×3)? *Ayuda:* el espacio fila de A es un plano en $\mathbb{R}^3$; hacen falta ciertos ángulos para ubicar ese plano y uno más para elegir $\boldsymbol{v}_1$ y $\boldsymbol{v}_2$ dentro de él.

12. Cada matriz de 3×3 tiene nueve elementos, así que $U\Sigma V^T$ debe tener nueve parámetros. ¿Cuántos hay en U, en Σ y en V? Responder lo mismo para 4×4. ¿Cuántos parámetros describen una rotación del espacio de dimensión 4?

13. ¿Cuántos números hacen falta para dar la dirección de un vector unitario $\boldsymbol{v}_1$ de $\mathbb{R}^5$? ¿Y la de un unitario $\boldsymbol{v}_2$ ortogonal a él? ¿Y para $\boldsymbol{v}_3$, $\boldsymbol{v}_4$, $\boldsymbol{v}_5$? ¿Cuántos en total?

14. Mostrar que una matriz de $m \times n$ y rango r tiene $r(m+n-r)$ parámetros libres en su SVD $A = U_r \Sigma_r V_r^T$. ¿Por qué r vectores ortonormales $\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r$ de $\mathbb{R}^m$ tienen $(m-1) + (m-2) + \cdots + (m-r)$ parámetros? *Otro camino:* usar $A = CR$ del Capítulo 1, donde R contiene una identidad de $r \times r$ y eso quita r^2 parámetros de los $rm + rn$.

15. Si $\boldsymbol{v}$ es autovector de A^TA con autovalor $\lambda \neq 0$, ¿de qué matriz es autovector $A\boldsymbol{v}$, y con qué autovalor?

16. Si $A = U\Sigma V^T$ es cuadrada e invertible, escribir A^{-1} en términos de U, Σ y V. ¿Cuáles son los valores singulares de A^TA (no los de A)?

17. Si $A = A^T$ tiene columnas ortogonales $\boldsymbol{x}_1, \boldsymbol{x}_2, \boldsymbol{x}_3$ de $\mathbb{R}^3$ con normas 2, 3 y 4, encontrar su SVD.

18. Las razones del éxito de los autovalores están en $A^k = X\Lambda^k X^{-1}$: (a) los autovalores de A^k son $\lambda_1^k, \ldots, \lambda_n^k$; (b) un autovector de A también lo es de A^k. Mostrar que (a) y (b) son *falsas* para valores y vectores singulares, con $A = \left[\begin{smallmatrix} -2 & -6 \\ 6 & 2 \end{smallmatrix}\right]$.

9 CAPÍTULO

Análisis de Componentes Principales (PCA)

9.1 Introducción

El **Análisis de Componentes Principales** (PCA, por sus siglas en inglés) es una técnica *no supervisada* para **reducir la dimensión** de un conjunto de datos conservando la mayor parte posible de su variabilidad. Toma p variables, en general *correlacionadas*, y las reemplaza por $d \leq p$ variables nuevas y *no correlacionadas*: las *componentes principales*, ordenadas de mayor a menor varianza.

PCA se usa de manera transversal en análisis de datos, aprendizaje automático y visualización, sobre todo con datos de **alta dimensión** (imágenes, señales biomédicas, genómica, texto vectorizado), donde sirve para *resumir* información redundante y filtrar ruido, *visualizar* estructura en dos o tres dimensiones (PC1 contra PC2) y *acelerar* y *estabilizar* los modelos que se ajustan después. Un ejemplo típico son las imágenes de alta resolución: la matriz de intensidades contiene información redundante, y una aproximación de rango bajo la comprime sin que el ojo note la diferencia.

Como ya conocemos la SVD, empezamos por la pregunta más fácil de formular:

dada una matriz X, ¿cuál es la matriz de rango $\leq d$ más cercana a X?

La respuesta es el **teorema de Eckart–Young**: la SVD truncada. La pregunta de PCA,

¿cuál es el subespacio de dimensión d que mejor aproxima a una nube de puntos de $\mathbb{R}^p$?,

resulta ser un caso particular de la primera, y su solución sale de Eckart–Young casi gratis. El plan es el siguiente.

1. Repasamos las normas de matrices que vamos a usar: Frobenius, espectral y nuclear, y la SVD truncada (Secciones 9.2 y 9.3).
2. Probamos el teorema de Eckart–Young: entre *todas* las matrices de rango $\leq d$, la más cercana a X es la SVD truncada X_d (Sección 9.4). Es la deuda que quedó pendiente en el capítulo de la SVD. Enseguida lo vemos funcionar en una foto (Sección 9.5).
3. Deducimos la solución del problema de PCA: las direcciones principales son los primeros d vectores singulares derechos de la matriz de datos (Sección 9.6).
4. Releemos la solución con los ojos de la estadística: centrado, matriz de covarianza, máxima varianza, componentes no correlacionadas y proporción de varianza explicada (Sección 9.7).
5. Hacemos un PCA a mano y decimos cómo se calcula en la computadora (Sección 9.8).

Observación 9.1 (Un poco de historia). Pearson [12] planteó en 1901 el problema de las "rectas y planos más cercanos a un sistema de puntos" (nuestra Sección 9.6), y Hotelling [8] lo reformuló en 1933 como maximización de varianza (nuestra Sección 9.7). El teorema de aproximación por matrices de rango bajo lleva el nombre de Eckart y Young [3] (1936), aunque para operadores integrales ya lo había probado E. Schmidt en 1907; ver la historia de la SVD de Stewart [13].

9.2 Lo que vamos a usar de las normas

Para decidir qué matriz está "más cerca" de X hay que medir distancias entre matrices, y eso ya está hecho: la norma de Frobenius se definió en la Sección 1.3.6, la espectral en la Sección 8.1, y la Sección 8.7 las puso a las dos —y a la nuclear— en términos de los valores singulares,

$$\|A\|_2 = \sigma_1, \qquad \|A\|_F = \left(\sigma_1^2 + \cdots + \sigma_r^2\right)^{1/2}, \qquad \|A\|_* = \sigma_1 + \cdots + \sigma_r,$$

y probó que las tres son *ortogonalmente invariantes* (Definición 8.29 y Corolario 8.30): no cambian al multiplicar por matrices ortogonales, porque eso no cambia los valores singulares. Esa es la propiedad que vamos a usar una y otra vez.

De la norma de Frobenius necesitamos además dos hechos elementales, que conviene tener a mano escritos en forma matricial.

Proposición 9.2 (Lo que hace falta de Frobenius). Sean $X, A, B \in \mathbb{R}^{n\times p}$ y sea $\langle A, B\rangle_F = \operatorname{tr}(A^T B) = \sum_{i,j} a_{ij} b_{ij}$ el producto interno de Frobenius de la Sección 1.3.6.

(a) **Por filas y por columnas.**

$$\|X\|_F^2 = \operatorname{tr}(X^T X) = \operatorname{tr}(X X^T) = \sum_{j=1}^{p} \|\operatorname{col}_j(X)\|^2 = \sum_{i=1}^{n} \|\operatorname{fila}_i(X)\|^2.$$

(b) **Pitágoras.** Si $P \in \mathbb{R}^{n\times n}$ es una proyección ortogonal ($P = P^T = P^2$), entonces $\|X\|_F^2 = \|PX\|_F^2 + \|(I-P)X\|_F^2$; y si $P \in \mathbb{R}^{p\times p}$ lo es, $\|X\|_F^2 = \|XP\|_F^2 + \|X(I-P)\|_F^2$.

Demostración. (a) La entrada (j,j) de $X^T X$ es $\operatorname{col}_j(X)^T \operatorname{col}_j(X) = \|\operatorname{col}_j(X)\|^2$, y sumando en j queda $\operatorname{tr}(X^T X) = \sum_j \|\operatorname{col}_j(X)\|^2$, que es la suma de todos los x_{ij}^2. La cuenta con XX^T es la misma leída por filas.

(b) Escribimos $X = PX + (I-P)X$. Las dos piezas son ortogonales para el producto de Frobenius:

$$\langle PX, (I-P)X\rangle_F = \operatorname{tr}\Big(X^T P^T (I-P) X\Big) = \operatorname{tr}\Big(X^T (P - P^2) X\Big) = 0,$$

usando $P^T = P$ y $P^2 = P$. Desarrollando $\|X\|_F^2 = \langle PX + (I-P)X,\ PX + (I-P)X\rangle_F$ desaparece el término cruzado. El caso de la derecha es igual con $\operatorname{tr}(XP(I-P)X^T)$. ∎

Observación 9.3 (Dos lecturas de la norma de Frobenius). El ítem (a) es el que vamos a usar todo el tiempo y conviene subrayarlo: la norma de Frobenius al cuadrado de una matriz de datos es *la suma de los cuadrados de las longitudes de sus filas*, es decir la suma de $\|\boldsymbol{x}_i\|^2$ sobre las n observaciones. Medir una matriz en norma de Frobenius es, para nosotros, medir una nube de puntos.

9.3 La SVD truncada

La Proposición 8.27 —la que dice que $\|X\|_F^2 = \sum_k \sigma_k^2$— es la que conecta a Frobenius con la SVD, y lo hace de un modo muy concreto: recordemos que $X = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T + \cdots + \sigma_r u_r v_r^T$ es una suma de matrices de rango uno *ordenadas por importancia*. Quedarse con los primeros d sumandos es *truncar* la SVD.

Corolario 9.4 (La SVD truncada)**.** Sea $X = U\Sigma V^T$ con $\sigma_1 \geq \cdots \geq \sigma_r > 0$ y sea $d \leq r$. Llamamos $U_d \in \mathbb{R}^{n\times d}$, $V_d \in \mathbb{R}^{p\times d}$ a las matrices con las primeras d columnas de U y de V, $\Sigma_d = \operatorname{diag}(\sigma_1, \ldots, \sigma_d)$, y

$$X_d := U_d \Sigma_d V_d^T = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T + \cdots + \sigma_d u_d v_d^T \qquad (\textbf{SVD truncada de } X).$$

Entonces:

(a) $X_d = XV_dV_d^T = U_dU_d^TX$: es la proyección (por filas) de X sobre $\operatorname{span}(\boldsymbol{v}_1, \ldots, \boldsymbol{v}_d)$, y también la proyección (por columnas) sobre $\operatorname{span}(\boldsymbol{u}_1, \ldots, \boldsymbol{u}_d)$.

(b) $\operatorname{rango}(X_d) = d$.

(c) $\|X_d\|_F^2 = \sigma_1^2 + \cdots + \sigma_d^2$ y $\|X - X_d\|_F^2 = \sigma_{d+1}^2 + \cdots + \sigma_r^2$.

(d) $\|X - X_d\|_2 = \sigma_{d+1}$ y $\|X - X_d\|_* = \sigma_{d+1} + \cdots + \sigma_r$ (con $\sigma_{r+1} := 0$).

Demostración. (a) Como las $\boldsymbol{v}_i$ son ortonormales, $\boldsymbol{v}_i^T V_d$ es la fila i-ésima de I_d si $i \leq d$ y es cero si $i > d$. Entonces $XV_d = \sum_{i=1}^r \sigma_i u_i (\boldsymbol{v}_i^T V_d) = \sum_{i=1}^d \sigma_i u_i e_i^T = U_d\Sigma_d$, y multiplicando por V_d^T queda X_d. Del mismo modo $U_d^T X = \Sigma_d V_d^T$.

(b) $X_d = U_d(\Sigma_d V_d^T)$: las columnas de U_d son linealmente independientes y $\Sigma_d V_d^T$ tiene d filas linealmente independientes, así que el producto tiene rango d.

(c) y (d) $X - X_d = \sum_{i>d} \sigma_i u_i v_i^T = U_{>d}\Sigma_{>d}V_{>d}^T$, donde $U_{>d}$ y $V_{>d}$ (las columnas restantes) tienen columnas ortonormales: es una SVD de $X - X_d$, cuyos valores singulares son entonces $\sigma_{d+1} \geq \cdots \geq \sigma_r$. Las tres normas se leen de los valores singulares. Igual para X_d, cuyos valores singulares son $\sigma_1, \ldots, \sigma_d$. ∎

Observación 9.5 (Cuánto se comprime)**.** Guardar $X \in \mathbb{R}^{n\times p}$ cuesta np números. Guardar $X_d = U_d\Sigma_d V_d^T$ cuesta $d(n + p + 1)$: d columnas de largo n, d de largo p y d valores singulares. Para una imagen de 512×512 con $d = 20$ son 20 500 números contra 262 144: menos del 8%. La pregunta es si con tan poco se pierde mucho. Eckart–Young contesta: el error es exactamente el de los valores singulares descartados, y *ninguna* otra matriz de rango $\leq d$ lo hace mejor.

9.4 El teorema de Eckart–Young

Ahora sí, la pregunta del capítulo. Dada $X \in \mathbb{R}^{n\times p}$ y d menor que su rango, queremos resolver

$$\min_{M\in\mathbb{R}^{n\times p},\ \operatorname{rango}(M)\leq d} \|X - M\|. \tag{9.1}$$

No es un problema de optimización cualquiera: el conjunto de matrices de rango $\leq d$ no es convexo (la suma de dos matrices de rango uno puede tener rango dos), así que las

herramientas habituales no se aplican. Es excepcional que un problema así tenga una solución explícita, y esta la tiene.

Teorema 9.6 (Eckart–Young [3]). Sea $X \in \mathbb{R}^{n\times p}$ con valores singulares $\sigma_1 \geq \cdots \geq \sigma_r > 0$ y sea $1 \leq d < r$. Para toda $M \in \mathbb{R}^{n\times p}$ con $\operatorname{rango}(M) \leq d$,

$$\|X - M\|_2 \;\geq\; \sigma_{d+1} = \|X - X_d\|_2\,, \tag{9.2}$$

$$\|X - M\|_F^2 \;\geq\; \sigma_{d+1}^2 + \cdots + \sigma_r^2 = \|X - X_d\|_F^2\,. \tag{9.3}$$

Es decir, la SVD truncada X_d es una matriz de rango $\leq d$ lo más cercana posible a X, en la norma espectral y en la de Frobenius. En Frobenius, si $\sigma_d > \sigma_{d+1}$, es la única (Observación 9.12).

La demostración usa dos herramientas. La primera dice cuánto puede estirar X a un vector según dónde esté; es la versión "con valores singulares" del cociente de Rayleigh.

Lema 9.7 (Cuánto estira X a un vector). Sea $X = U\Sigma V^T$ una SVD completa de $X \in \mathbb{R}^{n\times p}$: las columnas $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_p$ de V forman una base ortonormal de $\mathbb{R}^p$, $X\boldsymbol{v}_i = \sigma_i u_i$ para $i \leq r$, $X\boldsymbol{v}_i = 0$ para $i > r$, y convenimos $\sigma_i = 0$ para $r < i \leq p$. Para cada $k = 1, \ldots, p$:

(a) si $\boldsymbol{w} \in \operatorname{span}(\boldsymbol{v}_1, \ldots, \boldsymbol{v}_k)$, entonces $\|X\boldsymbol{w}\| \geq \sigma_k \|\boldsymbol{w}\|$;

(b) si $\boldsymbol{w} \in \operatorname{span}(\boldsymbol{v}_k, \ldots, \boldsymbol{v}_p)$, entonces $\|X\boldsymbol{w}\| \leq \sigma_k \|\boldsymbol{w}\|$.

Demostración. Escribimos $\boldsymbol{w} = c_1\boldsymbol{v}_1 + \cdots + c_p v_p$, de modo que $\|\boldsymbol{w}\|^2 = \sum_i c_i^2$. Como $X\boldsymbol{w} = \sum_{i\leq r} c_i\sigma_i u_i$ y los $\boldsymbol{u}_i$ son ortonormales,

$$\|X\boldsymbol{w}\|^2 = \sum_{i=1}^{p} c_i^2\sigma_i^2.$$

En (a) solo aparecen los c_i con $i \leq k$, y para ellos $\sigma_i \geq \sigma_k$: la suma es $\geq \sigma_k^2 \sum_i c_i^2$. En (b) solo aparecen los c_i con $i \geq k$, y para ellos $\sigma_i \leq \sigma_k$. ∎

Con $k = 1$, la parte (b) es $\|X\boldsymbol{w}\| \leq \sigma_1\|\boldsymbol{w}\|$: volvemos a encontrar $\|X\|_2 = \sigma_1$, que es el Teorema 8.2.

La segunda herramienta es puro conteo de dimensiones y no habla de matrices para nada. La aislamos porque la vamos a usar dos veces.

Lema 9.8 (Tres subespacios que se cortan). Sean $\mathcal{U}_1, \mathcal{U}_2, \mathcal{U}_3$ subespacios de $\mathbb{R}^p$ con

$$\dim\mathcal{U}_1 + \dim\mathcal{U}_2 + \dim\mathcal{U}_3 \;>\; 2p.$$

Entonces $\mathcal{U}_1 \cap \mathcal{U}_2 \cap \mathcal{U}_3 \neq \{0\}$: hay un vector unitario que está en los tres.

Demostración. De la fórmula de las dimensiones de la suma, $\dim(\mathcal{U} + \mathcal{U}') = \dim\mathcal{U} + \dim\mathcal{U}' - \dim(\mathcal{U} \cap \mathcal{U}')$, y de que $\mathcal{U} + \mathcal{U}'$ es un subespacio de $\mathbb{R}^p$, sale

$$\dim(\mathcal{U} \cap \mathcal{U}') \;\geq\; \dim\mathcal{U} + \dim\mathcal{U}' - p.$$

Aplicándola dos veces, primero a $\mathcal{U}_1 \cap \mathcal{U}_2$ y después a ese subespacio con $\mathcal{U}_3$,

$$\dim(\mathcal{U}_1 \cap \mathcal{U}_2 \cap \mathcal{U}_3) \;\geq\; \dim \mathcal{U}_1 + \dim \mathcal{U}_2 + \dim \mathcal{U}_3 - 2p \;\geq\; 1. \qquad \blacksquare$$

La tercera herramienta es una desigualdad clásica para valores singulares, que sale del lema anterior.

Lema 9.9 (Desigualdad de Weyl para valores singulares). Sean $A, B \in \mathbb{R}^{n\times p}$, con la convención $\sigma_k(\cdot) = 0$ si k supera al rango. Si $i, j \geq 1$ e $i + j - 1 \leq p$, entonces

$$\sigma_{i+j-1}(A + B) \;\leq\; \sigma_i(A) + \sigma_j(B). \tag{9.4}$$

Demostración. Sea $C = A + B$ y sean $a_1, \ldots, a_p$, $b_1, \ldots, b_p$ y $c_1, \ldots, c_p$ bases ortonormales de vectores singulares derechos de A, B y C (como en el Lema 9.7). Los subespacios

$$\mathcal{U}_1 = \operatorname{span}(c_1, \ldots, c_{i+j-1}), \qquad \mathcal{U}_2 = \operatorname{span}(a_i, \ldots, a_p), \qquad \mathcal{U}_3 = \operatorname{span}(b_j, \ldots, b_p)$$

tienen dimensiones $i + j - 1$, $p - i + 1$ y $p - j + 1$, que suman $2p + 1 > 2p$. Por el Lema 9.8 hay un vector unitario $\boldsymbol{w}$ en los tres. Entonces, por el Lema 9.7, (a) para C y (b) para A y para B,

$$\sigma_{i+j-1}(C) \;\leq\; \|C\boldsymbol{w}\| \;\leq\; \|A\boldsymbol{w}\| + \|B\boldsymbol{w}\| \;\leq\; \sigma_i(A) + \sigma_j(B). \qquad \blacksquare$$

Observación 9.10. Weyl probó en 1912 la desigualdad análoga para los autovalores de matrices simétricas; la versión para valores singulares se demuestra igual (ver [7] o [1]). Una consecuencia útil: con $j = 1$ y $B = E$, $|\sigma_i(A + E) - \sigma_i(A)| \leq \|E\|_2$, es decir, *los valores singulares son estables frente a perturbaciones*: si a los datos se les suma un ruido E, ningún σ_i se mueve más que $\|E\|_2$ (Ejercicio 9.4).

Demostración del Teorema de Eckart–Young. Sea M de rango $\leq d$; entonces $\sigma_{d+1}(M) = 0$. Aplicamos la desigualdad de Weyl a $A = X - M$ y $B = M$, con $j = d+1$ e $i = 1, \ldots, r-d$ (de modo que $i + j - 1 = d + i \leq r \leq p$):

$$\sigma_{d+i}(X) = \sigma_{d+i}\Big((X - M) + M\Big) \;\leq\; \sigma_i(X - M) + \sigma_{d+1}(M) = \sigma_i(X - M). \tag{9.5}$$

Con $i = 1$ queda $\sigma_{d+1}(X) \leq \sigma_1(X - M) = \|X - M\|_2$, que es (9.2). Elevando (9.5) al cuadrado y sumando en $i = 1, \ldots, r - d$,

$$\sum_{k=d+1}^{r} \sigma_k^2(X) \;\leq\; \sum_{i=1}^{r-d} \sigma_i^2(X - M) \;\leq\; \sum_{i\geq 1} \sigma_i^2(X - M) = \|X - M\|_F^2 ,$$

que es (9.3). Por último, X_d tiene rango d y los errores $\|X - X_d\|_2 = \sigma_{d+1}$ y $\|X - X_d\|_F^2 = \sum_{k>d} \sigma_k^2$ son los del Corolario 9.4: se alcanzan las cotas. $\blacksquare$

Observación 9.11 (La demostración del video, en la norma espectral). Para la norma espectral el argumento es especialmente transparente (es el que da Strang [14]): como $\operatorname{rango}(M) \leq d$, el espacio nulo $N(M)$ tiene dimensión $\geq p - d$, y $\operatorname{span}(\boldsymbol{v}_1, \ldots, \boldsymbol{v}_{d+1})$ tiene dimensión $d + 1$; las dimensiones suman más que p, así que hay un vector unitario $\boldsymbol{w}$ en los dos (es el Lema 9.8 con $\mathcal{U}_3 = \mathbb{R}^p$). Entonces $(X - M)\boldsymbol{w} = X\boldsymbol{w}$ y, por el Lema 9.7(a), $\|X - M\|_2 \geq \|X\boldsymbol{w}\| \geq \sigma_{d+1}$. La desigualdad de Weyl es la misma idea con un subespacio más, lo que permite comparar *todos* los valores singulares y no solo el primero.

Observación 9.12 (¿Es única la mejor aproximación?). En la norma de Frobenius, si $\sigma_d > \sigma_{d+1}$, X_d es la *única* matriz de rango $\leq d$ a distancia mínima de X; no lo vamos a demostrar. En la norma espectral, en cambio, no es única: esa norma solo "mira" el mayor valor singular del error, y hay lugar para mover el resto (Ejercicio 9.11).

Observación 9.13 (Eckart–Young–Mirsky: todas las normas invariantes). Que el minimizador sea la SVD truncada no es exclusivo de las normas de Frobenius y espectral. Mirsky [11] probó que para *toda* norma ortogonalmente invariante (Definición 8.29)

$$\min_{\text{rango}(M)\leq d} \|X - M\| = \|X - X_d\|.$$

El minimizador es el mismo; lo que cambia con la norma es el valor mínimo: $\left(\sum_{i>d} \sigma_i^2\right)^{1/2}$ en Frobenius, σ_{d+1} en la espectral, $\sum_{i>d} \sigma_i$ en la nuclear. Hay una demostración corta en [10]. La invariancia es esencial: para la norma $\|A\|_\infty$ = máxima suma de módulos por fila, que no es ortogonalmente invariante, el teorema es *falso* (Ejercicio 9.12).

Observación 9.14 (Otras demostraciones). El libro de Strang presenta dos demostraciones más para la norma de Frobenius: una de G. W. Stewart, que parte de la SVD de la matriz óptima M (y no de X), y otra de N. Srebro, que iguala a cero las derivadas de $E(C, R) = \|X - CR\|_F^2$ respecto de los factores C y R de $M = CR$ (Ejercicio 9.13).

9.5 Un ejemplo: la foto del tigre

Una imagen en escala de grises es una matriz: la entrada $a_{ij} \in [0, 1]$ es la intensidad del píxel de la fila i y la columna j (0 es negro, 1 es blanco). La foto del tigre de la Figura 9.1 es una matriz $A \in \mathbb{R}^{620\times 600}$. Su SVD la escribe como suma de matrices de rango uno,

$$A = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T + \sigma_2 \boldsymbol{u}_2 \boldsymbol{v}_2^T + \cdots + \sigma_r u_r v_r^T, \qquad r = \text{rango}(A) = 598,$$

y la SVD truncada $A_d = \sum_{i\leq d} \sigma_i u_i v_i^T$ se queda con los primeros d términos. Por el Teorema de Eckart–Young, A_d es la mejor imagen que se puede armar con d "piezas" de rango uno.

Cómo se ve una matriz de rango uno. En $A_1 = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T$ la entrada (i, j) es $\sigma_1 (\boldsymbol{u}_1)_i (\boldsymbol{v}_1)_j$: todas las filas son múltiplos de la misma fila $\boldsymbol{v}_1^T$ y todas las columnas son múltiplos de la misma columna $\boldsymbol{u}_1$. Por eso la imagen $d = 1$ es un "tejido escocés" de franjas horizontales y verticales, sin ninguna diagonal. Como A tiene entradas no negativas, $\boldsymbol{u}_1$ y $\boldsymbol{v}_1$ se pueden elegir con entradas no negativas (Perron–Frobenius aplicado a $A^T A$), y A_1 es esencialmente el "gris promedio" de la foto modulado por filas y columnas. Ese primer término solo ya se lleva el 81% de $\|A\|_F^2 = \sum \sigma_i^2$; los términos siguientes van agregando bordes y detalles.

Cuánto se guarda. Como vimos en la Observación 9.5, guardar A cuesta $mn = 372\,000$ números y guardar A_d cuesta $d(m + n + 1)$. Con $d = 50$ son 61 050 números, el 16,4%, y el tigre se reconoce sin problemas; con $d = 20$ (el 6,6%) ya se ven rayas horizontales y verticales, que son la huella de las matrices de rango uno.

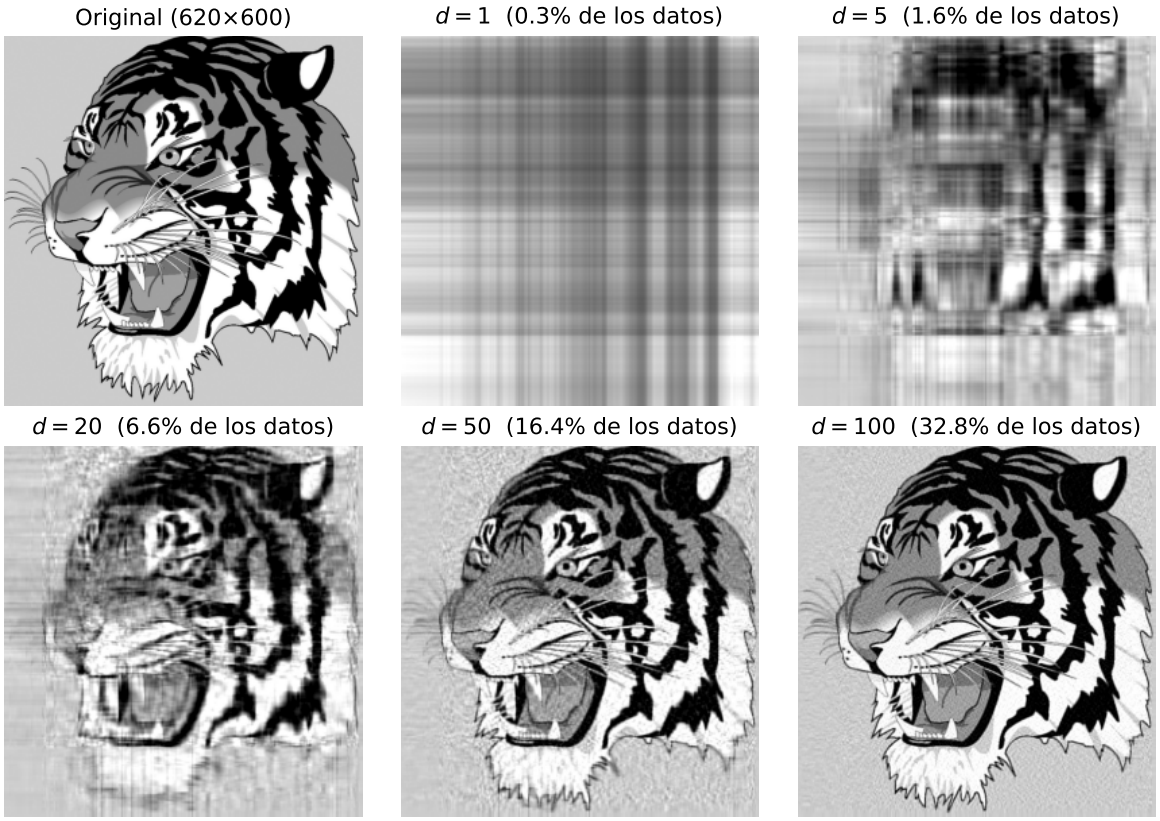


Figura 9.1. El tigre (620×600; es el dibujo clásico que se distribuye con Ghostscript, pasado a escala de grises) y sus SVD truncadas A_d. Entre paréntesis, la proporción $d(m+n+1)/(mn)$ de números que hay que guardar.

Las cotas de Eckart–Young, en números. Eckart–Young no solo dice que A_d es óptima: dice *cuánto* vale el error, y lo dice solo en términos de los valores singulares descartados. La tabla lo verifica para el tigre ($\|A\|_F \approx 429{,}8$, $\sigma_1 \approx 387{,}3$).

d	σ_{d+1}	$\|A - A_d\|_2$	$\left(\sum_{i>d} \sigma_i^2\right)^{1/2}$	$\|A - A_d\|_F$	$\|A - A_d\|_F \,/\, \|A\|_F$
5	46,48	46,48	147,67	147,67	0,34
20	17,77	17,77	96,40	96,40	0,22
50	9,35	9,35	65,40	65,40	0,15
100	5,18	5,18	42,65	42,65	0,10

También se cumple $\|A - A_d\|_2 \le \|A - A_d\|_F \le \sqrt{r-d}\;\|A - A_d\|_2$ y, en la norma nuclear, $\|A - A_d\|_* = \sum_{i>d} \sigma_i$ (por ejemplo 1041,3 para $d = 50$).

Comparación con borrar filas y columnas. Otra manera ingenua de "comprimir" es quedarse con una fracción $1 - c$ de las filas y de las columnas: se guardan $(1-c)^2 mn$ números. Para gastar lo mismo que la SVD con $d = 50$ hay que tomar

$$(1-c)^2 mn = d(m+n+1) \quad \Longrightarrow \quad c = 1 - \sqrt{\frac{d(m+n+1)}{mn}} \approx 0{,}59,$$

es decir, ¡tirar el 59% de las filas y el 59% de las columnas! La Figura 9.2 compara, a igual cantidad de números guardados, borrar las filas y columnas centrales, borrar filas y

columnas al azar (pintándolas de negro para que la imagen conserve el tamaño), rellenar cada fila o columna borrada con la vecina conservada más cercana, y la SVD truncada.

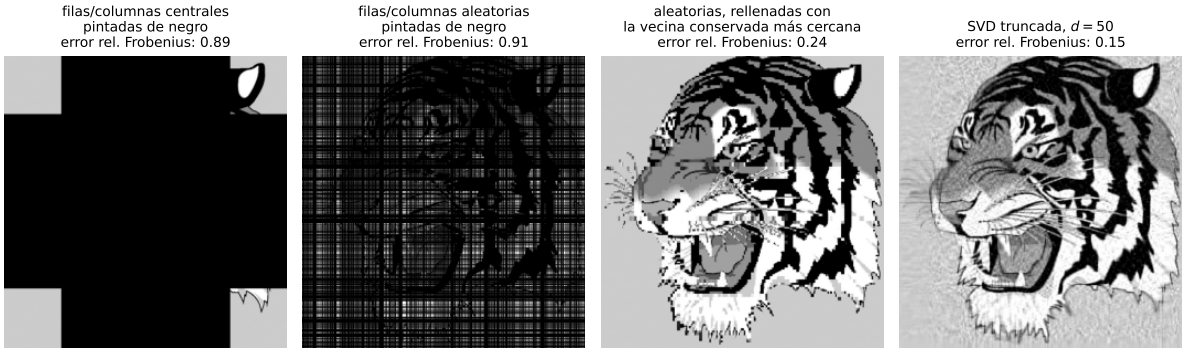


Figura 9.2. Cuatro imágenes que cuestan lo mismo que A_{50} ($c \approx 59\%$ de filas y columnas descartadas en las tres primeras).

La SVD gana en las dos normas: el error espectral es 9,35 contra 19,8 del relleno por vecinos y más de 300 al pintar de negro; el error relativo de Frobenius es 0,15 contra 0,24. Y eso a pesar de que la imagen rellenada tiene rango hasta 243, mucho más que 50. Dos comentarios honestos:

- Eckart–Young compara A_d con matrices de rango $\leq d$; las imágenes con filas borradas tienen rango mayor, así que el teorema no decide la comparación: la decide la cuenta.
- A la vista, la imagen al azar rellenada con la vecina más cercana parece más nítida que A_{50} aunque esté más lejos en norma. Este tigre es un dibujo con zonas de gris constante, y duplicar filas vecinas casi no se nota; en cambio la SVD reparte el error como una textura fina por toda la imagen. Las normas matriciales no son el ojo humano.

¿Se entiende por qué anda tan bien?

Por Eckart–Young, la pregunta "¿por qué A_d se parece tanto a A?" es exactamente la pregunta "¿por qué los σ_i con $i > d$ son tan chicos?": el error es σ_{d+1} en la norma espectral y $\left(\sum_{i>d} \sigma_i^2\right)^{1/2}$ en la de Frobenius. No importa el rango (el tigre tiene rango 598, casi completo) sino *la velocidad con que decaen los valores singulares*.

La Figura 9.3 compara el tigre con una matriz "sin estructura": una matriz R de 620×600 de **ruido uniforme**, cuyas entradas se eligen al azar, independientes y uniformes en $[0, 1]$. Es una "imagen" de grises sin ninguna relación entre píxeles vecinos. Sus valores singulares se entienden separando el promedio:

$$R = \tfrac{1}{2}\,\mathbf{1}\mathbf{1}^T + \left(R - \tfrac{1}{2}\,\mathbf{1}\mathbf{1}^T\right).$$

El primer sumando tiene rango uno y su único valor singular es $\frac{1}{2}\|\mathbf{1}_m\|\,\|\mathbf{1}_n\| = \frac{1}{2}\sqrt{mn} \approx 305$: prácticamente el $\sigma_1 \approx 305{,}1$ de la figura. Solo él ya se lleva el 75% de $\|R\|_F^2$, porque el cuadrado de la media de cada entrada es $\frac{1}{4}$ y la media de su cuadrado es $\frac{1}{3}$. El segundo sumando tiene entradas independientes con media 0 y desvío $1/\sqrt{12} \approx 0{,}29$, y la teoría de matrices aleatorias (la ley de Marchenko–Pastur, y el teorema de Bai–Yin para los extremos) dice que sus valores singulares llenan el intervalo entre $(\sqrt{m} - \sqrt{n})/\sqrt{12} \approx 0{,}1$ y

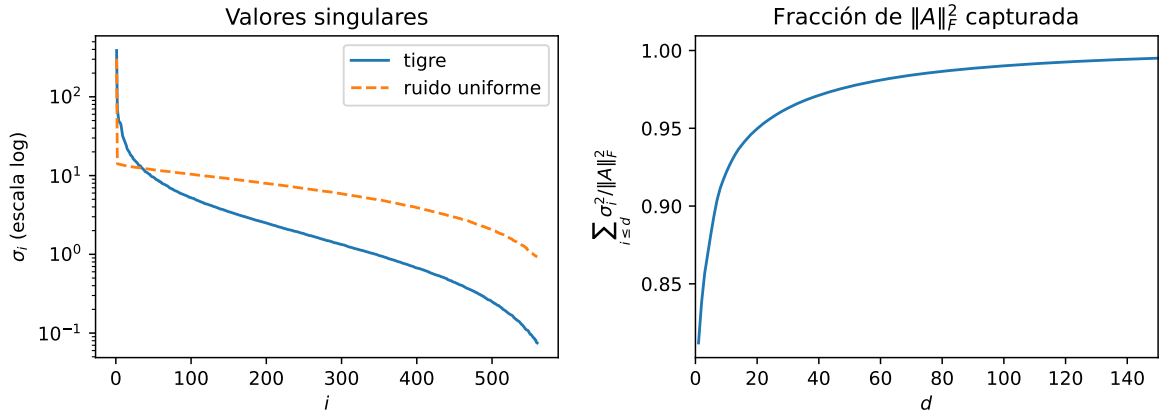


Figura 9.3. Izquierda: valores singulares del tigre y de una matriz de ruido uniforme en $[0,1]$ del mismo tamaño (escala logarítmica). Derecha: fracción $\sum_{i\le d}\sigma_i^2/\sum_i\sigma_i^2$ capturada por los primeros d términos, para las dos matrices.

$(\sqrt{m}+\sqrt{n})/\sqrt{12}\approx 14$. En la figura, $\sigma_2\approx 14{,}2$, los σ_i bajan lentamente hasta $\sigma_{560}\approx 0{,}9$, y el último es $\sigma_{600}\approx 0{,}09$. Sacado el promedio, la energía queda repartida en cientos de direcciones y no hay nada que comprimir. La tabla compara las dos matrices (el error relativo es $\|A-A_d\|_F\,/\,\|A\|_F$, y lo mismo para R):

	fracción de $\|\cdot\|_F^2$ con $d=1$	error relativo, $d=50$	error relativo, $d=100$
ruido	75%	0,43	0,37
tigre	81%	0,15	0,10

Con $d=1$ las dos se parecen, porque las dos tienen un promedio grande; después el ruido casi no mejora. En el tigre, en cambio, los σ_i caen de a órdenes de magnitud. Las razones son geométricas:

- **Filas vecinas se parecen.** Dos filas consecutivas de una foto son casi iguales, así que las 620 filas, vistas como puntos de $\mathbb{R}^{600}$, están muy cerca de un subespacio de dimensión baja. Esa es justamente la pregunta de PCA, que viene en la sección siguiente: vamos a ver que $\|A-A_d\|_F^2$ es la suma de las distancias al cuadrado de las filas al mejor subespacio de dimensión d (Proposición 9.18).
- **Zonas de color constante tienen rango uno.** Un rectángulo de gris uniforme es $c\,\mathbf{1}\mathbf{1}^T$. El fondo y las manchas grandes cuestan muy poco; lo caro son los bordes.
- **Las diagonales son caras.** Un borde diagonal no se alinea con filas y columnas: la matriz identidad, que es una "diagonal", tiene todos sus valores singulares iguales a 1 y no se puede comprimir nada (ver también el Ejercicio 9.14). Por eso los primeros A_d tienen franjas horizontales y verticales y las diagonales aparecen tarde.

Lo que permite comprimir la foto no es el rango sino que sus valores singulares decaen rápido, y el ruido es justamente el caso en que no decaen.

Observación 9.15 (¿Por qué JPEG no usa la SVD?). La SVD elige la base óptima *para cada imagen*, pero hay que guardar esa base: $\boldsymbol{u}_i$ y $\boldsymbol{v}_i$ son los $d(m+n)$ números del conteo. Los formatos como JPEG usan una base *fija* (cosenos, en bloques de 8×8) que no hay que transmitir, y guardan solo los coeficientes grandes. La idea es la misma, con otra base: pocas piezas simples y coeficientes que decaen rápido.

El Trabajo práctico del final del capítulo propone repetir todo esto con una foto propia.

9.6 PCA: la mejor proyección de los datos

Sea $X \in \mathbb{R}^{n\times p}$ una **matriz de datos**: n observaciones (las filas $\boldsymbol{x}_1^T, \dots, \boldsymbol{x}_n^T$, con $\boldsymbol{x}_i \in \mathbb{R}^p$) de p variables (las columnas). También puede ser una imagen: en el tigre, cada una de las 620 filas es un punto de $\mathbb{R}^{600}$. Queremos reemplazar cada fila $\boldsymbol{x}_i$ por un punto de un subespacio de dimensión $d \le p$, perdiendo lo menos posible.

Observación 9.16 (SVD truncada versus PCA)**.** Con la foto del tigre aplicamos Eckart–Young directamente a la matriz de intensidades: queríamos comprimir *esa* matriz. Cuando la matriz es una tabla de datos, lo que interesa es la *forma* de la nube de puntos, no su posición: primero *centramos* las variables (Observación 9.23 y Sección 9.7) y después truncamos. Vamos a ver que PCA es Eckart–Young aplicado a la matriz de datos centrada.

Fijemos el subespacio por medio de una base ortonormal: $W \in \mathbb{R}^{p\times d}$ con $W^TW = I_d$ (una matriz *semiortogonal*, en la terminología del capítulo de Ortogonalidad). Sabemos que $P_W = WW^T$ es la proyección ortogonal de $\mathbb{R}^p$ sobre $\operatorname{span}(W)$, el espacio generado por las columnas de W: P_W es simétrica, $P_W^2 = P_W$ y $P_W\boldsymbol{x}$ es el punto de $\operatorname{span}(W)$ más cercano a $\boldsymbol{x}$. Reemplazar cada fila $\boldsymbol{x}_i$ por su proyección $P_W\boldsymbol{x}_i$ es, en forma matricial, reemplazar X por

$$XWW^T, \qquad \text{cuya fila } i \text{ es } (WW^T\boldsymbol{x}_i)^T = (P_W\boldsymbol{x}_i)^T.$$

Medimos la pérdida con la norma de Frobenius: sumamos los errores al cuadrado de todas las entradas.

Definición 9.17 (El problema de PCA)**.** Dados $X \in \mathbb{R}^{n\times p}$ y $d \le p$, buscamos

$$\min_{W\in\mathbb{R}^{p\times d},\ W^TW=I_d} \left\|X - XWW^T\right\|_F^2. \tag{9.6}$$

Las columnas de una solución W^* se llaman **direcciones principales**; las columnas de $XW^* \in \mathbb{R}^{n\times d}$ (las coordenadas de los datos proyectados) son las **componentes principales**.

Proposición 9.18 (Qué mide el problema (9.6))**.** Si $W^TW = I_d$, entonces

$$\left\|X - XWW^T\right\|_F^2 = \sum_{i=1}^{n} \|\boldsymbol{x}_i - P_W\boldsymbol{x}_i\|^2 = \sum_{i=1}^{n} \operatorname{dist}\big(\boldsymbol{x}_i, \operatorname{span}(W)\big)^2.$$

Es decir, (9.6) pide el subespacio de dimensión d *que pasa por el origen* y minimiza la suma de los cuadrados de las distancias (ortogonales) de los datos al subespacio.

Demostración. La fila i de $X - XWW^T$ es $\boldsymbol{x}_i^T - \boldsymbol{x}_i^TWW^T = (\boldsymbol{x}_i - P_W\boldsymbol{x}_i)^T$ porque P_W es simétrica. La norma de Frobenius al cuadrado es la suma de las normas al cuadrado de las filas (Proposición 9.2(a)). Por último $\|\boldsymbol{x} - P_W\boldsymbol{x}\| = \operatorname{dist}(\boldsymbol{x}, \operatorname{span}(W))$ es la propiedad básica de la proyección ortogonal. ∎

Observación 9.19 (Interpretación geométrica: ajuste ortogonal, no regresión)**.** La recta de regresión de y sobre $\boldsymbol{x}$ (la veremos cuando estudiemos mínimos cuadrados) minimiza distancias *verticales*: el error se mide solo en la variable respuesta. En (9.6) no hay variable respuesta: todas las coordenadas juegan el mismo papel y el error es la distancia *perpendicular* al subespacio. Por eso PCA es una técnica *no supervisada*: no usa etiquetas ni distingue entradas de salidas.

El problema (9.6) compara a X con matrices de una forma muy particular, XWW^T. Todas ellas tienen rango $\leq d$, así que son candidatas en el problema de Eckart–Young (9.1): el problema de PCA es el mismo problema con *menos* competidores. Y el ganador del problema grande, $X_d = XV_dV_d^T$, ¡es uno de ellos!

Teorema 9.20 (Solución de PCA)**.** Sea $X = U\Sigma V^T$ una SVD completa de $X \in \mathbb{R}^{n\times p}$ (como en el Lema 9.7: V es de $p \times p$), con valores singulares $\sigma_1 \geq \cdots \geq \sigma_r > 0$ (y $\sigma_i = 0$ para $i > r$). Para toda $W \in \mathbb{R}^{p\times d}$ con $W^TW = I_d$,

$$\left\|X - XWW^T\right\|_F^2 \;\geq\; \sigma_{d+1}^2 + \sigma_{d+2}^2 + \cdots + \sigma_r^2,$$

y la igualdad se alcanza en $W^* = V_d$, las primeras d columnas de V. Es decir, las direcciones principales son los primeros d vectores singulares derechos de X, y

$$\min_{W^TW=I_d} \left\|X - XWW^T\right\|_F^2 = \min_{\text{rango}(M)\leq d} \|X - M\|_F^2 = \|X - X_d\|_F^2 .$$

Demostración. Si $d \geq r$ no hay nada que probar: $XV_dV_d^T = X$ porque V_d contiene a $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r$, y el error es cero. Sea $d < r$. Como $\text{rango}(XWW^T) \leq \text{rango}(W) = d$,

$$\{\, XWW^T :\; W^TW = I_d \,\} \;\subseteq\; \{\, M \in \mathbb{R}^{n\times p} :\; \text{rango}(M) \leq d \,\},$$

y por el Teorema de Eckart–Young,

$$\left\|X - XWW^T\right\|_F^2 \;\geq\; \min_{\text{rango}(M)\leq d} \|X - M\|_F^2 = \sum_{i=d+1}^{r} \sigma_i^2.$$

Por otro lado, $W = V_d$ es semiortogonal y $XV_dV_d^T = X_d$ (Corolario 9.4(a)), así que

$$\min_{W^TW=I_d} \left\|X - XWW^T\right\|_F^2 \;\leq\; \left\|X - XV_dV_d^T\right\|_F^2 = \|X - X_d\|_F^2 = \sum_{i=d+1}^{r} \sigma_i^2.$$

Las dos desigualdades dan la igualdad de los mínimos, alcanzada en $W = V_d$. ∎

Corolario 9.21 (Conclusión práctica)**.** La mejor proyección de los datos sobre un subespacio de dimensión d usa los primeros d vectores singulares derechos de X:

- **direcciones principales**: las columnas $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_d$ de V_d;
- **datos proyectados**: $\widehat{X} = XV_dV_d^T = X_d$, la SVD truncada ($n \times p$, mismo tamaño que X, filas en $\text{span}(V_d)$);
- **coordenadas en el subespacio** (*scores*): $Z = XV_d = U_d\Sigma_d \in \mathbb{R}^{n\times d}$; la fila i de Z son las d coordenadas de $\boldsymbol{x}_i$ en la base $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_d$, y $\widehat{X} = ZV_d^T$.

El error cometido es $\|X - X_d\|_F^2 = \sigma_{d+1}^2 + \cdots + \sigma_r^2$: la "energía" de los valores singulares descartados.

Observación 9.22 (Qué es único y qué no). Lo que el problema determina es el *subespacio* $\text{span}(\boldsymbol{v}_1, \ldots, \boldsymbol{v}_d)$, no la matriz W: si $R \in \mathbb{R}^{d\times d}$ es ortogonal, $W = V_d R$ también es semiortogonal, genera el mismo subespacio, y $WW^T = V_d R R^T V_d^T = V_d V_d^T$ da el mismo error. En particular cada $\boldsymbol{v}_i$ está definido a menos del signo (una SVD siempre lo está). Si $\sigma_d > \sigma_{d+1}$, el subespacio óptimo es único (no lo demostramos); si $\sigma_d = \sigma_{d+1}$ hay infinitos (Ejemplo 9.25). Lo que distingue a la base V_d entre todas las $W = V_d R$ es que sus columnas están *ordenadas por importancia* y producen componentes *no correlacionadas* (Teorema 9.30).

Observación 9.23 (El origen importa). El subespacio $\text{span}(W)$ pasa por el origen. Si la nube de puntos está lejos del origen, la mejor dirección será la que apunta hacia la nube (hacia su media) y no la que describe su forma (Ejemplo 9.25). Por eso en la Sección 9.7 restaremos primero la media de cada variable. Hasta entonces trabajamos con X genérica: todo lo anterior vale para cualquier matriz.

9.7 PCA como maximización de la varianza

Hasta acá resolvimos un problema de aproximación de matrices. Ahora leemos la solución con los ojos de la estadística —así se presenta PCA en un curso de estadística—: aparecen la matriz de covarianza, la varianza de cada componente y la proporción de varianza explicada. Todo lo que sigue es *muestral*: no usamos vectores aleatorios ni objetos poblacionales, solo la tabla de datos.

9.7.1 Centrado

Definición 9.24 (Media y matriz centrada). Sea $X \in \mathbb{R}^{n\times p}$ una matriz de datos. El vector de medias de las columnas es $\bar{\boldsymbol{x}} = \frac{1}{n} X^T \mathbf{1} \in \mathbb{R}^p$, con $\mathbf{1} = (1, \ldots, 1)^T \in \mathbb{R}^n$, y la **matriz centrada** es

$$X_c = X - \mathbf{1}\bar{\boldsymbol{x}}^T = \left(I - \tfrac{1}{n}\mathbf{1}\mathbf{1}^T\right) X.$$

Cada columna de X_c tiene media cero: $\mathbf{1}^T X_c = 0$.

La matriz $H = I - \frac{1}{n}\mathbf{1}\mathbf{1}^T$ es la proyección ortogonal sobre $\mathbf{1}^\perp$ (es simétrica e idempotente, y $H\mathbf{1} = 0$): centrar es proyectar cada columna sobre el complemento ortogonal del vector de unos.

Ejemplo 9.25 (Por qué hay que centrar). Consideremos cuatro observaciones en $\mathbb{R}^2$ ubicadas en los vértices de un rombo alrededor de $(5, 5)$:

$$X = \begin{pmatrix} 6 & 5 \\ 5 & 6 \\ 4 & 5 \\ 5 & 4 \end{pmatrix}, \qquad X^T X = \begin{pmatrix} 102 & 100 \\ 100 & 102 \end{pmatrix}, \qquad \sigma_1^2 = 202, \quad \sigma_2^2 = 2, \quad \boldsymbol{v}_1 = \tfrac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Sin centrar, la "dirección principal" es la bisectriz, con $\sigma_1^2/(\sigma_1^2+\sigma_2^2) = 99\%$ de la energía: es la dirección que apunta del origen a la media $(5,5)$, y no dice nada sobre la forma de la nube. Centrando, $\bar{\boldsymbol{x}} = (5,5)^T$ y

$$X_c = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & 0 \\ 0 & -1 \end{pmatrix}, \qquad X_c^T X_c = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, \qquad \sigma_1^2 = \sigma_2^2 = 2.$$

La nube centrada es un rombo simétrico: no tiene ninguna dirección privilegiada, y en efecto *cualquier* vector unitario es una dirección principal (es el caso $\sigma_1 = \sigma_2$ de la Observación 9.22).

Convención. De ahora en más, en esta sección, X *denota la matriz de datos ya centrada por columnas.*

9.7.2 Covarianza muestral

Definición 9.26 (Covarianza muestral)**.** La **matriz de covarianza muestral** de la matriz centrada $X \in \mathbb{R}^{n\times p}$ es

$$S = \frac{1}{n-1} X^T X \ \in \mathbb{R}^{p\times p}.$$

Su entrada (j,k) es $s_{jk} = \frac{1}{n-1}\sum_{i=1}^n x_{ij}x_{ik}$, la covarianza muestral entre las variables j y k; en la diagonal, $s_{jj} = \frac{1}{n-1}\sum_i x_{ij}^2$ es la varianza muestral de la variable j. Las correlaciones son $r_{jk} = s_{jk}/\sqrt{s_{jj}s_{kk}}$.

Observación 9.27 (La letra S)**.** En los Capítulos 6 y 7 usamos S para una matriz simétrica definida positiva, la que define un producto interno $\langle \boldsymbol{x}, y\rangle_S = \boldsymbol{x}^T S y$. Acá S es la covarianza muestral. No es una coincidencia desafortunada: la Proposición 9.28 dice que la covarianza muestral *es* simétrica semidefinida positiva, y es definida positiva en cuanto los datos no estén contenidos en un hiperplano por el origen. O sea que la covarianza muestral es exactamente una de aquellas S, y toda la geometría que construimos con ellas —la S-ortogonalidad, las S-proyecciones, las elipses— se aplica sin cambiar una coma a la nube de datos. Volvemos sobre esto en la Sección 9.7.7.

Proposición 9.28 (Propiedades de S)**.** Sea $X = U\Sigma V^T$ una SVD completa de la matriz centrada (V de $p\times p$), con $\sigma_1 \geq \cdots \geq \sigma_r > 0$.

(a) S es simétrica y semidefinida positiva: $\boldsymbol{w}^T S \boldsymbol{w} = \frac{1}{n-1}\|X\boldsymbol{w}\|^2 \geq 0$.

(b) $S = V\Lambda V^T$ con $\Lambda = \frac{1}{n-1}\Sigma^T\Sigma$: los autovectores de S son los vectores singulares derechos de X, y sus autovalores son

$$\lambda_k = \frac{\sigma_k^2}{n-1} \quad (k \leq r), \qquad \lambda_k = 0 \quad (k > r).$$

(c) La **varianza total** es $\operatorname{tr}(S) = \sum_{j=1}^p s_{jj} = \sum_{k=1}^p \lambda_k = \frac{1}{n-1}\|X\|_F^2$.

Demostración. (a) $S^T = S$ es inmediato y $\boldsymbol{w}^T X^T X \boldsymbol{w} = \|X\boldsymbol{w}\|^2$. (b) Como $U^T U = I$,

$$X^T X = V\Sigma^T U^T U \Sigma V^T = V(\Sigma^T\Sigma)V^T, \qquad \Sigma^T\Sigma = \operatorname{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0).$$

(c) La traza es la suma de la diagonal y también la suma de los autovalores; la última igualdad es la Proposición 9.2(a). ∎

9.7.3 Error de reconstrucción y varianza explicada

Dada $W \in \mathbb{R}^{p\times d}$ semiortogonal, las columnas de

$$Z = XW \in \mathbb{R}^{n\times d}$$

son d *variables nuevas*: cada una es una combinación lineal de las p variables originales, con coeficientes en la columna correspondiente de W. La fila i de Z es $\boldsymbol{x}_i^T W = (W^T \boldsymbol{x}_i)^T$: las coordenadas de la observación i en la base de $\operatorname{span}(W)$. Como X está centrada, Z también ($\mathbf{1}^T Z = \mathbf{1}^T XW = 0$), y su matriz de covarianza es

$$\operatorname{cov}(Z) = \frac{1}{n-1} Z^T Z = W^T S W.$$

Su traza, $\operatorname{tr}(W^T S W)$, es la varianza total de las variables nuevas: la **varianza explicada** por las d direcciones de W. El teorema siguiente dice que error de reconstrucción y varianza explicada son las dos caras de la misma moneda.

Teorema 9.29 (Error de reconstrucción = varianza total − varianza explicada)**.** Sean $X \in \mathbb{R}^{n\times p}$ y $W \in \mathbb{R}^{p\times d}$ con $W^T W = I_d$. Entonces

$$\left\| X - XWW^T \right\|_F^2 = \operatorname{tr}(X^T X) - \operatorname{tr}(W^T X^T X W). \tag{9.7}$$

Si X está centrada, dividiendo por $n-1$,

$$\underbrace{\operatorname{tr}(W^T S W)}_{\text{varianza explicada}} + \underbrace{\frac{1}{n-1}\left\| X - XWW^T \right\|_F^2}_{\text{error de reconstrucción}} = \underbrace{\operatorname{tr}(S)}_{\text{varianza total}}. \tag{9.8}$$

En consecuencia, *minimizar el error de reconstrucción es lo mismo que maximizar la varianza explicada*, y por el Teorema 9.20 la solución de los dos problemas es $W^* = V_d$.

Demostración. Sea $P = WW^T$, que es simétrica e idempotente; entonces $I - P$ también. Por la Proposición 9.2(a) y la propiedad cíclica de la traza,

$$\begin{aligned}\|X(I-P)\|_F^2 &= \operatorname{tr}\Big((I-P)X^T X(I-P)\Big) = \operatorname{tr}\Big(X^T X(I-P)^2\Big) \\ &= \operatorname{tr}(X^T X) - \operatorname{tr}(X^T XWW^T) = \operatorname{tr}(X^T X) - \operatorname{tr}(W^T X^T X W).\end{aligned}$$

La segunda fórmula es la primera dividida por $n-1$, con $\operatorname{tr}(S) = \operatorname{tr}(X^T X)/(n-1)$. El primer término no depende de W, de donde sigue la equivalencia entre minimizar y maximizar. ∎

9.7.4 Máxima varianza y componentes no correlacionadas

Teorema 9.30 (PCA = máxima varianza explicada)**.** Sea X centrada con SVD completa $X = U\Sigma V^T$. Para toda $W \in \mathbb{R}^{p\times d}$ semiortogonal,

$$\operatorname{tr}(W^T S W) \;\le\; \lambda_1 + \cdots + \lambda_d, \qquad \lambda_k = \frac{\sigma_k^2}{n-1},$$

con igualdad en $W^* = V_d$. Las componentes principales $Z^* = XV_d = U_d\Sigma_d$ satisfacen

$$\operatorname{cov}(Z^*) = V_d^T S V_d = \operatorname{diag}(\lambda_1, \ldots, \lambda_d) :$$

la k-ésima componente principal $z_k = X\boldsymbol{v}_k = \sigma_k u_k$ tiene varianza $\lambda_k = \sigma_k^2/(n-1)$, y componentes distintas están **no correlacionadas**.

Demostración. Por el Teorema 9.29, $\operatorname{tr}(W^T S W) = \operatorname{tr}(S) - \frac{1}{n-1}\left\|X - XWW^T\right\|_F^2$, y por el Teorema 9.20 el error es mínimo en $W = V_d$, donde vale $\sigma_{d+1}^2 + \cdots + \sigma_r^2$. Como $\operatorname{tr}(S) = \frac{1}{n-1}(\sigma_1^2 + \cdots + \sigma_r^2)$ (Proposición 9.28(c)), el máximo de $\operatorname{tr}(W^T S W)$ es $\frac{1}{n-1}(\sigma_1^2 + \cdots + \sigma_d^2) = \lambda_1 + \cdots + \lambda_d$. La matriz $V_d^T S V_d = \operatorname{diag}(\lambda_1, \ldots, \lambda_d)$ es la Proposición 9.28(b) restringida a las primeras d columnas. ∎

Con $d = 1$, el teorema es el cociente de Rayleigh del capítulo de la SVD (Teorema 6.13) para la matriz S: $\max_{\|\boldsymbol{w}\|=1} \boldsymbol{w}^T S \boldsymbol{w} = \lambda_1$, alcanzado en $\boldsymbol{w} = \boldsymbol{v}_1$, la dirección de máxima varianza. Las direcciones siguientes se pueden elegir de a una.

Corolario 9.31 (Construcción secuencial: las soluciones están anidadas)**.** Para cada k,

$$\max\{\, \boldsymbol{w}^T S \boldsymbol{w} :\ \|\boldsymbol{w}\| = 1,\ \boldsymbol{w} \perp \boldsymbol{v}_1, \ldots, \boldsymbol{v}_{k-1} \,\} = \lambda_k, \qquad \text{alcanzado en } \boldsymbol{w} = \boldsymbol{v}_k.$$

Por lo tanto, la solución del problema con d direcciones, V_d, se obtiene agregando una columna a la solución del problema con $d-1$ direcciones: *elegir las d mejores direcciones a la vez es lo mismo que elegirlas de a una.* Esto no es cierto para problemas de optimización arbitrarios, y es lo que hace tan cómodo al PCA: para pasar de d a $d+1$ no hay que recalcular nada.

Demostración. Si $\|\boldsymbol{w}\| = 1$ y $\boldsymbol{w} \perp \boldsymbol{v}_1, \ldots, \boldsymbol{v}_{k-1}$, la matriz $W = [\,\boldsymbol{v}_1 \;\cdots\; \boldsymbol{v}_{k-1}\; \boldsymbol{w}\,]$ es semiortogonal y, por el Teorema 9.30 con $d = k$,

$$\lambda_1 + \cdots + \lambda_{k-1} + \boldsymbol{w}^T S \boldsymbol{w} = \operatorname{tr}(W^T S W) \le \lambda_1 + \cdots + \lambda_k,$$

es decir, $\boldsymbol{w}^T S \boldsymbol{w} \le \lambda_k$. Con $\boldsymbol{w} = \boldsymbol{v}_k$ vale la igualdad. ∎

Observación 9.32 (Ortogonal en $\mathbb{R}^p \iff$ no correlacionado en $\mathbb{R}^n$)**.** Para direcciones $\boldsymbol{w}, \boldsymbol{w}' \in \mathbb{R}^p$, la covarianza entre las variables $X\boldsymbol{w}$ y $X\boldsymbol{w}'$ es $\boldsymbol{w}^T S \boldsymbol{w}'$. Si $\boldsymbol{w} = \boldsymbol{v}_k$ es una dirección principal, $\boldsymbol{w}'^T S \boldsymbol{v}_k = \lambda_k\, \boldsymbol{w}'^T \boldsymbol{v}_k$: la variable $X\boldsymbol{w}'$ no está correlacionada con la componente z_k si y solo si $\boldsymbol{w}' \perp \boldsymbol{v}_k$ (cuando $\lambda_k \neq 0$). Por eso el Corolario 9.31 se lee así en el lenguaje de los datos: *$\boldsymbol{v}_1$ es la dirección de máxima varianza; $\boldsymbol{v}_2$ es la dirección de máxima varianza entre las no correlacionadas con z_1; $\boldsymbol{v}_3$ la de máxima varianza entre las no correlacionadas con z_1 y z_2*, y así sucesivamente. Las varianzas obtenidas son $\lambda_1 \ge \lambda_2 \ge \cdots$.

9.7.5 Proporción de varianza explicada y elección de d

Definición 9.33 (Proporción de varianza explicada). La **proporción de varianza explicada** por las primeras d componentes es

$$\mathrm{PVE}(d) = \frac{\lambda_1 + \cdots + \lambda_d}{\lambda_1 + \cdots + \lambda_p} = \frac{\sigma_1^2 + \cdots + \sigma_d^2}{\sigma_1^2 + \cdots + \sigma_r^2} = \frac{\|X_d\|_F^2}{\|X\|_F^2} = 1 - \frac{\|X - X_d\|_F^2}{\|X\|_F^2}.$$

En la práctica se grafica $\mathrm{PVE}(d)$ (o los λ_k en orden decreciente, el *scree plot*) y se elige d donde la curva hace un "codo", o el menor d que supera un umbral fijado de antemano (típicamente entre 80% y 95%). No hay una regla universal: d es un compromiso entre fidelidad y simplicidad.

Observación 9.34 (Escalas distintas: PCA sobre la matriz de correlación). El problema (9.6) suma errores al cuadrado en todas las variables por igual. Si una variable está en gramos y otra en kilómetros, la de mayor varianza numérica domina la primera componente aunque no sea la más informativa. Cuando las unidades no son comparables se **estandariza**: se reemplaza X por $XD^{-1/2}$ con $D = \mathrm{diag}(s_{11}, \ldots, s_{pp})$, de modo que cada variable pase a tener varianza 1. La covarianza de la matriz estandarizada es la matriz de correlación $R = D^{-1/2} S D^{-1/2}$, y su varianza total es $\mathrm{tr}(R) = p$. Las componentes de X y de $XD^{-1/2}$ son en general *distintas*: PCA no es invariante por cambios de escala de las variables (sí lo es por rotaciones: Ejercicio 9.19).

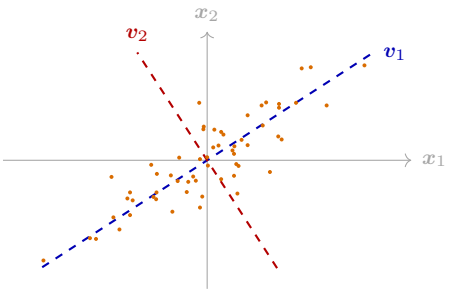
Observación 9.35 (Cómo leer las direcciones principales). Si llamamos $\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(p)} \in \mathbb{R}^n$ a las columnas de X (las variables), la componente $z_k = X\boldsymbol{v}_k$ es la variable nueva $z_k = v_{1k}\boldsymbol{x}^{(1)} + \cdots + v_{pk}\boldsymbol{x}^{(p)}$: una combinación lineal de las variables originales. Las entradas de $\boldsymbol{v}_k$ (*pesos* o *loadings*) dicen qué variables intervienen en la componente y con qué signo; entradas grandes del mismo signo indican variables que "se mueven juntas". Como $\|\boldsymbol{v}_k\| = 1$, los pesos son comparables entre sí, una vez más, solo si las variables están en escalas comparables.

Observación 9.36 (La última componente). La dirección de *menor* varianza es $\boldsymbol{v}_p$, con varianza λ_p. En efecto, si $\|\boldsymbol{w}\| = 1$, la suma de los cuadrados de las distancias de los datos al hiperplano $\boldsymbol{w}^\perp$ es $\|X\boldsymbol{w}\|^2 = (n-1)\,\boldsymbol{w}^T S \boldsymbol{w}$, y por el Teorema 9.20 con $d = p - 1$ el hiperplano más cercano a los datos es $\mathrm{span}(\boldsymbol{v}_1, \ldots, \boldsymbol{v}_{p-1}) = \boldsymbol{v}_p^\perp$. Si $\lambda_p \approx 0$, los datos están (casi) contenidos en ese hiperplano: hay una relación lineal aproximada $v_{1p}\boldsymbol{x}^{(1)} + \cdots + v_{pp}\boldsymbol{x}^{(p)} \approx 0$ entre las variables. Es la *regresión ortogonal* (o de mínimos cuadrados totales).

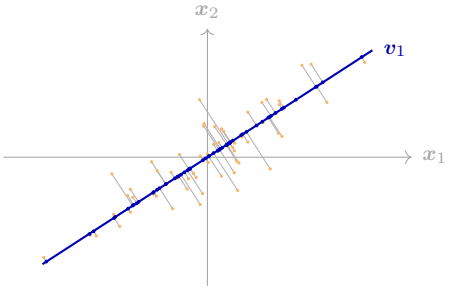
9.7.6 Geometría en el plano

Las figuras siguientes muestran $n = 60$ observaciones de $p = 2$ variables (ya centradas). Sus valores singulares son $\sigma_1 = 15{,}03$ y $\sigma_2 = 3{,}88$, de modo que $\lambda_1 = 3{,}83$, $\lambda_2 = 0{,}26$ y $\mathrm{PVE}(1) = 93{,}7\%$. La Figura 9.4(a) muestra la nube y las dos direcciones principales; (b) la proyección de cada punto sobre la recta $\mathrm{span}(\boldsymbol{v}_1)$, que es la reconstrucción de rango uno $\widehat{X} = XV_1V_1^T$, junto con los segmentos de error $\boldsymbol{x}_i - \widehat{\boldsymbol{x}}_i$, todos perpendiculares a la recta; (c) lo mismo sobre la recta $\mathrm{span}(\boldsymbol{v}_2)$: la suma de los cuadrados de los segmentos pasa de $\sigma_2^2 = 15{,}1$ a $\sigma_1^2 = 225{,}9$; y (d) las componentes principales $Z = XV$, es decir la misma nube en las coordenadas (z_1, z_2): los ejes quedan alineados con la forma de la nube y las

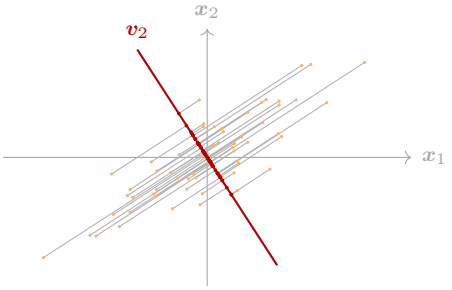
dos variables nuevas no están correlacionadas.



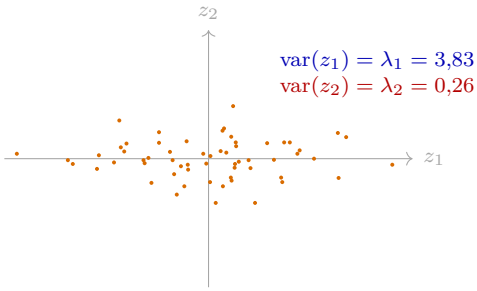
(a) nube centrada y direcciones principales



(b) proyección sobre span($\boldsymbol{v}_1$): error $= \sigma_2^2 = 15{,}1$



(c) proyección sobre span($\boldsymbol{v}_2$): error $= \sigma_1^2 = 225{,}9$



(d) componentes principales $Z = XV$

Figura 9.4. PCA de una nube de 60 puntos en el plano. (a) Datos centrados con $\boldsymbol{v}_1$ (azul) y $\boldsymbol{v}_2$ (rojo). (b) Reconstrucción de rango uno $\widehat{X} = XV_1V_1^T$: cada punto va a su proyección ortogonal sobre la recta span($\boldsymbol{v}_1$); los segmentos grises son los errores. (c) La misma construcción con $\boldsymbol{v}_2$: el error es quince veces mayor. (d) Las componentes principales: la nube expresada en la base $\boldsymbol{v}_1, \boldsymbol{v}_2$; las variables nuevas tienen covarianza cero.

9.7.7 La elipse de la nube

Vale la pena detenerse en el dibujo, porque es el mismo que ya hicimos dos veces. En la Sección 6.5 vimos que una matriz simétrica definida positiva S queda retratada por la elipse (o el elipsoide)

$$\mathcal{E} = \{\, \boldsymbol{x} \in \mathbb{R}^p : \ \boldsymbol{x}^T S^{-1} \boldsymbol{x} = 1 \,\},$$

cuyos ejes apuntan en las direcciones de los autovectores de S y cuyos semiejes miden $\sqrt{\lambda_1}, \dots, \sqrt{\lambda_p}$. Si S es la covarianza muestral de una nube centrada, esa elipse *es* la forma de la nube: el eje mayor es la dirección en la que los datos se desparraman más.

Juntando las piezas, las direcciones principales $\boldsymbol{v}_1, \dots, \boldsymbol{v}_p$ son los ejes de esa elipse, ordenados de mayor a menor semieje, y $\lambda_k = \sigma_k^2/(n-1)$ son los semiejes al cuadrado. Elegir las d primeras componentes principales es quedarse con los d ejes más largos del elipsoide y aplastar los demás. Y la elipse explica de un vistazo las dos advertencias de más arriba: si la nube está lejos del origen la elipse no se parece en nada a su forma (por eso hay que centrar), y si se cambian las unidades de una variable el elipsoide se estira en esa dirección y los ejes giran (por eso hay que estandarizar cuando las unidades no son comparables).

La misma elipse aparece en el Capítulo 8: por el Teorema 8.21, la imagen de la esfera unitaria por una matriz es un elipsoide de semiejes $\sigma_1, \dots, \sigma_r$ en las direcciones $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$. El elipsoide de los datos y el elipsoide de la SVD son el mismo objeto mirado desde los dos lados.

9.8 PCA en la práctica

9.8.1 PCA a mano

Ejemplo 9.37 (PCA en $\mathbb{R}^2$, todo a mano). Tomemos $n = 4$, $p = 2$ y una matriz *ya centrada* (las columnas suman cero):

$$X = \begin{pmatrix} 2 & 1 \\ 1 & 2 \\ -2 & -1 \\ -1 & -2 \end{pmatrix}.$$

1) Covarianza muestral. Como $n = 4$,

$$S = \frac{1}{n-1} X^T X = \frac{1}{3} \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix} = \begin{pmatrix} \frac{10}{3} & \frac{8}{3} \\ \frac{8}{3} & \frac{10}{3} \end{pmatrix}.$$

2) Autovalores y autovectores de S. Para una matriz $\left(\begin{smallmatrix} a & b \\ b & a \end{smallmatrix}\right)$ los autovalores son $a \pm b$, con autovectores $(1,1)^T$ y $(1,-1)^T$. Aquí

$$\lambda_1 = \tfrac{10}{3} + \tfrac{8}{3} = 6, \qquad \lambda_2 = \tfrac{10}{3} - \tfrac{8}{3} = \tfrac{2}{3}, \qquad \boldsymbol{v}_1 = \tfrac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \boldsymbol{v}_2 = \tfrac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

3) Dirección principal y scores. Para $d = 1$, $W^* = \boldsymbol{v}_1$ y la componente principal es $z = X\boldsymbol{v}_1$:

$$z_i = \frac{x_{i1} + x_{i2}}{\sqrt{2}}, \qquad \text{es decir,} \qquad z = \left(\tfrac{3}{\sqrt{2}},\ \tfrac{3}{\sqrt{2}},\ -\tfrac{3}{\sqrt{2}},\ -\tfrac{3}{\sqrt{2}} \right)^T.$$

Su varianza muestral es $\frac{1}{n-1} \sum_i z_i^2 = \frac{1}{3} \cdot 4 \cdot \frac{9}{2} = 6 = \lambda_1$, como predice el Teorema 9.30. La segunda componente, $X\boldsymbol{v}_2 = \frac{1}{\sqrt{2}}(1,-1,-1,1)^T$, tiene varianza $\frac{1}{3} \cdot 4 \cdot \frac{1}{2} = \frac{2}{3} = \lambda_2$ y covarianza cero con z.

4) Reconstrucción y error (Eckart–Young). La reconstrucción de rango uno es $\widehat{X} = z v_1^T$; fila a fila,

$$\widehat{\boldsymbol{x}}_i = z_i \, \boldsymbol{v}_1^T = \pm \tfrac{3}{2} \, (1,1),$$

de modo que

$$\left\| X - \widehat{X} \right\|_F^2 = \sum_{i=1}^{4} \| \boldsymbol{x}_i - \widehat{\boldsymbol{x}}_i \|^2 = 4 \cdot \left(\tfrac{1}{4} + \tfrac{1}{4} \right) = 2.$$

Los valores singulares de X cumplen $\sigma_k^2 = (n-1)\lambda_k$: $\sigma_1^2 = 18$ y $\sigma_2^2 = 2$. Eckart–Young predice $\|X - X_1\|_F^2 = \sigma_2^2 = 2$, en perfecto acuerdo con la cuenta directa.

5) Varianza total y proporción explicada.

$$\operatorname{tr}(S) = \lambda_1 + \lambda_2 = 6 + \tfrac{2}{3} = \tfrac{20}{3}, \qquad \text{PVE}(1) = \frac{6}{20/3} = \frac{18}{20} = 0{,}90.$$

Interpretación: la dirección principal es la bisectriz $x_2 = x_1$ (las dos variables crecen juntas), y quedándonos con una sola coordenada conservamos el 90% de la variabilidad.

9.8.2 PCA en la computadora

1. Centrar las columnas de X (y estandarizar si las escalas difieren).
2. Calcular la SVD $X = U\Sigma V^T$.
3. Tomar $W = V_d$. Scores: $Z = XV_d = U_d\Sigma_d$. Reconstrucción: $\widehat{X} = ZV_d^T = X_d$.
4. Varianzas $\lambda_k = \sigma_k^2/(n-1)$ y PVE(d); elegir d mirando el scree plot o un umbral.

En Python la SVD es la función `svd` de `numpy.linalg`, y PCA ya viene empaquetado en las clases `PCA` y `TruncatedSVD` de `sklearn.decomposition` (esta última no centra: es la SVD truncada de la Sección 9.3).

Observación 9.38 (SVD de $\boldsymbol{X}$, no autovalores de $\boldsymbol{X^TX}$)**.** Matemáticamente da lo mismo diagonalizar S que calcular la SVD de X (Proposición 9.28). Numéricamente no: formar X^TX eleva al cuadrado los valores singulares y con ellos el número de condición σ_1/σ_r, así que los σ_k pequeños se pierden en el error de redondeo. Los programas serios calculan la SVD de la matriz centrada: `prcomp` de R siempre, y `PCA` de `scikit-learn` salvo cuando hay pocas variables y muchas más observaciones ($p < 1000$ y $n > 10p$), donde por velocidad diagonaliza la covarianza (su documentación advierte que así es menos estable).

Observación 9.39 (Cuando $\boldsymbol{p \gg n}$: el truco de la matriz de Gram)**.** Si hay muchas más variables que observaciones (imágenes de $p = 10^6$ píxeles, $n = 1000$ fotos), S es de $10^6 \times 10^6$ pero tiene rango $\leq n-1$. Conviene trabajar con la matriz de Gram $XX^T \in \mathbb{R}^{n\times n}$, cuyos autovectores son los $\boldsymbol{u}_k$ con autovalores σ_k^2, y recuperar $\boldsymbol{v}_k = X^T\boldsymbol{u}_k/\sigma_k$ (ecuación (8.1) del capítulo de la SVD). Es lo que hacen las *eigenfaces* del ejemplo que sigue. Cuando n y p son ambos enormes se usan métodos iterativos o aleatorizados que solo calculan los d primeros vectores singulares (`TruncatedSVD`).

9.8.3 Un ejemplo con muchas variables: las *eigenfaces*

Turk y Pentland [15] usaron PCA para reconocer caras. Cada foto de $h \times \boldsymbol{w}$ píxeles se "aplana" en un vector de $\mathbb{R}^{hw}$, y las n fotos forman las filas de $X \in \mathbb{R}^{n\times hw}$. En la base *Labeled Faces in the Wild* que usamos en el Trabajo práctico hay $n = 1288$ fotos de 50×37 píxeles, así que $p = 1850$.

- La media $\bar{\boldsymbol{x}} \in \mathbb{R}^{1850}$ es la **cara promedio**, y la matriz centrada $X_c = X - \mathbf{1}\bar{\boldsymbol{x}}^T$ tiene rango $\leq n-1$.
- Las direcciones principales $\boldsymbol{v}_k \in \mathbb{R}^{1850}$ (las filas de V^T en la SVD de X_c) son vectores del mismo tamaño que una foto, y se pueden *mirar* como imágenes: son las **eigenfaces**. Las primeras recogen la iluminación y la forma general de la cara; las siguientes, rasgos cada vez más finos.
- Cada cara se aproxima por la cara promedio más una combinación de pocas eigenfaces,

$$\boldsymbol{x}_i \;\approx\; \bar{\boldsymbol{x}} + \sum_{k=1}^{d} z_{ik}\,\boldsymbol{v}_k, \qquad z_{ik} = \boldsymbol{v}_k^T(\boldsymbol{x}_i - \bar{\boldsymbol{x}}),$$

  que es la fila i de la reconstrucción $\mathbf{1}\bar{\boldsymbol{x}}^T + (X_c)_d$. En lugar de 1850 números, cada cara queda descripta por sus d scores $(z_{i1}, \ldots, z_{id})$; con d entre 50 y 150 la cara ya se reconoce.
- Una cara *nueva* $\boldsymbol{x}$ se procesa con lo aprendido: se le resta la misma cara promedio y se proyecta sobre las mismas $\boldsymbol{v}_k$.

Ejercicios

Las etiquetas indican el sabor de cada ejercicio: [CÁLCULO] para fijar la mecánica, [CONCEPTO] para justificar y demostrar, [DATOS] para la conexión con ciencia de datos (en la computadora).

9.1 [CONCEPTO] **Proyectar fila a fila.** Sea $W \in \mathbb{R}^{p\times d}$ con $W^TW = I_d$ y sea $\Pi_W : \mathbb{R}^{n\times p} \to \mathbb{R}^{n\times p}$, $\Pi_W(A) = AWW^T$.

(a) Probar que Π_W es lineal, que $\Pi_W \circ \Pi_W = \Pi_W$, y que para todas las matrices A, B vale $\langle \Pi_W(A), B\rangle_F = \langle A, \Pi_W(B)\rangle_F$. Es decir, Π_W es una proyección ortogonal del espacio de matrices con el producto interno de Frobenius. ¿Sobre qué subespacio de $\mathbb{R}^{n\times p}$ proyecta?

(b) Si las columnas de W son linealmente independientes pero no ortonormales, ¿cuál es la proyección ortogonal de $\mathbb{R}^p$ sobre $\operatorname{span}(W)$? Probar que

$$\min_{C\in\mathbb{R}^{n\times d}} \left\|X - CW^T\right\|_F^2 \quad \text{se alcanza en} \quad C = XW(W^TW)^{-1},$$

y que el mínimo no cambia si se reemplaza W por una base ortonormal del mismo subespacio.

9.2 [CONCEPTO] **Frobenius y la norma espectral.** Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$.

(a) Probar que $\|AB\|_F \le \|A\|_2 \, \|B\|_F$ y que $\|AB\|_F \le \|A\|_F \, \|B\|_F$. *Ayuda:* mirar AB columna por columna.

(b) Probar que $\|A\|_2 \le \|A\|_F \le \sqrt{r}\, \|A\|_2$ con $r = \operatorname{rango}(A)$, y decir para qué matrices vale cada igualdad.

(c) Probar que $\|A\|_F^2 = \sum_i \|A\boldsymbol{e}_i\|^2 = \sum_i \|A\boldsymbol{q}_i\|^2$ para cualquier base ortonormal $\boldsymbol{q}_1, \ldots, q_n$ de $\mathbb{R}^n$. (Esto explica por qué Frobenius es invariante ortogonal.)

9.3 [CONCEPTO] **Normas ortogonalmente invariantes.**

(a) Probar que si Q y Q' son ortogonales, QAQ' tiene los mismos valores singulares que A. *Ayuda:* si $A = U\Sigma V^T$, ¿cuál es una SVD de QAQ'?

(b) Deducir que son ortogonalmente invariantes la norma de Frobenius, la espectral $\|A\|_2 = \max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \sigma_1(A)$, la nuclear $\|A\|_* = \sum_i \sigma_i(A)$ y (opcional) las normas de Ky Fan $\|A\|_{(k)} = \sum_{i=1}^k \sigma_i(A)$. Para la espectral, dar además una prueba directa a partir de la definición como máximo.

(c) ¿Cuál de las normas de (b) proviene de un producto interno?

(d) Calcular las normas de Frobenius, espectral y nuclear de I_n y de la matriz $\mathbf{1}\mathbf{1}^T \in \mathbb{R}^{n\times n}$ de todos unos.

9.4 [CONCEPTO] **Consecuencias de la desigualdad de Weyl.** Sean $A, B, E \in \mathbb{R}^{n\times p}$.

(a) Probar que $|\sigma_i(A+E) - \sigma_i(A)| \le \|E\|_2$ para todo i. *Ayuda:* Weyl con $j = 1$, aplicada a $A+E$ y a $A = (A+E) + (-E)$. Interpretar: si a una matriz de datos se le suma un ruido de norma espectral chica, sus valores singulares casi no cambian.

(b) Probar que si $\operatorname{rango}(B) \le k$, entonces $\sigma_{i+k}(A) \le \sigma_i(A+B)$ y $\sigma_{i+k}(A+B) \le \sigma_i(A)$: sumar una matriz de rango k corre los valores singulares a lo sumo k lugares.

(c) Deducir que si A' se obtiene de A cambiando una sola fila, entonces $\sigma_{i+1}(A) \le \sigma_i(A') \le \sigma_{i-1}(A)$ para todo i, con la convención $\sigma_0(A) = +\infty$ (los valores singulares *se entrelazan*). Un único dato atípico, ¿puede agrandar mucho a σ_1? ¿Y a σ_1 y σ_2 a la vez?

9.5 [Concepto] **Quitar el sumando más grande.** Sea $A = \sum_{i=1}^{r} \sigma_i u_i v_i^T$ la SVD de A y A_k su SVD truncada.

(a) Dar una matriz de rango uno lo más próxima posible a A (en Frobenius y en la norma espectral). ¿Y de rango k? ¿Cuándo es la única posible?

(b) ¿Cuáles son los valores singulares (en orden decreciente) de $A - A_k$? Omitir los ceros. ¿Cuál es su rango?

(c) Calcular $\|A - A_k\|_F$, $\|A - A_k\|_2$ y $\|A - A_k\|_*$ en términos de los σ_i.

9.6 [Cálculo] Encontrar la SVD truncada de rango uno A_1 de cada una de las matrices

$$A = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \qquad A = \begin{pmatrix} 0 & 3 \\ 2 & 0 \end{pmatrix}, \qquad A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix},$$

y calcular en cada caso el error $\|A - A_1\|_F$ y $\|A - A_1\|_2$. ¿En cuáles de los tres casos es A_1 la *única* aproximación de rango uno óptima en Frobenius? (En la norma espectral no lo es nunca: Ejercicio 9.11.)

9.7 [Cálculo] Encontrar una aproximación de rango uno más cercana, en la norma espectral, a la rotación $A = \left(\begin{smallmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{smallmatrix}\right)$. Mostrar que $(A\boldsymbol{v})\boldsymbol{v}^T$ es una SVD truncada de rango uno de A para todo vector unitario $\boldsymbol{v}$, de modo que la mejor aproximación no es única (¿por qué esto no contradice al Teorema 9.6?), y calcular el error de esas aproximaciones en las normas espectral y de Frobenius. ¿Es $M = 0$ también óptima en la norma espectral? ¿Y en la de Frobenius?

9.8 [Concepto] Si S es simétrica definida positiva con $S = Q\Lambda Q^T$, $\lambda_1 \ge \cdots \ge \lambda_n > 0$, explicar con Eckart–Young por qué $\lambda_1 \boldsymbol{q}_1 q_1^T$ es una aproximación de rango uno óptima de S en la norma espectral (y, si $\lambda_1 > \lambda_2$, la única óptima en la de Frobenius). ¿Qué cambia si S es simétrica pero su autovalor de mayor módulo es negativo? *Ayuda:* ¿cuál es la SVD de una matriz simétrica?

9.9 [Concepto] ¿Qué matrices de rango 3 cumplen $\|A - A_1\|_2 = \|A - A_2\|_2$, donde $A_2 = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^T + \sigma_2 \boldsymbol{u}_2 \boldsymbol{v}_2^T$? ¿Puede cumplirse $\|A - A_1\|_F = \|A - A_2\|_F$?

9.10 [Cálculo] Si A es de 2×2 e invertible con $\sigma_1 \ge \sigma_2 > 0$, encontrar $\|A^{-1}\|_2$ y $\|A^{-1}\|_F^2$. Deducir que $\|A\|_2 \, \|A^{-1}\|_2 = \sigma_1/\sigma_2$ (el *número de condición* de A).

9.11 [Cálculo] **En la norma espectral la mejor aproximación no es única.** Sean $X = \operatorname{diag}(3, 2, 1)$ y $d = 1$.

(a) Probar que $M_m = \operatorname{diag}(m, 0, 0)$ cumple $\|X - M_m\|_2 = 2 = \sigma_2$ para todo $m \in [1, 5]$: todas son aproximaciones óptimas de rango uno en la norma espectral.

(b) Calcular $\|X - M_m\|_F^2$ en función de m y verificar que en Frobenius la única óptima de esa familia es $m = 3$.

(c) Encontrar una matriz de rango uno óptima en la norma espectral que *no* sea diagonal. *Ayuda:* probar con $M = 3\,\boldsymbol{e}_1(e_1 + \delta \boldsymbol{e}_3)^T$.

9.12 [Cálculo] **Eckart–Young es falso para normas no invariantes.** Para $A = \left(\begin{smallmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{smallmatrix}\right) \in \mathbb{R}^{2\times 2}$ sea $\|A\|_\infty = \max\big(|a_{11}| + |a_{12}|,\ |a_{21}| + |a_{22}|\big)$ (la mayor suma de módulos por fila).

(a) Probar que $\|A\|_\infty = \max_{\boldsymbol{x}\neq 0} \|A\boldsymbol{x}\|_\infty / \|\boldsymbol{x}\|_\infty$, donde $\|\boldsymbol{x}\|_\infty = \max(|x_1|, |x_2|)$, con x_1, x_2 las coordenadas de $\boldsymbol{x}$.

(b) Sea $A = \left(\begin{smallmatrix} 3 & 0 \\ 4 & 5 \end{smallmatrix}\right)$, cuya SVD calculamos en el capítulo de la SVD, y sea $A_1 = \frac{3}{2}\left(\begin{smallmatrix} 1 & 1 \\ 3 & 3 \end{smallmatrix}\right)$ su SVD truncada. Calcular $\|A - A_1\|_\infty$ y encontrar una matriz B de rango uno con $\|A - B\|_\infty < \|A - A_1\|_\infty$. *Ayuda:* probar con B de segunda fila $(4,\ 5m)$ y primera fila proporcional a ella.

(c) Mostrar que $\|\cdot\|_\infty$ no es ortogonalmente invariante: encontrar una matriz diagonal A y una rotación Q con $\|QA\|_\infty \neq \|A\|_\infty$.

9.13 [Concepto] **Otra demostración: derivar el error.** Toda matriz de rango $\leq d$ se escribe $M = CR$ con $C \in \mathbb{R}^{n\times d}$ y $R \in \mathbb{R}^{d\times p}$. Sea $E(C, R) = \|X - CR\|_F^2$.

(a) Probar que $E(C + H, R) = E(C, R) + 2\langle CR - X, HR\rangle_F + \|HR\|_F^2$ y deducir que el gradiente de E respecto de C es $2(CR - X)R^T$. Del mismo modo, el gradiente respecto de R es $2C^T(CR - X)$. (Son las derivadas $\partial E/\partial C$ y $\partial E/\partial R$ de la ecuación (19) de la Sección I.9 de Strang; hacer la cuenta entrada por entrada para $n = p = 2$ y $d = 1$.)

(b) Por la SVD de M se puede suponer que las filas de R son ortonormales ($RR^T = I_d$) y las columnas de C ortogonales ($C^TC = D$ diagonal). Probar que en un punto crítico $C = XR^T$ y $X^TXR^T = R^TD$: las columnas de R^T son autovectores de X^TX, o sea vectores singulares derechos de X.

(c) Concluir que en un punto crítico E es la suma de los σ_i^2 que *no* corresponden a las columnas elegidas, y que el mínimo se obtiene eligiendo los d mayores: $M = X_d$.

9.14 [Concepto] **El rango de una imagen simple.** Sea A la matriz de $N \times N$ que representa la imagen en blanco y negro de la región bajo la parábola $y = 1 - x^2$ en el cuadrado $[0, 1]^2$: la entrada (i, j) vale 1 si el píxel de coordenadas $\left(\frac{j}{N}, \frac{i}{N}\right)$ está bajo la parábola y 0 si no (Figura 9.5). Las filas de A son de la forma $(1, \ldots, 1, 0, \ldots, 0)$ con una cantidad decreciente de unos.

(a) Probar que una matriz cuyas filas son de esa forma tiene rango igual a la cantidad de filas no nulas *distintas*.

(b) Quitar el rectángulo de unos que toca a la parábola en el punto de pendiente -1 (Figura 9.5); quedan dos piezas. Argumentar que en una de ellas todas las filas son distintas y en la otra todas las columnas son distintas, y estimar así $\text{rango}(A) \approx CN$. ¿Cuánto vale C?

(c) Concluir que una imagen "simple" puede tener rango casi completo. ¿Por qué, entonces, la SVD truncada con $d \ll N$ suele reproducirla bien? (Pensar en Eckart–Young: lo que importa no es el rango sino el tamaño de los σ_i descartados.)

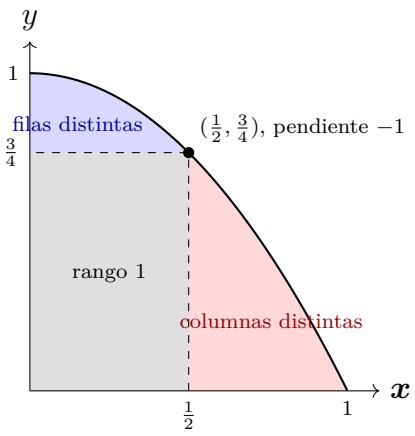


Figura 9.5. Ejercicio 9.14: la región bajo $y = 1 - x^2$, el rectángulo de rango uno y las dos piezas restantes.

9.15 [Cálculo] **Cuánto se guarda.** Una imagen de $m \times n$ píxeles se guarda con mn números; su SVD truncada A_d con $d(m + n + 1)$.

(a) Para una imagen de 1000×1000, ¿qué d ocupa el 5% del espacio original?

(b) Otra forma de "comprimir" es conservar solo una fracción $1 - c$ de las filas y de las columnas. ¿Qué c da la misma cantidad de números que A_d para el d de (a)? ¿Por qué la SVD truncada es una idea mejor? (Comparar qué garantiza Eckart–Young con lo que garantiza tirar filas.)

9.16 [Concepto] **Otra demostración: el lema de la traza máxima.** Sea $S \in \mathbb{R}^{p\times p}$ simétrica, con autovalores $\lambda_1 \geq \cdots \geq \lambda_p$ y base ortonormal de autovectores $\boldsymbol{q}_1, \ldots, q_p$, y sea $W \in \mathbb{R}^{p\times d}$ con $W^TW = I_d$. Llamamos $P = WW^T$ y $c_i = \boldsymbol{q}_i^T P \boldsymbol{q}_i$.

(a) Probar que $\|P\boldsymbol{x}\| \leq \|\boldsymbol{x}\|$ para todo $\boldsymbol{x}$, con igualdad si y solo si $\boldsymbol{x} \in \operatorname{span}(W)$, y deducir que $0 \leq c_i = \|P\boldsymbol{q}_i\|^2 \leq 1$.

(b) Probar que $\sum_{i=1}^{p} c_i = \operatorname{tr}(P) = d$.

(c) Probar que $\operatorname{tr}(W^TSW) = \sum_{i=1}^{p} \lambda_i c_i$ y deducir que $\operatorname{tr}(W^TSW) \leq \lambda_1 + \cdots + \lambda_d$, con igualdad en $W = [\,\boldsymbol{q}_1 \ \cdots \ q_d\,]$. *Ayuda:* $\sum_i \lambda_i c_i - \sum_{i\leq d} \lambda_i = \sum_{i\leq d}(\lambda_i - \lambda_d)(c_i - 1) + \sum_{i>d}(\lambda_i - \lambda_d)c_i$. Es otra demostración del Teorema 9.30, sin Eckart–Young, y vale para cualquier S simétrica.

(d) Deducir la cota inferior $\operatorname{tr}(W^TSW) \geq \lambda_{p-d+1} + \cdots + \lambda_p$ y decir dónde se alcanza.

9.17 [Concepto] **Qué es único.** Sea X con $\sigma_d > \sigma_{d+1}$ y sea $W^* = V_d$.

(a) Probar que $W = V_dR$ resuelve (9.6) para toda $R \in \mathbb{R}^{d\times d}$ ortogonal, y que toda solución es de esa forma (usar que el subespacio óptimo es único, Observación 9.22).

(b) ¿Cómo cambian los scores $Z = XW$ al cambiar R? Probar que la matriz ZZ^T y la reconstrucción ZW^T no dependen de R.

(c) Para el rombo centrado del Ejemplo 9.25, verificar que todo vector unitario $\boldsymbol{w}$ da el mismo error $\left\|X_c - X_c ww^T\right\|_F^2$.

9.18 [Cálculo] **PCA a mano, con centrado.** Sean las observaciones $(5, 3)$, $(1, -1)$, $(4, 0)$ y $(2, 2)$ en $\mathbb{R}^2$.

(a) Calcular $\bar{\boldsymbol{x}}$ y la matriz centrada X_c.

(b) Calcular S, sus autovalores y sus autovectores unitarios.

(c) Calcular las dos componentes principales $z_1, z_2 \in \mathbb{R}^4$, sus varianzas y su covarianza.

(d) Calcular la reconstrucción de rango uno $\widehat{X}$ y el error $\left\|X_c - \widehat{X}\right\|_F^2$; verificar con Eckart–Young que vale σ_2^2.

(e) Calcular PVE(1).

(f) Calcular la dirección principal *sin* centrar, y explicar en el dibujo qué está midiendo.

9.19 [Concepto] **Invariancias de PCA.** Sea X centrada con SVD $U\Sigma V^T$.

(a) (Rotar las variables.) Si $\widetilde{X} = XQ$ con $Q \in \mathbb{R}^{p\times p}$ ortogonal, probar que $\widetilde{X}$ tiene los mismos valores singulares, que sus direcciones principales son $Q^T\boldsymbol{v}_k$ y que sus componentes principales son las mismas que las de X.

(b) (Cambiar de escala una variable.) Sea $\widetilde{X} = XD$ con $D = \operatorname{diag}(3, 1)$ y X el rombo centrado del Ejemplo 9.25. Calcular las direcciones principales de $\widetilde{X}$ y compararlas con las de X. Concluir que PCA *no* es invariante por cambios de escala, y explicar por qué se estandariza cuando las unidades no son comparables.

(c) (Trasladar.) Si $\widetilde{X} = X + \mathbf{1}c^T$ con $c \in \mathbb{R}^p$, ¿qué le pasa al PCA después de centrar?

9.20 [Concepto] **Varianza total.** Sea X una matriz de datos (no necesariamente centrada) con media $\bar{\boldsymbol{x}}$ y sea S la covarianza muestral de X_c. Probar que

$$(n-1)\operatorname{tr}(S) = \sum_{i=1}^{n} \|\boldsymbol{x}_i - \bar{\boldsymbol{x}}\|^2 = \|X_c\|_F^2 ,$$

y que $\bar{\boldsymbol{x}}$ es el punto $m \in \mathbb{R}^p$ que minimiza $\sum_i \|\boldsymbol{x}_i - m\|^2$. Interpretar: la varianza total es la suma de los cuadrados de las distancias al centro. Deducir la identidad $\mathrm{PVE}(d) = 1 - \|X_c - (X_c)_d\|_F^2 \,/\, \|X_c\|_F^2$.

9.21 [Concepto] **Cuando $p \gg n$.** Sea $X \in \mathbb{R}^{n\times p}$ centrada con $n < p$.

(a) Probar que $\operatorname{rango}(X) \le n-1$ y por lo tanto S tiene al menos $p-n+1$ autovalores nulos.

(b) Probar que si $XX^T\boldsymbol{u} = \sigma^2\boldsymbol{u}$ con $\sigma > 0$ y $\|\boldsymbol{u}\| = 1$, entonces $\boldsymbol{v} = X^T\boldsymbol{u}/\sigma$ es un vector unitario con $X^TX\boldsymbol{v} = \sigma^2\boldsymbol{v}$.

(c) Comparar el costo de diagonalizar X^TX $(p \times p)$ con el de diagonalizar XX^T $(n \times n)$ para $n = 1000$ y $p = 10^6$.

9.22 [Concepto] **La primera componente, directamente.** Para $d = 1$, probar directamente que $\boldsymbol{v}_1$, el autovector de S asociado a λ_1, maximiza $\boldsymbol{w}^TS\boldsymbol{w}$ sujeto a $\|\boldsymbol{w}\| = 1$, y que la varianza de $z = X\boldsymbol{v}_1$ es λ_1. *Ayuda:* escribir $\boldsymbol{w}$ en la base de autovectores.

9.23 [Concepto] **Máxima varianza no es máxima separación.** Sean $2m$ puntos de $\mathbb{R}^2$: la clase A son $(t_i, 0)$ y la clase B son $(t_i, 1)$, con $t_1, \dots, t_m$ números distintos y de media cero.

(a) Calcular la matriz de datos centrada, su covarianza S y la primera dirección principal $\boldsymbol{v}_1$ en función de $\sum_i t_i^2$.

(b) Probar que si los t_i están suficientemente desparramados ($\sum_i t_i^2$ grande), entonces $\boldsymbol{v}_1 \to (1,0)$: la dirección de máxima varianza es *paralela* a las dos rectas.

(c) Proyectar los puntos sobre $\boldsymbol{v}_1$ y sobre $(0,1)$. ¿Cuál de las dos proyecciones permite distinguir las clases? ¿Cuál explica más varianza?

(d) Concluir: la dirección que PCA elige puede ser exactamente la peor para separar dos grupos. (El capítulo siguiente convierte esta observación en un criterio, y el que le sigue lo resuelve.)

9.24 [Datos] **Un plano con ruido.** Generar n puntos $\boldsymbol{x}_i = a_i u + b_i v + \varepsilon_i \in \mathbb{R}^3$, con $\boldsymbol{u}, \boldsymbol{v}$ ortonormales, a_i, b_i aleatorios y ε_i un ruido chico (por ejemplo, generado con `np.random.normal` con desvío s).

(a) Aplicar PCA y estimar el subespacio de dimensión 2.

(b) Medir el ángulo entre el plano estimado y $\operatorname{span}\{\boldsymbol{u}, \boldsymbol{v}\}$ (por ejemplo, la norma de la proyección de $\boldsymbol{v}_3$ sobre $\operatorname{span}\{\boldsymbol{u}, \boldsymbol{v}\}$).

(c) Explorar el efecto del tamaño del ruido s sobre $\lambda_1, \lambda_2, \lambda_3$ y sobre el PVE(2). Relacionar con el Ejercicio 9.4(a).

9.25 [Datos] **PCA no es robusto.** A las cuatro observaciones del Ejemplo 9.37 se agregan dos observaciones atípicas, $(6,-6)$ y $(-6,6)$.

(a) Verificar que los seis puntos siguen centrados, calcular la nueva S y sus autovalores, y mostrar que la dirección principal *gira* 90°: pasa de la bisectriz $x_2 = x_1$ a la recta $x_2 = -x_1$.

(b) ¿Qué PVE(1) se obtiene ahora? ¿Describe bien a la mayoría de los datos?

(c) (En la computadora.) Repetir con una nube 2D grande y unos pocos puntos de norma muy grande: estudiar cómo cambian λ_1, λ_2 y el ángulo de $\boldsymbol{v}_1$ a medida que los atípicos se alejan. Discutir estrategias (detección de atípicos, medidas robustas de dispersión) *antes* de aplicar PCA.

9.26 [Datos] **Nadie le gana a X_d.** Tomar $X \in \mathbb{R}^{50\times 30}$ con entradas aleatorias y $d = 5$.

(a) Generar 10^4 matrices de rango $\le d$ de dos maneras: $M = CR$ con $C \in \mathbb{R}^{50\times 5}$ y $R \in \mathbb{R}^{5\times 30}$ aleatorias, y $M = XWW^T$ con W semiortogonal aleatoria (la Q de la factorización QR de una matriz aleatoria de 30×5). Hacer histogramas de $\|X - M\|_F$ y marcar $\|X - X_d\|_F$.

(b) Lo mismo con la norma espectral y la nuclear.

(c) Partiendo de $M = CR$ aleatoria, mejorar los factores alternadamente, $C \leftarrow XR^T(RR^T)^{-1}$ y $R \leftarrow (C^TC)^{-1}C^TX$ (¿por qué cada paso no aumenta el error? ver el Ejercicio 9.1(b)), y observar que $\|X - CR\|_F$ converge a $\|X - X_d\|_F$.

Trabajo práctico: SVD, imágenes y eigenfaces

La práctica se hace en la notebook `SVD_PCA_con_recortes.ipynb` de Google Colab. Antes de comenzar, haga una copia en su propio Drive (*Archivo* → *Guardar una copia en Drive*);

no modifique el archivo original. Deberá entregar un enlace a su copia con las soluciones y respuestas. La notebook **no debe ser solo de código**: use las celdas de texto (que aceptan LaTeX) para escribir sus razonamientos y conclusiones, que serán evaluados con mucho más detalle que el código.

La numeración TP.1–TP.16 es la de estas notas; en la notebook los mismos puntos aparecen como Ejercicio 1 (a)–(d) [TP.1–TP.4], Ejercicio 2 (a)–(c) [TP.5–TP.7], Ejercicio 2, segunda parte, (a)–(g) [Parte C y TP.8–TP.13] y Ejercicio 3 (a)–(c) [TP.14–TP.16].

Parte A: la SVD desde cero

TP.1 Su propia SVD. Defina una función `mi_svd(A)` que reciba una matriz A y devuelva U, Σ y V^T, a partir de los autovalores y autovectores de A^TA (las columnas de V) y de AA^T (las columnas de U); los valores singulares son las raíces de los autovalores no nulos. Investigue `np.linalg.eig`.

- *Cuidado*: `eig` no devuelve los autovalores ordenados.
- *Cuidado*: hay que garantizar la consistencia de signos entre U y V mediante la relación $A\boldsymbol{v}_i = \sigma_i u_i$. (¿Por qué es más prolijo calcular solo V y definir $\boldsymbol{u}_i = A\boldsymbol{v}_i/\sigma_i$? ¿Y por qué, en general, no conviene calcular la SVD a partir de A^TA? Ver la Observación 9.38.)

TP.2 Verifique que su función anda. Pruébela con

$$A_1 = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}, \qquad A_2 = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}, \qquad A_3 = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix},$$

verificando $A \approx U\Sigma V^T$ con `np.allclose(A, U @ Sigma @ Vt)`.

TP.3 La SVD en dibujos. Aplique las tres matrices a una grilla de puntos de $[-1, 1] \times [-1, 1]$ y grafique la grilla y sus imágenes.

TP.4 Explique con sus palabras lo que observa en cada gráfico y cómo podría haber conocido ese efecto solo por conocer la SVD. (¿Qué hacen V^T, Σ y U? ¿En qué se transforma el círculo unitario? ¿Qué pasa con A_3, que tiene rango uno?)

Parte B: compresión de imágenes en escala de grises

Por Eckart–Young, la mejor aproximación de rango k de una imagen $A \in \mathbb{R}^{m\times n}$ es su SVD truncada $A_k = \sum_{i\le k} \sigma_i u_i v_i^T = U_k \Sigma_k V_k^T$. La notebook carga una imagen en escala de grises (`scipy.datasets.face`, de 768×1024).

TP.5 Use `np.linalg.svd` para calcular la SVD de la matriz de la imagen. ¿Qué devuelve exactamente? (Compare `full_matrices=True` y `False`.)

TP.6 Defina una función `aproximacion_rango_k(U, S, Vt, k)` que reconstruya la imagen con los primeros k valores singulares.

TP.7 Grafique la imagen original junto con sus aproximaciones para $k \in \{5, 20, 50, 100\}$. Observe cómo mejora la calidad a medida que agregamos componentes. ¿Cuántos números hay que guardar en cada caso?

Parte C: ¿y si en lugar de la SVD cortamos filas y columnas?

Ahora comparamos la SVD con la manera "ingenua" de achicar una imagen: tirar filas y columnas. Puede seguir con la imagen de la Parte B o, mejor, subir una foto propia: escriba un código que permita subir una imagen desde su dispositivo, la pase a escala de grises, la convierta en una matriz de intensidades y permita reconstruir la imagen a partir de la matriz.

TP.8 Filas y columnas centrales. Escriba un código que elimine el 10% de las filas centrales y el 10% de las columnas centrales, y visualice la imagen resultante.

TP.9 Filas y columnas al azar. Escriba un código que elimine un porcentaje $c\%$ de filas y $c\%$ de columnas elegidas al azar, con c ingresado por el usuario, y visualice el resultado.

TP.10 A igual cantidad de números. Elija un valor de k que lo deje conforme con la imagen A_k de la Parte B. Determine el valor de c que da la misma cantidad de información (números guardados) que A_k: $(1-c)^2 mn = k(m+n+1)$. Compare las dos imágenes. Para que tengan el mismo tamaño, pruebe pintar de negro (o de blanco) las filas y columnas en lugar de eliminarlas, y también rellenar cada fila o columna borrada con la vecina conservada más cercana.

TP.11 Normas de la diferencia. Calcule las normas espectral, de Frobenius y nuclear de la diferencia entre la imagen original y cada una de sus versiones (las A_k y las recortadas). Verifique las fórmulas de Eckart–Young para $A - A_k$. ¿Permite el teorema predecir quién gana contra las imágenes recortadas? (¿Qué rango tienen?)

TP.12 Más datos y peor. Grafique, en función de la cantidad de números guardados, el error relativo $\|A - B\|_F \,/\, \|A\|_F$ de la SVD truncada ($B = A_k$, para $k = 1, 2, \ldots, 200$) y el de la imagen recortada al azar y rellenada (B para c entre 0,95 y 0). ¿Cuántos números más que la SVD hay que guardar cortando filas y columnas para lograr el mismo error? Escriba sus conclusiones.

TP.13 Volviendo a la foto. ¿Se entiende por qué anda tan bien la aproximación con la SVD? Grafique los valores singulares de la imagen (en escala logarítmica) junto con los de una matriz aleatoria del mismo tamaño y explique la diferencia (Sección 9.5).

Parte D: PCA y eigenfaces

Cuando aplicamos PCA a un conjunto de fotos de caras (centradas restando la cara promedio), las direcciones principales son a su vez imágenes, las **eigenfaces**, y cualquier cara se reconstruye como la cara promedio más una combinación de las primeras k eigenfaces (Sección 9.8.3).

TP.14 Cargue la base de caras de `sklearn.datasets` con

```
fetch_lfw_people(min_faces_per_person=70, resize=0.4):
```

la matriz X tiene una cara aplanada por fila. Calcule la cara promedio y centre los datos.

TP.15 Calcule la SVD de la matriz centrada para obtener las eigenfaces (las filas de V^T). Visualice la cara promedio y las primeras 5 eigenfaces.

TP.16 Elija una cara y grafique su reconstrucción $\boldsymbol{x}_{\text{rec}} = \bar{\boldsymbol{x}} + \sum_{i \le k} c_i \, \boldsymbol{v}_i$, con $c_i = \boldsymbol{v}_i^T(\boldsymbol{x} - \bar{\boldsymbol{x}})$, para $k \in \{5, 20, 50, 150\}$. (Opcional: grafique PVE(k) y diga cuántas componentes hacen falta para el 90%; compare con el truco de la matriz de Gram de la Observación 9.39.)

Herramientas útiles (Python):

- subir el archivo: `google.colab.files.upload()`;
- pasar a grises: `PIL.Image.open(f).convert("L")`;
- la matriz: `np.asarray(img, dtype=float)/255`;
- verla: `plt.imshow(A, cmap="gray", vmin=0, vmax=1)`;
- borrar filas o columnas: `np.delete(A, filas, axis=0)`;
- SVD: `np.linalg.svd(A, full_matrices=False)`;
- normas: `np.linalg.norm(E, 2)`, `np.linalg.norm(E, "fro")`, `np.linalg.norm(E, "nuc")`.

10 CAPÍTULO

PCA y clasificación

10.1 Introducción

Clasificar es decidir a qué grupo pertenece una observación nueva, a partir de un conjunto de observaciones de las que ya sabemos a qué grupo pertenecen. Los grupos se llaman **clases** (en estadística se habla también de *poblaciones*). Por ejemplo: reconocer qué número es la imagen de un dígito escrito a mano (diez clases: $0, 1, \ldots, 9$), decidir si un tumor es benigno o maligno a partir de mediciones de sus células, o distinguir un colectivo de una camioneta por la forma de su silueta.

Los datos son, como en PCA, una matriz $X \in \mathbb{R}^{n \times p}$ con una observación por fila ($\boldsymbol{x}_1^\mathsf{T}, \ldots, \boldsymbol{x}_n^\mathsf{T}$, con $\boldsymbol{x}_i \in \mathbb{R}^p$) y una variable por columna. La novedad es que ahora cada observación viene con una **etiqueta**: un vector y con $y_i \in \{1, \ldots, C\}$, la clase de la observación i. PCA no usaba las etiquetas; para clasificar, las vamos a usar.

En la práctica de este capítulo y del siguiente trabajamos con cuatro conjuntos de datos:

datos	n	p	C	qué se mide
tumores de mama	569	30	2	núcleos celulares en imágenes de punciones (maligno/benigno)
dígitos	1797	64	10	intensidades de imágenes de 8×8 de dígitos escritos a mano
cáncer de pulmón	32	56	3	atributos sin descripción, con valores enteros de 0 a 3 (tres tipos de cáncer)
siluetas de vehículos	845	18	4	medidas de forma de la silueta (colectivo, camioneta, dos autos)

(n observaciones, p variables, C clases). Los dos primeros vienen con `scikit-learn` y los dos últimos se bajan del repositorio UCI [9] (el de vehículos tiene 846 filas, una de ellas incompleta, que descartamos).

Este capítulo **no usa teoría estadística**: todo es geometría de vectores y matrices. La idea central es muy simple: *resumimos cada clase con su media, y una observación nueva se asigna a la clase cuya media está más cerca.* El plan:

1. la media de cada clase (Sección 10.2);
2. la regla de la media más cercana, y cómo parte el espacio (Sección 10.3);
3. cómo se mide si un clasificador anda bien: entrenamiento y prueba (Sección 10.4), y por qué importan las unidades (Sección 10.5);
4. PCA antes de clasificar (Sección 10.6) y lo que PCA no ve (Sección 10.7), que nos lleva al próximo capítulo.

Hay clasificadores mucho más elaborados (ver, por ejemplo, [6]); acá nos quedamos con el más simple.

10.2 La media de cada clase

Llamamos n_k a la cantidad de observaciones de la clase k (así que $n_1 + \cdots + n_C = n$) y

$$\bar{\boldsymbol{x}}_k = \frac{1}{n_k} \sum_{i:\ y_i = k} \boldsymbol{x}_i \ \in \mathbb{R}^p$$

a la **media de la clase** k: el promedio, variable por variable, de las filas de X que son de la clase k. Es un punto de $\mathbb{R}^p$ que resume a toda la clase. Como en el Capítulo 9, $\bar{\boldsymbol{x}} = \frac{1}{n}\sum_{i=1}^n \boldsymbol{x}_i$ es la media de todos los datos.

En los dígitos, cada observación es una imagen de 8×8 píxeles guardada como un vector de $\mathbb{R}^{64}$, con una entrada por píxel (su intensidad de gris). La media de la clase 3 es otro vector de $\mathbb{R}^{64}$ que, dibujado como imagen, es un "tres promedio": borroso, pero se reconoce (Figura 10.1).

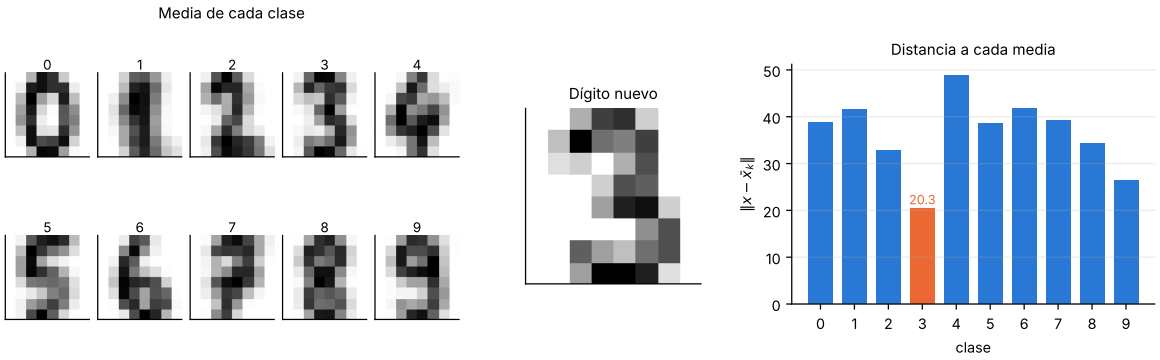


Figura 10.1. Dígitos escritos a mano (imágenes de 8×8 píxeles, así que $p = 64$). Izquierda: la media de cada una de las diez clases, calculada con 1257 imágenes de entrenamiento y dibujada como imagen. Centro: un dígito que no se usó para calcular las medias. Derecha: su distancia a cada una de las medias; la más chica es la distancia a la media de los treses.

Ejemplo 10.1 (Ocho puntos en el plano)**.** Usamos este ejemplo en todo el capítulo y en el siguiente. La clase 1 son los puntos $(2,3)$, $(1,3)$, $(-1,-3)$, $(-2,-3)$ y la clase 2 son $(5,3)$, $(4,3)$, $(2,-3)$, $(1,-3)$: la segunda es la primera trasladada en $(3,0)$ (Figura 10.2). Las medias de las clases son

$$\bar{\boldsymbol{x}}_1 = \tfrac{1}{4}\Big((2,3) + (1,3) + (-1,-3) + (-2,-3)\Big) = (0,0), \qquad \bar{\boldsymbol{x}}_2 = (3,0),$$

y la media de los ocho puntos es $\bar{\boldsymbol{x}} = (3/2, 0)$.

Observación 10.2 (Todas las medias con una multiplicación)**.** Sea $G \in \mathbb{R}^{n \times C}$ la **matriz indicadora** de las clases: $g_{ik} = 1$ si la observación i es de la clase k, y $g_{ik} = 0$ si no. La fila k de $G^\mathsf{T} X$ es la suma de las filas de X que son de la clase k, y $G^\mathsf{T} G = \operatorname{diag}(n_1, \ldots, n_C)$ (cada fila de G tiene un solo uno, así que sus columnas son ortogonales, y la columna k tiene n_k unos). Entonces

$$M = (G^\mathsf{T} G)^{-1} G^\mathsf{T} X \in \mathbb{R}^{C \times p} \qquad \text{tiene en la fila } k \text{ a } \bar{\boldsymbol{x}}_k^\mathsf{T}.$$

En los ocho puntos, ordenados como en el Ejemplo 10.1,

$$G^{\mathsf{T}} = \begin{pmatrix} 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{pmatrix},$$

$$G^{\mathsf{T}}G = \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix}, \qquad G^{\mathsf{T}}X = \begin{pmatrix} 0 & 0 \\ 12 & 0 \end{pmatrix}, \qquad M = \begin{pmatrix} 0 & 0 \\ 3 & 0 \end{pmatrix}.$$

Así se calculan todas las medias a la vez en la computadora.

10.3 La regla de la media más cercana

Definición 10.3 (Clasificador de la media más cercana). Dadas las medias $\bar{\boldsymbol{x}}_1, \ldots, \bar{\boldsymbol{x}}_C$ de las clases, una observación nueva $\boldsymbol{x} \in \mathbb{R}^p$ se asigna a la clase cuya media está más cerca:

$$f(\boldsymbol{x}) = \operatorname*{argmin}_{k=1,\ldots,C} \|\boldsymbol{x} - \bar{\boldsymbol{x}}_k\|,$$

es decir, $f(\boldsymbol{x})$ es el k para el que la distancia $\|\boldsymbol{x} - \bar{\boldsymbol{x}}_k\|$ es mínima. (Si hay empate, se elige cualquiera de las clases empatadas; en la computadora, la primera.)

En la Figura 10.1, el dígito nuevo está a distancia 20,3 de la media de los treses y a más de 26 de todas las demás: se lo asigna a la clase 3, y efectivamente es un tres. ¿Cómo queda partido el espacio entre las clases? Con dos clases la respuesta es sencilla.

Proposición 10.4 (Con dos clases, la frontera es la mediatriz). Sean $\boldsymbol{a} \neq \boldsymbol{b}$ dos puntos de $\mathbb{R}^p$ (las medias de dos clases) y sea $m = \frac{1}{2}(\boldsymbol{a} + \boldsymbol{b})$ el punto medio entre ellos. Para todo $\boldsymbol{x} \in \mathbb{R}^p$,

$$\|\boldsymbol{x} - \boldsymbol{a}\|^2 - \|\boldsymbol{x} - \boldsymbol{b}\|^2 = -2\,(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}(\boldsymbol{x} - m).$$

En consecuencia, $\boldsymbol{x}$ está más cerca de $\boldsymbol{a}$ que de $\boldsymbol{b}$ si y solo si $(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}(\boldsymbol{x} - m) > 0$, y los puntos que están a la misma distancia de $\boldsymbol{a}$ y de $\boldsymbol{b}$ forman el hiperplano

$$\left\{\boldsymbol{x} \in \mathbb{R}^p : \ (\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}(\boldsymbol{x} - m) = 0\right\},$$

que pasa por el punto medio m y es perpendicular al segmento que une $\boldsymbol{a}$ con $\boldsymbol{b}$. En el plano es la mediatriz del segmento, y en $\mathbb{R}^p$ también lo llamamos así.

Demostración. Desarrollando, $\|\boldsymbol{x} - \boldsymbol{a}\|^2 = \|\boldsymbol{x}\|^2 - 2\boldsymbol{a}^{\mathsf{T}}\boldsymbol{x} + \|\boldsymbol{a}\|^2$, y lo mismo con $\boldsymbol{b}$. Al restar se cancela $\|\boldsymbol{x}\|^2$:

$$\|\boldsymbol{x} - \boldsymbol{a}\|^2 - \|\boldsymbol{x} - \boldsymbol{b}\|^2 = -2(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}\boldsymbol{x} + \|\boldsymbol{a}\|^2 - \|\boldsymbol{b}\|^2.$$

Como $\boldsymbol{a}^{\mathsf{T}}\boldsymbol{b} = \boldsymbol{b}^{\mathsf{T}}\boldsymbol{a}$, se tiene $\|\boldsymbol{a}\|^2 - \|\boldsymbol{b}\|^2 = (\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}(\boldsymbol{a} + \boldsymbol{b}) = 2(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}m$, y queda $-2(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}\boldsymbol{x} + 2(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}m = -2(\boldsymbol{a} - \boldsymbol{b})^{\mathsf{T}}(\boldsymbol{x} - m)$. ∎

Con dos clases, entonces, la regla de la media más cercana corta $\mathbb{R}^p$ en dos semiespacios con un hiperplano: es un *clasificador lineal*. Con más clases, la clase k gana en los puntos que están más cerca de $\bar{\boldsymbol{x}}_k$ que de cada una de las otras medias; comparando de a dos con la Proposición 10.4, la región de la clase k es la intersección de $C - 1$ semiespacios, y las fronteras son pedazos de mediatrices (Ejercicios 10.1 y 10.2).

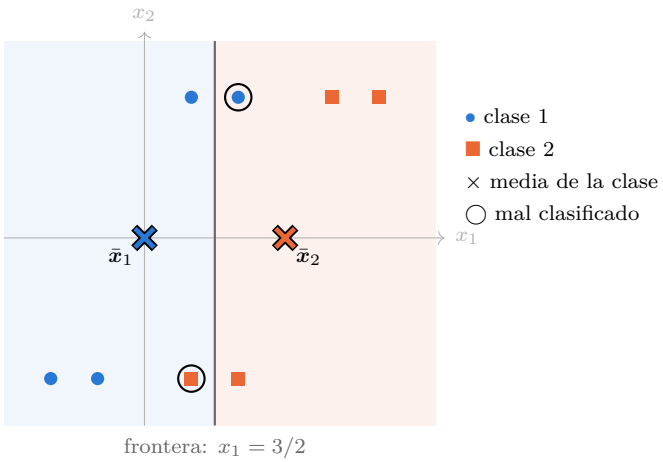


Figura 10.2. Los ocho puntos del Ejemplo 10.1 y las medias de las dos clases. La regla de la media más cercana corta el plano por la mediatriz de las medias (la recta $\boldsymbol{x}_1 = 3/2$) y se equivoca en los dos puntos marcados.

Ejemplo 10.5 (La media más cercana en los ocho puntos). En el Ejemplo 10.1, la mediatriz de $\bar{\boldsymbol{x}}_1 = (0, 0)$ y $\bar{\boldsymbol{x}}_2 = (3, 0)$ es la recta $\boldsymbol{x}_1 = 3/2$: todo punto con $\boldsymbol{x}_1 < 3/2$ va a la clase 1, y todo punto con $\boldsymbol{x}_1 > 3/2$, a la clase 2. El punto $(2, 3)$ de la clase 1 y el punto $(1, -3)$ de la clase 2 quedan del lado equivocado, así que la regla acierta 6 de los 8 puntos (Figura 10.2). Mirando el dibujo, las clases se pueden separar perfectamente con una recta inclinada. La regla no la encuentra porque solo mira las medias y no la forma de las clases, que son alargadas. En el próximo capítulo (LDA, análisis discriminante lineal) vamos a encontrar esa recta.

10.4 Entrenar y probar

¿Cómo sabemos si un clasificador anda bien? Contar los aciertos sobre los mismos datos con los que calculamos las medias es hacer trampa: el clasificador ya "vio" esos datos, y el resultado suele ser demasiado optimista. Lo que interesa es cómo le va con datos *nuevos*. Por eso, antes de empezar, los datos se separan al azar en dos partes:

- los de **entrenamiento**, $(X_{\text{ent}}, y_{\text{ent}})$, con los que se calcula *todo* lo que el clasificador necesita: las medias de las clases y, más adelante, los desvíos para estandarizar y las direcciones de PCA;
- los de **prueba**, $(X_{\text{pru}}, y_{\text{pru}})$, que se guardan y se usan una sola vez, al final, para contar los aciertos.

Lo habitual es separar un 70% para entrenar y un 30% para probar, manteniendo en las dos partes la proporción de cada clase (separación *estratificada*) y con una *semilla* fija (el número con el que arranca el generador de números al azar), para que el resultado se pueda repetir.

> **Definición 10.6** (Aciertos y matriz de confusión). Supongamos que el clasificador les asigna las clases $\hat{y}_1, \dots, \hat{y}_m$ a las m observaciones de prueba, cuyas clases verdaderas son $y_1, \dots, y_m$. La proporción de **aciertos** es la proporción de las observaciones con $\hat{y}_i = y_i$, y el **error** es uno menos la proporción de aciertos. La **matriz de confusión**

es $K \in \mathbb{R}^{C\times C}$ con

$$K_{jk} = \text{cantidad de observaciones de la clase } j \text{ asignadas a la clase } k.$$

En la diagonal están los aciertos, así que la proporción de aciertos es $\operatorname{tr}(K)/m$.

Ejemplo 10.7 (Tumores de mama). Con las variables estandarizadas (Sección 10.5), la regla de la media más cercana clasifica así a los 171 tumores de prueba (filas: clase verdadera; columnas: clase asignada; primero maligno y después benigno):

$$K = \begin{pmatrix} 56 & 8 \\ 7 & 100 \end{pmatrix}.$$

Acierta $56 + 100 = 156$ de 171, el 91,2%. Pero la matriz muestra más: de los 64 tumores malignos, 8 fueron clasificados como benignos, que en medicina es el error más grave. La matriz de confusión dice *qué* se confunde con qué, y no solo cuánto.

Receta: cómo se clasifica (vale para cualquier clasificador)

1. **Separar** los datos en entrenamiento y prueba.
2. **Entrenar**: con los datos de entrenamiento, calcular todo lo que haga falta (medias y desvíos para estandarizar, las direcciones de PCA, las medias de las clases).
3. **Probar**: a X_{pru} aplicarle *las mismas* transformaciones, con los números del paso 2 (sin recalcularlos), clasificar y comparar con y_{pru}: aciertos y matriz de confusión.
4. **Usar**: una observación nueva se trata igual que una de prueba.

Observación 10.8 (Con pocos datos). Con los 32 pacientes de cáncer de pulmón, la prueba tiene solo 10, y el porcentaje de aciertos puede cambiar mucho según cómo haya caído la separación al azar. En ese caso conviene repetir la separación con varias semillas y mirar todos los resultados (Ejercicio 10.9).

10.5 Las unidades importan

El cuadrado de la distancia euclídea suma las diferencias al cuadrado de todas las variables por igual. Si una variable varía mucho más que las otras (si tiene un desvío mucho mayor), domina la distancia.

En los datos de vinos (otro conjunto clásico, que también viene con `scikit-learn`: 178 vinos, 13 variables químicas y 3 variedades de uva), la variable *prolina* tiene, en el entrenamiento, un desvío de 327, y todas las demás tienen desvíos menores que 15: la varianza de la prolina es el 99,8% de la suma de las varianzas de las 13 variables. La regla de la media más cercana usa entonces prácticamente solo la prolina: en los 54 vinos de prueba asigna exactamente las mismas clases que si miráramos únicamente esa variable, y acierta el 68,5%. **Estandarizando**, es decir, restando la media y dividiendo por el desvío de cada variable (los dos calculados con el entrenamiento), acierta el 98,1%. En los tumores de mama pasa lo mismo en menor escala: 87,7% sin estandarizar y 91,2% estandarizando (las dos áreas de los núcleos, con desvíos de 578 y 364, dominan a todas las demás variables).

En forma matricial, estandarizar es reemplazar cada $\boldsymbol{x}$ por

$$D^{-1}(\boldsymbol{x} - \bar{\boldsymbol{x}}), \qquad D = \operatorname{diag}(s_1, \ldots, s_p),$$

con la media $\bar{\boldsymbol{x}}$ y los desvíos s_j de las variables calculados con el entrenamiento: es cambiar las unidades de cada variable. Las distancias cambian, y con ellas pueden cambiar las clases asignadas (Ejercicio 10.5). Estandarizar no siempre es mejor: si todas las variables ya están en la misma escala, como los píxeles de una imagen, puede empeorar las cosas (Ejercicio 10.8). En el próximo capítulo, LDA va a elegir la manera de medir distancias teniendo en cuenta la forma de las clases.

10.6 PCA antes de clasificar

Con muchas variables (64 píxeles, 30 mediciones) es natural reducir primero la dimensión con PCA y clasificar en $\mathbb{R}^d$, con d chico:

1. con los datos de entrenamiento, calcular la media $\bar{\boldsymbol{x}}$ (y, si hace falta, estandarizar) y la SVD de la matriz centrada, $X_c = U\Sigma V^\mathsf{T}$; quedarse con V_d, las primeras d columnas de V;
2. reemplazar cada observación $\boldsymbol{x}$ (de entrenamiento o de prueba) por sus d scores $z = V_d^\mathsf{T}(\boldsymbol{x} - \bar{\boldsymbol{x}}) \in \mathbb{R}^d$;
3. clasificar z con la regla de la media más cercana en $\mathbb{R}^d$.

Para el paso 3 hacen falta las medias de las clases en las coordenadas nuevas, y no hay que calcular nada más: como los scores se obtienen restando $\bar{\boldsymbol{x}}$ y multiplicando por V_d^T, la media de los scores de la clase k es el score de la media,

$$\frac{1}{n_k} \sum_{i:\ y_i = k} V_d^\mathsf{T}(\boldsymbol{x}_i - \bar{\boldsymbol{x}}) = V_d^\mathsf{T}\left(\frac{1}{n_k} \sum_{i:\ y_i = k} \boldsymbol{x}_i - \bar{\boldsymbol{x}}\right) = V_d^\mathsf{T}(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}}).$$

Lo primero que conviene saber es que, si no truncamos, no perdemos nada.

Proposición 10.9 (Con todas las componentes no cambia nada). Si $d = p$, es decir, si usamos la matriz ortogonal $V \in \mathbb{R}^{p\times p}$ con todos los vectores singulares derechos, entonces para todo $\boldsymbol{x} \in \mathbb{R}^p$ y toda clase k,

$$\left\| V^\mathsf{T}(\boldsymbol{x} - \bar{\boldsymbol{x}}) - V^\mathsf{T}(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}}) \right\| = \|\boldsymbol{x} - \bar{\boldsymbol{x}}_k\|.$$

Por lo tanto, la regla de la media más cercana con los p scores asigna las mismas clases que con las variables originales.

Demostración. $V^\mathsf{T}(\boldsymbol{x} - \bar{\boldsymbol{x}}) - V^\mathsf{T}(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}}) = V^\mathsf{T}(\boldsymbol{x} - \bar{\boldsymbol{x}}_k)$, y una matriz ortogonal conserva las longitudes: $\|V^\mathsf{T}\boldsymbol{u}\|^2 = \boldsymbol{u}^\mathsf{T}VV^\mathsf{T}\boldsymbol{u} = \boldsymbol{u}^\mathsf{T}\boldsymbol{u} = \|\boldsymbol{u}\|^2$. ∎

Pasar a las coordenadas de PCA es solo llevar el origen a $\bar{\boldsymbol{x}}$ y girar los ejes (y tal vez reflejar alguno), y eso no cambia las distancias. Si la matriz centrada tiene rango $r < p$, alcanza con sus r primeras componentes: tampoco cambia nada (Ejercicio 10.6). Eso pasa si hay más variables que datos, o si hay variables constantes: en los dígitos de entrenamiento hay cuatro píxeles que valen siempre 0, y $r = 60$. Lo que sí cambia las cosas

es *truncar*, quedarse con d componentes cuando hay más: se pierden las coordenadas en las direcciones $\boldsymbol{v}_{d+1}, \boldsymbol{v}_{d+2}, \ldots$, las distancias a las medias se achican, cada una de manera distinta, y la clase asignada puede cambiar. A veces es para bien (se descarta "ruido") y muchas veces para mal.

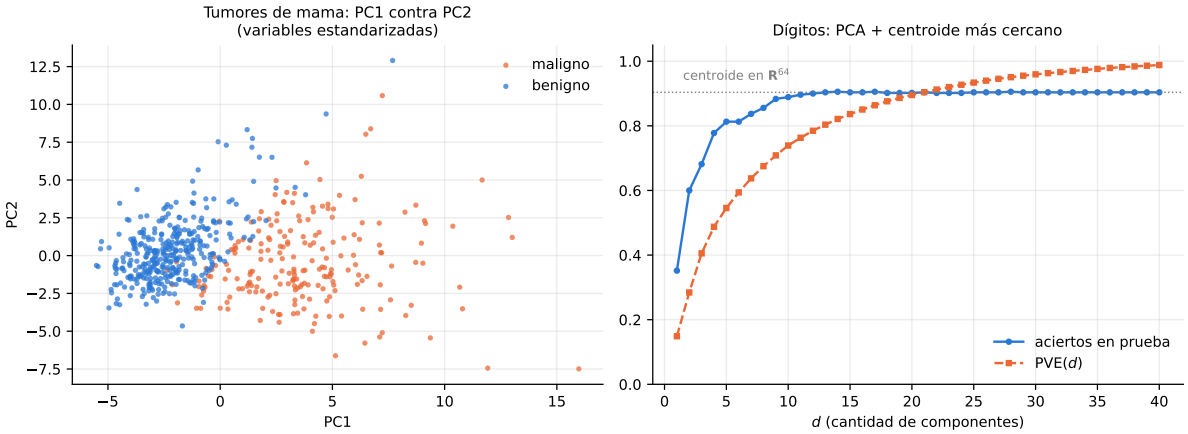


Figura 10.3. Izquierda: las dos primeras componentes principales de los 569 tumores de mama (todos los datos, con las variables estandarizadas; entre paréntesis, la proporción de la varianza que explica cada una); las clases ya se distinguen bastante en PC1. Derecha: dígitos (sin estandarizar); proporción de aciertos en prueba de la media más cercana calculada en $\mathbb{R}^d$ con los scores de PCA, junto con la proporción de varianza explicada PVE(d) por las primeras d componentes (definida en el Capítulo 9).

La Figura 10.3 muestra dos situaciones típicas. En los tumores de mama (estandarizados), la primera componente principal ya separa bastante bien las clases: con $d = 1$, la regla de la media más cercana acierta el 90,1% de los tumores de prueba, y con $d \geq 4$ se llega al 91,2% que se obtiene con las 30 variables. En los dígitos, con $d = 2$ se acierta apenas el 60% (los dos primeros scores sirven para dibujar, pero no alcanzan para clasificar), con $d = 10$ el 88,9% y con $d = 20$ el 90,2%, casi lo mismo que en $\mathbb{R}^{64}$ (90,4%). Observemos que la curva de aciertos se estabiliza mucho antes que la de varianza explicada (a partir de $d = 10$ mejora muy poco, y PVE(10) es apenas del 74%): *explicar varianza y clasificar bien no son lo mismo.*

Mirar antes de clasificar. El gráfico de PC1 contra PC2 con los puntos coloreados por clase es una muy buena primera mirada a un conjunto de datos con muchas variables, y muchas veces muestra más que cualquier par de variables originales (aunque, como vamos a ver enseguida, puede esconder justo la dirección que separa las clases). Es el punto P.4 de la práctica.

10.7 Lo que PCA no ve

PCA elige sus direcciones *sin mirar las etiquetas*: busca las direcciones en las que los datos, todos juntos, varían más. Para clasificar, en cambio, queremos direcciones en las que las clases proyectadas queden *separadas*, y nada garantiza que sean las de máxima varianza.

Ejemplo 10.10 (PCA en los ocho puntos). Centrando los ocho puntos del Ejemplo 10.1 (recordemos que $\bar{\boldsymbol{x}} = (3/2, 0)$), la matriz de covarianza es

$$S = \frac{1}{7}\begin{pmatrix} 38 & 36 \\ 36 & 72 \end{pmatrix},$$

con autovalores $\lambda_1 \approx 13{,}54$ y $\lambda_2 \approx 2{,}17$ y direcciones principales $\boldsymbol{v}_1 \approx (0{,}535;\ 0{,}845)$ y $\boldsymbol{v}_2 \approx (0{,}845;\ -0{,}535)$. La primera explica el 86% de la varianza (PVE(1) $\approx 0{,}86$): la nube de los ocho puntos es alargada en la dirección de $\boldsymbol{v}_1$, igual que cada clase (Figura 10.4).

Si reducimos a $d = 1$ con PCA, los scores $\boldsymbol{v}_1^{\mathsf{T}}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})$ de la clase 1 son 2,80; 2,27; −3,87; −4,41, y los de la clase 2 son 4,41; 3,87; −2,27; −2,80: las clases quedan completamente mezcladas. Las medias de los scores son −0,80 y 0,80, y la regla de la media más cercana en la recta acierta 4 de los 8 puntos, como si tiráramos una moneda.

En cambio, los scores sobre la segunda dirección, $\boldsymbol{v}_2^{\mathsf{T}}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})$, son −1,18; −2,03; −0,51; −1,35 en la clase 1 y 1,35; 0,51; 2,03; 1,18 en la clase 2: todos negativos en una clase y todos positivos en la otra. Las clases quedan perfectamente separadas, y la regla de la media más cercana sobre $\boldsymbol{v}_2$ acierta los 8 puntos (¡mejor que en todo el plano, donde acertaba 6!). La dirección que separa las clases es justamente la de varianza *chica*, la que PCA descarta. Mirando el plano se entiende por qué: la recta que pasa por $\bar{\boldsymbol{x}}$ en la dirección de $\boldsymbol{v}_1$ deja a cada clase de un lado, y lo que distingue a las clases es de qué lado de esa recta están, es decir, el signo de su coordenada sobre $\boldsymbol{v}_2$.

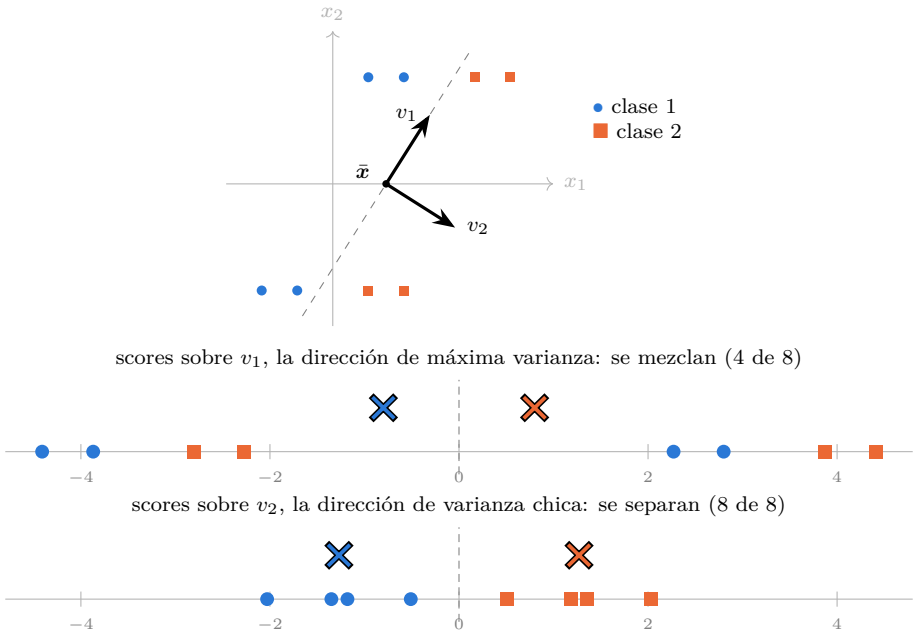


Figura 10.4. Arriba: los ocho puntos y sus direcciones principales, dibujadas desde la media $\bar{\boldsymbol{x}}$; la recta punteada pasa por $\bar{\boldsymbol{x}}$ en la dirección de $\boldsymbol{v}_1$. Abajo: los scores de cada punto sobre $\boldsymbol{v}_1$ y sobre $\boldsymbol{v}_2$, con la media de los scores de cada clase (×); la raya punteada es el punto medio entre las dos medias, la frontera de la regla de la media más cercana en la recta.

La explicación es que la varianza en una dirección mezcla dos cosas: cuánto se desparrama cada clase alrededor de su media, y cuánto se separan entre sí las medias de las clases. Para clasificar solo sirve lo segundo; lo primero estorba. PCA no puede distinguirlas porque no mira las etiquetas, y en los ocho puntos casi toda la varianza en la

dirección de $\boldsymbol{v}_1$ es dispersión de cada clase alrededor de su media. En el próximo capítulo, **LDA** va a buscar directamente, usando las etiquetas, la dirección en la que las medias de las clases quedan lo más separadas posible en relación con lo que se desparrama cada clase.

Ideas clave

- **Clasificar**: asignar una clase a una observación nueva, usando datos cuyas clases conocemos (la matriz X y el vector de etiquetas y).
- **La media de cada clase**, $\bar{\boldsymbol{x}}_k$, resume a la clase con un punto. Todas a la vez: $M = (G^\mathsf{T}G)^{-1}G^\mathsf{T}X$.
- **La media más cercana**: se asigna la clase cuya media está más cerca. Con dos clases, la frontera es el hiperplano que pasa por el punto medio entre las medias y es perpendicular al segmento que las une (la mediatriz).
- **Entrenar y probar**: todo se calcula con el entrenamiento y se mide con la prueba; la matriz de confusión dice qué clases se confunden.
- **Las unidades importan**: una variable con un desvío mucho mayor que las otras domina la distancia; estandarizar (con los desvíos del entrenamiento) lo corrige.
- **PCA antes de clasificar**: con todas las componentes no cambia nada (V es ortogonal); truncar sí cambia. Explicar varianza no es lo mismo que clasificar bien.
- **PCA no mira las etiquetas**: la dirección de máxima varianza puede mezclar las clases, y la que las separa puede ser de varianza chica. LDA busca esa dirección.

Ejercicios

[Cálculo] para fijar la mecánica, [Concepto] para justificar y demostrar, [Datos] para la computadora.

10.1 [Cálculo] **Tres clases a mano.** La clase A son los puntos $(0,0), (2,0), (0,2), (2,2)$; la clase B, $(5,0), (7,0), (5,2), (7,2)$; y la clase C, $(2,5), (4,5), (2,7), (4,7)$.

(a) Calcular las medias de las tres clases y la media de los doce puntos. Escribir la matriz indicadora G y verificar que $(G^\mathsf{T}G)^{-1}G^\mathsf{T}X$ tiene a las medias en las filas.

(b) Escribir las ecuaciones de las tres mediatrices y dibujar las regiones de la media más cercana. ¿Por qué las tres mediatrices se cortan en un mismo punto?

(c) Clasificar los puntos $(3,3)$, $(4,3)$ y $(4,4)$.

10.2 [Concepto] **Las regiones son convexas.** Sea R_k el conjunto de los $\boldsymbol{x} \in \mathbb{R}^p$ que están más cerca de $\bar{\boldsymbol{x}}_k$ que de todas las otras medias.

(a) Usando la Proposición 10.4, escribir R_k como intersección de $C-1$ semiespacios.

(b) Deducir que si $\boldsymbol{x}$ y $\boldsymbol{x}'$ están en R_k, todo el segmento que los une está en R_k.

10.3 [Concepto] **Todas las distancias de una vez.** Sean $X_{\text{nueva}} \in \mathbb{R}^{m\times p}$, con filas $\boldsymbol{u}_1^\mathsf{T}, \ldots, \boldsymbol{u}_m^\mathsf{T}$ (las observaciones que queremos clasificar), y $M \in \mathbb{R}^{C\times p}$, con las medias de las clases en las filas. Sea $\Delta \in \mathbb{R}^{m\times C}$ la matriz con $\Delta_{ik} = \|\boldsymbol{u}_i - \bar{\boldsymbol{x}}_k\|^2$.

(a) Probar que $\Delta = \boldsymbol{a}\,\mathbf{1}_C^\mathsf{T} - 2X_{\text{nueva}}M^\mathsf{T} + \mathbf{1}_m\,c^\mathsf{T}$, donde $a_i = \|\boldsymbol{u}_i\|^2$, $c_k = \|\bar{\boldsymbol{x}}_k\|^2$, y $\mathbf{1}_C$, $\mathbf{1}_m$ son vectores de unos.

(b) Deducir que la clase asignada a $\boldsymbol{u}_i$ es el k que hace máximo $\bar{\boldsymbol{x}}_k^\mathsf{T}\boldsymbol{u}_i - \frac{1}{2}\|\bar{\boldsymbol{x}}_k\|^2$, que es una función lineal de $\boldsymbol{u}_i$ más una constante.

10.4 [Cálculo] **La matriz de confusión.**

(a) Diez observaciones de prueba tienen las clases verdaderas y, y el clasificador les asigna las clases $\hat{y}$:

$$y = (1,1,1,2,2,2,3,3,3,3), \qquad \hat{y} = (1,1,2,2,2,3,3,3,1,3).$$

Calcular la matriz de confusión, la proporción de aciertos y la proporción de aciertos dentro de cada clase.

(b) Si G y $\widehat{G}$ son las matrices indicadoras de las clases verdaderas y de las asignadas, probar que $K = G^\mathsf{T}\widehat{G}$, que la suma de la fila j de K es la cantidad de observaciones de la clase j, y que el clasificador acierta todo si y solo si K es diagonal.

10.5 [Concepto] **¿Qué cosas no cambian la clase asignada?** A todos los datos, los de entrenamiento y los nuevos, se les aplica la misma transformación. ¿Cambia la clase que asigna la regla de la media más cercana si la transformación es una traslación $\boldsymbol{x} \mapsto \boldsymbol{x} + c$? ¿Y si es $\boldsymbol{x} \mapsto Q\boldsymbol{x}$, con Q ortogonal? ¿Y si se multiplica una sola de las variables por 10? Dar un ejemplo en $\mathbb{R}^2$, con dos clases de dos puntos cada una, en el que estandarizar cambie la clase asignada a un punto nuevo.

10.6 [Concepto] **Cuando la matriz centrada no tiene rango completo.** Sea X_c la matriz de entrenamiento centrada, de rango $r < p$ (por ejemplo, porque hay más variables que datos); sean $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r$ sus primeros r vectores singulares derechos, $V_r = [\boldsymbol{v}_1 \cdots \boldsymbol{v}_r]$ y $P = V_r V_r^\mathsf{T}$.

(a) Probar que cada $\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}}$ es combinación lineal de las filas de X_c, y que por lo tanto está en $\operatorname{span}(\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r)$.

(b) Probar que $(I - P)(\boldsymbol{x} - \bar{\boldsymbol{x}}_k) = (I - P)(\boldsymbol{x} - \bar{\boldsymbol{x}})$, que no depende de k, y deducir que $\|\boldsymbol{x} - \bar{\boldsymbol{x}}_k\|^2 = \|V_r^\mathsf{T}(\boldsymbol{x} - \bar{\boldsymbol{x}}_k)\|^2 + \|(I - P)(\boldsymbol{x} - \bar{\boldsymbol{x}})\|^2$.

(c) Concluir que la regla de la media más cercana con los r scores asigna las mismas clases que en $\mathbb{R}^p$.

(d) Truncar sí puede cambiar las cosas: mostrar con los ocho puntos del Ejemplo 10.1 (donde $r = p = 2$) que con $d = 1$ cambian algunas de las clases asignadas (comparar con el Ejemplo 10.10).

10.7 [Cálculo] **Máxima varianza no es máxima separación.** La clase 1 son los puntos $(-3, 0)$, $(-1, 0)$, $(1, 0)$, $(3, 0)$ y la clase 2 son $(-3, 1)$, $(-1, 1)$, $(1, 1)$, $(3, 1)$.

(a) Centrar los ocho puntos, calcular la matriz de covarianza, $\boldsymbol{v}_1$ y PVE(1), y proyectar las dos clases sobre $\boldsymbol{v}_1$. ¿Se distinguen? ¿Sobre qué dirección sí se distinguen, y cuánto vale la varianza de los datos en esa dirección?

(b) Clasificar los ocho puntos con la media más cercana en $\mathbb{R}^2$. Después reducir a $d = 1$ con PCA: ¿qué les pasa a las medias de las dos clases en la recta? ¿Se pueden clasificar los puntos?

(c) Explicar por qué maximizar la varianza no garantiza separar las clases: ¿qué información no usa PCA?

10.8 [Datos] **¿Conviene estandarizar los píxeles?** En los dígitos, comparar los aciertos de la media más cercana y de PCA + media más cercana, con y sin estandarizar. ¿Qué pasa con los píxeles que valen siempre 0 en el entrenamiento? ¿Por qué estandarizar puede empeorar las cosas en imágenes?

10.9 [Datos] **¿Cuánto depende de la separación?** Repetir 20 veces la separación 70/30, con las semillas $0, 1, \ldots, 19$, y calcular cada vez los aciertos en prueba de la media más cercana. Hacerlo con los tumores de mama (estandarizados) y con el cáncer de pulmón (cuyas variables ya están todas en la misma escala), y comparar los veinte resultados de cada uno (mínimo, máximo, histograma). ¿Por qué varían tanto más con el cáncer de pulmón?

10.10 [Datos] **Los dígitos promedio.** Con los dígitos de entrenamiento, calcular las diez medias y dibujarlas como imágenes de 8×8 (Figura 10.1). Clasificar los dígitos de prueba con la media más cercana, mirar la matriz de confusión y dibujar algunos dígitos mal clasificados al lado de la media de su clase y de la media de la clase que se les asignó. ¿Qué dígitos se confunden más? ¿Se entiende por qué?

Práctica: clasificar con PCA

Los datos de la práctica son los cuatro conjuntos de la Sección 10.1: tumores de mama, dígitos, cáncer de pulmón y siluetas de vehículos (son los de la notebook `Datos_PCA.ipynb` de la cátedra, pero acá se cargan con un archivo de Python). Cada grupo trabaja con el conjunto que se le asigne. El objetivo es investigar si es posible predecir la clase a partir de las variables, y qué se gana y qué se pierde al reducir la dimensión con PCA. El informe se entrega en una notebook de Colab con el código, los gráficos (con ejes y títulos) y las respuestas a cada punto, escritas en celdas de texto. Junto con la notebook se distribuyen dos archivos de Python: `datos_clasificacion.py`, que carga los cuatro conjuntos ya limpios, y `herramientas_clasificacion.py`, con funciones auxiliares; para usarlos en Colab basta subirlos y hacer `import`.

P.1 Investigación preliminar. Busque información sobre su conjunto de datos y conteste: ¿en qué consisten los datos? ¿Cuál es el objetivo de la clasificación? ¿Cuántos predictores hay? Describa las variables (si hay información sobre ellas). Notación: $X \in \mathbb{R}^{n \times p}$ es la matriz cuyas filas son los individuos y cuyas columnas son las características medidas, e y es el vector con la clase de cada individuo.

P.2 Cargar y describir. Cargue los datos con

```
X, y, variables, clases = cargar("mama")
```

(o `"digitos"`, `"pulmon"`, `"vehiculos"`). Informe n, p, C y cuántos individuos hay en cada clase. ¿Había datos faltantes en el archivo original? (Lea la descripción de `cargar` en `datos_clasificacion.py`.) ¿Las variables están en escalas parecidas? (Mire los desvíos de las columnas.)

P.3 Gráficos exploratorios. Elija pares de variables (pares de columnas de X) y haga gráficos de dispersión con los puntos coloreados según la clase. Etiquete los ejes.

P.4 PCA. Centre los datos (y estandarícelos si las escalas son muy distintas; justifique) y calcule PCA con la SVD.

- Grafique los valores singulares y PVE(d).
- Grafique PC1 contra PC2 con los puntos coloreados por clase y los ejes etiquetados.
- Mire las entradas de $\boldsymbol{v}_1$ y $\boldsymbol{v}_2$: ¿qué variables pesan más?
- ¿Qué gráfico permite ver mejor las clases, los pares de variables o las componentes principales? ¿Por qué?

P.5 Entrenamiento y prueba. Lea la receta de la Sección 10.4. Separe los datos en entrenamiento (70%) y prueba (30%), de manera estratificada y con una semilla fija (`separar(X, y)`). De acá en adelante, todo lo que se calcule (medias, desvíos, V_d, medias de las clases) se calcula con el entrenamiento. Con el cáncer de pulmón, repita además todo con otras semillas (Observación 10.8).

P.6 La media más cercana. Calcule los aciertos en entrenamiento y en prueba de la regla de la media más cercana en $\mathbb{R}^p$, con y sin estandarizar, y la matriz de confusión en prueba. ¿Qué clases se confunden más?

P.7 PCA + media más cercana. Para $d = 1, 2, \ldots$ (hasta el rango de la matriz centrada de entrenamiento, o hasta 40), reduzca a d componentes y clasifique con la media más cercana en $\mathbb{R}^d$. Grafique los aciertos en prueba junto con PVE(d). ¿Con cuántas componentes conviene quedarse? (Elegir d mirando los datos de prueba es hacer un poco de trampa, porque la prueba debería usarse una sola vez; acá lo aceptamos por simplicidad.) Verifique que con todas las componentes se obtiene lo mismo que en $\mathbb{R}^p$ (Proposición 10.9 y Ejercicio 10.6).

P.8 Conclusiones. ¿Qué usaría para clasificar sus datos, y con cuántas componentes? ¿Es cierto que "explicar más varianza" significa "clasificar mejor"? ¿Qué información no usa PCA?

Los archivos de Python

- `datos_clasificacion.py`: `cargar(nombre)` devuelve `X, y, variables, clases` para `"mama"`, `"digitos"`, `"pulmon"` y `"vehiculos"` (las etiquetas y son enteros $0, \ldots, C-1$). Arregla la lectura del cáncer de pulmón (el archivo está separado por comas, la clase es la *primera* columna y hay cinco datos faltantes, marcados con `?`, que se reemplazan por la mediana de su columna). Incluye `separar(X, y, prop_prueba=0.3, semilla=0)`, una separación estratificada.
- `herramientas_clasificacion.py`: `estandarizar`, `columnas_no_constantes`, `pca_svd`, `scores` (proyecta datos nuevos con la media y la V_d del entrenamiento), `medias` (las medias de las clases, una por fila), `clasificar_media` (la regla de la media más cercana), `matriz_confusion`, `aciertos` y dos funciones de gráficos. (El archivo trae también las funciones que se usan en el Capítulo 11.)

11 CAPÍTULO

Análisis discriminante lineal (LDA)

11.1 Introducción

En el capítulo anterior clasificamos con la regla más simple: resumir cada clase con su media y asignar una observación nueva a la clase cuya media está más cerca. En los ocho puntos de ese capítulo la regla acierta 6 de los 8 puntos, aunque las dos clases se pueden separar perfectamente con una recta inclinada; y PCA no ayuda, porque la dirección de máxima varianza mezcla las clases. Las dos cosas fallan por lo mismo: miran las medias, o la nube entera, pero no la *forma* de cada clase.

La idea de Fisher [4], de 1936, es buscar directamente la dirección en la que *las medias de las clases proyectadas quedan lo más separadas posible en relación con lo que se desparrama cada clase proyectada.* Con esa dirección se clasifica como antes: se proyecta y se usa la media más cercana. El método se llama **análisis discriminante lineal** (LDA, por su nombre en inglés, *linear discriminant analysis*).

Lo que más nos interesa es la matemática que hay detrás. Escrito con matrices, el problema de Fisher es maximizar un cociente de dos formas cuadráticas, $\boldsymbol{w}^\mathsf{T} A \boldsymbol{w} / \boldsymbol{w}^\mathsf{T} B \boldsymbol{w}$: un **cociente de Rayleigh generalizado** (Sección I.10 de [14]). No usamos teoría estadística (en estadística, LDA se deduce de un modelo probabilístico para las clases; acá no nos hace falta). El plan:

1. con dos clases, el cociente de Fisher, escrito con matrices (Sección 11.2);
2. el teorema general: el cociente de Rayleigh generalizado (Sección 11.3);
3. la dirección de Fisher, como caso particular de ese teorema (Sección 11.4), y cómo se clasifica con ella (Sección 11.5);
4. más de dos clases, que es aplicar el mismo teorema, y una comparación con PCA (Sección 11.6);
5. otra aplicación del mismo teorema: diagonalizar dos formas cuadráticas a la vez (Sección 11.7).

11.2 Dos clases: el cociente de Fisher

Usamos la notación del capítulo anterior: $X \in \mathbb{R}^{n \times p}$ tiene las observaciones $\boldsymbol{x}_1^\mathsf{T}, \ldots, \boldsymbol{x}_n^\mathsf{T}$ en las filas, $y_i \in \{1, \ldots, C\}$ es la clase de la observación i, la clase k tiene n_k observaciones y media $\bar{\boldsymbol{x}}_k$, y $\bar{\boldsymbol{x}}$ es la media de todos los datos. En las Secciones 11.2 a 11.5 hay dos clases ($C = 2$); la Sección 11.3 es la herramienta general.

Proyectar sobre una dirección. Dado un vector $\boldsymbol{w} \neq 0$, cada observación $\boldsymbol{x}$ se resume con un número, $\boldsymbol{w}^\mathsf{T}\boldsymbol{x}$ (si $\|\boldsymbol{w}\| = 1$, es la coordenada de la proyección de $\boldsymbol{x}$ sobre la recta $\operatorname{span}(\boldsymbol{w})$, como un score de PCA). La media de los números $\boldsymbol{w}^\mathsf{T}\boldsymbol{x}_i$ de la clase k es el número de la media: $\frac{1}{n_k}\sum_{i:\, y_i=k} \boldsymbol{w}^\mathsf{T}\boldsymbol{x}_i = \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k$. Para que las clases queden separadas en la recta nos interesan dos cosas:

- que las **medias proyectadas** queden lejos, es decir, que $(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_1 - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_2)^2$ sea grande;
- que cada **clase proyectada** se desparrame poco alrededor de su media proyectada, es decir, que

$$\sum_{k=1}^{2} \sum_{i:\, y_i=k} \left(\boldsymbol{w}^\mathsf{T}\boldsymbol{x}_i - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\right)^2$$

  sea chica.

Las dos cantidades, con matrices. Las dos son *formas cuadráticas* en $\boldsymbol{w}$, es decir, de la forma $\boldsymbol{w}^\mathsf{T}M\boldsymbol{w}$ con M simétrica.

Las medias proyectadas. Sea $\boldsymbol{a} = \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2 \in \mathbb{R}^p$. Entonces $\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_1 - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_2 = \boldsymbol{w}^\mathsf{T}\boldsymbol{a}$ es un número (una matriz de $1 \times p$ por una de $p \times 1$), igual a su transpuesto $\boldsymbol{a}^\mathsf{T}\boldsymbol{w}$, y

$$(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_1 - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_2)^2 = (\boldsymbol{w}^\mathsf{T}\boldsymbol{a})(\boldsymbol{a}^\mathsf{T}\boldsymbol{w}) = \boldsymbol{w}^\mathsf{T}\left(\boldsymbol{a}\boldsymbol{a}^\mathsf{T}\right)\boldsymbol{w}.$$

La matriz $\boldsymbol{a}\boldsymbol{a}^\mathsf{T} \in \mathbb{R}^{p\times p}$ es simétrica, de rango uno y semidefinida positiva.

Las clases proyectadas. Sea $\tilde{X} \in \mathbb{R}^{n\times p}$ la matriz cuya fila i es $(\boldsymbol{x}_i - \bar{\boldsymbol{x}}_{y_i})^\mathsf{T}$: cada observación menos la media de su clase. Entonces

$$\tilde{X}\boldsymbol{w} = \begin{pmatrix} (\boldsymbol{x}_1 - \bar{\boldsymbol{x}}_{y_1})^\mathsf{T} \\ \vdots \\ (\boldsymbol{x}_n - \bar{\boldsymbol{x}}_{y_n})^\mathsf{T} \end{pmatrix} \boldsymbol{w} = \begin{pmatrix} \boldsymbol{w}^\mathsf{T}\boldsymbol{x}_1 - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_{y_1} \\ \vdots \\ \boldsymbol{w}^\mathsf{T}\boldsymbol{x}_n - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_{y_n} \end{pmatrix} \in \mathbb{R}^n$$

tiene en la entrada i cuánto se aleja la observación i proyectada de la media proyectada de su clase, y la suma de arriba es la suma de los cuadrados de esas entradas:

$$\sum_{k=1}^{2} \sum_{i:\, y_i=k} \left(\boldsymbol{w}^\mathsf{T}\boldsymbol{x}_i - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\right)^2 = \|\tilde{X}\boldsymbol{w}\|^2 = (\tilde{X}\boldsymbol{w})^\mathsf{T}(\tilde{X}\boldsymbol{w}) = \boldsymbol{w}^\mathsf{T}\left(\tilde{X}^\mathsf{T}\tilde{X}\right)\boldsymbol{w}.$$

Definición 11.1 (Dispersión dentro de las clases). La **matriz de dispersión dentro de las clases** es

$$S = \tilde{X}^\mathsf{T}\tilde{X} = \sum_{k} \sum_{i:\, y_i=k} (\boldsymbol{x}_i - \bar{\boldsymbol{x}}_k)(\boldsymbol{x}_i - \bar{\boldsymbol{x}}_k)^\mathsf{T} \in \mathbb{R}^{p\times p}.$$

Es simétrica y semidefinida positiva, porque $\boldsymbol{w}^\mathsf{T}S\boldsymbol{w} = \|\tilde{X}\boldsymbol{w}\|^2 \geq 0$.

Observación 11.2 (¿Cuándo es invertible?). Si $S\boldsymbol{w} = 0$, entonces $\|\tilde{X}\boldsymbol{w}\|^2 = \boldsymbol{w}^\mathsf{T}S\boldsymbol{w} = 0$, es decir, $\tilde{X}\boldsymbol{w} = 0$; y al revés, si $\tilde{X}\boldsymbol{w} = 0$, entonces $S\boldsymbol{w} = \tilde{X}^\mathsf{T}\tilde{X}\boldsymbol{w} = 0$. Así que S es invertible si y solo si $\tilde{X}$ tiene rango p, y en ese caso es *definida positiva*: $\boldsymbol{w}^\mathsf{T}S\boldsymbol{w} > 0$ para todo $\boldsymbol{w} \neq 0$. Como las filas de $\tilde{X}$ de cada clase suman cero, $\operatorname{rango}(\tilde{X}) \leq n - C$ (Ejercicio 11.7): si hay más variables que datos, S no es invertible. En todo el capítulo suponemos que S es invertible.

Definición 11.3 (Cociente de Fisher). Si S es invertible, para $\boldsymbol{w} \neq 0$ el **cociente de Fisher** es

$$J(\boldsymbol{w}) = \frac{(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_1 - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_2)^2}{\sum_{k=1}^{2} \sum_{i:\ y_i=k} \left(\boldsymbol{w}^\mathsf{T}\boldsymbol{x}_i - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\right)^2} = \frac{\boldsymbol{w}^\mathsf{T}(\boldsymbol{a}\boldsymbol{a}^\mathsf{T})\boldsymbol{w}}{\boldsymbol{w}^\mathsf{T} S \boldsymbol{w}}, \qquad \boldsymbol{a} = \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2.$$

Queremos el numerador grande (las medias proyectadas lejos) y el denominador chico (cada clase proyectada compacta): $J(\boldsymbol{w})$ mide la separación de las medias proyectadas *en relación con* la dispersión de las clases proyectadas. Como numerador y denominador quedan multiplicados por c^2 al cambiar $\boldsymbol{w}$ por $c\boldsymbol{w}$, $J(c\boldsymbol{w}) = J(\boldsymbol{w})$ para todo $c \neq 0$: solo importa la dirección. Y escrito así, J es un cociente de dos formas cuadráticas, con la matriz $\boldsymbol{a}\boldsymbol{a}^\mathsf{T}$ arriba y la matriz S abajo: es el problema de la próxima sección.

Ejemplo 11.4 (Los ocho puntos). En los ocho puntos del capítulo anterior, la clase 1 es $(2,3)$, $(1,3)$, $(-1,-3)$, $(-2,-3)$, con media $\bar{\boldsymbol{x}}_1 = (0,0)$, y la clase 2 es la clase 1 trasladada en $(3,0)$, con media $\bar{\boldsymbol{x}}_2 = (3,0)$. Entonces

$$\boldsymbol{a} = \begin{pmatrix} -3 \\ 0 \end{pmatrix}, \qquad \boldsymbol{a}\boldsymbol{a}^\mathsf{T} = \begin{pmatrix} 9 & 0 \\ 0 & 0 \end{pmatrix}.$$

Restando a cada punto la media de su clase quedan, en las dos clases, los mismos cuatro vectores $(2,3)$, $(1,3)$, $(-1,-3)$, $(-2,-3)$, así que

$$\tilde{X} = \begin{pmatrix} 2 & 1 & -1 & -2 & 2 & 1 & -1 & -2 \\ 3 & 3 & -3 & -3 & 3 & 3 & -3 & -3 \end{pmatrix}^\mathsf{T}, \qquad S = \tilde{X}^\mathsf{T}\tilde{X} = \begin{pmatrix} 20 & 36 \\ 36 & 72 \end{pmatrix}.$$

Comparemos algunas direcciones:

- $\boldsymbol{e}_1 = (1,0)$, la dirección de la recta que une las medias, que es la que usa la regla de la media más cercana: $J(\boldsymbol{e}_1) = 9/20 = 0{,}45$;
- $\boldsymbol{v}_1 \approx (0{,}535;\ 0{,}845)$, la primera dirección principal: $J(\boldsymbol{v}_1) \approx 2{,}58/89{,}7 \approx 0{,}029$;
- $\boldsymbol{v}_2 \approx (0{,}845;\ -0{,}535)$, la segunda dirección principal, que en el capítulo anterior separaba las clases: $J(\boldsymbol{v}_2) \approx 6{,}42/2{,}34 \approx 2{,}74$.

¿Hay una dirección mejor que $\boldsymbol{v}_2$? Sí: en la Sección 11.4 vemos que el máximo de J es 4,5.

11.3 El cociente de Rayleigh generalizado

Sean $A, B \in \mathbb{R}^{p\times p}$ simétricas, con B *definida positiva*. El **cociente de Rayleigh generalizado** es

$$R(\boldsymbol{w}) = \frac{\boldsymbol{w}^\mathsf{T} A \boldsymbol{w}}{\boldsymbol{w}^\mathsf{T} B \boldsymbol{w}} \qquad (\boldsymbol{w} \neq 0).$$

Queremos su máximo y su mínimo, y dónde se alcanzan. Maximizar J es el caso $A = \boldsymbol{a}\boldsymbol{a}^\mathsf{T}$, $B = S$. Con $B = I$ es el cociente de Rayleigh del Teorema 6.13: su máximo es el mayor autovalor de A, y se alcanza en un autovector. Con B general, el papel de los autovalores y de los autovectores lo juegan los **autovalores** y los **autovectores generalizados** de (A, B): los λ y los $\boldsymbol{w} \neq 0$ tales que

$$A\boldsymbol{w} = \lambda B \boldsymbol{w}.$$

Como $A\boldsymbol{w} = \lambda B\boldsymbol{w}$ es lo mismo que $(A - \lambda B)\boldsymbol{w} = 0$, los autovalores generalizados son las raíces de $\det(A - \lambda B) = 0$.

Teorema 11.5 (Cociente de Rayleigh generalizado). Sean A simétrica y B simétrica definida positiva.

(a) Los autovalores generalizados de (A, B) son reales, $\lambda_1 \geq \cdots \geq \lambda_p$, y hay una base $\boldsymbol{w}_1, \ldots, \boldsymbol{w}_p$ de $\mathbb{R}^p$ formada por autovectores generalizados ($A\boldsymbol{w}_k = \lambda_k B\boldsymbol{w}_k$) que cumplen

$$\boldsymbol{w}_j^{\mathsf{T}} B \boldsymbol{w}_k = \delta_{jk} = \begin{cases} 1 & \text{si } j = k, \\ 0 & \text{si } j \neq k. \end{cases}$$

(b) Para todo $\boldsymbol{w} \neq 0$,

$$\lambda_p \;\leq\; \frac{\boldsymbol{w}^{\mathsf{T}} A \boldsymbol{w}}{\boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w}} \;\leq\; \lambda_1;$$

el máximo se alcanza en $\boldsymbol{w}_1$ y el mínimo en $\boldsymbol{w}_p$.

(c) Más en general, para cada k,

$$\max\left\{ \frac{\boldsymbol{w}^{\mathsf{T}} A \boldsymbol{w}}{\boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w}} : \; \boldsymbol{w} \neq 0, \; \boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w}_j = 0 \; (j < k) \right\} = \lambda_k, \qquad \text{alcanzado en } \boldsymbol{w} = \boldsymbol{w}_k.$$

Por (a), los autovectores generalizados $\boldsymbol{w}_1, \ldots, \boldsymbol{w}_p$ son **B-ortogonales** ($\boldsymbol{w}_j^{\mathsf{T}} B \boldsymbol{w}_k = 0$ si $j \neq k$), aunque en general no son ortogonales. Así se traduce la ortogonalidad de los autovectores de una matriz simétrica, que es el caso $B = I$. Y, como en ese caso, dos autovectores generalizados de autovalores distintos son siempre B-ortogonales; se ve directamente, con la misma cuenta que para una matriz simétrica (Ejercicio 11.4).

La idea de la demostración. Cambiar $\boldsymbol{w}$ por una variable y en la que el denominador sea $y^{\mathsf{T}} y$: así queda el cociente de Rayleigh de siempre, de una matriz simétrica, que ya sabemos resolver. Para eso hace falta la raíz cuadrada de B.

La raíz cuadrada de una matriz definida positiva. Si $B = Q\Lambda Q^{\mathsf{T}}$ con $\Lambda = \operatorname{diag}(\beta_1, \ldots, \beta_p)$, $\beta_i > 0$ (teorema espectral), definimos

$$B^{1/2} = Q\Lambda^{1/2}Q^{\mathsf{T}}, \qquad B^{-1/2} = Q\Lambda^{-1/2}Q^{\mathsf{T}},$$

con $\Lambda^{1/2} = \operatorname{diag}(\sqrt{\beta_1}, \ldots, \sqrt{\beta_p})$ y $\Lambda^{-1/2} = \operatorname{diag}(1/\sqrt{\beta_1}, \ldots, 1/\sqrt{\beta_p})$. Las dos son simétricas definidas positivas, $(B^{1/2})^2 = B$ y $B^{-1/2} = (B^{1/2})^{-1}$; en particular, $B^{-1/2} B B^{-1/2} = I$.

Demostración del Teorema 11.5. Sean $H = B^{-1/2} A B^{-1/2}$, que es simétrica, e $y = B^{1/2}\boldsymbol{w}$, es decir, $\boldsymbol{w} = B^{-1/2} y$. Entonces $\boldsymbol{w}^{\mathsf{T}} A \boldsymbol{w} = y^{\mathsf{T}} B^{-1/2} A B^{-1/2} y = y^{\mathsf{T}} H y$ y $\boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w} = y^{\mathsf{T}} B^{-1/2} B B^{-1/2} y = y^{\mathsf{T}} y$, así que

$$R(\boldsymbol{w}) = \frac{\boldsymbol{w}^{\mathsf{T}} A \boldsymbol{w}}{\boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w}} = \frac{y^{\mathsf{T}} H y}{y^{\mathsf{T}} y} :$$

el cociente generalizado en $\boldsymbol{w}$ es el cociente de Rayleigh usual de H en y. Además, multiplicando $A\boldsymbol{w} = \lambda B\boldsymbol{w}$ a izquierda por $B^{-1/2}$ y escribiendo $\boldsymbol{w} = B^{-1/2} y$ queda $Hy = \lambda y$, y los pasos son reversibles: $A\boldsymbol{w} = \lambda B\boldsymbol{w}$ si y solo si $Hy = \lambda y$.

(a) Por el teorema espectral, H tiene autovalores reales $\lambda_1 \geq \cdots \geq \lambda_p$ y una base ortonormal de autovectores $y_1, \ldots, y_p$. Por lo anterior, los λ_k son los autovalores generalizados (también con las multiplicidades, porque $\det(A - \lambda B) = \det\big(B^{1/2}(H - \lambda I)B^{1/2}\big) = \det(B)\det(H - \lambda I)$), y los $\boldsymbol{w}_k = B^{-1/2}y_k$ son autovectores generalizados. Forman una base porque $B^{-1/2}$ es invertible, y $\boldsymbol{w}_j^{\mathsf{T}} B \boldsymbol{w}_k = y_j^{\mathsf{T}} B^{-1/2} B B^{-1/2} y_k = y_j^{\mathsf{T}} y_k = \delta_{jk}$.

(b) y (c) Cuando $\boldsymbol{w}$ recorre los vectores no nulos, $y = B^{1/2}\boldsymbol{w}$ también, y la restricción $\boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w}_j = 0$ es $y^{\mathsf{T}} y_j = 0$. Entonces (b) y (c) son los Teorema 6.13 y el Corolario 6.19 aplicados a la matriz simétrica H, cuyos autovalores son los λ_k y cuyos autovectores son los y_k: el máximo de $y^{\mathsf{T}} H y / y^{\mathsf{T}} y$ se alcanza en y_1, es decir, en $\boldsymbol{w}_1 = B^{-1/2} y_1$, y así siguiendo. ∎

Es decir, *el denominador se absorbe con un cambio de variable*: maximizar el cociente generalizado es lo mismo que maximizar el cociente de Rayleigh usual de la matriz simétrica $H = B^{-1/2} A B^{-1/2}$.

Ejemplo 11.6 (Strang, Sección I.10). Sean $A = \left(\begin{smallmatrix} 4 & -2 \\ -2 & 4 \end{smallmatrix}\right)$ y $B = \left(\begin{smallmatrix} 1 & 0 \\ 0 & 2 \end{smallmatrix}\right)$. Entonces

$$\det(A - \lambda B) = (4 - \lambda)(4 - 2\lambda) - 4 = 2\lambda^2 - 12\lambda + 12,$$

con raíces $\lambda = 3 \pm \sqrt{3}$. Con $B^{-1/2} = \operatorname{diag}(1, 1/\sqrt{2})$ queda

$$H = B^{-1/2} A B^{-1/2} = \begin{pmatrix} 4 & -\sqrt{2} \\ -\sqrt{2} & 2 \end{pmatrix},$$

cuyo polinomio característico es $\lambda^2 - 6\lambda + 6$, la mitad del anterior: mismos autovalores. Los autovectores generalizados son $\boldsymbol{w}_1 = (2,\, 1 - \sqrt{3})$ para $\lambda_1 = 3 + \sqrt{3}$ y $\boldsymbol{w}_2 = (2,\, 1 + \sqrt{3})$ para $\lambda_2 = 3 - \sqrt{3}$ (verificarlo). No son ortogonales, $\boldsymbol{w}_1^{\mathsf{T}} \boldsymbol{w}_2 = 4 + (1 - 3) = 2$, pero sí B-ortogonales: $\boldsymbol{w}_1^{\mathsf{T}} B \boldsymbol{w}_2 = 4 + 2(1 - \sqrt{3})(1 + \sqrt{3}) = 4 - 4 = 0$. El máximo de $\boldsymbol{w}^{\mathsf{T}} A \boldsymbol{w} / \boldsymbol{w}^{\mathsf{T}} B \boldsymbol{w}$ es $3 + \sqrt{3} \approx 4{,}73$, mientras que el mayor autovalor de A es 6: el denominador cambia todo.

Observación 11.7 (En la computadora). Como dice Strang, $B^{1/2}$ y $B^{-1/2}$ son herramientas para *pensar*, no para calcular. Los programas resuelven $A\boldsymbol{w} = \lambda B \boldsymbol{w}$ directamente (`scipy.linalg.eigh(A, B)` en Python, `eig(A, B)` en Matlab), con la factorización de Cholesky de B [5, Sección 8.7]. `eigh` devuelve los $\boldsymbol{w}_k$ normalizados como en el Teorema 11.5(a), $\boldsymbol{w}_j^{\mathsf{T}} B \boldsymbol{w}_k = \delta_{jk}$, y los autovalores en orden *creciente*: $\boldsymbol{w}_1$ es la última columna.

11.4 La dirección de Fisher, un caso particular

Con dos clases, J es el cociente de Rayleigh generalizado con $A = \boldsymbol{a}\boldsymbol{a}^{\mathsf{T}}$ y $B = S$, así que, por el Teorema 11.5, su máximo es el mayor autovalor generalizado de $(\boldsymbol{a}\boldsymbol{a}^{\mathsf{T}}, S)$. Como $\boldsymbol{a}\boldsymbol{a}^{\mathsf{T}}$ tiene rango uno, los autovalores se calculan a mano.

Corolario 11.8 (Dirección de Fisher). Sean S invertible y $\boldsymbol{a} = \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2 \neq 0$. El único autovalor generalizado no nulo de $(\boldsymbol{a}\boldsymbol{a}^{\mathsf{T}}, S)$ es $\lambda_1 = \boldsymbol{a}^{\mathsf{T}} S^{-1} \boldsymbol{a} > 0$, con autovector $S^{-1}\boldsymbol{a}$. Por lo tanto, para todo $\boldsymbol{w} \neq 0$,

$$J(\boldsymbol{w}) \;\leq\; \boldsymbol{a}^{\mathsf{T}} S^{-1} \boldsymbol{a},$$

y el máximo se alcanza en la **dirección de Fisher**

$$\boldsymbol{w}^* = S^{-1}(\bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2) \,.$$

Demostración. Como en la demostración del Teorema 11.5, sea $H = S^{-1/2}\,\boldsymbol{a}\boldsymbol{a}^\mathsf{T} S^{-1/2}$. Con $h = S^{-1/2}\boldsymbol{a}$, que no es cero porque $\boldsymbol{a} \neq 0$ y $S^{-1/2}$ es invertible, y como $S^{-1/2}$ es simétrica, $H = hh^\mathsf{T}$, que tiene rango uno: $Hh = h\,(h^\mathsf{T}h) = \|h\|^2 h$ y $H\boldsymbol{u} = h\,(h^\mathsf{T}\boldsymbol{u}) = 0$ para todo $\boldsymbol{u} \perp h$. Como h y una base de los vectores ortogonales a h forman una base de $\mathbb{R}^p$, los autovalores de H son

$$\lambda_1 = \|h\|^2 = \boldsymbol{a}^\mathsf{T} S^{-1/2} S^{-1/2} \boldsymbol{a} = \boldsymbol{a}^\mathsf{T} S^{-1} \boldsymbol{a} > 0 \qquad \text{y} \qquad \lambda_2 = \cdots = \lambda_p = 0.$$

El autovector de λ_1 es $y_1 = h/\|h\|$, y el autovector generalizado correspondiente es $\boldsymbol{w}_1 = S^{-1/2} y_1 = S^{-1}\boldsymbol{a}/\|h\|$, un múltiplo de $\boldsymbol{w}^*$. Por el Teorema 11.5, el máximo de J es λ_1 y se alcanza en $\boldsymbol{w}_1$, y entonces también en $\boldsymbol{w}^*$, porque $J(c\boldsymbol{w}) = J(\boldsymbol{w})$. ■

Así, la dirección de Fisher no necesita una demostración aparte: es el teorema general con una matriz A de rango uno. (En el Ejercicio 11.5 hay una demostración directa, sin autovalores, con la desigualdad de Cauchy–Schwarz; con ella se ve, además, que el máximo se alcanza *solo* en los múltiplos de $\boldsymbol{w}^*$.)

Ejemplo 11.9 (La dirección de Fisher en los ocho puntos). Con la matriz S del Ejemplo 11.4, $\det S = 20 \cdot 72 - 36^2 = 144$ y

$$S^{-1} = \frac{1}{144}\begin{pmatrix} 72 & -36 \\ -36 & 20 \end{pmatrix}, \qquad \boldsymbol{w}^* = S^{-1}\begin{pmatrix} -3 \\ 0 \end{pmatrix} = \frac{1}{144}\begin{pmatrix} -216 \\ 108 \end{pmatrix} = \frac{3}{4}\begin{pmatrix} -2 \\ 1 \end{pmatrix}.$$

Como solo importa la dirección, tomamos $\boldsymbol{w} = (2, -1)$. El máximo de J es $\boldsymbol{a}^\mathsf{T} S^{-1}\boldsymbol{a} = 9 \cdot 72/144 = 4{,}5$, bastante más que $J(\boldsymbol{v}_2) \approx 2{,}74$. Proyectando, los cuatro puntos de la clase 1 dan $2\boldsymbol{x}_1 - \boldsymbol{x}_2 = 1;\ -1;\ 1;\ -1$, y los de la clase 2 dan 7; 5; 7; 5: sobre esta dirección las clases quedan perfectamente separadas (Figura 11.1).

11.5 Clasificar con LDA

Con la dirección de Fisher, cada observación se resume con un número, y se clasifica con la regla del capítulo anterior, ahora en la recta.

Definición 11.10 (Regla de LDA con dos clases). Sea $\boldsymbol{w}$ un múltiplo no nulo de $\boldsymbol{w}^* = S^{-1}(\bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2)$. Una observación $\boldsymbol{x}$ se asigna a la clase cuya media proyectada está más cerca de $\boldsymbol{w}^\mathsf{T}\boldsymbol{x}$:

$$f(\boldsymbol{x}) = \operatorname*{argmin}_{k=1,2} \left|\boldsymbol{w}^\mathsf{T}\boldsymbol{x} - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\right|.$$

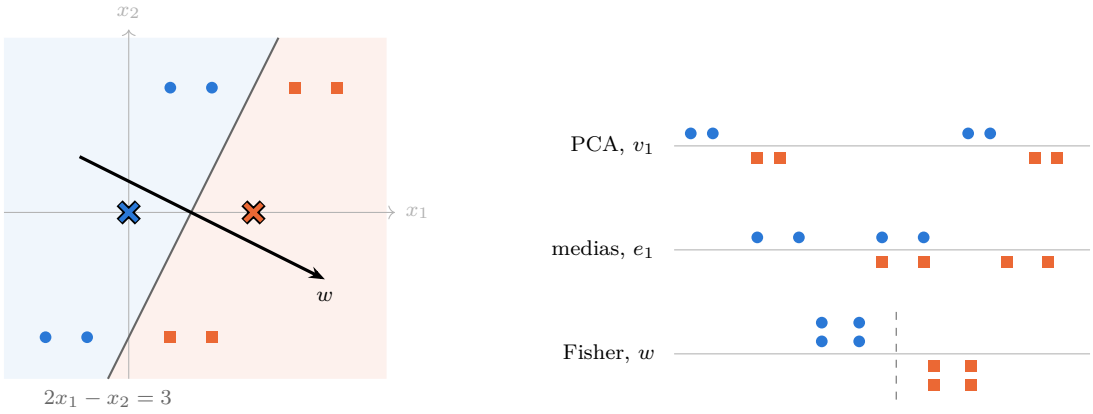
En la recta, la frontera es el punto medio de las dos medias proyectadas,

$$c = \tfrac{1}{2}\left(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_1 + \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_2\right) :$$

la regla asigna cada observación según de qué lado de c cae $\boldsymbol{w}^\mathsf{T}\boldsymbol{x}$. En $\mathbb{R}^p$, entonces, la frontera entre las dos clases es el hiperplano $\{\boldsymbol{x} :\ \boldsymbol{w}^\mathsf{T}\boldsymbol{x} = c\}$, perpendicular a $\boldsymbol{w}$, que pasa

por el punto medio $m = \frac{1}{2}(\bar{\boldsymbol{x}}_1 + \bar{\boldsymbol{x}}_2)$ de las medias, porque $\boldsymbol{w}^\mathsf{T} m = c$. Como en el capítulo anterior, es un *clasificador lineal*, pero la frontera ya no es la mediatriz de las medias: está inclinada según la forma de las clases.

Ejemplo 11.11 (LDA en los ocho puntos). Con $\boldsymbol{w} = (2, -1)$, las medias proyectadas son $\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_1 = 0$ y $\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_2 = 6$, y $c = 3$: la regla asigna la clase 1 si $2\boldsymbol{x}_1 - \boldsymbol{x}_2 < 3$ y la clase 2 si $2\boldsymbol{x}_1 - \boldsymbol{x}_2 > 3$. La frontera es la recta $2\boldsymbol{x}_1 - \boldsymbol{x}_2 = 3$, que pasa por $m = (3/2, 0)$, y la regla acierta los 8 puntos, contra 6 de la media más cercana (Figura 11.1).



(a) la frontera de LDA

(b) los datos proyectados

Figura 11.1. Los ocho puntos (círculos: clase 1; cuadrados: clase 2; cruces: las medias). (a) La dirección de Fisher $\boldsymbol{w} = (2, -1)$ y la frontera de LDA, la recta $2\boldsymbol{x}_1 - \boldsymbol{x}_2 = 3$, que es perpendicular a $\boldsymbol{w}$ y pasa por el punto medio de las medias: separa perfectamente. (b) Los puntos proyectados sobre la primera dirección principal, sobre la dirección de la recta que une las medias y sobre la dirección de Fisher (las tres de longitud uno); sobre la de Fisher, cada valor aparece dos veces, y la línea punteada es el punto medio c.

Con datos. Como en el capítulo anterior, todo se calcula con los datos de entrenamiento: las medias, S, la dirección $\boldsymbol{w}$ (resolviendo el sistema $S\boldsymbol{w} = \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2$: no hace falta invertir S) y el punto medio c. Después se proyectan los datos de prueba con *el mismo* $\boldsymbol{w}$, se les asigna la clase según de qué lado de c caen, y se calculan los aciertos y la matriz de confusión.

Observación 11.12 (La covarianza pooled). En la computadora se suele usar, en lugar de S, la **covarianza pooled** $S/(n-C)$, que es un promedio ponderado de las covarianzas de las clases (con pesos $(n_k - 1)/(n - C)$). Da lo mismo: $\big(S/(n-C)\big)^{-1}(\bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2) = (n-C)\,\boldsymbol{w}^*$ es un múltiplo de $\boldsymbol{w}^*$. (Con más clases pasa lo mismo: las direcciones de la Sección 11.6 quedan multiplicadas por una constante, y se asignan las mismas clases.)

Ejemplo 11.13 (Tumores de mama). Con los 398 tumores de entrenamiento ($p = 30$) se calculan la dirección de Fisher, $\boldsymbol{w} = S^{-1}(\bar{\boldsymbol{x}}_{\text{mal}} - \bar{\boldsymbol{x}}_{\text{ben}})$, y el punto medio c. En los 171 tumores de prueba, la matriz de confusión es (filas: clase verdadera; columnas: clase asignada; primero maligno y después benigno)

$$K = \begin{pmatrix} 58 & 6 \\ 2 & 105 \end{pmatrix}:$$

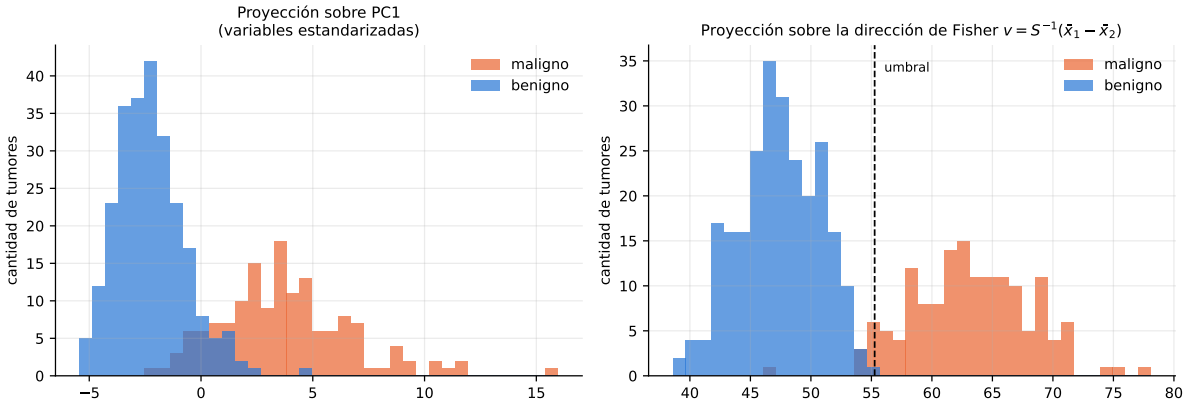


Figura 11.2. Tumores de mama, datos de entrenamiento: histogramas por clase de la proyección sobre la primera componente principal (izquierda, con las variables estandarizadas) y sobre la dirección de Fisher (derecha), con el punto medio c entre las dos medias proyectadas, que es la frontera de LDA.

LDA acierta 163 de 171, el 95,3%, contra el 91,2% de la media más cercana con las variables estandarizadas y el 90,1% de PCA con una componente. Además, de los 64 tumores malignos, solo 6 fueron clasificados como benignos (con la media más cercana eran 8). Como LDA no depende de las unidades (Ejercicio 11.9), el resultado es exactamente el mismo con las variables estandarizadas o sin estandarizar. La Figura 11.2 muestra por qué anda mejor: proyectados sobre la dirección de Fisher, los tumores de las dos clases se solapan mucho menos que sobre la primera componente principal.

11.6 Más de dos clases

Con C clases buscamos varias direcciones: dos para dibujar las clases en el plano y, para clasificar, las que hagan falta. El criterio es el de dos clases, sumado sobre todos los pares de clases. Proyectando sobre $\boldsymbol{w}$, queremos:

- que las **medias proyectadas** queden lejos unas de otras. Para cada par de clases $j < k$, como con dos clases,

$$\left(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_j - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\right)^2 = \boldsymbol{w}^\mathsf{T}(\bar{\boldsymbol{x}}_j - \bar{\boldsymbol{x}}_k)(\bar{\boldsymbol{x}}_j - \bar{\boldsymbol{x}}_k)^\mathsf{T}\boldsymbol{w},$$

  y el par cuenta $n_j n_k$ veces: tantas como pares de observaciones con una en cada clase;
- que cada **clase proyectada** sea compacta: $\boldsymbol{w}^\mathsf{T} S \boldsymbol{w}$ chico, como antes.

Sumando sobre los pares y dividiendo por n, la primera cantidad resulta ser la dispersión de las medias proyectadas alrededor de la media proyectada de todos los datos, $\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}$, con cada clase contada n_k veces (Ejercicio 11.8):

$$\frac{1}{n}\sum_{j<k} n_j n_k \left(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_j - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\right)^2 = \sum_{k=1}^{C} n_k \left(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}\right)^2 = \boldsymbol{w}^\mathsf{T} S_B \boldsymbol{w},$$

otra vez una forma cuadrática, con la matriz que sigue.

Definición 11.14 (Dispersión entre clases). La **matriz de dispersión entre clases** es

$$S_B = \sum_{k=1}^{C} n_k(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}})(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}})^\mathsf{T} \in \mathbb{R}^{p\times p}$$

(la B viene de *between*, "entre"). Es simétrica y semidefinida positiva, y con dos clases es $S_B = \frac{n_1 n_2}{n}\,\boldsymbol{a}\boldsymbol{a}^\mathsf{T}$, porque hay un solo par.

Fisher propone maximizar, como con dos clases,

$$\frac{\boldsymbol{w}^\mathsf{T} S_B \boldsymbol{w}}{\boldsymbol{w}^\mathsf{T} S \boldsymbol{w}}.$$

Es otra vez un cociente de Rayleigh generalizado, ahora con $A = S_B$ y $B = S$, así que *no hay nada nuevo que demostrar*. Sean $\lambda_1 \geq \cdots \geq \lambda_p$ y $\boldsymbol{w}_1, \ldots, \boldsymbol{w}_p$ los autovalores y los autovectores generalizados de (S_B, S), normalizados con $\boldsymbol{w}_j^\mathsf{T} S \boldsymbol{w}_k = \delta_{jk}$. Por el Teorema 11.5, la mejor dirección es $\boldsymbol{w}_1$, con cociente λ_1; entre las direcciones S-ortogonales a $\boldsymbol{w}_1$, la mejor es $\boldsymbol{w}_2$, con cociente λ_2; y así siguiendo. Con dos clases, el cociente es $\frac{n_1 n_2}{n} J(\boldsymbol{w})$, y $\boldsymbol{w}_1$ es la dirección de Fisher. Lo único nuevo es cuántas de estas direcciones sirven.

Proposición 11.15 (A lo sumo $C-1$ direcciones). Los autovalores generalizados λ_k de (S_B, S) son mayores o iguales que cero, y a lo sumo $C-1$ son positivos. Si $\lambda_k = 0$, todas las medias proyectadas sobre $\boldsymbol{w}_k$ coinciden: esa dirección no separa nada.

Demostración. Sea $\boldsymbol{w}$ un autovector generalizado, $S_B\boldsymbol{w} = \lambda S\boldsymbol{w}$, con $\boldsymbol{w}^\mathsf{T} S \boldsymbol{w} = 1$. Multiplicando a izquierda por $\boldsymbol{w}^\mathsf{T}$,

$$\lambda = \boldsymbol{w}^\mathsf{T} S_B \boldsymbol{w} = \sum_{k=1}^{C} n_k \left(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}\right)^2 \geq 0,$$

y es cero solo si todas las medias proyectadas sobre $\boldsymbol{w}$ coinciden (con $\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}$). Como en la demostración del Teorema 11.5, los λ_k son los autovalores de la matriz simétrica $H = S^{-1/2} S_B S^{-1/2}$, así que la cantidad de λ_k no nulos es $\operatorname{rango}(H) = \operatorname{rango}(S_B)$ (multiplicar por matrices invertibles no cambia el rango). Con $d_k = \bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}}$, para todo $\boldsymbol{v}$ vale $S_B\boldsymbol{v} = \sum_k n_k d_k\,(d_k^\mathsf{T}\boldsymbol{v})$, así que las columnas de S_B están en $\operatorname{span}(d_1, \ldots, d_C)$; y esos C vectores son linealmente dependientes, porque $\sum_k n_k d_k = \sum_k n_k \bar{\boldsymbol{x}}_k - n\bar{\boldsymbol{x}} = 0$. Entonces $\operatorname{rango}(S_B) \leq \dim \operatorname{span}(d_1, \ldots, d_C) \leq C - 1$. ∎

Así, con C clases hay a lo sumo $C-1$ **direcciones discriminantes** útiles: una con dos clases, dos con tres (un plano), nueve con los diez dígitos. Es razonable: las C medias están en un subespacio afín de dimensión $C-1$ como mucho, y fuera de él no hay nada que separar.

Definición 11.16 (Regla de LDA). Sea r la cantidad de autovalores generalizados positivos de (S_B, S) (a lo sumo $C-1$) y sea $W = [\,\boldsymbol{w}_1 \;\cdots\; \boldsymbol{w}_r\,] \in \mathbb{R}^{p\times r}$. Cada observación $\boldsymbol{x}$ se reemplaza por sus **coordenadas discriminantes** $z = W^\mathsf{T}\boldsymbol{x} \in \mathbb{R}^r$, y se le asigna la clase k cuya media está más cerca en $\mathbb{R}^r$: la que hace mínima la distancia $\|W^\mathsf{T}\boldsymbol{x} - W^\mathsf{T}\bar{\boldsymbol{x}}_k\|$.

Con dos clases, $r = 1$ y es la regla de la Sección 11.5; para dibujar se usan las dos primeras coordenadas (LD1 y LD2). La normalización importa: por el Teorema 11.5(a), $W^{\mathsf{T}}SW = I_r$ y $W^{\mathsf{T}}S_BW = \operatorname{diag}(\lambda_1, \ldots, \lambda_r)$, así que en las coordenadas z la dispersión dentro de las clases es la misma en todas las direcciones, y por eso se mide con la distancia euclídea. Que las dos matrices queden diagonales a la vez es la diagonalización simultánea de la Sección 11.7.

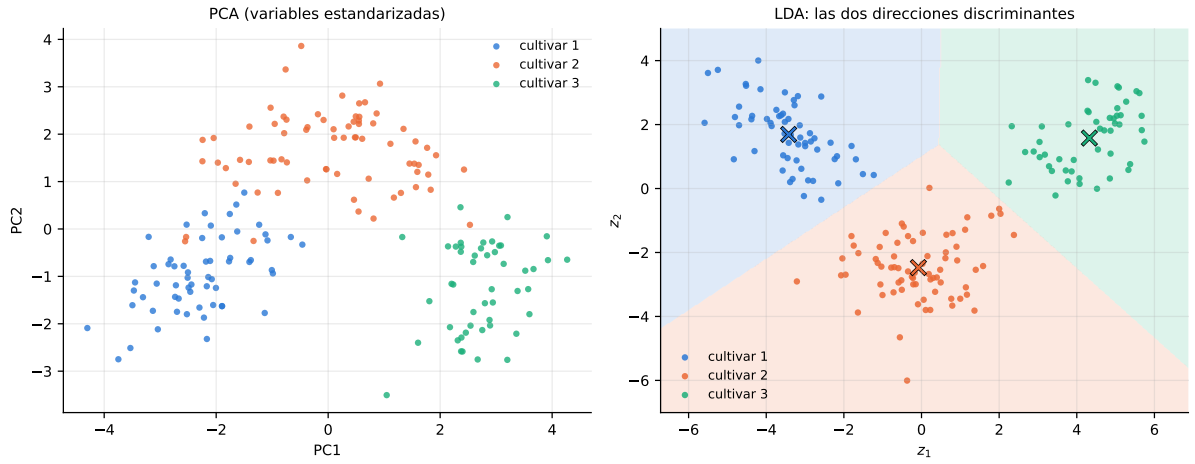


Figura 11.3. Vinos ($n = 178$, $p = 13$, $C = 3$ variedades; las dos figuras usan los 178 vinos). Izquierda: las dos primeras componentes principales de las variables estandarizadas. Derecha: las dos coordenadas discriminantes de LDA (normalizadas con la covarianza pooled), con las medias de las clases ($\times$) y las regiones de la regla de LDA, la media más cercana en ese plano.

Ejemplo 11.17 (Vinos). En los vinos del capítulo anterior (178 vinos, $p = 13$, $C = 3$) hay a lo sumo dos direcciones discriminantes; con todos los vinos, los autovalores generalizados positivos de (S_B, S) son $\lambda_1 \approx 9{,}08$ y $\lambda_2 \approx 4{,}13$. La Figura 11.3 compara el plano de PCA con el de LDA: en el primero las clases se tocan, y en el segundo quedan bien separadas. Para clasificar, todo se calcula con los 124 vinos de entrenamiento: la regla de LDA acierta los 54 vinos de prueba (100%), contra el 98,1% de la media más cercana con las variables estandarizadas y el 68,5% sin estandarizar (con una sola coordenada discriminante, LDA acierta el 94,4%). Con o sin estandarizar, LDA asigna las mismas clases (Ejercicio 11.9).

Ejemplo 11.18 (Dígitos). Con los diez dígitos hay hasta nueve direcciones discriminantes (antes hay que sacar los cuatro píxeles que valen 0 en todas las imágenes de entrenamiento, porque con ellos S no es invertible: Observación 11.2). Con las nueve, LDA acierta el 95,9% de los dígitos de prueba, contra el 88,3% de la media más cercana con nueve componentes principales y el 90,4% con los 64 píxeles: nueve números por imagen, bien elegidos, alcanzan.

La Tabla 11.1 pone lado a lado PCA, del capítulo anterior, y LDA.

11.7 Otra aplicación: la diagonalización simultánea

La parte (a) del Teorema 11.5, escrita con matrices, dice algo que vale la pena mirar por sí mismo: *dos* formas cuadráticas, una de ellas definida positiva, se pueden diagonalizar a la vez con un mismo cambio de base.

	PCA	LDA
usa las etiquetas	no	sí
qué busca	máxima varianza: $\|X_c\boldsymbol{w}\|^2$, con $\|\boldsymbol{w}\| = 1$	máxima separación relativa: $\dfrac{\boldsymbol{w}^\mathsf{T} S_B \boldsymbol{w}}{\boldsymbol{w}^\mathsf{T} S \boldsymbol{w}}$
cómo se calcula	SVD de la matriz centrada X_c	autovectores generalizados de (S_B, S)
las direcciones son	ortonormales	S-ortonormales
cuántas	hasta el rango de X_c	hasta $C-1$
cambiar las unidades	cambia el resultado	no cambia nada
sirve para	describir, comprimir, dibujar	separar y clasificar

Cuadro 11.1. PCA y LDA, lado a lado.

Teorema 11.19 (Diagonalización simultánea por congruencia)**.** Si A es simétrica y B es simétrica definida positiva, hay una matriz invertible W tal que

$$W^\mathsf{T} B W = I, \qquad W^\mathsf{T} A W = \Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_p),$$

donde $\lambda_1, \dots, \lambda_p$ son los autovalores generalizados de (A, B). Las columnas de W son los autovectores generalizados $\boldsymbol{w}_1, \dots, \boldsymbol{w}_p$ del Teorema 11.5(a).

Demostración. Como en la demostración del Teorema 11.5, sea $H = B^{-1/2} A B^{-1/2}$, que es simétrica. Por el teorema espectral, $H = Q \Lambda Q^\mathsf{T}$, con $Q = [\, y_1 \ \cdots \ y_p \,]$ ortogonal y $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_p)$. Sea $W = B^{-1/2} Q$, que es invertible porque es un producto de matrices invertibles. Entonces

$$\begin{aligned} W^\mathsf{T} B W &= Q^\mathsf{T} B^{-1/2} B B^{-1/2} Q = Q^\mathsf{T} Q = I, \\ W^\mathsf{T} A W &= Q^\mathsf{T} B^{-1/2} A B^{-1/2} Q = Q^\mathsf{T} H Q = \Lambda, \end{aligned}$$

y las columnas de W son los $\boldsymbol{w}_k = B^{-1/2} y_k$ del Teorema 11.5(a). ∎

Con el cambio de variables $\boldsymbol{w} = W\xi$, las dos formas cuadráticas quedan diagonales *en la misma base*:

$$\boldsymbol{w}^\mathsf{T} B \boldsymbol{w} = \xi_1^2 + \cdots + \xi_p^2, \qquad \boldsymbol{w}^\mathsf{T} A \boldsymbol{w} = \lambda_1 \xi_1^2 + \cdots + \lambda_p \xi_p^2.$$

En LDA ya lo usamos: en las coordenadas discriminantes, S pasa a ser la identidad y S_B pasa a ser diagonal (Sección 11.6).

Congruencia, no semejanza. En el teorema aparece $W^\mathsf{T}(\cdot)W$, no $W^{-1}(\cdot)W$: es una *congruencia*, que conserva la simetría pero no los autovalores. En el Ejemplo 11.6, los autovalores de A son 2 y 6, y los de $\Lambda = W^\mathsf{T} A W$ son $3 \pm \sqrt{3}$: otros números, pero los mismos signos. Eso pasa siempre: una congruencia conserva cuántos autovalores son positivos, cuántos negativos y cuántos nulos (es la ley de inercia de Sylvester, que no demostramos).

¿Dónde se usa? Un ejemplo de *machine learning*: las interfaces cerebro–computadora. Se registra la actividad eléctrica del cerebro (un electroencefalograma) con p electrodos mientras una persona imagina que mueve la mano izquierda (clase 1) o la derecha (clase 2), y se calculan las matrices de covarianza Σ_1 y Σ_2 de las p señales en cada clase. El método CSP (*common spatial patterns*) busca combinaciones de los electrodos, $\boldsymbol{w}^\mathsf{T}\boldsymbol{x}$, cuya varianza sea grande en una clase y chica en la otra: el máximo y el mínimo de $\boldsymbol{w}^\mathsf{T}\Sigma_1\boldsymbol{w}/\boldsymbol{w}^\mathsf{T}\Sigma_2\boldsymbol{w}$, que es un cociente de Rayleigh generalizado. Por el Teorema 11.5, esas combinaciones son las columnas de la matriz W que diagonaliza a la vez las dos covarianzas, $W^\mathsf{T}\Sigma_2 W = I$ y $W^\mathsf{T}\Sigma_1 W = \Lambda$, y se usan las de λ_k más grande y más chico. Las varianzas de esas pocas combinaciones son después las variables para decidir, por ejemplo con LDA, si la persona pensó en la mano izquierda o en la derecha [2].

Videos

- **Video 26: Cociente de Rayleigh y autovalores generalizados** (18 min). Definición de cociente de Rayleigh. Equivalencia en la maximización y minimización con el cociente de Rayleigh con denominador igual a la identidad. ¿Cómo se traduce la ortogonalidad del caso clásico en este caso? (Sección 11.3.)

Ideas clave

- **Fisher, con matrices**: las medias proyectadas lejos, $(\boldsymbol{w}^\mathsf{T}\boldsymbol{a})^2 = \boldsymbol{w}^\mathsf{T}(\boldsymbol{a}\boldsymbol{a}^\mathsf{T})\boldsymbol{w}$, y cada clase proyectada compacta, $\|\tilde{X}\boldsymbol{w}\|^2 = \boldsymbol{w}^\mathsf{T}S\boldsymbol{w}$; el cociente de Fisher es $J(\boldsymbol{w}) = \boldsymbol{w}^\mathsf{T}(\boldsymbol{a}\boldsymbol{a}^\mathsf{T})\boldsymbol{w}/\boldsymbol{w}^\mathsf{T}S\boldsymbol{w}$.
- **Rayleigh generalizado**: el máximo de $\boldsymbol{w}^\mathsf{T}A\boldsymbol{w}/\boldsymbol{w}^\mathsf{T}B\boldsymbol{w}$ es el mayor autovalor de $A\boldsymbol{w} = \lambda B\boldsymbol{w}$. Con $y = B^{1/2}\boldsymbol{w}$ el denominador pasa a ser $y^\mathsf{T}y$, y es el problema de la matriz simétrica $H = B^{-1/2}AB^{-1/2}$. Hay una base de autovectores generalizados B-ortogonales.
- **La dirección de Fisher es un caso particular**: con $A = \boldsymbol{a}\boldsymbol{a}^\mathsf{T}$, de rango uno, el único autovalor no nulo es $\boldsymbol{a}^\mathsf{T}S^{-1}\boldsymbol{a}$, con autovector $\boldsymbol{w}^* = S^{-1}(\bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2)$.
- **Clasificar**: se proyecta sobre $\boldsymbol{w}^*$ y se corta en el punto medio de las medias proyectadas; la frontera es un hiperplano perpendicular a $\boldsymbol{w}^*$.
- C **clases**: como con dos, sumando sobre los pares de clases (cada par cuenta $n_j n_k$ veces), las medias proyectadas separadas, $\frac{1}{n}\sum_{j<k} n_j n_k(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_j - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k)^2 = \boldsymbol{w}^\mathsf{T}S_B\boldsymbol{w}$, con $S_B = \sum_k n_k(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}})(\bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}})^\mathsf{T}$; y cada clase compacta, $\boldsymbol{w}^\mathsf{T}S\boldsymbol{w}$. Es el mismo teorema con $A = S_B$: las direcciones son los autovectores generalizados de (S_B, S), y sirven a lo sumo $C-1$, porque $\text{rango}(S_B) \le C-1$.
- **Diagonalización simultánea**: con $H = B^{-1/2}AB^{-1/2} = Q\Lambda Q^\mathsf{T}$ y $W = B^{-1/2}Q$, $W^\mathsf{T}BW = I$ y $W^\mathsf{T}AW = \Lambda$ (congruencia, no semejanza). Se usa, por ejemplo, en las interfaces cerebro–computadora (CSP).

Ejercicios

[Cálculo] para fijar la mecánica, [Concepto] para justificar y demostrar (la computadora se usa en la práctica). Los ejercicios 11.1, 11.2, 11.3, 11.5 y 11.13 son de la Sección I.10 de Strang (con algunos agregados), escritos con la notación del capítulo: A en el numerador y B en el denominador (Strang usa S y M).

11.1 [Cálculo] Resolver $(A-\lambda B)\boldsymbol{x}=0$ y $(H-\lambda I)y=0$, después de calcular $H=B^{-1/2}AB^{-1/2}$, para

$$A=\begin{pmatrix}5&4\\4&5\end{pmatrix},\qquad B=\begin{pmatrix}1&0\\0&4\end{pmatrix}.$$

Primero hallar λ_1 y λ_2 de $\det(A-\lambda B)=0$; la ecuación $\det(H-\lambda I)=0$ debería dar los mismos valores. Verificar que $\boldsymbol{x}_1^{\mathsf T}\boldsymbol{x}_2\neq 0$ pero $\boldsymbol{x}_1^{\mathsf T}B\boldsymbol{x}_2=0$, y que $y_1^{\mathsf T}y_2=0$ porque H es simétrica. ¿Cómo se relacionan los autovectores $\boldsymbol{x}_1,\boldsymbol{x}_2$ con los autovectores y_1,y_2?

11.2 [Cálculo]

(a) Para $\boldsymbol{x}=(\boldsymbol{a},\boldsymbol{b})$ e $y=(c,d)$, escribir los cocientes del ejercicio anterior como

$$R^*(\boldsymbol{x})=\frac{\boldsymbol{x}^{\mathsf T}A\boldsymbol{x}}{\boldsymbol{x}^{\mathsf T}B\boldsymbol{x}}=\frac{5\boldsymbol{a}^2+8\boldsymbol{a}\boldsymbol{b}+5\boldsymbol{b}^2}{\boldsymbol{a}^2+4\boldsymbol{b}^2},\qquad R(y)=\frac{y^{\mathsf T}Hy}{y^{\mathsf T}y}=\frac{5c^2+4cd+\frac{5}{4}d^2}{c^2+d^2}.$$

(b) Derivar $R(y)$ respecto de c y de d para encontrar su máximo y su mínimo.

(c) Lo mismo con $R^*(\boldsymbol{x})$ respecto de $\boldsymbol{a}$ y de $\boldsymbol{b}$.

(d) Verificar que los máximos se alcanzan en autovectores de $(A-\lambda B)\boldsymbol{x}=0$ y de $(H-\lambda I)y=0$.

11.3 [Cálculo] En el Ejercicio 11.1, cambiar B por $\left(\begin{smallmatrix}1&0\\0&0\end{smallmatrix}\right)$ y resolver $A\boldsymbol{x}=\lambda B\boldsymbol{x}$. Ahora B es singular: hay un $\boldsymbol{x}_2\neq 0$ con $B\boldsymbol{x}_2=0$, sobre el que el cociente $\boldsymbol{x}^{\mathsf T}A\boldsymbol{x}/\boldsymbol{x}^{\mathsf T}B\boldsymbol{x}$ no está definido ("vale infinito"), y se dice que uno de los autovalores es infinito. Verificar que $\boldsymbol{x}_2$ sigue siendo B-ortogonal al autovector $\boldsymbol{x}_1$ del otro autovalor.

11.4 [Concepto] **B-ortogonales, directamente.** Sin usar $B^{1/2}$, probar que si $A\boldsymbol{w}_1=\lambda_1 B\boldsymbol{w}_1$, $A\boldsymbol{w}_2=\lambda_2 B\boldsymbol{w}_2$ y $\lambda_1\neq\lambda_2$, entonces $\boldsymbol{w}_1^{\mathsf T}B\boldsymbol{w}_2=0$ y también $\boldsymbol{w}_1^{\mathsf T}A\boldsymbol{w}_2=0$. (Sugerencia: multiplicar la primera ecuación a izquierda por $\boldsymbol{w}_2^{\mathsf T}$ y la segunda por $\boldsymbol{w}_1^{\mathsf T}$, y usar que A y B son simétricas, como para los autovectores de una matriz simétrica, que es el caso $B=I$.)

11.5 [Concepto] **La dirección de Fisher, de dos maneras.** (Strang.) Sean $\boldsymbol{u}\in\mathbb{R}^p$ no nulo, B definida positiva y $R(\boldsymbol{x})=\boldsymbol{x}^{\mathsf T}A\boldsymbol{x}/\boldsymbol{x}^{\mathsf T}B\boldsymbol{x}$ con $A=\boldsymbol{u}\boldsymbol{u}^{\mathsf T}$, que es el problema de Fisher.

(a) ¿Qué vector $\boldsymbol{x}$ maximiza $R(\boldsymbol{x})$? ¿Cuánto vale el máximo? (Usar el Corolario 11.8 con $\boldsymbol{u}$ en lugar de $\boldsymbol{a}$ y B en lugar de S: su demostración solo usa que S es definida positiva.) Si $p\geq 2$, ¿cuánto vale el mínimo, y dónde se alcanza?

(b) Otra demostración del máximo, sin autovalores, que es la de la desigualdad de Cauchy–Schwarz del Capítulo 3: con $\boldsymbol{v}=B^{-1}\boldsymbol{u}$, desarrollar $0\leq(\boldsymbol{x}-t\boldsymbol{v})^{\mathsf T}B(\boldsymbol{x}-t\boldsymbol{v})$ como un polinomio de grado dos en t, y usar que su discriminante es menor o igual que cero para probar que $(\boldsymbol{u}^{\mathsf T}\boldsymbol{x})^2\leq(\boldsymbol{u}^{\mathsf T}B^{-1}\boldsymbol{u})\,(\boldsymbol{x}^{\mathsf T}B\boldsymbol{x})$.

(c) Probar que vale la igualdad si y solo si $\boldsymbol{x}$ es un múltiplo de $B^{-1}\boldsymbol{u}$. Deducir que el máximo del cociente de Fisher se alcanza solo en los múltiplos de $\boldsymbol{w}^*$.

11.6 [Cálculo] **Los ocho puntos.** Con los datos de los Ejemplos 11.4 a 11.11:

(a) Verificar $S = \tilde{X}^\mathsf{T}\tilde{X}$, S^{-1}, la dirección de Fisher y $J_{\max} = 4{,}5$. Calcular $J(\boldsymbol{e}_2)$ y $J\big((3,-1)\big)$.

(b) Calcular S_B y resolver $\det(S_B - \lambda S) = 0$: ¿cuáles son los dos autovalores generalizados? ¿Cómo se relaciona el mayor con $J_{\max}$?

(c) Clasificar los puntos $(2,0)$, $(1,-2)$ y $(0,-1)$ con LDA y con la media más cercana del capítulo anterior. ¿En cuáles difieren? ¿Qué pasa con $(3,3)$?

11.7 [Concepto] **La matriz S.**

(a) Probar que $\tilde{X}^\mathsf{T}\tilde{X} = \sum_k \sum_{i:\, y_i = k} (\boldsymbol{x}_i - \bar{\boldsymbol{x}}_k)(\boldsymbol{x}_i - \bar{\boldsymbol{x}}_k)^\mathsf{T}$.

(b) Probar que $S\boldsymbol{w} = 0$ si y solo si $\tilde{X}\boldsymbol{w} = 0$, y que esto pasa si y solo si cada clase, proyectada sobre $\operatorname{span}(\boldsymbol{w})$, queda en un solo punto.

(c) Si G es la matriz indicadora de las clases del capítulo anterior, probar que $G^\mathsf{T}\tilde{X} = 0$. Deducir que $\operatorname{rango}(\tilde{X}) \le n - C$ y que, si $p > n - C$, S no es invertible.

11.8 [Concepto] **La dispersión entre clases, de otra manera.** Sea $\bar{\boldsymbol{x}} = \frac{1}{n}\sum_k n_k \bar{\boldsymbol{x}}_k$ la media de todos los datos.

(a) Probar que

$$S_B = \frac{1}{n} \sum_{j<k} n_j n_k \, (\bar{\boldsymbol{x}}_j - \bar{\boldsymbol{x}}_k)(\bar{\boldsymbol{x}}_j - \bar{\boldsymbol{x}}_k)^\mathsf{T},$$

y deducir la igualdad de la Sección 11.6,

$$\frac{1}{n} \sum_{j<k} n_j n_k \Big(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_j - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k\Big)^2 = \sum_k n_k \Big(\boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}_k - \boldsymbol{w}^\mathsf{T}\bar{\boldsymbol{x}}\Big)^2.$$

(Sugerencia: desarrollar los productos en la suma sobre *todos* los pares (j,k), que es el doble de la suma sobre $j<k$, y usar que $\sum_k n_k \bar{\boldsymbol{x}}_k = n\bar{\boldsymbol{x}}$.)

(b) Probar que $S_B = \bar{X}^\mathsf{T}\bar{X}$, donde $\bar{X} \in \mathbb{R}^{n\times p}$ es la matriz cuya fila i es $(\bar{\boldsymbol{x}}_{y_i} - \bar{\boldsymbol{x}})^\mathsf{T}$: cada observación reemplazada por la media de su clase, menos la media de todos los datos.

(c) Con dos clases, probar que $\boldsymbol{w}^* = S^{-1}\boldsymbol{a}$ es autovector generalizado de (S_B, S) con autovalor $\frac{n_1 n_2}{n}\,\boldsymbol{a}^\mathsf{T}S^{-1}\boldsymbol{a}$. ¿Cuánto valen los demás autovalores generalizados?

11.9 [Concepto] **Las unidades.** Cada observación $\boldsymbol{x}$ se reemplaza por $\boldsymbol{x}' = T\boldsymbol{x} + \boldsymbol{b}$, con T invertible.

(a) Probar que las medias nuevas son $T\bar{\boldsymbol{x}}_k + \boldsymbol{b}$ y que $\tilde{X}' = \tilde{X}T^\mathsf{T}$, y deducir que $S' = TST^\mathsf{T}$ y $S'_B = TS_BT^\mathsf{T}$.

(b) Con dos clases, probar que la dirección de Fisher nueva es $T^{-\top}\boldsymbol{w}^*$, donde $T^{-\top} = (T^{-1})^\mathsf{T}$, que

$$(T^{-\top}\boldsymbol{w}^*)^\mathsf{T}\boldsymbol{x}' = \boldsymbol{w}^{*\top}\boldsymbol{x} + \boldsymbol{w}^{*\top}T^{-1}\boldsymbol{b} \qquad \text{para todo } \boldsymbol{x},$$

y que la regla de LDA asigna las mismas clases.

(c) Con C clases, probar que si $S_B\boldsymbol{w} = \lambda S\boldsymbol{w}$, entonces $S'_B(T^{-\top}\boldsymbol{w}) = \lambda\, S'(T^{-\top}\boldsymbol{w})$: los autovalores generalizados no cambian, y las direcciones pasan a ser los $T^{-\top}\boldsymbol{w}_k$, con la misma normalización. Deducir que las coordenadas discriminantes solo se corren en una constante, y que la regla de LDA asigna las mismas clases.

(d) En cambio, en PCA las unidades importan: con los puntos $(1,1)$, $(-1,-1)$, $(\frac{1}{2},-\frac{1}{2})$ y $(-\frac{1}{2},\frac{1}{2})$, calcular la primera dirección principal antes y después de multiplicar la primera variable por 10.

11.10 [Cálculo] **Tres clases redondas.** Con las tres clases del ejercicio "Tres clases a mano" del capítulo anterior (la clase A son los puntos $(0,0)$, $(2,0)$, $(0,2)$, $(2,2)$; la clase B, $(5,0)$, $(7,0)$, $(5,2)$, $(7,2)$; y la clase C, $(2,5)$, $(4,5)$, $(2,7)$, $(4,7)$):

(a) Verificar que $S = 12I$: las clases son "redondas". Deducir que las direcciones discriminantes son autovectores de S_B, y calcularlas, junto con los autovalores generalizados (a mano o con la computadora: los números no son redondos).

(b) Como $p = 2 = C - 1$, la matriz W es de 2×2. Probar que $W = \frac{1}{\sqrt{12}}Q$, con Q ortogonal, y deducir que la regla de LDA asigna las mismas clases que la media más cercana en el plano. ¿Por qué era de esperar, si las clases son redondas?

11.11 [Concepto] **Regularizar.** Sea $\boldsymbol{w}_\varepsilon = (S + \varepsilon I)^{-1}\boldsymbol{a}$, con $\boldsymbol{a} = \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2$ y $\varepsilon > 0$.

(a) Probar que $S + \varepsilon I$ es definida positiva aunque S no sea invertible.

(b) Si $S = Q\Lambda Q^{\mathsf{T}}$, escribir $\boldsymbol{w}_\varepsilon$ en la base de los autovectores de S.

(c) Probar que $\varepsilon\boldsymbol{w}_\varepsilon \to \boldsymbol{a}$ cuando $\varepsilon \to \infty$ (la regla se parece cada vez más a la de la media más cercana) y que $\boldsymbol{w}_\varepsilon \to S^{-1}\boldsymbol{a}$ cuando $\varepsilon \to 0$, si S es invertible.

11.12 [Concepto] **Diagonalización simultánea: la recíproca.** Probar que si Z es invertible, $Z^{\mathsf{T}}BZ = I$ y $Z^{\mathsf{T}}AZ = \Lambda$ es diagonal, entonces $AZ = BZ\Lambda$: las columnas de Z son autovectores generalizados de (A, B), y los elementos de la diagonal de Λ son los autovalores generalizados. (Sugerencia: de $Z^{\mathsf{T}}BZ = I$ sale que $(Z^{\mathsf{T}})^{-1} = BZ$.)

11.13 [Concepto] **Congruencias.** (Strang.)

(a) ¿Por qué toda congruencia $Z^{\mathsf{T}}AZ$ preserva la simetría de A?

(b) ¿Por qué $Z^{\mathsf{T}}BZ$ es definida positiva si B lo es y Z es cuadrada e invertible? Aplicar el test de energía a $Z^{\mathsf{T}}BZ$, sin olvidar explicar por qué $Z\boldsymbol{x}$ no es el vector cero.

(c) ¿Qué matrices son congruentes a la identidad, es decir, de la forma $Z^{\mathsf{T}}IZ$ con Z invertible?

Práctica: LDA versus PCA

Los datos son los de la práctica del capítulo anterior (tumores de mama, dígitos, cáncer de pulmón y siluetas de vehículos), con la misma separación en entrenamiento y prueba (`separar(X, y)`, con la misma semilla) y los mismos archivos `datos_clasificacion.py` y `herramientas_clasificacion.py`. El objetivo es comparar PCA y LDA, para dibujar las clases y para clasificar. El informe se entrega en una notebook de Colab, con el código, los gráficos (con ejes y títulos) y las respuestas, escritas en celdas de texto.

Antes de empezar. Saque las columnas que son constantes en el entrenamiento (con `columnas_no_constantes`; en el punto L.2, las que son constantes en las dos clases elegidas): si no, S no es invertible. Con el cáncer de pulmón, S no es invertible ni así (hay más variables que datos: Observación 11.2): en los puntos L.2 a L.5 use $S + \varepsilon I$ con ε chico (por ejemplo, $\varepsilon = 10^{-3}\,\mathrm{tr}(S)/p$), que es definida positiva (Ejercicio 11.11), y vea el punto L.6.

L.1 Lo que ya tenemos. Retome la investigación preliminar, los gráficos exploratorios, el gráfico de PC1 contra PC2 y los aciertos de la media más cercana (con y sin PCA) de la práctica anterior.

L.2 LDA con dos clases. Con dos clases hay una sola dirección. Use los tumores de mama (o, si su conjunto tiene más clases, elija dos: por ejemplo, los dígitos 3 y 8, o los dos autos de los vehículos).

- Calcule S, la matriz de dispersión dentro de las clases (o la covarianza pooled $S/(n-2)$, que da la misma dirección: Observación 11.12).
- Calcule $\boldsymbol{w} = S^{-1}(\bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2)$ resolviendo el sistema $S\boldsymbol{w} = \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2$; no invierta S (use `np.linalg.solve`).
- Proyecte: $X\boldsymbol{w} \in \mathbb{R}^n$ es un número por individuo. Es el producto matricial `X @ w`, no el producto entrada por entrada `X * w` (que da una matriz de $n \times p$).
- Haga histogramas de $X\boldsymbol{w}$ separados por clase, en entrenamiento y en prueba, y compárelos con los de la proyección sobre PC1.
- Clasifique con la media más cercana en la recta (cortando en el punto medio c de las medias proyectadas) y calcule los aciertos y la matriz de confusión en prueba. Compare con la práctica anterior.

L.3 LDA con más de dos clases. Si su conjunto tiene más de dos clases:

- Calcule S_B y las direcciones de LDA con la fórmula $W = S^{-1/2}V$, donde V tiene los autovectores de $H = S^{-1/2}S_B S^{-1/2}$ con autovalor positivo (como en la demostración del Teorema 11.5, con $A = S_B$ y $B = S$). ¿Cuántos autovalores positivos hay? ¿Por qué?
- Verifique numéricamente que $W^{\mathsf{T}}SW = I$ y que $W^{\mathsf{T}}S_B W$ es diagonal. Compare con lo que da `scipy.linalg.eigh(S_B, S)`: ¿son las mismas direcciones?
- Grafique los datos en las dos primeras coordenadas discriminantes (LD1 contra LD2), coloreados por clase, y compare con el gráfico de PC1 contra PC2.

L.4 Clasificar. Clasifique los datos de prueba con la regla de LDA (la media más cercana en las coordenadas discriminantes): con todas las coordenadas, y también con solo dos. Informe los aciertos y la matriz de confusión, y compárelos con los de la práctica anterior (media más cercana en $\mathbb{R}^p$, y PCA + media más cercana con la misma cantidad de componentes). Todo se calcula con el entrenamiento y se aplica, sin recalcular, a la prueba.

L.5 Las unidades. Multiplique una de las variables por 1000 (un cambio de unidades) y repita PCA y LDA. ¿Qué cambia y qué no? (Ejercicio 11.9.) Si usó $S + \varepsilon I$, ¿sigue valiendo exactamente? ¿Por qué?

L.6 Más variables que datos. Con el cáncer de pulmón ($n = 32$, $p = 56$): ¿qué rango tiene S? ¿Qué pasa al intentar resolver $S\boldsymbol{w} = \bar{\boldsymbol{x}}_k - \bar{\boldsymbol{x}}_j$? Pruebe (i) reducir primero con PCA a d componentes, con d menor o igual que la cantidad de datos de entrenamiento menos C, y después hacer LDA, y (ii) regularizar, $S + \varepsilon I$. Compare los aciertos en el entrenamiento y en la prueba, repitiendo todo con varias semillas, como en la práctica anterior. ¿Qué concluye?

L.7 Conclusiones. ¿Qué método y qué dimensión elegiría para su conjunto de datos, y por qué? ¿Qué gráfico muestra mejor las clases?

L.8 (Opcional) Compare con `scikit-learn`: la clase `LinearDiscriminantAnalysis` del módulo `sklearn.discriminant_analysis`, con `priors` iguales para todas las clases. ¿Asigna las mismas clases que la regla de LDA con todas las coordenadas discriminantes?

Los archivos de Python

- `herramientas_clasificacion.py` (el mismo de la práctica anterior) tiene también las funciones de LDA: `dispersiones` (S, S_B y $X_c^{\mathsf{T}} X_c$), `covarianza_pooled` ($S/(n-C)$), `direccion_fisher` y `umbral_fisher` (el punto medio c; punto L.2), `raiz_inversa` y `lda_practica` (la fórmula $S^{-1/2}V$ del punto L.3), `lda_autovalores` (lo mismo con `scipy.linalg.eigh`) y `clasificar_lda` (la media más cercana en las coordenadas discriminantes); y, de la práctica anterior, `columnas_no_constantes`.

12 CAPÍTULO

Normas de matrices

En el Capítulo 7 estudiamos normas en espacios vectoriales cualesquiera, y en particular las de $\mathbb{R}^{n\times p}$: como ese espacio tiene dimensión np, todo lo de allí se aplica a matrices sin cambiar una coma. Pero las matrices tienen una operación que los vectores no tienen —el producto— y eso cambia las cosas. Este capítulo trata de las normas de matrices que *son compatibles con el producto*. Esa compatibilidad es lo que las vuelve la herramienta central del análisis numérico: es la que permite acotar el error de un cálculo largo, decidir si un método iterativo converge y medir cuán confiable es la solución de un sistema lineal.

12.1 Normas matriciales

Recordemos la construcción del Capítulo 7. Sea $\mathrm{vec} : \mathbb{R}^{n\times p} \to \mathbb{R}^{np}$ la función que transforma matrices en vectores apilando sus columnas. Para cada norma $\|\cdot\|$ en $\mathbb{R}^{np}$ queda definido un funcional $|||\cdot|||$ en $\mathbb{R}^{n\times p}$,

$$|||A||| = \|\mathrm{vec}(A)\|,$$

y no es difícil mostrar que es una norma (Ejercicio 1). El caso más usado es la **norma de Frobenius** de la Sección 1.3.6,

$$\|A\|_F = \|\mathrm{vec}(A)\|_2 = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{p} a_{ij}^2} = \sqrt{\mathrm{tr}(A^T A)},$$

que no es otra cosa que la norma $\|\cdot\|_2$ de $\mathbb{R}^{np}$.

Hasta acá nada distingue a una matriz de un vector largo. La diferencia aparece cuando se multiplican. Si queremos usar una norma para acotar errores en una cuenta que encadena productos, lo mínimo que necesitamos es poder acotar $\|AB\|$ en términos de $\|A\|$ y $\|B\|$. Eso es lo que pedimos.

Definición 12.1 (Norma matricial). Una norma $\|\cdot\|$ definida sobre matrices es una **norma matricial** si además de las tres propiedades de norma verifica la *submultiplicatividad*:

(n4) $\|AB\| \le \|A\|\,\|B\|$ para todo par de matrices A y B compatible con el producto.

Conviene subrayar que la desigualdad es $\le$ y no $=$: pedir la igualdad sería absurdo, porque AB puede ser la matriz nula sin que lo sean A ni B. Lo que (n4) dice es que *multiplicar no puede agrandar más que el producto de los tamaños*, y eso alcanza para que, iterando, $\|A^k\| \le \|A\|^k$.

Proposición 12.2. La norma de Frobenius es una norma matricial.

Demostración. Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$. La entrada (i,j) de AB es el producto escalar de la fila i de A con la columna j de B,

$$(AB)_{ij} = \operatorname{fila}_i(A)\ \operatorname{col}_j(B),$$

así que por la desigualdad de Cauchy–Schwarz

$$(AB)_{ij}^2 \ \le\ \|\operatorname{fila}_i(A)\|_2^2\ \|\operatorname{col}_j(B)\|_2^2.$$

Ahora sumamos en i y en j. El primer factor no depende de j y el segundo no depende de i, de modo que la suma doble se parte en un producto de dos sumas simples:

$$\|AB\|_F^2 \ \le\ \Big(\sum_{i=1}^{m}\|\operatorname{fila}_i(A)\|_2^2\Big)\Big(\sum_{j=1}^{p}\|\operatorname{col}_j(B)\|_2^2\Big) = \|A\|_F^2\,\|B\|_F^2,$$

porque la norma de Frobenius al cuadrado es tanto la suma de los cuadrados de las longitudes de las filas como la de las columnas (Ejercicio 2). Tomando raíz cuadrada se completa la demostración. ∎

Observación 12.3 (Una cota mejor, mirando por columnas)**.** La fórmula (1.4) del Capítulo 1 dice que $\operatorname{col}_j(AB) = A\ \operatorname{col}_j(B)$: el producto AB no es otra cosa que A aplicada a cada columna de B, una por una. Si medimos cada una de esas columnas con la norma espectral,

$$\|AB\|_F^2 = \sum_{j=1}^{p}\|A\ \operatorname{col}_j(B)\|_2^2 \ \le\ \|A\|_2^2\sum_{j=1}^{p}\|\operatorname{col}_j(B)\|_2^2 = \|A\|_2^2\,\|B\|_F^2,$$

es decir $\|AB\|_F \le \|A\|_2\|B\|_F$. Como $\|A\|_2 \le \|A\|_F$, esto es más fuerte que la proposición anterior. La versión simétrica, $\|AB\|_F \le \|A\|_F\|B\|_2$, sale mirando por filas con (1.5) (Ejercicio 8).

No es cierto que toda norma en un espacio de matrices sea una norma matricial. Para verlo basta mirar la que se obtiene de la norma del máximo de $\mathbb{R}^{np}$,

$$\|A\|_{\max} = \|\operatorname{vec}(A)\|_\infty = \max_{i,j}|a_{ij}|,$$

—el mayor elemento en módulo— que llamaremos **norma del máximo**. Tomando

$$A = B = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

resulta $\|AB\|_{\max} = 2$ mientras que $\|A\|_{\max}\|B\|_{\max} = 1$: la desigualdad (n4) falla. El Ejercicio 6 muestra que multiplicándola por una constante adecuada se la puede arreglar.

Observación 12.4 (Frobenius y los valores singulares)**.** La Proposición 8.27 del Capítulo 8 dice que

$$\|A\|_F^2 = \sigma_1^2 + \cdots + \sigma_r^2,$$

y el Corolario 8.30 que $\|\cdot\|_F$, $\|\cdot\|_2$ y $\|\cdot\|_*$ son ortogonalmente invariantes. Que la norma nuclear sea efectivamente una norma es el Ejercicio 19.

12.2 Normas inducidas

Una clase de normas sobre matrices que resultan ser siempre normas matriciales son las que consideran a la matriz $A \in \mathbb{R}^{n\times p}$ no como un vector reordenado sino como un operador lineal entre $\mathbb{R}^p$ y $\mathbb{R}^n$. Dada una norma vectorial $\|\cdot\|$ definida tanto en $\mathbb{R}^n$ como en $\mathbb{R}^p$ definimos la norma matricial inducida por $\|\cdot\|$ como

$$\|A\| = \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|}. \tag{12.1}$$

Aquí lo estándar es usar la misma notación que para la norma vectorial como para la norma matricial inducida. Antes de demostrar que toda norma inducida es una norma matricial hacemos la siguiente observación que quedará como Ejercicio 4:

$$\max_{\boldsymbol{x}\neq \mathbf{0}} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \max_{\|\boldsymbol{x}\|\leq 1} \|A\boldsymbol{x}\|.$$

Teorema 12.5. Dada una norma vectorial $\|\cdot\|$, la norma definida por (12.1) es una norma matricial.

Demostración. Verificaremos que la norma inducida cumple con las tres propiedades de una norma: no negatividad y propiedad de separación, homogeneidad, y desigualdad triangular. Luego, probaremos la submultiplicatividad.

Por definición, tenemos

$$\|A\| = \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|}.$$

Dado que tanto $\|A\boldsymbol{x}\|$ como $\|\boldsymbol{x}\|$ son no negativas, el cociente también es no negativo, por lo que $\|A\| \geq 0$. Si $A = 0$, entonces $A\boldsymbol{x} = 0$ para todo $\boldsymbol{x}$, lo cual implica que $\|A\boldsymbol{x}\| = 0$ para todo $\boldsymbol{x}$, y, por lo tanto, $\|A\| = 0$. Por otro lado, si $\|A\| = 0$, entonces $\|A\boldsymbol{x}\| = 0$ para todo $\boldsymbol{x}$ con $\|\boldsymbol{x}\| \neq 0$, lo cual solo es posible si $A = 0$.

Sea ahora $\alpha \in \mathbb{R}$. Tenemos que

$$\|\alpha A\| = \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|\alpha A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \max_{\|\boldsymbol{x}\|\neq 0} \frac{|\alpha|\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = |\alpha| \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = |\alpha|\|A\|.$$

Esto prueba la propiedad de homogeneidad.

Para verificar la desigualdad triangular queremos probar que $\|A + B\| \leq \|A\| + \|B\|$. Por definición de la norma inducida,

$$\|A + B\| = \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|(A + B)\boldsymbol{x}\|}{\|\boldsymbol{x}\|}.$$

Dado que $\|(A+B)\boldsymbol{x}\| \leq \|A\boldsymbol{x}\|+\|B\boldsymbol{x}\|$ (por la desigualdad triangular de la norma vectorial), se tiene que

$$\frac{\|(A + B)\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} + \frac{\|B\boldsymbol{x}\|}{\|\boldsymbol{x}\|}.$$

Tomando el máximo en ambos lados respecto de $\|\boldsymbol{x}\| \neq 0$, obtenemos

$$\|A + B\| = \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|(A + B)\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} + \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|B\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \|A\| + \|B\|.$$

Por lo tanto, $\|A\|$ cumple con las propiedades de no negatividad, homogeneidad y desigualdad triangular, lo cual demuestra que es una norma. Finalmente, probaremos que $\|AB\| \leq \|A\|\|B\|$.

Por definición,

$$\|AB\| = \max_{\|\boldsymbol{x}\|\neq 0} \frac{\|AB\boldsymbol{x}\|}{\|\boldsymbol{x}\|}.$$

Sea $\boldsymbol{y} = B\boldsymbol{x}$. Entonces $\|\boldsymbol{y}\| \leq \|B\|\|\boldsymbol{x}\|$, y

$$\|AB\boldsymbol{x}\| = \|A\boldsymbol{y}\| \leq \|A\|\|\boldsymbol{y}\| \leq \|A\|\|B\|\|\boldsymbol{x}\|.$$

Por lo tanto,

$$\frac{\|AB\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \|A\|\|B\|,$$

y tomando el máximo sobre todos los $\boldsymbol{x}$ con $\|\boldsymbol{x}\| \neq 0$, obtenemos que

$$\|AB\| \leq \|A\|\|B\|.$$

■

La definición (12.1) es un máximo sobre infinitos vectores: sirve para demostrar, pero no para calcular. Para las tres normas vectoriales más usadas —$\|\cdot\|_2$, $\|\cdot\|_1$ y $\|\cdot\|_\infty$— ese máximo se puede escribir directamente en términos de las entradas de la matriz.

Teorema 12.6. Sea A una matriz de columnas $\{\boldsymbol{a}_1, \ldots, \boldsymbol{a}_n\}$ y filas $\{\boldsymbol{a}_1^\star, \ldots \boldsymbol{a}_m^\star\}$. Tenemos que

(a) $\|A\|_2 = \sigma_1(A)$.

(b) $\|A\|_1 = \max_{1\leq j\leq n} \sum_i |a_{i,j}| = \max_{1\leq j\leq n} \|\boldsymbol{a}_j\|_1$.

(c) $\|A\|_\infty = \max_{1\leq i\leq m} \sum_j |a_{i,j}| = \max_{1\leq i\leq m} \|\boldsymbol{a}_i^\star\|_1$.

Demostración. La parte (a) ya está hecha: la norma inducida por $\|\cdot\|_2$ es exactamente la *norma espectral* de la Definición 8.3, y el Teorema 8.2 dice que ese máximo vale $\sigma_1(A)$. Dicho de otro modo, la norma espectral que venimos usando desde el Capítulo 8 es un caso particular de la construcción de esta sección, y por el Teorema 12.5 resulta ser, de paso, una norma matricial.

Ahora, para la norma ℓ_1, la fórmula (1.2) del Capítulo 1 dice que $A\boldsymbol{x}$ es la combinación de las columnas de A con coeficientes x_j. Entonces, por la desigualdad triangular, si $\boldsymbol{x} = [x_1, \ldots, x_n]^T$

$$\|A\boldsymbol{x}\|_1 = \left\|\sum_{j=1}^n x_j \boldsymbol{a}_j\right\|_1 \leq \sum_{j=1}^n \|x_j \boldsymbol{a}_j\|_1 = \sum_{j=1}^n |x_j|\|\boldsymbol{a}_j\|_1.$$

Por lo tanto, si $\|x\|_1 = 1$,

$$\|A\boldsymbol{x}\|_1 \leq \left(\max_{1\leq j\leq n} \|\boldsymbol{a}_j\|_1\right) \sum_{j=1}^n |x_j| = \max_{1\leq j\leq n} \|\boldsymbol{a}_j\|_1$$

y

$$\|A\|_1 = \max_{\|\boldsymbol{x}\|_1=1} \|A\boldsymbol{x}\|_1 \leq \max_{1\leq j\leq n} \|\boldsymbol{a}_j\|_1.$$

Para mostrar la igualdad, consideremos una matriz A y sea j_0 tal que

$$\max_{1\leq j\leq m} \|\boldsymbol{a}_j\|_1 = \|\boldsymbol{a}_{j_0}\|_1.$$

Si tomamos $\boldsymbol{x} = \boldsymbol{e}_{j_0}$, el vector que vale uno en la posición j_0 y cero en las demás, tenemos que

$$\|A\boldsymbol{x}\|_1 = \|\boldsymbol{a}_{j_0}\| = \max_{1\leq j\leq m} \|\boldsymbol{a}_j\|_1.$$

Como además $\|\boldsymbol{x}\|_1 = 1$ tenemos que

$$\|A\|_1 \geq \max_{1\leq j\leq n} \|\boldsymbol{a}_j\|_1.$$

La caracterización de la norma ℓ_∞ sale del mismo modo, pero mirando por filas en lugar de por columnas: queda como el Ejercicio 13. ■

12.3 Espectro y radio espectral.

Dada una matriz $A \in \mathbb{R}^{n\times n}$ se define su *espectro* $\sigma(A)$ como el conjunto de autovalores de A, así

$$\sigma(A) = \{\lambda \in \mathbb{C} : \lambda \text{ es autovalor de } A\}.$$

El *radio espectral* $\rho(A)$ de A es el máximo módulo de sus autovalores, más precisamente

$$\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}.$$

Por lo dicho anteriormente,

$$\text{si } A \text{ es simétrica} \quad \Longrightarrow \quad \rho(A) = \|A\|_2.$$

El radio espectral juega un papel fundamental en el estudio de métodos iterativos para sistemas lineales, principalmente debido al siguiente teorema:

Teorema 12.7 (Caracterización del radio espectral)**.** Sea $A \in \mathbb{R}^{n\times n}$, entonces

$$\rho(A) = \inf\{\|A\| : \|\cdot\| \text{ es una norma inducida}\}.$$

La demostración se apoya en la descomposición de Schur (Teorema 5.6 del Capítulo 5): toda $A \in \mathbb{C}^{n\times n}$ se escribe $A = UTU^*$ con U unitaria y T triangular superior cuya diagonal son los autovalores de A contados con multiplicidad. Eso es cierto aunque A no sea diagonalizable, y si los autovalores de A son reales se puede tomar U real ortogonal.

Demostración del Teorema 12.7. Es fácil ver que $\rho(A) \leq \|A\|$ para toda norma inducida $\|\cdot\|$ y cualquier matriz cuadrada A (EJERCICIO). Lo más difícil es ver que dada $A \in \mathbb{R}^{n\times n}$, para todo $\varepsilon > 0$ existe una norma inducida $\|\cdot\|$ tal que $\|A\| < \rho(A) + \varepsilon$.

Sean entonces $A \in \mathbb{R}^{n\times n}$ y $\varepsilon > 0$ dados. Por el Teorema 5.6 de descomposición de Schur existe U unitaria tal que $UA\bar{U}^T = T$ con T triangular superior tal que

$$\text{diag}(T) = (\lambda_1, \lambda_2, \ldots, \lambda_n), \quad \text{y } \lambda_i,\ i = 1, 2, \ldots, n \text{ son los autovalores de } A.$$

Entonces T es de la forma

$$T = \begin{bmatrix} \lambda_1 & t_{12} & t_{13} & \dots & t_{1n} \\ 0 & \lambda_2 & t_{23} & \dots & t_{2n} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & \lambda_{n-1} & t_{(n-1)n} \\ 0 & \dots & 0 & 0 & \lambda_n \end{bmatrix}.$$

Para $z \in \mathbb{R}$, $z > 0$, definimos

$$D_z = \operatorname{diag}(z, z^2, \dots, z^n) = \begin{bmatrix} z & 0 & 0 & \dots & 0 \\ 0 & z^2 & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & z^{n-1} & 0 \\ 0 & 0 & \dots & 0 & z^n \end{bmatrix}$$

Por (1.5), multiplicar por D_z a izquierda multiplica la fila i por z^i; por (1.4), multiplicar por D_z^{-1} a derecha multiplica la columna j por z^{-j}. Haciendo las dos cosas, la entrada (i, j) de T queda multiplicada por z^{i-j}: la diagonal no se mueve —ahí $i = j$— y todo lo de arriba de la diagonal, donde $i < j$, se achica. Es decir,

$$D_z U A \bar{U}^T D_z^{-1} = D_z T D_z^{-1} = \begin{bmatrix} \lambda_1 & z^{-1}t_{12} & z^{-2}t_{13} & \dots & z^{-(n-1)}t_{1n} \\ 0 & \lambda_2 & z^{-1}t_{23} & \dots & z^{-(n-2)}t_{2n} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & \lambda_{n-1} & z^{-1}t_{(n-1)n} \\ 0 & \dots & 0 & 0 & \lambda_n \end{bmatrix},$$

Elegimos ahora z suficientemente grande de manera que

$$\max_{1 \le j \le n} \sum_{i=1}^{j-1} z^{i-j} |t_{ij}| < \varepsilon,$$

y entonces

$$\|D_z U A \bar{U}^T D_z^{-1}\|_1 = \max_{1 \le j \le n} |\lambda_j| + \sum_{i=1}^{j-1} z^{i-j} |t_{ij}| < \rho(A) + \varepsilon.$$

Faltaría ver que $\|D_z U A \bar{U}^T D_z^{-1}\|_1$ es una norma inducida de A. Definimos entonces la norma $\|x\| = \|D_z U x\|_1$ para $x \in \mathbb{R}^n$ (que resulta una norma, verificar), y observemos que

$$\|A\| = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|D_z U A x\|_1}{\|\underbrace{D_z U x}_{y}\|_1} = \max_{\substack{y \in \mathbb{R}^n \\ y \neq 0}} \frac{\|D_z U A (D_z U)^{-1} y\|_1}{\|y\|_1} = \|D_z U A \bar{U}^T D_z^{-1}\|_1.$$

■

La importancia del *radio espectral* queda plasmada en el siguiente teorema.

Teorema 12.8. Sea $A \in \mathbb{R}^{n \times n}$, entonces las siguientes afirmaciones son equivalentes:

(a) $\rho(A) < 1$.

(b) $\|A\| < 1$ para alguna norma inducida.

(c) $\lim_{k\to\infty} \|A^k\| = 0$, para toda norma inducida $\|\cdot\|$.

(d) $\lim_{k\to\infty} A^k x = 0$, para todo vector $x \in \mathbb{R}^n$.

Demostración. (1) $\Rightarrow$ (2) es inmediato por el Teorema 12.7.

(2) $\Rightarrow$ (3). Supongamos que $\|A\|_* < 1$ para alguna norma inducida $\|\cdot\|_*$. Sea $\|\cdot\|$ una norma inducida cualquiera. Entonces, como todas las normas son equivalentes, por ser el espacio de las matrices de dimensión finita, existe $c > 0$ tal que

$$\|A^k\| \le c\|A^k\|_*, \qquad \forall k \in \mathbb{N}_0.$$

Por el Teorema 12.5 de consistencia, resulta que $\|A^k\|_* \le \|A\|_*^k$ y luego

$$\|A^k\| \le c\|A^k\|_* \le c\|A\|_*^k \to 0, \quad \text{cuando } k \to \infty.$$

(3) $\Rightarrow$ (4). Sea $x \in \mathbb{R}^n$ y sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y también su norma inducida en $\mathbb{R}^{n\times n}$. Entonces, por el Teorema 12.5 de consistencia

$$\|A^k x - 0\| = \|A^k x\| \le \|A^k\|\|x\| \to 0, \quad \text{cuando } k \to \infty.$$

(4) $\Rightarrow$ (1). Sea $\lambda \in \sigma(A)$ y sea x un autovector asociado a λ, luego

$$Ax = \lambda x, \qquad \text{y} \qquad A^k x = \lambda^k x.$$

Así,

$$\|A^k x\| = |\lambda|^k \|x\|$$

para cualquier norma $\|\cdot\|$ de $\mathbb{R}^n$. Por (4), $\|A^k x\| \to 0$ y por ende $|\lambda|^k\|x\| \to 0$. Como x es un autovector, es no nulo, y por lo tanto $|\lambda|^k \to 0$ cuando $k \to \infty$. Por lo tanto $|\lambda| < 1$. Como $\lambda \in \sigma(A)$ era arbitrario, resulta $\rho(A) = \max_{\lambda\in\sigma(A)} |\lambda| < 1$. ∎

Teorema 12.9. Sea $A \in \mathbb{R}^{n\times n}$. Entonces, cualquiera sea la norma inducida $\|\cdot\|$, resulta

$$\rho(A) = \lim_{k\to\infty} \|A^k\|^{1/k}.$$

Demostración. Veamos primero que $\rho(A) \le \|A^k\|^{1/k}$. Sea $\lambda \in \sigma(A)$ y sea x un autovector asociado a λ. Entonces

$$Ax = \lambda x \implies A^k x = \lambda^k x \implies \|A^k x\| = |\lambda|^k\|x\|$$
$$\implies |\lambda|^k = \frac{\|A^k x\|}{\|x\|} \le \|A^k\| \implies |\lambda| \le \|A^k\|^{1/k} \implies \rho(A) \le \|A^k\|^{1/k}.$$

Veamos ahora que el límite de $\|A^k\|^{1/k}$ es $\rho(A)$. Sea $\varepsilon > 0$ y definimos

$$\tilde{A} = \frac{1}{\rho(A)+\varepsilon} A \implies \rho(\tilde{A}) = \frac{1}{\rho(A)+\varepsilon}\rho(A) = \frac{\rho(A)}{\rho(A)+\varepsilon} < 1.$$

Por el Teorema anterior, $\lim_{k\to\infty} \|\tilde{A}^k\| = 0$ y por lo tanto, existe $k_0 \in \mathbb{N}$ tal que

$$\|\tilde{A}^k\| = \frac{\|A^k\|}{(\rho(A)+\varepsilon)^k} < 1, \quad \forall k \geq k_0.$$

Es decir que dado $\varepsilon > 0$, existe $k_0 \in \mathbb{N}$ tal que

$$\rho(A) \leq \|A^k\|^{1/k} \leq \rho(A) + \varepsilon, \quad \forall k \geq k_0.$$

O sea, $\lim_{k\to\infty} \|A^k\|^{1/k} = \rho(A)$. ∎

Cuando $\rho(A) < 1$, la serie geométrica de matrices converge y da la inversa de $I - A$.

Teorema 12.10 (Serie de Neumann). Sea $A \in \mathbb{R}^{n\times n}$ con $\rho(A) < 1$. Entonces $I - A$ es invertible y

$$(I-A)^{-1} = \sum_{k=0}^{\infty} A^k = I + A + A^2 + A^3 + \cdots,$$

con convergencia en cualquier norma. Si además $\|A\| < 1$ para alguna norma inducida, entonces

$$\left\|(I-A)^{-1}\right\| \leq \frac{1}{1-\|A\|}, \qquad \left\|(I-A)^{-1} - \sum_{k=0}^{m} A^k\right\| \leq \frac{\|A\|^{m+1}}{1-\|A\|}.$$

Demostración. Si $I - A$ no fuera invertible, existiría $x \neq 0$ con $(I-A)x = 0$, es decir $Ax = x$: entonces 1 sería autovalor de A y $\rho(A) \geq 1$, en contra de la hipótesis. Sea $S_m = \sum_{k=0}^{m} A^k$. La identidad telescópica

$$(I-A)\,S_m = I - A^{m+1}$$

se verifica desarrollando el producto. Por el Teorema 12.8, $\rho(A) < 1$ implica $\|A^{m+1}\| \to 0$, así que $(I-A)S_m \to I$ y, multiplicando por $(I-A)^{-1}$, $S_m \to (I-A)^{-1}$.

Para las cotas, si $\|\cdot\|$ es inducida y $\|A\| < 1$, la submultiplicatividad da $\|A^k\| \leq \|A\|^k$ y entonces $\|S_m\| \leq \sum_{k=0}^{m} \|A\|^k \leq 1/(1-\|A\|)$; pasando al límite se obtiene la primera. La segunda sale de $(I-A)^{-1} - S_m = \sum_{k>m} A^k = A^{m+1}(I-A)^{-1}$ y de la primera. ∎

Observación 12.11 (De dónde viene esto). La serie de Neumann es la versión matricial de $\frac{1}{1-a} = \sum a^k$ para $|a| < 1$, y es el esqueleto de los *métodos iterativos* para resolver $Ax = b$. La idea es partir $A = M - N$ con M fácil de invertir —diagonal, o triangular, como las que salieron de la eliminación en el Capítulo 2— y escribir $Ax = b$ como

$$x = M^{-1}Nx + M^{-1}b =: Tx + c.$$

La iteración $x^{(k+1)} = Tx^{(k)} + c$ converge, para cualquier punto de partida, exactamente cuando $\rho(T) < 1$, y entonces el límite es $(I-T)^{-1}c$, que es la solución. El radio espectral de la *matriz de iteración* T es, entonces, lo único que hay que mirar para saber si un método iterativo sirve, y cuán rápido converge: el error se multiplica, aproximadamente, por $\rho(T)$ en cada paso.

12.4 Número de condición y error relativo

Dada $A \in \mathbb{R}^{n\times n}$ y $b \in \mathbb{R}^n$, consideremos el problema de hallar $x \in \mathbb{R}^n$ tal que $Ax = b$. Supongamos que $\tilde{x} \in \mathbb{R}^n$ es una solución aproximada del sistema. Considerando una norma dada $\|\cdot\|$ de $\mathbb{R}^n$, definimos:

$$\begin{aligned} \text{error} &= x - \tilde{x}, \\ \text{error relativo} &= \frac{\|x-\tilde{x}\|}{\|x\|}, \\ \text{residuo} &= A\tilde{x} - b = \tilde{b} - b, \quad \text{si } \tilde{b} = A\tilde{x}, \\ \text{residuo relativo} &= \frac{\|\tilde{b}-b\|}{\|b\|}. \end{aligned}$$

Queremos hallar una estimación para el error relativo $\frac{\|x-\tilde{x}\|}{\|x\|}$ en términos del residuo relativo $\frac{\|\tilde{b}-b\|}{\|b\|}$. Observemos lo siguiente

$$\|\tilde{x} - x\| = \|A^{-1}\tilde{b} - A^{-1}b\| \leq \|A^{-1}\|\|\tilde{b} - b\|,$$

Además,

$$\|Ax\| = \|b\| \quad \Longrightarrow \quad \|b\| \leq \|A\|\|x\|.$$

Luego,

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \|A\|\|A^{-1}\|\frac{\|\tilde{b} - b\|}{\|b\|}. \tag{12.2}$$

Análogamente

$$\|\tilde{b} - b\| = \|A\tilde{x} - Ax\| \leq \|A\|\|\tilde{x} - x\|,$$

y

$$\|x\| = \|A^{-1}b\| \leq \|A^{-1}\|\|b\|.$$

Por lo tanto

$$\frac{1}{\|A\|\|A^{-1}\|}\frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|}. \tag{12.3}$$

De (12.2)–(12.3) obtenemos que

$$\frac{1}{\|A\|\|A^{-1}\|}\frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \|A\|\|A^{-1}\|\frac{\|\tilde{b} - b\|}{\|b\|}. \tag{12.4}$$

Definición 12.12. Dada una norma inducida $\|\cdot\|$ en el espacio de las matrices de $n \times n$, se define el **número de condición** para esa norma como

$$\kappa(A) = \|A\|\,\|A^{-1}\|, \qquad A \in \mathbb{R}^{n\times n} \text{ invertible.}$$

Lema 12.13. Si $x \in \mathbb{R}^n \setminus \{0\}$ es la solución de $Ax = b$, entonces, cualquiera sea $\tilde{x} \in \mathbb{R}^n$, se cumple que

$$\frac{1}{\kappa(A)}\frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \kappa(A)\frac{\|\tilde{b} - b\|}{\|b\|},$$

para $\tilde{b} = A\tilde{x}$.

Observación 12.14. El número de condición siempre es mayor o igual a uno:

$$\kappa(A) = \|A\|\|A^{-1}\| \geq \|AA^{-1}\| = \|I\| = 1.$$

Cuando $\kappa(A)$ es pequeño, o cercano a uno, $\kappa(A) \cong 1$ resulta

$$\frac{\|\tilde{x} - x\|}{\|x\|} \cong \frac{\|\tilde{b} - b\|}{\|b\|}$$

Es decir, pequeñas perturbaciones en el lado derecho de la ecuación, producen pequeños cambios en las soluciones. En este caso decimos que el problema $Ax = b$ está *bien condicionado*.

Observación 12.15. Dada la solución x de $Ax = b$, si $\tilde{x}$ es una aproximación de x, entonces

$$\underbrace{\frac{\|\tilde{x} - x\|}{\|x\|}}_{\text{desconocido}} \leq \kappa(A) \underbrace{\frac{\|A\tilde{x} - b\|}{\|b\|}}_{\text{calculable}}.$$

El lado derecho de la desigualdad anterior se utiliza en la implementación de criterios de parada en algunos métodos iterativos.

Observación 12.16. Observemos que multiplicar una matriz por una constante arbitraria no nula, no afecta el número de condición:

$$\kappa(\alpha A) = \|\alpha A\|\|(\alpha A)^{-1}\| = |\alpha|\|A\|\frac{1}{|\alpha|}\|A^{-1}\| = \kappa(A).$$

Hay una relación estrecha entre el número de condición y el espectro cuando se usa la norma $\|\cdot\|_2$ y la matriz es simétrica.

Lema 12.17. Si $A \in \mathbb{R}^{n\times n}$ es simétrica e invertible, entonces

$$\kappa_2(A) = \frac{|\lambda|_{\max}}{|\lambda|_{\min}},$$

donde $|\lambda|_{\max}$ y $|\lambda|_{\min}$ son el mayor y el menor *módulo* de los autovalores de A.

Demostración. Como A es simétrica, $\|A\|_2 = \rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\} = |\lambda|_{\max}$. Como además A es invertible, A^{-1} es simétrica y sus autovalores son los λ^{-1} con $\lambda \in \sigma(A)$ (Corolario 5.10), así que

$$\begin{aligned}\|A^{-1}\|_2 = \rho(A^{-1}) &= \max\left\{|\mu| : \mu \in \sigma(A^{-1})\right\} = \max\left\{|\lambda|^{-1} : \lambda \in \sigma(A)\right\} \\ &= \frac{1}{\min\left\{|\lambda| : \lambda \in \sigma(A)\right\}} = \frac{1}{|\lambda|_{\min}},\end{aligned}$$

donde la anteúltima igualdad dice simplemente que el máximo de los inversos de números positivos es el inverso del mínimo. Multiplicando las dos normas queda el enunciado. ∎

Para una matriz cualquiera —sin ninguna hipótesis— la respuesta la da la SVD, y es todavía más simple.

Lema 12.18 (El número de condición son los valores singulares). Sea $A \in \mathbb{R}^{n\times n}$ invertible, con valores singulares $\sigma_1 \geq \cdots \geq \sigma_n > 0$. Entonces

$$\kappa_2(A) = \frac{\sigma_1}{\sigma_n}$$

Demostración. Por la Definición 8.3, $\|A\|_2 = \sigma_1$. Si $A = U\Sigma V^T$ es una SVD de A con $\Sigma = \operatorname{diag}(\sigma_1, \ldots, \sigma_n)$ invertible, entonces

$$A^{-1} = V\Sigma^{-1}U^T,$$

y como U y V son ortogonales eso es una SVD de A^{-1}, salvo por el orden de la diagonal: los valores singulares de A^{-1} son $\sigma_n^{-1} \geq \cdots \geq \sigma_1^{-1}$. El mayor es σ_n^{-1}, de donde $\|A^{-1}\|_2 = 1/\sigma_n$. ∎

Observación 12.19 (Qué mide, en una frase). El Teorema 8.21 dice que A transforma la esfera unitaria en un elipsoide de semiejes $\sigma_1, \ldots, \sigma_n$. El número de condición es el cociente entre el semieje más largo y el más corto: cuán *achatado* queda ese elipsoide. Una matriz bien condicionada manda la esfera a algo todavía parecido a una esfera; una mal condicionada la aplasta casi hasta un subespacio, y por eso un cambio chico del lado derecho produce un cambio enorme en la solución. De paso se ve que $\kappa_2(A) = 1$ exactamente cuando todos los valores singulares coinciden, es decir cuando A es un múltiplo de una matriz ortogonal: *las matrices ortogonales son las mejor condicionadas que hay*, y es la razón por la que QR y las reflexiones de Householder del Capítulo 3 son numéricamente preferibles a la eliminación gaussiana.

Ejercicios

1. Mostrar que si $\|\cdot\|$ es una norma en $\mathbb{R}^{np}$ entonces $|||\cdot|||$ en $\mathbb{R}^{n\times p}$ definido como

   $$|||A||| = \|\operatorname{vec}(A)\|$$

   es una norma.

2. Sea $A \in \mathbb{R}^{m\times n}$.

   (a) Mostrar que $\|A\|_F^2 = \sum_{j=1}^n \|\operatorname{col}_j(A)\|_2^2$ y también $\|A\|_F^2 = \sum_{i=1}^m \|\operatorname{fila}_i(A)\|_2^2$: la norma de Frobenius al cuadrado es tanto la suma de los cuadrados de las longitudes de las columnas como la de las filas.

   (b) Mostrar que si Q es una matriz ortogonal entonces $\|A\|_F = \|QA\|_F = \|AQ\|_F$.

3. Decimos que una norma de matrices está **normalizada** si la matriz identidad de cualquier orden tiene norma 1. (Cuidado con el nombre: no tiene nada que ver con las matrices unitarias del Capítulo 5 ni con las normas ortogonalmente invariantes de la Sección 8.7; de hecho $\|\cdot\|_F$ es ortogonalmente invariante y no está normalizada.)

   (a) Mostrar que toda norma inducida está normalizada.

   (b) ¿Es cierto que toda norma matricial debe estar normalizada?

(c) Considere en $\mathbb{R}^{n\times p}$

$$\|A\| = \|\mathrm{vec}(A)\|_1.$$

¿Está normalizada? ¿Es una norma matricial?

4. Probar que

$$\max_{\boldsymbol{x}\neq\boldsymbol{0}} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \max_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \max_{\|\boldsymbol{x}\|\leq 1} \|A\boldsymbol{x}\|$$

5. Para una matriz A de columnas $\{\boldsymbol{a}_1, \ldots, \boldsymbol{a}_n\}$ definimos

$$\|A\|_{2,1} = \sum_{j=1}^{n} \|\boldsymbol{a}_j\|_2.$$

Mostrar que es una norma. ¿Es una norma matricial?

6. Mostrar que la siguiente modificación de la norma del máximo la vuelve una norma matricial en $\mathbb{R}^{m\times n}$:

$$\|A\| = \sqrt{mn}\, \|\mathrm{vec}(A)\|_\infty.$$

7. Probar que $\|A\|_F = \|A^T\|_F$ y $\|A\|_2 = \|A^T\|_2$, pero que en cambio $\|A\|_1 = \|A^T\|_\infty$. Dar una matriz con $\|A\|_1 \neq \|A^T\|_1$.

8. *(Cotas mixtas.)* Usando que $\mathrm{fila}_i(AB) = \mathrm{fila}_i(A)B$ —la fórmula (1.5) del Capítulo 1— probar que $\|AB\|_F \leq \|A\|_F \, \|B\|_2$, que es la versión por filas de la Observación 12.3. ¿Por qué estas dos cotas son mejores que la submultiplicatividad $\|AB\|_F \leq \|A\|_F \|B\|_F$ de la Proposición 12.2?

9. *(A mano.)* Para cada una de las matrices

$$A_1 = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}, \qquad A_2 = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}, \qquad A_3 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

$$A_4 = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}, \qquad A_5 = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \qquad A_6 = \mathrm{diag}(3, -2, 1),$$

calcular, haciendo las cuentas: $\|A\|_1$, $\|A\|_\infty$, $\|A\|_F$, $\|A\|_2$, $\|A\|_*$ y $\rho(A)$. *Sugerencias:* $\|A\|_1$ y $\|A\|_\infty$ salen del Teorema 12.6 mirando sumas de columnas y de filas; para $\|A\|_2$ y $\|A\|_*$ hacen falta los valores singulares, que acá se consiguen sin esfuerzo en cada caso: A_1 tiene su SVD calculada en el Ejemplo 8.13; A_2 y A_3 tienen rango uno; A_4, A_6 son simétricas (Ejercicio 14); y A_5 es ortogonal. Armar una tabla con los seis resultados en filas.

10. Con los números del ejercicio anterior:

(a) Verificar en cada caso las desigualdades $\rho(A) \leq \|A\|_2 \leq \|A\|_F \leq \sqrt{r}\, \|A\|_2$, donde $r = \mathrm{rango}(A)$.

(b) Probar las dos últimas en general, y caracterizar las matrices en las que vale cada igualdad. *Sugerencia:* las tres normas se leen de los σ_k (Sección 8.7); la primera igualdad pide $\sigma_1^2 = \sigma_1^2 + \cdots + \sigma_r^2$ y la segunda, que todos los σ_k sean iguales. ¿Cuáles de las seis matrices de arriba realizan cada igualdad?

(c) Deducir de la misma manera que $\|A\|_F \le \|A\|_* \le \sqrt{r}\,\|A\|_F$.

(d) ¿En cuáles de las seis es $\rho(A) < \|A\|_2$ estrictamente? ¿Qué tienen en común aquellas en las que vale la igualdad?

11. *(Rango uno.)* Sea $A = \boldsymbol{u}\boldsymbol{v}^T$ con $\boldsymbol{u} \in \mathbb{R}^m$ y $\boldsymbol{v} \in \mathbb{R}^n$ no nulos.

(a) Probar que A tiene un solo valor singular no nulo y que vale $\|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2$. *Sugerencia:* $A^TA = \|\boldsymbol{u}\|_2^2\,\boldsymbol{v}\boldsymbol{v}^T$.

(b) Deducir que $\|A\|_2 = \|A\|_F = \|A\|_* = \|\boldsymbol{u}\|_2\|\boldsymbol{v}\|_2$.

(c) Probar que $\|A\|_1 = \|\boldsymbol{u}\|_1 \max_j |v_j|$ y $\|A\|_\infty = \|\boldsymbol{v}\|_1 \max_i |u_i|$.

(d) Verificar los cuatro valores a mano con $\boldsymbol{u} = (1, 2, -2)^T$ y $\boldsymbol{v} = (3, 0, 4)^T$. (Deberían dar 15, 15, 15, 20 y 14.)

12. Calcular $\|\cdot\|_1$, $\|\cdot\|_\infty$, $\|\cdot\|_F$, $\|\cdot\|_2$ y $\|\cdot\|_*$ de la identidad I_n y de la matriz $\mathbf{1}\mathbf{1}^T \in \mathbb{R}^{n\times n}$ de todos unos. Las dos matrices tienen la misma norma $\|\cdot\|_2$; ¿cuál de las normas distingue mejor el rango, y por qué?

13. *(La parte que falta del Teorema 12.6.)* Probar la parte (c), es decir que $\|A\|_\infty = \max_i \|\operatorname{fila}_i(A)\|_1$, siguiendo el mismo esquema que la demostración de la parte (b) pero mirando por filas.

(a) Probar que si $\|\boldsymbol{x}\|_\infty \le 1$ entonces $|(A\boldsymbol{x})_i| = |\operatorname{fila}_i(A)\,\boldsymbol{x}| \le \|\operatorname{fila}_i(A)\|_1$, y deducir $\|A\|_\infty \le \max_i \|\operatorname{fila}_i(A)\|_1$.

(b) Para la otra desigualdad, sea i_0 la fila de mayor norma ℓ_1 y tomar $\boldsymbol{x}$ con $x_j = \operatorname{sgn}(a_{i_0 j})$ (y $x_j = 1$ si $a_{i_0 j} = 0$). Verificar que $\|\boldsymbol{x}\|_\infty = 1$ y que $(A\boldsymbol{x})_{i_0} = \|\operatorname{fila}_{i_0}(A)\|_1$.

(c) ¿Por qué acá el vector que realiza el máximo tiene todas sus coordenadas no nulas, mientras que en la parte (b) alcanzaba con un vector de la base canónica?

14. Probar que si $A \in \mathbb{R}^{n\times n}$ es simétrica entonces $\|A\|_2 = \rho(A)$ —la igualdad que se usa sin demostrar al final de la Sección 12.2— y que sus valores singulares son los módulos de sus autovalores. Dar una matriz no simétrica con $\rho(A) < \|A\|_2$ y otra, también no simétrica, con $\rho(A) = \|A\|_2$.

15. Probar que $\rho(A) \le \|A\|$ para toda norma inducida $\|\cdot\|$ y toda A cuadrada. *Sugerencia:* si $A\boldsymbol{x} = \lambda\boldsymbol{x}$ con $\boldsymbol{x} \neq \mathbf{0}$, dividir $\|A\boldsymbol{x}\|$ por $\|\boldsymbol{x}\|$. Dar después una matriz con $\rho(A) = 0$ y $\|A\|_2$ tan grande como se quiera, y concluir que ρ *no* es una norma.

16. Del Teorema 12.8 demostrar las implicaciones $(c) \Rightarrow (d)$ y $(d) \Rightarrow (a)$, que no usan nada más que la submultiplicatividad y la definición de autovector.

17. Verificar $\rho(A) = \lim_k \|A^k\|^{1/k}$ en $A = \left[\begin{smallmatrix} 0 & t \\ 0 & 0 \end{smallmatrix}\right]$ con $t > 0$ y en una matriz diagonalizable a elección, calculando $\|A^k\|^{1/k}$ para $k = 1, 2, 5, 10, 50$. ¿Por qué el límite se alcanza enseguida en un caso y es lento en el otro?

18. Probar que $\|A\|_2^2 \le \|A\|_1\,\|A\|_\infty$. *Sugerencia:* $\|A\|_2^2 = \|A^TA\|_2 \le \|A^TA\|_\infty$ y $\|A^T\|_\infty = \|A\|_1$ (Ejercicio 7). Verificarlo en $A_1 = \left[\begin{smallmatrix} 3 & 0 \\ 4 & 5 \end{smallmatrix}\right]$ del Ejercicio 9.

19. Probar que $\|A\|_* = \sum_i \sigma_i(A)$ es una norma. Lo único que cuesta es la desigualdad triangular; una manera es usar la caracterización

$$\|A\|_* = \max\Big\{\operatorname{tr}(Q^T A) \;:\; Q \in \mathbb{R}^{m\times n},\ \|Q\|_2 \le 1\Big\},$$

que conviene probar primero con la SVD de A: el máximo se alcanza en $Q = U_r V_r^T$.

20. *(Número de condición.)*

    (a) Probar que $\kappa(A) \ge 1$ para toda norma inducida y que $\kappa(\alpha A) = \kappa(A)$ para todo $\alpha \neq 0$.

    (b) Calcular $\kappa_2(A)$ para $A = \left[\begin{smallmatrix} 1 & 1 \\ 1 & 1+\varepsilon \end{smallmatrix}\right]$ y estudiar qué pasa cuando $\varepsilon \to 0$. (Para ε chico da del orden de $4/\varepsilon$.)

    (c) Resolver $Ax = b$ con $b = (2,2)^T$ y con $b = (2, 2+\delta)^T$ y comparar el cambio relativo de la solución con el del lado derecho, contrastándolo con la cota del Lema 12.13.

21. Probar que si $A = \boldsymbol{u}\boldsymbol{v}^T$ y $B = \boldsymbol{v}\boldsymbol{w}^T$ con $\boldsymbol{u}, \boldsymbol{v}, \boldsymbol{w}$ vectores no nulos, entonces se satisface que $\|AB\|_F^2 = \|A\|_F^2 \|B\|_F^2$.

    La implicación contraria es una conjetura: las únicas matrices sin elementos nulos, de rango uno, que satisfacen $\|AB\|_F = \|A\|_F \, \|B\|_F$ son de la forma $A = \boldsymbol{u}\boldsymbol{v}^T$ y $B = \boldsymbol{v}\boldsymbol{w}^T$ con un vector compartido $\boldsymbol{v}$.

13 CAPÍTULO

Mínimos cuadrados y pseudoinversa

Casi todos los sistemas lineales que aparecen con datos reales son *incompatibles*: hay más ecuaciones que incógnitas y ninguna combinación de las columnas reproduce exactamente el lado derecho. Este capítulo trata de qué hacer entonces. La respuesta corta es que se reemplaza la igualdad $A\boldsymbol{x} = \boldsymbol{b}$ por el problema de minimizar $\|A\boldsymbol{x} - \boldsymbol{b}\|_2$, que siempre tiene solución; la respuesta larga ocupa el capítulo, y el instrumento que la organiza es la SVD.

13.1 Cuándo tiene solución un sistema

Empecemos por la pregunta previa. Dados $A \in \mathbb{R}^{m\times n}$ y $\boldsymbol{b} \in \mathbb{R}^m$, ¿cuándo existe $\boldsymbol{x}$ con $A\boldsymbol{x} = \boldsymbol{b}$?

La respuesta ya está en el Capítulo 1: por la fórmula (1.2), $A\boldsymbol{x}$ es la combinación lineal de las columnas de A con coeficientes las entradas de $\boldsymbol{x}$, de modo que los $A\boldsymbol{x}$ barren exactamente el espacio columna $C(A)$. Entonces

$$A\boldsymbol{x} = \boldsymbol{b} \text{ tiene solución} \quad \Longleftrightarrow \quad \boldsymbol{b} \in C(A). \tag{13.1}$$

Y si $\boldsymbol{x}_0$ es una solución, todas son $\boldsymbol{x}_0 + N(A)$, porque restar dos soluciones da un vector del núcleo. Hasta acá no hay nada nuevo.

Lo que sí es nuevo, y es lo que vamos a usar todo el capítulo, es que la SVD convierte (13.1) en una cuenta con números.

13.1.1 La misma pregunta, leída con la SVD

Sea $A = U\Sigma V^{\mathsf{T}}$ una SVD completa de A (Capítulo 8), con $U \in \mathbb{R}^{m\times m}$ y $V \in \mathbb{R}^{n\times n}$ ortogonales, $r = \operatorname{rango}(A)$ y

$$\Sigma = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{m\times n}, \qquad D = \operatorname{diag}(\sigma_1, \dots, \sigma_r), \quad \sigma_1 \geq \cdots \geq \sigma_r > 0.$$

Hacemos el cambio de variables

$$\boldsymbol{z} = V^{\mathsf{T}}\boldsymbol{x} \in \mathbb{R}^n, \qquad \boldsymbol{c} = U^{\mathsf{T}}\boldsymbol{b} \in \mathbb{R}^m. \tag{13.2}$$

Como U y V son ortogonales, el cambio es biyectivo y no altera ninguna norma: $\|\boldsymbol{x}\|_2 = \|\boldsymbol{z}\|_2$ y $\|\boldsymbol{b}\|_2 = \|\boldsymbol{c}\|_2$. Multiplicando $A\boldsymbol{x} = \boldsymbol{b}$ por U^{T} a izquierda,

$$A\boldsymbol{x} = \boldsymbol{b} \quad \Longleftrightarrow \quad U\Sigma V^{\mathsf{T}}\boldsymbol{x} = \boldsymbol{b} \quad \Longleftrightarrow \quad \Sigma\boldsymbol{z} = \boldsymbol{c}.$$

Este último sistema es trivial, porque Σ es diagonal: se desacopla en m ecuaciones independientes,

$$\sigma_i z_i = c_i \quad (i \leq r), \qquad\qquad 0 = c_i \quad (i > r). \tag{13.3}$$

Las primeras r siempre se pueden resolver, y de manera única: $z_i = c_i/\sigma_i$. Las últimas $m - r$ no tienen nada que resolver: o se cumplen o no. Y las variables $z_{r+1}, \dots, z_n$ no aparecen en ninguna ecuación: quedan libres.

Esa lectura de un renglón contesta las tres preguntas a la vez.

Teorema 13.1 (Consistencia, vista desde la SVD). Sea $A = U\Sigma V^\mathsf{T}$ de rango r y sea $\boldsymbol{c} = U^\mathsf{T}\boldsymbol{b}$.

(a) $A\boldsymbol{x} = \boldsymbol{b}$ tiene solución si y sólo si $c_{r+1} = \cdots = c_m = 0$, es decir si y sólo si $\boldsymbol{b}$ está en el subespacio generado por las primeras r columnas de U —que son, justamente, una base ortonormal de $C(A)$.

(b) Cuando hay solución, el conjunto de todas ellas es $\boldsymbol{x}_0 + N(A)$, con $N(A) = \operatorname{span}(\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n)$ de dimensión $n - r$. Hay una sola solución exactamente cuando $r = n$.

(c) $A\boldsymbol{x} = \boldsymbol{b}$ tiene solución para *todo* $\boldsymbol{b} \in \mathbb{R}^m$ si y sólo si $r = m$, es decir si y sólo si Σ no tiene filas nulas.

Demostración. Todo sale de (13.3). (a) El sistema es compatible si y sólo si las ecuaciones $0 = c_i$ con $i > r$ se cumplen; y $c_i = \boldsymbol{u}_i^\mathsf{T}\boldsymbol{b}$, así que pedir que se anulen para $i > r$ es pedir que $\boldsymbol{b}$ no tenga componente fuera de $\operatorname{span}(\boldsymbol{u}_1, \dots, \boldsymbol{u}_r) = C(A)$. (b) Las coordenadas $z_1, \dots, z_r$ quedan determinadas y $z_{r+1}, \dots, z_n$ son libres; deshaciendo el cambio, esas direcciones libres son $\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n$, que generan $N(A)$. Hay unicidad cuando no sobra ninguna, o sea cuando $r = n$. (c) Si $r = m$ no hay ecuaciones del segundo tipo y (a) no pide nada; si $r < m$, basta tomar $\boldsymbol{b} = \boldsymbol{u}_m$ para que $c_m = 1 \neq 0$. ∎

El ítem (c) merece un comentario, porque se lee directamente en la forma de Σ y decide el caso según las dimensiones.

Observación 13.2 (Los tres casos). Como $r \leq \min(m, n)$:

- Si $m > n$ (más ecuaciones que incógnitas), entonces $r \leq n < m$ y nunca puede ser $r = m$: *ninguna* matriz con más filas que columnas resuelve $A\boldsymbol{x} = \boldsymbol{b}$ para todo $\boldsymbol{b}$. Siempre hay lados derechos inalcanzables, y éste es el caso de los datos: el que motiva todo el capítulo.
- Si $m = n$, la condición $r = m = n$ es que A sea invertible, o sea que todos los σ_i sean positivos; la solución es entonces única.
- Si $m < n$ (sistema subdeterminado), $r = m$ sí es posible, y entonces hay solución para todo $\boldsymbol{b}$, pero nunca es única: sobran $n - m \geq 1$ direcciones libres. Éste es el caso que hará falta la Sección 13.6 para elegir una.

En los tres casos la condición $r = m$ equivale a que las filas de A sean linealmente independientes, por el teorema de la dimensión (Teorema 1.9) aplicado a A^T.

Ejemplo 13.3. Sea

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}.$$

Acá $U = V = I$ y $\Sigma = A$, de modo que $\boldsymbol{c} = \boldsymbol{b}$ y el sistema desacoplado es $z_1 = 1$, $z_2 = 2$, $0 = 3$. La tercera ecuación es imposible: $\boldsymbol{b} \notin C(A)$. Lo que sobra es exactamente la tercera coordenada, y su tamaño —el 3— va a ser el error mínimo que podremos conseguir.

El Ejemplo 13.3 ya sugiere qué hacer cuando el sistema es incompatible: las ecuaciones $0 = c_i$ no se pueden arreglar, pero tampoco dependen de $\boldsymbol{x}$. Si en vez de exigir igualdad medimos el error, esas componentes aportan una constante y todo lo demás se puede anular.

13.2 El problema de mínimos cuadrados

13.2.1 De dónde viene

En un modelo de **regresión lineal** se observan m individuos, de cada uno se miden n predictores y una respuesta, y se quiere explicar la respuesta como combinación lineal de los predictores:

$$\boldsymbol{y} \approx X\boldsymbol{\beta}, \qquad X \in \mathbb{R}^{m\times n}, \quad \boldsymbol{\beta} \in \mathbb{R}^n, \quad \boldsymbol{y} \in \mathbb{R}^m.$$

La matriz X se llama **matriz de diseño** y tiene en su fila i los predictores del individuo i; el vector $\boldsymbol{\beta}$ son los coeficientes que se quieren estimar. Como hay muchos más individuos que predictores, estamos en el caso $m > n$ de la Observación 13.2: el sistema $X\boldsymbol{\beta} = \boldsymbol{y}$ es incompatible salvo casualidad. En lugar de resolverlo se busca el $\boldsymbol{\beta}$ que deje el **residuo** $\boldsymbol{r} = \boldsymbol{y} - X\boldsymbol{\beta}$ lo más chico posible.

Definición 13.4 (Problema de mínimos cuadrados). Dados $A \in \mathbb{R}^{m\times n}$ y $\boldsymbol{b} \in \mathbb{R}^m$, una **solución de mínimos cuadrados** es cualquier $\hat{\boldsymbol{x}} \in \mathbb{R}^n$ que realice

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} \|A\boldsymbol{x} - \boldsymbol{b}\|_2 .$$

Medimos con la norma euclídea y no con otra por dos razones que conviene tener presentes: porque es la única que viene de un producto interno —así que minimizar es proyectar, y hay fórmula cerrada— y porque es invariante por matrices ortogonales (Corolario 8.30), que es lo que permite el cambio de variables de (13.2). Con $\|\cdot\|_2$ reemplazada por $\|\cdot\|_1$ o $\|\cdot\|_\infty$ el problema sigue teniendo sentido, pero deja de ser una proyección y se resuelve con otras herramientas.

13.2.2 Existencia, y todas las soluciones

El mismo cambio de variables de la sección anterior resuelve el problema de un saque. No hace falta ningún argumento de compacidad ni de convexidad: la solución se escribe.

Teorema 13.5 (Mínimos cuadrados con la SVD). Sea $A = U\Sigma V^{\mathsf{T}}$ de rango r, sea $\boldsymbol{b} \in \mathbb{R}^m$ y sea $\boldsymbol{c} = U^{\mathsf{T}}\boldsymbol{b}$. Entonces, con $\boldsymbol{z} = V^{\mathsf{T}}\boldsymbol{x}$,

$$\|A\boldsymbol{x} - \boldsymbol{b}\|_2^2 = \sum_{i=1}^{r}\big(\sigma_i z_i - c_i\big)^2 \;+\; \sum_{i=r+1}^{m} c_i^2. \tag{13.4}$$

En consecuencia:

(a) El problema *siempre* tiene solución, y el valor mínimo es $\left(\sum_{i>r} c_i^2\right)^{1/2}$, que no depende de $\boldsymbol{x}$.

(b) $\hat{\boldsymbol{x}} = V\hat{\boldsymbol{z}}$ es solución si y sólo si $\hat{z}_i = c_i/\sigma_i$ para $i \le r$, quedando $\hat{z}_{r+1}, \dots, \hat{z}_n$ *libres*.

(c) El conjunto de soluciones es un subespacio afín de dimensión $n-r$: dos soluciones difieren en un vector de $N(A)$. Hay una sola exactamente cuando $r = n$.

(d) Todas las soluciones dan el mismo vector ajustado $A\hat{\boldsymbol{x}}$.

Demostración. Como U es ortogonal, $\|A\boldsymbol{x} - \boldsymbol{b}\|_2 = \left\|U^{\mathsf{T}}(A\boldsymbol{x} - \boldsymbol{b})\right\|_2 = \|\Sigma\boldsymbol{z} - \boldsymbol{c}\|_2$. El vector $\Sigma\boldsymbol{z}$ tiene $\sigma_i z_i$ en las primeras r coordenadas y ceros en las últimas $m - r$, de donde sale (13.4) sumando coordenada a coordenada.

La segunda suma de (13.4) es una constante: no hay nada que hacer con ella. La primera es una suma de cuadrados independientes, cada uno anulable eligiendo $z_i = c_i/\sigma_i$, lo cual prueba (a) y (b). Para (c), deshaciendo el cambio, las direcciones libres son $\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n$, que generan $N(A)$ (Teorema 13.1(b)). Para (d), si $\hat{\boldsymbol{x}}$ y $\hat{\boldsymbol{x}}'$ son soluciones, su diferencia está en $N(A)$ y entonces $A\hat{\boldsymbol{x}} = A\hat{\boldsymbol{x}}'$. ∎

Observación 13.6 (Dónde falla el argumento "la función crece")**.** Es tentador probar la existencia diciendo que $f(\boldsymbol{x}) = \|A\boldsymbol{x} - \boldsymbol{b}\|_2^2$ es continua y tiende a $+\infty$ cuando $\|\boldsymbol{x}\|_2 \to \infty$, y que por lo tanto alcanza un mínimo. El argumento es correcto *sólo* si $N(A) = \{\boldsymbol{0}\}$. Si hay núcleo, f no crece: es **constante** en cada dirección del núcleo, porque $A(\boldsymbol{x} + t\boldsymbol{v}) = A\boldsymbol{x}$ para $\boldsymbol{v} \in N(A)$. Por ejemplo, con $A = \left[\begin{smallmatrix} 1 & 1 \\ 1 & 1 \end{smallmatrix}\right]$ y $\boldsymbol{b} = (1, 0)^{\mathsf{T}}$, la función f vale 1 sobre toda la recta $t\,(1, -1)^{\mathsf{T}}$. El mínimo igual existe —lo dice el Teorema 13.5— pero por otra razón, y es justamente el caso de núcleo no trivial el que nos va a ocupar de acá en adelante.

13.2.3 La lectura geométrica

El Teorema 13.5 dice qué es $A\hat{\boldsymbol{x}}$ sin nombrarlo: reconstruyendo, $A\hat{\boldsymbol{x}} = U\Sigma\hat{\boldsymbol{z}}$ tiene coordenadas $c_1, \dots, c_r, 0, \dots, 0$ en la base $\boldsymbol{u}_1, \dots, \boldsymbol{u}_m$, o sea que es la proyección ortogonal de $\boldsymbol{b}$ sobre $C(A) = \operatorname{span}(\boldsymbol{u}_1, \dots, \boldsymbol{u}_r)$.

Corolario 13.7 (Mínimos cuadrados es proyectar)**.** Con la notación anterior,

$$A\hat{\boldsymbol{x}} = P_{C(A)}\,\boldsymbol{b} = U_r U_r^{\mathsf{T}}\,\boldsymbol{b}, \qquad \boldsymbol{r} = \boldsymbol{b} - A\hat{\boldsymbol{x}} \;\perp\; C(A),$$

donde $U_r = [\,\boldsymbol{u}_1 \;\cdots\; \boldsymbol{u}_r\,]$. El residuo $\boldsymbol{r}$ es la componente de $\boldsymbol{b}$ en $N(A^{\mathsf{T}})$, y su longitud es el mínimo $\left(\sum_{i>r} c_i^2\right)^{1/2}$.

13.3 Las ecuaciones normales

La Figura 13.1 da una caracterización que no menciona la SVD y que es la que se usa para calcular: que el residuo sea ortogonal a $C(A)$ equivale a que sea ortogonal a cada columna de A, y apilando esas n condiciones en una sola ecuación matricial —como en la Sección 1.5— queda $A^{\mathsf{T}}(\boldsymbol{b} - A\hat{\boldsymbol{x}}) = \boldsymbol{0}$.

Teorema 13.8 (Ecuaciones normales)**.** $\hat{\boldsymbol{x}}$ es solución de mínimos cuadrados si y sólo

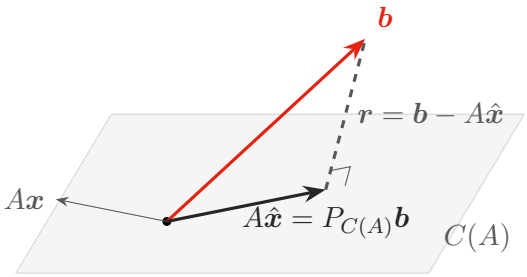


Figura 13.1. Mínimos cuadrados en $\mathbb{R}^m$. Los vectores $A\boldsymbol{x}$ barren el plano $C(A)$. El más cercano a $\boldsymbol{b}$ es el pie de la perpendicular, $A\hat{\boldsymbol{x}}$, y el residuo $\boldsymbol{r}$ queda ortogonal a todo el plano. El mínimo $\|\boldsymbol{r}\|_2$ es la distancia de $\boldsymbol{b}$ a $C(A)$.

si

$$A^{\mathsf{T}}A\,\hat{\boldsymbol{x}} = A^{\mathsf{T}}\boldsymbol{b} \tag{13.5}$$

Además este sistema *siempre* es compatible, aunque $A\boldsymbol{x} = \boldsymbol{b}$ no lo sea.

Demostración. Para cualquier $\boldsymbol{x}$ escribimos $A\boldsymbol{x} - \boldsymbol{b} = A(\boldsymbol{x} - \hat{\boldsymbol{x}}) - (\boldsymbol{b} - A\hat{\boldsymbol{x}})$. Si vale (13.5), el segundo sumando es ortogonal a $C(A)$ y el primero está en $C(A)$, así que por Pitágoras

$$\|A\boldsymbol{x} - \boldsymbol{b}\|_2^2 = \|A(\boldsymbol{x} - \hat{\boldsymbol{x}})\|_2^2 + \|\boldsymbol{b} - A\hat{\boldsymbol{x}}\|_2^2 \;\geq\; \|\boldsymbol{b} - A\hat{\boldsymbol{x}}\|_2^2 ,$$

con igualdad si y sólo si $A\boldsymbol{x} = A\hat{\boldsymbol{x}}$: luego $\hat{\boldsymbol{x}}$ es mínimo. Recíprocamente, si $\hat{\boldsymbol{x}}$ es mínimo, el Corolario 13.7 dice que $\boldsymbol{b} - A\hat{\boldsymbol{x}} \perp C(A)$, que es (13.5).

Para la compatibilidad, por (13.1) hay que ver que $A^{\mathsf{T}}\boldsymbol{b} \in C(A^{\mathsf{T}}A)$. Con la SVD, $A^{\mathsf{T}}A = V\Sigma^{\mathsf{T}}\Sigma V^{\mathsf{T}}$ y $\Sigma^{\mathsf{T}}\Sigma = \operatorname{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0)$, de donde $C(A^{\mathsf{T}}A) = \operatorname{span}(\boldsymbol{v}_1, \dots, \boldsymbol{v}_r) = C(A^{\mathsf{T}})$; y $A^{\mathsf{T}}\boldsymbol{b} \in C(A^{\mathsf{T}})$ siempre. ∎

Proposición 13.9 (El núcleo no cambia). $N(A^{\mathsf{T}}A) = N(A)$ y, por lo tanto, $\operatorname{rango}(A^{\mathsf{T}}A) = \operatorname{rango}(A)$.

Demostración. Si $A\boldsymbol{v} = \boldsymbol{0}$ entonces $A^{\mathsf{T}}A\boldsymbol{v} = \boldsymbol{0}$. Recíprocamente, si $A^{\mathsf{T}}A\boldsymbol{v} = \boldsymbol{0}$, multiplicando por $\boldsymbol{v}^{\mathsf{T}}$ a izquierda queda $0 = \boldsymbol{v}^{\mathsf{T}}A^{\mathsf{T}}A\boldsymbol{v} = \|A\boldsymbol{v}\|_2^2$, así que $A\boldsymbol{v} = \boldsymbol{0}$. Los rangos coinciden por el Teorema 1.9, porque las dos matrices tienen n columnas. ∎

Corolario 13.10 (El caso de rango completo por columnas). Son equivalentes: las columnas de A son linealmente independientes; $\operatorname{rango}(A) = n$; $A^{\mathsf{T}}A$ es invertible; la solución de mínimos cuadrados es única. En ese caso

$$\hat{\boldsymbol{x}} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\boldsymbol{b}, \qquad P_{C(A)} = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}.$$

Demostración. Las tres primeras equivalen por la Proposición 13.9 ($A^{\mathsf{T}}A$ es cuadrada de $n \times n$ e invertible exactamente cuando su núcleo es trivial), y la cuarta por el Teorema 13.5(c). La fórmula de $\hat{\boldsymbol{x}}$ sale de despejar en (13.5), y la de la proyección de $A\hat{\boldsymbol{x}} = P_{C(A)}\boldsymbol{b}$ para todo $\boldsymbol{b}$. Que $P_{C(A)}$ así escrita es simétrica e idempotente se verifica directamente, y su traza es n (Corolario 5.11). ∎

Observación 13.11. Si $A\boldsymbol{x} = \boldsymbol{b}$ *sí* tiene solución, esa solución también cumple (13.5) y el residuo es nulo: mínimos cuadrados no estropea nada, extiende. Por eso (13.5) se puede usar siempre, sin preguntarse antes si el sistema era compatible.

13.4 Mínimos cuadrados con QR

Las ecuaciones normales son correctas pero no son la manera de calcular. La factorización QR del Capítulo 3 resuelve el problema sin formar nunca $A^\mathsf{T}A$.

Proposición 13.12 (Mínimos cuadrados por QR). Sea $A \in \mathbb{R}^{m\times n}$ con $\operatorname{rango}(A) = n$ y sea $A = QR$ una factorización reducida, con $Q \in \mathbb{R}^{m\times n}$ de columnas ortonormales ($Q^\mathsf{T}Q = I_n$) y $R \in \mathbb{R}^{n\times n}$ triangular superior e invertible. Entonces la solución de mínimos cuadrados es la del sistema triangular

$$R\,\hat{\boldsymbol{x}} = Q^\mathsf{T}\boldsymbol{b} \tag{13.6}$$

y la proyección sobre $C(A)$ es $P_{C(A)} = QQ^\mathsf{T}$.

Demostración. Reemplazando $A = QR$ en (13.5) y usando $Q^\mathsf{T}Q = I_n$,

$$A^\mathsf{T}A = R^\mathsf{T}Q^\mathsf{T}QR = R^\mathsf{T}R, \qquad A^\mathsf{T}\boldsymbol{b} = R^\mathsf{T}Q^\mathsf{T}\boldsymbol{b},$$

así que las ecuaciones normales son $R^\mathsf{T}R\hat{\boldsymbol{x}} = R^\mathsf{T}Q^\mathsf{T}\boldsymbol{b}$. Como R es invertible, R^T también, y se la puede cancelar: queda (13.6). Para la proyección, $A(A^\mathsf{T}A)^{-1}A^\mathsf{T} = QR(R^\mathsf{T}R)^{-1}R^\mathsf{T}Q^\mathsf{T} = QRR^{-1}R^{-\mathsf{T}}R^\mathsf{T}Q^\mathsf{T} = QQ^\mathsf{T}$. ∎

Dos ventajas, una práctica y otra conceptual. La práctica es que $R\hat{\boldsymbol{x}} = Q^\mathsf{T}\boldsymbol{b}$ se resuelve por sustitución hacia atrás, sin invertir nada. La conceptual es que $P_{C(A)} = QQ^\mathsf{T}$ hace evidente lo que la fórmula $A(A^\mathsf{T}A)^{-1}A^\mathsf{T}$ esconde: proyectar sobre $C(A)$ es escribir $\boldsymbol{b}$ en una base ortonormal de $C(A)$ y tirar lo que sobra. Son la misma matriz, pero sólo una de las dos se ve.

13.5 Por qué no se usan las ecuaciones normales

Hay además una razón de fondo para preferir QR, y es un corolario inmediato de lo que vimos en el Capítulo 12.

Proposición 13.13 (Formar $A^\mathsf{T}A$ eleva al cuadrado el número de condición). Sea $A \in \mathbb{R}^{m\times n}$ con $\operatorname{rango}(A) = n$ y valores singulares $\sigma_1 \geq \cdots \geq \sigma_n > 0$. Entonces los valores singulares de $A^\mathsf{T}A$ son $\sigma_1^2 \geq \cdots \geq \sigma_n^2$ y

$$\kappa_2(A^\mathsf{T}A) = \kappa_2(A)^2$$

Demostración. De $A = U\Sigma V^\mathsf{T}$ sale $A^\mathsf{T}A = V(\Sigma^\mathsf{T}\Sigma)V^\mathsf{T}$ con $\Sigma^\mathsf{T}\Sigma = \operatorname{diag}(\sigma_1^2, \ldots, \sigma_n^2)$, y como V es ortogonal eso es una diagonalización ortogonal y a la vez una SVD de $A^\mathsf{T}A$. Por el Lema 12.18, $\kappa_2(A^\mathsf{T}A) = \sigma_1^2/\sigma_n^2 = (\sigma_1/\sigma_n)^2 = \kappa_2(A)^2$. ∎

El número de condición mide cuántos dígitos se pueden perder (Capítulo 12): elevarlo al cuadrado significa perder el *doble* de dígitos. Y no es un peligro teórico.

Ejemplo 13.14 (Una matriz sana que se arruina al multiplicar). Sea, con $\varepsilon > 0$ chico,

$$A = \begin{bmatrix} 1 & 1 \\ \varepsilon & 0 \\ 0 & \varepsilon \end{bmatrix}, \qquad A^{\mathsf{T}}A = \begin{bmatrix} 1+\varepsilon^2 & 1 \\ 1 & 1+\varepsilon^2 \end{bmatrix}.$$

Los autovalores de $A^{\mathsf{T}}A$ son $2+\varepsilon^2$ y ε^2, de modo que $\sigma_1(A) = \sqrt{2+\varepsilon^2}$, $\sigma_2(A) = \varepsilon$ y

$$\kappa_2(A) = \frac{\sqrt{2+\varepsilon^2}}{\varepsilon} \approx \frac{\sqrt{2}}{\varepsilon}, \qquad \kappa_2(A^{\mathsf{T}}A) \approx \frac{2}{\varepsilon^2}.$$

Con $\varepsilon = 10^{-3}$: $\kappa_2(A) \approx 1{,}4 \cdot 10^3$, que en doble precisión no es ningún problema, mientras que $\kappa_2(A^{\mathsf{T}}A) \approx 2 \cdot 10^6$. Peor todavía: si ε^2 cae por debajo de la precisión de la máquina, al calcular $1+\varepsilon^2$ se redondea a 1, la matriz $A^{\mathsf{T}}A$ *se vuelve exactamente singular* y el método falla por completo —aunque las columnas de A sean, perfectamente, independientes. La factorización QR trabaja con A y no con $A^{\mathsf{T}}A$, y no sufre nada de esto.

13.6 La pseudoinversa

Falta el caso $\operatorname{rango}(A) = r < n$, donde el Teorema 13.5 dice que hay infinitas soluciones. Para quedarse con una hay que dar un criterio, y el natural es pedir la más corta. La SVD la señala sola: en el Teorema 13.5(b) las coordenadas $\hat{z}_{r+1}, \dots, \hat{z}_n$ quedaban libres, y como el cambio de variables conserva normas, $\|\hat{\boldsymbol{x}}\|_2 = \|\hat{\boldsymbol{z}}\|_2$ se minimiza poniéndolas en cero.

Definición 13.15 (Pseudoinversa de Moore–Penrose). Sea $A = U\Sigma V^{\mathsf{T}}$ con $\Sigma = \left[\begin{smallmatrix} D & 0 \\ 0 & 0 \end{smallmatrix}\right]$ y $D = \operatorname{diag}(\sigma_1, \dots, \sigma_r)$. La **pseudoinversa** de A es

$$A^{+} = V\,\Sigma^{+}\,U^{\mathsf{T}} \in \mathbb{R}^{n\times m}, \qquad \Sigma^{+} = \begin{bmatrix} D^{-1} & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{n\times m}.$$

Equivalentemente, agrupando como en (1.8),

$$A = \sum_{i=1}^{r} \sigma_i\, \boldsymbol{u}_i \boldsymbol{v}_i^{\mathsf{T}} \qquad \Longleftrightarrow \qquad A^{+} = \sum_{i=1}^{r} \frac{1}{\sigma_i}\, \boldsymbol{v}_i \boldsymbol{u}_i^{\mathsf{T}}. \tag{13.7}$$

La forma (13.7) dice en una línea qué hace A^{+}: invierte lo que A estira, en las mismas direcciones y al revés, y no toca nada de lo que A aplastó. Los σ_i nulos no se invierten —se dejan en cero— y ahí está toda la diferencia con una inversa.

Teorema 13.16 (La pseudoinversa resuelve mínimos cuadrados). Para todo $A \in \mathbb{R}^{m\times n}$ y todo $\boldsymbol{b} \in \mathbb{R}^m$:

(a) $A^{+}\boldsymbol{b}$ es solución de mínimos cuadrados, y el conjunto de todas las soluciones es

$$\mathcal{S} = A^{+}\boldsymbol{b} + N(A) = \left\{ A^{+}\boldsymbol{b} + (I - A^{+}A)\boldsymbol{z} \;:\; \boldsymbol{z} \in \mathbb{R}^n \right\}.$$

(b) $A^{+}\boldsymbol{b}$ es la *única* solución de norma mínima, y es la única que está en $C(A^{\mathsf{T}})$, es decir la única ortogonal a $N(A)$.

(c) $AA^{+} = P_{C(A)}$ y $A^{+}A = P_{C(A^{\mathsf{T}})}$.

Demostración. Con $\boldsymbol{c} = U^{\mathsf{T}}\boldsymbol{b}$, el vector $\Sigma^{+}\boldsymbol{c}$ tiene coordenadas c_i/σ_i para $i \le r$ y 0 para $i > r$. Por el Teorema 13.5(b) eso es exactamente una solución, la que elige libres $= 0$; y $A^{+}\boldsymbol{b} = V\Sigma^{+}\boldsymbol{c}$. Las demás se obtienen moviendo las coordenadas libres, que es sumar un elemento de $N(A)$: eso es (a).

Para (b), si $\hat{\boldsymbol{z}}$ es cualquier solución, $\|\hat{\boldsymbol{x}}\|_2^2 = \|\hat{\boldsymbol{z}}\|_2^2 = \sum_{i\le r}(c_i/\sigma_i)^2 + \sum_{i>r}\hat{z}_i^2$, donde la primera suma es la misma para todas: el mínimo se alcanza, y sólo se alcanza, anulando las coordenadas libres. Esa elección deja $\hat{\boldsymbol{x}} \in \operatorname{span}(\boldsymbol{v}_1, \dots, \boldsymbol{v}_r) = C(A^{\mathsf{T}})$, que es $N(A)^{\perp}$.

Para (c), $AA^{+} = U\Sigma\Sigma^{+}U^{\mathsf{T}} = U\left[\begin{smallmatrix} I_r & 0 \\ 0 & 0 \end{smallmatrix}\right]U^{\mathsf{T}} = U_r U_r^{\mathsf{T}}$, que es la proyección sobre $C(A)$ por el Corolario 13.7; y análogamente $A^{+}A = V_r V_r^{\mathsf{T}}$. ∎

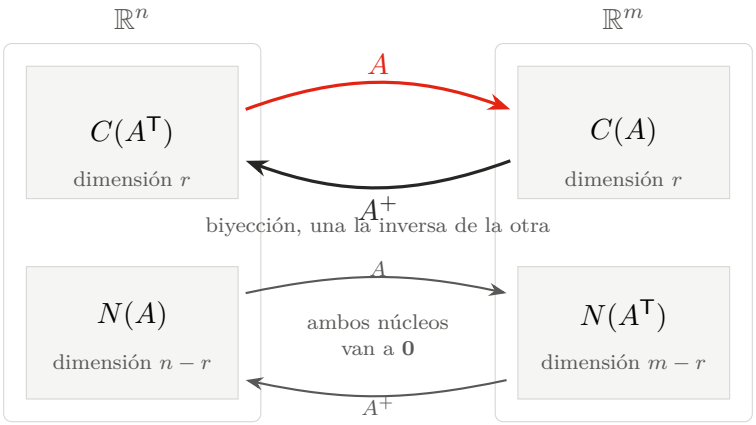


Figura 13.2. La pseudoinversa en el dibujo de los cuatro subespacios de la Sección 1.5. Restringida al espacio fila $C(A^{\mathsf{T}})$, la matriz A es una biyección sobre el espacio columna $C(A)$; A^{+} es exactamente su inversa. Los dos núcleos van a cero. Por eso $A^{+}\boldsymbol{b}$ cae en $C(A^{\mathsf{T}})$ —y es, entre todas las soluciones, la de norma mínima— y por eso $A^{+}A$ y AA^{+} son proyecciones y no la identidad.

Proposición 13.17 (Las cuatro ecuaciones de Penrose)**.** La matriz A^{+} de la Definición 13.15 verifica

$$\text{(P1) } AA^{+}A = A, \qquad \text{(P2) } A^{+}AA^{+} = A^{+},$$

$$\text{(P3) } (AA^{+})^{\mathsf{T}} = AA^{+}, \qquad \text{(P4) } (A^{+}A)^{\mathsf{T}} = A^{+}A,$$

y es la *única* matriz que las verifica a la vez.

Demostración. Escribamos $J = \Sigma\Sigma^{+} = \left[\begin{smallmatrix} I_r & 0 \\ 0 & 0 \end{smallmatrix}\right]$ de $m \times m$ y $K = \Sigma^{+}\Sigma$ de $n \times n$, análoga. Las dos son simétricas, idempotentes, y cumplen $\Sigma K = \Sigma = J\Sigma$ y $\Sigma^{+}J = \Sigma^{+} = K\Sigma^{+}$, como se ve multiplicando por bloques. Entonces

$$AA^{+}A = U\Sigma K V^{\mathsf{T}} = U\Sigma V^{\mathsf{T}} = A, \qquad A^{+}AA^{+} = V\Sigma^{+}JU^{\mathsf{T}} = V\Sigma^{+}U^{\mathsf{T}} = A^{+},$$

y $AA^{+} = UJU^{\mathsf{T}}$, $A^{+}A = VKV^{\mathsf{T}}$ son simétricas por serlo J y K. La unicidad es el Ejercicio 13.4. ∎

Observación 13.18 (Casos particulares)**.** La pseudoinversa generaliza a la inversa en todos los sentidos razonables:

- Si A es cuadrada e invertible, $A^{+} = A^{-1}$ (todos los $\sigma_i > 0$ y $\Sigma^{+} = \Sigma^{-1}$).
- Si $\operatorname{rango}(A) = n$ (columnas independientes), $A^{+} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ y se recupera el Corolario 13.10.
- Si $\operatorname{rango}(A) = m$ (filas independientes), $A^{+} = A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}$, y $A^{+}\boldsymbol{b}$ es la solución de norma mínima del sistema compatible $A\boldsymbol{x} = \boldsymbol{b}$ —el caso subdeterminado de la Observación 13.2.
- Si $A = \boldsymbol{u}\boldsymbol{v}^{\mathsf{T}}$ tiene rango uno, entonces $A^{+} = \dfrac{1}{\|\boldsymbol{u}\|_2^2\,\|\boldsymbol{v}\|_2^2}\,\boldsymbol{v}\boldsymbol{u}^{\mathsf{T}}$.

Observación 13.19 (Cuando σ_r es chico: truncar)**.** La fórmula (13.7) tiene un $1/\sigma_i$ adentro, así que un valor singular chiquito amplifica por $1/\sigma_r$ todo el ruido que $\boldsymbol{b}$ tenga en la dirección $\boldsymbol{u}_r$. Formalmente la cuenta es correcta; numéricamente la solución de norma mínima puede ser enorme y no significar nada. Lo que se hace es cortar la suma:

$$A_k^{+} = \sum_{i=1}^{k} \frac{1}{\sigma_i}\,\boldsymbol{v}_i\boldsymbol{u}_i^{\mathsf{T}}, \qquad k < r,$$

que es la pseudoinversa de la SVD truncada A_k del Corolario 9.4. Se resigna algo de ajuste —por Eckart–Young (Teorema 9.6), exactamente lo que miden los σ_i descartados— a cambio de una solución estable. Es la misma idea que estuvo detrás de todo el Capítulo 9: quedarse con las direcciones que los datos determinan bien y descartar las que no.

13.7 Regresión lineal

Volvemos al principio, con $A = X$, $\boldsymbol{b} = \boldsymbol{y}$ y $\boldsymbol{x} = \boldsymbol{\beta}$. El estimador de mínimos cuadrados resuelve $X^{\mathsf{T}}X\hat{\boldsymbol{\beta}} = X^{\mathsf{T}}\boldsymbol{y}$, y es único exactamente cuando los predictores no tienen colinealidad exacta.

Ejemplo 13.20 (Ajustar una recta a tres puntos)**.** Queremos $y \approx \beta_0 + \beta_1 x$ para $(0,1)$, $(1,2)$, $(2,2)$. La matriz de diseño lleva una columna de unos para el término independiente:

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}.$$

Los tres puntos no están alineados, así que $X\boldsymbol{\beta} = \boldsymbol{y}$ es incompatible. Las ecuaciones normales son

$$X^{\mathsf{T}}X = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \qquad X^{\mathsf{T}}\boldsymbol{y} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}, \qquad \det(X^{\mathsf{T}}X) = 6 \neq 0,$$

y resolviendo el sistema de 2×2,

$$\hat{\boldsymbol{\beta}} = \frac{1}{6}\begin{bmatrix} 5 & -3 \\ -3 & 3 \end{bmatrix}\begin{pmatrix} 5 \\ 6 \end{pmatrix} = \frac{1}{6}\begin{pmatrix} 7 \\ 3 \end{pmatrix} = \begin{pmatrix} 7/6 \\ 1/2 \end{pmatrix}.$$

La recta ajustada es $\hat{y} = \frac{7}{6} + \frac{1}{2}x$. El residuo es

$$\boldsymbol{r} = \boldsymbol{y} - X\hat{\boldsymbol{\beta}} = \left(-\tfrac{1}{6},\ \tfrac{1}{3},\ -\tfrac{1}{6}\right)^{\mathsf{T}}, \qquad \|\boldsymbol{r}\|_2^2 = \tfrac{1}{6},$$

y se verifica $X^{\mathsf{T}}\boldsymbol{r} = \mathbf{0}$: la primera coordenada dice que los residuos suman cero —porque X tiene la columna de unos— y la segunda, que no están correlacionados con x. Geométricamente, $\boldsymbol{y} \in \mathbb{R}^3$ se proyectó sobre el plano $C(X)$, que es la Figura 13.1 con $m = 3$ y $n = 2$.

Observación 13.21 (Colinealidad). Si dos predictores son combinación lineal de los otros, $\operatorname{rango}(X) < n$ y hay infinitos $\hat{\boldsymbol{\beta}}$. Todos dan *el mismo* ajuste $X\hat{\boldsymbol{\beta}}$ y los mismos residuos —el Teorema 13.5(d)—, pero coeficientes distintos, que se mueven a lo largo de $N(X)$. Es decir: el modelo predice igual de bien y los coeficientes individuales dejan de tener sentido por separado. La convención habitual es reportar $\hat{\boldsymbol{\beta}} = X^{+}\boldsymbol{y}$, la de norma mínima; en la práctica es más frecuente eliminar predictores redundantes, o pasar a las componentes principales del Capítulo 9, que por construcción no están correlacionadas.

Ejercicios

13.1 *(A mano.)* Para

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}$$

calcular $\hat{\boldsymbol{x}}$ por las ecuaciones normales, el residuo $\boldsymbol{r}$, la matriz de proyección $P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ y verificar que $P^{\mathsf{T}} = P = P^2$ y $\operatorname{tr}(P) = 2$.

13.2 Resolver "a ojo", usando sólo (13.3), los problemas de mínimos cuadrados con

$$\Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix},\ \boldsymbol{c} = (6, 2, 5)^{\mathsf{T}}; \qquad \Sigma = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix},\ \boldsymbol{c} = (4, 7)^{\mathsf{T}}.$$

En cada caso dar todas las soluciones, la de norma mínima y el valor del mínimo.

13.3 Calcular A^{+} para

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \quad A = \operatorname{diag}(2, 0), \quad A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad A = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix},$$

y verificar en cada caso las cuatro ecuaciones de Penrose. *Sugerencia:* las cuatro tienen rango uno; usar la última fórmula de la Observación 13.18. (Deberían dar, respectivamente, $\frac{1}{25}\left[\begin{smallmatrix} 1 & 2 \\ 2 & 4 \end{smallmatrix}\right]$, $\operatorname{diag}(\frac{1}{2}, 0)$, $\frac{1}{4}\left[\begin{smallmatrix} 1 & 1 \\ 1 & 1 \end{smallmatrix}\right]$ y $\left[\begin{smallmatrix} 0 & 0 \\ 1/2 & 0 \end{smallmatrix}\right]$.)

13.4 *(Unicidad de la pseudoinversa.)* Supongamos que X e Y verifican las cuatro ecuaciones de Penrose para la misma A. Probar que $X = Y$. *Sugerencia:* empezar por $X = XAX = X(AX)^{\mathsf{T}} = XX^{\mathsf{T}}A^{\mathsf{T}}$ y, usando $A^{\mathsf{T}} = (AYA)^{\mathsf{T}}$, llegar a $X = XAY$; hacer lo simétrico para $Y = XAY$.

13.5 Sea $A = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}$ y $b = 3$. Describir todas las soluciones de $A\boldsymbol{x} = b$, calcular A^{+} y verificar que $A^{+}b = (1, 1, 1)^{\mathsf{T}}$ es la de norma mínima, comparándola con $(3, 0, 0)^{\mathsf{T}}$. ¿Cuál es la interpretación geométrica?

13.6 Probar que, para toda A:

(a) $(A^{+})^{+} = A$ y $(A^{\mathsf{T}})^{+} = (A^{+})^{\mathsf{T}}$.

(b) $(\alpha A)^+ = \alpha^{-1} A^+$ si $\alpha \neq 0$.

(c) Si Q y P son ortogonales, $(QAP)^+ = P^{\mathsf{T}} A^+ Q^{\mathsf{T}}$.

(d) En cambio, $(AB)^+ \neq B^+ A^+$ en general: dar un contraejemplo de 2×2. *Sugerencia:* probar con dos matrices de rango uno.

13.7 Para la matriz del Ejercicio 13.1, construir una factorización QR reducida por Gram–Schmidt (Sección 3.7), resolver $R\hat{\boldsymbol{x}} = Q^{\mathsf{T}}\boldsymbol{b}$ por sustitución hacia atrás y comprobar que da lo mismo que las ecuaciones normales. Verificar además que QQ^{T} coincide con la matriz P del primer ejercicio.

13.8 Con $A = \left[\begin{smallmatrix} 1 & 1 \\ \varepsilon & 0 \\ 0 & \varepsilon \end{smallmatrix}\right]$ del Ejemplo 13.14:

(a) Calcular σ_1, σ_2, $\kappa_2(A)$ y $\kappa_2(A^{\mathsf{T}}A)$ exactamente, y verificar la Proposición 13.13.

(b) ¿A partir de qué ε la matriz $A^{\mathsf{T}}A$ se vuelve numéricamente singular en una máquina que distingue números hasta 10^{-16}? ¿Y a partir de qué ε se arruina A?

(c) Comprobarlo en la computadora, resolviendo el mismo problema de mínimos cuadrados por ecuaciones normales y por QR para $\varepsilon = 10^{-3}, 10^{-6}, 10^{-9}$.

13.9 Probar que AA^+ y A^+A son proyecciones ortogonales y que $\operatorname{tr}(AA^+) = \operatorname{tr}(A^+A) = \operatorname{rango}(A)$ (Corolario 5.11). Deducir que $I - A^+A$ es la proyección sobre $N(A)$, lo cual explica la parametrización $\mathcal{S} = A^+\boldsymbol{b} + (I - A^+A)\boldsymbol{z}$ del Teorema 13.16(a).

13.10 Sea $\hat{\boldsymbol{x}}$ cualquier solución de mínimos cuadrados y $\boldsymbol{r} = \boldsymbol{b} - A\hat{\boldsymbol{x}}$. Probar que

$$\|\boldsymbol{b}\|_2^2 = \|A\hat{\boldsymbol{x}}\|_2^2 + \|\boldsymbol{r}\|_2^2 ,$$

y que en regresión, si X tiene una columna de unos, los residuos suman cero. ¿Qué dice la primera identidad en términos de los c_i del Teorema 13.5?

13.11 *(Con datos.)* Tomar cualquiera de los conjuntos del Capítulo 11, elegir una variable como respuesta y el resto como predictores, y ajustar por mínimos cuadrados. Comparar la solución por ecuaciones normales, por QR y por `pinv`. Agregar después una columna que sea combinación lineal exacta de dos de las otras y repetir: ¿qué hace cada método? ¿Cambia el ajuste $X\hat{\boldsymbol{\beta}}$? ¿Y los coeficientes?

Bibliografía

[1] Rajendra Bhatia. *Matrix Analysis*, volume 169 of *Graduate Texts in Mathematics*. Springer, 1997. Incluye desigualdades de Weyl/Ky Fan para valores singulares.

[2] B. Blankertz, R. Tomioka, S. Lemm, M. Kawanabe, and K.-R. Müller. Optimizing spatial filters for robust EEG single-trial analysis. *IEEE Signal Processing Magazine*, 25:41–56, 2008.

[3] Carl Eckart and Gale Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3):211–218, September 1936.

[4] Ronald A. Fisher. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7:179–188, 1936.

[5] Gene H. Golub and Charles F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, 4th edition, 2013.

[6] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2 edition, 2009.

[7] Roger A. Horn and Charles R. Johnson. *Matrix Analysis*. Cambridge University Press, 2 edition, 2013. Ver el resultado de Weyl para valores singulares; p.ej., Teorema 3.3.16.

[8] Harold Hotelling. Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24:417–441, 498–520, 1933.

[9] Markelle Kelly, Rachel Longjohn, and Kolby Nottingham. The UCI machine learning repository. `https://archive.ics.uci.edu`. Datos de cáncer de pulmón y de siluetas de vehículos.

[10] Chi-Kwong Li and Gilbert Strang. An elementary proof of mirsky's low rank approximation theorem. *Electronic Journal of Linear Algebra*, 36:694–697, 2020.

[11] L. Mirsky. Symmetric gauge functions and unitarily invariant norms. *The Quarterly Journal of Mathematics*, 11(1):50–59, January 1960.

[12] Karl Pearson. On lines and planes of closest fit to systems of points in space. *Philosophical Magazine (6)*, 2(11):559–572, 1901.

[13] G. W. Stewart. On the early history of the singular value decomposition. *SIAM Review*, 35(4):551–566, 1993.

[14] Gilbert Strang. *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press, Wellesley, MA, 2019. Traducción al castellano de L. Forzani.

[15] Matthew Turk and Alex Pentland. Eigenfaces for recognition. *Journal of Cognitive Neuroscience*, 3(1):71–86, 1991.